

Probabilità per la psicologia

Modulo di richiamo

Corrado Caudek

22 settembre 2026

Come usare il modulo

Progetto UTET · Materiali digitali di supporto

Un percorso essenziale sugli elementi fondamentali della teoria della probabilità, pensato per affrontare l'inferenza bayesiana in psicologia con basi concettuali solide, notazione coerente ed esempi riproducibili.

Questo modulo accompagna il manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Non sostituisce il volume principale: raccoglie i richiami di probabilità necessari per comprenderne con maggiore sicurezza il linguaggio, i modelli e il flusso di lavoro inferenziale.

[Inizia il percorso](#) [Esamina la struttura](#) [Vai al companion principale](#)

Funzione

Richiamo propedeutico

Destinatari

Studenti e studiosi di psicologia

Prerequisiti

Algebra elementare e statistica descrittiva

Modalità

Studio sequenziale o consultazione

Il percorso è progressivo: ogni parte introduce concetti impiegati nelle successive. Per una prima lettura conviene seguire l'ordine proposto; in seguito il sito può essere usato come riferimento rapido durante lo studio del manuale.

01

Orientarsi

Leggi l'apertura del capitolo e identifica obiettivi, prerequisiti e concetti centrali.

02

Ricostruire

Riproduci i passaggi essenziali, le formule e gli esempi con carta e penna.

03

Collegare

Riconduci ogni concetto al ruolo che svolge in prior, verosimiglianza e posterior.

Percorso del modulo

Le quattro parti conducono dal significato della probabilità alla verosimiglianza e all'aggiornamento bayesiano. Le appendici raccolgono la notazione e gli strumenti matematici da consultare quando necessario.

Parte 1 · Capitoli 1–5 · Livello base

Fondamenti della probabilità

Interpretazione bayesiana, assiomi, coerenza, calcolo combinatorio, probabilità condizionata e teorema di Bayes.

[Apri la parte 1](#)

Parte 2 · Capitoli 6–9 · Livello intermedio

Variabili casuali e distribuzioni

Variabili discrete e continue, funzioni di distribuzione, valore atteso, varianza, covarianza e correlazione.

[Apri la parte 2](#)

Parte 3 · Capitoli 10–12 · Livello intermedio

Distribuzioni fondamentali

Il vocabolario probabilistico impiegato nei modelli: distribuzioni discrete, continue e loro proprietà principali.

[Apri la parte 3](#)

Parte 4 · Capitoli 13–16 · Livello avanzato

Verso l'inferenza

Campionamento, informazione, precisione, verosimiglianza e passaggio dalla probabilità all'aggiornamento bayesiano.

[Apri la parte 4](#)

Appendici · Consultazione

Strumenti matematici

Simbologia, notazione e richiami matematici destinati alla consultazione durante lo studio dei capitoli.

[Consulta le appendici](#)

Questo sito privilegia interpretazione, formule essenziali ed esempi minimali. Gli approfondimenti tecnici e il codice sono disponibili quando servono, ma non interrompono il filo concettuale principale.

Collegamento con il manuale

Il modulo prepara i concetti probabilistici utilizzati nel manuale principale. In particolare, chiarisce il significato della probabilità come rappresentazione dell'incertezza, introduce il linguaggio delle variabili casuali e delle distribuzioni e costruisce il passaggio dalla probabilità condizionata alla verosimiglianza e alla distribuzione a posteriori.

Per affrontare il manuale non è necessario memorizzare ogni derivazione. È invece importante saper riconoscere:

- che cosa rappresentano gli eventi e le variabili casuali;
- come si legge una probabilità condizionata;
- quale ruolo svolgono valore atteso, varianza e dipendenza;
- perché la verosimiglianza collega un modello ai dati osservati;
- come il teorema di Bayes formalizza l'aggiornamento delle credenze.

Informazioni editoriali

Il materiale fa parte del progetto UTET a supporto del manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Il sito è aggiornabile e può quindi integrare correzioni, chiarimenti ed esempi successivi alla pubblicazione del volume.

- **Autore:** Corrado Caudek ([ORCID 0000-0002-1404-0420](#))
- **Segnalazioni:** usa il comando “Segnala un problema” presente nelle pagine oppure il [repository GitHub](#)
- **Licenza:** [CC BY-NC-ND 4.0](#)

Parte I

PARTE 1: Fondamenti della probabilità

Interpretazione bayesiana della probabilità

i In sintesi

Da sapere La probabilità bayesiana rappresenta un grado di credenza razionale relativo alle informazioni disponibili. La coerenza impone vincoli alle valutazioni probabilistiche e l'aggiornamento bayesiano descrive come modificarle quando arrivano nuovi dati.

Da saper fare Distinguere l'interpretazione bayesiana da quella frequentista; riconoscere il ruolo dello stato informativo; spiegare il significato della coerenza; individuare *prior*, verosimiglianza e *posterior* in un semplice problema di aggiornamento.

Introduzione

In questo capitolo adotteremo una **prospettiva bayesiana** sulla probabilità. Secondo questo approccio, la probabilità non è una proprietà intrinseca degli eventi, né una semplice frequenza osservata, ma un **grado di credenza razionale** che un agente assegna a un'affermazione sulla base delle informazioni disponibili. Questo punto di vista, sviluppato da pensatori quali Thomas Bayes, Pierre-Simon Laplace e Bruno de Finetti, fornisce una cornice concettuale particolarmente adatta alle scienze psicologiche, in cui spesso si è chiamati a ragionare in condizioni di informazione parziale, errore di misura e variabilità individuale.

Dal punto di vista bayesiano, gli assiomi della probabilità non descrivono proprietà oggettive dei fenomeni aleatori, ma costituiscono vincoli di coerenza logica per un sistema di credenze razionali. Essi specificano come le nostre valutazioni dell'incertezza devono relazionarsi tra loro per evitare contraddizioni. La violazione di questi vincoli renderebbe l'assegnazione delle probabilità internamente incoerente, esponendo il soggetto a valutazioni paradossali e a scelte decisionali sistematicamente svantaggiose.

Nel corso del modulo ricorreremo spesso a simulazioni al computer. Il loro sco-

po non è definire astrattamente che cosa sia la probabilità, ma mostrare come un sistema di credenze coerente si comporti quando entra in contatto con i dati empirici. Le simulazioni renderanno quindi visibili le conseguenze operative dei modelli probabilistici.

1.1 Perché la probabilità bayesiana in psicologia?

L'approccio bayesiano offre un quadro epistemologico e statistico particolarmente adatto alla ricerca psicologica, grazie a tre proprietà distintive rispetto al paradigma frequentista.

Integrazione di informazioni complementari.

Molti studi, in particolare quelli di ambito clinico e sperimentale, si basano su campioni di dimensioni ridotte (n tra 20 e 50), nei quali l'informazione empirica è limitata. L'inferenza bayesiana può integrare formalmente le conoscenze pregresse attraverso la distribuzione a priori, combinandole in modo esplicito con l'informazione fornita dai dati.

Formalizzazione della conoscenza cumulativa.

La ricerca psicologica non procede mai da un vuoto teorico, ma si innesta su teorie consolidate e risultati precedenti. L'approccio bayesiano traduce questa dimensione cumulativa in termini matematici, rendendo esplicito e verificabile l'aggiornamento delle credenze alla luce di nuovi dati, un processo che nei metodi tradizionali rimane spesso implicito.

Interpretabilità diretta dei risultati.

L'inferenza bayesiana consente di esprimere conclusioni nel linguaggio della probabilità, per esempio: «Dato il modello e i dati osservati, la probabilità che l'effetto sia compreso tra 0.2 e 0.8 è del 95%». Questa formulazione evita le note ambiguità degli intervalli di confidenza frequentisti, facilita la comunicazione scientifica e permette di tradurre i risultati in decisioni cliniche, indicazioni pratiche e sviluppo teorico.

i Esempio concreto

Scenario. Uno psicologo clinico intende valutare l'efficacia di un nuovo protocollo per l'ansia attraverso uno studio pilota condotto su un campione ristretto ($n = 15$).

Approccio tradizionale. «La numerosità campionaria è insufficiente per garantire una potenza statistica adeguata. Non è possibile trarre conclusioni affidabili senza ampliare il campione».

Approccio bayesiano. «Posso integrare le evidenze della letteratura preesistente definendo un *prior* informativo, per poi aggiornarlo con i dati raccolti sui 15 pazienti. Ne risulterà una distribuzione a posteriori che quantificherà sia l'effetto stimato sia l'incertezza residua, fornendo una base esplicita per la decisione clinica anche in presenza di dati limitati».

💡 Prerequisiti

Questo è il capitolo introduttivo del modulo. Non sono richiesti prerequisiti specifici oltre a conoscenze elementari di algebra e statistica descrittiva.

Come risorse opzionali possono essere consultate l'Appendice [A](#) e i richiami matematici e notazionali del [Companion](#).

Panoramica del capitolo

Il capitolo sviluppa il percorso seguente:

1. distingue l'incertezza epistemica da quella ontologica;
2. introduce il decisore coerente e il soggettivismo di de Finetti;
3. definisce la probabilità come grado di credenza razionale;
4. collega la coerenza agli assiomi della probabilità;
5. confronta le interpretazioni bayesiana e frequentista;
6. chiarisce il ruolo illustrativo delle simulazioni;
7. anticipa la logica dell'aggiornamento bayesiano e le sue applicazioni in psicologia.

i Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()

apply_visual_theme()
```

1.2 Casualità e incertezza: due prospettive a confronto

L'incertezza è una condizione costante dell'esperienza umana: non possiamo ricostruire il passato con assoluta precisione, né prevedere il futuro con certezza, e spesso la complessità del presente ci sfugge. Come osserva Spiegelhalter (2024), questa condizione ci invita a considerare la casualità non come una proprietà misteriosa degli eventi, ma come un modello operativo che, rinunciando alle predizioni deterministiche, ci permette di individuare delle regolarità statistiche utili per interpretare la realtà e prendere decisioni.

Per analizzare sistematicamente l'incertezza, è utile distinguere due dimensioni fondamentali dello stato epistemico. Questa distinzione chiarisce quali aspetti dell'incertezza sono radicati nella struttura del mondo e quali, invece, nei limiti della nostra conoscenza. Ciò è una premessa necessaria per comprendere il ruolo della probabilità nella ricerca psicologica.

1.2.1 Incertezza epistemica

L'**incertezza epistemica** (dal greco ἐπιστήμη, “conoscenza”) deriva da informazioni insufficienti o di scarsa qualità. È, almeno in linea di principio, riducibile: nuovi dati, disegni sperimentali più accurati o misurazioni più affidabili possono infatti ridurre l'impatto. In psicologia, questa forma di incertezza è onnipresente: campioni di dimensioni limitate, variabili non controllate, informazioni cliniche o anamnestiche incomplete ne sono esempi tipici.

1.2.2 Incertezza ontologica

L'**incertezza ontologica** (dal greco ὄντος, “essere”) riguarda invece l'imprevedibilità che sembra inerente ai fenomeni stessi. Non dipende dalle limitazioni del ricercatore e non scompare nemmeno in presenza di misurazioni estremamente precise. In ambito psicologico, rientrano in questa categoria la variabilità comportamentale residua anche in condizioni sperimentali controllate, la natura probabilistica delle decisioni in situazioni ambigue e fenomeni quali l'emergere di intuizioni, creatività o cambiamenti improvvisi della strategia cognitiva.

1.2.3 La sintesi bayesiana: l'incertezza come stato epistemico

Nel quadro bayesiano adottato in questo manuale, le due forme di incertezza, epistemica e ontologica, sono trattate in modo unificato. Ciò che viene spesso descritto come incertezza ontologica viene formalizzato mediante lo stesso strumento: l'assegnazione di probabilità.

Questa scelta si basa su una premessa epistemologica: l'accesso dell'osservatore allo stato del sistema è sempre parziale. La probabilità diventa quindi lo strumento con cui quantifichiamo sistematicamente i limiti della nostra conoscenza, a prescindere dal fatto che questi derivino da informazioni incomplete o dalla complessità intrinseca del fenomeno.

Come osservò Laplace, un intelletto onnisciente che conoscesse tutte le forze della natura e la posizione di ogni particella, vedrebbe il futuro determinato con la stessa certezza con cui vede il passato. In un universo deterministico, l'impossibilità di previsioni perfette non dipende dalla natura del mondo, ma esclusivamente dall'incompletezza della nostra conoscenza.

Da questa prospettiva, la probabilità non è una proprietà intrinseca del mondo, ma una **conseguenza necessaria dei limiti cognitivi ed epistemici dell'osservatore**. È il nostro stato informativo, non il mondo in sé, a generare l'incertezza.

Questa interpretazione **epistemica della probabilità**, intesa come misura del grado di credenza razionale, costituisce il fondamento concettuale e metodologico dell'intero manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza. Fondamenti, workflow e applicazioni*. Tuttavia, un sistema di credenze, per quanto coerente, rimane astratto finché non viene utilizzato da un decisore. È a questo compito che ora rivolgiamo la nostra attenzione.

1.3 Il decisore coerente di fronte all'incertezza

La trattazione dell'incertezza come stato epistemico, illustrata in precedenza, trova il suo compimento operativo nella figura del decisore razionale. Il paradigma bayesiano non si limita a descrivere l'incertezza, ma fornisce strumenti per agire in modo coerente in sua presenza.

1.3.1 Il soggettivismo di de Finetti

Nel suo lavoro fondamentale, Bruno de Finetti ha adottato un approccio esplicitamente soggettivista al processo decisionale in condizioni di incertezza (Finetti, 1970). Le probabilità non sono proprietà intrinseche del mondo, ma valutazioni personali che esprimono quanto un agente ritenga plausibili i diversi stati possibili del sistema.

Di fronte alle stesse circostanze incerte, due decisori possono quindi divergere, talvolta marcatamente, nella stima delle probabilità, nella desiderabilità degli esiti o nella valutazione dell'influenza delle proprie azioni. Questa variabilità non rappresenta un difetto del ragionamento, ma una caratteristica inevitabile di qualsiasi processo decisionale reale.

Il paradigma bayesiano, tuttavia, non si limita a fornire una cornice soggettivista, ma propone anche un ideale matematico di razionalità interna che specifica come dovrebbe comportarsi un decisore che, pur mantenendo le proprie valutazioni soggettive, rispetta un requisito fondamentale: la **coerenza**.

Essere coerenti significa che le proprie credenze e preferenze non devono entrare in contraddizione, in modo da evitare perdite certe quando le valutazioni vengono tradotte in decisioni. Il formalismo matematico che introdurremo non mira a descrivere fedelmente le credenze di ogni decisore in ogni situazione, ma fornisce famiglie di modelli sufficientemente flessibili da rappresentare almeno una versione coerente e operativa di tali credenze.

Nel quadro bayesiano, la coerenza è il massimo che possiamo ragionevolmente richiedere a un decisore. Non gli imponiamo di compiere scelte "giuste" secondo criteri esterni, ma solo di mantenere un sistema di credenze compatibile con le proprie valutazioni. In questa prospettiva, tutto è soggettivo, persino affermazioni apparentemente oggettive come "il vero valore del parametro è x ". Formulazioni di questo tipo vanno interpretate come abbreviazioni di: "Sono convinto che il vero valore del parametro sia x ". Questa rilettura, lungi dall'essere un semplice dettaglio linguistico, permette di accettare le divergenze tra agenti senza rinunciare ai vincoli della coerenza (Heard, 2021).

1.3.2 L'incertezza soggettiva

Le fonti di incertezza che complicano il processo decisionale sono molteplici: eventi futuri non ancora verificati, circostanze passate di cui non si ha notizia, informazioni in possesso di altri ma non del decisore, conoscenze dimenticate. Il paradigma bayesiano tratta tutte queste forme in modo unitario: qualsiasi aspetto rispetto al

quale il decisore è incerto deve essere esplicitamente riconosciuto e incorporato nel processo decisionale. Il framework considera esclusivamente lo stato attuale delle conoscenze del decisore, a prescindere da ciò che egli dovrebbe conoscere in linea di principio (Heard, 2021).

La gestione operativa di questa molteplicità avviene attraverso lo strumento formale già introdotto, ovvero la probabilità come **grado di credenza razionale**, che consente di quantificare in modo coerente l'incertezza soggettiva alla luce delle informazioni disponibili.

1.3.3 Coerenza e credenze: il filo conduttore

In sintesi, l'approccio bayesiano unifica due istanze apparentemente distanti: da un lato, il riconoscimento della soggettività e della variabilità interindividuale nelle valutazioni probabilistiche; dall'altro, l'esigenza di un vincolo formale di coerenza che impedisca contraddizioni interne. La probabilità diventa il linguaggio comune in cui si esprime l'incertezza, epistemica, ontologica o soggettiva che sia, e il criterio di coerenza garantisce che tale linguaggio venga impiegato in modo logicamente inattaccabile.

Questa duplice anima, soggettiva nei contenuti e oggettiva nella sintassi formale, costituisce il nucleo metodologico dell'inferenza bayesiana e sarà alla base di tutti gli sviluppi tecnici presentati nel manuale.

i Credere e avere fiducia: due concetti distinti?

Nel linguaggio quotidiano, "credere" è un atteggiamento categorico: o si crede o non si crede. L'approccio bayesiano introduce invece i gradi di credenza (*credence*): non solo credo che domani piovgerà, ad esempio, ma assegno a questa previsione una fiducia del 70%. I gradi di credenza permettono di quantificare l'incertezza in modo granulare e coerente, mentre le credenze categoriche semplificano le decisioni pratiche (Jackson, 2020). Questi due approcci sono complementari: nel manuale adotteremo sistematicamente il primo, perché più adatto all'analisi dei dati psicologici.

1.4 Probabilità come grado di credenza

1.4.1 La visione bayesiana soggettivista

Nel paradigma bayesiano, la probabilità è interpretata come un **grado di fiducia razionale** nel verificarsi di un evento, sulla base delle informazioni disponibili in un determinato momento.

La probabilità è il grado di credenza (plausibilità) assegnato a un'affermazione, in funzione di uno specifico stato informativo.

Questa definizione si basa su quattro caratteristiche interconnesse:

- **Soggettività** — individui diversi, con conoscenze e informazioni differenti, possono legittimamente attribuire probabilità diverse allo stesso evento.
- **Razionalità** — tale soggettività non è arbitraria: le probabilità devono rispettare gli assiomi della probabilità, che garantiscono coerenza interna.
- **Condizionalità** — ogni probabilità è intrinsecamente legata all'insieme informativo disponibile: parlare di probabilità senza specificare "dato ciò che so" è, in senso bayesiano, incompleto.
- **Aggiornabilità** — al sopraggiungere di nuove evidenze, le probabilità vengono riviste in modo sistematico attraverso il meccanismo dell'aggiornamento bayesiano.

Queste proprietà rendono la probabilità uno strumento flessibile ma rigoroso per rappresentare e gestire l'incertezza nei contesti reali di decisione e analisi dei dati.

i Applicazione clinica

Lo stesso punteggio ottenuto in un test per la depressione può avere implicazioni diverse a seconda che il soggetto provenga da un reparto psichiatrico (dove la prevalenza è elevata) o dalla popolazione generale (dove la prevalenza è bassa). La probabilità di depressione non è una proprietà intrinseca del test, ma un grado di credenza che integra conoscenze pregresse (prevalenza, anamnesi) ed evidenza empirica (sensibilità, specificità) attraverso il ragionamento bayesiano.

1.4.2 La coerenza: l'argomento della scommessa olandese

Se la probabilità è un grado di credenza soggettivo, come si possono giustificare gli assiomi matematici che la governano? La risposta è il celebre *argomento della scommessa olandese* (*Dutch Book*), sviluppato da Ramsey e de Finetti.

Supponiamo che un decisore sia disposto a scommettere denaro in base alle proprie valutazioni probabilistiche. Se queste sono internamente incoerenti, esiste sempre una combinazione di scommesse che, secondo lui, sono accettabili, ma producono una **perdita certa**, qualunque sia l'esito del fenomeno. L'incoerenza non è quindi un problema astratto, ma una forma di vulnerabilità strategica: un sistema di credenze incoerente può essere sfruttato sistematicamente a svantaggio dell'agente.

Esempio: al lancio di una moneta, un decisore assegna probabilità $2/3$ sia a *Testa* sia a *Croce*. È disposto a pagare 2 € per ricevere 3 € se esce "testa" e lo stesso per "croce". Accettando entrambe le scommesse, paga 4 € e incassa comunque solo 3 €, subendo una perdita certa di 1 €. L'incoerenza sta nel fatto che la somma delle probabilità ($4/3 > 1$), che viola l'assioma fondamentale della probabilità.

Questo esempio mostra che il rispetto degli assiomi probabilistici non è un dettaglio tecnico, ma una condizione necessaria per un ragionamento coerente: chi li viola è esposto a conseguenze pratiche negative, a prescindere da come si svolgeranno i fatti.

1.4.3 Gli assiomi di Kolmogorov

Ramsey e de Finetti hanno dimostrato che per evitare perdite certe è necessario rispettare specifici vincoli di coerenza. Questi vincoli sono formalizzati negli **assiomi della probabilità** (introdotti da Kolmogorov), che impongono che i gradi di credenza siano non negativi, che lo spazio di tutte le possibilità abbia probabilità 1 e che la probabilità di eventi mutuamente esclusivi sia additiva. La loro formulazione esatta e le loro conseguenze saranno esaminate in dettaglio nel capitolo successivo (Capitolo 2). Per ora, è sufficiente sapere che questi assiomi non sono mere convenzioni matematiche, ma esprimono le condizioni minime per un sistema di credenze internamente coerente.

1.4.4 Implicazioni per la psicologia

L'argomento della scommessa olandese attribuisce alle regole della probabilità un significato pragmatico: non si limitano a descrivere relazioni formali tra eventi, ma stabiliscono anche i vincoli che un sistema di credenze deve rispettare per poter guidare scelte razionali in condizioni di incertezza.

La psicologia cognitiva ha ampiamente documentato deviazioni sistematiche da questi criteri di coerenza (Griffiths et al., 2024). L'argomento della scommessa olandese chiarisce la portata pratica di tali deviazioni: non si tratta di distorsioni cognitive astratte, ma di vulnerabilità decisionali che possono tradursi in esiti prevedibilmente sfavorevoli ogni volta che le credenze orientano il comportamento. In questo senso, il rispetto degli assiomi probabilistici non è solo un requisito logico, ma una condizione per un agire razionale nel mondo.

Per approfondire

Una trattazione più formale dell'argomento del *Dutch Book*, insieme al *Principio Principale* di Lewis (che collega credenze soggettive e probabilità oggettive) e alle diverse misure quantitative dell'evidenza, si trova nel capitolo sui fondamenti epistemologici del sito [companion](#).

1.5 Le origini storiche

Le radici dell'approccio bayesiano affondano nel Settecento, quando Thomas Bayes (1701–1761) formulò il teorema che porta il suo nome, mostrando come le credenze sulle cause possano essere aggiornate a partire dagli effetti osservati. Pierre-Simon Laplace (1749–1827) sviluppò e applicò queste idee a un'ampia gamma di problemi scientifici, definendo la probabilità come “buon senso ridotto a calcolo”. Nel Novecento, Bruno de Finetti (1906–1985) ha fornito una rigorosa fondazione soggettivista, sostenendo che la probabilità “non esiste” come proprietà del mondo, ma è uno strumento per quantificare l'incertezza individuale. Harold Jeffreys (1891–1989), con il suo *Theory of Probability* (1939), ha invece elaborato un approccio “oggettivo”

basato su prior non informativi, dimostrando l'efficacia pratica dell'inferenza bayesiana nell'analisi dei dati scientifici. Dopo un periodo di eclissi dovuto al predominio del frequentismo, l'approccio bayesiano ha conosciuto una rinascita a partire dagli anni Novanta, resa possibile dallo sviluppo di metodi computazionali come i metodi Monte Carlo basati su catene di Markov (MCMC) e dalla loro crescente diffusione in ambito psicologico e nelle scienze cognitive (Gelman et al., 2013; Johnson et al., 2022; Kruschke, 2014; McElreath, 2020).

1.6 Il ruolo delle simulazioni: illustrazione, non definizione

Una differenza fondamentale tra l'approccio bayesiano e quello frequentista riguarda il ruolo delle simulazioni e della legge dei grandi numeri. Le due prospettive divergono sul significato delle frequenze empiriche e sul loro rapporto con il concetto di probabilità.

1.6.1 La prospettiva frequentista

Secondo il frequentismo, la probabilità di un evento è definita come il limite della sua frequenza relativa nel limite di una sequenza ideale di prove di prove identiche:

$$P(A) = \lim_{n \rightarrow \infty} \frac{\text{frequenza di occorrenza di } A}{n}.$$

In questa interpretazione, la probabilità è una **proprietà oggettiva** del fenomeno, indipendente dall'osservatore e stimabile tramite esperimenti ripetuti. In questa cornice, la probabilità coincide concettualmente con il comportamento a lungo termine delle frequenze osservate.

Tuttavia, l'approccio frequentista presenta due difficoltà principali quando viene applicato a contesti concreti.

La prima riguarda l'uso della probabilità in riferimento a **eventi o decisioni singoli**. La definizione frequentista interpreta la probabilità come frequenza relativa nel lungo periodo e risulta quindi particolarmente naturale quando si considerano fenomeni ripetibili e osservabili attraverso molte prove simili. Diventa invece meno immediata quando si deve valutare un evento unico, come "domani pioverà a Firenze", o quando si deve prendere una decisione su un caso specifico, come la scelta della terapia per un paziente.

In queste situazioni, il riferimento a un collettivo di casi simili resta possibile, ma non è sempre univoco. Per attribuire una probabilità all'evento singolo, infatti, è necessario stabilire a quale classe di eventi esso appartenga. Tuttavia, tale scelta può variare a seconda delle informazioni prese in considerazione. Allo stesso modo, una stima come "il 55% dei pazienti trattati con questa terapia migliora" descrive il comportamento medio di un gruppo, ma non determina direttamente quale esito sia più probabile per un paziente specifico, date le sue caratteristiche particolari.

La seconda difficoltà riguarda il carattere **ideale e non direttamente osservabi-**

le della probabilità così definita. In senso frequentista, la probabilità corrisponde al limite della frequenza relativa in una sequenza indefinitamente lunga di prove. Tale limite, tuttavia, non può essere osservato empiricamente, poiché nella pratica disponiamo solo di un numero finito di osservazioni. La frequenza relativa calcolata su un numero finito di prove può quindi fornire una stima utile della probabilità, ma non coincide necessariamente con la probabilità vera, che resta un'entità teorica.

In sintesi, la prospettiva frequentista è molto efficace quando si analizzano fenomeni ripetibili e grandi campioni di osservazioni. Al contrario, risulta meno naturale quando l'obiettivo è ragionare su eventi unici, prendere decisioni individuali o formulare giudizi probabilistici in situazioni in cui non esiste una sequenza chiaramente definita di repliche.

1.6.2 La prospettiva bayesiana

La prospettiva bayesiana interpreta invece la probabilità come un **grado di credenza razionale** sul verificarsi di un evento, sulla base delle informazioni disponibili. Le probabilità riflettono lo stato informativo dell'agente *prima* dell'osservazione dei dati.

In questo contesto, le simulazioni non definiscono che cosa sia la probabilità, ma verificano che un sistema di credenze coerente produca comportamenti empirici compatibili con le aspettative. La legge dei grandi numeri spiega perché, se le credenze iniziali sono coerenti, le frequenze osservate tenderanno a rifletterle nel lungo periodo. Tale convergenza, tuttavia, non costituisce la definizione ontologica della probabilità, ma una conseguenza delle sue regole di coerenza.

La distinzione è sostanziale: nel frequentismo, la probabilità è definita dalla regolarità empirica che emerge dalla ripetizione ideale; nel bayesiano, invece, essa esprime uno stato di conoscenza che guida aspettative razionali sui fenomeni osservabili. Questa differenza di fondo determina anche il diverso ruolo attribuito alle simulazioni.

1.6.3 Simulazione come verifica di coerenza

Nel quadro bayesiano, le simulazioni svolgono un ruolo di *verifica* e di *illustrazione*. Mostrano come un sistema di credenze coerente generi regolarità empiriche compatibili con le aspettative teoriche.

Le simulazioni permettono di illustrare concetti quali la convergenza statistica e la variabilità campionaria, di confrontare le previsioni di un modello probabilistico con i dati osservati e di esplorare il comportamento dei modelli in condizioni controllate. È importante sottolineare che le simulazioni non stabiliscono cosa sia la probabilità, ma rendono visibili le conseguenze pratiche delle assegnazioni probabilistiche.

1.6.4 Esempio: lancio di moneta rivisitato

`set.seed(42)`

```
# Assegno credenza  $P(\text{Testa}) = 0.5$  per simmetria epistemica
p_testa_credenza <- 0.5

# Simulazione: verifico che questa credenza è coerente
n_lanci <- 10000
risultati <- rbinom(n_lanci, 1, p_testa_credenza)

# Frequenza cumulativa
freq_cumulativa <- cumsum(risultati) / seq_along(risultati)

# Grafico
df <- data.frame(
  lancio = seq_along(risultati),
  freq = freq_cumulativa
)

ggplot(df, aes(x = lancio, y = freq)) +
  geom_line(alpha = 0.7) +
  geom_hline(yintercept = p_testa_credenza,
             linetype = "dashed", color = "red", linewidth = 0.8) +
  labs(
    title = "Frequenza cumulativa converge alla credenza",
    subtitle = "La credenza  $P(\text{Testa})=0.5$  predice la convergenza osservata",
    x = "Numero di lanci",
    y = "Frequenza cumulativa di Teste"
  ) +
  coord_cartesian(ylim = c(0.3, 0.7))
```




Figura 1.1: Convergenza della frequenza cumulativa di Testa verso il valore assunto nel modello di simulazione.

La Figura 1.1 mostra che l'assegnazione di $P(\text{Testa}) = 0.5$ deriva da un principio di simmetria epistemica, in assenza di informazioni che privilegino un esito rispetto all'altro. La simulazione verifica la coerenza di questa credenza con il comportamento

empirico atteso. È importante notare che la probabilità 0.5 non è definita dalla convergenza empirica, ma rappresenta un'assegnazione iniziale le cui conseguenze a lungo termine sono descritte dalla legge dei grandi numeri.

1.7 Introduzione all'aggiornamento bayesiano

Un principio fondamentale dell'epistemologia bayesiana è che un agente razionale possiede credenze di diversa intensità, soggette ai vincoli di coerenza imposti dagli assiomi della probabilità. Lo stato attuale di una credenza e la sua evoluzione in seguito all'acquisizione di nuove informazioni possono essere rappresentati mediante distribuzioni di probabilità.

1.7.1 Il principio di condizionamento

Il **principio di condizionamento** specifica come un agente razionale debba rivedere le proprie credenze quando emergono nuove evidenze. Esso traduce il concetto di probabilità condizionata in una regola operativa: la probabilità iniziale (o *a priori*) di un'ipotesi H viene trasformata nella sua probabilità finale (o *a posteriori*) dopo l'osservazione di un dato E rilevante.

Più che un assioma, si tratta di una **prescrizione di coerenza dinamica** che impone che il nuovo grado di fiducia in H coincida con la probabilità che gli si attribuiva inizialmente, *dato che* si è verificato E . In questo modo, l'informazione nuova viene così incorporata in modo sistematico, evitando aggiustamenti arbitrari e garantendo che la revisione rimanga ancorata allo stato di conoscenza precedente.

1.7.2 Il teorema di Bayes: struttura concettuale

Il **teorema di Bayes** è lo strumento matematico che realizza il principio di condizionamento, scomponendo la credenza aggiornata in tre componenti essenziali:

1. **Probabilità a priori** $P(H)$: il grado di fiducia iniziale nell'ipotesi, prima di osservare i dati.
2. **Verosimiglianza** $P(E | H)$: la plausibilità dell'evidenza E *supponendo vera* l'ipotesi H , ovvero quanto il dato osservato sia compatibile con l'ipotesi.
3. **Probabilità marginale dell'evidenza** $P(E)$: un fattore di normalizzazione che assicura la coerenza e che è pari alla probabilità complessiva di osservare E sotto tutte le ipotesi considerate.

Il teorema mostra come una credenza iniziale, $P(H)$, venga modulata dalla forza dell'evidenza, $P(E | H)$, per generare una credenza finale, $P(H | E)$. È il nucleo matematico dell'apprendimento dall'esperienza, ovvero l'aggiornamento sistematico e coerente delle opinioni alla luce di nuovi dati.

1.7.3 Un esempio anticipatorio: i test diagnostici

Un esempio paradigmatico di aggiornamento bayesiano è l'interpretazione di un test diagnostico. Qui l'ipotesi H è la presenza di una malattia, mentre l'evidenza E è un risultato positivo.

La probabilità a priori riflette la prevalenza della malattia nella popolazione. La verosimiglianza è espressa dalla sensibilità del test (probabilità di un risultato positivo in un paziente affetto dalla malattia) e dal tasso di falsi positivi (probabilità di un risultato positivo in un individuo sano). Combinando questi elementi, il teorema restituisce la probabilità a posteriori di malattia in seguito a un esito positivo.

Questo esempio illustra un principio generale: **l'evidenza assume significato solo alla luce delle conoscenze pregresse**. Un test, anche se molto accurato, può condurre a una probabilità a posteriori sorprendentemente bassa se la malattia era inizialmente rara. Questa è la radice della cosiddetta *fallacia del tasso base*: la tendenza, ben documentata in psicologia cognitiva, a sovrastimare $P(\text{malattia} \mid \text{positivo})$ trascurando la prevalenza. Il teorema di Bayes non è quindi soltanto una regola di calcolo, ma un correttivo normativo a una delle più robuste distorsioni del ragionamento umano.

L'esempio verrà ripreso e sviluppato numericamente nei capitoli successivi, dove mostreremo come la combinazione di *prior* e verosimiglianza possa condurre a risultati controintuitivi, ma logicamente inattaccabili.

1.7.4 Sintesi concettuale

L'aggiornamento bayesiano può essere rappresentato nella sua essenza come:

$$\underbrace{P(H)}_{\text{prior}} \xrightarrow[\text{osservazione dei dati}]{\text{aggiornamento bayesiano}} \underbrace{P(H \mid E)}_{\text{posterior}}.$$

Questa sintesi visuale coglie l'essenza dell'inferenza bayesiana: un modello formale del ragionamento che integra nuove informazioni con le conoscenze acquisite senza ignorare i dati né sopravvalutarli. In questa prospettiva, il teorema di Bayes non è solo uno strumento matematico, ma una guida razionale per orientarsi e prendere decisioni in condizioni di incertezza.

1.8 La probabilità bayesiana nella ricerca psicologica

La teoria bayesiana della probabilità si rivela particolarmente adatta allo studio dei fenomeni psicologici, in quanto fornisce strumenti concettuali e metodologici per affrontare in modo esplicito e coerente l'incertezza che caratterizza sia la ricerca empirica sia la pratica clinica.

1.8.1 Quantificare l'incertezza in ambito clinico e cognitivo

In ambito diagnostico, il framework bayesiano consente di integrare in modo sistematico fonti informative eterogenee, come l'anamnesi, l'osservazione comportamentale e i test psicometrici, aggiornando le credenze del clinico con ogni nuova evidenza. Un contributo particolarmente rilevante è la possibilità di incorporare esplicitamente la prevalenza dei disturbi, riducendo il rischio di errori dovuti alla negligenza dei tassi di base.

Un influente filone di ricerca nello studio dei processi cognitivi propone che molti aspetti del funzionamento mentale possano essere descritti come approssimazioni di un ragionamento bayesiano ideale (Griffiths et al., 2024). La percezione, per esempio, può essere modellata come integrazione tra aspettative pregresse e informazioni sensoriali, spiegando così i fenomeni delle illusioni percettive. L'apprendimento e molti bias cognitivi trovano invece una loro interpretazione naturale come aggiornamenti imperfetti o scostamenti dall'ottimalità bayesiana.

Dal punto di vista metodologico, l'inferenza bayesiana offre vantaggi concreti nell'analisi dei dati psicologici: l'incorporazione formale delle conoscenze pregresse, la quantificazione diretta dell'evidenza a favore di ipotesi specifiche, la gestione naturale dei campioni ridotti e la propagazione coerente dell'incertezza attraverso modelli statistici complessi.

In ambito terapeutico, infine, l'approccio consente di aggiornare sequenzialmente le stime di efficacia degli interventi, adattando i protocolli alle risposte del singolo paziente e bilanciando probabilità ed esiti attesi nelle scelte cliniche.

1.8.2 Un quadro epistemologico coerente

A differenza del frequentismo, che definisce la probabilità come limite della frequenza relativa in una sequenza ideale di prove ripetute e considera i parametri come quantità fisse ma ignote, l'approccio bayesiano interpreta la probabilità come grado di credenza razionale e rappresenta l'incertezza dell'osservatore sui parametri mediante distribuzioni di probabilità. Consente, inoltre, di formulare affermazioni come: "La probabilità che l'effetto del trattamento sia positivo è pari a 0.85".

Ne deriva un'interpretazione diretta degli intervalli di stima: un intervallo di credibilità al 95% esprime, dati i risultati osservati e il modello adottato, che esiste una probabilità del 95% che il parametro cada al suo interno. Questo approccio offre un vantaggio operativo non trascurabile per chi deve prendere decisioni cliniche o di politica sanitaria.

L'approccio bayesiano non sostituisce l'inferenza frequentista, ma la integra in un quadro epistemologico più ampio in cui la soggettività delle credenze iniziali viene resa esplicita e vincolata dalla coerenza formale e in cui l'evidenza empirica modula le opinioni in modo trasparente e verificabile.

Riflessioni conclusive

Abbiamo iniziato questo capitolo con una domanda: perché la probabilità bayesiana in psicologia? La risposta che abbiamo fornito è che la probabilità, intesa come grado di credenza razionale, offre un linguaggio unitario per quantificare l'incertezza, sia quella che deriva dai limiti della nostra conoscenza, sia quella che sembra inerente ai fenomeni stessi. Questa prospettiva, che affonda le proprie radici in Bayes, Laplace e de Finetti, non è un tecnicismo matematico, ma una lente interpretativa attraverso cui leggere il ragionamento umano in condizioni di incertezza.

Abbiamo visto che gli assiomi della probabilità non sono mere convenzioni formali, ma **principi di coerenza** che vincolano le nostre credenze: violarli significa esporsi a contraddizioni interne e a decisioni sistematicamente svantaggiose, come dimostrato dall'argomento della scommessa olandese. Abbiamo anche compreso che, nel quadro bayesiano, l'incertezza non è più una proprietà del mondo che emerge solo in lunghe sequenze di prove, ma una misura della nostra conoscenza imperfetta, applicabile anche a eventi singoli e non ripetibili, come la prognosi di un paziente o l'esito di una decisione clinica.

Questo cambiamento di prospettiva ha implicazioni concrete per la ricerca psicologica. L'approccio bayesiano rende esplicite le assunzioni iniziali attraverso la scelta del prior, formalizza l'apprendimento dai dati con il teorema di Bayes e fornisce strumenti per gestire la complessità dei modelli statistici senza compromettere la trasparenza. Non elimina l'incertezza, che nella psicologia è una **condizione strutturale** e non un'eccezione, ma fornisce un linguaggio per quantificarla, comunicarla e integrarla nelle decisioni.

Nei prossimi capitoli trasformeremo queste idee in strumenti operativi. Scopriremo come costruire un modello bayesiano, come scegliere i **prior** e come interpretare i risultati. Inoltre, vedremo che concetti come l'equiprobabilità, spesso considerati oggettivi, riflettono in realtà delle simmetrie nel nostro stato informativo. L'obiettivo non è eliminare l'incertezza, un compito impossibile in psicologia, ma imparare a ragionare con essa trasformandola da ostacolo a risorsa.

Esercizi

1. Spiega con parole tue la differenza tra incertezza epistemica e incertezza ontologica. Fornisci un esempio psicologico per ciascuna.
2. Perché l'interpretazione frequentista risulta meno immediata quando si considera un evento singolo, come la prognosi di un paziente?
3. Un decisore assegna probabilità 0.7 a *Testa* e 0.6 a *Croce*. Mostra perché queste valutazioni non sono coerenti e costruisci una coppia di scommesse che produca una perdita certa.
4. In un problema diagnostico, identifica il ruolo della prevalenza, della sensibilità e del tasso di falsi positivi nell'aggiornamento bayesiano.
5. Modifica la simulazione del lancio di moneta ponendo $P(\text{Testa}) = 0.65$. Descrivi ciò che accade alla frequenza cumulativa all'aumentare del numero di

lanci.

6. Spiega perché una simulazione può illustrare le conseguenze di un modello probabilistico, ma non costituisce una definizione della probabilità.

Soluzioni

1. L'incertezza epistemica dipende da conoscenze incomplete ed è potenzialmente riducibile; per esempio, una stima clinica basata su pochi dati anamnestici. L'incertezza ontologica riguarda la variabilità attribuita al fenomeno; per esempio, risposte comportamentali differenti anche in condizioni sperimentali simili. Nel quadro adottato nel capitolo, entrambe vengono rappresentate mediante probabilità.
2. La definizione frequentista richiede un riferimento a una classe di prove ripetibili. Per un caso singolo la scelta della classe di riferimento non è sempre univoca e una frequenza di gruppo non determina direttamente l'esito del singolo individuo.
3. Le probabilità sommano a 1.3 e violano il vincolo di additività. Se il decisore paga £0.70 per una scommessa che restituisce £1 in caso di Testa e £0.60 per una scommessa che restituisce £1 in caso di Croce, paga complessivamente £1.30 ma riceve al massimo £1: perde certamente £0.30.
4. La prevalenza fornisce la probabilità a priori della condizione. La sensibilità descrive la probabilità di un risultato positivo quando la condizione è presente; il tasso di falsi positivi descrive la probabilità di un positivo quando la condizione è assente. Il teorema di Bayes combina queste quantità per ottenere la probabilità a posteriori.
5. La frequenza cumulativa oscilla maggiormente nei primi lanci e tende poi a stabilizzarsi intorno a 0.65. La simulazione rende visibile una conseguenza del modello assunto, non dimostra che 0.65 sia il valore corretto per una moneta reale.
6. La simulazione presuppone già un modello e un valore probabilistico usato per generare i dati. Può quindi mostrare le conseguenze di quell'assegnazione, ma non può fondare la definizione che ha utilizzato come punto di partenza.

Punti chiave

- La probabilità bayesiana rappresenta un grado di credenza razionale relativo a uno stato informativo.
- La soggettività delle valutazioni non implica arbitrarietà: le probabilità devono rispettare vincoli di coerenza.
- L'argomento della scommessa olandese mostra le conseguenze operative di credenze incoerenti.
- Le simulazioni illustrano le conseguenze di un modello probabilistico, ma non definiscono la probabilità.
- L'aggiornamento bayesiano combina probabilità a priori, verosimiglianza

ed evidenza per ottenere una probabilità a posteriori.

- Nel Capitolo 2 le regole di coerenza verranno formalizzate mediante gli assiomi della probabilità.

Riferimenti bibliografici

- Finetti, B. de. (1970). *Teoria delle probabilità* (pp. VIII, 350–769). G. Einaudi.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3^a ed.). Chapman and Hall/CRC.
- Griffiths, T. L., Chater, N., & Tenenbaum, J. B. (2024). *Bayesian models of cognition: reverse engineering the mind*. MIT Press.
- Heard, N. (2021). *An introduction to Bayesian inference, methods and computation*. Springer.
- Jackson, E. G. (2020). The relationship between belief and credence. *Philosophy Compass*, 15(6), e12668.
- Johnson, A. A., Ott, M., & Dogucu, M. (2022). *Bayes Rules! An Introduction to Bayesian Modeling with R*. CRC Press.
- Kruschke, J. (2014). *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan*. Academic Press.
- McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan* (2nd Edition). CRC Press.
- Spiegelhalter, D. (2024). Why probability probably doesn't exist (but it is useful to act like it does). *Nature*, 636(8043), 560–563.

Assiomi e coerenza delle credenze

i In sintesi

Da sapere Gli assiomi della probabilità stabiliscono i vincoli minimi che rendono coerente un sistema di credenze. Da questi vincoli derivano proprietà come la regola del complemento, la monotonia, la regola dell'unione e i limiti entro cui può variare una probabilità congiunta.

Da saper fare Riconoscere semplici assegnazioni incoerenti; spiegare il significato degli assiomi; interpretare i vincoli di Fréchet; leggere una tabella di probabilità congiunta e distinguere le probabilità congiunte, marginali e condizionate.

Introduzione

Nel capitolo precedente abbiamo visto che, nell'interpretazione bayesiana, la probabilità non descrive frequenze oggettive, ma **gradi di credenza razionale**. Questa idea, apparentemente semplice, solleva immediatamente una domanda cruciale: cosa significa, esattamente, che una credenza sia "razionale"?

Non basta avere opinioni: tutti ne abbiamo. Non basta nemmeno avere opinioni informate o ragionevoli. Il punto è più sottile e profondo: le nostre credenze devono essere **internamente coerenti** tra loro. Se, per esempio, credo che piovverà con probabilità 0.7 e che non piovverà con probabilità 0.5, sto commettendo un errore logico, a prescindere da quanto siano informate le mie valutazioni meteorologiche. La somma delle mie credenze su eventi mutuamente esclusivi ed esaustivi deve essere 1, non per una convenzione arbitraria, ma perché altrimenti il mio sistema di credenze si contraddice.

Questo capitolo sviluppa il quadro matematico che rende espliciti e controllabili tali vincoli di coerenza. Attenzione, però: non si tratta di aggiungere un livello puramente formale alla discussione. La matematica che introdurremo non è un semplice ornamento tecnico, ma il linguaggio attraverso cui possiamo esprimere con precisione il significato di un ragionamento coerente in condizioni di incertezza.

2.1 Perché la coerenza probabilistica è importante in psicologia?

Per gli psicologi, questi assiomi definiscono lo standard normativo contro cui valutare il ragionamento umano in condizioni di incertezza, un tema centrale nella ricerca sui bias cognitivi a partire da Kahneman e Tversky. Inoltre, quando costruiamo modelli statistici, la coerenza probabilistica non è facoltativa: un modello incoerente è logicamente impossibile, come un triangolo con quattro lati. Comprendere questi vincoli ci rende ricercatori più consapevoli e clinici più competenti.

Prerequisiti

La lettura del presente capitolo presuppone la conoscenza dei contenuti trattati nel Capitolo 1. Per richiami alle proprietà delle somme e alle operazioni insiemistiche (unione, intersezione, complemento), si rimanda al [Companion](#), dove sono raccolte le appendici di approfondimento.

Panoramica del capitolo

Il percorso che seguiremo è questo:

1. Reinterpreteremo lo **spazio campionario** non come l'insieme degli esiti fisicamente possibili, ma come l'insieme delle possibilità che *noi* consideriamo date le nostre informazioni.
2. Vedremo come gli **eventi** diventino *proposizioni* sul mondo a cui assegniamo gradi di credenza.
3. Introdurremo gli **assiomi di Kolmogorov** non come regole arbitrarie, ma come vincoli *necessari* per evitare auto-contraddizioni.
4. Impareremo a **diagnosticare incoerenze** nelle assegnazioni probabilistiche.
5. Costruiremo **tabelle di probabilità congiunta**, lo strumento operativo fondamentale per rappresentare sistemi di credenze complessi.
6. Mostriamo come tutte le probabilità di interesse (marginali, condizionate) **derivino** dalla distribuzione congiunta.

Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()

library(ggplot2)
library(tidyr)
library(viridis)

apply_visual_theme()
```

2.2 Spazio campionario come possibilità epistemiche

Prima di addentrarci nelle definizioni formali, fermiamoci a riflettere su ciò che stiamo cercando di catturare.

Quando uno psicologo clinico valuta un paziente, non sta osservando un “esperimento casuale” nel senso fisico del termine. Non c’è un dado che rotola, né una moneta che viene lanciata. Eppure, il clinico si trova in una condizione di *incertezza genuina*: sulla base delle informazioni raccolte (anamnesi, colloquio, test), deve formarsi un’opinione sulle possibili condizioni del paziente.

Questa situazione, ovvero avere informazioni incomplete e dover ragionare su possibilità alternative, è esattamente ciò che la teoria della probabilità, nell’interpretazione bayesiana, è progettata per gestire. Il primo passo è definire le possibilità che stiamo prendendo in considerazione.

Definizione 2.1 (Spazio campionario). Lo *spazio campionario* Ω rappresenta l’insieme delle *possibilità epistemiche* compatibili con lo stato informativo corrente. Esso non descrive necessariamente tutto ciò che può accadere fisicamente, ma piuttosto ciò che, dati i limiti della nostra conoscenza, consideriamo logicamente possibile.

2.2.1 Un cambio di prospettiva fondamentale

Questa definizione merita attenzione. Nella visione frequentista tradizionale, lo spazio campionario è qualcosa di “oggettivo”: l’insieme di tutti gli esiti che un esperimento può produrre, indipendentemente da chi lo osserva. Nell’approccio bayesiano, invece, lo spazio campionario diventa *epistémico*: dipende da ciò che *noi* sappiamo e dalle distinzioni che *noi* riteniamo rilevanti.

Questo cambiamento non è un dettaglio tecnico, ma un cambio di prospettiva filosofica con conseguenze pratiche profonde. Ciò significa che:

- **ricercatori diversi possono legittimamente usare spazi campionari diversi** per lo stesso fenomeno, se hanno informazioni diverse o interessi diversi;
- **lo spazio campionario può cambiare** quando si acquisiscono nuove informazioni. Prima di un test diagnostico, consideriamo come possibili sia il risultato “positivo” che quello “negativo”; dopo aver osservato il risultato, lo spazio delle possibilità rilevanti si restringe.
- **la scelta dello spazio campionario è una decisione di modellazione**, non una scoperta empirica; richiede un giudizio sul livello di dettaglio appropriato per il problema in esame.

2.2.2 Caratteristiche dello spazio campionario epistémico

La composizione dello spazio campionario riflette dunque la natura informazionale e soggettiva della probabilità bayesiana. Non esiste uno spazio campionario corretto in senso assoluto, ma esiste quello più adeguato, in base alle nostre informazioni e ai nostri obiettivi.

i Esempio psicologico: livelli di granularità nella valutazione clinica

Consideriamo la valutazione di un paziente per una possibile depressione. Lo spazio campionario può essere definito a diversi livelli, a seconda delle informazioni disponibili e degli obiettivi clinici:

Livello 1 (binario):

$$\Omega_1 = \{\text{Depresso}, \text{Non depresso}\}.$$

Questo è il livello appropriato per una decisione sì/no: il paziente necessita di trattamento per depressione?

Livello 2 (severità):

$$\Omega_2 = \{\text{Nessuna}, \text{Lieve}, \text{Moderata}, \text{Severa}\}.$$

Qui distinguiamo gradi di severità, che sono importanti quando dobbiamo decidere *quale tipo* di trattamento proporre.

Livello 3 (combinazioni diagnostiche):

$$\Omega_3 = \{\text{Depressione}, \text{Ansia}, \text{Comorbidità}, \text{Nessuna}\}.$$

Questo livello considera la possibilità di diagnosi multiple o alternative. Nessuno di questi spazi campionari è “più corretto” degli altri in senso assoluto. La scelta dipende da:

- le **informazioni disponibili** (uno screening rapido vs. una valutazione approfondita);
- l'**obiettivo dell'analisi** (screening di popolazione vs. diagnosi differenziale);
- le **decisioni da prendere** (inviare a uno specialista o pianificare un trattamento specifico).

La consapevolezza che lo spazio campionario è una *scelta* di modellazione e non un dato di fatto è il primo passo verso un uso maturo della probabilità.

2.3 Eventi come proposizioni sul mondo

Una volta definito lo spazio delle possibilità, il passo successivo è considerare le *affermazioni* su queste possibilità. Qui avviene un'altra importante traduzione concettuale.

Nella teoria degli insiemi, un “evento” è semplicemente un sottoinsieme dello spazio campionario. Tuttavia, nell'interpretazione epistemica, un evento acquista un significato più ricco: diventa una *proposizione*, un'affermazione sul mondo che può essere vera o falsa.

Definizione 2.2 (Evento). Un *evento* $A \subseteq \Omega$ è una *proposizione* alla quale possiamo assegnare un grado di credenza $P(A)$, condizionato allo stato informativo corrente.

2.3.1 La logica delle proposizioni incerte

Questa interpretazione collega la teoria della probabilità alla logica proposizionale. Le operazioni insiemistiche diventano operazioni logiche:

- L'**unione** $A \cup B$ corrisponde alla disgiunzione logica: “ A oppure B è vera” (o entrambe).
- L'**intersezione** $A \cap B$ corrisponde alla congiunzione logica: “ A e B sono entrambe vere”.
- Il **complemento** A^c corrisponde alla negazione: “ A è falsa”.

Questa corrispondenza non è casuale. La teoria della probabilità può essere considerata come un'estensione della logica classica al caso dell'incertezza. Mentre la logica classica assegna solo valori “vero” (1) o “falso” (0) alle proposizioni, la probabilità assegna valori intermedi che rappresentano *gradi* di credenza.

L'**insieme vuoto** $\emptyset$ corrisponde a una proposizione logicamente contraddittoria, qualcosa che non può essere vero in nessuna delle possibilità prese in considerazione. Al contrario, lo **spazio campionario** Ω corrisponde a una tautologia, qualcosa che è necessariamente vero, dato che una delle possibilità deve realizzarsi.

i Esempio: eventi in un test psicometrico

La *Satisfaction with Life Scale* (SWLS) produce punteggi compresi tra 5 e 35. Definiamo:

- $\Omega = \{5, 6, 7, \dots, 35\}$ (punteggi possibili);
- $A = \text{“Punteggio} \geq 25\text{”}$ (alta soddisfazione) $= \{25, 26, \dots, 35\}$;
- $B = \text{“Punteggio} \leq 15\text{”}$ (bassa soddisfazione) $= \{5, 6, \dots, 15\}$;
- $C = \text{“Punteggio tra 16 e 24”}$ (soddisfazione moderata) $= \{16, 17, \dots, 24\}$.

Alcune operazioni sugli eventi e il loro significato:

- $A \cup B$: “La persona ha soddisfazione alta *oppure* bassa” (estremi).
- $A \cap B = \emptyset$: “Alta e bassa soddisfazione insieme”—impossibile per definizione.
- $A^c = B \cup C$: “Non alta soddisfazione” = “soddisfazione bassa o moderata”.
- $A \cup B \cup C = \Omega$: le tre categorie esauriscono tutte le possibilità.

Quando assegniamo $P(A) = 0.30$, stiamo dicendo: “Dato ciò che so della popolazione di riferimento e del contesto di valutazione, ritengo plausibile che un individuo selezionato presenti un’alta soddisfazione di vita con una probabilità del 30%”

Si tratta di un’affermazione epistemica, non di una frequenza oggettiva. Due ricercatori con informazioni diverse potrebbero legittimamente assegnare valori diversi.

2.4 Gli assiomi di Kolmogorov come vincoli di coerenza

Arriviamo ora al cuore concettuale del capitolo. Abbiamo visto che le probabilità sono gradi di credenza su proposizioni. Ma quali valori possiamo assegnare? Siamo liberi di scegliere qualsiasi numero ci piaccia?

La risposta è no, e capire *perché* è fondamentale.

2.4.1 Il problema della coerenza

Immaginiamo un clinico che, valutando un paziente, assegna le seguenti probabilità a tre diagnosi mutualmente esclusive:

- $P(\text{Schizofrenia}) = 0.6$
- $P(\text{disturbo bipolare}) = 0.5$
- $P(\text{Nessun disturbo psicotico}) = 0.2$

La somma è 1.3. Cosa significa? Significa che il clinico sta assegnando più certezza di quanta ne abbia a disposizione. È come se il clinico dicesse: “Sono sicuro al 130% che una di queste tre cose sia vera”, il che non ha senso.

Questo non è necessariamente un errore di valutazione clinica (il clinico potrebbe avere ottime ragioni per ciascuna stima individuale). Si tratta piuttosto di un errore *logico*: le credenze sono in contraddizione tra loro. Come abbiamo visto nel capitolo precedente, un sistema di credenze incoerente può esporre a perdite certe (l'argomento della scommessa olandese).

Gli assiomi che introduciamo ora sono precisamente i vincoli che *impediscono* questo tipo di auto-contraddizioni.

Definizione 2.3 (Funzione di probabilità). Una *funzione di probabilità* è una funzione

$$P : \mathcal{F} \rightarrow [0, 1],$$

che assegna a ogni evento A appartenente a una famiglia di eventi $\mathcal{F}$ il numero $P(A)$, interpretabile come il grado di credenza nell'affermazione A , dato lo stato informativo corrente.

Per essere *coerente*, la funzione P deve soddisfare i seguenti **assiomi di coerenza**:

1. Non negatività

$$P(A) \geq 0 \quad \text{per ogni evento } A.$$

2. Normalizzazione

$$P(\Omega) = 1.$$

3. Additività

Se A e B sono eventi mutuamente esclusivi ($A \cap B = \emptyset$), allora

$$P(A \cup B) = P(A) + P(B).$$

Per spazi campionari infiniti, questo principio si estende a successioni numerabili di eventi: se $A_1, A_2, \dots$ sono a due a due disgiunti, allora

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Nella pratica psicologica, tuttavia, lavoreremo quasi sempre con spazi finiti, per cui la versione finita è quella che utilizzeremo più spesso.

2.4.2 Perché questi assiomi e non altri?

Una domanda legittima è: perché proprio questi tre vincoli? La risposta a questa domanda si trova nella teoria della decisione e nell'argomento della scommessa olandese, che abbiamo trattato nel capitolo precedente. Tuttavia, è possibile fornire un'interpretazione intuitiva di ciascun assioma.

La non negatività riflette un fatto semplice: non esiste un grado di credenza “meno che impossibile”. Zero significa “sono certo che non accadrà”; non c'è nulla al di sotto dello zero. Se qualcuno vi dicesse: “Credo che pioverà con probabilità -0.3”, non sapreste nemmeno cosa intende.

La normalizzazione esprime la convinzione che *qualcosa* debba accadere. Per costruzione, lo spazio campionario contiene tutte le possibilità che prendiamo in considerazione. Una di queste deve verificarsi. Assegnare $P(\Omega) < 1$ significherebbe ammettere la possibilità che nessuna delle alternative si verifichi, ma in tal caso avremmo dimenticato qualche alternativa nel nostro spazio campionario.

L'additività è forse il vincolo più importante, e merita una riflessione più approfondita. Dice che, se A e B non possono verificarsi insieme, allora la mia credenza che “si verifichi A oppure B ” deve essere esattamente la somma delle mie credenze separate in A e in B .

Perché? Qualsiasi altra assegnazione sarebbe incoerente. Se assegnassi $P(A \cup B) < P(A) + P(B)$, direi che credo “meno” nella disgiunzione rispetto alle due opzioni prese separatamente, ma la disgiunzione include entrambe le opzioni! Viceversa, se assegnassi $P(A \cup B) > P(A) + P(B)$, starei “contando due volte” qualcosa.

L'additività numerabile estende questo ragionamento a sequenze infinite di eventi, necessarie per trattare variabili continue, ma il principio è lo stesso.

i Un'analogia utile: le aree

Le proprietà della probabilità sono analoghe a quelle delle aree. Se due regioni non si sovrappongono, la loro area totale è la somma delle due aree. Se le regioni si sovrappongono, è necessario sottrarre l'area di sovrapposizione per evitare di contarla due volte. L'area totale disponibile (normalizzata a 1) non può essere superata. Nessuna regione ha un'area negativa.

Questa analogia non è casuale: matematicamente, la probabilità è una “misura” e le misure generalizzano il concetto di area/volume. Tuttavia, l'interpretazione è diversa: non stiamo misurando estensioni spaziali, ma gradi di credenza.

2.4.3 Conseguenze immediate degli assiomi

Una volta accettati questi vincoli fondamentali, ne derivano molte altre come conseguenze logiche necessarie. Non si tratta di regole aggiuntive da memorizzare, ma di teoremi che derivano dagli assiomi.

Teorema 2.1 (Proprietà derivate della probabilità).

1. Probabilità del complemento

$$P(A^c) = 1 - P(A).$$

2. Probabilità dell'insieme vuoto

$$P(\emptyset) = 0.$$

3. Monotonia

Se $A \subseteq B$, allora

$$P(A) \leq P(B).$$

4. Regola dell'unione (eventi non disgiunti)

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

5. Principio di inclusione-esclusione (caso generale)

$$P(A_1 \cup A_2 \cup A_3) = \sum P(A_i) - \sum P(A_i \cap A_j) + P(A_1 \cap A_2 \cap A_3).$$

La prima proprietà è particolarmente importante e vale la pena di comprenderla bene: se credo che pioverà con probabilità 0.7, *devo* credere che non pioverà con probabilità 0.3. Non ho scelta. È una conseguenza logica degli assiomi.

La quarta proprietà (regola dell'unione generale) merita attenzione, in quanto mostra cosa accade quando gli eventi non sono disgiunti. La sottrazione di $P(A \cap B)$ corregge il “doppio conteggio” che si verificherebbe sommando semplicemente le due probabilità.

2.5 Diagnosi di incoerenze: casi tipici

La teoria è utile solo se ci permette di individuare e correggere gli errori nella pratica. Vediamo alcuni pattern comuni di incoerenza e come riconoscerli.

2.5.1 Incoerenza 1: violazione dell'additività

Questo è l'errore più comune e l'abbiamo già visto nell'esempio iniziale. Quando abbiamo eventi mutuamente esclusivi che insieme esauriscono tutte le possibilità, le loro probabilità devono sommare a 1.

⚠ Esempio di incoerenza clinica

Sovrastima delle probabilità

Un clinico valuta un paziente con sintomi psicotici e assegna i seguenti gradi di credenza a tre diagnosi mutualmente esclusive:

- $P(\text{Schizofrenia}) = 0.6$;
- $P(\text{disturbo bipolare}) = 0.5$;
- $P(\text{Nessun disturbo psicotico}) = 0.2$.

La somma $0.6 + 0.5 + 0.2 = 1.3$ eccede il valore massimo consentito di 1.

Diagnosi del problema: il clinico ha probabilmente valutato ciascuna ipotesi separatamente, chiedendosi “Quanto è plausibile questa diagnosi?” senza considerare il vincolo secondo cui le tre ipotesi devono spartirsi il 100% della credenza disponibile.

Correzione: il clinico deve riconsiderare le sue valutazioni come un *sistema*. Una possibilità è normalizzare i valori (dividere ogni valore per 1.3), ma è preferibile rivalutare criticamente quale diagnosi sia stata sovrastimata. Forse la sicurezza sulla schizofrenia (0.6) e sul disturbo bipolare (0.5) è eccessiva, vista l’evidenza disponibile.

2.5.2 Incoerenza 2: violazione dei vincoli di Fréchet per eventi congiunti

Un tipo più sottile di incoerenza emerge quando si considera la probabilità che due eventi si verifichino *insieme*. Anche in questo caso, esistono vincoli logici che non possono essere violati.

Consideriamo un esempio. Sappiamo che il 60% dei pazienti di un determinato ambulatorio soffre di depressione e il 50% di ansia. Qual è la probabilità che un paziente soffra di *entrambe* le condizioni?

La risposta non è libera. Non possiamo dire “5%” perché la matematica ci impone un valore minimo più alto. Non possiamo neanche dire “55%” perché supererebbe la probabilità dell’evento meno probabile.

Teorema 2.2 (Vincoli di Fréchet). *Per qualsiasi coppia di eventi A e B vale la disuguaglianza:*

$$\max\{0, P(A) + P(B) - 1\} \leq P(A \cap B) \leq \min\{P(A), P(B)\}.$$

Interpretazione intuitiva

Il limite superiore dice qualcosa di ovvio una volta che ci si pensa: la probabilità che accadano sia A che B non può essere maggiore della probabilità che accada solo A (né di quella che accada solo B). Se credo che piovenga con una probabilità del 50%, non posso credere che piovenga e farà freddo con una probabilità del 60%.

Il limite inferiore è meno ovvio ma altrettanto importante: se $P(A) + P(B) > 1$, i due eventi devono sovrapporsi almeno in parte. Se il 60% dei pazienti soffre di depressione e

il 50% di ansia, allora almeno il 10% deve soffrire di entrambe le patologie, semplicemente perché altrimenti avremmo più del 100% di pazienti!

i Applicazione alla comorbidità psicologica

Definizione dello scenario

Torniamo all'esempio con $P(\text{Depressione}) = 0.6$ e $P(\text{Ansia}) = 0.5$.

I vincoli di Fréchet determinano l'intervallo ammissibile per la comorbidità:

- limite inferiore: $\max(0, 0.6 + 0.5 - 1) = 0.1$;
- limite superiore: $\min(0.6, 0.5) = 0.5$.

Quindi la probabilità di comorbidità **deve** essere compresa tra il 10% e il 50%.

Implicazioni pratiche: se un collega vi dicesse: "Nella mia esperienza, solo il 5% dei pazienti presenta entrambe le condizioni", potreste rispondergli che una stima del genere è logicamente impossibile, considerando le prevalenze di depressione e ansia riportate. O ha sbagliato le prevalenze, o ha sbagliato la stima della comorbidità. Non c'è una terza possibilità.

Viceversa, qualsiasi valore compreso tra il 10% e il 50% è *logicamente ammissibile*, il che non significa che sia corretto, ma solo che non contraddice le altre assunzioni.

Mappa dei valori ammissibili.


```
# Creare griglia di valori
grid <- expand.grid(
  P_A = seq(0, 1, by = 0.02),
  P_B = seq(0, 1, by = 0.02)
)

# Calcolare vincoli per ogni coppia
grid$limite_inferiore <- pmax(0, grid$P_A + grid$P_B - 1)
grid$limite_superiore <- pmin(grid$P_A, grid$P_B)
grid$ampiezza_lecita <- grid$limite_superiore - grid$limite_inferiore

# Visualizzazione
ggplot(grid, aes(x = P_A, y = P_B, fill = ampiezza_lecita)) +
  geom_tile() +
  scale_fill_viridis_c(
    name = "Ampiezza dell'intervallo\nammissibile",
    option = "plasma",
    limits = c(0, 0.5)
  ) +
  labs(
    title = "Vincoli di Fréchet:\nintervalli ammissibili per P(A ∩ B)",
    subtitle = "Per ogni coppia (P(A), P(B)), l'area colorata
    ↪ mostra\nquanti valori di P(A ∩ B) sono logicamente possibili",
    x = "P(A)",
    y = "P(B)",
    caption = "Colori più chiari = maggiore libertà nella scelta di P(A
    ↪ ∩ B)"
  ) +
  coord_fixed()
```

Vincoli di Fréchet: intervalli ammissibili per $P(A \cap B)$

Per ogni coppia $(P(A), P(B))$, l'area colorata mostra quanti valori di $P(A \cap B)$ sono logicamente possibili



Colori più chiari = maggiore libertà nella scelta di $P(A \cap B)$

Figura 2.1: Regione dei valori ammissibili per $P(A \cap B)$ in funzione di $P(A)$ e $P(B)$.

La Figura 2.1 rivela pattern interessanti. Negli angoli, corrispondenti agli eventi rari o quasi certi, i vincoli sono più stringenti e c'è meno libertà nella scelta della probabilità congiunta. Al centro, dove le probabilità sono intermedie, c'è maggiore libertà.

La regione in alto a destra, in cui $P(A) + P(B) > 1$, impone una sovrapposizione minima obbligatoria. La regione in basso a sinistra, invece, permette una sovrapposizione nulla.

2.6 Tabelle di probabilità congiunta

Passiamo ora dallo studio dei vincoli teorici alla costruzione di rappresentazioni operative. Le **tabelle di probabilità congiunta** sono lo strumento fondamentale per questo scopo.

2.6.1 L'idea centrale: la distribuzione congiunta è la “fonte”

Quando abbiamo due o più variabili, possiamo chiederci:

- Qual è la probabilità di ciascun valore della prima variabile? (*marginale*)
- Qual è la probabilità di ciascuna *combinazione* di valori? (*congiunta*)
- Se conosco il valore di una variabile, qual è la probabilità dei valori dell'altra? (*condizionata*)

Queste domande non sono indipendenti. Se conosco la distribuzione congiunta, ovvero le probabilità di tutte le combinazioni, posso derivare tutte le altre. La distri-

buzione congiunta è l'informazione completa sul sistema: a partire da essa è possibile ricavare tutte le distribuzioni marginali e condizionate, che ne sono semplicemente delle conseguenze.

2.6.2 Struttura di una tabella 2×2

Consideriamo il caso più semplice: due eventi dicotomici A e B .

	B	B^c	Marginale
A	$P(A \cap B)$	$P(A \cap B^c)$	$P(A)$
A^c	$P(A^c \cap B)$	$P(A^c \cap B^c)$	$P(A^c)$
Marginale	$P(B)$	$P(B^c)$	1

- Le **quattro celle interne** contengono le probabilità congiunte.
- I **margin**i contengono le probabilità marginali, ottenute sommando righe o colonne:

$$P(A) = P(A \cap B) + P(A \cap B^c), \quad P(B) = P(A \cap B) + P(A^c \cap B).$$

- L'**angolo in basso a destra** deve valere 1: la somma delle quattro celle interne è 1. Anche le marginali di riga sommano a 1, così come le marginali di colonna.

2.6.3 Costruzione di una tabella congiunta

Come si costruisce una tabella congiunta a partire dalle informazioni disponibili? La regola fondamentale è il **principio del prodotto**:

$$P(A \cap B) = P(A | B) P(B) = P(B | A) P(A).$$

Se conosciamo una probabilità marginale e una condizionata, possiamo ricavare la congiunta.

i Esempio: test diagnostico per la depressione

Consideriamo un test per la depressione con:

- **prevalenza**: $P(D) = 0.15$;
- **sensibilità**: $P(T^+ | D) = 0.85$;
- **tasso di falsi positivi**: $P(T^+ | D^c) = 0.20$.

Costruiamo la tabella congiunta:

```
prevalenza <- 0.15
sensibilita <- 0.85
tasso_falsi_positivi <- 0.20

p_D_pos <- sensibilita * prevalenza          # 0.1275
p_D_neg <- (1 - sensibilita) * prevalenza    # 0.0225
```

```

p_Dc_pos <- tasso_falsi_positivi * (1 - prevalenza) # 0.1700
p_Dc_neg <- (1 - tasso_falsi_positivi) * (1 - prevalenza) # 0.6800

tabella_congiunta <- matrix(
  c(p_D_pos, p_D_neg, p_Dc_pos, p_Dc_neg),
  nrow = 2, byrow = TRUE,
  dimnames = list(
    "Stato reale" = c("Depresso", "Non depresso"),
    "Test" = c("Positivo", "Negativo")
  )
)
round(tabella_congiunta, 4)
#>           Test
#> Stato reale  Positivo Negativo
#> Depresso      0.128   0.0225
#> Non depresso   0.170   0.6800

```

Ogni cella rappresenta la probabilità di una combinazione: veri positivi (0.1275), falsi negativi (0.0225), falsi positivi (0.1700), veri negativi (0.6800). La somma è 1. La Figura 2.2 offre una rappresentazione visiva delle quattro probabilità.




Figura 2.2: Probabilità congiunte delle combinazioni tra stato depressivo e risultato del test.

2.6.4 Calcolo di marginali e condizionate

Una volta costruita la tabella congiunta, tutto il resto si ottiene per derivazione.

2.6.4.1 Probabilità marginali

Si ottengono sommando lungo righe o colonne:

```
#> P(D)      = 0.15 (prevalenza)
```

```
#> P(T+)      = 0.297 (test positivo)
```

Notiamo che $P(T^+) \approx 0.30$ è molto più alta della prevalenza (0.15), perché include sia i veri che i falsi positivi.

2.6.4.2 Probabilità condizionate

Si ottengono come rapporto tra probabilità congiunta e marginale:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

Interpretazione epistemica: condizionare significa *restringere* lo spazio delle possibilità a quelle compatibili con l'informazione acquisita, ri-normalizzando le probabilità su questo spazio ristretto.

i Esempio: valore predittivo positivo

La domanda clinica cruciale: “Se il test è positivo, qual è la probabilità che il paziente sia depresso?”

$$P(D | T^+) = \frac{P(D \cap T^+)}{P(T^+)} = \frac{0.1275}{0.1275 + 0.1700} \approx 0.429.$$

```
#> P(D | T+) = 0.429
```

Nonostante l'85% di sensibilità, un test positivo indica depressione solo nel 43% dei casi. La ragione è la bassa prevalenza: la maggior parte dei positivi è falsa. Questo fenomeno, il *paradosso dei test diagnostici*, è stato introdotto nel capitolo precedente e sarà ripreso nel Capitolo 5.

! Messaggio chiave

Una volta specificata la tabella congiunta, marginali e condizionate sono **determinate**. Non c'è libertà di scelta: specificare separatamente $P(A | B)$ e $P(B | A)$ senza una congiunta coerente quasi certamente introduce contraddizioni. La regola è: **specificare la distribuzione congiunta, derivare tutto il resto.**

2.6.5 Verifica empirica mediante simulazione

Un modo potente per verificare la coerenza di un sistema di credenze è simulare dati secondo quella distribuzione e controllare che le frequenze osservate convergano alle probabilità teoriche.

i Verifica Monte Carlo

Simuliamo 100.000 osservazioni dalla tabella congiunta:

```
set.seed(123)
N <- 100000
probs <- c(p_D_pos, p_D_neg, p_Dc_pos, p_Dc_neg)
outcomes <- sample(1:4, size = N, replace = TRUE, prob = probs)
freq_empiriche <- table(outcomes) / N

df_verifica <- data.frame(
  Configurazione = c("DnT+", "DnT-", "D^cnT+", "D^cnT-"),
  Teorica = round(probs, 4),
  Empirica = round(as.numeric(freq_empiriche), 4)
)
print(df_verifica)
```

	Configurazione	Teorica	Empirica
#> 1	DnT+	0.1275	0.1266
#> 2	DnT-	0.0225	0.0226
#> 3	D^cnT+	0.1700	0.1699
#> 4	D^cnT-	0.6800	0.6809




Figura 2.3: Confronto tra probabilità teoriche e frequenze relative ottenute dalla simulazione.

Il confronto riportato nella Figura 2.3 mostra che la simulazione riproduce le conseguenze della distribuzione congiunta specificata. Tuttavia, non dimostra che il modello descriva correttamente una popolazione reale, ma rende visibile ciò che ci si aspetta di osservare se il modello generativo adottato è appropriato.

2.6.6 Estensione a tabelle multidimensionali

Il framework si estende naturalmente a più variabili e più categorie. Il principio è invariato: specificare le probabilità di tutte le combinazioni, derivare tutto il resto.

i Esempio: depressione × ansia (tabella 2×3)

```
tab_2x3 <- matrix(
  c(0.15, 0.20, 0.15, # Depresso: ansia nessuna/lieve/grave
    0.35, 0.10, 0.05), # Non depresso: ansia nessuna/lieve/grave
  nrow = 2, byrow = TRUE,
  dimnames = list(
    Depressione = c("D", "D^c"),
    Ansia = c("Nessuna", "Lieve", "Grave")
  )
)
print(tab_2x3)
#>               Ansia
#> Depressione Nessuna Lieve Grave
#>      D      0.15  0.2  0.15
#>      D^c    0.35  0.1  0.05
cat("\nMarginali depressione:", rowSums(tab_2x3), "\n")
#>
#> Marginali depressione: 0.5 0.5
cat("Marginali ansia:", colSums(tab_2x3), "\n")
#> Marginali ansia: 0.5 0.3 0.2
```

Tabella congiunta 2×3: Depressione × Ansia




Figura 2.4: Distribuzione congiunta tra stato depressivo e tre livelli di ansia.

Riflessioni conclusive

Questo capitolo è iniziato con l'interrogativo sul significato della coerenza delle credenze, per poi introdurre strumenti operativi per la rappresentazione e la gestione di sistemi di credenze complessi. È stato dimostrato che il formalismo probabilistico non è una semplice convenzione, ma la struttura logica necessaria per un ragionamento coerente in condizioni di incertezza. Gli assiomi di Kolmogorov costituiscono vincoli da rispettare per evitare contraddizioni.

Questo quadro teorico offre diversi vantaggi per lo psicologo e il ricercatore. Fornisce uno standard normativo per valutare la correttezza logica di un giudizio probabilistico, a prescindere dalla sua accuratezza empirica. Offre strumenti diagnostici, come i vincoli di Fréchet, per individuare incoerenze nel ragionamento. Le tabelle di probabilità congiunta riassumono in un'unica struttura tutte le informazioni probabilistiche relative a un sistema. Infine, questo quadro stabilisce una relazione tra le astrazioni teoriche e i dati osservabili, mostrando come le credenze si traducano in aspettative empiriche verificabili tramite simulazioni.

Questo capitolo ha esposto i concetti fondamentali, ma alcune questioni rimangono ancora da affrontare. Rimane da definire il metodo per l'assegnazione delle probabilità iniziali in assenza di dati, il problema dell'aggiornamento delle credenze alla luce di nuove evidenze (affrontato dal teorema di Bayes) e il trattamento delle variabili continue che richiedono l'uso di distribuzioni di probabilità. Questi temi verranno trattati nei capitoli successivi, mantenendo la struttura di coerenza qui definita come riferimento costante.

Prima di procedere, è opportuno soffermarsi a considerare un punto filosofico più profondo. La coerenza è una condizione necessaria per evitare contraddizioni, ma non è sufficiente per un ragionamento corretto. Un sistema di credenze può essere internamente coerente, ma errato rispetto ai fatti. La coerenza protegge dagli errori logici, ma non da quelli empirici. Per avvicinarsi alla realtà, è necessario confrontare le credenze con i dati: questo sarà il tema dell'**inferenza bayesiana**.

Esercizi

1. Tre ipotesi mutuamente esclusive ed esaustive ricevono probabilità 0.30, 0.45 e 0.25. Le valutazioni sono coerenti? Spiega il criterio utilizzato.
2. Se $P(A) = 0.72$, quale valore deve avere $P(A^c)$? Spiega il significato della formula del complemento.
3. Due eventi disgiunti hanno probabilità $P(A) = 0.40$ e $P(B) = 0.35$. Qual è $P(A \cup B)$? Perché in questo caso non occorre sottrarre un termine di sovrapposizione?
4. Per due eventi vale $P(A) = 0.60$ e $P(B) = 0.50$. Usa i vincoli di Fréchet per stabilire quali tra i valori 0.05, 0.10, 0.30 e 0.55 possono rappresentare $P(A \cap B)$. Interpreta il risultato senza limitarti al calcolo.
5. Osserva la seguente tabella congiunta e identifica: una probabilità congiunta, una marginale e una condizionata che potrebbe essere calcolata a partire dalla tabella.

	B	B^c	Marginale
A	0.20	0.30	0.50
A^c	0.10	0.40	0.50
Marginale	0.30	0.70	1.00

6. Nel caso del test diagnostico discusso nel capitolo, la sensibilità è 0.85 ma $P(D | T^+) \approx 0.43$. Spiega perché questi due valori non sono in contraddizione.
7. Spiega con parole tue perché la distribuzione congiunta contiene più informazione delle sole probabilità marginali.
8. Una simulazione produce frequenze molto vicine alle probabilità inserite nel modello. Che cosa possiamo concludere e che cosa, invece, non possiamo concludere sulla validità empirica del modello?

Soluzioni

1. Sì. Le tre ipotesi si escludono a vicenda ed esauriscono le possibilità; le probabilità sono non negative e sommano a 1.
2. $P(A^c) = 1 - P(A) = 0.28$. La formula esprime che un evento e il suo complemento esauriscono tutte le possibilità e non possono verificarsi insieme.
3. $P(A \cup B) = 0.40 + 0.35 = 0.75$. Poiché gli eventi sono disgiunti, $P(A \cap B) = 0$ e non vi è alcuna sovrapposizione da sottrarre.
4. I limiti sono $\max(0, 0.60 + 0.50 - 1) = 0.10$ e $\min(0.60, 0.50) = 0.50$. Sono quindi ammissibili 0.10 e 0.30; 0.05 è troppo basso e 0.55 è troppo alto. Il risultato indica che le due probabilità marginali impongono almeno una sovrapposizione del 10%, mentre l'intersezione non può superare l'evento meno probabile.
5. Per esempio, $P(A \cap B) = 0.20$ è una probabilità congiunta e $P(A) = 0.50$ è una marginale. Una condizionata calcolabile è $P(A | B) = 0.20/0.30 \approx 0.67$: tra i casi in cui si verifica B , circa due terzi appartengono anche ad A .
6. La sensibilità è $P(T^+ | D)$: parte dai soggetti depressi e indica quanti risultano positivi. Il valore predittivo positivo è $P(D | T^+)$: parte dai risultati positivi e considera anche i falsi positivi. La prevalenza relativamente bassa fa sì che i falsi positivi pesino molto tra tutti i positivi.
7. Le marginali descrivono separatamente quanto sono plausibili A e B , ma non mostrano come i due eventi si combinano. La congiunta specifica le probabilità di tutte le combinazioni e permette quindi di ricavare sia le marginali sia le condizionate.
8. Possiamo concludere che la procedura di simulazione riproduce le conseguenze del modello specificato. Non possiamo concludere, solo da questo confronto, che le probabilità inserite descrivano correttamente una popolazione reale o che il modello sia empiricamente adeguato.

i Punti chiave

- Una funzione di probabilità coerente assegna valori non negativi, attribuisce probabilità 1 allo spazio campionario ed è additiva per eventi disgiunti.
- La probabilità del complemento, la monotonia e la regola generale dell'unione derivano dagli assiomi.
- I vincoli di Fréchet stabiliscono l'intervallo logicamente ammissibile per $P(A \cap B)$ quando sono note $P(A)$ e $P(B)$.
- Una tabella congiunta rappresenta le probabilità di tutte le combinazioni tra gli eventi considerati.
- Le probabilità marginali si ottengono sommando righe o colonne; le probabilità condizionate si ottengono rapportando una probabilità congiunta alla marginale pertinente.
- La coerenza è necessaria, ma non garantisce che le credenze siano empiricamente corrette.
- Nel Capitolo 3 applicheremo questi principi a situazioni di equiprobabilità e al conteggio dei casi possibili.

Equiprobabilità e calcolo combinatorio

i In sintesi

Da sapere L'equiprobabilità è giustificata solo quando le informazioni disponibili non distinguono razionalmente gli esiti. In questo caso la formula classica della probabilità consente di trasformare un conteggio in una probabilità. Permutazioni, disposizioni e combinazioni servono a contare configurazioni diverse; la distribuzione Beta permette invece di rappresentare credenze non uniformi su una probabilità continua.

Da saper fare Valutare se un'ipotesi di equiprobabilità è plausibile; scegliere la tecnica di conteggio appropriata; spiegare il significato delle formule combinatorie; interpretare media e concentrazione di una distribuzione Beta; comprendere come dati binomiali modificano una distribuzione Beta.

Introduzione

Qual è la probabilità di ottenere «testa» nel lancio di una moneta? La risposta spontanea, $1/2$, sembra ovvia. Eppure, dietro questa apparente semplicità si nasconde una questione epistemologica importante.

La formula

$$\text{Probabilità} = \frac{\text{casi favorevoli}}{\text{casi possibili}}$$

viene spesso presentata come *la* definizione di probabilità. Ma questa formula è legittima soltanto quando tutti gli esiti elementari possono essere trattati come ugualmente plausibili. Prima di contare i casi, dobbiamo quindi chiederci perché sia ragionevole assegnare loro la stessa probabilità.

Questo capitolo chiarisce il significato dell'equiprobabilità, presenta le principali tecniche di calcolo combinatorio e mostra come superare l'ipotesi di uniformità mediante la distribuzione Beta.

3.1 Perché l'equiprobabilità è importante in psicologia?

L'equiprobabilità compare ogni volta che randomizziamo l'ordine degli stimoli, estraiamo partecipanti, formiamo gruppi o descriviamo le possibilità di risposta. In questi casi può essere un'ipotesi utile, ma non deve diventare una scorciatoia automatica. Le persone differiscono per abilità, preferenze e propensioni alla risposta; gli item hanno difficoltà diverse; gli interventi possono produrre esiti differenti in sottogruppi diversi.

Comprendere quando gli esiti possono essere trattati come equiprobabili aiuta quindi a distinguere due operazioni: **contare le possibilità** e **assegnare loro una probabilità**. Il calcolo combinatorio risolve il primo problema; la modellizzazione probabilistica deve giustificare il secondo.

Prerequisiti

Per seguire questo capitolo è necessario aver letto Capitolo 1 e Capitolo 2. Per la notazione matematica può essere utile consultare Appendice A. Per un richiamo alle operazioni tra insiemi ed eventi e alle nozioni di base del calcolo combinatorio, consulta le appendici dedicate fornite nel Companion. È sufficiente una familiarità elementare con R per leggere gli esempi computazionali; gli esempi non richiedono competenze di programmazione avanzate.

Panoramica del capitolo

Il percorso che seguiremo è questo:

1. chiariremo il **principio di indifferenza** e le condizioni che possono giustificare l'equiprobabilità;
2. ricaveremo la **formula classica** come conseguenza dell'equiprobabilità;
3. distingueremo **principio della somma**, **principio del prodotto**, permutazioni, disposizioni e combinazioni;
4. vedremo perché, nei fenomeni psicologici, l'equiprobabilità è spesso inadeguata;
5. introdurremo la **distribuzione Beta** e l'aggiornamento Beta-Binomiale;
6. collegheremo questi strumenti ad alcuni esempi psicologici.

Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()

library(ggplot2)
```



```
apply_visual_theme()
```

3.2 Il principio di indifferenza

Partiamo dalla domanda fondamentale: quando è legittimo assumere che tutti gli esiti siano ugualmente probabili?

La risposta, secondo la prospettiva bayesiana, non riguarda le proprietà fisiche degli oggetti, ma *lo stato delle nostre conoscenze*. Il principio che giustifica l'equiprobabilità è chiamato **principio di indifferenza**.

Definizione 3.1 (Principio di indifferenza). Se non abbiamo *ragioni per distinguere* tra n possibilità mutualmente esclusive ed esaustive, è razionalmente coerente assegnare a ciascuna la stessa credenza, pari a $1/n$.

3.2.1 L'equiprobabilità come simmetria dell'ignoranza

Questa definizione merita una lettura attenta. Non dice che gli esiti *sono* equiprobabili. Dice che è *razionale trattarli come tali* quando non abbiamo informazioni che ci permettano di distinguerli.

In questa prospettiva, l'equiprobabilità non è una proprietà del mondo, ma una proprietà della nostra relazione epistemica con esso. Riflette la **simmetria della nostra ignoranza**: se non conosciamo nulla che favorisca un esito rispetto a un altro, non abbiamo basi razionali per assegnare probabilità diverse.

3.2.2 Condizioni di applicabilità

Il principio di indifferenza è potente ma non automatico. La sua applicazione richiede che siano soddisfatte alcune condizioni:

1. **Simmetria fisica rilevante**: il sistema non deve presentare differenze *rilevanti* tra gli esiti.
2. **Ignoranza genuina**: non devono essere disponibili informazioni che permettano di distinguere razionalmente tra gli esiti.
3. **Assenza di struttura rilevante**: il processo non deve presentare pattern o vincoli che rendano alcuni risultati più probabili di altri.

La parola chiave qui è *giudizio*. L'equiprobabilità non si applica in modo meccanico, ma richiede una valutazione esplicita del contesto.

! Due modi di motivare l'equiprobabilità

Lettura frequentista: un modello di dado equo assegna probabilità $1/6$ a ciascuna faccia e collega questa probabilità alle frequenze relative attese in molte ripetizioni.

Lettura bayesiana: date le informazioni disponibili e la simmetria del problema,

non vi sono ragioni per assegnare probabilità diverse alle sei facce; ciascuna riceve quindi probabilità $1/6$.

In entrambe le letture l'equiprobabilità dipende da un modello. La differenza riguarda soprattutto il significato attribuito alla probabilità.

i Indifferenza e scelta della parametrizzazione

L'applicazione ingenua del principio di indifferenza può produrre risposte diverse. Supponiamo che il lato L di un cubo possa variare tra 0 e 1 metro. Qual è la probabilità che $L > 0.5$?

- Se assegniamo una distribuzione uniforme alla *lunghezza* L , la probabilità è 0.5.
- Se assegniamo una distribuzione uniforme al *volume* $V = L^3$, la probabilità corrispondente è diversa.

Il problema non ha una risposta univoca finché non specifichiamo rispetto a quale quantità adottiamo l'uniformità. L'indifferenza non è dunque indipendente dalla rappresentazione scelta: la parametrizzazione fa parte del modello.

3.3 La formula classica come caso speciale

Una volta compreso il principio di indifferenza, possiamo finalmente dare una collocazione precisa alla formula classica della probabilità. Non si tratta di una definizione fondamentale, ma di un **teorema derivato** che vale sotto condizioni specifiche.

Teorema 3.1 (Formula classica della probabilità). *Sia $\Omega = \{\omega_1, \dots, \omega_n\}$ uno spazio campionario finito in cui, per **simmetria epistemica**, tutti gli esiti sono ritenuti equiprobabili:*

$$P(\omega_i) = \frac{1}{n} \quad \text{per ogni } i.$$

Allora, per qualsiasi evento $A \subseteq \Omega$,

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{casi favorevoli}}{\text{casi possibili}}.$$

! Messaggio chiave

La formula classica **non definisce** che cosa sia una probabilità. È una conseguenza degli assiomi e dell'ipotesi di equiprobabilità; non può essere applicata quando alcuni esiti sono più plausibili di altri.

3.4 Tecniche di calcolo combinatorio

Assumendo che l'equiprobabilità sia stata verificata, il calcolo combinatorio fornisce gli strumenti per contare le configurazioni. La scelta della tecnica appropriata dipende da due domande:

1. L'ordine conta?
2. Selezioniamo tutti gli elementi o solo alcuni?

3.4.1 Principio della somma

Quando le possibilità si suddividono in categorie mutuamente esclusive, il numero totale è la somma delle possibilità appartenenti a ciascuna categoria:

$$n_{\text{totale}} = n_1 + n_2 + \dots + n_k.$$

i Esempio psicologico

Un paziente può accedere a:

- 8 protocolli cognitivi,
- 6 protocolli comportamentali,
- 10 protocolli integrati.

Il numero complessivo di protocolli disponibili è:

$$8 + 6 + 10 = 24.$$

Se un protocollo venisse estratto uniformemente tra i 24 disponibili, ciascun protocollo avrebbe probabilità $1/24$ di essere selezionato.

Nota: il principio della somma stabilisce quante opzioni esistono. L'equiprobabilità dipende invece dal meccanismo di selezione e non sarebbe appropriata se le indicazioni cliniche rendessero alcuni protocolli preferibili per quello specifico paziente.

3.4.2 Principio del prodotto

Quando una configurazione viene costruita attraverso più passaggi e ogni scelta al primo passaggio può essere completata mediante tutte le scelte previste nei passaggi successivi, il numero totale delle configurazioni si ottiene moltiplicando il numero delle alternative disponibili a ciascun passaggio:

$$n_{\text{totale}} = n_1 \times n_2 \times \dots \times n_k.$$

Questo è un principio di conteggio: non richiede che le scelte siano probabilisticamente indipendenti.

i Esempio psicologico

Nella progettazione di uno studio:

- 3 metodi di valutazione,
- 4 frequenze di misurazione,
- 2 durate di follow-up,

producono:

$$3 \times 4 \times 2 = 24$$

disegni possibili. Il principio del prodotto conta le configurazioni; non afferma che siano tutte ugualmente appropriate. Se un meccanismo di randomizzazione selezionasse uniformemente uno dei 24 disegni, ciascuno avrebbe probabilità $1/24$ di essere selezionato.

Nota: nella pratica, fattibilità, costo e validità rendono alcuni disegni preferibili ad altri. Il conteggio delle alternative non sostituisce la valutazione metodologica.

3.4.3 Permutazioni: tutti gli ordinamenti di n elementi

Le **permutazioni** contano i modi di ordinare n oggetti distinti quando l'ordine è rilevante:

$$P_n = n! = n \times (n - 1) \times \dots \times 1. \quad (3.1)$$

L'intuizione è semplice: il primo elemento può essere scelto in n modi, il secondo in $n - 1$, e così via.

i Esempio psicologico

In un esperimento sulla memoria, 5 parole vengono presentate in ordine casuale. Quanti ordinamenti sono possibili?

$$5! = 120.$$

Se la randomizzazione è davvero casuale (equiprobabilità degli ordinamenti), ogni sequenza specifica ha probabilità $1/120 \approx 0.008$.

```
parole <- c("tavolo", "fiore", "automobile", "stella", "libro")
n_perm <- factorial(length(parole))
```

```
cat("Parole:", paste(parole, collapse = ", "), "\n")
#> Parole: tavolo, fiore, automobile, stella, libro
cat("Ordini possibili:", n_perm, "\n")
#> Ordini possibili: 120
cat("P(ordine specifico):", round(1/n_perm, 5), "\n\n")
#> P(ordine specifico): 0.00833
```

```
# Esempi di sequenze
```

```

set.seed(123)
cat("Sequenze casuali:\n")
#> Sequenze casuali:
for(i in 1:3) {
  cat(" ", paste(sample(parole), collapse = " → "), "\n")
}
#>   automobile → fiore → libro → stella → tavolo
#>   automobile → tavolo → fiore → libro → stella
#>   fiore → automobile → tavolo → stella → libro

```

Nota psicologica: l'equiprobabilità riguarda la selezione, non gli effetti psicologici dell'ordine.

3.4.4 Disposizioni: k elementi ordinati da n

Le **disposizioni** contano i modi di scegliere e ordinare k oggetti distinti da un insieme di n elementi:

$$D_{n,k} = \frac{n!}{(n-k)!} = n \times (n-1) \times \dots \times (n-k+1). \quad (3.2)$$

i Esempio psicologico

Con 8 partecipanti e 3 ruoli distinti (facilitatore, osservatore, responsabile del tempo), le assegnazioni possibili sono:

$$D_{8,3} = \frac{8!}{5!} = 8 \times 7 \times 6 = 336.$$

Se un meccanismo di assegnazione scegliesse uniformemente tra le 336 possibilità, ogni assegnazione avrebbe probabilità $1/336 \approx 0.003$.

Nota: nella pratica, i ruoli vengono spesso assegnati in base alle competenze. In tal caso il conteggio rimane corretto, ma l'equiprobabilità non descrive il processo di assegnazione.

3.4.5 Combinazioni: k elementi non ordinati da n

Le **combinazioni** contano i sottoinsiemi di k elementi scelti da n , quando l'ordine non è rilevante:

$$C_{n,k} = \binom{n}{k} = \frac{n!}{k!(n-k)!}. \quad (3.3)$$

i Esempio psicologico

Con 12 volontari per il supporto tra pari, le coppie possibili sono:

$$\binom{12}{2} = \frac{12!}{2! \cdot 10!} = 66.$$

Se la coppia venisse estratta uniformemente tra le 66 possibilità, ciascuna avrebbe probabilità $1/66 \approx 0.015$.

Nota: se la formazione delle coppie tiene conto della compatibilità, il conteggio resta 66 ma le probabilità di selezione non sono necessariamente uguali.

💡 Riepilogo: quale tecnica usare?

Tecnica	Ordine conta?	Formula	Esempio psicologico
Permutazioni	Sì (tutti gli elementi)	$n!$	Ordine di n stimoli
Disposizioni	Sì (solo k elementi)	$\frac{n!}{(n-k)!}$	Assegnazione di ruoli
Combinazioni	No	$\binom{n}{k}$	Formazione di gruppi

❗ Il punto fondamentale da non dimenticare

Le formule combinatorie contano le configurazioni possibili anche quando queste non sono equiprobabili. L'equiprobabilità è necessaria soltanto quando trasformiamo il conteggio in una probabilità mediante il rapporto tra casi favorevoli e casi possibili. La combinatoria ci dice *quante* configurazioni esistono, non *quali* siano più plausibili.

3.5 Quando l'equiprobabilità non si applica

Finora abbiamo esaminato i casi in cui l'equiprobabilità può essere utile. Nei modelli sostantivi della ricerca psicologica, tuttavia, persone, item e contesti presentano spesso differenze sistematiche: l'equiprobabilità deve quindi essere giustificata caso per caso.

3.5.1 La variabilità è la norma, non l'anomalia

Quasi ogni fenomeno psicologico presenta una variabilità sistematica. Gli item di un test hanno difficoltà diverse. Le persone hanno abilità diverse. I trattamenti funzionano in modo diverso per pazienti diversi. Ignorare questa variabilità assumendo equiprobabilità significa perdere l'essenza del fenomeno.

3.5.2 Esempio: difficoltà degli item nei test

Consideriamo un test con 5 item di difficoltà diversa:

```
item_difficolta <- c(0.9, 0.7, 0.5, 0.3, 0.1)
cat("Probabilità di risposta corretta per item:\n")
#> Probabilità di risposta corretta per item:
for (i in seq_along(item_difficolta)) {
  cat("  Item", i, ":", item_difficolta[i], "\n")
}
#>   Item 1 : 0.9
#>   Item 2 : 0.7
#>   Item 3 : 0.5
#>   Item 4 : 0.3
#>   Item 5 : 0.1
set.seed(123)
risposte <- replicate(1000, rbinom(5, 1, item_difficolta))
cat("\nProporzioni osservate (simulate):", round(rowMeans(risposte), 2))
#>
#> Proporzioni osservate (simulate): 0.89 0.71 0.48 0.29 0.1
```

Assumere equiprobabilità ($P = 0.5$ per ogni item) produrrebbe una sottostima sugli item facili e una sovrastima su quelli difficili. L'errore non è solo quantitativo: si ignorerebbe una proprietà fondamentale degli item.

3.5.3 La lezione più ampia

L'equiprobabilità è un'ipotesi da verificare, non da assumere per default. Quando la rifiutiamo, riconosciamo che il mondo è più ricco di quanto l'equiprobabilità possa rappresentare. La distribuzione Beta, che vedremo ora, ci offre uno strumento per esprimere questa ricchezza.

3.6 La distribuzione Beta: dal discreto al continuo

Finora abbiamo ragionato su spazi finiti. Ma in molti contesti psicologici dobbiamo stimare dei **parametri sconosciuti** che possono assumere qualsiasi valore in un intervallo continuo (ad esempio, la probabilità di risposta a un trattamento).

La **distribuzione Beta** è lo strumento che ci permette di rappresentare le nostre credenze su questi parametri.

3.6.1 Intuizione: la Beta come “memoria di esperienze”

La distribuzione Beta(α, β) descrive quanto sono plausibili i diversi valori di una probabilità θ compresa tra 0 e 1. I parametri possono essere interpretati come **pseudo-conteggi** che sintetizzano la direzione e la forza dell'informazione precedente; non devono però essere confusi necessariamente con osservazioni reali.

- **Beta(1,1)**: distribuzione uniforme rispetto a θ ; intervalli della stessa ampiezza ricevono la stessa probabilità.

- **Beta(5,5)**: distribuzione simmetrica e concentrata intorno a 0.5.
- **Beta(20,10)**: distribuzione concentrata su valori relativamente elevati, con media circa 0.67.
- **Beta(2,8)**: distribuzione concentrata su valori relativamente bassi, con media 0.20.

```
theta <- seq(0, 1, length.out = 500)
beta_params <- list(
  "Beta(1,1): Ignoranza totale" = c(1, 1),
  "Beta(5,5): Credenza centrale" = c(5, 5),
  "Beta(20,10): Aspettativa alta" = c(20, 10),
  "Beta(2,8): Aspettativa bassa" = c(2, 8)
)
df_beta <- data.frame()
for (nome in names(beta_params)) {
  params <- beta_params[[nome]]
  df_beta <- rbind(df_beta, data.frame(
    theta = theta,
    Densita = dbeta(theta, params[1], params[2]),
    Distribuzione = nome
  ))
}
ggplot(df_beta, aes(x = theta, y = Densita, color = Distribuzione)) +
  geom_line(linewidth = 1.2) +
  facet_wrap(~ Distribuzione, scales = "free_y", ncol = 2) +
  labs(x = expression(theta), y = "Densità",
    title = "Forme della distribuzione Beta") +
  theme(legend.position = "none")
```




Figura 3.1: Quattro distribuzioni Beta con posizioni e concentrazioni differenti.

La Figura 12.5 mostra che i due parametri controllano sia la posizione sia la concentrazione della distribuzione.

3.6.2 Due parametri, due significati

- **Posizione:** la media della distribuzione è

$$\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}.$$

- **Concentrazione:** a parità di media, $\alpha + \beta$ controlla quanto la distribuzione è raccolta intorno ai valori centrali. Valori più alti indicano una credenza più concentrata; valori più bassi una maggiore dispersione.

3.6.3 Beta(1,1): l'equiprobabilità continua

Beta(1,1) è la **distribuzione uniforme** su $[0, 1]$: intervalli della stessa ampiezza ricevono la stessa probabilità. È quindi un analogo continuo dell'equiprobabilità rispetto al parametro θ , ma non rappresenta un'ignoranza assoluta indipendente dalla parametrizzazione:

Equiprobabilità discreta $\longleftrightarrow$ Uniformità continua (Beta(1,1))

3.6.4 Aggiornamento bayesiano: il modello Beta-Binomiale

Se partiamo da Beta(α, β) e osserviamo k successi su n prove, la nuova credenza (posteriore) è:

$$\theta \sim \text{Beta}(\alpha, \beta) \xrightarrow{\text{osserviamo } k \text{ su } n} \theta | k \sim \text{Beta}(\alpha + k, \beta + n - k).$$

I successi osservati si “aggiungono” ad α , gli insuccessi a β . L'aggiornamento è intuitivo: la conoscenza precedente si combina con i nuovi dati.

i Esempio: test a scelta multipla

Uno studente risponde a 20 domande a scelta multipla (4 opzioni). Adottiamo un prior Beta(1,3), centrato sulla probabilità 0.25 prevista da una risposta casuale a quattro alternative. Se osserva 7 risposte corrette, la posterior diventa Beta(8,16), con media $8/24 \approx 0.33$.

```
theta <- seq(0, 1, length.out = 500)
prior <- dbeta(theta, 1, 3)
posterior <- dbeta(theta, 8, 16)
df <- data.frame(
  theta = rep(theta, 2),
  Densita = c(prior, posterior),
  Tipo = rep(c("Prior Beta(1,3)", "Posterior Beta(8,16)"), each = 500)
)
ggplot(df, aes(x = theta, y = Densita, color = Tipo)) +
  geom_line(linewidth = 1.3) +
  geom_vline(xintercept = c(0.25, 0.33), linetype = "dashed", alpha =
    0.5) +
  labs(title = "Aggiornamento bayesiano: prima e dopo 20 risposte",
```

```
x = expression(theta ~ "(probabilità di risposta corretta)",
y = "Densità")
```




Figura 3.2: Distribuzione a priori e distribuzione a posteriori dopo 7 risposte corrette su 20.

La Figura 3.2 rende visibile lo spostamento dalla distribuzione a priori alla distribuzione a posteriori.

Intervallo di credibilità 95%:

```
alpha_post <- 8
beta_post <- 16
ci <- qbeta(c(0.025, 0.975), alpha_post, beta_post)
cat("Media posteriore:", round(alpha_post/(alpha_post + beta_post), 3),
    "\n")
#> Media posteriore: 0.333
cat("Intervallo 95%: [", round(ci[1], 2), ",", round(ci[2], 2), "]")
#> Intervallo 95%: [ 0.16 , 0.53 ]
```

L'intervallo è circa [0.16,0.53]. Condizionatamente al modello, al prior e ai dati osservati, la probabilità posteriore che θ appartenga a questo intervallo è 0.95. L'ampiezza dell'intervallo mostra che, dopo sole 20 risposte, rimane una notevole incertezza.

3.6.5 Aggiornamento sequenziale: la conoscenza si accumula

Una conseguenza pratica importante è che l'aggiornamento può avvenire **man mano che si osservano nuovi dati**, senza ricalcolare tutto da capo.

```
set.seed(42)
theta_vero <- 0.4
```

```

n_domande <- 20
risposte <- rbinom(n_domande, 1, theta_vero)
alpha <- 1
beta <- 3
theta_grid <- seq(0, 1, length.out = 200)
df_evol <- data.frame()
for (i in c(0, 5, 10, 20)) {
  if (i == 0) {
    dens <- dbeta(theta_grid, alpha, beta)
    label <- "Prior (n=0)"
  } else {
    a <- 1 + sum(risposte[1:i])
    b <- 3 + i - sum(risposte[1:i])
    dens <- dbeta(theta_grid, a, b)
    label <- paste0("n = ", i)
  }
  df_evol <- rbind(df_evol, data.frame(
    theta = theta_grid, Densita = dens, n = label
  ))
}
ggplot(df_evol, aes(x = theta, y = Densita, color = n)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = theta_vero, linetype = "dashed") +
  annotate("text", x = theta_vero + 0.05, y = max(df_evol$Densita) * 0.9,
    label = expression(theta~"vero"), hjust = 0) +
  labs(title = "Evoluzione delle credenze all'accumularsi dei dati",
    x = expression(theta), y = "Densità", color = "Osservazioni")

```




Figura 3.3: Evoluzione della distribuzione Beta durante un aggiornamento sequenziale simulato.

La Figura 3.3 mostra l'evoluzione della distribuzione in quattro momenti della stessa sequenza simulata.

In questa simulazione la distribuzione tende a spostarsi verso il valore che ha generato i dati ($\theta = 0.4$) e a restringersi. Il restringimento riflette l'aumento dell'informazione; la posizione può però oscillare da un aggiornamento al successivo, perché i dati osservati sono variabili.

3.7 Applicazioni psicologiche

Gli strumenti che abbiamo sviluppato trovano applicazione diretta in contesti psicologici concreti.

3.7.1 Item Response Theory (IRT)

La **teoria della risposta agli item** formalizza ciò che ogni insegnante sa intuitivamente: la probabilità di rispondere correttamente a una domanda dipende sia dallo studente sia dalla domanda. Un modello logistico semplice, noto come modello di Rasch, è:

$$P(\text{corretto} \mid \theta, b) = \frac{1}{1 + e^{-(\theta - b)}},$$

dove θ è l'abilità dello studente e b la difficoltà dell'item. Questa formulazione non assume equiprobabilità: riconosce che la probabilità di risposta corretta cambia sistematicamente in funzione dell'abilità della persona e della difficoltà dell'item.

3.7.2 Bias di risposta nei questionari

Le risposte ai questionari sono influenzate da fenomeni sistematici come l'**acquiescenza** (tendenza a rispondere "sì"), la **desiderabilità sociale** o gli **effetti di posizione**. Questi bias significano che le opzioni di risposta non sono equiprobabili. Un modello adeguato deve esplicitare queste tendenze, distinguendo la variabilità dovuta al costrutto misurato da quella dovuta allo stile di risposta.

3.7.3 Efficacia degli interventi

Quando si valuta l'efficacia di un trattamento, l'equiprobabilità è particolarmente inappropriata. Non tutti i pazienti rispondono allo stesso modo. Un modello bayesiano può:

1. incorporare informazioni provenienti da studi precedenti mediante il prior;
2. aggiornare le stime quando si accumulano nuovi dati;
3. rappresentare esplicitamente la variabilità interindividuale;
4. quantificare l'incertezza sui parametri in modo interpretabile.

Questo approccio produce stime che riconoscono la complessità del fenomeno, invece di nascondersela sotto l'ipotesi di uniformità.

Riflessioni conclusive

Siamo partiti da una domanda apparentemente semplice: quando possiamo considerare gli esiti come ugualmente probabili? La risposta, però, dipende dalle informazioni disponibili e dal modello adottato.

L'equiprobabilità non deriva dal semplice fatto che possiamo elencare gli esiti. Il calcolo combinatorio stabilisce quante configurazioni sono possibili, ma per trasformare questi conteggi in probabilità è necessario anche giustificare che le configurazioni siano trattate nello stesso modo dal meccanismo o dallo stato informativo preso in considerazione.

Nella ricerca psicologica, tuttavia, questa condizione è spesso violata: le persone, gli item e i contesti differiscono sistematicamente. La distribuzione Beta offre un primo strumento per rappresentare credenze non uniformi su una probabilità e mostra come l'informazione precedente possa essere aggiornata alla luce di nuovi dati.

Nel Capitolo 5 vedremo come la probabilità condizionata e il teorema di Bayes generalizzano questo processo di aggiornamento.

Esercizi

1. Un dado viene descritto soltanto come «a sei facce». È sufficiente questa informazione per assegnare probabilità $1/6$ a ogni faccia? Spiega quale ulteriore assunzione è necessaria.
2. In un'urna ci sono 3 palline rosse e 2 blu. Supponendo che ogni pallina abbia la stessa probabilità di essere estratta, qual è la probabilità di ottenere una pallina rossa? Indica quale parte del ragionamento dipende dal conteggio e quale dall'equiprobabilità.
3. Uno studio può usare 2 tipi di stimolo e 3 tempi di misurazione. Quanti disegni si possono formare combinando un tipo di stimolo con un tempo? Quale principio di conteggio stai usando?
4. Per ciascuna situazione indica se servono permutazioni, disposizioni o combinazioni:
 - a. ordinare tutti e 5 gli stimoli di una lista;
 - b. assegnare 3 ruoli diversi a 8 partecipanti;
 - c. scegliere 3 persone da un gruppo di 8 senza attribuire ruoli.
5. Cinque parole possono essere presentate in $5! = 120$ ordini. Che cosa possiamo concludere da questo conteggio? Che cosa occorre aggiungere per affermare che ogni ordine ha probabilità $1/120$?
6. Confronta $\text{Beta}(5,5)$ e $\text{Beta}(20,20)$. Hanno la stessa media? Quale delle due esprime una credenza più concentrata intorno a 0.5?
7. Un prior $\text{Beta}(2,3)$ viene aggiornato con 4 successi e 1 insuccesso. Qual è la distribuzione a posteriori? Spiega il significato dell'aumento dei due parametri.
8. Dopo un'analisi otteniamo un intervallo di credibilità al 95% pari a $[0.16, 0.53]$. Che cosa significa questa affermazione nell'interpretazione bayesiana? Perché

non equivale a dire che il modello è certamente corretto?

Soluzioni

1. No. Occorre assumere che il dado e il meccanismo di lancio non forniscano ragioni per favorire una faccia rispetto alle altre. La presenza di sei facce permette di elencare gli esiti, ma non garantisce da sola l'equiprobabilità.
2. I casi favorevoli sono 3 e quelli possibili 5, quindi $P(\text{rossa}) = 3/5 = 0.60$. Il conteggio fornisce i numeri 3 e 5; il rapporto è legittimo perché abbiamo assunto che ogni pallina sia selezionata con la stessa probabilità.
3. I disegni sono $2 \times 3 = 6$. Usiamo il principio del prodotto, perché a ciascuna scelta del tipo di stimolo possono essere associate tutte e tre le scelte del tempo di misurazione.
4. a. Permutazioni, perché si ordinano tutti gli elementi. b. Disposizioni, perché si scelgono tre persone e i ruoli sono distinti. c. Combinazioni, perché si scelgono tre persone e l'ordine non conta.
5. Possiamo concludere che esistono 120 ordini distinti. Per attribuire probabilità $1/120$ a ciascuno dobbiamo anche assumere che la procedura di randomizzazione selezioni uniformemente tra i 120 ordini.
6. Entrambe hanno media 0.5. Beta(20,20) è più concentrata perché la somma dei parametri è maggiore; esprime quindi meno dispersione intorno alla stessa posizione centrale.
7. La posterior è Beta($2 + 4, 3 + 1$) = Beta(6,4). I successi aumentano il primo parametro e gli insuccessi il secondo: i nuovi dati si combinano con l'informazione rappresentata dal prior.
8. Condizionatamente al modello, al prior e ai dati, la probabilità posteriore che il parametro appartenga all'intervallo è 0.95. L'affermazione riguarda l'incertezza sul parametro *all'interno del modello*; non dimostra che le assunzioni del modello siano corrette.

Punti chiave

- L'equiprobabilità deve essere giustificata dalle informazioni e dal meccanismo considerato; non deriva dal semplice elenco degli esiti.
- La formula $P(A) = |A|/|\Omega|$ vale quando gli esiti elementari sono equiprobabili.
- Il principio della somma conta alternative mutuamente esclusive; il principio del prodotto conta configurazioni costruite attraverso più passaggi.
- Permutazioni, disposizioni e combinazioni differiscono per il ruolo dell'ordine e per il numero di elementi selezionati.
- La combinatoria conta configurazioni; solo un'ulteriore ipotesi di equiprobabilità permette di trasformare i conteggi in probabilità.
- La distribuzione Beta rappresenta credenze su una probabilità continua mediante posizione e concentrazione.

- Beta(1,1) è uniforme rispetto a θ , ma l'uniformità dipende dalla parametrizzazione scelta.
- Nel modello Beta-Binomiale i dati aggiornano i parametri aggiungendo successi e insuccessi.

Probabilità condizionata come aggiornamento

i In sintesi

Da sapere La probabilità condizionata descrive come cambia una valutazione probabilistica quando restringiamo l'attenzione alle situazioni compatibili con una nuova informazione. L'indipendenza è il caso in cui il condizionamento non modifica la probabilità; il teorema del prodotto e la legge della probabilità totale permettono di costruire probabilità congiunte e marginali. Il paradosso di Simpson mostra perché l'aggregazione può nascondere differenze rilevanti tra sottogruppi.

Da saper fare Interpretare $P(A | B)$; distinguere probabilità dirette e inverse; riconoscere indipendenza e disgiunzione; spiegare il significato del teorema del prodotto e della legge della probabilità totale; comprendere perché una relazione aggregata può differire da quelle osservate nei sottogruppi.

Introduzione

Immaginate di essere uno psicologo clinico che ha appena ricevuto l'esito positivo di un test diagnostico per un paziente. Prima della somministrazione del test, avevate formulato una stima della probabilità che il paziente soffrisse di depressione. Ora il referto è sul tavolo. Cosa è cambiato?

Dal punto di vista ontologico, nulla; da quello epistemico, tutto. I fatti oggettivi non sono cambiati: il paziente era depresso o non lo era già prima che il test venisse eseguito. Ciò che è cambiato radicalmente è il vostro stato di conoscenza. Avete acquisito un'informazione nuova che deve ora essere integrata in modo coerente, ristrutturando sistematicamente la valutazione iniziale.

Questo processo dinamico di revisione razionale delle credenze alla luce dell'evidenza empirica costituisce l'essenza stessa del pensiero bayesiano. Lo strumento formale che lo incarna è la **probabilità condizionata**, il ponte matematico che collega le conoscenze precedenti a quelle successive all'osservazione.

4.1 Perché la probabilità condizionata è importante in psicologia?

In psicologia, quasi ogni valutazione dipende strettamente dal contesto informativo che la corredo. La probabilità che un individuo presenti un determinato disturbo cambia in base all'esito diagnostico, la probabilità di rievocare uno stimolo varia in funzione delle condizioni di apprendimento e la probabilità di fornire una risposta corretta dipende dall'interazione tra abilità del soggetto, difficoltà dell'item e conoscenze pregresse.

La probabilità condizionata permette di rappresentare formalmente questi cambiamenti. È utile per descrivere l'**aggiornamento** prodotto da nuove informazioni, per distinguere la probabilità di un dato sotto un'ipotesi dalla probabilità dell'ipotesi dopo aver osservato il dato, per formulare e valutare assunzioni di **indipendenza**, per combinare scenari alternativi mediante la **legge della probabilità totale** e per evitare conclusioni fuorvianti quando i dati aggregati nascondono sottogruppi differenti.

Questi concetti preparano il terreno per il teorema di Bayes che, nel prossimo capitolo, ci permetterà di collegare probabilità condizionate orientate in direzioni opposte.

Prerequisiti

Per seguire questo capitolo è necessario aver letto Capitolo 1, Capitolo 2 e Capitolo 3.

Per la notazione matematica può essere utile consultare Appendice A. Per un richiamo alle operazioni tra insiemi ed eventi e alla notazione delle sommatorie, consulta le appendici dedicate fornite nel Companion.

È sufficiente saper leggere una tabella congiunta 2×2 . Gli esempi in R servono a visualizzare i concetti e non richiedono competenze di programmazione avanzate.

Panoramica del capitolo

Il percorso che seguiremo è questo:

1. definiremo la **probabilità condizionata** come restrizione e rinormalizzazione;
2. esamineremo le sue proprietà e un esempio di test diagnostico;
3. introdurremo l'**indipendenza stocastica** e la distingueremo dalla disgiunzione;
4. useremo il **teorema del prodotto** per scomporre probabilità congiunte;
5. applicheremo la **legge della probabilità totale** a popolazioni eterogenee;
6. analizzeremo il **paradosso di Simpson** come avvertimento contro aggregazioni non motivate.

i Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()

library(ggplot2)

apply_visual_theme()
```

4.2 Definizione e interpretazione epistemica

Partiamo da una credenza iniziale in un evento A . Poi apprendiamo che si è verificato un altro evento B . Come dovrebbe cambiare la nostra credenza in A ?

La risposta intuitiva è che dobbiamo considerare soltanto le situazioni in cui B è vero e valutare quale quota della probabilità attribuita a B appartiene anche ad A . La formula seguente traduce questa idea in linguaggio matematico.

Definizione 4.1 (Probabilità condizionata). Se $P(B) > 0$, la *probabilità condizionata* di A dato B è definita come:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}. \quad (4.1)$$

Interpretazione epistemica: $P(A | B)$ quantifica il grado di credenza in A quando si assume o si apprende che B è vero. In altri contesti la stessa quantità descrive la probabilità di A nella sottopopolazione definita da B .

4.2.1 Il meccanismo dell'aggiornamento

Apprendere che B è vero innesca un processo in due fasi:

1. Riduzione epistemica — Lo spazio delle possibilità Ω viene ristretto al solo sottoinsieme B . Tutte le configurazioni in cui B è falso vengono eliminate, non perché siano diventate “impossibili” in senso metafisico, ma perché sono diventate *irrilevanti* per il nostro ragionamento.

2. Rinormalizzazione — Le probabilità delle configurazioni rimanenti (quelle in cui B è vero) vengono riscalate in modo che tornino a sommare a 1, con un fattore di scala pari a $1/P(B)$.

Questo procedimento garantisce **coerenza**: se avessimo modellato fin dall’inizio un mondo in cui B è l’unica possibilità, avremmo ottenuto esattamente le stesse probabilità relative.

4.2.2 Un’analogia: lo zoom fotografico

Pensate alla distribuzione di probabilità congiunta come a una fotografia. La probabilità condizionata è come fare uno **zoom** su una porzione dell’immagine (la regione B): da un lato si perde di vista tutto ciò che sta fuori dalla regione (riduzione),

dall'altro i dettagli della porzione selezionata riempiono ora l'intero schermo (rinormalizzazione), mentre i rapporti tra gli elementi **all'interno** della regione rimangono invariati.

Probabilità condizionata: 'zoom' nello spazio B

$$P(A|B) = 0.35/0.50 = 0.70$$




Figura 4.1: Il condizionamento restringe lo spazio a B e rinormalizza le probabilità al suo interno.

La Figura 4.1 rappresenta il nuovo spazio probabilistico dopo il condizionamento su B.

4.2.3 Ogni probabilità dipende da uno sfondo informativo

Dal punto di vista bayesiano, ogni assegnazione di probabilità dipende da uno **sfondo informativo**, anche quando viene esplicitato.

Quando diciamo " $P(A) = 0.3$ ", in realtà intendiamo " $P(A | \mathcal{I}) = 0.3$ ", dove $\mathcal{I}$ rappresenta tutto ciò che sappiamo: dati precedenti, teoria, contesto e assunzioni. La notazione $P(A)$ è quindi un'abbreviazione comoda: il valore assegnato può cambiare quando cambiano i dati, le assunzioni o le informazioni di contesto.

4.3 Proprietà della probabilità condizionata

Un risultato importante è che le probabilità condizionate soddisfano tutti gli assiomi della probabilità. In altre parole, $P(\cdot | B)$ è essa stessa una funzione di probabilità legittima.

Teorema 4.1 (Proprietà della condizionata). *Fissato un evento B con $P(B) > 0$, la funzione $P(\cdot | B)$ soddisfa:*

1. **Non-negatività:** $P(A | B) \geq 0$ per ogni evento A.
2. **Normalizzazione:** $P(\Omega | B) = 1$; inoltre $P(B | B) = 1$.

3. **Additività:** se A_1 e A_2 sono disgiunti,

$$P(A_1 \cup A_2 | B) = P(A_1 | B) + P(A_2 | B).$$

4. **Complemento:** $P(A^c | B) = 1 - P(A | B)$.

5. **Regola della catena:** quando le probabilità condizionanti sono definite,

$$P(A \cap B | C) = P(A | B \cap C) \cdot P(B | C).$$

Interpretazione epistemica: una volta fissata l'informazione B , le credenze sugli eventi rimanenti devono continuare a rispettare gli assiomi della probabilità. Il condizionamento modifica lo spazio rilevante, non le regole di coerenza.

i Esempio clinico: test di screening per la depressione

Uno psicologo utilizza un test di screening per il disturbo depressivo maggiore in un contesto di comunità.

Informazioni disponibili:

- **prevalenza:** $P(D) = 0.08$;
- **sensibilità:** $P(T^+ | D) = 0.85$;
- **specificità:** $P(T^- | D^c) = 0.90$.

Costruzione della distribuzione congiunta

```
# Parametri epidemiologici
P_D <- 0.08
sens <- 0.85
spec <- 0.90

# Tassi di classificazione errata
fp_rate <- 1 - spec

# Probabilità congiunte
P_D_and_Tpos <- sens * P_D
P_D_and_Tneg <- (1 - sens) * P_D
P_Dc_and_Tpos <- fp_rate * (1 - P_D)
P_Dc_and_Tneg <- spec * (1 - P_D)

# Probabilità condizionate
P_Tpos <- P_D_and_Tpos + P_Dc_and_Tpos
P_Tneg <- P_D_and_Tneg + P_Dc_and_Tneg
P_D_given_Tpos <- P_D_and_Tpos / P_Tpos
P_D_given_Tneg <- P_D_and_Tneg / P_Tneg
```

Valore predittivo positivo (la domanda clinica cruciale):

$$P(D | T^+) = 0.43$$

Condizionatamente ai valori assunti, la probabilità di depressione dopo un risultato positivo è di circa il 43%, non dell'85%. La sensibilità è $P(T^+ | D)$, mentre la domanda clinica riguarda $P(D | T^+)$. La bassa prevalenza fa sì che

anche un tasso di falsi positivi del 10% produca un gran numero di risultati positivi tra le persone che non soffrono di depressione.

Valore predittivo negativo:

$$P(D^c | T^-) = 1 - P(D | T^-) = 0.986$$

Dopo un test negativo, la probabilità di depressione scende a circa l'1.4%, mentre la probabilità di non depressione è di circa il 98.6%.

Visualizzazione dell'aggiornamento




Figura 4.2: Probabilità di depressione prima del test e dopo un risultato positivo o negativo.

La Figura 4.2 mostra che lo stesso risultato può modificare la probabilità in direzioni e misure diverse. **La lezione epistemica** è che l'informazione fornita da un test dipende sia dalla sensibilità e dalla specificità, sia dalla prevalenza del disturbo nel contesto in cui il test viene applicato.

4.4 Indipendenza stocastica

Abbiamo visto che la probabilità condizionata descrive l'impatto dell'informazione su un evento sulle credenze riguardo a un altro evento. Ma cosa succede quando l'informazione *non modifica nulla*? Esiste cioè una situazione in cui apprendere che B si è verificato non modifica la nostra credenza in A ?

La risposta è sì e questo definisce il concetto di **indipendenza stocastica**.

Definizione 4.2 (Indipendenza (definizione epistemica)). Due eventi A e B sono detti **indipendenti** (notazione: $A \perp B$) se

$$P(A \cap B) = P(A)P(B).$$

Quando $P(A) > 0$ e $P(B) > 0$, questa condizione equivale a

$$P(A | B) = P(A) \quad \text{e} \quad P(B | A) = P(B).$$

In termini informativi, la conoscenza di uno dei due eventi non modifica la probabilità assegnata all'altro.

4.4.1 Indipendenza probabilistica e causalità

L'indipendenza probabilistica è una proprietà della distribuzione di probabilità che assumiamo per descrivere i dati; di per sé, però, non equivale né all'assenza né alla presenza di un rapporto causale. Due variabili possono risultare correlate perché una influenza l'altra, perché condividono una causa comune o a causa di distorsioni introdotte dal campionamento. Allo stesso modo, una relazione causale può esistere anche senza tradursi in un'associazione marginale immediatamente evidente.

Per chiarire questo punto, consideriamo due lanci della stessa moneta. Se la probabilità di ottenere "testa" è nota e fissa, i due lanci possono essere considerati indipendenti: il risultato del primo lancio non influisce sulla probabilità del secondo. Se invece tale probabilità è incerta, pur essendo comune a entrambi i lanci, l'esito del primo lancio fornisce informazioni sull'incertezza e può quindi modificare la previsione del secondo lancio. L'indipendenza, pertanto, non è una proprietà intrinseca degli eventi, ma dipende dalle variabili prese in considerazione e dalle informazioni incluse nel modello.

4.4.2 La fattorizzazione e la forma condizionata

Due eventi A e B sono indipendenti quando la probabilità che si verifichino entrambi è uguale al prodotto delle loro probabilità:

$$P(A \cap B) = P(A) \cdot P(B). \quad (4.2)$$

Questa definizione, detta **forma fattorizzata**, è la più generale, perché rimane valida anche quando uno dei due eventi ha probabilità nulla.

Se invece $P(A) > 0$ e $P(B) > 0$, dalla stessa uguaglianza si possono ricavare le forme condizionate:

$$P(A | B) = P(A), \quad P(B | A) = P(B).$$

Queste relazioni mostrano che la conoscenza del verificarsi di un evento non modifica la probabilità dell'altro.

La forma fattorizzata e la forma condizionata esprimono dunque la stessa idea: la distribuzione congiunta non evidenzia alcuna associazione tra A e B , perché l'informazione su uno dei due eventi non influisce sull'altro.

⚠ Un errore comune: confondere disgiunzione e indipendenza

4.4.3 Eventi disgiunti e indipendenza

Due eventi **disgiunti**, o **mutualmente esclusivi**, non possono verificarsi contemporaneamente. In simboli, $A \cap B = \emptyset$.

Se entrambi hanno una probabilità positiva, ovvero se $P(A) > 0$ e $P(B) > 0$, allora non possono essere indipendenti. Infatti, $P(A \cap B) = 0$, mentre $P(A) \cdot P(B) > 0$. Di conseguenza, la condizione di indipendenza $P(A \cap B) = P(A) \cdot P(B)$ non è soddisfatta.

L'unica eccezione si verifica quando almeno uno dei due eventi ha probabilità nulla. In questo caso, sia $P(A \cap B)$ sia $P(A) \cdot P(B)$ sono uguali a zero.

Dal punto di vista informativo, due eventi disgiunti con probabilità positiva sono fortemente dipendenti: sapere che si è verificato A permette di concludere con certezza che B non si è verificato. L'indipendenza richiederebbe invece che l'informazione sul verificarsi di un evento non influenzi la probabilità dell'altro.

Esempio. Consideriamo il risultato di un test diagnostico. Gli eventi "il test ha esito positivo" e "il test ha esito negativo" sono disgiunti, perché non possono verificarsi nello stesso momento. Sapere che il risultato è positivo implica che non è negativo. I due eventi sono quindi dipendenti.

4.4.4 Un esempio: il test diagnostico

Torniamo al test diagnostico per la depressione discusso nella sezione precedente. Il test e lo stato sono (fortunatamente!) dipendenti: un test che fosse indipendente dallo stato sarebbe clinicamente inutile.

Verifichiamolo numericamente:

```
# Parametri del modello diagnostico
P_D <- 0.08
sens <- 0.85
spec <- 0.90

P_Tpos <- sens * P_D + (1 - spec) * (1 - P_D)
P_D_and_Tpos <- sens * P_D

# Valore atteso sotto indipendenza
P_D_indep <- P_D * P_Tpos

cat("P(D) × P(T+) =", round(P_D_indep, 4), "\n")
#> P(D) × P(T+) = 0.0128
cat("P(D ∩ T+) nel modello =", round(P_D_and_Tpos, 4), "\n")
#> P(D ∩ T+) nel modello = 0.068
cat("Differenza:", round(P_D_and_Tpos - P_D_indep, 4), "\n")
#> Differenza: 0.0552
```

La differenza è sostanziale: $P(D \cap T^+) = 0.068$, mentre il prodotto delle marginali è $0.08 \times 0.16 = 0.0128$. Il test e la depressione sono quindi **dipendenti**, proprio come ci si aspetta da uno strumento diagnostico utile.

4.4.5 Il test di indipendenza nella pratica

Quando disponiamo di una distribuzione congiunta, possiamo verificare l'indipendenza confrontando $P(A \cap B)$ con $P(A)P(B)$. Per le probabilità teoriche l'uguaglianza deve essere esatta. Nei dati empirici, invece, le proporzioni campionarie differiscono quasi sempre a causa della variabilità casuale: per valutare se un modello di indipendenza è adeguato, è necessario tenere conto dell'incertezza di stima.

Nella pratica psicologica, tuttavia, è importante ricordare che l'indipendenza è spesso un'**assunzione**, non un dato di fatto. Quando costruiamo modelli statistici, possiamo assumere l'indipendenza tra le osservazioni o l'indipendenza condizionale tra gli item o gli errori, a seconda delle variabili incluse nel modello. Tali assunzioni devono essere giustificate dal punto di vista teorico e verificate dal punto di vista empirico, perché la loro violazione può portare a stime distorte e a conclusioni errate. L'indipendenza è uno strumento potente, ma va maneggiato con la consapevolezza che, nei fenomeni psicologici, la dipendenza è spesso la regola, non l'eccezione.

4.5 Teorema del prodotto e regola della catena

Il **teorema del prodotto** permette di esprimere la probabilità congiunta di due o più eventi mediante probabilità marginali e condizionate.

Teorema 4.2 (Teorema del prodotto). *Siano A e B due eventi. Se $P(B) > 0$, allora*

$$P(A \cap B) = P(A | B) P(B).$$

Analogamente, se $P(A) > 0$, si può scrivere

$$P(A \cap B) = P(B | A) P(A).$$

Le due espressioni descrivono la stessa probabilità congiunta, ma la scompongono in un ordine diverso.

4.5.1 Interpretazione sequenziale

La prima fattorizzazione può essere letta come una costruzione in due passaggi:

1. si considera la probabilità che si verifichi B , cioè $P(B)$;
2. una volta assunto che B si sia verificato, si considera la probabilità di A , cioè $P(A | B)$.

Il prodotto

$$P(A | B) P(B)$$

fornisce quindi la probabilità che A e B si verifichino entrambi.

Questa interpretazione è detta **sequenziale** perché scompone un evento congiunto in una successione di probabilità condizionate. L'ordine scelto, tuttavia, non deve necessariamente rappresentare una successione temporale o un rapporto causale.

4.5.2 La regola della catena

Il teorema del prodotto si estende a un numero arbitrario di eventi. Per $A_1, \dots, A_n$, purché tutte le probabilità condizionate coinvolte siano definite, vale

$$\begin{aligned} P(A_1 \cap A_2 \cap \dots \cap A_n) &= P(A_1) \\ &\quad \cdot P(A_2 | A_1) \\ &\quad \cdot P(A_3 | A_1 \cap A_2) \dots \\ &\quad \cdot P(A_n | A_1 \cap \dots \cap A_{n-1}). \end{aligned} \quad (4.3)$$

Ogni fattore esprime la probabilità di un evento condizionata al verificarsi di tutti gli eventi che lo precedono nella fattorizzazione.

La regola della catena non impone un ordine unico. La stessa probabilità congiunta può essere scomposta secondo qualunque ordine degli eventi, purché le corrispondenti probabilità condizionate siano definite.

4.6 Legge della probabilità totale

La **legge della probabilità totale** permette di calcolare la probabilità di un evento quando questo può verificarsi attraverso più scenari alternativi.

Teorema 4.3 (Legge della probabilità totale). *Sia $B_1, B_2, \dots, B_n$ una **partizione** dello spazio campionario Ω : gli eventi B_i sono mutuamente esclusivi e, nel loro insieme, coprono tutti i possibili esiti. Se $P(B_i) > 0$ per ogni i , allora*

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i).$$

4.6.1 Interpretazione

Poiché gli eventi $B_1, \dots, B_n$ rappresentano scenari alternativi ed esaustivi, l'evento A può essere scomposto nell'unione disgiunta

$$A = (A \cap B_1) \cup (A \cap B_2) \cup \dots \cup (A \cap B_n).$$

Di conseguenza,

$$P(A) = \sum_{i=1}^n P(A \cap B_i).$$

Applicando il teorema del prodotto a ciascun termine,

$$P(A \cap B_i) = P(A | B_i) P(B_i),$$

si ottiene la legge della probabilità totale.

Ogni termine della somma combina due elementi:

- $P(A | B_i)$: la probabilità di A nello scenario B_i ;

- $P(B_i)$: la probabilità che si presenti proprio quello scenario.

La probabilità complessiva di A è quindi una **media ponderata** delle probabilità condizionate $P(A | B_i)$, con pesi pari alle probabilità degli scenari.

4.6.2 Applicazione: popolazioni eterogenee

Nelle applicazioni reali, gli individui possono provenire da sottopopolazioni caratterizzate da rischi di base differenti. Consideriamo, per esempio, un test per la depressione somministrato a due gruppi:

Provenienza	Proporzione	Prevalenza della depressione
Clinica specialistica	30%	40%
Popolazione generale	70%	5%

Supponiamo che il test abbia:

$$\text{sensibilità} = 0.85, \quad \text{specificità} = 0.90.$$

La probabilità di un falso positivo è quindi

$$1 - \text{specificità} = 0.10.$$

Indichiamo con D l'evento "presenza di depressione" e con T^+ l'evento "test positivo".

4.6.2.1 Tasso di positività nella clinica specialistica

Nella clinica, un risultato positivo può derivare da due casi alternativi:

1. il paziente è depresso e il test è positivo;
2. il paziente non è depresso e il test produce un falso positivo.

Pertanto,

$$\begin{aligned} P(T^+ | \text{clinica}) &= P(T^+ | D) \cdot P(D | \text{clinica}) \\ &\quad + P(T^+ | D^c) \cdot P(D^c | \text{clinica}) \\ &= 0.85 \cdot 0.40 + 0.10 \cdot 0.60 \\ &= 0.40. \end{aligned}$$

4.6.2.2 Tasso di positività nella popolazione generale

Analogamente,

$$\begin{aligned} P(T^+ | \text{popolazione}) &= 0.85 \cdot 0.05 + 0.10 \cdot 0.95 \\ &= 0.1375. \end{aligned}$$

4.6.2.3 Tasso complessivo di positività

Applicando nuovamente la legge della probabilità totale ai due gruppi,

$$\begin{aligned} P(T^+) &= P(T^+ | \text{clinica}) P(\text{clinica}) \\ &\quad + P(T^+ | \text{popolazione}) P(\text{popolazione}) \\ &= 0.40 \cdot 0.30 + 0.1375 \cdot 0.70 \\ &= 0.21625 \approx 0.216. \end{aligned}$$

Il tasso complessivo di positività è quindi circa il (21.6%).

Questo valore è una **media ponderata** dei tassi di positività nei due gruppi. Non coincide con la loro media aritmetica, perché i gruppi rappresentano proporzioni diverse della popolazione complessiva.

4.6.3 Il significato di un risultato positivo

La probabilità di depressione dopo un risultato positivo dipende dalla prevalenza nel gruppo di provenienza.

Nella clinica specialistica,

$$\begin{aligned} P(D | T^+, \text{clinica}) &= \frac{P(T^+ | D, \text{clinica}) P(D | \text{clinica})}{P(T^+ | \text{clinica})} \\ &= \frac{0.85 \cdot 0.40}{0.40} \\ &= 0.85. \end{aligned}$$

Nella popolazione generale,

$$\begin{aligned} P(D | T^+, \text{popolazione}) &= \frac{0.85 \cdot 0.05}{0.1375} \\ &\approx 0.31. \end{aligned}$$

La sensibilità e la specificità del test sono identiche nei due gruppi, ma il significato diagnostico di un risultato positivo cambia notevolmente: nella clinica la probabilità di depressione dopo un test positivo è dell'85%, mentre nella popolazione generale è circa del 31%.

Implicazione clinica. L'interpretazione di un risultato diagnostico non dipende soltanto dalle caratteristiche del test, ma anche dalla prevalenza della condizione nella popolazione esaminata.

4.7 Paradosso di Simpson

Il **paradosso di Simpson** mostra come l'aggregazione dei dati possa nascondere, attenuare o persino invertire una relazione osservata all'interno di sottogruppi rilevanti.

4.7.1 Il fenomeno

Il paradosso si verifica quando l'associazione tra due variabili cambia direzione passando dall'analisi aggregata all'analisi condizionata per una terza variabile. In altre parole, una relazione che sembra presente nei dati complessivi può scomparire o assumere il segno opposto quando i dati vengono esaminati separatamente in gruppi più omogenei.

i Esempio: efficacia di un trattamento per la depressione

Due cliniche valutano l'efficacia di un trattamento per la depressione. La clinica A accoglie prevalentemente casi lievi, mentre la clinica B tratta soprattutto casi gravi.

```
# Clinica A: casi lievi
n_A_trattati <- 90
n_A_guariti_trattati <- 81
n_A_controllo <- 10
n_A_guariti_controllo <- 9

# Clinica B: casi gravi
n_B_trattati <- 10
n_B_guariti_trattati <- 2
n_B_controllo <- 90
n_B_guariti_controllo <- 27

# Proporzioni di guarigione per clinica
prop_A_trattati <- n_A_guariti_trattati / n_A_trattati
prop_A_controllo <- n_A_guariti_controllo / n_A_controllo
prop_B_trattati <- n_B_guariti_trattati / n_B_trattati
prop_B_controllo <- n_B_guariti_controllo / n_B_controllo

# Proporzioni aggregate
n_tot_trattati <- n_A_trattati + n_B_trattati
n_tot_guariti_trattati <-
  n_A_guariti_trattati + n_B_guariti_trattati

n_tot_controllo <- n_A_controllo + n_B_controllo
n_tot_guariti_controllo <-
  n_A_guariti_controllo + n_B_guariti_controllo

prop_tot_trattati <-
  n_tot_guariti_trattati / n_tot_trattati

prop_tot_controllo <-
  n_tot_guariti_controllo / n_tot_controllo
```

Risultati nei singoli sottogruppi

Nella clinica A:

$$P(\text{Guarigione} \mid \text{Trattamento}, \text{Clinica A}) = \frac{81}{90} = 0.90,$$

$$P(\text{Guarigione} \mid \text{Controllo}, \text{Clinica A}) = \frac{9}{10} = 0.90.$$

Il trattamento non produce alcun miglioramento rispetto al controllo.
Nella clinica B:

$$P(\text{Guarigione} \mid \text{Trattamento}, \text{Clinica B}) = \frac{2}{10} = 0.20,$$

$$P(\text{Guarigione} \mid \text{Controllo}, \text{Clinica B}) = \frac{27}{90} = 0.30.$$

In questo caso, il gruppo trattato presenta una proporzione di guarigioni inferiore a quella del gruppo di controllo.

In sintesi:

- Clinica A: trattati 90%, controllo 90%;
- Clinica B: trattati 20%, controllo 30%.

In nessuna delle due cliniche il trattamento risulta superiore.

Risultato aggregato

Se si ignorano le differenze tra le cliniche e si combinano tutti i dati, si ottiene:

$$P(\text{Guarigione} \mid \text{Trattamento}) = \frac{81 + 2}{90 + 10} = \frac{83}{100} = 0.83,$$

mentre

$$P(\text{Guarigione} \mid \text{Controllo}) = \frac{9 + 27}{10 + 90} = \frac{36}{100} = 0.36.$$

Pertanto:

- Trattati: 83%;
- Controllo: 36%.

Nell'analisi aggregata, il trattamento sembra dunque nettamente più efficace, nonostante non risulti migliore in nessuna delle due cliniche.




Figura 4.3: Il confronto aggregato può avere una direzione diversa dai confronti effettuati all'interno di ciascuna clinica.

Perché si verifica l'inversione?

La spiegazione risiede nella diversa composizione dei gruppi.

La clinica A presenta una probabilità di guarigione elevata, perché tratta soprattutto casi lievi. Inoltre, contribuisce quasi interamente al gruppo trattato:

$$P(\text{Clinica A} \mid \text{Trattamento}) = \frac{90}{100} = 0.90.$$

La clinica B presenta invece una probabilità di guarigione più bassa, perché tratta prevalentemente casi gravi. Essa contribuisce quasi interamente al gruppo di controllo:

$$P(\text{Clinica B} \mid \text{Controllo}) = \frac{90}{100} = 0.90.$$

Di conseguenza, il confronto aggregato mette a confronto due gruppi con composizioni molto diverse:

- il gruppo trattato è formato soprattutto da casi lievi;
- il gruppo di controllo è formato soprattutto da casi gravi.

La maggiore proporzione di guarigioni nel gruppo trattato dipende quindi dalla diversa gravità iniziale dei pazienti, non necessariamente dall'efficacia del trattamento.

La variabile **clinica**, che in questo esempio rappresenta anche la gravità dei casi, è associata sia all'assegnazione del trattamento sia alla probabilità di guarigione. Ignorandola, l'analisi aggregata confonde l'effetto del trattamento con le differenze tra le popolazioni esaminate.

Confronti marginali e condizionati

La Figura 4.3 mette in evidenza la distinzione tra due tipi di confronto.

La probabilità marginale

$$P(\text{Guarigione} \mid \text{Trattamento})$$

descrive il tasso di guarigione nel gruppo trattato così come questo è effettivamente composto.

La probabilità condizionata

$$P(\text{Guarigione} \mid \text{Trattamento}, \text{Clinica})$$

confronta invece trattamento e controllo separatamente all'interno di ciascuna clinica, e quindi tra pazienti appartenenti a contesti più omogenei.

Le due analisi non sono matematicamente contraddittorie: rispondono a domande differenti e utilizzano pesi diversi nella combinazione dei sottogruppi.

La lezione metodologica

Il paradosso di Simpson non implica che l'analisi condizionata sia sempre preferibile a quella aggregata. La scelta dipende dalla domanda scientifica e dal ruolo svolto dalla variabile di stratificazione.

In particolare, prima di controllare per una variabile è necessario stabilire se essa rappresenti:

- un fattore confondente;
- un meccanismo intermedio;
- una conseguenza dell'esposizione;
- oppure una semplice caratteristica descrittiva dei gruppi.

La lezione fondamentale è che una relazione aggregata non dovrebbe essere interpretata senza esaminare come sono composti i gruppi e senza considerare le variabili che influenzano sia l'esposizione sia l'esito.

Riflessioni conclusive

La probabilità condizionata formalizza un'idea fondamentale: una valutazione probabilistica dipende dalle informazioni prese in considerazione. Condizionare su B significa restringere l'attenzione alle situazioni compatibili con B e rinormalizzare le probabilità al loro interno.

L'indipendenza descrive il caso in cui questa restrizione non modifica la probabilità di un altro evento. Si tratta di un'ipotesi forte che dipende dal modello informativo adottato e che non coincide con la disgiunzione; inoltre, non determina da sola l'esistenza o l'assenza di relazioni causali.

Il teorema del prodotto permette di scomporre una probabilità congiunta in una

sequenza di probabilità condizionate. La legge della probabilità totale compie il passaggio complementare: combina scenari alternativi per ottenere una probabilità marginale. Il paradosso di Simpson mostra infine che le probabilità marginali e quelle condizionate possono raccontare storie diverse quando i gruppi hanno composizioni diverse.

Nel Capitolo 5 useremo questi strumenti per collegare $P(\text{Dati} \mid \text{Ipotesi})$ a $P(\text{Ipotesi} \mid \text{Dati})$.

Esercizi

1. In una tabella congiunta, $P(A \cap B) = 0.20$ e $P(B) = 0.50$. Calcola $P(A \mid B)$ e spiega con parole tue che cosa rappresenta il risultato.
2. Un test ha sensibilità 0.85. Uno studente afferma: «Se il test è positivo, la probabilità che la persona abbia il disturbo è 0.85». Spiega perché l'affermazione non è giustificata dalle sole informazioni disponibili.
3. Due eventi soddisfano $P(A) = 0.40$, $P(B) = 0.50$ e $P(A \cap B) = 0.20$. Sono indipendenti? Qual è il significato informativo della risposta?
4. Perché due eventi disgiunti con probabilità positiva non possono essere indipendenti? Rispondi senza limitarti a citare la formula.
5. La formula $P(A \cap B) = P(A \mid B)P(B)$ contiene una probabilità condizionata e una probabilità marginale. Descrivi il significato dei due fattori in un processo sequenziale.
6. Una popolazione è composta per il 30% da un gruppo in cui $P(A) = 0.40$ e per il 70% da un gruppo in cui $P(A) = 0.10$. Calcola la probabilità complessiva di A e spiega perché si tratta di una media ponderata.
7. In ciascuna di due cliniche un trattamento non è migliore del controllo, ma nei dati aggregati sembra molto più efficace. Quale informazione controlleresti prima di concludere che il trattamento funziona?
8. Spiega la differenza tra le domande $P(\text{test positivo} \mid \text{disturbo})$ e $P(\text{disturbo} \mid \text{test positivo})$. Quale delle due corrisponde alla sensibilità e quale interessa maggiormente dopo aver osservato un risultato positivo?

Soluzioni

1. $P(A \mid B) = 0.20/0.50 = 0.40$. Tra tutta la probabilità assegnata alle situazioni in cui B è vero, il 40% appartiene anche ad A .
2. La sensibilità è $P(T^+ \mid D)$, non $P(D \mid T^+)$. Per calcolare la seconda probabilità servono anche la prevalenza del disturbo e il tasso di falsi positivi, o informazioni equivalenti.
3. Sì, perché $P(A)P(B) = 0.40 \times 0.50 = 0.20 = P(A \cap B)$. Nel modello adottato, conoscere il verificarsi di uno dei due eventi non modifica la probabilità dell'altro.
4. Se sappiamo che si è verificato A , la disgiunzione implica che B non può essersi verificato. L'informazione su A modifica quindi completamente la

probabilità di B , che diventa zero.

5. $P(B)$ rappresenta la probabilità di raggiungere lo scenario B ; $P(A | B)$ rappresenta la probabilità che si verifichi anche A una volta che ci troviamo in quello scenario. Il prodotto fornisce la probabilità che entrambi si verifichino.
6. $P(A) = 0.40 \times 0.30 + 0.10 \times 0.70 = 0.19$. I due valori vengono pesati in base alla proporzione dei gruppi; il gruppo più numeroso contribuisce maggiormente al risultato complessivo.
7. Controllerei come sono distribuiti trattamento e controllo tra le cliniche e se le cliniche differiscono per gravità, prognosi o altre caratteristiche legate all'esito. Una composizione diseguale può produrre un confronto aggregato fuorviante.
8. $P(T^+ | D)$ è la probabilità di un test positivo tra le persone con il disturbo ed è la sensibilità. $P(D | T^+)$ è la probabilità del disturbo dopo un risultato positivo ed è la quantità più direttamente rilevante per interpretare quel risultato.

i Punti chiave

- Per $P(B) > 0$, $P(A | B) = P(A \cap B) / P(B)$.
- Condizionare significa restringere l'attenzione alle situazioni compatibili con B e rinormalizzare.
- $P(A | B)$ e $P(B | A)$ rispondono a domande diverse e in generale non coincidono.
- Due eventi sono indipendenti quando $P(A \cap B) = P(A)P(B)$.
- Eventi disgiunti con probabilità positiva sono dipendenti, perché il verificarsi dell'uno esclude l'altro.
- Il teorema del prodotto costruisce probabilità congiunte mediante probabilità condizionate.
- La legge della probabilità totale combina scenari alternativi attraverso una media ponderata.
- Un confronto aggregato può differire dai confronti entro i sottogruppi; la scelta tra quantità marginali e condizionate dipende dalla domanda scientifica.

Il teorema di Bayes

i In sintesi

Da sapere Il teorema di Bayes collega la probabilità dei dati sotto un'ipotesi alla probabilità dell'ipotesi dopo aver osservato i dati. L'aggiornamento combina ciò che era plausibile prima dell'osservazione con la forza dell'evidenza e produce una probabilità, o una distribuzione, a posteriori. Gli esempi diagnostici mostrano perché il tasso base non può essere ignorato.

Da saper fare Distinguere $P(E \mid H)$ da $P(H \mid E)$; interpretare prior, verosimiglianza, evidenza e posterior; comprendere come la prevalenza influenzi il valore predittivo di un test; leggere un aggiornamento sequenziale e, a un primo livello, un aggiornamento Beta-Binomiale.

Introduzione

Il **teorema di Bayes** formalizza un'operazione che compiamo continuamente: modificare ciò che riteniamo plausibile quando riceviamo nuove informazioni. Nei capitoli precedenti abbiamo introdotto la probabilità condizionata come strumento per rappresentare questo cambiamento. Ora possiamo affrontare il problema inverso: partire da un dato osservato e valutare quali ipotesi lo spiegano meglio.

In psicologia, questo passaggio è particolarmente importante perché osserviamo quasi sempre indicatori indiretti — risposte a item, punteggi, tempi di reazione, sintomi, comportamenti — mentre ci interessano costrutti o stati non direttamente osservabili, come un tratto, un processo cognitivo, una condizione clinica o un effetto sperimentale. Il teorema di Bayes offre un linguaggio coerente per collegare questi due livelli senza confondere la probabilità dei dati con la probabilità delle ipotesi.

Il filo conduttore del capitolo sarà quindi semplice: **che cosa credevamo prima, che cosa ci dicono i dati e che cosa diventa plausibile dopo averli osservati?**

💡 Prerequisiti

Per seguire questo capitolo è necessario aver letto Capitolo 1, Capitolo 2, Capitolo 3 e, soprattutto, Capitolo 4.

Per la notazione matematica può essere utile consultare Appendice A. Per un richiamo alle operazioni tra insiemi ed eventi e alla notazione delle sommatorie, consulta le appendici dedicate fornite nel Companion.

Gli esempi in R servono a visualizzare i concetti e non richiedono competenze di programmazione avanzate.

Lettura complementare consigliata: Chivers, T. (2024), *Everything is Predictable: How Bayesian Statistics Explain Our World* (Chivers, 2024).

Panoramica del capitolo

Il percorso seguirà la logica dell'aggiornamento:

1. partiremo dalla differenza tra predizione e inferenza;
2. deriveremo il teorema di Bayes dalla probabilità congiunta;
3. applicheremo la formula a un problema diagnostico;
4. vedremo perché la prevalenza modifica il significato di un risultato;
5. tradurremo questi principi nel ragionamento clinico e nell'aggiornamento sequenziale;
6. anticiperemo infine il caso in cui l'incertezza riguarda un parametro continuo.

Gli aspetti più tecnici relativi a *odds* e rapporti di verosimiglianza sono raccolti in box a scomparsa: sono utili per il calcolo e per le applicazioni, ma non interrompono il filo concettuale principale.

i Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()

library(dplyr)
library(ggplot2)

apply_visual_theme()
```

5.1 Il problema fondamentale della conoscenza

Immaginiamo che uno psicologo clinico valuti un paziente con sintomi compatibili con la depressione. Per approfondire la valutazione, somministra un test di screening, che restituisce un risultato positivo.

Che cosa sappiamo ora che non sapevamo prima?

La risposta intuitiva potrebbe essere: «Il paziente è probabilmente depresso». Ma

il risultato non autorizza ancora questa conclusione. Le caratteristiche del test ci dicono anzitutto quanto sia probabile osservare un esito positivo **se il paziente fosse depresso**:

$$P(T^+ | D).$$

La domanda clinica procede invece nella direzione opposta:

$$P(D | T^+),$$

cioè: quanto è plausibile che il paziente sia depresso **dopo** aver osservato il risultato positivo?

Le due probabilità non coincidono. La prima descrive il comportamento del test quando la condizione è presente; la seconda riguarda ciò che possiamo inferire sul paziente alla luce dell'esito osservato. Il problema che Bayes risolve è proprio questa **inversione del condizionamento**.

5.1.1 Predire i dati, inferire le ipotesi

La distinzione riflette un'asimmetria fondamentale del ragionamento scientifico.

Tipo di ragionamento	Domanda	Formula	Direzione
Predizione	«Se il paziente è depresso, quanto è probabile un test positivo?»	$P(T^+ D)$	Dall'ipotesi ai dati
Inferenza	«Dato un test positivo, quanto è probabile la depressione?»	$P(D T^+)$	Dai dati all'ipotesi

I modelli scientifici sono spesso costruiti nella prima direzione: stabiliscono quali osservazioni ci aspetteremmo se una certa ipotesi fosse vera. Il mondo, però, ci presenta i dati e lascia nascosti gli stati che li hanno prodotti. Osserviamo un punteggio, una risposta o una differenza tra gruppi; vogliamo risalire al tratto, alla condizione o all'effetto sottostante.

Questo problema ricorre in tutta la psicologia:

- un questionario produce un punteggio: che cosa suggerisce sul tratto latente?
- un esperimento mostra una differenza: quanto sostiene l'esistenza di un effetto?
- un paziente migliora: quanto è plausibile che il cambiamento dipenda dal trattamento?

I dati non dichiarano direttamente quale spiegazione sia vera. Ci dicono quanto sarebbero attesi sotto spiegazioni diverse. Il teorema di Bayes formalizza il passaggio dai dati osservati alle ipotesi che possono averli generati.

5.2 Dalla probabilità congiunta al teorema di Bayes

Il teorema di Bayes non introduce un nuovo principio probabilistico. Deriva dal fatto che la stessa probabilità congiunta può essere scomposta in due modi:

$$P(A \cap B) = P(A | B) P(B) = P(B | A) P(A). \quad (5.1)$$

L'intersezione è simmetrica, perché $A \cap B = B \cap A$. Le due fattorizzazioni devono quindi descrivere la stessa quantità. Uguagliandole,

$$P(A | B) P(B) = P(B | A) P(A),$$

e dividendo per $P(B)$, purché $P(B) > 0$, otteniamo

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}.$$

Teorema 5.1 (Teorema di Bayes — forma fondamentale). *Per due eventi A e B , con $P(B) > 0$, vale*

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}. \quad (5.2)$$

La formula consente di passare da $P(B | A)$ a $P(A | B)$, ma non attraverso una semplice inversione: servono anche la probabilità iniziale di A e la probabilità complessiva dell'evidenza B .

5.2.1 I quattro elementi dell'aggiornamento

Nel linguaggio bayesiano, A rappresenta di solito un'ipotesi e B l'evidenza osservata. La formula può essere letta così:

$$\text{posterior} = \frac{\text{verosimiglianza} \times \text{prior}}{\text{evidenza}}.$$

! Prior, verosimiglianza, evidenza e posterior

Prior: $P(A)$ Esprime quanto l'ipotesi fosse plausibile prima di osservare B . Può derivare da studi precedenti, prevalenze, conoscenze teoriche o informazioni sul caso. La scelta deve essere motivata e, quando è influente, valutata con analisi di sensibilità.

Verosimiglianza: $P(B | A)$ Indica quanto il dato osservato sia compatibile con l'ipotesi. Risponde alla domanda: «Se A fosse vera, quanto sarebbe probabile osservare B ?»

Evidenza marginale: $P(B)$ È la probabilità complessiva del dato, considerando i diversi modi in cui potrebbe essere prodotto. Normalizza il risultato.

Posterior: $P(A | B)$ Esprime quanto l'ipotesi sia plausibile dopo aver osservato il dato. È la sintesi tra informazione precedente ed evidenza nuova.

Quando si confrontano valori alternativi della stessa ipotesi o dello stesso parametro, è spesso sufficiente mettere in evidenza il nucleo dell'aggiornamento:

$$P(A | B) \propto P(B | A) P(A).$$

Il simbolo $\propto$ ricorda che il posterior è determinato dal prodotto tra verosimiglianza e prior, mentre $P(B)$ svolge il ruolo di costante di normalizzazione.

5.3 La forma estesa e il primo aggiornamento diagnostico

Nelle applicazioni, $P(B)$ non è sempre disponibile direttamente. Se A e A^c rappresentano le due possibilità rilevanti, la legge della probabilità totale permette di scrivere

$$P(B) = P(B | A) P(A) + P(B | A^c) P(A^c).$$

Sostituendo questa espressione nella formula di Bayes otteniamo la **forma estesa**:

$$P(A | B) = \frac{P(B | A) P(A)}{P(B | A) P(A) + P(B | A^c) P(A^c)}. \quad (5.3)$$

Il denominatore raccoglie tutti i modi in cui l'evidenza può presentarsi: B può verificarsi quando A è vero, ma anche quando A è falso. In diagnostica, questo significa che un test positivo può essere un vero positivo oppure un falso positivo.

Consideriamo un test per la depressione. Indichiamo con D la presenza della condizione e con T^+ un risultato positivo. Supponiamo che

$$P(D) = 0.15, \quad P(T^+ | D) = 0.85, \quad P(T^+ | D^c) = 0.10.$$

La probabilità complessiva di un risultato positivo è

$$\begin{aligned} P(T^+) &= P(T^+ | D) P(D) + P(T^+ | D^c) P(D^c) \\ &= 0.85 \cdot 0.15 + 0.10 \cdot 0.85 \\ &= 0.2125. \end{aligned}$$

Di conseguenza,

$$\begin{aligned} P(D | T^+) &= \frac{0.85 \cdot 0.15}{0.85 \cdot 0.15 + 0.10 \cdot 0.85} \\ &= 0.60. \end{aligned}$$

Il risultato positivo porta dunque la probabilità di depressione dal 15% al 60%. È un aggiornamento importante, ma non una certezza diagnostica: tra le persone con esito positivo, il 40% non presenta la condizione.

i Approfondimento: costruire la tabella diagnostica

Le quattro combinazioni tra stato clinico ed esito del test sono

$$P(D \cap T^+) = 0.85 \cdot 0.15 = 0.1275,$$

$$P(D \cap T^-) = 0.15 \cdot 0.15 = 0.0225,$$

$$P(D^c \cap T^+) = 0.10 \cdot 0.85 = 0.085,$$

$$P(D^c \cap T^-) = 0.90 \cdot 0.85 = 0.765.$$

```
P_D <- 0.15
sens <- 0.85
fp_rate <- 0.10

P_D_and_Tpos <- sens * P_D
P_D_and_Tneg <- (1 - sens) * P_D
P_Dc_and_Tpos <- fp_rate * (1 - P_D)
P_Dc_and_Tneg <- (1 - fp_rate) * (1 - P_D)

tab <- matrix(
  c(
    P_D_and_Tpos,
    P_D_and_Tneg,
    P_Dc_and_Tpos,
    P_Dc_and_Tneg
  ),
  nrow = 2,
  byrow = TRUE,
  dimnames = list(
    Stato = c("Depresso", "Non depresso"),
    Test = c("T+", "T-")
  )
)

print(round(tab, 4))
#>      Test
#> Stato      T+      T-
#> Depresso   0.128 0.0225
#> Non depresso 0.085 0.7650

P_Tpos <- sum(tab[, "T+"])
P_D_given_Tpos <- tab["Depresso", "T+"] / P_Tpos

cat("P(D | T+) =", round(P_D_given_Tpos, 4), "\n")
#> P(D | T+) = 0.6
```

La tabella e la formula estesa conducono allo stesso risultato, perché sono due rappresentazioni dello stesso calcolo.

5.4 La fallacia del tasso base

L'esempio precedente mostra che il significato di un risultato dipende anche da ciò che era plausibile prima del test. Ignorare questa informazione conduce alla **fallacia del tasso base**: la tendenza a concentrarsi sulle prestazioni dello strumento trascurando la frequenza iniziale della condizione.

Supponiamo che un test per una malattia rara abbia sensibilità e specificità del 99%. Una persona risulta positiva. È naturale pensare che abbia circa il 99% di probabilità di essere malata, ma questa risposta confonde

$$P(T^+ | M)$$

con

$$P(M | T^+).$$

Assumiamo una prevalenza dello 0.1%, cioè una persona malata ogni 1 000. Per rendere visibile il meccanismo, immaginiamo di applicare il test a 100 000 persone:

- 100 sono malate; con una sensibilità del 99%, otteniamo 99 veri positivi;
- 99 900 sono sane; con un tasso di falsi positivi dell'1%, otteniamo 999 falsi positivi.

I risultati positivi sono quindi

$$99 + 999 = 1\,098,$$

e soltanto 99 di essi corrispondono a persone realmente malate:

$$P(M | T^+) = \frac{99}{1\,098} \approx 0.09.$$

Il valore predittivo positivo è circa il 9%, non il 99%. Il problema non è che il test sia poco accurato: l'1% di falsi positivi viene applicato a un gruppo di persone sane enormemente più grande del gruppo delle persone malate.

i Il calcolo con la formula di Bayes

Con

$$P(M) = 0.001, \quad P(T^+ | M) = 0.99, \quad P(T^+ | M^c) = 0.01,$$

si ottiene

$$\begin{aligned} P(M | T^+) &= \frac{0.99 \cdot 0.001}{0.99 \cdot 0.001 + 0.01 \cdot 0.999} \\ &= \frac{0.00099}{0.01098} \\ &\approx 0.090. \end{aligned}$$

prevalenza <- 0.001

```

sens <- 0.99
spec <- 0.99

P_Tpos <-
  sens * prevalenza +
  (1 - spec) * (1 - prevalenza)

VPP <- (sens * prevalenza) / P_Tpos

cat("Prevalenza:", prevalenza * 100, "%\n")
#> Prevalenza: 0.1 %
cat("Valore predittivo positivo:", round(VPP * 100, 1), "%\n")
#> Valore predittivo positivo: 9 %

```

5.4.1 Lo stesso test, significati diversi

Il valore predittivo positivo dipende sia dalle caratteristiche del test sia dalla prevalenza:

$$P(M | T^+) = \frac{\text{sensibilità} \cdot \text{prevalenza}}{\text{sensibilità} \cdot \text{prevalenza} + (1 - \text{specificità}) \cdot (1 - \text{prevalenza})}.$$

Se sensibilità e specificità restano costanti, il valore predittivo positivo cresce con la prevalenza.




Figura 5.1: Effetto della prevalenza sul valore predittivo positivo. Le caratteristiche del test rimangono costanti, ma il significato di un risultato positivo cambia con il contesto.

La Figura 5.1 mostra che lo stesso test può avere significati molto diversi in popolazioni differenti. Con sensibilità dell'85% e specificità del 90%, per esempio, il

valore predittivo positivo è circa il 43% quando la prevalenza è dell'8%, ma sale a circa il 78% quando la prevalenza è del 30%.

La lezione è generale: un risultato non può essere interpretato fuori dal contesto in cui è stato osservato.

5.5 Dal risultato del test al ragionamento clinico

Il teorema di Bayes non è soltanto una formula: descrive la struttura di una valutazione clinica ben condotta. Prima di un test esiste già una **probabilità pre-test**, fondata sul motivo dell'invio, sui sintomi, sulla storia clinica e sulla frequenza della condizione in casi comparabili. Il risultato aggiunge evidenza. Dalla loro combinazione emerge la **probabilità post-test**.

5.5.1 Come interpretare il risultato di un test psicologico

Supponiamo che un test di screening per la depressione produca un punteggio superiore alla soglia. Non possiamo concludere automaticamente che il paziente sia depresso, né attribuire alla diagnosi una probabilità pari alla sensibilità del test.

La sensibilità descrive

$$P(T^+ | D),$$

mentre la domanda clinica riguarda

$$P(D | T^+).$$

Per interpretare l'esito servono quindi tre elementi:

1. **il punto di partenza**, cioè la probabilità pre-test;
2. **la forza dell'evidenza**, cioè quanto il risultato sia più compatibile con la condizione che con la sua assenza;
3. **il punto di arrivo**, cioè la probabilità post-test.

Consideriamo un test ipotetico con sensibilità 0.85 e specificità 0.80. Lo stesso risultato positivo viene osservato in due contesti. Nel primo, il paziente presenta sintomi persistenti e una probabilità pre-test del 65%; nel secondo, il test è usato in uno screening non selettivo con probabilità pre-test dell'8%.

Con le stesse caratteristiche del test, la probabilità post-test è circa l'88% nel primo scenario e circa il 27% nel secondo. Il dato osservato è identico, ma il suo significato cambia perché cambia il contesto da cui parte l'aggiornamento.

```
sens <- 0.85
spec <- 0.80
LR_pos <- sens / (1 - spec)

calcola_posterior <- function(prior, LR) {
  odds_prior <- prior / (1 - prior)
  odds_post <- odds_prior * LR
}
```

```

odds_post / (1 + odds_post)
}

prior_sintomatico <- 0.65
prior_screening <- 0.08

post_sintomatico <-
  calcola_posterior(prior_sintomatico, LR_pos)

post_screening <-
  calcola_posterior(prior_screening, LR_pos)

cat(
  "Paziente sintomatico:",
  round(post_sintomatico * 100, 1),
  "%\n"
)
#> Paziente sintomatico: 88.8 %

cat(
  "Screening non selettivo:",
  round(post_screening * 100, 1),
  "%\n"
)
#> Screening non selettivo: 27 %

```

Un test psicologico non produce dunque una diagnosi automatica. Fornisce evidenza che deve essere integrata con il quadro clinico, la qualità dello strumento, le ipotesi alternative e le conseguenze delle decisioni.

5.5.2 Una forma operativa: odds e rapporti di verosimiglianza

Nelle applicazioni diagnostiche, l'aggiornamento può essere espresso in una forma particolarmente compatta:

$$\text{Odds}(H | E) = \text{Odds}(H) \times \text{LR}.$$

In parole: gli *odds* posteriori si ottengono moltiplicando gli *odds* iniziali per la forza dell'evidenza. Questa forma è utile soprattutto quando si combinano più risultati in sequenza. I dettagli di definizione e calcolo sono raccolti nel box seguente.

i Approfondimento tecnico: odds e likelihood ratio

Gli *odds* di un'ipotesi H confrontano la probabilità che sia vera con la probabilità che sia falsa:

$$\text{Odds}(H) = \frac{P(H)}{1 - P(H)} = \frac{P(H)}{P(H^c)}.$$

Se $P(H) = 0.20$, allora

$$\text{Odds}(H) = \frac{0.20}{0.80} = 0.25,$$

cioè odds 1 : 4. Per tornare alla probabilità si usa

$$P(H) = \frac{\text{Odds}(H)}{1 + \text{Odds}(H)}.$$

Il **rapporto di verosimiglianza** è

$$\text{LR} = \frac{P(E | H)}{P(E | H^c)}.$$

Misura quanto l'evidenza osservata sia più compatibile con H che con H^c :

- se $\text{LR} > 1$, l'evidenza favorisce H ;
- se $\text{LR} < 1$, l'evidenza favorisce H^c ;
- se $\text{LR} = 1$, l'evidenza non modifica gli odds.

In diagnostica:

$$\text{LR}^+ = \frac{P(T^+ | M)}{P(T^+ | M^c)} = \frac{\text{sensibilità}}{1 - \text{specificità}},$$

$$\text{LR}^- = \frac{P(T^- | M)}{P(T^- | M^c)} = \frac{1 - \text{sensibilità}}{\text{specificità}}.$$

Un test informativo tende ad avere $\text{LR}^+ > 1$ e $\text{LR}^- < 1$. Quanto più i valori si allontanano da 1, tanto maggiore è l'aggiornamento, ma l'effetto pratico dipende sempre dagli odds iniziali.

LR^+	LR^-	Modifica indicativa degli odds
> 10	< 0.1	Generalmente ampia
5–10	0.1–0.2	Moderata o ampia
2–5	0.2–0.5	Limitata o moderata
1–2	0.5–1	Piccola

Le soglie sono orientative, non universali. Inoltre, gli *odds* non vanno confusi con l'**odds ratio**, che confronta gli odds tra due gruppi o condizioni.

i Esempio tecnico: aggiornamento dopo un test positivo o negativo

Consideriamo un test con sensibilità 0.85, specificità 0.90 e probabilità pre-test del 10%.

Gli odds iniziali sono

$$\text{Odds}(M) = \frac{0.10}{0.90} \approx 0.111.$$

I rapporti di verosimiglianza sono

$$LR^+ = \frac{0.85}{0.10} = 8.5,$$

$$LR^- = \frac{0.15}{0.90} \approx 0.167.$$

Dopo un risultato positivo:

$$\text{Odds}(M | T^+) = 0.111 \cdot 8.5 \approx 0.944,$$

$$P(M | T^+) = \frac{0.944}{1 + 0.944} \approx 0.486.$$

Dopo un risultato negativo:

$$\text{Odds}(M | T^-) = 0.111 \cdot 0.167 \approx 0.0185,$$

$$P(M | T^-) = \frac{0.0185}{1 + 0.0185} \approx 0.018.$$

```
prior_prob <- 0.10
sens <- 0.85
spec <- 0.90

LR_pos <- sens / (1 - spec)
LR_neg <- (1 - sens) / spec

prior_odds <- prior_prob / (1 - prior_prob)

post_odds_pos <- prior_odds * LR_pos
post_prob_pos <- post_odds_pos / (1 + post_odds_pos)

post_odds_neg <- prior_odds * LR_neg
post_prob_neg <- post_odds_neg / (1 + post_odds_neg)

data.frame(
  Scenario = c(
    "Prima del test",
    "Dopo test positivo",
    "Dopo test negativo"
  ),
  Probabilita = paste0(
    round(
      c(prior_prob, post_prob_pos, post_prob_neg) * 100,
      1
    ),
    "%"
  ),
  Odds = round(
    c(prior_odds, post_odds_pos, post_odds_neg),
    3
  )
)
```

```

)
)
#>           Scenario Probabilita Odds
#> 1      Prima del test          10% 0.111
#> 2 Dopo test positivo        48.6% 0.944
#> 3 Dopo test negativo         1.8% 0.019

```

5.5.3 L'evidenza si accumula nel tempo

Il ragionamento clinico è spesso sequenziale: un colloquio modifica la valutazione iniziale, un questionario aggiunge informazione, un'osservazione successiva aggiorna ancora il quadro. In termini bayesiani, il posterior di un passaggio diventa il prior del passaggio seguente.

i Esempio: aggiornamento sequenziale nella valutazione dell'ADHD

Consideriamo un esempio puramente illustrativo relativo alla valutazione di un bambino per una possibile diagnosi di ADHD. Usiamo due strumenti:

- T_1 : un questionario di screening;
- T_2 : un'osservazione strutturata.

I valori non descrivono strumenti reali. Supponiamo

$$P(\text{ADHD}) = 0.05,$$

$$\text{sensibilità di } T_1 = 0.80, \quad \text{specificità di } T_1 = 0.85,$$

$$\text{sensibilità di } T_2 = 0.75, \quad \text{specificità di } T_2 = 0.88.$$

I rapporti di verosimiglianza positivi sono

$$LR_1^+ = \frac{0.80}{1 - 0.85} \approx 5.33,$$

$$LR_2^+ = \frac{0.75}{1 - 0.88} = 6.25.$$

Gli odds iniziali sono

$$\text{Odds}(\text{ADHD}) = \frac{0.05}{0.95} \approx 0.0526.$$

Dopo il primo risultato positivo:

$$\text{Odds}(\text{ADHD} \mid T_1^+) = 0.0526 \cdot 5.33 \approx 0.281,$$

$$P(\text{ADHD} \mid T_1^+) = \frac{0.281}{1 + 0.281} \approx 0.219.$$

Dopo il secondo risultato positivo:

$$\text{Odds}(\text{ADHD} \mid T_1^+, T_2^+) = 0.281 \cdot 6.25 \approx 1.754,$$

$$P(\text{ADHD} \mid T_1^+, T_2^+) = \frac{1.754}{1 + 1.754} \approx 0.637.$$

```

P_ADHD <- 0.05

sens_T1 <- 0.80
spec_T1 <- 0.85
sens_T2 <- 0.75
spec_T2 <- 0.88

LR_pos_T1 <- sens_T1 / (1 - spec_T1)
LR_pos_T2 <- sens_T2 / (1 - spec_T2)

prior_odds <- P_ADHD / (1 - P_ADHD)

post_odds_T1 <- prior_odds * LR_pos_T1
post_prob_T1 <- post_odds_T1 / (1 + post_odds_T1)

post_odds_both <- post_odds_T1 * LR_pos_T2
post_prob_both <- post_odds_both / (1 + post_odds_both)

data.frame(
  Fase = c(
    "Probabilità iniziale",
    "Dopo questionario positivo",
    "Dopo questionario e osservazione positivi"
  ),
  Probabilità = paste0(
    round(c(P_ADHD, post_prob_T1, post_prob_both) * 100, 1),
    "%"
  )
)
#>                                     Fase Probabilità
#> 1                               Probabilità iniziale      5%
#> 2                               Dopo questionario positivo  21.9%
#> 3 Dopo questionario e osservazione positivi      63.7%

```





Figura 5.2: Aggiornamento sequenziale della probabilità di ADHD dopo due risultati positivi, sotto l'assunzione di indipendenza condizionata.

La Figura 5.2 visualizza il passaggio dal 5% al 21.9% e poi al 63.7%.

La moltiplicazione diretta dei due rapporti di verosimiglianza richiede però un'assunzione importante: i risultati devono essere **condizionatamente indipendenti** sia dato lo stato ADHD sia dato lo stato non-ADHD. Se i due strumenti dipendono dalle stesse fonti informative o misurano aspetti quasi identici, moltiplicare i rapporti rischia di contare due volte la stessa evidenza.

Anche una probabilità post-test elevata non equivale automaticamente a una diagnosi. La decisione clinica deve considerare criteri diagnostici, qualità delle misure, ipotesi alternative e costi delle diverse decisioni.

5.6 Aggiornamento bayesiano con distribuzioni continue

Finora abbiamo aggiornato la probabilità di eventi o ipotesi discrete. Quando la quantità di interesse è continua, come una probabilità, una media o l'ampiezza di un effetto, l'aggiornamento riguarda un'intera **distribuzione di probabilità**.

L'idea non cambia:

$$\text{posterior} \propto \text{verosimiglianza} \times \text{prior}.$$

Cambia invece l'oggetto dell'inferenza. Il risultato non è un solo valore, ma una distribuzione che indica quali valori del parametro siano più plausibili e quanta incertezza rimanga. Il modello Beta-Binomiale offre una prima anticipazione di questo passaggio; verrà ripreso e sviluppato nei capitoli successivi.

! Anticipazione: il modello Beta-Binomiale

Consideriamo un parametro $\theta \in [0, 1]$ che rappresenta la probabilità di successo in una prova binaria. Se scegliamo un prior Beta e osserviamo k successi in n prove, otteniamo

- **Prior:** $\theta \sim \text{Beta}(\alpha, \beta)$;
- **Dati:** k successi in n prove;
- **Posterior:**

$$\theta | k \sim \text{Beta}(\alpha + k, \beta + n - k).$$

Questa proprietà è detta **coniugazione**: prior e posterior appartengono alla stessa famiglia e l'aggiornamento si traduce nella modifica dei parametri.

Supponiamo di stimare la probabilità θ che uno studente risponda correttamente a una domanda con quattro alternative. Usiamo il prior

$$\theta \sim \text{Beta}(1, 3),$$

che ha media 0.25 ma rimane ampio. Dopo 12 risposte corrette su 30, il posterior è

$$\theta | k \sim \text{Beta}(13, 21).$$




Figura 5.3: Aggiornamento nel modello Beta-Binomiale: il posterior combina le informazioni del prior con quelle fornite dai dati.

La Figura 5.3 confronta prior, verosimiglianza riscalata e posterior. La media a posteriori è

$$E(\theta | k) = \frac{13}{13 + 21} \approx 0.38,$$

compresa tra la media del prior, 0.25, e la proporzione osservata, $12/30 = 0.40$. Il posterior rappresenta quindi un compromesso tra informazione precedente e dati.

i Anticipazione: intervalli di credibilità

La distribuzione a posteriori descrive anche l'incertezza residua. Un intervallo di credibilità al 95% individua una regione che contiene il 95% della probabilità a posteriori.




Figura 5.4: Distribuzione a posteriori e intervallo di credibilità al 95%.

La Figura 5.4 consente di affermare, dato il modello, il prior e i dati, che

$$P(0.23 \leq \theta \leq 0.55 | \text{dati}) \approx 0.95.$$

Questa interpretazione riguarda direttamente la distribuzione a posteriori del parametro. Un intervallo di confidenza frequentista descrive invece la copertura a lungo termine della procedura con cui gli intervalli vengono costruiti. La distinzione verrà approfondita in seguito.

Riflessioni conclusive

Il teorema di Bayes rende esplicita la struttura dell'apprendimento dai dati. Partiamo da una valutazione iniziale, consideriamo quanto l'evidenza sia compatibile con le ipotesi e arriviamo a una valutazione aggiornata. In questo processo, $P(E | H)$ e $P(H | E)$ conservano significati distinti: il primo termine descrive ciò che ci aspet-

teremmo sotto l'ipotesi, il secondo ciò che possiamo credere dell'ipotesi dopo aver osservato il dato.

Gli esempi diagnostici mostrano perché nessun risultato possiede un significato assoluto. La stessa evidenza può condurre a conclusioni diverse quando cambia il tasso base, e più evidenze possono essere combinate solo tenendo conto delle dipendenze tra le misure. L'anticipazione sulle distribuzioni continue estende infine la stessa logica: quando l'incertezza riguarda un parametro, l'aggiornamento produce un'intera distribuzione a posteriori.

Nel Capitolo 6 introdurremo le **variabili casuali**, necessarie per rappresentare in modo sistematico quantità numeriche incerte.

Esercizi

1. Un test ha sensibilità 0.90. Spiega perché questa informazione, da sola, non permette di concludere che una persona con risultato positivo abbia il 90% di probabilità di presentare la condizione.
2. Nella formula $P(H | E) \propto P(E | H)P(H)$, quale ruolo svolgono il prior e la verosimiglianza? Descrivi il loro significato senza eseguire calcoli.
3. Due persone ottengono lo stesso risultato positivo allo stesso test, ma provengono da contesti con prevalenze diverse. Perché le loro probabilità a posteriori possono essere differenti?
4. Un rapporto di verosimiglianza uguale a 1 che cosa indica? Che effetto produce sugli *odds* iniziali?
5. In un aggiornamento sequenziale, la probabilità passa dal 5% al 22% dopo un primo risultato positivo e al 64% dopo un secondo. Come va interpretata questa sequenza? Quale assunzione è necessaria per moltiplicare direttamente i due rapporti di verosimiglianza?
6. Nel modello Beta-Binomiale del capitolo, la media del prior è 0.25, la proporzione osservata è 0.40 e la media del posterior è circa 0.38. Che cosa comunica la posizione della media a posteriori?
7. Interpreta questa affermazione: «Dato il modello, il prior e i dati, la probabilità a posteriori che θ sia compreso tra 0.23 e 0.55 è 0.95».
8. Un risultato positivo aumenta molto la probabilità di una condizione, ma non la porta vicino a 1. È corretto considerare il test “sbagliato”? Motiva la risposta facendo riferimento a prior e forza dell'evidenza.

Soluzioni

1. La sensibilità è $P(T^+ | D)$: descrive la probabilità di un risultato positivo tra le persone che presentano la condizione. La domanda clinica è invece $P(D | T^+)$, che dipende anche dalla prevalenza e dal tasso di falsi positivi.
2. Il prior rappresenta ciò che era plausibile prima dell'osservazione; la ve-

rosimiglianza misura quanto il dato osservato sia compatibile con ciascuna ipotesi o valore del parametro. Il posterior combina entrambe le informazioni.

3. Il tasso base entra nel calcolo come prior. A parità di test ed esito, una condizione inizialmente più frequente riceve in genere una probabilità a posteriori maggiore.
4. Un rapporto di verosimiglianza pari a 1 indica che l'evidenza è ugualmente compatibile con l'ipotesi e con la sua alternativa. Moltiplicare gli *odds* per 1 non li modifica.
5. La sequenza rappresenta un accumulo di evidenza: ogni risultato modifica la credenza prodotta dal passaggio precedente. La moltiplicazione diretta richiede che i risultati siano condizionatamente indipendenti dato ciascuno stato considerato.
6. Il posterior si colloca tra prior e dati, ma più vicino alla proporzione osservata. Ciò indica che entrambi contribuiscono all'aggiornamento e che, nell'esempio, i dati apportano più informazione del prior relativamente debole.
7. L'intervallo contiene il 95% della probabilità della distribuzione a posteriori di θ , condizionatamente al modello, al prior e ai dati utilizzati. Non significa che l'intervallo sia valido indipendentemente da tali assunzioni.
8. No. Un test può fornire evidenza favorevole senza rendere la condizione quasi certa. L'esito finale dipende sia dalla forza dell'evidenza, espressa dal rapporto di verosimiglianza, sia dalla probabilità iniziale.

i Punti chiave

- Il teorema di Bayes deriva dalla probabilità condizionata:

$$P(H | E) = \frac{P(E | H)P(H)}{P(E)}.$$

- $P(E | H)$ e $P(H | E)$ non sono intercambiabili.
- Il prior rappresenta le informazioni precedenti; la verosimiglianza descrive la compatibilità dei dati con l'ipotesi; il posterior è la credenza aggiornata.
- Il significato di un risultato diagnostico dipende dal tasso base.
- In forma di *odds*:

$$\text{Odds}(H | E) = \text{Odds}(H) \times \text{LR}.$$

- Più evidenze possono essere combinate sequenzialmente, ma la moltiplicazione diretta dei rapporti di verosimiglianza richiede appropriate assunzioni di indipendenza condizionata.
- Nel modello Beta-Binomiale, prior e dati determinano una distribuzione a posteriori sull'incertezza relativa a θ .

- Un intervallo di credibilità deve essere interpretato condizionatamente al modello, al prior e ai dati.

Parte II

PARTE 2: Variabili casuali e distribuzioni

Riferimenti bibliografici

Chivers, T. (2024). *Everything is Predictable: How Bayesian Statistics Explain Our World*. Simon; Schuster.

Variabili casuali

i In sintesi

Da sapere Una variabile casuale associa un valore numerico a ciascun possibile esito. Le variabili discrete sono descritte da funzioni di massa di probabilità, quelle continue da densità; la funzione di distribuzione cumulativa vale in entrambi i casi. Le distribuzioni congiunte permettono inoltre di rappresentare più quantità incerte simultaneamente.

Da saper fare Distinguere una variabile casuale dal valore che assume; riconoscere se una variabile è discreta o continua; interpretare PMF, PDF e CDF; spiegare perché una densità non è una probabilità; leggere probabilità marginali e valutare il significato dell'indipendenza tra variabili.

Introduzione

Si consideri uno scenario ricorrente nella pratica clinica: un clinico intende valutare l'efficacia di un intervento per il disturbo d'ansia sociale e somministra la *Liebowitz Social Anxiety Scale* (LSAS) a 50 pazienti prima e dopo un ciclo di 12 sedute.

La domanda non si esaurisce nel decidere se l'intervento «funzioni» oppure no. Interessa anche descrivere quanto possano variare i punteggi, quale miglioramento sia plausibile e quanta incertezza rimanga sulle quantità stimate.

Per affrontare domande di questo tipo è necessario passare dalla probabilità di eventi alla probabilità associata a valori numerici. La nozione di **variabile casuale** realizza questo passaggio e costituisce un ponte tra il calcolo delle probabilità e i modelli statistici bayesiani.

6.1 Perché le variabili casuali sono importanti in psicologia?

Molti risultati psicologici sono espressi mediante numeri: punteggi, conteggi di comportamenti, tempi di reazione, misure fisiologiche, differenze pre-post e parame-

tri di un modello. Il numero osservato varia da persona a persona o da una ripetizione all'altra, e questa variabilità deve essere rappresentata esplicitamente.

Le variabili casuali permettono di:

- collegare gli esiti possibili di uno studio ai valori che saranno analizzati;
- descrivere quali valori siano più o meno plausibili;
- distinguere probabilità associate a singoli valori da probabilità associate a intervalli;
- definire prior, verosimiglianze e distribuzioni a posteriori;
- formulare domande come «qual è la probabilità che il miglioramento superi una soglia clinicamente rilevante?».

La funzione che assegna i numeri è deterministica; l'incertezza riguarda quale esito si realizzerà e, di conseguenza, quale valore verrà osservato.

Prerequisiti

Per seguire questo capitolo è necessario aver letto [Capitolo 1](#), [Capitolo 2](#), [Capitolo 3](#), [Capitolo 4](#) e [Capitolo 5](#).

Per la notazione matematica può essere utile consultare [Appendice A](#). Per un richiamo a integrali, derivate e sommatorie, consulta le appendici matematiche fornite nel [Companion](#).

Gli esempi in R servono a visualizzare i concetti e non richiedono competenze di programmazione avanzate.

Panoramica del capitolo

Il percorso che seguiremo è questo:

1. definiremo la variabile casuale come funzione dagli esiti ai numeri reali;
2. distingueremo variabili casuali discrete e continue;
3. introdurremo la funzione di massa di probabilità per le variabili discrete;
4. introdurremo la funzione di densità per le variabili continue;
5. useremo la funzione di distribuzione cumulativa come rappresentazione comune;
6. estenderemo il quadro alle distribuzioni congiunte, alle marginali e all'indipendenza.

Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()

apply_visual_theme()
```

6.2 Dalla probabilità degli eventi ai valori numerici

Nel framework bayesiano sviluppato nei capitoli precedenti, abbiamo assegnato probabilità a *eventi*, ovvero proposizioni sul mondo. Quando un clinico afferma $P(\text{Depressione maggiore}) = 0.3$, sta quantificando la propria credenza in una proposizione binaria.

Questa struttura è potente per molte domande, ma risulta insufficiente quando l'oggetto dell'incertezza non è un evento sì/no, bensì un *valore numerico*. Consideriamo alcune domande tipiche:

- *Quale sarà il punteggio di questo paziente al BDI-II tra sei mesi?*
- *Quanto tempo impiegherà un partecipante in un compito di decisione lessicale?*
- *Quanti sintomi depressivi riporterà il paziente nella prossima settimana?*

In tutti questi casi, l'incertezza non riguarda il verificarsi di un evento, ma l'ampiezza, la durata o l'intensità di un fenomeno. Per modellare questo tipo di incertezza, dobbiamo passare dagli eventi alle *variabili casuali*.

6.2.1 L'idea fondamentale

Il passaggio concettuale consiste nel riconoscere che molti esperimenti producono naturalmente risultati numerici. Un test psicometrico restituisce un punteggio, una misurazione fisiologica produce un valore continuo, un compito cognitivo genera un tempo di reazione. Anche quando gli esiti originari non sono numerici, è possibile *codificarli* mediante numeri, per esempio assegnando 1 al successo e 0 al fallimento. La codifica, tuttavia, non crea automaticamente una scala quantitativa: attribuire 0, 1 e 2 a tre categorie permette di distinguerle, ma non implica che le distanze tra le categorie abbiano un significato metrico.

La traduzione sistematica degli esiti in numeri è realizzata tramite una *variabile casuale*. La "casualità" non risiede nella funzione, che è deterministica, ma nell'incertezza relativa all'esito che si verificherà nello spazio campionario.

6.3 Definizione formale di variabile casuale

Definizione 6.1 (Variabile casuale). Per gli scopi introduttivi di questo manuale, sia Ω uno spazio campionario. Una *variabile casuale* è una funzione

$$X : \Omega \rightarrow \mathbb{R}$$

che associa a ogni esito $\omega \in \Omega$ un unico numero reale $X(\omega)$.

La variabile casuale traduce ciascuna possibilità in un numero, rendendo possibile l'applicazione dell'analisi matematica allo studio dell'incertezza.

Per convenzione, le variabili casuali sono indicate con lettere maiuscole (X, Y, Z), mentre i valori numerici che possono assumere sono indicati con lettere minuscole (x, y, z). Questa distinzione permette di scrivere espressioni come $P(X = x)$ o $P(X \leq x)$.

i Esempio: punteggio in un test a scelta multipla

Consideriamo un test di memoria di lavoro composto da 5 item. Ogni item può essere risolto correttamente (C) o erroneamente (E). Lo spazio campionario è costituito da tutte le possibili sequenze di risposte:

$$\Omega = \{CCCCC, CCCCE, CCCEC, \dots, EEEEE\}.$$

Poiché ogni item ha due esiti possibili e gli item sono 5, lo spazio campionario contiene $2^5 = 32$ elementi.

Definiamo la variabile casuale X che associa a ogni sequenza di risposte il numero totale di risposte corrette:

$$X(\omega) = \text{numero di C in } \omega.$$

Per l'esito $\omega = CCECE$, il valore è $X(CCECE) = 3$. La funzione è deterministica: data la sequenza, il punteggio è univoco. L'incertezza riguarda solo *quale* sequenza verrà osservata.

L'evento $\{X = 3\}$ rappresenta l'insieme di tutti gli esiti che producono esattamente 3 risposte corrette, che contiene $\binom{5}{3} = 10$ elementi.

Se assumiamo che ciascuna risposta sia corretta con probabilità $p = 0.6$ indipendentemente dalle altre:

$$P(X = 3) = \binom{5}{3} (0.6)^3 (0.4)^2 = 10 \times 0.216 \times 0.16 = 0.3456.$$

6.3.1 Perché questo passaggio è cruciale per l'inferenza bayesiana

Nell'inferenza bayesiana, i parametri dei modelli, come la probabilità di successo θ o la media μ , sono trattati essi stessi come variabili casuali. La distribuzione a priori $p(\theta)$ esprime l'incertezza iniziale sul parametro, mentre la distribuzione a posteriori $p(\theta | \text{dati})$ esprime l'incertezza aggiornata.

Senza il concetto di variabile casuale, non sarebbe possibile formulare domande come: "Qual è la probabilità che l'efficacia del trattamento superi una certa soglia clinicamente rilevante?"

6.4 Variabili casuali discrete

Una variabile casuale è detta *discreta* quando l'insieme dei valori possibili è finito o numerabile.

Definizione 6.2 (Variabile casuale discreta). Una variabile casuale X è *discreta* se esiste un insieme finito o numerabile $\mathcal{X} = \{x_1, x_2, \dots\}$ tale che $P(X \in \mathcal{X}) = 1$.

6.4.1 Esempi in psicologia

- **Punteggi grezzi nei test:** numero di risposte corrette (da 0 a n).
- **Scale Likert:** punteggi da 1 a 5 o da 1 a 7.
- **Conteggi di comportamenti:** episodi di abbuffata, risvegli notturni.
- **Categorie diagnostiche codificate:** 0 = assente, 1 = lieve, 2 = moderato, 3 = grave.
- **Numero di criteri soddisfatti** in una valutazione diagnostica.

La caratteristica distintiva è che l'insieme dei valori possibili è finito o numerabile. Nei comuni esempi di conteggio, valori non appartenenti a questo insieme — per esempio 2.5 risposte corrette — non sono esiti possibili della variabile.

6.5 Funzione di massa di probabilità

Per descrivere completamente una variabile casuale discreta, è sufficiente specificare la probabilità associata a ciascun valore possibile.

Definizione 6.3 (Funzione di massa di probabilità (PMF)). La *funzione di massa di probabilità* di una variabile casuale discreta X è la funzione

$$p_X : \mathcal{X} \rightarrow [0, 1]$$

definita da $p_X(x) = P(X = x)$ per ogni $x \in \mathcal{X}$.

La PMF deve soddisfare due condizioni:

1. **Non-negatività:** $p_X(x) \geq 0$ per ogni $x \in \mathcal{X}$.
2. **Normalizzazione:** $\sum_{x \in \mathcal{X}} p_X(x) = 1$.

Una volta nota la PMF, per un sottoinsieme $B \subseteq \mathcal{X}$ vale:

$$P(X \in B) = \sum_{x \in B} p_X(x).$$

6.5.1 Ponte applicativo: la PMF nella pratica clinica

Quando uno psicologo riporta che “il 15% dei pazienti mostra remissione completa (4), il 35% miglioramento sostanziale (3), il 30% miglioramento parziale (2), il 15% nessun cambiamento (1) e il 5% peggioramento (0)”, sta descrivendo una PMF:

x (esito)	0	1	2	3	4
$p_X(x)$	0.05	0.15	0.30	0.35	0.15

Da questa PMF possiamo calcolare, ad esempio, la probabilità di un esito positivo (miglioramento parziale o superiore):

$$P(X \geq 2) = 0.30 + 0.35 + 0.15 = 0.80.$$

i Esempio: PMF del punteggio in un test a 5 item

Riprendiamo il test a 5 item con $p = 0.7$. La variabile X (numero di risposte corrette) può assumere valori tra 0 e 5:

$$p_X(x) = \binom{5}{x} (0.7)^x (0.3)^{5-x}.$$

La distribuzione completa:

x	0	1	2	3	4	5
$p_X(x)$	0.0024	0.0284	0.1323	0.3087	0.3601	0.1681

La probabilità di ottenere almeno 3 risposte corrette è:

$$P(X \geq 3) = 0.3087 + 0.3601 + 0.1681 = 0.8369.$$

6.5.2 Connessione con il percorso bayesiano

La stessa espressione matematica può essere letta in due modi diversi. Come PMF, descrive la probabilità dei possibili valori di X quando θ è fissato. Dopo aver osservato k successi su n prove, se consideriamo l'espressione come funzione di θ , otteniamo la *verosimiglianza*:

$$L(\theta | k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}.$$

La formula è la stessa, ma cambia la domanda: la PMF varia rispetto ai dati possibili; la verosimiglianza confronta valori possibili del parametro alla luce dei dati osservati.

6.6 Variabili casuali continue

Molte grandezze psicologiche sono modellate come continue. Tempi di reazione, livelli di cortisolo e alcuni punteggi o costrutti rappresentati su una scala continua possono assumere, almeno nel modello, qualsiasi valore entro un intervallo. Questa è un'idealizzazione utile: gli strumenti di misura hanno sempre una precisione finita.

Definizione 6.4 (Variabile casuale continua). In questo manuale chiamiamo *continua* una variabile casuale X che ammette una funzione non negativa $f_X : \mathbb{R} \rightarrow [0, +\infty)$, detta *funzione di densità di probabilità* (PDF), tale che per ogni intervallo $[a, b]$:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

La probabilità non è più assegnata a singoli valori, ma a *intervalli* della retta reale.

6.6.1 Esempi in psicologia

- **Tempi di reazione:** latenza in compiti cognitivi, tipicamente in millisecondi.
- **Misure fisiologiche:** livelli di cortisolo, frequenza cardiaca, conduttanza cutanea.
- **Punteggi standardizzati modellati come continui:** per esempio z-score e T-score.
- **Variabili latenti continue:** per esempio un tratto di ansia o un'abilità rappresentati da un modello psicometrico. Altri modelli possono invece usare variabili latenti discrete.
- **Effetti stimati:** dimensioni dell'effetto, coefficienti di regressione.

6.7 Funzione di densità di probabilità

La funzione di densità di probabilità svolge per le variabili continue un ruolo analogo a quello della PMF per le variabili discrete, ma con una differenza cruciale: $f_X(x)$ non rappresenta la probabilità che la variabile assuma esattamente il valore x .

Infatti, per una variabile casuale continua:

$$P(X = x_0) = \int_{x_0}^{x_0} f_X(x) dx = 0.$$

La probabilità non è concentrata nei punti, ma *distribuita sugli intervalli*.

6.7.1 Come interpretare la densità

La densità $f_X(x)$ misura la *concentrazione della probabilità*. Valori elevati indicano regioni nelle quali intervalli della stessa piccola ampiezza raccolgono più probabilità. Non è corretto confrontare probabilità puntuali, perché per una variabile continua ogni singolo punto ha probabilità zero.

Un'analogia: se la probabilità fosse acqua e la retta reale un contenitore, la densità indicherebbe l'altezza dell'acqua. La quantità totale è sempre 1, ma può essere distribuita in modo più o meno concentrato.

Teorema 6.1 (Proprietà delle PDF). *Una funzione $f_X(x)$ è una valida densità se e solo se:*

1. **Non-negatività:** $f_X(x) \geq 0$ per ogni x .
2. **Normalizzazione:** $\int_{-\infty}^{+\infty} f_X(x) dx = 1$.

È importante notare che $f_X(x)$ può superare 1: ciò non viola alcun principio, poiché $f_X(x)$ non è una probabilità. Solo l'*area* ottenuta integrando la densità su un intervallo restituisce una probabilità. Analogamente, $P(X = x) = 0$ non significa che il valore x sia logicamente impossibile: significa che un singolo punto non possiede area.

6.7.2 Ponte applicativo: la PDF nella valutazione clinica

Quando, a scopo modellistico, una misura psicologica viene descritta mediante una distribuzione continua con determinati parametri, si sta specificando una PDF.

Da tale modello è possibile calcolare, per esempio:

- la probabilità che una misura superi una soglia;
- l'intervallo che contiene una determinata quota della distribuzione;
- la probabilità di osservare valori in una regione estrema.

La scelta della famiglia distributiva e dei parametri deve essere giustificata dai dati e dal contesto; non è una proprietà automatica dello strumento di misura.

i Esempio: tempo di reazione in un compito cognitivo

Consideriamo una variabile T che rappresenta il tempo di reazione (in ms). I tempi di reazione sono spesso modellati con distribuzioni asimmetriche positive, come la *log-normale*.

Supponiamo $\ln(T) \sim N(5.7, 0.3^2)$. La PDF è:

$$f_T(t) = \frac{1}{t\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln(t) - \mu)^2}{2\sigma^2}\right) \quad \text{per } t > 0.$$

```
mu <- 5.7
sigma <- 0.3

t_vals <- seq(150, 600, length.out = 500)
df_rt <- data.frame(
  t = t_vals,
  densita = dlnorm(t_vals, meanlog = mu, sdlog = sigma)
)

ggplot(df_rt, aes(x = t, y = densita)) +
  geom_line(linewidth = 1.2) +
  labs(
    x = "Tempo di reazione (ms)",
    y = "Densità di probabilità",
    title = "Distribuzione log-normale dei tempi di reazione"
  )
```




Figura 6.1: Densità log-normale usata a scopo illustrativo per rappresentare tempi di reazione positivi e asimmetrici.

La Figura 6.1 mostra la densità scelta nell'esempio. La probabilità che il tempo di reazione cada tra 300 e 400 ms è l'area sotto la curva in quell'intervallo:

```
prob_300_400 <- plnorm(400, meanlog = mu, sdlog = sigma) -
  plnorm(300, meanlog = mu, sdlog = sigma)
cat("P(300 ≤ T ≤ 400):", round(prob_300_400, 3), "\n")
#> P(300 ≤ T ≤ 400): 0.329
```

6.8 Funzione di distribuzione cumulativa

Esiste una descrizione che vale sia per le variabili discrete che per quelle continue: la *funzione di distribuzione cumulativa*.

Definizione 6.5 (Funzione di distribuzione cumulativa (CDF)). La *funzione di distribuzione cumulativa* di una variabile casuale X è la funzione

$$F_X : \mathbb{R} \rightarrow [0, 1]$$

definita da $F_X(x) = P(X \leq x)$.

In un'interpretazione epistemica della probabilità, $F_X(x)$ rappresenta il grado di credenza che il valore di X non superi la soglia x . Più in generale, è la probabilità cumulata fino a x .

6.8.1 Relazione con PMF e PDF

- **Per variabili continue:** $F_X(x) = \int_{-\infty}^x f_X(t) dt$, e $f_X(x) = \frac{d}{dx} F_X(x)$.
- **Per variabili discrete:** $F_X(x) = \sum_{x_i \leq x} p_X(x_i)$.

Teorema 6.2 (Proprietà della CDF).

1. **Monotonia non decrescente:** $F_X(a) \leq F_X(b)$ per $a < b$.
2. **Comportamento asintotico:** $\lim_{x \rightarrow -\infty} F_X(x) = 0$, $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
3. **Continuità da destra:** $\lim_{h \rightarrow 0^+} F_X(x + h) = F_X(x)$.

6.8.2 Ponte applicativo: uso della CDF per i cut-off clinici

La CDF è lo strumento naturale per calcolare la probabilità di cadere sotto una certa soglia. Se X rappresenta un punteggio psicologico e il modello assegna una distribuzione a X :

- $F_X(9)$ è la probabilità di osservare un punteggio non superiore a 9;
- $1 - F_X(19)$ è la probabilità di osservare un punteggio superiore a 19;
- $F_X(14) - F_X(9)$ è la probabilità di osservare un punteggio maggiore di 9 e non superiore a 14.

L'eventuale significato clinico delle soglie dipende dallo strumento, dalla popolazione e dallo scopo della valutazione.

6.8.3 Connessione con il percorso bayesiano

La CDF è lo strumento fondamentale per calcolare gli *intervalli di credibilità*. Se il parametro θ ha distribuzione a posteriori $p(\theta \mid \text{dati})$:

- il **quantile** q_α tale che $F_\theta(q_\alpha) = \alpha$;
- l'**intervallo di credibilità al 95%** è $[q_{0.025}, q_{0.975}]$;
- la **probabilità a posteriori** che θ superi una soglia θ_0 è $1 - F_\theta(\theta_0)$.

6.9 Variabili casuali multiple

In molti contesti è necessario modellare *più fenomeni aleatori simultaneamente*. Nello studio della comorbidità, ad esempio, è necessario rappresentare congiuntamente ansia e depressione.

6.9.1 Distribuzione congiunta

Definizione 6.6 (Distribuzione congiunta). Siano X e Y due variabili casuali discrete. La *funzione di massa di probabilità congiunta* è:

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

Essa assegna una probabilità a ciascuna coppia di valori (x, y) .

6.9.2 Esempio: ansia e depressione

	Depr. bassa	Depr. media	Depr. alta
Ansia bassa	0.25	0.10	0.05
Ansia media	0.08	0.15	0.07
Ansia alta	0.02	0.08	0.20

La somma di tutte le celle è 1. $p_{X,Y}(\text{alta}, \text{alta}) = 0.20$.

6.9.3 Distribuzioni marginali

Le *distribuzioni marginali* si ottengono sommando sulla variabile da eliminare:

$$p_X(x) = \sum_y p_{X,Y}(x, y), \quad p_Y(y) = \sum_x p_{X,Y}(x, y).$$

Nell'esempio: $p_X(\text{ansia alta}) = 0.02 + 0.08 + 0.20 = 0.30$. Per variabili continue, l'operazione analoga usa un integrale al posto della somma.

6.9.4 Indipendenza probabilistica

Le variabili X e Y sono *indipendenti* se:

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y) \quad \text{per ogni } (x, y).$$

Nell'esempio, ansia e depressione *non* sono indipendenti: $0.20 \neq 0.30 \times 0.32 = 0.096$. La combinazione «ansia alta e depressione alta» riceve quindi più probabilità di quella prevista sotto un modello di indipendenza.

6.9.5 Ponte applicativo

Nella pratica clinica, le relazioni tra ansia e depressione, tra sintomi e funzionamento, richiedono tutte di modellare distribuzioni congiunte. Nell'inferenza bayesiana, quando abbiamo più parametri, la distribuzione a posteriori è una distribuzione congiunta su tutti i parametri.

Riflessioni conclusive

Il concetto di variabile casuale rappresenta l'elemento di collegamento fondamentale tra la teoria della probabilità e l'analisi quantitativa dei fenomeni psicologici. Ogni osservazione, che si tratti di un punteggio, di un tempo di reazione o di un conteggio, può essere formalizzata come un oggetto matematico sul quale è possibile applicare gli strumenti del calcolo probabilistico.

Le variabili casuali si distinguono in due classi principali: discrete e continue. Le prime richiedono una formalizzazione tecnica basata su somme, le seconde su integrali. Pur impiegando strumenti matematici diversi, entrambe le classi rispondono

allo stesso obiettivo: descrivere la distribuzione della probabilità nell'insieme dei valori possibili.

Per chi si avvicina allo studio dell'inferenza bayesiana, la conoscenza di questi concetti è fondamentale per specificare le distribuzioni a priori sui parametri, per comprendere la funzione di verosimiglianza, per interpretare le distribuzioni a posteriori e gli intervalli di credibilità e per formulare domande probabilistiche relative a fenomeni psicologici.

Nei capitoli successivi verranno esaminate le famiglie parametriche di distribuzioni, quali la distribuzione Beta, la distribuzione Normale, la distribuzione Binomiale, la distribuzione di Poisson e altre, che costituiscono gli elementi base della modellazione bayesiana.

Esercizi

1. In uno studio, X associa a ogni partecipante il numero di risposte corrette in un test. Qual è la differenza tra la variabile casuale X e il valore osservato $X = 7$?
2. Le categorie «assenza», «lieve» e «grave» vengono codificate con 0, 1 e 2. Che cosa consente questa codifica e che cosa non permette di concludere sulle distanze tra le categorie?
3. Classifica come discrete o continue, nel modello adottato, le seguenti variabili: numero di errori, tempo di reazione, punteggio su una scala Likert da 1 a 5, livello di cortisolo.
4. Una PMF assegna probabilità 0.05, 0.15, 0.30, 0.35 e 0.15 agli esiti 0, 1, 2, 3 e 4. Che cosa significa $P(X \geq 2) = 0.80$?
5. Per una variabile continua, una densità in un punto vale 1.4. Perché questo valore non viola gli assiomi della probabilità? E perché $P(X = x) = 0$ non rende x impossibile?
6. Supponi che $F_X(14) = 0.72$ e $F_X(9) = 0.40$. Interpreta $F_X(14)$ e la differenza $F_X(14) - F_X(9)$.
7. Nella tabella congiunta del capitolo, la probabilità marginale di ansia alta è 0.30. Spiega perché per ottenerla si sommano tutte le celle della riga «ansia alta».
8. Per due variabili, $P(X = x, Y = y)$ è diverso da $P(X = x)P(Y = y)$. Che cosa indica questa disuguaglianza? Che cosa non permette, da sola, di concludere sul rapporto causale tra le variabili?

Soluzioni

1. X è la regola che associa un numero a ogni possibile esito; $X = 7$ è uno specifico evento o valore osservato della variabile.
2. La codifica permette di rappresentare e distinguere le categorie mediante numeri. Non implica che la distanza tra 0 e 1 sia psicologicamente uguale alla distanza tra 1 e 2, né che i numeri possano essere trattati automaticamente

come misure quantitative.

3. Numero di errori: discreta. Tempo di reazione: modellato come continuo. Scala Likert da 1 a 5: discreta. Livello di cortisolo: modellato come continuo, pur essendo misurato con precisione finita.
4. Significa che, secondo la distribuzione specificata, la probabilità di osservare un esito pari a 2, 3 oppure 4 è 0.80. Il valore deriva dalla somma delle masse assegnate a questi tre esiti.
5. Una densità non è una probabilità puntuale: le probabilità sono aree sotto la curva e devono essere comprese tra 0 e 1. Un singolo punto ha area nulla, ma può comunque essere un possibile valore della variabile.
6. $F_X(14) = 0.72$ significa che la probabilità di osservare un valore non superiore a 14 è 0.72. La differenza $0.72 - 0.40 = 0.32$ è la probabilità che il valore sia maggiore di 9 e non superiore a 14.
7. La marginale ignora quale livello assuma l'altra variabile. Per includere tutti i modi in cui può verificarsi «ansia alta», si sommano le probabilità con depressione bassa, media e alta.
8. Indica che, per quella coppia di valori, la distribuzione congiunta non si fattorizza come previsto dall'indipendenza. Mostra dipendenza probabilistica, ma non stabilisce da sola che una variabile causi l'altra.

i Punti chiave

- Una variabile casuale è una funzione $X : \Omega \rightarrow \mathbb{R}$; l'incertezza riguarda il valore che verrà osservato.
- Una codifica numerica non rende automaticamente quantitativa una variabile categoriale.
- Per una variabile discreta:

$$p_X(x) = P(X = x), \quad \sum_x p_X(x) = 1.$$

- Per una variabile continua descritta da una densità:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

- La densità può superare 1; è l'area su un intervallo a rappresentare una probabilità.
- La CDF vale per variabili discrete e continue:

$$F_X(x) = P(X \leq x).$$

- Una marginale si ottiene eliminando le altre variabili mediante somme o integrali.
- L'indipendenza richiede che la distribuzione congiunta si fattorizzi nel

prodotto delle marginali; non equivale a un'affermazione causale.

- In un modello bayesiano, prior e posterior sui parametri sono distribuzioni di variabili casuali.

Distribuzioni di massa e di densità

i In sintesi

Da sapere Distinguere una funzione di massa di probabilità da una funzione di densità; comprendere perché, nel caso continuo, le probabilità riguardano intervalli e non singoli punti; interpretare la funzione di distribuzione cumulativa.

Da saper fare Leggere PMF, PDF e CDF; ricavare probabilità semplici da una tabella, da un'area o dalla differenza tra valori della CDF; distinguere il significato frequentista e bayesiano di una distribuzione.

Introduzione

Nel capitolo precedente (Capitolo 6) abbiamo introdotto le **variabili casuali** come funzioni che associano valori numerici agli esiti di un esperimento aleatorio. Abbiamo distinto tra variabili casuali **discrete**, che assumono un insieme finito o numerabile di valori, e variabili casuali **continue**, che possono assumere qualsiasi valore all'interno di un intervallo. Per ciascun caso, abbiamo definito formalmente la *funzione di massa di probabilità* (PMF) e la *funzione di densità di probabilità* (PDF) come strumenti fondamentali per descrivere l'incertezza sui valori assunti dalla variabile.

Questo capitolo ha lo scopo di approfondire la **comprensione intuitiva, geometrica e operativa** di tali concetti. Vedremo come la PMF assegni "pesi" discreti a singoli valori, mentre la PDF distribuisca la probabilità in modo continuo lungo la retta reale, rendendo necessario l'uso dell'integrazione per calcolare la probabilità associata a intervalli di valori. In questo contesto affronteremo anche il noto "paradosso" secondo cui, per una variabile casuale continua dotata di densità, la probabilità di osservare un valore esatto è pari a zero, mostrando come questa proprietà non sia affatto paradossale, ma una conseguenza naturale della struttura matematica del continuo.

Un aspetto centrale della trattazione riguarda inoltre la **distinzione interpretativa** tra l'approccio frequentista e quello bayesiano alle distribuzioni di probabilità. Nel paradigma frequentista, la funzione di densità descrive il comportamento dei

dati in ipotetiche ripetizioni dell'esperimento. Nell'approccio bayesiano, invece, la PDF rappresenta il **grado di credenza** assegnato ai possibili valori di una quantità incerta, come un parametro o una grandezza latente. Questa differenza concettuale, apparentemente sottile, ha implicazioni profonde per il modo in cui interpretiamo le distribuzioni, calcoliamo le probabilità e traiamo conclusioni inferenziali.

7.1 Perché le distribuzioni di probabilità sono importanti in psicologia?

In psicologia, molte domande riguardano non un singolo valore isolato, ma l'intera gamma dei risultati plausibili: quali punteggi sono comuni, quanto sono probabili valori estremi, quale intervallo contiene la maggior parte dei casi e come cambia l'incertezza dopo avere osservato nuovi dati. Le distribuzioni di probabilità forniscono il linguaggio necessario per rispondere a queste domande.

La distinzione tra massa e densità evita errori interpretativi frequenti. Per un punteggio discreto può avere senso assegnare probabilità a valori specifici; per una misura trattata come continua, invece, la probabilità è associata a intervalli. La CDF consente poi di tradurre soglie psicologicamente rilevanti in probabilità cumulative. Nel quadro bayesiano, le stesse strutture descrivono anche l'incertezza su parametri, effetti e quantità latenti.

Prerequisiti

Per seguire il capitolo è necessario avere letto Capitolo 6. Per la notazione, consulta Appendice A.

Per un richiamo su integrali, derivate e limiti, consulta le appendici matematiche disponibili nel Companion.

Panoramica del capitolo

Il capitolo procede in cinque passaggi:

1. distingue massa e densità di probabilità;
2. mostra come leggere una PMF e una PDF;
3. chiarisce perché un punto ha probabilità zero nel caso continuo;
4. introduce la funzione di distribuzione cumulativa;
5. confronta l'interpretazione frequentista e quella bayesiana delle distribuzioni.

Preparazione del notebook

```
here::here("code", "_common.R") |>  
  source()  
  apply_visual_theme()
```

7.2 Dalla massa alla densità di probabilità

La distinzione tra variabili casuali **discrete** e **continue** non è solo tecnica: riflette due modi profondamente diversi in cui la probabilità si distribuisce sui valori possibili. Nel caso discreto, si può assegnare una probabilità positiva a ogni singolo valore; nel caso continuo, invece, la probabilità non si concentra su punti isolati ma si **distribuisce su un continuum**, per cui sono assegnabili solo le probabilità associate a intervalli.

Questa differenza concettuale è cruciale per comprendere correttamente il ruolo delle funzioni di massa e di densità di probabilità.

7.3 La funzione di massa di probabilità

Per una variabile casuale discreta X che assume valori nell'insieme

$$\mathcal{X} = \{x_1, x_2, \dots\},$$

la **funzione di massa di probabilità** (PMF) associa a ciascun valore possibile la probabilità corrispondente:

$$p_X(x) = P(X = x).$$

Il termine *massa* evoca una metafora fisica appropriata: la probabilità può essere immaginata come una collezione di **pesi discreti** collocati sui valori possibili della variabile. Ogni valore x_i è associato a una quantità $p_X(x_i)$ e la somma totale delle masse deve essere pari a 1. In questo contesto, è perfettamente lecito “concentrare” una parte rilevante della probabilità in pochi punti specifici.

i Esempio: soddisfazione lavorativa su scala Likert

Distribuzione tipica delle risposte

Consideriamo le risposte a un item sulla soddisfazione lavorativa, misurata su una scala Likert a 5 punti (1 = “molto insoddisfatto”, 5 = “molto soddisfatto”). Consideriamo, a scopo illustrativo, la seguente distribuzione ipotetica, nella quale le risposte sono più concentrate sui livelli centrali e moderatamente positivi:

Risposta	1 (molto insod.)	2	3	4	5 (molto sodd.)
$p_X(x)$	0.05	0.10	0.25	0.40	0.20

In questa PMF ipotetica, poca probabilità è assegnata alla forte insoddisfazione, mentre la maggior parte è concentrata sui livelli moderati o buoni. La coerenza della distribuzione è immediatamente verificabile:

$$\sum_{x=1}^5 p_X(x) = 0.05 + 0.10 + 0.25 + 0.40 + 0.20 = 1.$$

Simulando 10.000 risposte secondo questa distribuzione e confrontando le frequenze empiriche con la PMF teorica, osserviamo una chiara convergenza:

```
set.seed(123)
prob_teoriche <- c(0.05, 0.10, 0.25, 0.40, 0.20)
n_risposte <- 10000

risposte <- sample(1:5, size = n_risposte, replace = TRUE, prob =
  prob_teoriche)
freq_rel <- table(risposte) / n_risposte

df <- data.frame(
  valore = 1:5,
  empirica = as.numeric(freq_rel),
  teorica = prob_teoriche
)

ggplot(df, aes(x = factor(valore))) +
  geom_col(aes(y = empirica), alpha = 0.7, width = 0.6) +
  geom_point(aes(y = teorica), size = 4) +
  labs(
    x = "Livello di soddisfazione",
    y = "Probabilità / Frequenza relativa",
    title = "PMF della soddisfazione lavorativa (scala Likert 1-5)"
  )
```




Figura 7.1: Frequenze relative simulate e probabilità teoriche per una PMF su una scala di soddisfazione a cinque livelli.

La Figura 7.1 confronta le frequenze relative ottenute nella simulazione con le probabilità specificate dalla PMF.

Da questa distribuzione possiamo calcolare probabilità di interesse pratico. Ad esempio, la probabilità che un lavoratore riporti almeno un livello di soddisfazione “buono” (4 o 5) è:

$$P(X \geq 4) = p_X(4) + p_X(5) = 0.40 + 0.20 = 0.60.$$

La probabilità di insoddisfazione (1 o 2) è invece:

$$P(X \leq 2) = p_X(1) + p_X(2) = 0.05 + 0.10 = 0.15.$$

La vicinanza tra frequenze simulate e probabilità teoriche illustra una conseguenza del modello in prove ripetute. Non dimostra che questa PMF descriva una popolazione reale: tale adeguatezza richiederebbe dati empirici e controlli del modello.

7.4 La funzione di densità di probabilità

Nel caso delle variabili casuali continue dotate di densità, non si assegna una massa positiva a ciascun singolo valore. La probabilità viene invece distribuita su intervalli mediante una funzione di densità. La soluzione concettuale consiste quindi nel passare dalla “massa” alla “densità”.

Invece di chiederci quanta probabilità c'è *in* un punto, ci chiediamo quanta probabilità c'è *attorno* a un punto per unità di lunghezza.

Definizione 7.1 (Funzione di densità di probabilità). Una funzione

$$f_X : \mathbb{R} \rightarrow [0, +\infty)$$

è una *funzione di densità di probabilità* (PDF) per una variabile casuale continua X se, per ogni intervallo $[a, b] \subseteq \mathbb{R}$,

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx,$$

e se soddisfa la condizione di normalizzazione

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1.$$

La densità $f_X(x)$ misura la **concentrazione locale della probabilità** in prossimità del punto x . Un valore elevato di $f_X(x)$ indica che, in un intorno molto piccolo di x , si concentra una probabilità relativamente maggiore rispetto alle regioni con densità inferiore.

È importante notare che la densità non rappresenta una probabilità puntuale: per una variabile continua dotata di densità, la probabilità che X assuma esattamente un singolo valore è zero, $P(X = x) = 0$. La probabilità è rappresentata dall'area sotto la curva su un intervallo, non dall'altezza della curva in un punto.

7.5 Dagli istogrammi alle densità

Un modo intuitivo per comprendere la PDF consiste nel confrontarla con un **istogramma in scala di densità**. Con un campione sufficientemente ampio e una scelta adeguata della larghezza delle classi, l'istogramma può approssimare la forma della densità teorica. La qualità dell'approssimazione dipende però sia dalla numerosità campionaria sia dal modo in cui vengono definite le classi.

Per illustrare questo concetto, consideriamo un modello didattico in cui i punteggi di QI sono rappresentati da una distribuzione normale con media $\mu = 100$ e deviazione standard $\sigma = 15$. Questa è un'approssimazione convenzionale, non una descrizione esatta di ogni popolazione o strumento. Osserviamo come l'istogramma in scala di densità diventi più stabile all'aumentare della dimensione campionaria:

```
set.seed(42)
mu <- 100
sigma <- 15

n_piccolo <- 50
n_grande <- 20000

x_piccolo <- rnorm(n_piccolo, mean = mu, sd = sigma)
x_grande <- rnorm(n_grande, mean = mu, sd = sigma)

x_seq <- seq(40, 160, length.out = 200)
y_teorica <- dnorm(x_seq, mean = mu, sd = sigma)
df_teorica <- data.frame(x = x_seq, y = y_teorica)
```

```

p1 <- ggplot(data.frame(x = x_piccolo), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 15,
                 color = "white", alpha = 0.7) +
  geom_line(data = df_teorica, aes(x = x, y = y),
            linewidth = 1) +
  labs(title = paste("n =", n_piccolo, "individui"),
       x = "QI", y = "Densità")

p2 <- ggplot(data.frame(x = x_grande), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 50,
                 color = "white", alpha = 0.7) +
  geom_line(data = df_teorica, aes(x = x, y = y),
            linewidth = 1) +
  labs(
    title = paste("n =", format(n_grande, big.mark = ","), "individui"),
    x = "QI", y = "Densità")

gridExtra::grid.arrange(p1, p2, ncol = 2)

```




Figura 7.2: Istogrammi in scala di densità per un campione piccolo e uno grande, confrontati con la densità normale usata per generare i dati.

Nella Figura 7.2, il campione piccolo produce un istogramma irregolare, mentre quello grande restituisce un profilo più stabile e vicino alla densità generatrice. La figura illustra il comportamento atteso sotto il modello simulato; non dimostra che una distribuzione normale sia adeguata per dati reali.

La PDF è un **modello idealizzato** della distribuzione di una variabile continua. La sua utilità dipende dalla capacità del modello di rappresentare gli aspetti dei dati rilevanti per la domanda di ricerca.

7.5.1 Punto chiave da ricordare

- La PMF può assegnare probabilità positive a **valori specifici**.
- La PDF assegna un valore di densità ai punti, ma le probabilità si ottengono su **intervalli**.
- Nel caso continuo dotato di densità, un singolo punto ha probabilità zero.
- Una densità può descrivere dati osservabili oppure, nel quadro bayesiano, l'incertezza su una quantità ignota.

7.6 Il paradosso della probabilità nulla

Una delle proprietà più controintuitive delle variabili casuali continue è che la probabilità di osservare *esattamente* un valore specifico è sempre nulla:

$$P(X = x_0) = 0 \quad \text{per ogni } x_0 \in \mathbb{R}.$$

A prima vista, ciò sembra generare un paradosso: se ogni valore puntuale ha probabilità zero, com'è possibile osservare empiricamente un valore qualunque? Quando misuriamo un'altezza di 170 cm, non stiamo forse registrando un evento che la teoria considera impossibile?

7.6.1 Perché la probabilità di un punto è zero

La risposta risiede nel significato geometrico della densità di probabilità. Per una variabile continua, la probabilità si ottiene come l'**area sottostante la curva** su un intervallo. Un singolo punto corrisponde a un intervallo di ampiezza nulla e, quindi, a un'area nulla:

$$P(X = x_0) = \int_{x_0}^{x_0} f_X(x) dx = 0.$$

Questa non è una lacuna della teoria, bensì una proprietà logica del continuo matematico: qualsiasi area calcolata su un intervallo di lunghezza zero è necessariamente pari a zero. Se a ogni singolo punto fosse assegnata una probabilità positiva, l'accumulo su un insieme non numerabile di punti violerebbe la condizione di normalizzazione, secondo cui l'area totale sottostante alla densità deve essere pari a 1.

7.6.2 Perché allora osserviamo un valore?

L'apparente paradosso si dissolve ricordando che una misura empirica non fornisce mai un punto matematico "perfetto", bensì un valore con una **risoluzione finita**. Dire "170 cm" significa, in pratica, "un valore in un piccolo intervallo attorno a 170", determinato dalla precisione dello strumento e dal processo di arrotondamento. La teoria continua descrive proprio questo: le probabilità su intervalli, non su singoli punti.

7.6.3 Implicazioni pratiche

Per le variabili continue non ha senso chiedersi: “Qual è la probabilità che il tempo di reazione sia *esattamente* 250 ms?”. La domanda operativa corretta è: “Qual è la probabilità che il tempo di reazione sia compreso tra 245 e 255 ms?”. Le probabilità si calcolano sempre su **intervalli**, mai su punti singoli.

Un corollario importante è che, per le variabili continue, includere o escludere gli estremi di un intervallo non modifica la probabilità:

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b).$$

Questo perché i singoli punti a e b hanno probabilità zero.

7.6.4 Conseguenze per la valutazione psicologica

Questa proprietà matematica ha implicazioni dirette sull'interpretazione dei punteggi nei test psicologici. Consideriamo la valutazione del QI: non ha senso chiedersi “qual è la probabilità che il QI di questo bambino sia esattamente 115?” – la risposta sarebbe sempre zero, a prescindere dal bambino.

Le domande clinicamente rilevanti riguardano invece gli intervalli:

- “Qual è la probabilità che il punteggio cada nell'intervallo 110-120?”
- “Qual è la probabilità che il punteggio sia inferiore a 70?”
- “Qual è la probabilità che il punteggio superi 130?”

Queste soglie possono avere usi descrittivi o di screening, ma non determinano da sole una diagnosi o una valutazione clinica: l'interpretazione richiede informazioni sullo strumento, sull'errore di misura e sul contesto della persona.

Questo principio si applica a tutte le misurazioni continue in psicologia: punteggi di ansia, tempi di reazione, livelli di cortisolo e indici di benessere. La teoria delle variabili continue ci insegna a formulare le domande nel modo corretto, sempre in termini di intervalli e mai di valori puntuali.

7.7 La funzione di distribuzione cumulativa

La funzione di distribuzione cumulativa (CDF) fornisce una rappresentazione unificata delle distribuzioni di probabilità, valida sia per le variabili discrete che per quelle continue.

Definizione 7.2 (Funzione di distribuzione cumulativa). La *funzione di distribuzione cumulativa* di una variabile casuale X è definita come

$$F_X(x) = P(X \leq x).$$

Questa definizione è universale: la CDF “accumula” probabilità da $-\infty$ fino al valore x e rappresenta la probabilità che la variabile non superi la soglia x .

7.7.1 Proprietà fondamentali della CDF

Ogni CDF soddisfa tre proprietà strutturali.

Teorema 7.1 (Proprietà della CDF). *Per qualsiasi variabile casuale X , la CDF F_X soddisfa:*

1. **Monotonia non decrescente:** se $a < b$, allora $F_X(a) \leq F_X(b)$.
2. **Limiti agli estremi:** $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
3. **Continuità a destra:** $\lim_{h \rightarrow 0^+} F_X(x + h) = F_X(x)$ per ogni x .

La monotonia riflette l'ovvio: ampliando l'intervallo $(-\infty, x]$ non si può perdere probabilità. I limiti garantiscono la normalizzazione globale. La continuità a destra è una convenzione tecnica necessaria soprattutto per le variabili discrete, in cui la CDF presenta salti.

7.7.2 CDF per variabili discrete e continue

Per variabili **discrete**, la CDF è una funzione a gradini: è costante tra due valori possibili e cresce a salti. L'altezza del salto nel punto x_i è esattamente $p_X(x_i)$.

Per una variabile **continua dotata di densità**, la CDF è continua e assolutamente continua. La densità coincide con la derivata della CDF quasi ovunque:

$$f_X(x) = \frac{d}{dx} F_X(x) \quad \text{quasi ovunque,}$$

e la CDF si ottiene integrando la densità:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

```
# CDF discreta (soddisfazione lavorativa 1-5)
valori_disc <- 1:5
prob_disc <- c(0.05, 0.10, 0.25, 0.40, 0.20)
cdf_disc <- cumsum(prob_disc)

df_disc <- data.frame(
  x_start = c(0, valori_disc),
  x_end = c(valori_disc, 6),
  y = c(0, cdf_disc)
)

p1 <- ggplot() +
  geom_segment(data = df_disc, aes(x = x_start, xend = x_end, y = y, yend
    = y),
    linewidth = 1) +
  geom_point(data = data.frame(x = valori_disc, y = cdf_disc),
    aes(x = x, y = y), size = 3) +
  geom_point(data = data.frame(x = valori_disc, y = c(0, cdf_disc[-5])),
    aes(x = x, y = y), size = 3, shape = 1) +
  scale_x_continuous(breaks = 0:6, limits = c(0, 6)) +
  scale_y_continuous(breaks = seq(0, 1, 0.2)) +
  labs(title = "CDF discreta (soddisfazione lavorativa)",
    x = "Livello di soddisfazione", y = expression(F[X](x)))
```

```
# CDF continua (QI, normale con mu=100, sigma=15)
x_cont <- seq(40, 160, length.out = 200)
cdf_cont <- pnorm(x_cont, mean = 100, sd = 15)

p2 <- ggplot(data.frame(x = x_cont, y = cdf_cont), aes(x = x, y = y)) +
  geom_line(linewidth = 1) +
  scale_y_continuous(breaks = seq(0, 1, 0.2)) +
  labs(title = "CDF continua (QI)",
       x = "QI", y = expression(F[X](x)))

gridExtra::grid.arrange(p1, p2, ncol = 2)
```




Figura 7.3: CDF di una variabile discreta (sinistra, a gradini) e di una variabile continua normale (destra, curva liscia). Nella CDF discreta, l'ampiezza di ogni salto corrisponde alla massa nel punto.

La Figura 7.3 mostra che la CDF cresce a salti nel caso discreto e in modo continuo nel caso normale. In entrambi i casi, il valore della funzione in x è una probabilità cumulativa.

7.7.3 Calcolo di probabilità mediante la CDF

Uno dei principali vantaggi della CDF è che permette di calcolare la probabilità di un intervallo mediante una differenza:

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

Questa relazione è valida sia per le variabili discrete sia per quelle continue. Se si vuole includere anche l'estremo sinistro nel caso discreto, si usa

$$P(a \leq X \leq b) = F_X(b) - F_X(a^-),$$

dove $F_X(a^-)$ indica il limite della CDF da sinistra.

i Esempio: calcoli con la CDF normale

Probabilità per la distribuzione del QI

Consideriamo, a scopo didattico, un modello normale per i punteggi di QI con media $\mu = 100$ e deviazione standard $\sigma = 15$. Calcoliamo alcune probabilità descrittive sotto questo modello.

```
mu <- 100
sigma <- 15

# P(QI > 130)
p_alto <- 1 - pnorm(130, mean = mu, sd = sigma)
cat("P(QI > 130) =", round(p_alto, 4), "\n")
#> P(QI > 130) = 0.0228

# P(85 < QI < 115)
p_norma <- pnorm(115, mean = mu, sd = sigma) - pnorm(85, mean = mu, sd
  <- sigma)
cat("P(85 < QI < 115) =", round(p_norma, 4), "\n")
#> P(85 < QI < 115) = 0.683

# P(QI < 70)
p_basso <- pnorm(70, mean = mu, sd = sigma)
cat("P(QI < 70) =", round(p_basso, 4), "\n")
#> P(QI < 70) = 0.0228

# Percentile 95
q95 <- qnorm(0.95, mean = mu, sd = sigma)
cat("95° percentile:", round(q95, 1), "\n")
#> 95° percentile: 125
```

Questi calcoli mostrano come la CDF (implementata in R da `pnorm`) consenta di tradurre le domande cliniche in operazioni matematiche dirette:

- sotto il modello, circa il 2.3% dei punteggi supera 130;
- circa il 68% dei punteggi cade tra 85 e 115;
- circa il 2.3% dei punteggi è inferiore a 70;
- il 95° percentile corrisponde a un punteggio di circa 125.

Queste probabilità descrivono il modello adottato. Il significato psicologico o clinico di una soglia non deriva dalla sola distribuzione e richiede ulteriori criteri di validità e interpretazione.

7.8 Interpretazioni bayesiana e frequentista

Le distribuzioni di probabilità assumono significati diversi nei due principali paradigmi dell'inferenza statistica. Questa distinzione non è soltanto filosofica, ma

ha un impatto diretto sul modo in cui interpretiamo i risultati, formuliamo i modelli e comunichiamo l'incertezza.

7.8.1 L'interpretazione frequentista

Nell'interpretazione frequentista standard, la probabilità è collegata alla **frequenza relativa di lungo periodo** in una serie ideale di ripetizioni dello stesso processo. Per un evento del tipo $a \leq X \leq b$, questa interpretazione implica:

$$P(a \leq X \leq b) = \lim_{n \rightarrow \infty} \frac{\#\{X_i \in [a, b]\}}{n},$$

dove $X_1, X_2, \dots, X_n$ sono realizzazioni indipendenti dello stesso processo stocastico.

In questa prospettiva, la funzione di densità non esprime una probabilità sul valore di un parametro fisso. Descrive invece la distribuzione di una variabile casuale, per esempio i possibili dati o una statistica campionaria nelle ripetizioni del processo. La variabile casuale X modella l'esito di un esperimento ripetibile, e la sua PDF descrive la variabilità osservabile tra le diverse ripetizioni.

Un esempio classico è la distribuzione dell'altezza nella popolazione adulta. Un modello normale con media $\mu = 170$ cm e deviazione standard $\sigma = 10$ cm descrive quale proporzione di individui ci aspetteremmo di osservare in ogni intervallo di altezza, se potessimo campionare ripetutamente e a caso da una popolazione di riferimento molto ampia e stabile.

7.8.2 L'interpretazione bayesiana

Nel paradigma bayesiano, la probabilità quantifica un **grado di credenza razionale**, ovvero una misura della plausibilità assegnata a diverse possibilità alla luce delle informazioni disponibili. Non è necessario immaginare delle ripetizioni ipotetiche: la probabilità è una proprietà dello stato informativo dell'osservatore.

Definizione 7.3 (Interpretazione bayesiana della PDF). Dal punto di vista bayesiano, una funzione di densità può rappresentare la **distribuzione dell'incertezza** su una quantità ignota, come un parametro, oppure una distribuzione predittiva per dati non ancora osservati. Quando X indica una quantità ignota, l'integrale $\int_a^b f_X(x) dx$ esprime il grado di credenza che il suo valore appartenga all'intervallo $[a, b]$, condizionatamente al modello e alle informazioni disponibili.

Ne deriva un'implicazione cruciale: il paradigma bayesiano permette di descrivere con distribuzioni di probabilità non solo i dati osservabili, ma anche quelle quantità che nel frequentismo sono considerate parametri fissi, come l'effetto medio di un trattamento, la prevalenza di una malattia o la probabilità soggettiva di risposta alla terapia.

In questa logica, una funzione di densità bayesiana rappresenta una mappa di plausibilità: le regioni con densità più alta corrispondono a valori che riteniamo più credibili, mentre quelle con densità bassa riflettono ipotesi meno plausibili. La forma stessa della distribuzione, la sua simmetria o asimmetria, l'estensione delle code e il

grado di concentrazione esprimono esplicitamente ciò che sappiamo e, soprattutto, ciò che ignoriamo sulla quantità di interesse.

7.8.3 Confronto tra le due prospettive

Le differenze metodologiche emergono in modo netto in un esempio elementare. Supponiamo di voler stimare l'altezza media di una popolazione, denotata con θ .

- **Nel paradigma frequentista**, θ è un **parametro fisso ma sconosciuto**. La probabilità si applica alle statistiche calcolate dai campioni, come la media campionaria $\bar{X}$. La PDF di $\bar{X}$ descrive come quest'ultima varierebbe se ripetessimo infinite volte il campionamento dalla stessa popolazione. Di conseguenza, un intervallo di confidenza al 95% **non** afferma che il valore di θ abbia una probabilità dello 0.95 di cadere in quell'intervallo (dal momento che θ non è una variabile casuale), ma piuttosto che il *metodo* utilizzato per costruire l'intervallo lo conterrebbe nel 95% delle ripetizioni sperimentali.
- **Nel paradigma bayesiano**, invece, è possibile assegnare direttamente una distribuzione di probabilità a θ , quantificando la nostra incertezza su di esso. La distribuzione *a priori* formalizza le conoscenze iniziali, mentre quella *a posteriori* aggiorna tali conoscenze con le informazioni provenienti dai dati. Pertanto, un intervallo di credibilità al 95% contiene il 95% della probabilità a posteriori di θ , condizionatamente al modello, alla prior e ai dati osservati.

```
set.seed(123)
```

```
# Frequentista: distribuzione dei dati
x_freq <- rnorm(1000, mean = 170, sd = 10)
x_seq <- seq(140, 200, length.out = 200)
y_teorica <- dnorm(x_seq, mean = 170, sd = 10)

p1 <- ggplot() +
  geom_histogram(data = data.frame(x = x_freq), aes(x = x, y =
    ~ after_stat(density)),
    bins = 30, alpha = 0.5, color = "white") +
  geom_line(data = data.frame(x = x_seq, y = y_teorica),
    aes(x = x, y = y), linewidth = 1.2) +
  labs(title = "Dati osservabili:\ndistribuzione normale",
    subtitle = "Variabilità tra osservazioni",
    x = "Altezza (cm)", y = "Densità")

# Bayesiano: distribuzione della credenza su un parametro
theta_seq <- seq(165, 175, length.out = 200)
prior <- dnorm(theta_seq, mean = 170, sd = 2)

p2 <- ggplot() +
  geom_ribbon(data = data.frame(x = theta_seq, y = prior),
    aes(x = x, ymin = 0, ymax = y),
    alpha = 0.3) +
  geom_line(data = data.frame(x = theta_seq, y = prior),
    aes(x = x, y = y), linewidth = 1.2) +
  labs(title = "Parametro ignoto:\ndistribuzione bayesiana",
```

```

subtitle = "Incertezza sul valore del parametro",
x = expression(theta ~ "(altezza media)"), y = "Densità")

gridExtra::grid.arrange(p1, p2, ncol = 2)

```




Figura 7.4: Due possibili oggetti di una distribuzione: a sinistra, la variabilità di dati osservabili; a destra, l'incertezza bayesiana su un parametro ignoto.

La Figura 7.4 visualizza due possibili oggetti della modellazione: una distribuzione per dati osservabili e una distribuzione che rappresenta l'incertezza su un parametro.

La CDF rimane in entrambi i paradigmi uno strumento per calcolare probabilità cumulative. A cambiare è l'oggetto a cui la distribuzione viene applicata e il significato inferenziale attribuito alla probabilità: frequenza di lungo periodo per processi ripetibili nell'interpretazione frequentista; grado di credenza coerente, condizionato alle informazioni disponibili, nell'interpretazione bayesiana.

Riflessioni conclusive

La distinzione tra **massa** e **densità** chiarisce due modi diversi di rappresentare l'incertezza. Una funzione di probabilità a massa finita (PMF) può assegnare probabilità positive a valori discreti, mentre una funzione di densità di probabilità (PDF) assegna densità e le probabilità si ottengono integrando su intervalli. Per questo motivo, nel caso continuo dotato di densità, un singolo punto ha probabilità zero, ma ciò non lo rende logicamente impossibile.

La **funzione di distribuzione cumulativa** unifica i due casi. Esprime la probabilità che la variabile non superi una soglia e consente di calcolare le probabilità degli intervalli mediante le differenze tra i valori cumulativi. La CDF è quindi particolarmente

utile quando una domanda psicologica è formulata in termini di soglie, percentili o fasce di valori.

Infine, la stessa struttura matematica può assumere ruoli diversi. Una distribuzione può descrivere la variabilità dei dati, la distribuzione campionaria di una statistica, l'incertezza bayesiana su un parametro o una previsione per osservazioni future. Nei capitoli successivi useremo la media, la varianza e altre proprietà per sintetizzare queste distribuzioni, senza perdere di vista il loro significato.

Esercizi

1. Una variabile discreta assegna probabilità 0.20, 0.35 e 0.45 ai valori 1, 2 e 3. Quale proprietà rende valida questa PMF? Che cosa significa $P(X = 2) = 0.35$?
2. Per la scala di soddisfazione presentata nel capitolo, calcola la probabilità di osservare un valore almeno pari a 4. Spiega il risultato con una frase.
3. Due punti di una PDF hanno altezze 0.08 e 0.04. Possiamo concludere che il primo punto ha probabilità doppia del secondo? Spiega che cosa si può affermare correttamente.
4. Un tempo di reazione viene modellato come continuo. Che cosa significa l'affermazione $P(X = 300) = 0$? Perché non implica che sia impossibile registrare 300 ms?
5. Una CDF soddisfa $F(10) = 0.30$ e $F(15) = 0.75$. Quanto vale $P(10 < X \leq 15)$? Qual è l'interpretazione del risultato?
6. In una distribuzione discreta, perché $P(10 \leq X \leq 15)$ non è sempre uguale a $F(15) - F(10)$? Quale informazione manca in quella differenza?
7. Un intervallo di credibilità bayesiano al 95% per un parametro è $[0.20, 0.50]$. Che cosa significa questa affermazione? Quali elementi condizionano l'interpretazione?
8. Valuta le seguenti affermazioni, correggendo quelle false:
 - a. Una densità non può superare 1.
 - b. Una CDF è non decrescente.
 - c. Per una variabile continua dotata di densità, includere gli estremi di un intervallo cambia la probabilità.
 - d. Un istogramma molto simile a una curva teorica dimostra che il modello è vero.

Soluzioni

1. Le probabilità sono non negative e sommano a 1. L'espressione $P(X = 2) = 0.35$ significa che al valore 2 è assegnata probabilità 0.35.
2. $P(X \geq 4) = 0.40 + 0.20 = 0.60$. Sotto la PMF, il 60% della probabilità è assegnato ai livelli 4 e 5.
3. No. Le altezze sono densità, non probabilità puntuali. In piccoli inter-

valli della stessa ampiezza attorno ai due punti, il primo può ricevere approssimativamente una probabilità maggiore, se la densità varia poco nell'intervallo.

4. Significa che un singolo punto ha area nulla sotto la densità. Una misura registrata come 300 ms rappresenta in pratica un intervallo determinato dalla precisione e dall'arrotondamento dello strumento.
5. $P(10 < X \leq 15) = F(15) - F(10) = 0.75 - 0.30 = 0.45$. Il 45% della probabilità è compreso sopra 10 e fino a 15 incluso.
6. La differenza $F(15) - F(10)$ esclude la massa eventualmente presente in $X = 10$. Per includerla occorre usare $F(15) - F(10^-)$ oppure aggiungere $P(X = 10)$.
7. L'intervallo contiene il 95% della probabilità a posteriori del parametro. L'interpretazione è condizionata al modello, alla prior e ai dati osservati.
8.
 - a. Falsa: una densità può superare 1, purché l'area totale sia 1.
 - b. Vera.
 - c. Falsa: i singoli punti hanno probabilità zero.
 - d. Falsa: la somiglianza è compatibile con il modello, ma non ne dimostra la verità o l'adeguatezza generale.

i Punti chiave

- Per una variabile discreta, $p_X(x) = P(X = x)$ e $\sum_x p_X(x) = 1$.
- Per una variabile continua dotata di densità,

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx, \quad \int_{-\infty}^{+\infty} f_X(x) dx = 1.$$

- La densità $f_X(x)$ non è una probabilità puntuale e può essere maggiore di 1.
- Per una variabile continua dotata di densità, $P(X = x) = 0$.
- La CDF è $F_X(x) = P(X \leq x)$ ed è non decrescente, continua a destra e compresa tra 0 e 1.
- Per ogni variabile casuale,

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

- Se X possiede una densità, $F_X(x) = \int_{-\infty}^x f_X(t) dt$ e $F'_X(x) = f_X(x)$ quasi ovunque.
- Nel quadro bayesiano, una distribuzione su un parametro descrive l'incertezza condizionata al modello e alle informazioni disponibili.

Proprietà delle variabili casuali

i In sintesi

Da sapere Comprendere il valore atteso come centro di una distribuzione e la varianza come misura della dispersione; distinguere le proprietà del valore atteso da quelle della varianza; interpretare deviazione standard, standardizzazione e precisione della media campionaria.

Da saper fare Calcolare e interpretare valore atteso e varianza in esempi elementari; riconoscere quando l'indipendenza è necessaria e quando non lo è; spiegare come una trasformazione lineare o la numerosità campionaria modificano centro e dispersione.

Introduzione

Immaginiamo uno scenario comune nella pratica clinica. Una psicologa deve decidere se raccomandare a un paziente affetto da depressione moderata un nuovo protocollo di intervento cognitivo-comportamentale. I dati disponibili indicano che, in media, i pazienti trattati mostrano un miglioramento di 8 punti nel BDI-II dopo 12 settimane.

Un miglioramento medio di 8 punti potrebbe derivare da situazioni molto diverse: potrebbe significare che quasi tutti i pazienti migliorano di circa 8 punti, oppure che alcuni migliorano molto e altri poco o per nulla. Nel primo caso l'esito è relativamente prevedibile; nel secondo, il risultato per il singolo paziente è molto più incerto.

Questo capitolo introduce i due indicatori fondamentali che permettono di distinguere queste situazioni: il **valore atteso**, che individua il centro della distribuzione, e la **varianza**, che ne quantifica la dispersione. Nel quadro bayesiano, quando la distribuzione riguarda una quantità ignota, il valore atteso può essere usato come sintesi puntuale e la varianza descrive quanta incertezza resta, sempre condizionatamente al modello e alle informazioni disponibili.

8.1 Perché valore atteso e varianza sono importanti in psicologia?

Le medie sono pervasive nella ricerca psicologica, ma una media non descrive da sola l'intera distribuzione. Due trattamenti, due test o due gruppi possono avere lo stesso valore medio e differire radicalmente per stabilità, eterogeneità o rischio di esiti estremi. Per interpretare correttamente un risultato è quindi necessario considerare insieme centro e dispersione.

Questa distinzione è importante anche nell'inferenza. Il valore atteso di una distribuzione predittiva riassume un esito futuro plausibile; il valore atteso di una distribuzione a posteriori riassume l'incertezza su un parametro. La varianza può invece rappresentare variabilità tra osservazioni oppure incertezza epistemica su una quantità ignota: il significato dipende sempre dall'oggetto descritto dalla distribuzione.

Prerequisiti

Per seguire il capitolo è necessario avere letto Capitolo 6 e Capitolo 7. Per la notazione, consulta Appendice A.

Per un richiamo su sommatorie, integrali e derivate, consulta le appendici matematiche disponibili nel Companion.

Panoramica del capitolo

Il capitolo procede in sei passaggi:

1. definisce il valore atteso come media ponderata dei valori possibili;
2. presenta linearità e additività del valore atteso;
3. introduce la varianza come media degli scarti quadratici;
4. distingue le proprietà algebriche del valore atteso da quelle della varianza;
5. collega deviazione standard e standardizzazione all'interpretazione dei punteggi;
6. presenta il teorema di Chebyshev e il concetto di momento.

Preparazione del notebook

```
here::here("code", "_common.R") |>  
  source()  
apply_visual_theme()
```

8.2 Il valore atteso come centro di gravità

Il **valore atteso** di una variabile casuale rappresenta il suo *baricentro probabilistico*, ovvero il punto attorno al quale la probabilità si bilancia. In una prospettiva bayesiana, il valore atteso formalizza la nostra **aspettativa razionale**, ovvero la migliore

previsione puntuale che possiamo fare alla luce dello stato informativo corrente.

Definizione 8.1 (Valore atteso (speranza matematica)). Il *valore atteso* (o *media* o *speranza matematica*) di una variabile casuale X è definito come segue.

Per variabili **discrete** con funzione di massa di probabilità p_X :

$$\mathbb{E}[X] = \sum_{x \in \mathcal{X}} x \cdot p_X(x).$$

Per variabili **continue** con funzione di densità di probabilità f_X :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx.$$

In entrambi i casi, il valore atteso è una **media ponderata** dei valori possibili, in cui i pesi sono dati dalle probabilità o dalla densità. La definizione richiede che la somma o l'integrale coinvolti siano ben definiti.

È importante sottolineare che il valore atteso **non deve necessariamente coincidere con un valore osservabile**. Questo punto è particolarmente rilevante in psicologia, dove molte scale forniscono solo valori interi.

i Esempio: risposta a un item dicotomico

Consideriamo un singolo item di un test cognitivo. Definiamo $X = 1$ se la risposta è corretta, $X = 0$ se è errata.

Se la probabilità di risposta corretta è $p = 0.7$:

$$\mathbb{E}[X] = 0 \cdot 0.3 + 1 \cdot 0.7 = 0.7.$$

Il valore 0.7 non è un esito possibile. Tuttavia, rappresenta correttamente il **centro di gravità** della distribuzione: se somministrassimo questo item a molti soggetti, la proporzione di risposte corrette tenderebbe a 0.7.

Se l'errore viene misurato mediante perdita quadratica, 0.7 è inoltre la previsione puntuale che minimizza l'errore quadratico medio atteso. Con funzioni di perdita diverse, la sintesi ottimale può essere diversa.

8.3 Il valore atteso come limite di frequenze

Un'interpretazione operativa del valore atteso è fornita dalla **legge dei grandi numeri**. Se ripetiamo un esperimento molte volte e calcoliamo la media aritmetica dei risultati, questa media tende al valore atteso teorico.

Formalmente, se $X_1, X_2, \dots, X_n$ sono variabili indipendenti e identicamente distribuite con valore atteso finito:

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n} \xrightarrow{n \rightarrow \infty} \mathbb{E}[X].$$

Questa convergenza **non definisce** il valore atteso, che resta una media ponderata secondo la definizione formale. Mostra invece come, sotto le condizioni della legge

dei grandi numeri, la media osservata in molte prove si stabilizzi attorno al valore atteso.

i Esempio: punteggio totale su due sottoscale

Consideriamo un questionario composto da due sottoscale, ciascuna con punteggi da 1 a 6. La distribuzione di ciascuna sottoscala è:

Punteggio	1	2	3	4	5	6
Probabilità	0.05	0.10	0.15	0.25	0.30	0.15

Il valore atteso di ciascuna sottoscala è:

$$\mathbb{E}[S] = 1(0.05) + 2(0.10) + 3(0.15) + 4(0.25) + 5(0.30) + 6(0.15) = 4.10.$$

Per la somma delle due sottoscale:

$$\mathbb{E}[X] = \mathbb{E}[S_1] + \mathbb{E}[S_2] = 4.10 + 4.10 = 8.20.$$

```
set.seed(123)
valori_subscala <- 1:6
prob_subscala <- c(0.05, 0.10, 0.15, 0.25, 0.30, 0.15)
E_subscala <- sum(valori_subscala * prob_subscala)

n_sim <- 100000
subscala1 <- sample(valori_subscala, n_sim, replace = TRUE, prob =
  ↪ prob_subscala)
subscala2 <- sample(valori_subscala, n_sim, replace = TRUE, prob =
  ↪ prob_subscala)
punteggio_totale <- subscala1 + subscala2

cat("Valore atteso teorico:", 2 * E_subscala, "\n")
#> Valore atteso teorico: 8.2
cat("Media empirica:", round(mean(punteggio_totale), 3), "\n")
#> Media empirica: 8.2
```

La vicinanza tra media empirica e valore teorico illustra la legge dei grandi numeri. Nella simulazione le sottoscale sono generate indipendentemente, ma l'additività del valore atteso non richiede questa assunzione.

8.3.1 Ponte applicativo: il punteggio atteso di una scala

Il risultato appena visto ha un'implicazione pratica immediata: **il punteggio atteso di una scala psicometrica**, quando il punteggio totale è definito come somma degli item, equivale alla somma dei valori attesi dei singoli item. Ad esempio, se una scala è composta da 20 item, ciascuno con valore atteso 3.5 (su scala 1-5), il punteggio totale atteso sarà $20 \times 3.5 = 70$.

Questa proprietà, che formalizzeremo come *linearità del valore atteso*, semplifica notevolmente i calcoli e permette di ragionare sulle proprietà aggregate di scale composite.

8.4 La linearità del valore atteso

Il valore atteso possiede un'importante proprietà algebrica: la **linearità**. Per qualunque coppia di variabili casuali X e Y e per qualunque costante a :

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y], \quad \mathbb{E}[aX] = a \mathbb{E}[X].$$

Questa proprietà **non richiede alcuna assunzione di indipendenza**: vale sempre, anche quando le variabili sono correlate.

Teorema 8.1 (Linearità). *Per qualsiasi variabile casuale X e per qualunque costanti $a, b \in \mathbb{R}$:*

$$\mathbb{E}[aX + b] = a \mathbb{E}[X] + b.$$

Teorema 8.2 (Additività). *Per qualsiasi coppia di variabili casuali X e Y :*

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

*Questa proprietà è valida **sempre**, sia che X e Y siano indipendenti o dipendenti.*

i Esempio: Punteggio composto di ansia e depressione

Consideriamo una valutazione psicometrica che combina due scale:

- punteggio di ansia A (scala 0–21, es. GAD-7) con $\mathbb{E}[A] = 12$;
- punteggio di depressione D (scala 0–27, es. PHQ-9) con $\mathbb{E}[D] = 14$.

Un indice composto di *distress psicologico* può essere definito come $\text{Distress} = A + D$. Per linearità:

$$\mathbb{E}[\text{Distress}] = \mathbb{E}[A] + \mathbb{E}[D] = 12 + 14 = 26.$$

Il calcolo rimane valido **anche se ansia e depressione sono correlate**, come tipicamente accade in caso di comorbidità.

Se volessimo un indice ponderato $\text{Distress}_w = 0.4A + 0.6D$:

$$\mathbb{E}[\text{Distress}_w] = 0.4 \cdot 12 + 0.6 \cdot 14 = 13.2.$$

Verifica illustrativa con due variabili continue correlate
`set.seed(42)`

```
n <- 10000
rho <- 0.6
z1 <- rnorm(n)
z2 <- rho * z1 + sqrt(1 - rho^2) * rnorm(n)
A <- 12 + 5 * z1
D <- 14 + 6 * z2
```

```
cat("E[Distress] empirica:", round(mean(A + D), 2), "\n")
#> E[Distress] empirica: 25.9
cat("E[Distress_w] empirica:", round(mean(0.4 * A + 0.6 * D), 2), "\n")
#> E[Distress_w] empirica: 13.2
```

Nonostante la correlazione, le medie empiriche risultano vicine ai valori attesi analitici. La simulazione illustra la proprietà matematica; non costituisce un modello realistico dei punteggi clinici, che sono discreti e limitati.

8.4.1 Prodotto di variabili casuali

Teorema 8.3 (Prodotto di variabili indipendenti). *Se X e Y sono variabili casuali indipendenti:*

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

A differenza dell'additività, questa proprietà non vale per qualunque coppia di variabili. L'indipendenza è una condizione **sufficiente**, ma non necessaria: l'uguaglianza può verificarsi anche per alcune variabili dipendenti. Questa distinzione sarà chiarita introducendo covarianza e correlazione.

8.4.2 Valore atteso della media campionaria

Se $X_1, \dots, X_n$ sono i.i.d. con $\mathbb{E}[X_i] = \mu$, la media campionaria

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

ha valore atteso:

$$\mathbb{E}[\bar{X}] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \cdot n \cdot \mu = \mu.$$

Questo risultato mostra che la media campionaria è uno stimatore non distorto del valore atteso della popolazione.

8.4.3 Ponte applicativo: non distorsione e precisione della media campionaria

Quando calcoliamo la media dei punteggi in un campione, utilizziamo la **media campionaria** come stimatore del valore atteso della popolazione. La proprietà $\mathbb{E}[\bar{X}] = \mu$ indica che lo stimatore è **non distorto**: considerando ipotetiche ripetizioni del campionamento, la media delle stime coincide con μ .

La non distorsione non basta, da sola, a garantire la **coerenza**. Nel caso i.i.d. con varianza finita, la coerenza deriva dalla legge dei grandi numeri e dal fatto

che la varianza della media diminuisce all'aumentare di n . Per quantificare questa variabilità introduciamo ora la varianza.

8.5 La varianza come misura di dispersione e incertezza

Il valore atteso identifica il centro di una distribuzione, ma da solo non fornisce informazioni su quanto i valori reali tendano a discostarsene.

Il significato della varianza dipende dall'oggetto descritto dalla distribuzione. In una distribuzione dei dati misura la variabilità tra osservazioni; in una distribuzione bayesiana su un parametro quantifica l'**incertezza residua** su quella quantità, condizionatamente al modello e alle informazioni disponibili.

8.5.1 Perché non usare la media degli scarti?

Consideriamo gli scarti dalla media $X - \mathbb{E}[X]$. Per la definizione di valore atteso:

$$\mathbb{E}[X - \mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[X] = 0.$$

La media degli scarti è sempre zero: gli scarti positivi e negativi si compensano. Per ottenere una misura che sia sempre non negativa, si utilizza il **quadrato degli scarti**.

Definizione 8.2 (Varianza). La *varianza* di una variabile casuale X è definita come il **valore atteso del quadrato degli scarti dalla media**:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

Denotando $\mu = \mathbb{E}[X]$:

- **Caso discreto:** $\text{Var}(X) = \sum_i (x_i - \mu)^2 p_X(x_i)$.
- **Caso continuo:** $\text{Var}(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f_X(x) dx$.

La varianza è **non negativa** e vale $\text{Var}(X) = 0$ se e solo se X assume un unico valore con probabilità 1.

8.5.2 Interpretazione epistemica

La varianza può essere interpretata come l'**errore quadratico atteso** quando si utilizza il valore atteso μ come previsione e si misura l'errore con una *funzione di perdita quadratica*:

$$\mathbb{E}[(X - \mu)^2] = \text{Var}(X).$$

La varianza quantifica quindi la media degli scarti **quadratici** tra la previsione e il valore assunto da X . Inoltre, il valore atteso è il numero che minimizza tale errore quadratico atteso.

i Esempio: confronto tra due trattamenti

Due trattamenti producono lo stesso miglioramento medio di 8 punti al BDI-II, ma con distribuzioni diverse:

Trattamento A (esiti prevedibili): | Miglioramento | 6 | 7 | 8 | 9 | 10 |
|:————:|:~:|:~:|:~:|:~:|:~:| | Probabilità | 0.10 | 0.25 | 0.30 | 0.25 | 0.10 |

Trattamento B (esiti variabili): | Miglioramento | 0 | 4 | 8 | 12 | 16 |
|:————:|:~:|:~:|:~:|:~:|:~:| | Probabilità | 0.10 | 0.25 | 0.30 | 0.25 | 0.10 |

```
valori_A <- c(6, 7, 8, 9, 10)
prob_A <- c(0.10, 0.25, 0.30, 0.25, 0.10)
E_A <- sum(valori_A * prob_A)
Var_A <- sum((valori_A - E_A)^2 * prob_A)

valori_B <- c(0, 4, 8, 12, 16)
prob_B <- c(0.10, 0.25, 0.30, 0.25, 0.10)
E_B <- sum(valori_B * prob_B)
Var_B <- sum((valori_B - E_B)^2 * prob_B)

cat("Trattamento A: E[X] =", E_A, ", Var(X) =", Var_A, "\n")
#> Trattamento A: E[X] = 8 , Var(X) = 1.3
cat("Trattamento B: E[X] =", E_B, ", Var(X) =", Var_B, "\n")
#> Trattamento B: E[X] = 8 , Var(X) = 20.8
```

Entrambi hanno lo stesso valore atteso, ma la varianza del Trattamento B è 16 volte maggiore. Con il Trattamento A possiamo prevedere con ragionevole confidenza il risultato; con il Trattamento B, l'esito è molto più incerto.

8.6 Formula alternativa della varianza

Spesso, dal punto di vista computazionale, è più conveniente utilizzare una forma equivalente.

Teorema 8.4 (Formula alternativa).

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Dimostrazione. Sia $\mu = \mathbb{E}[X]$:

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[(X - \mu)^2] \\ &= \mathbb{E}[X^2 - 2\mu X + \mu^2] \\ &= \mathbb{E}[X^2] - 2\mu^2 + \mu^2 \\ &= \mathbb{E}[X^2] - \mu^2. \end{aligned}$$

□

Questa formulazione mostra che la varianza dipende da due **momenti** della

distribuzione: $\mathbb{E}[X]$ e $\mathbb{E}[X^2]$.

8.7 Proprietà algebriche della varianza

La varianza presenta proprietà algebriche simili a quelle del valore atteso, ma con differenze cruciali.

8.7.1 Trasformazioni lineari

Per qualsiasi variabile casuale X e per costanti a e b :

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

Una traslazione (l'addizione di una costante b) **non modifica** la varianza: spostare tutti i valori non cambia la loro dispersione. La moltiplicazione per una costante a , invece, amplifica o riduce la varianza proporzionalmente a a^2 .

8.7.2 Ponte applicativo: conversione tra scale

Se Z è un punteggio standardizzato, il corrispondente T-score è $T = 50 + 10Z$. Pertanto:

$$\text{Var}(T) = 10^2 \cdot \text{Var}(Z) = 100.$$

Più in generale, per trasformare un punteggio grezzo X con media μ e deviazione standard σ si usa

$$T = 50 + 10 \frac{X - \mu}{\sigma}.$$

Il termine additivo 50 non modifica la dispersione; il coefficiente moltiplicativo 10 porta la deviazione standard a 10.

8.7.3 Varianza di una somma

In generale:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

Se X e Y sono indipendenti, la loro covarianza è zero e quindi

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

L'indipendenza è dunque una condizione **sufficiente**, ma non necessaria: la stessa additività vale per variabili non correlate, cioè con covarianza nulla. In presenza di covarianza positiva o negativa, la varianza della somma può essere rispettivamente maggiore o minore della somma delle varianze.

i Esempio: perché l'indipendenza conta

Riprendiamo l'esempio di ansia (A) e depressione (D) con $\text{Var}(A) = 25$ e $\text{Var}(D) = 36$.

Se fossero indipendenti: $\text{Var}(A + D) = 25 + 36 = 61$.

Con correlazione positiva ($\rho = 0.6$):

$$\text{Var}(A + D) = \text{Var}(A) + \text{Var}(D) + 2\text{Cov}(A, D).$$

$$\text{Cov}(A, D) = \rho \cdot \sigma_A \cdot \sigma_D = 0.6 \cdot 5 \cdot 6 = 18, \text{ quindi:}$$

$$\text{Var}(A + D) = 25 + 36 + 2(18) = 97.$$

La correlazione positiva **aumenta** la varianza della somma: quando una variabile è alta, l'altra tende a esserlo, amplificando la dispersione complessiva.

8.7.4 Varianza della media campionaria

Siano $X_1, X_2, \dots, X_n$ i.i.d. con $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2$. La media campionaria $\bar{X}$ ha varianza:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

8.7.5 Ponte applicativo: perché campioni più grandi danno stime più precise

La varianza della media campionaria decresce con l'inverso della numerosità campionaria:

- con $n = 25$ pazienti, $\text{Var}(\bar{X}) = \sigma^2/25$;
- con $n = 100$ pazienti, $\text{Var}(\bar{X}) = \sigma^2/100$.

Quadruplicando il campione, la varianza si riduce a un quarto. In termini di deviazione standard:

$$\text{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Per dimezzare l'errore standard è necessario *quadruplicare* il campione.

```
set.seed(123)
sigma2 <- 100
n_values <- c(5, 10, 25, 50, 100, 200)
n_rep <- 1000

risultati <- data.frame(
  n = integer(),
  var_media = numeric(),
  var_teorica = numeric()
)
```

```

for (n in n_values) {
  medie <- replicate(n_rep, mean(rnorm(n, mean = 50, sd = sqrt(sigma2))))
  risultati <- rbind(risultati, data.frame(
    n = n,
    var_medie = var(medie),
    var_teorica = sigma2 / n
  ))
}

ggplot(risultati, aes(x = n)) +
  geom_point(aes(y = var_medie), size = 3) +
  geom_line(aes(y = var_teorica), linewidth = 1) +
  scale_x_continuous(breaks = n_values) +
  labs(
    x = "Dimensione campionaria (n)",
    y = "Varianza della media campionaria",
    title = expression(Var(bar{X}) == sigma^2 / n)
  )

```




Figura 8.1: La varianza della media campionaria decresce con la dimensione del campione.

La Figura 8.1 mostra che la dispersione delle medie campionarie diminuisce all'aumentare della numerosità e segue il valore teorico σ^2/n .

8.8 Deviazione standard e standardizzazione

La varianza è espressa nel **quadrato** dell'unità di misura originale. Per ottenere una misura di dispersione **nella stessa scala** dei dati, si introduce la *deviazione standard*.

Definizione 8.3 (Deviazione standard). La *deviazione standard* di una variabile casuale X è:

$$\sigma_X = \text{SD}(X) = \sqrt{\text{Var}(X)}.$$

8.8.1 Standardizzazione

Definizione 8.4 (Variabile standardizzata). Data X con $\mathbb{E}[X] = \mu$ e $\text{SD}(X) = \sigma$, la *variabile standardizzata* è:

$$Z = \frac{X - \mu}{\sigma}.$$

Se X ha media finita e deviazione standard positiva e finita, la variabile standardizzata Z ha $\mathbb{E}[Z] = 0$ e $\text{Var}(Z) = 1$, indipendentemente dalla forma della distribuzione originaria.

i Esempio: confronto tra scale psicometriche diverse

Paziente A: BDI-II = 28 ($\mu = 14$, $\sigma = 10$). **Paziente B:** PHQ-9 = 18 ($\mu = 10$, $\sigma = 6$).

```
z_A <- (28 - 14) / 10
z_B <- (18 - 10) / 6
```

```
cat("Paziente A (BDI-II = 28): z =", z_A, "\n")
#> Paziente A (BDI-II = 28): z = 1.4
cat("Paziente B (PHQ-9 = 18): z =", round(z_B, 2), "\n\n")
#> Paziente B (PHQ-9 = 18): z = 1.33
```

```
cat("Interpretazione: il punteggio del Paziente A è leggermente più
  ↳ lontano\n")
#> Interpretazione: il punteggio del Paziente A è leggermente più
  ↳ lontano
cat("dalla media della propria distribuzione di riferimento.\n")
#> dalla media della propria distribuzione di riferimento.
```

Conversione in T-score (media 50, SD 10):

```
T_A <- 50 + 10 * z_A
T_B <- 50 + 10 * z_B

cat("T-score Paziente A:", T_A, "\n")
#> T-score Paziente A: 64
cat("T-score Paziente B:", round(T_B, 1), "\n")
#> T-score Paziente B: 63.3
```

I T-score collocano i due punteggi su una metrica comune. Il confronto conserva però significato solo se le distribuzioni di riferimento sono appropriate e se i costrutti misurati sono comparabili; una maggiore distanza standardizzata non equivale automaticamente a una maggiore gravità clinica.

8.8.2 Ponte applicativo: la standardizzazione nella pratica clinica

La trasformazione in punti z è uno strumento essenziale in psicometria per:

1. **Confrontare punteggi provenienti da scale diverse**, neutralizzando le differenze di media e dispersione.
2. **Interpretare la posizione di un individuo** all'interno della distribuzione di riferimento.
3. **Descrivere la distanza dalla media**: soglie come $|z| > 2$ possono essere usate come riferimenti descrittivi, ma la loro rarità effettiva dipende dalla forma della distribuzione e non costituisce, da sola, un criterio clinico.
4. **Costruire indicatori compositi** integrando misure con unità di misura differenti.

8.9 Il teorema di Chebyshev e i momenti

i Approfondimento: il teorema di Chebyshev

Una domanda che sorge naturalmente: **quanta probabilità si concentra entro un certo numero di deviazioni standard dalla media?** Il *teorema di Chebyshev* fornisce una risposta universale, applicabile a **qualsiasi distribuzione** con media e varianza finite.

Teorema 8.5. Teorema di Chebyshev

Sia X una variabile casuale con media μ e deviazione standard σ . Per ogni $k > 0$:

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Equivalentemente:

$$P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}.$$

k	$P(X - \mu < k\sigma) \geq$
2	75%
3	88.9% (~89%)
4	93.75% (~94%)

Questi limiti sono **molto conservativi**. Per una distribuzione normale, le probabilità effettive sono 68.3%, 95.4% e 99.7% per $k = 1, 2, 3$.

Applicazione clinica

Immaginiamo che un test cognitivo abbia media 100 e deviazione standard 15, ma che nulla sia noto sulla forma della sua distribuzione. Grazie a Chebyshev possiamo affermare che **almeno il 75%** dei punteggi si trova nell'intervallo $[70, 130]$, indipendentemente dalla distribuzione.

i Approfondimento: i momenti di una distribuzione

Momenti di una distribuzione

Il valore atteso e la varianza possono essere visti come i primi due **momenti** di una distribuzione.

Definizione 8.5. Momenti

Il *momento di ordine r* di una variabile casuale X è:

$$\mathbb{E}[X^r] = \begin{cases} \sum_i x_i^r \cdot p_X(x_i) & \text{(discreto)} \\ \int_{-\infty}^{+\infty} x^r \cdot f_X(x) dx & \text{(continuo)} \end{cases}$$

Il *momento centrale di ordine r* è $\mathbb{E}[(X - \mu)^r]$, dove $\mu = \mathbb{E}[X]$.

- Il **momento di ordine 1** è il valore atteso (centro).
- Il **momento centrale di ordine 2** è la varianza (dispersione).
- Il **momento centrale di ordine 3** (normalizzato) è la **skewness** (asimmetria).
- Il **momento centrale di ordine 4** (normalizzato) è collegato alla **kurtosis**, che descrive la propensione della distribuzione a produrre valori lontani dal centro rispetto a un riferimento.

Questi concetti diventano rilevanti nella validazione di scale psicometriche e nella scelta di modelli statistici appropriati.

Riflessioni conclusive

Il **valore atteso** e la **varianza** sono due strumenti fondamentali per sintetizzare una distribuzione di probabilità. Il primo identifica il centro della distribuzione; il secondo ne misura la dispersione. Quando la distribuzione rappresenta l'incertezza su una quantità ignota, tale dispersione descrive anche l'**incertezza residua**.

Per gli psicologi clinici, questi concetti sono strumenti operativi quotidiani. Quando comunichiamo che "il miglioramento atteso è di circa 8 punti", ci riferiamo al valore atteso. Se aggiungiamo che gli esiti sono fortemente concentrati attorno a 8 oppure molto dispersi, forniamo informazioni sulla variabilità; un singolo intervallo, da solo, non è sufficiente a determinare la varianza senza ulteriori informazioni sulla distribuzione. Entrambi sono essenziali per una comunicazione clinica completa.

La **linearità del valore atteso** permette di calcolare le medie di somme e combina-

zioni lineari — ecco perché il punteggio atteso di una scala è la somma dei punteggi attesi dei suoi item. Il comportamento della **varianza** mette in luce il ruolo della covarianza: la varianza di una somma coincide con la somma delle varianze quando la covarianza è nulla. L'indipendenza garantisce questa condizione, ma non è l'unico modo in cui può verificarsi.

Il risultato $\text{Var}(\bar{X}) = \sigma^2/n$ fornisce il **fondamento matematico della precisione statistica**: maggiore è il numero di osservazioni, minore è l'incertezza. Questo principio guida la progettazione degli studi clinici.

Nel quadro bayesiano, questi concetti assumono una valenza pienamente **inferenziale**. Sotto perdita quadratica, il valore atteso della distribuzione *a posteriori* fornisce una stima puntuale ottimale, mentre la varianza *a posteriori* misura l'incertezza residua condizionatamente al modello, alla prior e ai dati osservati.

Esercizi

1. Una variabile casuale assume i valori 0 e 1 con probabilità rispettivamente 0.30 e 0.70. Qual è il suo valore atteso? Perché il risultato non deve essere un esito osservabile?
2. Due trattamenti hanno entrambi un miglioramento atteso di 8 punti. Il primo ha varianza 1.3, il secondo varianza 20.8. Che cosa rimane uguale e che cosa cambia nell'interpretazione dei due trattamenti?
3. Due sottoscale sono fortemente correlate. È ancora corretto sommare i loro valori attesi per ottenere il valore atteso del punteggio totale? Spiega perché.
4. Per quali ragioni da $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ non segue automaticamente che $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$?
5. Una variabile X ha media 10 e varianza 4. Si definisce $Y = 2X + 5$. Quali sono media e varianza di Y ? Quale effetto hanno la moltiplicazione per 2 e l'addizione di 5?
6. Due variabili non sono indipendenti, ma hanno covarianza zero. La varianza della loro somma è uguale alla somma delle varianze? Che cosa mostra questo esempio sul ruolo dell'indipendenza?
7. La varianza di una popolazione è 100. Confronta la varianza e l'errore standard della media per campioni di numerosità 25 e 100. Qual è il significato del cambiamento?
8. Una distribuzione *a posteriori* per un effetto ha media 0.40 e deviazione standard 0.10. Che cosa sintetizzano questi due numeri? Perché la media *a posteriori* non è sempre la scelta ottimale con qualunque funzione di perdita?

Soluzioni

1. $\mathbb{E}[X] = 0(0.30) + 1(0.70) = 0.70$. Il valore atteso è una media ponderata e non deve coincidere con uno dei valori possibili della variabile.

2. Rimane uguale il centro della distribuzione: entrambi i trattamenti hanno miglioramento atteso pari a 8. Cambia la dispersione: il secondo trattamento produce esiti molto meno prevedibili.
3. Sì. La linearità del valore atteso vale anche quando le variabili sono dipendenti. La correlazione diventa invece rilevante per la varianza del totale.
4. Il valore atteso è sempre additivo. La varianza della somma contiene anche il termine $2\text{Cov}(X, Y)$, che può essere positivo, negativo o nullo.
5. $\mathbb{E}[Y] = 2(10) + 5 = 25$ e $\text{Var}(Y) = 2^2(4) = 16$. L'addizione sposta il centro senza modificare la dispersione; la moltiplicazione raddoppia la deviazione standard e quadruplica la varianza.
6. Sì. Se la covarianza è zero, il termine aggiuntivo nella varianza della somma scompare. L'indipendenza è sufficiente per ottenere covarianza zero, ma non è necessaria.
7. Per $n = 25$, $\text{Var}(\bar{X}) = 100/25 = 4$ e $\text{SE}(\bar{X}) = 2$. Per $n = 100$, la varianza è 1 e l'errore standard è 1. Quadruplicando il campione, la varianza si riduce a un quarto e l'errore standard si dimezza.
8. La media 0.40 sintetizza il centro della distribuzione a posteriori; la deviazione standard 0.10 ne descrive la dispersione. La media minimizza la perdita quadratica attesa, ma altre funzioni di perdita possono rendere preferibile, per esempio, la mediana o un'altra decisione.

i Punti chiave

- Il valore atteso è una media ponderata dei valori possibili:

$$\mathbb{E}[X] = \sum_x x p_X(x) \quad \text{o} \quad \mathbb{E}[X] = \int x f_X(x) dx.$$

- Il valore atteso non deve coincidere con un valore osservabile. Sotto perdita quadratica è la previsione puntuale che minimizza l'errore atteso.
- La linearità vale senza richiedere indipendenza:

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b, \quad \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

- La varianza è la media degli scarti quadratici dalla media:

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

- Per una trasformazione lineare,

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

- In generale,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

L'indipendenza è sufficiente, ma non necessaria, per eliminare il termine di covarianza.

- Per osservazioni i.i.d. con varianza σ^2 ,

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \text{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

- La deviazione standard è espressa nelle unità originali; una variabile standardizzata ha media 0 e varianza 1.
- Il teorema di Chebyshev fornisce limiti validi per ogni distribuzione con media e varianza finite, ma tali limiti possono essere conservativi.
- Nel Capitolo 9 introdurremo covarianza e correlazione per descrivere la dipendenza tra variabili.

Covarianza e correlazione

i In sintesi

Da sapere Comprendere covarianza e correlazione come sintesi della dipendenza lineare; distinguere associazione lineare, dipendenza e indipendenza; interpretare il ruolo della matrice di covarianza nelle distribuzioni congiunte e nei modelli bayesiani.

Da saper fare Determinare il segno di una covarianza; interpretare intensità e direzione di una correlazione senza attribuirle significati causali; riconoscere relazioni non lineari che una correlazione prossima a zero può nascondere.

Introduzione

Un ricercatore analizza la relazione tra ansia e prestazione cognitiva in un gruppo di studenti universitari. I dati suggeriscono che, in media, livelli più elevati di ansia si associano a punteggi più bassi in un compito di memoria di lavoro. Questa osservazione solleva almeno tre domande: in quale direzione varia l'associazione? Quanto è intensa? Un singolo numero è sufficiente a descriverla?

La **covarianza** quantifica la tendenza lineare di due variabili a variare insieme. La **correlazione** standardizza la covarianza rispetto alla dispersione delle due variabili e produce un indice compreso tra -1 e 1. Entrambe sono sintesi della distribuzione congiunta: risultano utili per comunicare la direzione e l'intensità della componente lineare, ma non descrivono ogni forma possibile di dipendenza.

Nel quadro bayesiano, una distribuzione congiunta può rappresentare l'incertezza su più parametri o quantità future. La sua struttura di covarianza indica allora come le incertezze sulle diverse quantità siano collegate, sempre condizionatamente al modello e alle informazioni disponibili.

9.1 Perché covarianza e correlazione sono importanti in psicologia?

Molte domande psicologiche riguardano relazioni tra variabili: ansia e prestazione, sostegno sociale e benessere, punteggi di due sottoscale, parametri di uno stesso modello. Covarianza e correlazione permettono di riassumere la componente lineare di queste relazioni e di confrontare associazioni misurate su scale differenti.

L'interpretazione richiede però cautela. Una correlazione non dimostra una relazione causale, può essere alterata da variabili non considerate e può risultare prossima a zero anche quando esiste una forte dipendenza non lineare. Per questo gli indici numerici devono essere letti insieme alla distribuzione congiunta, alla visualizzazione dei dati e al contesto teorico.

Prerequisiti

Per seguire il capitolo è necessario avere letto Capitolo 6, Capitolo 7 e Capitolo 8. Per la notazione, consulta Appendice A. Per un richiamo su somme doppie, integrali e matrici, consulta le appendici matematiche disponibili nel Companion.

Panoramica del capitolo

Il capitolo procede in sei passaggi:

1. estende le distribuzioni congiunte dal caso discreto al caso continuo;
2. definisce la covarianza come media del prodotto degli scarti dalle rispettive medie;
3. introduce la correlazione come covarianza standardizzata;
4. presenta le principali proprietà algebriche della covarianza;
5. distingue incorrelazione e indipendenza mediante un esempio non lineare;
6. mostra il ruolo della covarianza nelle distribuzioni a priori e a posteriori.

Preparazione del notebook

```
here::here("code", "_common.R") |>  
  source()  
  apply_visual_theme()
```

9.2 Dalle tabelle discrete alle densità continue

Nel capitolo sugli assiomi (Capitolo 2) abbiamo utilizzato tabelle congiunte per rappresentare le nostre credenze su coppie di variabili binarie. Gli stessi principi si estendono a situazioni più complesse: tabelle con più categorie e densità congiunte per variabili continue.

9.2.1 Tabelle con più categorie

Consideriamo, a scopo didattico, la relazione tra ansia e prestazione cognitiva, per la quale sono state proposte associazioni negative in alcuni contesti (Eysenck et al., 2007). Supponiamo di classificare l'ansia in tre livelli (bassa, media, alta) e la prestazione in tre livelli (insufficiente, sufficiente, buona).

La seguente tabella è una distribuzione congiunta ipotetica, costruita per illustrare i calcoli. I numeri non sono stime empiriche:

	Ansia Bassa	Ansia Media	Ansia Alta	Marginale
Insufficiente	0.05	0.10	0.15	0.30
Sufficiente	0.15	0.20	0.10	0.45
Buona	0.10	0.10	0.05	0.25
Marginale	0.30	0.40	0.30	1.00

Ogni cella assegna probabilità a una specifica configurazione. Le marginali si ottengono sommando per righe o colonne; le distribuzioni condizionate si ottengono dividendo le probabilità congiunte per la marginale appropriata. Le categorie sono ordinate, ma una codifica numerica successiva costituisce una scelta modellistica e non trasforma automaticamente le distanze tra categorie in intervalli equivalenti.

9.2.2 Il caso continuo: densità congiunte

Quando le variabili assumono valori continui, la distribuzione congiunta viene descritta mediante una **densità congiunta** $f(x, y)$.

Definizione 9.1. Una *densità congiunta* $f(x, y)$ assegna a ogni configurazione (x, y) un valore che rappresenta la concentrazione della credenza in quella regione. Per essere coerente, deve soddisfare:

1. **Non negatività:** $f(x, y) \geq 0$ per ogni (x, y) ;
2. **Normalizzazione:** $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$.

Il valore $f(x, y)$ è una densità, non la probabilità del singolo punto (x, y) . La probabilità di una regione si ottiene integrando la densità su quella regione.

Le densità marginali si ottengono integrando rispetto a una delle variabili:

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx.$$

Le densità condizionate si ottengono dividendo la densità congiunta per la marginale appropriata:

$$f_{X|Y}(x | y) = \frac{f(x, y)}{f_Y(y)}.$$

9.2.3 Regole di somma e prodotto per le densità congiunte

Le regole si applicano senza modifiche concettuali, sostituendo le somme con gli integrali.

- **Regola di somma (marginalizzazione):** $f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y) dx$.
- **Regola di prodotto:** $f_{X,Y}(x,y) = f_{Y|X}(y|x)f_X(x) = f_{X|Y}(x|y)f_Y(y)$.

Queste relazioni mostrano che la distribuzione congiunta determina le marginali e, dove i denominatori sono positivi, le distribuzioni condizionate. Marginali e condizionate compatibili possono a loro volta ricostruire la distribuzione congiunta.

9.2.4 Visualizzazione di una distribuzione congiunta continua

Modelliamo la relazione ansia-prestazione come una distribuzione continua.




Figura 9.1: Distribuzione congiunta simulata di ansia e prestazione. L'orientamento delle curve di livello rappresenta una correlazione negativa.

La Figura 9.1 mostra una distribuzione simulata, non dati osservati. La densità è maggiore vicino al centro della distribuzione; l'orientamento ellittico inclinato verso il basso rappresenta la componente lineare negativa tra ansia e prestazione.

! Dalla distribuzione congiunta ai riassunti numerici

La distribuzione congiunta contiene tutta l'informazione sulle relazioni tra le variabili. Tuttavia, comunicare un'intera distribuzione può risultare complesso. La covarianza e la correlazione sono riassunti numerici che:

- catturano l'aspetto *lineare* della relazione;
- condensano l'informazione in un singolo numero;
- comportano una perdita di informazione: dipendenze non lineari possono esistere anche in presenza di correlazione nulla.

Questi indici sono strumenti utili ma parziali: la distribuzione congiunta resta la fonte primaria dell'informazione.

9.3 Covarianza: misura della co-variazione lineare

9.3.1 La domanda fondamentale

Quando diciamo che due variabili “co-variano”, intendiamo che tendono a muoversi insieme in modo sistematico:

- Quando l'ansia è sopra la sua media, la prestazione tende a essere sotto la sua media?
- Quando il supporto sociale è elevato, il benessere tende a essere elevato?

La covarianza formalizza questa intuizione.

Definizione 9.2 (Covarianza). La *covarianza* tra due variabili casuali X e Y è:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Per variabili discrete con distribuzione congiunta $p(x, y)$:

$$\text{Cov}(X, Y) = \sum_x \sum_y (x - \mu_X)(y - \mu_Y) p(x, y).$$

L'interpretazione emerge dalla struttura del prodotto $(X - \mu_X)(Y - \mu_Y)$:

- quando **entrambe** sono sopra le medie, il prodotto è **positivo**;
- quando **entrambe** sono sotto, il prodotto è **positivo**;
- quando una è sopra e l'altra sotto, il prodotto è **negativo**.

La covarianza è la media di questi prodotti:

- **positiva**: le variabili tendono a muoversi nella stessa direzione;
- **negativa**: tendono a muoversi in direzioni opposte;
- **nulla**: assenza di tendenza *lineare* sistematica.

9.3.2 Formula computazionale

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Questa espressione confronta il valore atteso del prodotto XY con il prodotto dei due valori attesi. Se X e Y sono indipendenti e i momenti necessari esistono, i due termini coincidono. Una differenza non nulla segnala dipendenza lineare; una differenza nulla, invece, non dimostra l'indipendenza, perché possono rimanere dipendenze non lineari.

i Esempio: calcolo dalla tabella congiunta

Applichiamo i concetti alla tabella ansia-prestazione adottando, solo per l'esempio, la codifica numerica prestazione $X \in \{0, 1, 2\}$ e ansia $Y \in \{0, 1, 2\}$. Il risultato dipende da questa codifica e va interpretato come esercizio illustrativo, non come misura empirica su una scala a intervalli dimostrata.

```
tab_joint <- matrix(
  c(0.05, 0.10, 0.15,
    0.15, 0.20, 0.10,
    0.10, 0.10, 0.05),
  nrow = 3, byrow = TRUE,
  dimnames = list(
    Prestazione = c("Insufficiente (0)", "Sufficiente (1)", "Buona
    ↪ (2)"),
    Ansia = c("Bassa (0)", "Media (1)", "Alta (2)")
  )
)

val_prest <- 0:2
val_ansia <- 0:2
marg_prest <- rowSums(tab_joint)
marg_ansia <- colSums(tab_joint)

E_X <- sum(val_prest * marg_prest)
E_Y <- sum(val_ansia * marg_ansia)

E_XY <- 0
for (i in 1:3) {
  for (j in 1:3) {
    E_XY <- E_XY + val_prest[i] * val_ansia[j] * tab_joint[i, j]
  }
}

Cov_XY <- E_XY - E_X * E_Y

cat("Cov(X,Y) =", round(Cov_XY, 3), "\n")
#> Cov(X,Y) = -0.15
```

La covarianza negativa riassume la struttura della tabella scelta: alle categorie più elevate di ansia tendono a corrispondere categorie più basse di prestazione.

9.4 Correlazione: covarianza standardizzata

9.4.1 Il problema delle unità di misura

La covarianza dipende dalle unità di misura. Se misurassimo l'ansia su una scala da 0 a 100 anziché da 0 a 2, la covarianza cambierebbe, anche se la relazione rimanesse invariata.

La **correlazione** risolve questo problema standardizzando la covarianza.

Definizione 9.3 (Coefficiente di correlazione). Il *coefficiente di correlazione* di Pearson tra X e Y , quando entrambe hanno varianza finita e positiva, è:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\mathbb{V}(X) \mathbb{V}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

9.4.2 Proprietà fondamentali

1. **Limitatezza:** $-1 \leq \rho(X, Y) \leq 1$.
2. **Trasformazioni lineari:** se $a > 0$ e $b > 0$, $\rho(aX + c, bY + d) = \rho(X, Y)$. Se una sola delle due scale viene moltiplicata per una costante negativa, il segno della correlazione si inverte.
3. **Valori estremi:**
 - $\rho = +1$: relazione lineare perfetta positiva;
 - $\rho = -1$: relazione lineare perfetta negativa;
 - $\rho = 0$: assenza di relazione *lineare*.

9.4.3 Ponte applicativo: perché usiamo la correlazione

La correlazione si è affermata come linguaggio comune per comunicare l'intensità delle associazioni in psicologia per motivi precisi:

1. **Comparabilità:** $\rho = -0.40$ ha lo stesso significato indipendentemente dalle scale specifiche.
2. **Collegamento con la regressione lineare semplice:** in una regressione lineare con intercetta e un solo predittore, ρ^2 coincide con la proporzione di varianza della variabile risposta descritta dalla relazione lineare con il predittore. Con $\rho = -0.40$, questo valore è 0.16. Non è una percentuale di causalità né una misura generale di tutta la dipendenza.
3. **Sintesi tra studi:** la correlazione può essere trasformata, per esempio mediante la trasformazione di Fisher, e combinata in una meta-analisi che tenga conto della precisione e dell'eterogeneità degli studi.

i Esempio: correlazione ansia-prestazione

```
Var_X <- sum(val_prest^2 * marg_prest) - E_X^2
Var_Y <- sum(val_ansia^2 * marg_ansia) - E_Y^2
rho_XY <- Cov_XY / sqrt(Var_X * Var_Y)

cat("Correlazione  $\rho$  =", round(rho_XY, 3), "\n")
#> Correlazione  $\rho$  = -0.262
cat("Coefficiente di determinazione  $\rho^2$  =", round(rho_XY^2, 3), "\n")
#> Coefficiente di determinazione  $\rho^2$  = 0.068
```

Il valore $\rho \approx -0.26$ indica una relazione lineare negativa nella tabella codificata. Il quadrato, circa 0.07, coincide con la quota di varianza descritta da una regressione lineare semplice nel contesto corrispondente; non rappresenta una quota causale e non riassume eventuali dipendenze non lineari.

9.4.4 Linee guida interpretative

Le soglie proposte da Cohen (1988) sono talvolta usate come riferimenti descrittivi:

$ \rho $	Etichetta convenzionale
circa 0.10	piccola
circa 0.30	media
circa 0.50	grande

Queste etichette non sono regole universali. La rilevanza di una correlazione dipende dalla qualità delle misure, dalla variabilità del campione, dal disegno dello studio, dalle conseguenze pratiche e dalla teoria di riferimento. Anche una correlazione numericamente piccola può essere importante in un processo cumulativo o quando riguarda esiti rilevanti; una correlazione elevata può invece derivare da ridondanza degli strumenti, variabili confondenti o artefatti di misurazione.

⚠ Correlazione e causalità

Una correlazione descrive un'associazione lineare. Non stabilisce quale variabile produca l'altra e non esclude che entrambe dipendano da una terza variabile. L'interpretazione causale richiede un disegno e assunzioni ulteriori.

9.5 Proprietà matematiche della covarianza

Le proprietà della covarianza hanno conseguenze pratiche rilevanti.

Teorema 9.1 (Proprietà della covarianza). *Siano X , Y e Z variabili casuali e a , b , c costanti reali.*

1. **Simmetria:** $Cov(X, Y) = Cov(Y, X)$.
2. **Covarianza con una costante:** $Cov(c, X) = 0$.
3. **Linearità rispetto a moltiplicazione:** $Cov(aX, bY) = ab \cdot Cov(X, Y)$.
4. **Additività:** $Cov(X + Y, Z) = Cov(X, Z) + Cov(Y, Z)$.
5. **Varianza della somma:**

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + 2Cov(X, Y).$$

La proprietà della **varianza di una somma** è cruciale:

- covarianza positiva: fluttuazioni vanno nella stessa direzione, amplificando la variabilità;
- covarianza negativa: fluttuazioni si compensano, riducendo la variabilità;
- covarianza nulla: varianza della somma = somma delle varianze.

9.5.1 Ponte applicativo: affidabilità delle scale composite

Questa proprietà aiuta a comprendere la varianza di un punteggio composto. Quando gli item covariano positivamente, i termini di covarianza aumentano la varianza del punteggio totale. Ciò può favorire l'affidabilità se la covarianza riflette effettivamente il costrutto comune e gli errori non sono correlati; non basta però osservare covarianze positive per concludere che la scala sia affidabile o unidimensionale. Anche formulazioni simili, effetti di metodo o bias condivisi possono produrre covarianza.

9.6 Incorrelazione e indipendenza

9.6.1 Definizione di incorrelazione

Due variabili sono *incorrelate* quando la loro covarianza è nulla: $Cov(X, Y) = 0$.

9.6.2 La distinzione cruciale

! Relazione asimmetrica

- **L'indipendenza implica l'incorrelazione**, purché esistano i momenti necessari: se X e Y sono indipendenti, $Cov(X, Y) = 0$.
- **L'incorrelazione NON implica l'indipendenza**: $Cov(X, Y) = 0$ non esclude dipendenze non lineari.

Questa asimmetria nasce dal fatto che la correlazione cattura esclusivamente la *componente lineare* della relazione.

9.6.3 Un esempio didattico: una relazione a U rovesciata

Una relazione a **U rovesciata**, spesso associata in forma semplificata alla legge di Yerkes-Dodson, illustra il limite della correlazione lineare: la prestazione cresce fino a un livello intermedio di arousal e poi diminuisce. La simulazione seguente serve soltanto a mostrare la forma matematica e non descrive una legge universale della prestazione psicologica.

```
set.seed(42)
n <- 500
arousal <- runif(n, 0, 10)
prestazione <- -0.4 * (arousal - 5)^2 + 10 + rnorm(n, 0, 1)
r_lineare <- cor(arousal, prestazione)

df_yd <- data.frame(arousal = arousal, prestazione = prestazione)

ggplot(df_yd, aes(x = arousal, y = prestazione)) +
  geom_point(alpha = 0.4, size = 1.5) +
  geom_smooth(method = "lm", se = FALSE, color = "red",
             linetype = "dashed", linewidth = 1) +
  geom_smooth(method = "loess", se = FALSE, color = "blue", linewidth =
    1.2) +
  annotate("text", x = 8, y = 12,
         label = paste0("r = ", round(r_lineare, 3)),
         size = 4, color = "red") +
  labs(
    title = "Relazione simulata tra arousal e prestazione",
    subtitle = "Linea blu: andamento locale | Linea rossa: regressione
    lineare",
    x = "Livello di arousal",
    y = "Prestazione"
  )
```




Figura 9.2: Relazione simulata a U rovesciata tra arousal e prestazione. Una forte dipendenza non lineare può accompagnarsi a correlazioni lineari e monotone prossime a zero.

```
cat("Correlazione lineare (Pearson): r =", round(r_lineare, 3), "\n")
#> Correlazione lineare (Pearson): r = 0.007
cat("Correlazione per ranghi (Spearman): ps =", round(cor(arousal,
  ↪ prestazione, method = "spearman"), 3), "\n")
#> Correlazione per ranghi (Spearman): ps = 0.028
```

La Figura 9.2 mostra che una correlazione di Pearson prossima a zero non equivale ad assenza di dipendenza. Anche la correlazione di Spearman può risultare prossima a zero, perché misura associazioni monotone e non qualunque forma non lineare. La forma della nuvola di punti e un modello coerente con la teoria sono quindi indispensabili.

9.7 Covarianza nell'inferenza bayesiana

Nell'inferenza bayesiana, la covarianza diventa parte integrante della rappresentazione delle nostre credenze sui parametri.

9.7.1 Covarianza a priori

Prima di osservare i dati, possiamo specificare una distribuzione a priori che includa una struttura di covarianza, riflettendo assunzioni teoriche sulle relazioni tra i parametri.

```
mu_prior <- c(0, 0)
Sigma_prior <- matrix(c(1, 0.7, 0.7, 1), nrow = 2)

set.seed(123)
samples_prior <- MASS::mvrnorm(1000, mu_prior, Sigma_prior)

ggplot(as.data.frame(samples_prior), aes(x = V1, y = V2)) +
  geom_point(alpha = 0.4) +
  labs(
    title = "Prior multivariata con correlazione 0.7",
    subtitle = "Credenze iniziali sulla relazione tra parametri",
    x = expression(theta[1]),
    y = expression(theta[2])
  )
```

Prior multivariata con correlazione 0.7

Credenze iniziali sulla relazione tra parametri




Figura 9.3: Campioni da una distribuzione a priori bivariata con correlazione positiva tra i due parametri.

La Figura 9.3 visualizza le conseguenze della prior scelta. Specificare una correlazione positiva significa assegnare maggiore plausibilità congiunta alle configurazioni in cui i due parametri si discostano dalle rispettive medie nella stessa direzione. La matrice di covarianza deve inoltre essere matematicamente valida, in particolare simmetrica e semidefinita positiva.

9.7.2 Covarianza a posteriori

Dopo l'osservazione dei dati, la distribuzione a posteriori presenta una propria struttura di covarianza che rappresenta lo stato aggiornato delle credenze.

9.7.3 Ponte applicativo

In un modello di regressione, la covarianza *a posteriori* tra i parametri (ad esempio, intercetta e pendenza) rivela come le incertezze sui singoli parametri sono correlate. Una covarianza negativa (comune quando il predittore non è centrato) indica che una sovrastima dell'intercetta tende ad associarsi a una sottostima della pendenza.

Questa informazione è essenziale per:

- costruire intervalli di credibilità congiunti;
- propagare correttamente l'incertezza nelle previsioni;
- valutare l'identificabilità del modello.

Riflessioni conclusive

La covarianza e la correlazione sintetizzano la componente lineare di una distribuzione congiunta. La covarianza conserva le unità di misura e mostra se gli scarti dalle rispettive medie tendono ad avere lo stesso segno o segno opposto. La correlazione divide questa quantità per le deviazioni standard e consente di effettuare confronti su una scala compresa tra -1 e 1.

Questa sintesi è utile, ma incompleta. Una correlazione prossima a zero non esclude una dipendenza non lineare, mentre una correlazione elevata non dimostra necessariamente la causalità. Il suo valore può dipendere dalla variabilità del campione, dalla qualità delle misure e dalla presenza di valori anomali. Visualizzazione, teoria e disegno dello studio restano quindi necessari per attribuire un significato all'indice numerico.

Nel quadro bayesiano, la matrice di covarianza descrive anche come l'incertezza su più parametri o previsioni sia strutturata congiuntamente. Ignorare queste relazioni può alterare gli intervalli congiunti e la propagazione dell'incertezza nelle previsioni. Nel capitolo successivo useremo le distribuzioni di probabilità per passare dalla descrizione della variabilità al ragionamento inferenziale.

Esercizi

1. In una distribuzione congiunta, valori elevati di X tendono ad accompagnarsi a valori bassi di Y . Quale segno ci aspettiamo per la covarianza? Che cosa indica quel segno?
2. Due studi misurano la stessa associazione usando scale con unità diverse. Perché le covarianze non sono direttamente confrontabili, mentre le correlazioni lo sono più facilmente?
3. Una correlazione vale -0.40 . Che cosa descrivono il segno e il valore assoluto? Quale conclusione causale non è consentita?
4. In una regressione lineare semplice, una correlazione di 0.50 produce $\rho^2 = 0.25$. Come va interpretato questo valore? Perché non significa che una variabile causi il 25% dell'altra?
5. Due variabili hanno covarianza zero. Possiamo concludere che siano indipendenti? Descrivi una forma di relazione che potrebbe sfuggire alla covarianza.
6. Una scala contiene item positivamente correlati. È sufficiente per affermare che la scala sia affidabile e misuri un solo costrutto? Spiega quali cautele sono necessarie.
7. Una nuvola di punti segue chiaramente una forma a U rovesciata, ma la correlazione di Pearson è quasi zero. Come va interpretato questo risultato? Perché anche Spearman può essere prossimo a zero?
8. In una distribuzione a posteriori bivariata, intercetta e pendenza hanno covarianza negativa. Che cosa significa per l'incertezza congiunta sui due parametri?

Soluzioni

1. Ci aspettiamo una covarianza negativa. Gli scarti positivi di una variabile tendono ad accompagnarsi a scarti negativi dell'altra, e viceversa.
2. La covarianza cambia quando cambiano le unità e le scale delle variabili. La correlazione divide per le deviazioni standard e rimuove le unità, purché le trasformazioni siano lineari; una trasformazione con segno negativo può invertirne il segno.
3. Il segno negativo indica una relazione lineare inversa; il valore assoluto 0.40 ne riassume l'intensità lineare. Non permette di concludere che una variabile causi l'altra.
4. Nel contesto della regressione lineare semplice con intercetta, 0.25 è la quota di varianza della risposta descritta dalla relazione lineare con il predittore. Non è una percentuale di causalità e non comprende necessariamente forme non lineari di dipendenza.
5. No. La covarianza zero esclude soltanto una tendenza lineare media. Una relazione a U, a U rovesciata o un'altra dipendenza simmetrica non lineare può avere covarianza nulla.
6. No. Le covarianze positive possono riflettere un costrutto comune, ma anche formulazioni ridondanti, effetti di metodo o errori correlati. L'affidabilità e la struttura dimensionale richiedono ulteriori analisi e assunzioni.
7. Il valore prossimo a zero indica assenza di una componente lineare netta, non assenza di relazione. Spearman misura monotonicità: in una curva che prima cresce e poi decresce, le due tendenze possono compensarsi anche nei ranghi.
8. Significa che, nella distribuzione a posteriori, valori dell'intercetta superiori alla propria media tendono ad accompagnarsi a valori della pendenza inferiori alla propria media. Le stime non devono quindi essere interpretate come incertezze separate e indipendenti.

Punti chiave

- La covarianza misura la co-variazione lineare:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

- Il segno indica la direzione della relazione lineare; il valore numerico dipende dalle unità di misura.
- La correlazione di Pearson standardizza la covarianza:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}, \quad -1 \leq \rho \leq 1.$$

- In una regressione lineare semplice con intercetta, ρ^2 coincide con la quota di varianza descritta dalla relazione lineare; non misura causalità.
- In generale,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

- Se esistono i momenti necessari, l'indipendenza implica covarianza zero; l'inverso non è vero.
- Pearson descrive associazioni lineari; Spearman descrive associazioni monotone. Nessuno dei due cattura ogni forma di dipendenza.
- Una correlazione deve essere interpretata insieme a grafici, qualità delle misure, disegno dello studio e teoria.
- Nelle distribuzioni bayesiane multivariate, la covarianza descrive la struttura congiunta dell'incertezza sui parametri o sulle previsioni.

Parte III

PARTE 3: Distribuzioni specifiche

Riferimenti bibliografici

- Cohen, J. (1988). *Statistical power analysis for the behavior science*. Lawrence Erlbaum Association.
- Eysenck, M. W., Derakshan, N., Santos, R., & Calvo, M. G. (2007). Anxiety and cognitive performance: attentional control theory. *Emotion*, 7(2), 336–353.

Introduzione alle distribuzioni di probabilità

i In sintesi

Da sapere Comprendere che una famiglia di distribuzioni specifica valori possibili, forma e variabilità; distinguere il ruolo delle distribuzioni per dati, parametri e previsioni; riconoscere supporto, posizione, scala e forma come elementi della scelta modellistica.

Da saper fare Escludere famiglie incompatibili con il supporto della quantità; motivare una scelta distributiva in termini di processo generativo e forma attesa; interpretare il significato dei parametri senza confondere densità, probabilità e plausibilità.

Introduzione

Uno psicologo sta progettando uno studio sui tempi di reazione in un compito di decisione lessicale. I tempi sono positivi, spesso asimmetrici verso destra e talvolta presentano valori estremi. Una distribuzione normale assegna densità anche a valori negativi; una gamma o una log-normale, invece, rispettano il vincolo di positività e possono rappresentare l'asimmetria. La scelta tra queste famiglie richiede poi di confrontarne le implicazioni con il fenomeno e con i dati.

In un altro contesto, una ricercatrice clinica vuole rappresentare l'incertezza sulla probabilità di remissione dopo un trattamento. Poiché la quantità di interesse è compresa tra 0 e 1, una distribuzione Beta costituisce una candidata naturale. Anche in questo caso, però, i valori dei parametri esprimono assunzioni che devono essere motivate.

Una distribuzione non è soltanto una curva da disegnare. Indica quali valori il modello considera possibili, come distribuisce probabilità o densità, quanta variabilità prevede e quali forme ritiene plausibili. Nei capitoli precedenti abbiamo introdotto variabili casuali, funzioni di probabilità e densità, valore atteso, varianza, covarianza e correlazione. Ora introduciamo le **famiglie parametriche di distribuzioni**, il

vocabolario con cui questi concetti diventano modelli probabilistici.

10.1 Perché le distribuzioni sono importanti in psicologia?

I dati psicologici possono essere risposte binarie, conteggi, proporzioni, tempi, punteggi o misure fisiologiche. Queste quantità non condividono gli stessi valori possibili né la stessa struttura di variabilità. Scegliere una distribuzione significa quindi formulare ipotesi sul fenomeno: un tempo non può essere negativo, un conteggio è discreto, una probabilità è limitata tra 0 e 1.

Nel quadro bayesiano, le distribuzioni hanno inoltre ruoli distinti. Possono descrivere le osservazioni condizionatamente ai parametri, rappresentare l'incertezza sui parametri o esprimere previsioni su dati futuri. Comprendere questi ruoli evita di scegliere una famiglia soltanto perché la sua curva assomiglia a un istogramma.

Prerequisiti

Per seguire il capitolo è necessario avere letto Capitolo 6, Capitolo 7, Capitolo 8 e Capitolo 9. Per la notazione, consulta Appendice A.

Per un richiamo su combinatoria, sommatorie, integrali e derivate, consulta le appendici matematiche disponibili nel Companion.

Panoramica del capitolo

Il capitolo procede in sei passaggi:

1. introduce le famiglie parametriche e distingue famiglia e singola distribuzione;
2. presenta supporto, forma e natura della quantità come criteri di scelta;
3. chiarisce il ruolo dei parametri di posizione, scala e forma;
4. distingue distribuzioni per parametri, dati e previsioni;
5. costruisce una mappa orientativa delle principali famiglie discrete e continue;
6. applica i criteri di scelta a esempi psicologici.

Preparazione del notebook

```
here::here("code", "_common.R") |>  
  source()  
apply_visual_theme()
```

10.2 Dalle variabili casuali alle famiglie di distribuzioni

Una variabile casuale rappresenta una quantità incerta, come una risposta corretta o errata, il numero di sintomi riportati, il tempo di reazione o il punteggio ottenuto su una scala psicometrica. La distribuzione di probabilità specifica come la probabilità o la densità sono assegnate ai valori possibili di quella variabile.

Tuttavia, nella pratica scientifica non costruiamo ogni distribuzione da zero. Utilizziamo famiglie già note, ciascuna con proprietà matematiche e interpretative ben comprese. La distribuzione normale, la binomiale, la Poisson, la beta e la gamma sono esempi di **famiglie parametriche**.

Una famiglia parametrica è un insieme di distribuzioni descritte dalla stessa espressione generale e differenziate da uno o più **parametri**. Ad esempio:

- la famiglia normale è determinata da una media μ e da una deviazione standard σ ;
- la famiglia binomiale è determinata dal numero di prove n e dalla probabilità di successo p ;
- la famiglia beta è determinata da due parametri di forma, spesso indicati con α e β ;
- la famiglia di Poisson è determinata da un tasso medio λ .

Specificare una famiglia significa decidere la **forma generale** del modello. Specificare i valori dei parametri significa scegliere una distribuzione particolare all'interno di quella famiglia.

i Parametro della distribuzione e parametro inferenziale

Nei capitoli sulle distribuzioni, un parametro può essere considerato come un dato numerico, ad esempio una distribuzione normale con $\mu = 100$ e $\sigma = 15$. Questo permette di studiare le proprietà della distribuzione.

Nell'inferenza bayesiana, invece, molti parametri sono quantità ignote su cui abbiamo incertezza. Ad esempio, la probabilità di remissione θ può essere il parametro di un modello binomiale, ma anche una quantità su cui vogliamo costruire una distribuzione a priori e, dopo i dati, una distribuzione a posteriori. Questa distinzione sarà centrale nella Parte 4.

10.2.1 Le distribuzioni come rappresentazioni dell'incertezza

Nel ragionamento bayesiano, una distribuzione di probabilità è uno strumento per rappresentare l'incertezza. Può riguardare un'osservazione futura, un parametro sconosciuto o una quantità derivata dal modello. L'interpretazione dipende quindi dall'oggetto a cui la distribuzione è assegnata.

Consideriamo, ad esempio, la proporzione θ di studenti universitari con sintomi d'ansia clinicamente rilevanti. Dire "credo che sia il 25%" è una credenza puntuale. Spesso, però, non vogliamo attribuire tutta la nostra credenza a un singolo valore.

Potremmo assegnare maggiore plausibilità a valori compresi tra 0.20 e 0.30, minore plausibilità a valori intorno a 0.10 o 0.45 e plausibilità trascurabile a valori superiori a 0.70. Una distribuzione su θ rende esplicita questa struttura graduata di credenze.

Questa rappresentazione è più informativa di una stima puntuale, in quanto comunica anche la **dispersione** della nostra incertezza. Due ricercatori possono avere la stessa stima centrale, ad esempio 0.25, ma gradi di incertezza molto diversi: uno potrebbe essere quasi certo che il valore sia vicino a 0.25, mentre l'altro potrebbe considerare plausibile un intervallo molto ampio di valori.

10.2.2 Le distribuzioni come modelli della variabilità

Le distribuzioni servono anche a rappresentare la variabilità dei dati. In psicologia, la variabilità è spesso una componente essenziale del fenomeno: le persone rispondono in modo diverso allo stesso trattamento, lo stesso individuo può cambiare nel tempo e contesti diversi possono influenzare il comportamento osservato.

Per questo motivo, modellare soltanto la media può non essere sufficiente. Una distribuzione permette di rappresentare non solo il centro dei dati, ma anche la dispersione, l'asimmetria, le code e, quando necessario, la presenza di sottogruppi. In questo senso, la variabilità non è semplicemente rumore, ma informazione.

Come discusso da Segal et al. (2025), molti fenomeni psicologici e psicopatologici possono presentare una notevole eterogeneità. Le distribuzioni di probabilità forniscono un linguaggio per rendere visibile e modellabile questa eterogeneità.

10.3 Tre domande per scegliere una distribuzione

La scelta di una distribuzione non dovrebbe partire dalla domanda "Quale curva assomiglia al mio istogramma?". Questa domanda può essere utile, ma viene dopo. Prima è necessario chiarire che cosa si sta modellando e quali valori sono logicamente possibili.

10.3.1 1. Che tipo di quantità sto modellando?

La prima distinzione riguarda la natura della quantità:

- un **evento binario**, come risposta corretta/errata o remissione sì/no;
- un **conteggio**, come numero di sintomi, errori o episodi;
- una **proporzione** o probabilità, vincolata tra 0 e 1;
- una **misura continua**, come un tempo di reazione o un punteggio psicometrico;
- un **tasso**, come il numero medio di eventi per unità di tempo;
- una **varianza** o una deviazione standard, sempre non negativa.

Questa classificazione restringe subito l'insieme delle distribuzioni plausibili.

10.3.2 2. Qual è il supporto della quantità?

Il **supporto** è l'insieme dei valori che una variabile può assumere. Una distribuzione appropriata deve assegnare probabilità solo ai valori compatibili con il fenomeno.

Quantità da modellare	Supporto	Famiglie candidate	Esempio psicologico
Evento binario	$\{0, 1\}$	Bernoulli	Risposta corretta/errata
Numero di successi su n prove	$\{0, 1, \dots, n\}$	Binomiale	Item corretti su 20
Conteggio non limitato superiormente	$\{0, 1, 2, \dots\}$	Poisson, binomiale negativa	Numero di episodi in un periodo
Proporzione o probabilità	$[0, 1]$	Beta	Tasso di remissione
Misura continua su tutta la retta	$\mathbb{R}$	Normale, t di Student, Cauchy	Punteggi standardizzati
Quantità continua positiva	$(0, +\infty)$	Gamma, log-normale, esponenziale	Tempi di reazione, latenze
Varianza o precisione	$(0, +\infty)$	Gamma, chi-quadrato	Variabilità tra soggetti

Il supporto è un criterio di esclusione molto forte. Se una quantità non può assumere valori negativi, una distribuzione che assegna densità a valori negativi richiede una motivazione esplicita come approssimazione; spesso è preferibile una famiglia che rispetti direttamente il vincolo. Il supporto, tuttavia, non basta: più famiglie possono condividere gli stessi valori possibili ma formulare ipotesi diverse su forma e code.

10.3.3 3. Quale forma mi aspetto?

Dopo aver considerato il supporto, si valuta la forma attesa della distribuzione:

- simmetrica o asimmetrica;
- concentrata o dispersa;
- con code leggere o pesanti;
- con valori estremi frequenti o rari;
- con un solo picco o con più sottogruppi plausibili.

La forma non è un dettaglio estetico. Esprime ipotesi sostantive sul processo che genera i dati o sulla struttura dell'incertezza. Ad esempio, una distribuzione gamma può rappresentare tempi positivi e asimmetrici, mentre una distribuzione normale può essere ragionevole per una quantità approssimativamente simmetrica e non

troppo vicina a limiti naturali. Queste ipotesi devono poi essere controllate rispetto ai dati e alle previsioni del modello.

10.4 Famiglie parametriche e interpretazione dei parametri

10.4.1 Posizione, scala e forma

I parametri di una distribuzione possono avere ruoli diversi. Una distinzione utile è quella tra parametri di **posizione**, **scala** e **forma**.

Un parametro di posizione indica dove si concentra la distribuzione. Nella distribuzione normale, il parametro μ sposta la curva verso sinistra o verso destra. Un parametro di scala controlla la dispersione: nella distribuzione normale, per esempio, σ determina quanto la distribuzione è ampia. I parametri di forma, infine, modificano l'asimmetria, le code o la concentrazione: nella distribuzione beta, per esempio, i parametri α e β possono produrre distribuzioni simmetriche, asimmetriche, a U o fortemente concentrate.

```
x <- seq(-4, 4, length.out = 400)
curve_normali <- rbind(
  data.frame(x = x, density = dnorm(x, mean = 0, sd = 1), modello =
    ↪ "Normale(0, 1)"),
  data.frame(x = x, density = dnorm(x, mean = 1.5, sd = 1), modello =
    ↪ "Normale(1.5, 1)"),
  data.frame(x = x, density = dnorm(x, mean = 0, sd = 1.8), modello =
    ↪ "Normale(0, 1.8)")
)

ggplot(curve_normali, aes(x = x, y = density, linetype = modello)) +
  geom_line(linewidth = 1.1) +
  labs(
    title = "Effetto dei parametri in una famiglia parametrica",
    subtitle = "La media modifica la posizione; la deviazione standard
    ↪ modifica la dispersione",
    x = "Valore",
    y = "Densità",
    linetype = "Distribuzione"
  )
```




Figura 10.1: Effetto dei parametri di posizione e scala nella famiglia normale. La media sposta il centro della distribuzione; la deviazione standard ne modifica la dispersione.

La Figura 10.1 mostra il ruolo di posizione e scala nella famiglia normale. Lo stesso principio generale si applica alle altre famiglie: i parametri non sono simboli arbitrari, ma componenti del modello che determinano forma, centro, dispersione o altre proprietà della distribuzione.

10.4.2 Un piccolo lessico operativo

Nel seguito del modulo incontreremo spesso le seguenti parole. Conviene fissarle subito.

Supporto: l'insieme dei valori possibili. Una distribuzione Beta ha supporto $[0, 1]$, mentre una distribuzione di Poisson ha supporto $\{0, 1, 2, \dots\}$.

Massa di probabilità: per le variabili discrete, è la probabilità assegnata a ciascun valore specifico, come $P(X = 3)$.

Densità: per le variabili continue, è una funzione che permette di calcolare le probabilità su intervalli. Per una variabile continua, la probabilità che assuma un valore esatto è nulla; ciò che ha senso è la probabilità che assuma valori compresi tra a e b .

Funzione di distribuzione cumulativa: la funzione che restituisce $P(X \leq x)$.

Quantile: il valore sotto il quale cade una certa probabilità. Ad esempio, il quantile 0.95 è il valore sotto il quale si trova il 95% della distribuzione.

Questi concetti sono già stati introdotti nei capitoli precedenti, ma diventeranno operativi nei capitoli 11 e 12, in cui useremo anche le funzioni R associate alle principali distribuzioni.

10.5 Il ruolo delle distribuzioni in un modello bayesiano

Anche se la verosimiglianza e l'aggiornamento bayesiano verranno trattati in modo sistematico nella Parte 4, è utile anticipare il ruolo che le distribuzioni avranno in quel contesto.

Un modello bayesiano semplice può essere schematizzato nel modo seguente:

$$\theta \sim p(\theta), \quad Y | \theta \sim p(y | \theta).$$

La prima riga rappresenta l'incertezza sul parametro θ prima dell'osservazione dei dati. La seconda riga rappresenta il modello probabilistico dei dati condizionato a un valore del parametro. In questa forma compatta sono già presenti due usi diversi delle distribuzioni.

10.5.1 Distribuzioni per i parametri: prior

Una distribuzione a priori può rappresentare le assunzioni e l'incertezza riguardo a un parametro prima di osservare i dati considerati nell'analisi. Per esempio, se θ rappresenta una probabilità di remissione, una distribuzione beta può esprimere le credenze preliminari su valori compresi tra 0 e 1.

In questa funzione, la distribuzione risponde alla domanda:

Quali valori del parametro ritengo plausibili prima di osservare questi dati?

10.5.2 Distribuzioni per i dati: modello generativo

Una distribuzione può anche descrivere come potrebbero essere generati i dati, a partire da un determinato valore del parametro. Se osserviamo il numero di remissioni su n pazienti, una distribuzione binomiale può rappresentare il numero di successi attesi per un determinato valore di θ .

In questa funzione, la distribuzione risponde alla domanda:

Se il parametro assumesse questo valore, quali dati mi aspetterei di osservare?

10.5.3 Distribuzioni predittive

Infine, una distribuzione predittiva può descrivere ciò che ci aspettiamo di osservare in futuro. Nel quadro bayesiano, essa combina la variabilità prevista delle osservazioni con l'incertezza residua sui parametri, condizionatamente al modello.

Questa terza funzione sarà importante più avanti, ma è utile riconoscerla fin da ora: un modello probabilistico non serve solo a spiegare dati già osservati, ma anche a formulare aspettative controllabili su dati futuri.

! Idea guida

Nel manuale useremo le distribuzioni in tre modi complementari:

1. per descrivere quantità osservabili;
2. per rappresentare incertezza sui parametri;
3. per prevedere osservazioni future.

La Parte 3 costruisce il vocabolario. La Parte 4 mostrerà come questo vocabolario diventa inferenza.

10.6 Mappa delle principali famiglie

10.6.1 Distribuzioni discrete

Le distribuzioni discrete assegnano probabilità a valori separati e numerabili. Sono naturali quando gli esiti sono categorie, successi, errori o conteggi. La famiglia candidata deve comunque riflettere anche il modo in cui tali esiti vengono generati.

Famiglia	Quantità modellata	Parametri principali	Capitolo
Uniforme discreta	valori discreti equiprobabili	numero di valori possibili	Capitolo 11
Bernoulli	singolo evento binario	probabilità p	Capitolo 11
Binomiale	numero di successi in n prove	n, p	Capitolo 11
Poisson	conteggio di eventi in un intervallo	tasso λ	Capitolo 11

Esempi psicologici tipici sono la risposta corretta a un item, il numero di item superati, il numero di comportamenti osservati in una sessione o il numero di episodi registrati in un periodo.

10.6.2 Distribuzioni continue

Le distribuzioni continue assegnano densità su intervalli di valori. Sono candidate per tempi, misure fisiologiche, probabilità, tassi e parametri continui. Per una distribuzione uniforme continua, non sono i singoli punti ad avere uguale probabilità: intervalli della stessa ampiezza hanno uguale probabilità.

Famiglia	Quantità modellata	Parametri principali	Capitolo
Uniforme continua	uguale densità nell'intervallo	estremi a, b	Capitolo 12
Esponenziale	tempi di attesa	tasso λ	Capitolo 12
Normale	misure simmetriche su $\mathbb{R}$	μ, σ	Capitolo 12
Chi-quadrato	somme di quadrati, varianze	gradi di libertà	Capitolo 12
t di Student	quantità continue con code più pesanti	gradi di libertà	Capitolo 12
Cauchy	quantità continue con code molto pesanti	posizione, scala	Capitolo 12
Beta	proporzioni e probabilità	α, β	Capitolo 12
Gamma	tassi, tempi positivi, varianze	forma, tasso o scala	Capitolo 12

Questa mappa non deve essere memorizzata come una lista chiusa. Serve piuttosto a sviluppare un'abitudine: prima si guarda alla natura della quantità, poi al supporto, poi alla forma, infine al ruolo che la distribuzione deve svolgere nel modello.

10.7 Esempi di scelta della distribuzione

10.7.1 Remissione clinica: evento binario e probabilità

Supponiamo di voler studiare se un paziente raggiunge la remissione dopo un intervento psicoterapeutico. Per ogni paziente osserviamo un esito binario: remissione sì/no. La distribuzione naturale per una singola osservazione è la Bernoulli.

Se invece osserviamo y remissioni su n pazienti, la distribuzione naturale per il conteggio dei successi è la binomiale. Se vogliamo poi rappresentare l'incertezza sulla probabilità di remissione θ , una candidata naturale è la distribuzione Beta, perché θ deve appartenere all'intervallo $[0, 1]$.

Qui compaiono tre livelli:

- osservazione singola: Bernoulli;
- conteggio aggregato: Binomiale;
- incertezza sulla probabilità: Beta.

La relazione tra questi livelli verrà ripresa nei capitoli successivi.

10.7.2 Tempi di reazione: quantità positive e asimmetriche

I tempi di reazione non possono essere negativi e spesso presentano una coda lunga verso destra. Per questo motivo, una distribuzione normale potrebbe non essere adeguata, soprattutto in presenza di un'asimmetria marcata. Distribuzioni come la gamma o, in altri contesti, la log-normale rispettano il vincolo di positività e permettono l'asimmetria.

La scelta non dipende solo dal grafico dei dati. Dipende anche da ciò che si ritiene plausibile riguardo al processo: un tempo di reazione può essere considerato come una durata positiva influenzata da molteplici componenti cognitive, motorie e attentive.

10.7.3 Conteggi di eventi: frequenze in un intervallo

Se si conta il numero di errori in un compito o il numero di comportamenti osservati in una sessione, la variabile assume valori interi non negativi. La distribuzione di Poisson è una candidata quando il modello assume un tasso stabile nell'intervallo considerato e una variabilità compatibile con tale struttura.

Non ogni conteggio è quindi Poisson. Eterogeneità tra individui, eccesso di zeri, dipendenza tra eventi o dispersione maggiore di quella prevista possono richiedere modelli più flessibili, come la binomiale negativa o modelli gerarchici. La scelta dipende dal processo generativo, non soltanto dal fatto che i dati siano conteggi.

10.7.4 Punteggi psicometrici: continui o quasi continui?

Molti punteggi psicometrici derivano dalla somma di item discreti. In alcune analisi vengono trattati come quantità continue quando hanno molti valori possibili e l'approssimazione è adeguata allo scopo del modello. Questa scelta non rende però il punteggio intrinsecamente continuo né garantisce una distribuzione normale.

La normalità deve essere valutata rispetto alla scala, alla presenza di limiti inferiori o superiori, all'asimmetria, agli accumuli agli estremi e alle previsioni che il modello produce. In altri casi può essere preferibile modellare direttamente le risposte agli item o usare famiglie compatibili con il carattere discreto e limitato del punteggio.



Un errore comune

Non esiste una distribuzione “giusta” in assoluto. Esistono distribuzioni più o meno coerenti con il supporto della quantità, con la forma attesa, con il processo generativo ipotizzato e con lo scopo dell'analisi.

Una distribuzione è una scelta modellistica: deve essere motivata, controllata e, quando necessario, confrontata con alternative plausibili.

10.8 Distribuzioni e variabilità nei fenomeni psicologici

La ricerca psicologica si occupa di fenomeni altamente variabili. Le persone possono rispondere in modo diverso allo stesso trattamento, lo stesso costrutto può manifestarsi con configurazioni sintomatiche diverse e le misure possono variare da una sessione all'altra.

Tale variabilità non deve essere considerata solo come un ostacolo. Può indicare eterogeneità clinica, differenze individuali, sensibilità al contesto o sottogruppi teoricamente rilevanti. Rappresentare la variabilità mediante distribuzioni consente di porre domande più ricche:

- Quanto sono dispersi i punteggi?
- Ci sono code pesanti o valori estremi?
- La media è un riassunto adeguato?
- Una sola distribuzione è sufficiente o servono sottogruppi?
- L'incertezza riguarda i dati osservabili, i parametri o entrambi?

In una prospettiva bayesiana, queste domande diventano parte integrante del modello. Non ci limitiamo a stimare un valore centrale, ma specifichiamo una struttura probabilistica che rende esplicita la nostra rappresentazione del fenomeno.

10.9 Verso i capitoli successivi

Il resto della Parte 3 applicherà queste idee a famiglie specifiche.

Nel Capitolo 11 studieremo le distribuzioni discrete: la distribuzione uniforme discreta, la distribuzione di Bernoulli, la distribuzione binomiale e la distribuzione di Poisson. Queste distribuzioni sono fondamentali per eventi binari, conteggi e frequenze.

Nel Capitolo 12 studieremo le distribuzioni continue: uniforme continua, esponenziale, normale, chi-quadrato, t di Student, Cauchy, beta e gamma. Queste distribuzioni sono fondamentali per le misure continue, i tempi, le proporzioni, i tassi e i parametri positivi.

Dopo aver costruito questo vocabolario, la Parte 4 mostrerà come utilizzarlo per passare dai dati all'evidenza: prima, si comprenderà quanto un campione sia informativo; poi, si formalizzerà questa informazione con la verosimiglianza; infine, si aggiorneranno le credenze attraverso la distribuzione a posteriori.

Riflessioni conclusive

Le distribuzioni di probabilità sono il linguaggio con cui un modello rappresenta i valori possibili, la variabilità e l'incertezza. Ogni famiglia di distribuzioni porta con sé delle assunzioni riguardo al supporto, alla forma, alle code e al processo generativo. Per questo motivo, la scelta della distribuzione è una decisione scientifica e non un

passaggio automatico determinato esclusivamente dall'aspetto di un istogramma.

Nel quadro bayesiano, una distribuzione può descrivere i dati in relazione ai parametri, rappresentare l'incertezza sui parametri o formulare previsioni. La stessa famiglia può quindi avere ruoli diversi in modelli diversi e il suo significato dipende dalla variabile a cui viene assegnata e dalle condizioni espresse dal modello.

L'obiettivo non è memorizzare un catalogo di formule, ma imparare a porsi quattro domande: cosa sto modellando, quali valori sono possibili, quale forma è plausibile e quale ruolo deve svolgere la distribuzione? Nei capitoli successivi useremo queste domande per studiare le principali famiglie di distribuzioni discrete e continue.

Esercizi

1. Una variabile registra se una risposta è corretta oppure errata. Perché una distribuzione Bernoulli è più coerente di una distribuzione normale?
2. Un ricercatore osserva il numero di errori commessi in dieci prove. Qual è la differenza concettuale tra modellare ogni prova con una Bernoulli e modellare il numero totale di errori con una binomiale?
3. Una quantità può assumere soltanto valori compresi tra 0 e 1. Che cosa permette di concludere il supporto? Che cosa non permette ancora di decidere?
4. Due distribuzioni normali hanno la stessa media ma deviazioni standard diverse. Come cambia la loro interpretazione?
5. Una densità uniforme continua è costante tra 0 e 1. Significa che ogni singolo valore ha la stessa probabilità positiva? Spiega.
6. Un conteggio assume valori interi non negativi. È sufficiente questa informazione per scegliere automaticamente una distribuzione di Poisson? Quali altre caratteristiche del processo sono rilevanti?
7. In un modello sulla remissione, una binomiale descrive il numero di remissioni e una Beta descrive l'incertezza sulla probabilità di remissione. Quale ruolo svolge ciascuna distribuzione?
8. Un punteggio psicometrico è la somma di molti item e assume numerosi valori. Perché ciò non basta a garantire che una distribuzione normale sia adeguata?

Soluzioni

1. La risposta ha soltanto due esiti possibili, che possono essere codificati come 0 e 1. La Bernoulli assegna probabilità direttamente a questi due esiti; la normale assegna densità a un insieme continuo di valori, compresi valori non osservabili per quella variabile.
2. La Bernoulli descrive l'esito di una singola prova. La binomiale descrive il numero complessivo di successi o errori in un numero fissato di prove, sotto le assunzioni del modello binomiale.
3. Il supporto esclude famiglie che assegnano probabilità fuori dall'intervallo.

Non determina da solo la forma della distribuzione né i valori dei parametri: più famiglie o specificazioni possono condividere lo stesso supporto.

4. Le due distribuzioni hanno lo stesso centro. Quella con deviazione standard maggiore assegna maggiore dispersione ai valori e prevede osservazioni più lontane dalla media con maggiore frequenza.
5. No. In una distribuzione continua ogni singolo punto ha probabilità zero. La densità costante implica che intervalli della stessa ampiezza, contenuti nel supporto, hanno la stessa probabilità.
6. No. Occorre valutare, tra le altre cose, stabilità del tasso, dispersione, eccesso di zeri, eterogeneità tra individui e dipendenza tra eventi. Queste caratteristiche possono richiedere una famiglia diversa o un modello più articolato.
7. La binomiale è il modello dei dati condizionato alla probabilità di remissione. La Beta rappresenta l'incertezza su quella probabilità, come prior o posterior a seconda della fase dell'analisi.
8. Il punteggio resta discreto e limitato. Asimmetria, effetti pavimento o soffitto, accumuli agli estremi e struttura degli item possono rendere inadeguata l'approssimazione normale.

i Punti chiave

- Una famiglia parametrica raccoglie distribuzioni con la stessa espressione generale; i parametri selezionano una distribuzione specifica.
- Il **supporto** descrive i valori ammessi dal modello ed è il primo criterio di esclusione.
- Il supporto non basta: forma, code, dispersione e processo generativo distinguono famiglie con valori possibili simili.
- I parametri possono controllare posizione, scala, forma o altre proprietà; la loro interpretazione dipende dalla parametrizzazione.
- Per una variabile discreta si assegnano probabilità ai singoli valori; per una variabile continua le probabilità riguardano intervalli e si ottengono dalla densità.
- In una distribuzione uniforme continua, intervalli della stessa ampiezza hanno uguale probabilità; i singoli punti hanno probabilità zero.
- Nel modello bayesiano, le distribuzioni possono rappresentare dati, parametri o previsioni future.
- Bernoulli e binomiale svolgono ruoli diversi: la prima descrive un singolo esito binario, la seconda un conteggio di successi su un numero fissato di prove.
- Poisson è una possibile distribuzione per conteggi, non una scelta automatica per qualunque dato intero non negativo.
- Una distribuzione è una scelta modellistica da motivare e controllare mediante teoria, dati e previsioni del modello.

Riferimenti bibliografici

Segal, A., Tiego, J., Parkes, L., Holmes, A. J., Marquand, A. F., & Fornito, A. (2025). Embracing variability in the search for biological mechanisms of psychiatric illness. *Trends in Cognitive Sciences*, 29(1), 85–99.

Distribuzioni di variabili casuali discrete

i In sintesi

Da sapere Comprendere come una funzione di massa assegna probabilità ai valori di una variabile discreta; distinguere uniforme discreta, Bernoulli, binomiale, beta-binomiale e Poisson; riconoscere le assunzioni che collegano ciascuna famiglia al processo generativo.

Da saper fare Scegliere una famiglia discreta coerente con il tipo di dato e il disegno; interpretare supporto, parametri, media e varianza; spiegare che cosa indicano le funzioni d , p , q e r di R ; riconoscere quando indipendenza, probabilità costante o equidispersione sono poco plausibili; spiegare perché differenze tra unità nella probabilità di successo producono sovradisersione.

Introduzione

Nel capitolo precedente abbiamo introdotto l'idea generale di **distribuzione di probabilità**: un modo formale per assegnare probabilità ai valori possibili di una variabile casuale. In questo capitolo ci concentriamo sulle **distribuzioni discrete**, che descrivono variabili con un insieme finito o numerabile di valori, come una risposta corretta o errata, il numero di successi o il numero di eventi osservati in un intervallo.

La prospettiva adottata è bayesiana, ma lo scopo non è ancora svolgere un'inferenza completa. L'obiettivo è imparare a riconoscere alcune importanti **famiglie di modelli generativi discreti** e le assunzioni che esse incorporano. Nel Capitolo 13 useremo questi modelli per comprendere quanta informazione può contenere un campione; nel capitolo sulla verosimiglianza vedremo come, dopo avere osservato i dati, gli stessi modelli possano essere letti come funzioni dei parametri.

11.1 Perché le distribuzioni discrete sono importanti in psicologia?

Molti dati psicologici nascono in forma discreta: un item può essere corretto o errato, un sintomo può essere presente o assente, un partecipante può scegliere una tra più alternative e un comportamento può verificarsi un certo numero di volte. Riconoscere questa struttura permette di usare modelli che rispettano i valori realmente possibili e che rendono esplicite le ipotesi sul processo di osservazione.

Una distribuzione discreta risponde anzitutto a una domanda generativa:

Se questo modello e questi valori dei parametri fossero appropriati, quali dati potremmo osservare e con quali probabilità?

Ruolo bayesiano delle distribuzioni discrete

Nel percorso bayesiano, le distribuzioni discrete possono svolgere tre ruoli distinti:

1. **Modelli per i dati osservabili:** ad esempio, una risposta corretta o errata può essere modellata con una Bernoulli.
2. **Componenti della verosimiglianza:** dopo avere osservato i dati, la stessa espressione viene considerata come funzione dei parametri.
3. **Distribuzioni predittive:** integrando l'incertezza sui parametri, si ottengono probabilità per dati futuri. Un primo esempio è la distribuzione beta-binomiale (Sezione 11.7).

In questo capitolo ci concentriamo soprattutto sul primo ruolo, introducendo gli altri due soltanto quando aiutano a comprendere il significato del modello.

Prerequisiti

Per seguire il capitolo è utile avere letto Capitolo 6, Capitolo 7, Capitolo 8 e Capitolo 10. Il coefficiente binomiale è stato introdotto in Capitolo 3. Per la notazione matematica, consulta Appendice A.

Panoramica del capitolo

Il capitolo procede in sette passaggi:

1. distingue supporto e funzione di massa di una variabile discreta;
2. introduce le funzioni standard di R per probabilità, probabilità cumulate, quantili e simulazioni;
3. presenta la distribuzione uniforme discreta;
4. collega Bernoulli e binomiale ai dati binari e ai conteggi di successi;
5. mostra come la distribuzione beta-binomiale descriva i conteggi di successi quando la probabilità di successo varia tra unità o è incerta;

6. presenta la distribuzione di Poisson per alcuni processi di conteggio;
7. mostra perché sovradisersione, eterogeneità e dipendenza possono richiedere modelli più flessibili.

i Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()
apply_visual_theme()
```

11.2 Che cosa descrive una distribuzione discreta?

Una distribuzione discreta associa probabilità a valori separati e numerabili. Se X è una variabile casuale discreta, la sua distribuzione è descritta dalla **funzione di massa di probabilità**:

$$p_X(x) = P(X = x).$$

Le probabilità assegnate ai valori possibili devono soddisfare due condizioni:

$$p_X(x) \geq 0, \quad \sum_x p_X(x) = 1.$$

Il **supporto** della distribuzione è l'insieme dei valori che la variabile può assumere. Ad esempio:

- una variabile Bernoulli ha supporto $\{0, 1\}$;
- una variabile binomiale con n prove ha supporto $\{0, 1, \dots, n\}$;
- una variabile di Poisson ha supporto $\{0, 1, 2, \dots\}$.

! Modello condizionale, non certezza sul parametro

Quando scriviamo

$$Y | \theta \sim p(\cdot | \theta),$$

non stiamo dicendo che θ sia noto con certezza. Stiamo dicendo: **Se il parametro assumesse un certo valore, quale distribuzione avrebbero i dati?**

Questa distinzione è cruciale nella prospettiva bayesiana. Il modello dei dati è condizionato al parametro e l'incertezza sul parametro è rappresentata separatamente da una distribuzione a priori e, dopo avere osservato i dati, da una distribuzione a posteriori.

11.3 Le funzioni R per le distribuzioni

R utilizza una convenzione molto comoda per lavorare con le distribuzioni di probabilità. Ogni distribuzione ha quattro funzioni principali, identificate da una lettera iniziale:

Prefisso	Significato	Esempio con la binomiale
d	funzione di massa o densità	<code>dbinom(k, size, prob)</code>
p	funzione di ripartizione	<code>pbinom(k, size, prob)</code>
q	quantile	<code>qbinom(p, size, prob)</code>
r	generazione casuale	<code>rbinom(n, size, prob)</code>

Esempio: consideriamo $Y \sim \text{Binomiale}(10, 0.60)$.

```
# Probabilità di osservare esattamente 7 successi
p_esatto <- dbinom(7, size = 10, prob = 0.60)

# Probabilità di osservare al massimo 7 successi
p_cumulato <- pbinom(7, size = 10, prob = 0.60)

# Più piccolo valore che porta la probabilità cumulata almeno al 95%
q_95 <- qbinom(0.95, size = 10, prob = 0.60)

# Cinque campioni simulati dalla distribuzione
set.seed(1)
simulazioni <- rbinom(5, size = 10, prob = 0.60)

p_esatto
#> [1] 0.215
p_cumulato
#> [1] 0.833
q_95
#> [1] 8
simulazioni
#> [1] 7 7 6 4 7
```

Per una distribuzione discreta, le funzioni d restituiscono la massa di probabilità associata a un valore; per una distribuzione continua restituiscono invece una densità. Quando i dati sono stati osservati e l'espressione viene considerata come funzione dei parametri, questi valori contribuiscono alla verosimiglianza. Le funzioni r generano simulazioni dal modello e permettono di esaminare quali osservazioni il modello tende a produrre; da sole, però, non dimostrano che il modello sia adeguato ai dati reali.

11.4 Distribuzione uniforme discreta

11.4.1 Definizione

Definizione 11.1. Una variabile casuale X segue una distribuzione uniforme discreta su $\{1, \dots, N\}$ se assegna la stessa probabilità a ciascuno dei valori possibili:

$$X \sim \text{Uniforme discreta}(1, N), \quad P(X = x) = \frac{1}{N}, \quad x = 1, \dots, N.$$

I suoi momenti principali sono:

$$\mathbb{E}(X) = \frac{N+1}{2}, \quad \mathbb{V}(X) = \frac{N^2-1}{12}.$$

La distribuzione uniforme discreta rappresenta una scelta di **simmetria**: all'interno del modello, gli esiti vengono trattati nello stesso modo. Questa assegnazione deve essere giustificata dal meccanismo di selezione o dalle assunzioni informative; non deriva dal solo fatto che gli esiti possano essere elencati.

11.4.2 Esempio: assegnazione casuale a condizioni sperimentali

Supponiamo di assegnare partecipanti a quattro condizioni sperimentali con uguale probabilità. Il gruppo assegnato a un partecipante può essere modellato come:

$$G \sim \text{Uniforme discreta}(1, 4).$$

```
set.seed(42)
N <- 4
n_partecipanti <- 400
condizione <- sample(1:N, size = n_partecipanti, replace = TRUE)

df_uniforme <- data.frame(condizione = factor(condizione))

ggplot(df_uniforme, aes(x = condizione)) +
  geom_bar(aes(y = after_stat(prop), group = 1)) +
  geom_hline(yintercept = 1 / N, linetype = "dashed") +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = "Assegnazione casuale a quattro condizioni",
    subtitle = "La linea tratteggiata indica la probabilità teorica 1/4",
    x = "Condizione sperimentale",
    y = "Frequenza relativa"
  )
```




Figura 11.1: Frequenze relative simulate in 400 assegnazioni indipendenti a quattro condizioni equiprobabili.

La Figura 11.1 mostra che le frequenze osservate oscillano intorno a 1/4: l'equiprobabilità riguarda il modello, non l'uguaglianza esatta delle frequenze in un campione finito. Inoltre, questa simulazione usa assegnazioni indipendenti; un disegno a gruppi perfettamente bilanciati richiederebbe un diverso meccanismo di randomizzazione.

i Interpretazione bayesiana

Una distribuzione uniforme su un insieme finito può anche rappresentare una prior simmetrica su ipotesi o modelli alternativi:

$$P(M_1) = P(M_2) = \dots = P(M_K) = \frac{1}{K}.$$

Questa scelta non dimostra che i modelli siano ugualmente validi. Esprime soltanto pesi iniziali uguali, adottati perché la modellizzazione non distingue le alternative prima dei dati.

11.5 Distribuzione di Bernoulli

11.5.1 Definizione

Definizione 11.2. Una variabile casuale X segue una distribuzione di Bernoulli se può assumere solo due valori, convenzionalmente codificati come 1 e 0:

$$X \sim \text{Bernoulli}(p), \quad P(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}.$$

I suoi momenti principali sono:

$$\mathbb{E}(X) = p, \quad \mathbb{V}(X) = p(1 - p).$$

Il modello di Bernoulli è il più semplice per un dato binario. Il valore 1 non deve essere interpretato come un successo in senso stretto: è solo l'esito che abbiamo scelto di codificare come tale. In psicologia può indicare una risposta corretta, la presenza di un sintomo, l'adesione a un trattamento o una scelta tra due alternative.

11.5.2 Esempio: risposta corretta a un item

Un partecipante risponde a un item di memoria. Se la probabilità di risposta corretta è $p = 0.70$, la risposta X può essere modellata come:

$$X \mid p = 0.70 \sim \text{Bernoulli}(0.70).$$

```
p <- 0.70
bern_df <- data.frame(
  esito = factor(c(0, 1), labels = c("Errata", "Corretta")),
  probabilita = c(1 - p, p)
)

ggplot(bern_df, aes(x = esito, y = probabilita)) +
  geom_col() +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = "Distribuzione di Bernoulli",
    subtitle = "Probabilità di risposta corretta p = 0.70",
    x = "Esito",
    y = "Probabilità"
  )
```




Figura 11.2: Funzione di massa di una Bernoulli con probabilità dell'esito 1 pari a 0,70.

La Figura 11.2 rappresenta le due sole probabilità ammesse dal modello: $P(X = 1) = p$ e $P(X = 0) = 1 - p$.

```
set.seed(123)
risposte <- rbinom(20, size = 1, prob = p)
risposte
#> [1] 1 0 1 0 0 1 1 0 1 1 0 1 1 1 0 1 1 1 0
mean(risposte)
#> [1] 0.65
```

Anche se il parametro usato nella simulazione è $p = 0.70$, in un campione piccolo la proporzione osservata può discostarsi sensibilmente da 0.70. Questo aspetto verrà ripreso nel Capitolo 13: i dati osservati sono informativi, ma sono anche soggetti a variabilità campionaria.

11.5.3 Bernoulli come modello generativo

Per una sequenza di risposte binarie $X_1, \dots, X_n$, il modello più semplice assume:

$$X_i | p \stackrel{iid}{\sim} \text{Bernoulli}(p), \quad i = 1, \dots, n.$$

La sigla *iid* indica che, condizionatamente a p , le osservazioni sono indipendenti e condividono la stessa distribuzione. L'assunzione è semplice ma forte: la probabilità dell'esito codificato come 1 deve essere la stessa per tutte le osservazioni e una risposta non deve modificare direttamente le altre.

Quando la Bernoulli è troppo semplice

Nei dati psicologici reali, l'assunzione di un unico valore di p può essere irrealistica. Ad esempio, gli item diversi possono avere difficoltà diverse, i partecipanti possono avere abilità diverse, e le risposte successive possono non essere indipendenti.

La distribuzione di Bernoulli rimane comunque il punto di partenza: i modelli più ricchi spesso nascono proprio dal rilassamento di una o più delle sue assunzioni. Un primo esempio è la distribuzione beta-binomiale (Sezione 11.7), che consente alla probabilità di successo di variare tra partecipanti.

11.6 Distribuzione binomiale

11.6.1 Dalla Bernoulli alla binomiale

La distribuzione binomiale descrive il numero di successi in n prove di Bernoulli indipendenti, tutte con la stessa probabilità di successo p .

Se

$$X_1, \dots, X_n | p \sim \text{Bernoulli}(p),$$

e definiamo

$$Y = \sum_{i=1}^n X_i,$$

allora Y rappresenta il numero totale di successi. In questo caso:

$$Y | p \sim \text{Binomiale}(n, p).$$

11.6.2 Perché compare il coefficiente binomiale?

Se osserviamo esattamente k successi e $n - k$ insuccessi, la probabilità di una sequenza specifica è:

$$p^k(1 - p)^{n-k}.$$

Tuttavia, lo stesso numero di successi può comparire in molti ordini diversi. Il numero di sequenze con k successi in n prove è:

$$\binom{n}{k}.$$

Quindi, la probabilità complessiva di osservare k successi è:

$$P(Y = k | p, n) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

11.6.3 Definizione

Definizione 11.3. Una variabile casuale Y segue una distribuzione binomiale con parametri n e p se:

$$Y \sim \text{Binomiale}(n, p), \quad P(Y = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

I suoi momenti principali sono:

$$\mathbb{E}(Y) = np, \quad \mathbb{V}(Y) = np(1 - p).$$

11.6.4 Esempio: punteggio a un test

Un test contiene 20 item dicotomici. Se la probabilità di risposta corretta a ciascun item è $p = 0.75$, il numero totale di risposte corrette può essere modellato come:

$$Y | p = 0.75 \sim \text{Binomiale}(20, 0.75).$$

```
n_item <- 20
p_corretto <- 0.75
```

```

k <- 0:n_item

binom_df <- data.frame(
  k = k,
  probabilita = dbinom(k, size = n_item, prob = p_corretto)
)

ggplot(binom_df, aes(x = k, y = probabilita)) +
  geom_col() +
  scale_x_continuous(breaks = 0:n_item) +
  labs(
    title = "Distribuzione binomiale",
    subtitle = "Numero di risposte corrette su 20 item, p = 0.75",
    x = "Risposte corrette",
    y = "Probabilità"
  )

```




Figura 11.3: Distribuzione binomiale del numero di risposte corrette su 20 prove con probabilità costante pari a 0,75.

La Figura 11.3 assegna probabilità al numero totale di risposte corrette, non all'ordine in cui esse compaiono.

```

media_teorica <- n_item * p_corretto
var_teorica <- n_item * p_corretto * (1 - p_corretto)

cat("Media teorica:", media_teorica, "\n")
#> Media teorica: 15
cat("Varianza teorica:", var_teorica, "\n")
#> Varianza teorica: 3.75

```

11.6.5 La proporzione campionaria

Spesso non ci interessa solo il numero totale di successi Y , ma anche la proporzione:

$$\hat{p} = \frac{Y}{n}.$$

Poiché $Y \sim \text{Binomiale}(n, p)$, otteniamo:

$$\mathbb{E}(\hat{p}) = p, \quad \mathbb{V}(\hat{p}) = \frac{p(1-p)}{n}.$$

Questa relazione sarà centrale nel Capitolo 13: mostra perché campioni più grandi producono proporzioni più stabili.

```
set.seed(42)
n_values <- c(10, 50, 200)
p_vero <- 0.40
n_rep <- 5000

sim_list <- lapply(n_values, function(n) {
  phat <- rbinom(n_rep, size = n, prob = p_vero) / n
  data.frame(n = factor(n), phat = phat)
})

sim_df <- do.call(rbind, sim_list)

ggplot(sim_df, aes(x = phat)) +
  geom_histogram(bins = 30) +
  facet_wrap(~ n, ncol = 1) +
  labs(
    title = "Distribuzione simulata della proporzione campionaria",
    subtitle = "La variabilità diminuisce al crescere di n",
    x = "Proporzione osservata",
    y = "Frequenza"
  )
```




Figura 11.4: Distribuzioni simulate della proporzione campionaria per diverse numerosità, con probabilità generatrice pari a 0,40.

La Figura 11.4 illustra il significato di $\mathbb{V}(\hat{p}) = p(1 - p)/n$: aumentando n , le proporzioni simulate si concentrano maggiormente intorno a p .

11.6.6 Ruolo bayesiano: la binomiale come verosimiglianza

Se osserviamo y successi su n prove, la massa binomiale può essere riletta come funzione di p :

$$L(p | y, n) \propto p^y (1 - p)^{n-y}.$$

Il coefficiente $\binom{n}{y}$ è omissso nella proporzionalità perché non dipende da p . Questa espressione non è ancora una distribuzione a posteriori: è la **verosimiglianza**, che confronta quanto valori diversi di p rendano compatibile il risultato osservato, mantenendo fissi y e n .

i Anticipazione: prior Beta e aggiornamento

La distribuzione Beta, presentata in Sezione 12.8, è una distribuzione continua su $(0, 1)$ molto utile per rappresentare l'incertezza su una probabilità p . In Sezione 11.7 ne useremo due proprietà.

Se

$$p \sim \text{Beta}(\alpha, \beta)$$

e osserviamo y successi su n prove, allora la distribuzione a posteriori è:

$$p | y, n \sim \text{Beta}(\alpha + y, \beta + n - y).$$

Per ora non è necessario padroneggiare questa formula. È sufficiente riconoscere che i dati binomiali aggiornano le credenze su una probabilità.

11.7 Distribuzione beta-binomiale

11.7.1 Quando la probabilità di successo non è la stessa per tutti

La distribuzione binomiale assume che tutte le prove condividano la stessa probabilità di successo p . Quando le prove provengono da persone diverse, questa assunzione è spesso poco plausibile: in un compito di memoria, ad esempio, alcuni partecipanti ricordano più facilmente di altri.

Consideriamo dieci studenti che studiano 10 parole ciascuno. Il numero di parole ricordate da ciascuno è:

```
ricordati <- c(2, 3, 3, 4, 4, 8, 8, 9, 9, 10)
c(media = mean(ricordati), deviazione_standard = sd(ricordati))
#>                media deviazione_standard
#>                6.00                3.06
```

La proporzione complessiva di parole ricordate è 0.60. Se tutti gli studenti avessero la stessa probabilità $p = 0.60$, il numero di parole ricordate da ciascuno seguirebbe una distribuzione Binomiale(10,0.60), con deviazione standard

$$\sqrt{10 \times 0.60 \times 0.40} \approx 1.55.$$

La deviazione standard osservata è circa il doppio. La discrepanza compare anche nelle code della distribuzione:

```
c(
  binomiale_al_massimo_2 = pbinom(2, size = 10, prob = 0.60),
  osservata_al_massimo_2 = mean(ricordati <= 2),
  binomiale_almeno_9 = 1 - pbinom(8, size = 10, prob = 0.60),
  osservata_almeno_9 = mean(ricordati >= 9)
)
#> binomiale_al_massimo_2 osservata_al_massimo_2
#>                0.0123                0.1000
#> binomiale_almeno_9    osservata_almeno_9
#>                0.0464                0.3000
```

Sotto il modello binomiale, ricordare al massimo 2 parole ha probabilità di circa l'1% e ricordarne almeno 9 di circa il 5%. Nel campione, queste prestazioni riguardano rispettivamente 1 e 3 studenti su 10. Con soli dieci studenti le frequenze osservate sono molto instabili, ma tutte le indicazioni vanno nella stessa direzione: i dati sono più dispersi di quanto il modello binomiale possa produrre. Questo fenomeno si chiama **sovradispersione**.

11.7.2 Un modello a due stadi

Per rappresentare le differenze tra studenti possiamo attribuire a ciascuno una propria probabilità di ricordo p_i . Il processo generativo si articola allora in due stadi:

1. per ogni studente si estrae una probabilità p_i da una distribuzione che descrive la popolazione degli studenti;
2. condizionatamente a p_i , il numero di parole ricordate segue una binomiale:

$$Y_i | p_i \sim \text{Binomiale}(n, p_i).$$

La distribuzione di Y_i che si ottiene considerando entrambi gli stadi, cioè senza conoscere il valore di p_i , si chiama distribuzione **marginale** di Y_i . Poiché combina più distribuzioni condizionate, pesandole secondo la distribuzione del parametro, viene anche detta **mistura**.

11.7.3 Un caso semplice: due tipi di studenti

Iniziamo da un caso che si può calcolare con i soli strumenti di questo capitolo. Supponiamo che la popolazione comprenda due tipi di studenti, ugualmente frequenti: per il primo tipo la probabilità di ricordo è 0.3, per il secondo è 0.8.

$$P(p_i = 0.3) = P(p_i = 0.8) = 0.5.$$

Per la legge della probabilità totale, la probabilità di osservare k parole ricordate è la media delle due distribuzioni binomiali, pesata dalla frequenza dei due tipi:

$$P(Y = k) = 0.5 \binom{n}{k} 0.3^k 0.7^{n-k} + 0.5 \binom{n}{k} 0.8^k 0.2^{n-k}.$$

```
k <- 0:10
mistura <- 0.5 * dbinom(k, size = 10, prob = 0.3) +
  0.5 * dbinom(k, size = 10, prob = 0.8)

df_mistura <- rbind(
  data.frame(k = k, probabilita = dbinom(k, 10, 0.3), modello = "p = 0.3"),
  data.frame(k = k, probabilita = dbinom(k, 10, 0.8), modello = "p = 0.8"),
  data.frame(k = k, probabilita = mistura, modello = "mistura (0.5 e 0.5)")
)
df_mistura$modello <- factor(df_mistura$modello, levels =
  unique(df_mistura$modello))

ggplot(df_mistura, aes(x = k, y = probabilita)) +
  geom_col() +
  facet_wrap(~ modello, nrow = 1) +
  scale_x_continuous(breaks = k) +
  labs(
    title = "Una mistura di due binomiali",
    x = "Parole ricordate",
    y = "Probabilità"
  )
```




Figura 11.5: Numero di parole ricordate su 10 per studenti con probabilità di ricordo 0,3, per studenti con probabilità 0,8 e per una popolazione che contiene i due tipi in parti uguali.

La Figura 11.5 mostra che la mistura conserva i due massimi, attorno a 3 e a 8 parole. La probabilità media di ricordo nella popolazione è $0.5 \times 0.3 + 0.5 \times 0.8 = 0.55$, ma i valori 5 e 6, vicini a 10×0.55 , sono fra i meno probabili della zona centrale. Una binomiale con $p = 0.55$ avrebbe invece un solo massimo, proprio in quella zona.

11.7.4 Da dove viene la variabilità aggiuntiva

La media della mistura è la stessa di una binomiale con p uguale alla probabilità media:

$$\mathbb{E}(Y) = n \mathbb{E}(p_i) = 10 \times 0.55 = 5.5.$$

La varianza, invece, è molto più grande. Per capire perché, la si può scomporre in due parti:

$$\mathbb{V}(Y) = \underbrace{\mathbb{E}[\mathbb{V}(Y | p_i)]}_{\text{variabilità binomiale media}} + \underbrace{\mathbb{V}[\mathbb{E}(Y | p_i)]}_{\text{variabilità dovuta alle differenze in } p_i}.$$

Questa scomposizione è nota come **legge della varianza totale**. Nel nostro esempio:

- il primo termine è la media delle varianze binomiali dei due tipi: $10 \times (0.5 \times 0.3 \times 0.7 + 0.5 \times 0.8 \times 0.2) = 1.85$;
- il secondo termine è la varianza dei numeri medi di parole ricordate dai due tipi, 3 e 8: $10^2 \times \mathbb{V}(p_i) = 100 \times 0.0625 = 6.25$.

```
media_mistura <- sum(k * mistura)
varianza_mistura <- sum(k^2 * mistura) - media_mistura^2
```

```

c(
  varianza_mistura = varianza_mistura,
  somma_dei_due_termini = 1.85 + 6.25,
  varianza_binomiale_stessa_media = 10 * 0.55 * 0.45
)
#>                varianza_mistura                somma_dei_due_termini
#>                        8.10                        8.10
#> varianza_binomiale_stessa_media
#>                        2.48

```

La varianza della mistura è 8.1, più del triplo di quella di una binomiale con la stessa media (2.475). La differenza è interamente dovuta al secondo termine: se tutti gli studenti avessero la stessa probabilità, $\mathbb{V}(p_i)$ sarebbe zero e si ritornerebbe alla binomiale.

! L'origine della sovradisersione

La sovradisersione non richiede che il singolo studente si comporti in modo diverso da una binomiale. Nasce dal fatto che studenti diversi hanno probabilità diverse: alla variabilità di ciascuno attorno alla propria media si aggiunge la variabilità delle medie fra studenti.

11.7.5 Dal caso discreto al caso continuo

Due soli tipi di studenti sono una semplificazione. Più realisticamente, la probabilità di ricordo può assumere qualunque valore tra 0 e 1 e variare con continuità da uno studente all'altro. Per descriverla serve una distribuzione continua definita sull'intervallo $(0, 1)$: la **distribuzione Beta**, presentata in Sezione 12.8.

In questa sezione ne servono soltanto due proprietà. Una distribuzione $\text{Beta}(\alpha, \beta)$ si può descrivere con due quantità:

$$m = \frac{\alpha}{\alpha + \beta}, \quad \kappa = \alpha + \beta.$$

- m è la probabilità media di successo nella popolazione;
- κ indica quanto le probabilità individuali sono **concentrate** attorno a m : con κ grande sono simili fra loro, con κ piccolo sono molto diverse.

I parametri originali si ricavano da m e κ come $\alpha = m\kappa$ e $\beta = (1 - m)\kappa$.

Se la probabilità di ciascuna unità segue una distribuzione Beta e, condizionata a essa, il numero di successi segue una binomiale,

$$p_i \sim \text{Beta}(\alpha, \beta), \quad Y_i | p_i \sim \text{Binomiale}(n, p_i),$$

allora la distribuzione marginale di Y_i è una **beta-binomiale**.

11.7.6 Definizione

Definizione 11.4. Una variabile casuale Y segue una distribuzione beta-binomiale con parametri $n, \alpha > 0$ e $\beta > 0$ se:

$$Y \sim \text{BetaBinomiale}(n, \alpha, \beta), \quad P(Y = k) = \binom{n}{k} \frac{B(k + \alpha, n - k + \beta)}{B(\alpha, \beta)}, \quad k = 0, 1, \dots, n,$$

dove $B(\cdot, \cdot)$ è la funzione beta, la costante di normalizzazione della distribuzione Beta (Sezione 12.8).

Con $m = \alpha / (\alpha + \beta)$ e $\kappa = \alpha + \beta$, i suoi momenti principali sono:

$$\mathbb{E}(Y) = nm, \quad \mathbb{V}(Y) = nm(1 - m) \frac{\kappa + n}{\kappa + 1}.$$

La media coincide con quella di una binomiale con $p = m$. La varianza è la varianza binomiale $nm(1 - m)$ moltiplicata per il fattore

$$\frac{\kappa + n}{\kappa + 1} = 1 + \frac{n - 1}{\kappa + 1},$$

che è maggiore di 1 non appena $n > 1$. Il fattore cresce con il numero di prove per unità e diminuisce con la concentrazione κ .

Il caso $n = 1$ merita un'osservazione. Con una sola prova per unità il fattore vale 1 e la beta-binomiale coincide con una Bernoulli di parametro m : con una sola risposta binaria per persona, le differenze tra persone non lasciano alcuna traccia nella distribuzione dei dati. Per rilevare l'eterogeneità servono più prove per ciascuna unità.

11.7.7 Due casi limite

La beta-binomiale contiene come casi particolari due distribuzioni già incontrate in questo capitolo.

Concentrazione molto grande. Quando κ cresce, le probabilità individuali si concentrano attorno a m , il fattore $(\kappa + n)/(\kappa + 1)$ tende a 1 e la beta-binomiale tende alla Binomiale(n, m). La binomiale è quindi il caso in cui tutte le unità condividono la stessa probabilità.

Prior uniforme sulla probabilità. Con $\alpha = \beta = 1$ la distribuzione Beta è uniforme su $(0, 1)$ e la beta-binomiale assegna la stessa probabilità a tutti i conteggi possibili:

```
dbetabinom_base <- function(k, size, shape1, shape2) {
  exp(lchoose(size, k) + lbeta(k + shape1, size - k + shape2) -
    lbeta(shape1, shape2))
}

round(dbetabinom_base(0:10, size = 10, shape1 = 1, shape2 = 1), 4)
#> [1] 0.0909 0.0909 0.0909 0.0909 0.0909 0.0909 0.0909 0.0909 0.0909
#> [10] 0.0909 0.0909
```

Ciascun valore ha probabilità $1/11$: è la distribuzione uniforme discreta su $\{0, 1, \dots, 10\}$ (Sezione 11.4). Una probabilità incerta distribuita uniformemente produce conteggi distribuiti uniformemente, e non conteggi concentrati attorno a $n/2$.

11.7.8 Perché le prove non sono più indipendenti

Nel modello a due stadi, le prove di uno stesso studente sono indipendenti **condizionatamente** a p_i . Se però p_i non è noto, due prove dello stesso studente non sono più indipendenti: un successo nella prima prova rende più plausibile che lo studente abbia una probabilità alta, e quindi aumenta la probabilità di successo nella seconda.

La correlazione tra due prove della stessa unità è

$$\rho = \frac{1}{\kappa + 1},$$

e la varianza della beta-binomiale può essere riscritta come

$$\mathbb{V}(Y) = nm(1 - m) [1 + (n - 1)\rho].$$

In Sezione 12.8 vedremo che $1/(\kappa + 1)$ ammette anche un'altra lettura: è la quota della varianza di una singola prova dovuta alle differenze tra unità.

```
set.seed(11)
n_sim <- 100000
p_studente <- rbeta(n_sim, shape1 = 0.60 * 3, shape2 = 0.40 * 3)
prova_1 <- rbinom(n_sim, size = 1, prob = p_studente)
prova_2 <- rbinom(n_sim, size = 1, prob = p_studente)

c(correlazione_simulata = cor(prova_1, prova_2), correlazione_teorica = 1
  ~ / (3 + 1))
#> correlazione_simulata correlazione_teorica
#> 0.253 0.250
```

i Eterogeneità e dipendenza

Differenze tra unità e dipendenza tra le prove di una stessa unità sono due aspetti dello stesso fenomeno. Per questo, in Sezione 11.9, «partecipanti molto diversi tra loro» e «dati provenienti da gruppi differenti» compaiono tra le ragioni per cui l'assunzione di indipendenza della binomiale può non essere soddisfatta.

11.7.9 Esempio: le prestazioni di dieci studenti

Torniamo ai dieci studenti. Confrontiamo la binomiale con $p = 0.60$ e una beta-binomiale con la stessa media, $m = 0.60$, e concentrazione $\kappa = 3$, cioè con $\alpha = 1.8$ e $\beta = 1.2$.

```
k <- 0:10
df_confronto <- rbind(
  data.frame(k = k, probabilita = dbinom(k, 10, 0.60),
    modello = "Binomiale: p = 0.60 per tutti"),
  data.frame(k = k, probabilita = dbetabinom_base(k, 10, 0.60 * 3, 0.40 *
    ~ 3),
    modello = "Beta-binomiale: m = 0.60, κ = 3")
)
```

```
df_confronto$modello <- factor(df_confronto$modello, levels =
  ~ unique(df_confronto$modello))
df_osservati <- data.frame(k = k, frequenza =
  ~ as.numeric(table(factor(ricordati, levels = k))) / 10)

ggplot(df_confronto, aes(x = k, y = probabilita)) +
  geom_col() +
  geom_point(data = df_osservati, aes(x = k, y = frequenza), size = 2.5) +
  facet_wrap(~ modello, nrow = 1) +
  scale_x_continuous(breaks = k) +
  labs(
    title = "Binomiale e beta-binomiale",
    x = "Parole ricordate",
    y = "Probabilità"
  )
)
```




Figura 11.6: Numero di parole ricordate su 10 secondo una binomiale con probabilità fissata a 0,60 e secondo una beta-binomiale con la stessa media e concentrazione pari a 3. I punti indicano le frequenze relative osservate nei dieci studenti.

```
p_bb <- dbetabinom_base(k, 10, 0.60 * 3, 0.40 * 3)

round(rbind(
  binomiale = c(deviazione_standard = sqrt(10 * 0.60 * 0.40),
    al_massimo_2 = pbinom(2, 10, 0.60),
    almeno_9 = 1 - pbinom(8, 10, 0.60)),
  beta_binomiale = c(sqrt(10 * 0.60 * 0.40 * (3 + 10) / (3 + 1)),
    sum(p_bb[k <= 2]),
    sum(p_bb[k >= 9])),
  osservato = c(sd(ricordati), mean(ricordati <= 2), mean(ricordati >= 9))
), 3)
#>      deviazione_standard al_massimo_2 almeno_9
#> binomiale             1.55         0.012  0.046
#> beta_binomiale        2.79         0.137  0.232
#> osservato             3.06         0.100  0.300
```

La beta-binomiale riproduce molto meglio la dispersione dei dati: la sua deviazione standard è circa 2.8, contro 1.55 della binomiale e 3.06 osservata, e assegna alle prestazioni molto basse e molto alte probabilità paragonabili alle frequenze osservate. Il fattore di inflazione della varianza vale $(3 + 10)/(3 + 1) = 3.25$.

Il valore $\kappa = 3$ è stato scelto qui a scopo illustrativo. Stimare m e κ a partire dai dati è un problema di inferenza, che affronteremo nei capitoli successivi.

11.7.10 Le funzioni R

R di base non include funzioni per la beta-binomiale, ma è semplice costruirle. La funzione di massa è `dbetabinom_base()`, definita sopra. Le simulazioni si ottengono seguendo direttamente i due stadi del modello:

```
rbetabinom_base <- function(n_sim, size, shape1, shape2) {
  p <- rbeta(n_sim, shape1, shape2) # stadio 1: una probabilità per
  ↪ ciascuna unità
  rbinom(n_sim, size = size, prob = p) # stadio 2: i successi, data quella
  ↪ probabilità
}

set.seed(11)
y_sim <- rbetabinom_base(100000, size = 10, shape1 = 1.8, shape2 = 1.2)

round(rbind(
  simulata = as.numeric(table(factor(y_sim, levels = 0:10))) / 100000,
  esatta = dbetabinom_base(0:10, 10, 1.8, 1.2)
), 3)
#>           [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
#> simulata 0.025 0.046 0.065 0.080 0.094 0.103 0.112 0.119 0.124
#> esatta   0.026 0.047 0.064 0.079 0.092 0.104 0.113 0.120 0.123
#>           [,10] [,11]
#> simulata 0.122 0.109
#> esatta   0.122 0.110
```

Le frequenze simulate coincidono con le probabilità esatte entro l'errore di simulazione. La funzione di ripartizione si ottiene sommando le masse, ad esempio con `cumsum(dbetabinom_base(0:10, 10, 1.8, 1.2))`. Il pacchetto **extraDistr** fornisce funzioni già pronte per la beta-binomiale, come `dbbinom()`, `pbbinom()` e `rbbinom()`.

11.7.11 Ruolo bayesiano: eterogeneità e incertezza

La stessa distribuzione ammette due letture, che corrispondono a due significati diversi della distribuzione Beta.

Lettura	Che cosa descrive la Beta	Esempio
Eterogeneità	differenze reali tra unità: ciascuna ha la propria probabilità	la distribuzione dei punteggi in una popolazione di studenti con capacità diverse
Incertezza epistemica	un'unica probabilità, non nota: la Beta descrive ciò che crediamo su di essa	la previsione di quanti successi si osserveranno in nuove prove

Nella seconda lettura, la beta-binomiale è una **distribuzione predittiva**. Se l'incertezza su p prima dei dati è descritta da $p \sim \text{Beta}(\alpha, \beta)$, il numero di successi in n prove future segue una $\text{BetaBinomiale}(n, \alpha, \beta)$: è la distribuzione **predittiva a priori**. Dopo avere osservato y successi su n prove, la distribuzione a posteriori è $\text{Beta}(\alpha + y, \beta + n - y)$, come anticipato in Sezione 11.6, e il numero di successi in n' nuove prove segue

$$\tilde{Y} | y \sim \text{BetaBinomiale}(n', \alpha + y, \beta + n - y),$$

la distribuzione **predittiva a posteriori**.

Ad esempio, con prior $\text{Beta}(2, 2)$ e 7 successi su 10 prove, la posterior è $\text{Beta}(9, 5)$. Per 10 nuove prove, la deviazione standard della predittiva a posteriori è circa 1.92; quella di una binomiale che fissa p alla media a posteriori, $9/14$, è circa 1.52. La previsione che tratta p come noto sottostima l'incertezza, perché ignora l'incertezza residua sul parametro.

! Stessa formula, conseguenze diverse

Nella lettura come eterogeneità, la variabilità aggiuntiva è una proprietà della popolazione: osservare più studenti permette di descriverla meglio, ma non la elimina. Nella lettura come incertezza epistemica, la variabilità aggiuntiva dipende da ciò che non sappiamo: con più dati la posterior si concentra, κ cresce e la predittiva si avvicina a una binomiale.

11.8 Distribuzione di Poisson

11.8.1 Quando usarla

La distribuzione di Poisson è un possibile modello per il numero di eventi osservati in un intervallo di tempo, spazio o esposizione. La sua giustificazione richiede assunzioni idealizzate, tra cui:

- gli eventi sono conteggiabili e l'intervallo di osservazione è ben definito;
- il tasso medio è stabile nell'intervallo considerato;
- gli eventi in intervalli disgiunti sono approssimativamente indipendenti;

- in intervalli molto brevi, la probabilità di più eventi contemporanei è trascurabile rispetto a quella di un singolo evento.

In psicologia, esempi comuni sono:

- attacchi di panico in un mese;
- errori di omissione in un compito attentivo;
- risvegli notturni;
- comportamenti target osservati in una sessione.

11.8.2 Definizione

Definizione 11.5. Una variabile casuale Y segue una distribuzione di Poisson con parametro $\lambda > 0$ se:

$$Y \sim \text{Poisson}(\lambda), \quad P(Y = y) = \frac{\lambda^y e^{-\lambda}}{y!}, \quad y = 0, 1, 2, \dots$$

La sua proprietà caratteristica è:

$$\mathbb{E}(Y) = \mathbb{V}(Y) = \lambda.$$

Il parametro λ rappresenta il numero medio atteso di eventi nell'intervallo considerato. Se $\lambda = 2.5$, ci aspettiamo in media 2.5 eventi per intervallo, ma il numero osservato potrà essere 0, 1, 2, 3, e così via.

```
lambda <- 2.5
y <- 0:12
pois_df <- data.frame(
  y = y,
  probabilita = dpois(y, lambda = lambda)
)

ggplot(pois_df, aes(x = y, y = probabilita)) +
  geom_col() +
  scale_x_continuous(breaks = y) +
  labs(
    title = "Distribuzione di Poisson",
    subtitle = "Conteggi attesi con lambda = 2.5",
    x = "Numero di eventi",
    y = "Probabilità"
  )
```




Figura 11.7: Funzione di massa di una distribuzione di Poisson con tasso medio pari a 2,5 eventi per intervallo.

La Figura 11.7 mostra una distribuzione asimmetrica su conteggi interi non negativi; il parametro λ ne determina sia la media sia la varianza.

11.8.3 Esempio clinico

Un clinico sta monitorando il numero di attacchi di panico riportati da un paziente in un mese. Se il tasso medio atteso è $\lambda = 2.5$ attacchi al mese, allora:

$$Y \mid \lambda = 2.5 \sim \text{Poisson}(2.5).$$

```
set.seed(123)
mesi <- 24
attacchi <- rpois(mesi, lambda = 2.5)

data.frame(
  mese = 1:mesi,
  attacchi = attacchi
)
#>   mese attacchi
#> 1     1         2
#> 2     2         4
#> 3     3         2
#> 4     4         4
#> 5     5         5
#> 6     6         0
#> 7     7         2
#> 8     8         5
#> 9     9         3
#> 10    10         2
#> 11    11         5
#> 12    12         2
```

```
#> 13 13 3
#> 14 14 3
#> 15 15 1
#> 16 16 5
#> 17 17 1
#> 18 18 0
#> 19 19 2
#> 20 20 5
#> 21 21 4
#> 22 22 3
#> 23 23 3
#> 24 24 7
```

```
cat("Media osservata:", round(mean(attacchi), 2), "\n")
#> Media osservata: 3.04
cat("Varianza osservata:", round(var(attacchi), 2), "\n")
#> Varianza osservata: 3.09
```

Con pochi mesi di osservazione, media e varianza empiriche possono differire sensibilmente. Con molte osservazioni indipendenti generate da una Poisson, entrambe tendono verso λ . La somiglianza tra media e varianza è però soltanto una conseguenza necessaria del modello, non una prova sufficiente della sua adeguatezza.

11.8.4 Tassi ed esposizione

Spesso gli intervalli di osservazione non hanno la stessa durata. In questo caso non è sufficiente confrontare i conteggi grezzi: bisogna tenere conto dell'**esposizione**.

Se t_i è la durata dell'osservazione per l'unità i , possiamo scrivere:

$$Y_i | \lambda, t_i \sim \text{Poisson}(\lambda t_i),$$

dove λ è il tasso per unità di esposizione.

i Esempio

Osservare 4 comportamenti problema in 2 ore non ha lo stesso significato di osservarli in 20 minuti. Il conteggio è lo stesso, ma il tasso è diverso.

11.8.5 Ruolo bayesiano: prior Gamma per un tasso

Nel framework bayesiano, λ è una quantità incerta. Una scelta frequente per rappresentare l'incertezza su un tasso positivo è la distribuzione Gamma, presentata in Sezione 12.7.

Se

$$\lambda \sim \text{Gamma}(\alpha, \beta),$$

e osserviamo conteggi indipendenti $y_1, \dots, y_n$ su intervalli di uguale esposizione, allora:

$$\lambda \mid \mathbf{y} \sim \text{Gamma} \left(\alpha + \sum_{i=1}^n y_i, \beta + n \right),$$

nella parametrizzazione in cui β è il parametro di tasso della Gamma.

Per ora, il punto fondamentale è il seguente: la distribuzione di Poisson fornisce il modello dei conteggi, mentre la distribuzione Gamma rappresenta l'incertezza sul tasso che genera tali conteggi.

11.9 Quando i modelli discreti semplici non bastano

Le distribuzioni introdotte finora sono utili perché semplici e interpretabili. Proprio per questo, però, incorporano assunzioni forti.

11.9.1 Binomiale: indipendenza e probabilità costante

La distribuzione binomiale presuppone che tutte le prove abbiano la stessa probabilità p e siano indipendenti. Questa assunzione può essere problematica quando:

- gli item hanno difficoltà diverse;
- i partecipanti sono molto diversi tra loro;
- le prove successive sono influenzate dall'apprendimento, dalla fatica o dalla memoria;
- i dati provengono da gruppi o contesti differenti.

In questi casi la variabilità osservata può essere maggiore di quella prevista dalla distribuzione binomiale: si parla di **sovradispersione**. La distribuzione beta-binomiale (Sezione 11.7) è il modello più semplice che la rappresenta.

11.9.2 Poisson: equidispersione

La distribuzione di Poisson assume che media e varianza coincidano:

$$\mathbb{E}(Y) = \mathbb{V}(Y) = \lambda.$$

Nei dati psicologici, questa proprietà è spesso violata. Se la varianza è molto maggiore della media, una Poisson semplice può sottostimare la dispersione. Anche quando media e varianza sono simili, tuttavia, restano da controllare altre caratteristiche, come eccesso di zeri, dipendenza temporale ed eterogeneità tra individui.

Il modello analogo alla beta-binomiale per i conteggi di eventi è la **binomiale negativa**: si ottiene lasciando variare il tasso λ tra unità secondo una distribuzione Gamma (Sezione 12.7). Come nella beta-binomiale, l'eterogeneità dei tassi produce una varianza maggiore della media.

```
# Piccolo controllo descrittivo per dati di conteggio
media_attacchi <- mean(attacchi)
var_attacchi <- var(attacchi)
rapporto_dispersione <- var_attacchi / media_attacchi
```

```
cat("Media:", round(media_attacchi, 2), "\n")
#> Media: 3.04
cat("Varianza:", round(var_attacchi, 2), "\n")
#> Varianza: 3.09
cat("Varianza / media:", round(rapporto_dispersione, 2), "\n")
#> Varianza / media: 1.01
```

Il modello non è il fenomeno

Una distribuzione discreta è una rappresentazione semplificata del processo che potrebbe aver generato i dati. Non basta scegliere una distribuzione perché il dominio sembra corretto: bisogna chiedersi se le assunzioni del modello siano plausibili per il disegno di ricerca e per il fenomeno psicologico studiato.

Riflessioni conclusive

Le distribuzioni discrete introdotte in questo capitolo costituiscono un primo vocabolario per la modellazione dei dati psicologici. La distribuzione uniforme discreta rappresenta una simmetria tra alternative finite, la distribuzione di Bernoulli descrive un singolo esito binario, la distribuzione binomiale descrive il numero di successi in un numero fisso di prove, la distribuzione beta-binomiale descrive lo stesso conteggio quando la probabilità di successo varia tra unità o è incerta, e la distribuzione di Poisson è un modello possibile per il conteggio di eventi prodotti da un tasso stabile.

In prospettiva bayesiana, queste distribuzioni non sono soltanto formule per calcolare le probabilità. Esplicitano le assunzioni sul processo generativo. Dopo l'osservazione dei dati, le stesse espressioni possono essere considerate come verosimiglianze e, integrando l'incertezza sui parametri, contribuiscono alle distribuzioni predittive.

La scelta di una famiglia di distribuzioni non dipende quindi soltanto dal supporto. Bisogna chiedersi se l'indipendenza, la probabilità costante, il tasso stabile e l'equidispersione siano plausibili. Quando queste condizioni non sono soddisfatte, la soluzione non consiste nel forzare i dati nel modello più semplice, ma nel costruire una rappresentazione più adeguata dell'eterogeneità e della dipendenza.

11.9.1 Guida rapida: quale distribuzione usare?

Distribuzione	Supporto	Domanda modellata	Esempio psicologico	Parametro principale
Uniforme discreta	$\{1, \dots, N\}$	Quale alternativa viene selezionata se il modello le tratta simmetricamente?	Assegnazione casuale indipendente a condizioni	N
Bernoulli	$\{0, 1\}$	L'evento si verifica oppure no?	Risposta corretta a un item	p
Binomiale	$\{0, \dots, n\}$	Quanti successi si osservano in n prove <i>iid</i> ?	Numero di item corretti sotto probabilità costante	n, p
Beta-binomiale	$\{0, \dots, n\}$	Quanti successi si osservano in n prove, se la probabilità di successo varia tra unità o è incerta?	Numero di parole ricordate da studenti con capacità diverse	n, α, β oppure n, m, κ
Poisson	$\{0, 1, 2, \dots\}$	Quanti eventi si osservano in un intervallo con tasso stabile?	Numero di episodi riportati in un periodo	λ

Esercizi

1. Una variabile registra la presenza o l'assenza di un comportamento. Qual è il suo supporto e quale famiglia semplice può descrivere una singola osservazione?
2. Qual è la differenza tra modellare ogni risposta a un test con una Bernoulli e modellare il numero totale di risposte corrette con una binomiale?
3. Per una binomiale, che cosa restituiscono rispettivamente `dbinom(7, ...)` e `pbinom(7, ...)`?
4. In una distribuzione uniforme discreta su quattro condizioni, ciascuna condizione ha probabilità 1/4. Perché in 40 assegnazioni non è necessario osservare esattamente 10 persone per condizione?
5. Un test contiene item con difficoltà molto diverse. Quale assunzione del modello

binomiale diventa poco plausibile?

6. In un modello di Poisson, che cosa significa affermare che $\lambda = 2,5$ eventi al mese? Come cambia il numero atteso di eventi se l'osservazione dura due mesi?
7. Un insieme di conteggi ha media e varianza molto simili. Questo dimostra che una Poisson è il modello corretto? Spiega.
8. Una beta-binomiale è più dispersa di una binomiale con la stessa probabilità media. Quale fonte aggiuntiva di variabilità rappresenta?
9. Che cosa accade a una BetaBinomiale(n, α, β) quando la concentrazione $\kappa = \alpha + \beta$ diventa molto grande? E quando $\alpha = \beta = 1$?
10. Un test ha 10 item. La probabilità di risposta corretta varia tra partecipanti secondo una distribuzione Beta con media $m = 0,6$ e concentrazione $\kappa = 3$. Calcola la varianza del punteggio totale e confrontala con quella di una binomiale con $p = 0,6$.
11. In quale dei due scenari seguenti la beta-binomiale rappresenta eterogeneità e in quale incertezza epistemica? (a) La distribuzione dei punteggi in una classe di studenti con capacità diverse. (b) La previsione del numero di successi di una singola persona in 10 nuove prove, dopo averne osservate 10.
12. Perché, con una sola prova binaria per partecipante, non è possibile rilevare differenze tra partecipanti nella probabilità di successo?

Soluzioni

1. Il supporto è $\{0, 1\}$, dopo avere scelto una codifica per assenza e presenza. Una singola osservazione può essere descritta da una Bernoulli con parametro p , probabilità dell'esito codificato come 1.
2. La Bernoulli descrive una singola risposta binaria. La binomiale descrive il numero totale di successi in n prove, assumendo che le prove siano condizionatamente indipendenti e condividano la stessa probabilità p .
3. `dbinom(7, ...)` restituisce la probabilità di osservare esattamente 7 successi. `pbinom(7, ...)` restituisce la probabilità cumulata di osservarne al massimo 7.
4. L'equiprobabilità riguarda il meccanismo generativo, non le frequenze esatte in un campione finito. Le frequenze osservate oscillano casualmente intorno ai valori attesi. Un'assegnazione perfettamente bilanciata richiederebbe un vincolo aggiuntivo nel disegno.
5. Diventa poco plausibile l'ipotesi di una probabilità di successo costante per tutte le prove. Item di diversa difficoltà possono richiedere probabilità differenti o un modello che rappresenti esplicitamente tali differenze.
6. Il numero medio atteso è 2,5 eventi per mese. Se il tasso resta stabile e l'esposizione raddoppia, il numero atteso in due mesi è $2,5 \times 2 = 5$.
7. No. L'equidispersione è una conseguenza necessaria della Poisson, ma non è sufficiente a identificarla. Occorre controllare anche forma della

- distribuzione, zeri, dipendenza, stabilità del tasso ed eterogeneità.
8. Rappresenta l'incertezza o l'eterogeneità nella probabilità p . La predizione integra più valori possibili di p , invece di assumere un unico valore fissato per tutte le unità.
 9. Quando κ è molto grande, le probabilità individuali si concentrano attorno a m , il fattore $(\kappa + n)/(\kappa + 1)$ tende a 1 e la beta-binomiale tende alla Binomiale(n, m). Con $\alpha = \beta = 1$ la Beta è uniforme e la beta-binomiale assegna probabilità $1/(n + 1)$ a ciascun conteggio: è l'uniforme discreta su $\{0, \dots, n\}$.
 10. La varianza binomiale è $10 \times 0,6 \times 0,4 = 2,4$. Il fattore di inflazione è $(3 + 10)/(3 + 1) = 3,25$, quindi la varianza beta-binomiale è $2,4 \times 3,25 = 7,8$, con deviazione standard di circa 2,79 contro 1,55.
 11. (a) Eterogeneità: la Beta descrive differenze reali tra studenti, che non si riducono osservando più studenti. (b) Incertezza epistemica: la persona ha un'unica probabilità, non nota; la Beta è la distribuzione a posteriori e la beta-binomiale è la distribuzione predittiva a posteriori, che si avvicina a una binomiale al crescere dei dati.
 12. Con $n = 1$ il fattore di inflazione vale 1 e la beta-binomiale coincide con una Bernoulli di parametro m . La distribuzione dei dati dipende soltanto dalla probabilità media, e qualunque distribuzione delle probabilità individuali con la stessa media produce gli stessi dati. Per rilevare l'eterogeneità servono più prove per ciascuna unità.

i Punti chiave

- Una distribuzione discreta assegna probabilità a valori finiti o numerabili; la somma delle masse è uguale a 1.
- Il supporto descrive i valori ammessi, ma non basta da solo a scegliere una famiglia.
- Le funzioni d , p , q e r di R restituiscono rispettivamente massa o densità, probabilità cumulata, quantile e simulazioni.
- L'uniforme discreta tratta simmetricamente le alternative; questa simmetria è un'assunzione da giustificare.
- La Bernoulli descrive un singolo esito binario con probabilità p .
- La binomiale descrive un conteggio di successi quando le prove sono *iid* Bernoulli condizionatamente a p .
- La varianza della proporzione campionaria è $p(1 - p)/n$: campioni più grandi producono proporzioni più concentrate.
- La Poisson è un possibile modello per conteggi con tasso stabile ed equidispersione; media e varianza simili non ne dimostrano da sole l'adeguatezza.
- Esposizioni diverse richiedono di modellare il numero atteso come tasso per esposizione.

- La beta-binomiale descrive un conteggio di successi quando la probabilità varia tra unità secondo una Beta; ha la stessa media della binomiale con $p = m$ e varianza moltiplicata per $(\kappa + n)/(\kappa + 1)$.
- La sovradisersione deriva dalla varianza delle probabilità individuali; eterogeneità tra unità e dipendenza tra le prove di una stessa unità sono due aspetti dello stesso fenomeno.
- La stessa beta-binomiale descrive eterogeneità tra unità oppure, come distribuzione predittiva, incertezza su un'unica probabilità.
- Sovradispersione, eccesso di zeri, eterogeneità o dipendenza possono richiedere modelli più flessibili.
- Nel quadro bayesiano, la stessa famiglia può contribuire al modello dei dati, alla verosimiglianza o alla distribuzione predittiva.

i Ambiente di sviluppo

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Golden Gate 27.0
#>
#> Matrix products: default
#> BLAS:
#>   ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#>
#> LAPACK:
#>   ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   ↪ LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods
#> [7] base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.18.0
#> [3] withr_3.0.3         systemfonts_1.3.2
#> [5] patchwork_1.3.2     ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.16.0
#> [9] ggplot2_4.0.3       reliabilitydiag_0.2.1
#> [11] priorsense_1.2.0    posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7
#> [15] StanHeaders_2.39.1  brms_2.23.1
#> [17] Rcpp_1.1.2          sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1
#> [21] matrixStats_1.5.0   modelr_0.1.11
```

```

#> [23] tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2           rio_1.3.0
#> [27] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8          tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2              fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39         timechange_0.4.0     estimability_2.0.0
#> [10] lifecycle_1.0.5       magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0           tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51            labeling_0.4.3        bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8        curl_8.0.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8           purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1          xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4         scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2         rmarkdown_2.32        generics_0.1.4
#> [34] otel_0.2.0            RcppParallel_6.2.1    cachem_1.1.0
#> [37] stringr_1.6.0         parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0              Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2    glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1  lubridate_1.9.5       stringi_1.8.9
#> [49] gtable_0.3.6          QuickJSR_1.11.0       pillar_1.11.1
#> [52] htmltools_0.5.9       Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5     rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.23-1        backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13          snakecase_0.11.1      rstantools_2.7.1
#> [64] coda_0.19-4.1         gridExtra_2.3.1       nlme_3.1-171
#> [67] checkmate_2.3.4       xfun_0.60             pkgconfig_2.0.3

```


Distribuzioni di variabili casuali continue

i In sintesi

Da sapere Comprendere che, nel caso continuo, le probabilità sono aree sotto una densità; riconoscere supporto, forma e parametri delle principali distribuzioni continue; distinguere il ruolo di una distribuzione come modello dei dati, prior, distribuzione di un parametro che varia tra unità, componente della verosimiglianza o distribuzione predittiva.

Da saper fare Scegliere una famiglia compatibile con i valori possibili e con la forma attesa; interpretare i parametri di uniforme, normale, esponenziale, gamma, beta, chi-quadrato, t e Cauchy; spiegare che cosa restituiscono le funzioni d , p , q e r di R; leggere probabilità, quantili e simulazioni senza confondere densità e probabilità puntuale.

Introduzione

Nel Capitolo 11 abbiamo studiato variabili con valori finiti o numerabili, come risposte corrette o errate, numeri di successi e conteggi di eventi. In questo capitolo passiamo alle **variabili casuali continue**, usate per rappresentare quantità collocate su una scala numerica, come tempi, durate, effetti, tassi e proporzioni. Una di esse, la distribuzione beta, è già comparsa in Sezione 11.7 come distribuzione delle probabilità di successo di unità diverse; qui la presentiamo per esteso, insieme alle altre famiglie continue più usate.

La differenza fondamentale è che, per una variabile continua X , la probabilità di un singolo valore è nulla:

$$P(X = x) = 0.$$

Le probabilità riguardano invece intervalli e sono rappresentate da aree sotto una curva di densità. Dire che un valore puntuale ha probabilità zero non significa che sia impossibile: significa che, in un continuum, la probabilità si distribuisce su insiemi

di valori.

La prospettiva resta bayesiana, ma non svolgeremo ancora un'inferenza completa. Impareremo a riconoscere alcune importanti famiglie continue, le assunzioni che incorporano e i diversi ruoli che possono avere nel modello. Nel Capitolo 13 useremo questo vocabolario per comprendere quanta informazione contiene un campione; nel Capitolo 14 vedremo come il modello dei dati venga letto come funzione dei parametri dopo avere osservato i dati.

12.1 Perché le distribuzioni continue sono importanti in psicologia?

Molte quantità psicologiche vengono trattate mediante modelli continui: tempi di risposta, durate, punteggi standardizzati, differenze tra condizioni, effetti di regressione e parametri latenti. Anche quando lo strumento registra valori con precisione finita, un modello continuo può essere un'idealizzazione utile se rappresenta adeguatamente la scala e la variabilità del fenomeno.

La scelta della distribuzione rende esplicite domande sostanziali: la quantità può essere negativa? È limitata tra 0 e 1? È simmetrica o asimmetrica? I valori estremi devono essere molto rari oppure relativamente plausibili? Queste caratteristiche non sono dettagli tecnici: determinano quali dati il modello considera compatibili con il processo studiato.

i Cinque ruoli possibili

Una distribuzione continua può essere impiegata come:

1. **modello dei dati osservabili**, ad esempio una gamma per durate positive e asimmetriche;
2. **prior su un parametro**, ad esempio una beta su una probabilità o una normale su un effetto;
3. **distribuzione di un parametro che varia tra unità**, ad esempio una beta per le probabilità di successo di partecipanti diversi (Sezione 11.7) o una gamma per i tassi di eventi di pazienti diversi;
4. **componente della verosimiglianza**, quando i dati sono fissati e l'espressione viene considerata come funzione dei parametri;
5. **distribuzione predittiva**, quando si rappresentano i possibili valori di osservazioni future integrando l'incertezza sui parametri.

Il ruolo deve essere dichiarato: la stessa famiglia può comparire in punti diversi del modello con significati differenti.

💡 Prerequisiti

Per seguire il capitolo è utile avere letto Capitolo 6, Capitolo 7, Capitolo 8, Capitolo 10 e Capitolo 11. Per la notazione matematica, consulta Appendice A. Per richiami su integrali, derivate e funzioni, consulta le appendici matematiche disponibili nel Companion.

Panoramica del capitolo

Il capitolo procede in sette passaggi:

1. chiarisce il significato di densità, supporto e probabilità come area;
2. richiama le funzioni di R per densità, probabilità cumulate, quantili e simulazioni;
3. presenta le distribuzioni uniforme e normale;
4. introduce esponenziale e gamma per quantità positive;
5. presenta la beta per probabilità e proporzioni, collegandola alla beta-binomiale del capitolo precedente;
6. collega chi-quadrato, t di Student e Cauchy alle distribuzioni a code più o meno pesanti;
7. propone criteri per scegliere una famiglia continua coerente con il problema.

i Preparazione del notebook

```
here::here("code", "_common.R") |>  
  source()  
  apply_visual_theme()
```

12.2 Che cosa descrive una distribuzione continua?

Una distribuzione continua descrive una variabile casuale che può assumere valori in un intervallo della retta reale. La distribuzione è rappresentata da una **funzione di densità** $f(x)$.

Una funzione di densità deve soddisfare due condizioni:

$$f(x) \geq 0, \quad \int_{-\infty}^{+\infty} f(x) dx = 1.$$

La probabilità che X cada in un intervallo $[a, b]$ è data dall'area sotto la densità:

$$P(a \leq X \leq b) = \int_a^b f(x) dx.$$

!

Densità non significa probabilità puntuale

Per una variabile continua, il valore $f(x)$ non è una probabilità. Può anche essere maggiore di 1. La probabilità è sempre un'area sotto la curva, cioè l'integrale della densità su un intervallo.

Questa distinzione sarà importante nel capitolo sulla verosimiglianza: una densità può essere usata per confrontare valori del parametro, ma non deve essere confusa con una probabilità assegnata a un singolo punto.

12.2.1 Supporto della distribuzione

Il **supporto** è l'insieme dei valori che una variabile può assumere. Alcuni esempi:

Distribuzione	Supporto	Uso tipico
Uniforme(a, b)	$[a, b]$	quantità limitata a un intervallo
Normale(μ, σ^2)	$\mathbb{R}$	misure simmetriche, errori additivi, effetti
Esponenziale(λ)	$[0, \infty)$	tempi di attesa con tasso costante
Gamma(α, β)	$(0, \infty)$	durate e parametri positivi
Beta(α, β)	$(0, 1)$	probabilità e proporzioni senza valori esatti 0 o 1
t_ν	$\mathbb{R}$	dati o parametri simmetrici con code più pesanti
Cauchy(x_0, s)	$\mathbb{R}$	prior a code molto pesanti, con scala da giustificare

La prima domanda pratica, quando scegliamo una distribuzione, è quindi: **quali valori sono possibili per la variabile o per il parametro?** Il supporto permette di escludere famiglie incompatibili, ma non identifica da solo il modello appropriato.

12.3 Le funzioni R per le distribuzioni continue

R usa la stessa convenzione vista per le distribuzioni discrete. Ogni famiglia ha quattro funzioni principali:

Prefisso	Significato	Esempio con la normale
d	densità	<code>dnorm(x, mean, sd)</code>
p	probabilità cumulata	<code>pnorm(x, mean, sd)</code>
q	quantile	<code>qnorm(p, mean, sd)</code>
r	generazione casuale	<code>rnorm(n, mean, sd)</code>

Esempio: consideriamo punteggi standardizzati approssimativamente distribuiti come

$$X \sim \mathcal{N}(100, 15^2).$$

```
mu <- 100
sigma <- 15

# Densità nel punto 100: non è una probabilità puntuale.
densita_100 <- dnorm(100, mean = mu, sd = sigma)

# Probabilità di osservare un punteggio tra 85 e 115.
prob_85_115 <- pnorm(115, mean = mu, sd = sigma) -
  pnorm(85, mean = mu, sd = sigma)

# Quantile che lascia sotto di sé il 95% della distribuzione.
q_95 <- qnorm(0.95, mean = mu, sd = sigma)

# Cinque valori simulati.
set.seed(1)
simulazioni <- rnorm(5, mean = mu, sd = sigma)

densita_100
#> [1] 0.0266
prob_85_115
#> [1] 0.683
q_95
#> [1] 125
simulazioni
#> [1] 90.6 102.8 87.5 123.9 104.9
```

i Una lettura bayesiana delle simulazioni

Quando usiamo funzioni come `rnorm()` o `rgamma()`, non stiamo solo producendo numeri casuali. Stiamo simulando dati o parametri **sotto un modello**. Questa abitudine sarà utile nei capitoli successivi: simulare da una prior, da una distribuzione predittiva o da una posterior permette di rendere visibile l'incertezza.

12.4 Distribuzione uniforme continua

12.4.1 Definizione

La distribuzione uniforme continua assegna la stessa densità a tutti i valori di un intervallo finito $[a, b]$.

Definizione 12.1. Una variabile casuale X segue una distribuzione uniforme continua su $[a, b]$ se

$$X \sim \text{Uniforme}(a, b), \quad f(x) = \frac{1}{b-a}, \quad a \leq x \leq b,$$

mentre $f(x) = 0$ fuori dall'intervallo.

Le proprietà principali sono:

$$\mathbb{E}(X) = \frac{a+b}{2}, \quad \mathbb{V}(X) = \frac{(b-a)^2}{12}.$$

12.4.2 Interpretazione

La distribuzione uniforme rappresenta una scelta di **simmetria rispetto alla scala adottata**: all'interno di un intervallo, sottointervalli della stessa lunghezza ricevono la stessa probabilità.

Ad esempio, se decidiamo di trattare allo stesso modo intervalli della stessa ampiezza sulla scala di una probabilità, possiamo usare

$$\theta \sim \text{Uniforme}(0, 1).$$

Questa scelta coincide con una distribuzione Beta(1, 1).

La prior uniforme non è sempre neutrale

Una prior uniforme può sembrare non informativa, ma non è automaticamente neutrale. La sua forma dipende dalla scala scelta. Una prior uniforme su θ non corrisponde a una prior uniforme su una trasformazione non lineare, come $\log(\theta)$ o θ^2 .

La scelta non è neutrale nemmeno rispetto ai dati che il modello prevede. In Sezione 11.7 abbiamo visto che, se $\theta \sim \text{Uniforme}(0, 1)$ e il numero di successi in n prove segue una binomiale, ogni conteggio da 0 a n ha probabilità $1/(n+1)$. Con 10 prove, ottenere 0, 1 o 10 successi ha complessivamente probabilità $3/11 \approx 0.27$: una prior piatta sul parametro implica che i risultati estremi siano plausibili quanto quelli centrali.

Inoltre, una distribuzione uniforme su un intervallo finito esclude a priori tutti i valori fuori da quell'intervallo. Questa può essere una scelta ragionevole solo se il vincolo è davvero parte del problema.

12.4.3 Probabilità come lunghezza relativa

Per $X \sim \text{Uniforme}(a, b)$,

$$P(c \leq X \leq d) = \frac{d - c}{b - a}, \quad a \leq c < d \leq b.$$

Esempio: uno spinner su un intervallo da 0 a 360 gradi.

```
prob <- punif(250, min = 0, max = 360) -
  punif(150, min = 0, max = 360)

prob
#> [1] 0.278

x <- seq(0, 360, length.out = 500)
df_unif <- data.frame(
  x = x,
  densita = dunif(x, min = 0, max = 360),
  area = x >= 150 & x <= 250
)

ggplot(df_unif, aes(x = x, y = densita)) +
  geom_line(linewidth = 1) +
  geom_area(
    data = subset(df_unif, area),
    alpha = 0.4
  ) +
  labs(
    title = "Distribuzione uniforme continua",
    subtitle = "Area evidenziata: P(150 <= X <= 250)",
    x = "Valore",
    y = "Densità"
  )
```




Figura 12.1: Distribuzione uniforme su $[0, 360]$ con evidenziato l'intervallo tra 150 e 250 gradi.

La Figura 12.1 mostra che la probabilità dell'intervallo evidenziato dipende dalla sua lunghezza relativa, non dall'altezza della densità in un singolo punto.

12.5 Distribuzione normale

12.5.1 Definizione

La distribuzione normale, o gaussiana, è una delle distribuzioni continue più importanti. È adatta a rappresentare misure che variano attorno a un centro e che hanno deviazioni approssimativamente simmetriche.

Definizione 12.2. Una variabile casuale Y segue una distribuzione normale con media μ e deviazione standard $\sigma > 0$ se

$$Y \sim \mathcal{N}(\mu, \sigma^2),$$

con densità

$$f(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(y - \mu)^2}{2\sigma^2}\right].$$

Le proprietà principali sono:

$$\mathbb{E}(Y) = \mu, \quad \mathbb{V}(Y) = \sigma^2.$$

12.5.2 Interpretazione dei parametri

- μ è il centro della distribuzione: valori maggiori di μ spostano la curva verso destra, valori minori verso sinistra.
- σ è la scala della variabilità: valori maggiori producono curve più larghe e meno concentrate.

In psicologia, la normale è spesso un modello utile per punteggi standardizzati, errori di misura, effetti continui e medie campionarie. Va però usata come **approssimazione**, non come descrizione automatica di qualunque fenomeno psicologico.

i Perché la normale è così importante?

La normale compare spesso per due ragioni diverse:

1. può essere un modello ragionevole per alcune misure continue approssimativamente simmetriche;
2. nel Capitolo 13 vedremo che, sotto opportune condizioni, distribuzioni di somme o medie standardizzate possono avvicinarsi alla normale.

Il secondo punto, legato al teorema del limite centrale, riguarda la distribuzione campionaria di una statistica e non implica che i dati individuali siano necessariamente normali.

12.5.3 Regola 68-95-99.7

Per una distribuzione normale:

- circa il 68% della massa si trova entro $\mu \pm 1\sigma$;
- circa il 95% entro $\mu \pm 1.96\sigma$;
- circa il 99.7% entro $\mu \pm 3\sigma$.

```
mu <- 100
sigma <- 15

x <- seq(mu - 4 * sigma, mu + 4 * sigma, length.out = 1000)
df_norm <- data.frame(
  x = x,
  densita = dnorm(x, mean = mu, sd = sigma),
  centrale_95 = x >= mu - 1.96 * sigma & x <= mu + 1.96 * sigma
)

ggplot(df_norm, aes(x = x, y = densita)) +
  geom_line(linewidth = 1) +
  geom_area(
    data = subset(df_norm, centrale_95),
    alpha = 0.4
  ) +
  geom_vline(xintercept = mu - 1.96 * sigma, linetype = "dashed") +
  geom_vline(xintercept = mu + 1.96 * sigma, linetype = "dashed") +
  labs(
    title = "Distribuzione normale e intervallo centrale al 95%",
    subtitle = "Esempio: N(100, 15^2)",
    x = "Valore",
    y = "Densità"
  )
```




Figura 12.2: Distribuzione normale N(100, 15²) con evidenziato l'intervallo centrale che contiene circa il 95% della probabilità.

Nella Figura 12.2 l'area evidenziata è circa 0,95. Le linee tratteggiate delimitano un intervallo della distribuzione teorica, non un intervallo di credibilità per un parametro.

12.5.4 Quando la normale non è appropriata

La normale ha supporto su tutta la retta reale. Questo può essere problematico per variabili che sono vincolate:

- tempi di risposta e durate, che sono sempre positivi e spesso asimmetrici;
- conteggi di errori o sintomi, che sono discreti;
- proporzioni, che sono limitate tra 0 e 1;
- scale Likert con pochi livelli, che sono ordinali e limitate.

 Non normalizzare tutto

La normale è comoda, ma non deve diventare una scelta automatica. Una buona modellazione parte dalla natura del dato: supporto, simmetria, presenza di code pesanti, vincoli inferiori o superiori, e significato psicologico della variabile.

12.6 Distribuzione esponenziale

12.6.1 Definizione

La distribuzione esponenziale modella il tempo di attesa fino al verificarsi di un evento quando il tasso di occorrenza è costante nel tempo.

Definizione 12.3. Una variabile casuale T segue una distribuzione esponenziale con tasso $\lambda > 0$ se

$$T \sim \text{Exp}(\lambda), \quad f(t) = \lambda e^{-\lambda t}, \quad t \geq 0.$$

Le proprietà principali sono:

$$\mathbb{E}(T) = \frac{1}{\lambda}, \quad \mathbb{V}(T) = \frac{1}{\lambda^2}.$$

Il parametro λ è un **tasso**: eventi attesi per unità di tempo. Il suo inverso, $1/\lambda$, è il tempo medio di attesa.

12.6.2 Assenza di memoria

La caratteristica distintiva della distribuzione esponenziale è la proprietà di **assenza di memoria**:

$$P(T > s + t \mid T > s) = P(T > t).$$

In altre parole: aver già atteso fino a s non modifica la distribuzione dell'attesa residua. È una proprietà molto restrittiva; l'esponenziale è dunque appropriata solo quando il tasso costante è un'assunzione plausibile.

12.6.3 Esempio: tempo di attesa

Supponiamo che il tempo medio di attesa per un evento sia 4 giorni. Allora $\lambda = 1/4 = 0.25$.

```
lambda <- 0.25

# Probabilità di attendere al massimo 1,5 giorni.
pexp(1.5, rate = lambda)
#> [1] 0.313

# Probabilità di attendere tra 1 e 6 giorni.
pexp(6, rate = lambda) - pexp(1, rate = lambda)
#> [1] 0.556


x <- seq(0, 20, length.out= 500)
df_exp <- data.frame(
  x = x,
  densita = dexp(x, rate = lambda),
  area = x >= 1 & x <= 6
)

ggplot(df_exp, aes(x = x, y = densita)) +
  geom_line(linewidth = 1) +
  geom_area(data = subset(df_exp, area), alpha = 0.4) +
  labs(
    title = "Distribuzione esponenziale",
    subtitle = "Area evidenziata: P(1 <= T <= 6)",
    x = "Tempo di attesa",
    y = "Densità"
  )
```




Figura 12.3: Distribuzione esponenziale con tasso 0,25 e probabilità associata all'intervallo tra 1 e 6 giorni.

La Figura 12.3 rende visibile che la probabilità di attendere tra 1 e 6 giorni è l'area compresa tra i due limiti.

i Applicazioni psicologiche

L'esponenziale può essere utile per modellare le durate o i tempi tra gli eventi quando il rischio istantaneo è approssimativamente costante, ad esempio il tempo necessario per distrarsi, l'intervallo tra i comportamenti osservabili o il tempo necessario perché si verifichi un evento in un compito sperimentale. Per i tempi di reazione, tuttavia, l'esponenziale è spesso troppo semplice: distribuzioni come la log-normale, la gamma o l'ex-Gaussiana possono essere più realistiche.

12.7 Distribuzione gamma

12.7.1 Definizione

La distribuzione gamma è una famiglia flessibile per le variabili positive. Può essere utilizzata per modellare tempi, durate e altre quantità strettamente positive. Può inoltre rappresentare l'incertezza su alcuni parametri positivi, come tassi o precisioni, quando tale scelta è sostanzialmente giustificata.

In R useremo la parametrizzazione **shape-rate**.

Definizione 12.4. Una variabile casuale X segue una distribuzione gamma con parametri $\alpha > 0$ e $\beta > 0$ se

$$X \sim \text{Gamma}(\alpha, \beta),$$

con densità

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0.$$

Le sue proprietà principali sono:

$$\mathbb{E}(X) = \frac{\alpha}{\beta}, \quad \mathbb{V}(X) = \frac{\alpha}{\beta^2}.$$

Il parametro α contribuisce a determinare la forma, mentre β è un parametro di tasso: a parità di α , valori maggiori di β concentrano la distribuzione verso valori più piccoli. In R si usa `dgamma(x, shape = alpha, rate = beta)`.

Rate e scale

Spesso, la gamma è parametrizzata anche con un parametro di scala $\theta = 1/\beta$. In R, l'argomento `rate` usa β , mentre l'argomento `scale` usa $1/\beta$. Prima di utilizzare R è necessario verificare la parametrizzazione.

12.7.2 Relazione con l'esponenziale

L'esponenziale è un caso particolare della gamma:

$$\text{Exp}(\lambda) = \text{Gamma}(1, \lambda).$$

In un processo a tasso costante, la gamma esprime il tempo necessario ad accumulare più eventi. Se α è un intero positivo e il processo soddisfa le assunzioni richieste, la gamma descrive l'attesa fino al verificarsi di α eventi.

12.7.3 Ruolo bayesiano

Nel percorso bayesiano, la gamma è importante per parametri positivi:

- come prior per un tasso $\lambda > 0$;
- come possibile prior per una precisione $\tau = 1/\sigma^2$;
- come modello per durate positive e asimmetriche.

La distribuzione gamma è una prior coniugata per il tasso λ di un modello di Poisson. Se nel capitolo precedente abbiamo scritto

$$Y_i | \lambda \sim \text{Poisson}(\lambda),$$

allora una prior gamma su λ genera una posterior ancora gamma. Tornerà utile quando affronteremo più esplicitamente l'aggiornamento bayesiano.

Come la beta per le probabilità, la gamma può anche descrivere **differenze tra unità** nel tasso di eventi. Se ogni paziente ha un proprio tasso $\lambda_i \sim \text{Gamma}(\alpha, \beta)$ e $Y_i | \lambda_i \sim \text{Poisson}(\lambda_i)$, la distribuzione marginale dei conteggi è una **binomiale negativa**, con media α/β e varianza $\alpha/\beta + \alpha/\beta^2$, maggiore della media. È l'analogo,

per i conteggi di eventi, della beta-binomiale per i conteggi di successi (Sezione 11.7, Sezione 11.9).

12.7.4 Flessibilità della forma

```
x <- seq(0, 10, length.out = 500)
params_gamma <- data.frame(
  a_par = c(1, 2, 4, 9),
  b_par = c(1, 1, 1, 2)
)

df_gamma <- do.call(rbind, lapply(seq_len(nrow(params_gamma)), function(i)
  {
    a_par <- params_gamma$a_par[i]
    b_par <- params_gamma$b_par[i]
    data.frame(
      x = x,
      densita = dgamma(x, shape = a_par, rate = b_par),
      distribuzione = paste0("Gamma(", a_par, ", ", b_par, ")")
    )
  }
))

ggplot(df_gamma, aes(x = x, y = densita, color = distribuzione)) +
  geom_line(linewidth = 1) +
  labs(
    title = "Flessibilità della distribuzione gamma",
    x = "x",
    y = "Densità",
    color = "Distribuzione"
  )
```




Figura 12.4: Esempi di distribuzioni gamma nella parametrizzazione shape-rate.

La Figura 12.4 mostra che la famiglia gamma può assumere forme molto diverse. I parametri non vanno quindi interpretati separatamente dalla parametrizzazione e dalla scala del fenomeno.

 Anticipazione: aggiornamento Gamma-Poisson

Se $\lambda \sim \text{Gamma}(\alpha_0, \beta_0)$ e osserviamo conteggi Poisson indipendenti $y_1, \dots, y_n$, allora

$$\lambda \mid y \sim \text{Gamma}\left(\alpha_0 + \sum_{i=1}^n y_i, \beta_0 + n\right).$$

Questa formula non è ancora il tema centrale del capitolo, ma serve solo a mostrare perché la gamma è una distribuzione così utile nel vocabolario bayesiano.

12.8 Distribuzione beta

12.8.1 Definizione

La distribuzione beta è definita sull'intervallo $(0, 1)$. È dunque una famiglia particolarmente utile per rappresentare l'incertezza su probabilità e proporzioni che non assumono esattamente i valori 0 o 1.

Definizione 12.5. Una variabile casuale θ segue una distribuzione beta con parametri $\alpha > 0$ e $\beta > 0$ se

$$\theta \sim \text{Beta}(\alpha, \beta),$$

con densità

$$f(\theta) = \frac{\theta^{\alpha-1} (1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1.$$

Le proprietà principali sono:

$$\mathbb{E}(\theta) = \frac{\alpha}{\alpha + \beta},$$

$$\mathbb{V}(\theta) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

12.8.2 Media e concentrazione

Conviene introdurre subito una riparametrizzazione, già anticipata in Sezione 11.7, che useremo costantemente:

$$m = \frac{\alpha}{\alpha + \beta}, \quad \kappa = \alpha + \beta,$$

da cui si ricavano immediatamente $\alpha = m\kappa$ e $\beta = (1 - m)\kappa$. Il primo parametro individua il centro della distribuzione, il secondo quanto la massa di probabilità si addensa attorno a quel centro.

Che κ misuri davvero una concentrazione non è un'affermazione qualitativa: riscrivendo la varianza in termini di m e κ si ottiene

$$\mathbb{V}(\theta) = \frac{m(1-m)}{\kappa+1}.$$

A parità di media, l'incertezza è dunque inversamente proporzionale a $\kappa + 1$. Due distribuzioni con la stessa media, come $\text{Beta}(2, 2)$ e $\text{Beta}(20, 20)$, descrivono stati di conoscenza molto diversi: la prima ha $\kappa = 4$, la seconda $\kappa = 40$, e la varianza della seconda è circa otto volte più piccola.

La frazione $1/(\kappa + 1)$ ha una lettura precisa quando la beta descrive le probabilità di successo di unità diverse. Una singola prova di un'unità scelta a caso è una Bernoulli di parametro m , con varianza $m(1 - m)$. Per la legge della varianza totale (Sezione 11.7), questa varianza si scompone in una parte dovuta alla variabilità entro ciascuna unità e in una parte dovuta alle differenze tra unità, che è proprio $\mathbb{V}(\theta)$:

$$\frac{\mathbb{V}(\theta)}{m(1-m)} = \frac{1}{\kappa+1}.$$

È la stessa quantità che in Sezione 11.7 misurava la correlazione tra due prove della stessa unità. Ad esempio, con $m = 0.6$ e $\kappa = 3$, un quarto della varianza di una singola prova è dovuto alle differenze tra unità.

12.8.3 Interpretazione dei parametri

La beta è particolarmente intuitiva in un contesto bayesiano. Quando descrive l'incertezza su una probabilità, i suoi parametri si possono leggere come una forma di informazione preliminare:

- il rapporto $\alpha/(\alpha + \beta)$ determina la media;
- la somma $\alpha + \beta$ funge da parametro di concentrazione a parità di media;
- valori inferiori, uguali o superiori a 1 producono forme molto diverse, comprese densità a U, uniformi o unimodali.

Una distribuzione $\text{Beta}(1, 1)$ è uniforme su $(0, 1)$. Una $\text{Beta}(20, 10)$ ha media $2/3$ ed è relativamente concentrata attorno a valori elevati. L'interpretazione di questi parametri dipende dal modello e dalla convenzione adottata.

i Pseudo-osservazioni: due convenzioni, e quando usarle

Nella letteratura sulla beta si trovano due modi di interpretare i parametri come conteggi. I due metodi non sono in competizione e la scelta tra loro non è una questione di stile: ciascuno è corretto per una diversa sintesi della distribuzione a posteriori.

Convenzione A — α e β come conteggi. α rappresenta il numero di successi

e β il numero di insuccessi. Un prior Beta(2,2) corrisponde a «2 successi e 2 insuccessi», ovvero a 4 osservazioni preliminari. Con questa interpretazione, il peso del prior è $\kappa = \alpha + \beta$, ed è l'interpretazione corretta per la **media** a posteriori, che si scrive esattamente come una media ponderata:

$$\mathbb{E}[\theta | y] = \frac{\alpha + y}{\alpha + \beta + n} = \frac{\kappa}{\kappa + n} m + \frac{n}{\kappa + n} \frac{y}{n}, \quad m = \frac{\alpha}{\alpha + \beta}.$$

Convenzione B — $\alpha - 1$ e $\beta - 1$ come conteggi. $\alpha - 1$ rappresenta il numero di pseudo-successi e $\beta - 1$ il numero di pseudo-insuccessi. Questa convenzione deriva dalla forma della densità, i cui esponenti sono $\alpha - 1$ e $\beta - 1$. Se il prior deve contribuire agli esponenti come se fossero dei conteggi, allora i conteggi sono $\alpha - 1$ e $\beta - 1$. Con questa interpretazione, il peso del prior è $\kappa' = \alpha + \beta - 2$ ed è l'interpretazione corretta per la **moda** a posteriori, che ha una struttura identica alla precedente:

$$\text{moda}[\theta | y] = \frac{\alpha + y - 1}{\alpha + \beta + n - 2} = \frac{\kappa'}{\kappa' + n} m' + \frac{n}{\kappa' + n} \frac{y}{n}, \quad m' = \frac{\alpha - 1}{\alpha + \beta - 2}.$$

La differenza si nota soprattutto sul prior uniforme Beta(1,1), che pesa come **2** osservazioni sulla media e come **0** osservazioni sulla moda:

$$\mathbb{E}[\theta | y] = \frac{y + 1}{n + 2}, \quad \text{moda}[\theta | y] = \frac{y}{n}.$$

La prima è la regola di successione di Laplace: il prior uniforme sposta la stima verso 1/2. La seconda coincide con la proporzione osservata, ovvero con la stima di massima verosimiglianza, e su tale stima il prior uniforme non ha alcun effetto. Entrambe le affermazioni sono corrette perché si riferiscono a due quantità diverse della stessa distribuzione.

In questo testo seguiremo la **convenzione A**, per due ragioni. La prima è che riportiamo abitualmente la media a posteriori e, per tale sintesi, $\kappa = \alpha + \beta$ rappresenta il peso esatto. La seconda è che la convenzione B produce conteggi negativi quando $\alpha < 1$ o $\beta < 1$: il prior di Jeffreys Beta(0.5,0.5) diventerebbe «-0.5 pseudo-successi». Ciò non avviene a caso, in quanto proprio in quelle situazioni la densità è a U e la moda non è interna all'intervallo, venendo così a mancare la quantità in base alla quale la convenzione B è definita.

La matematica dell'aggiornamento non cambia in nessuno dei due casi — la formula resta $\theta | y \sim \text{Beta}(\alpha + y, \beta + n - y)$; cambia, però, il modo di raccontare quanto il prior «pesa». Resta valido l'avvertimento di fondo: la beta rappresenta una distribuzione di credenze e non necessariamente un vero campione precedente.

La lettura in termini di pseudo-osservazioni vale inoltre soltanto quando la beta descrive l'incertezza su un'unica probabilità. Quando descrive le probabilità di unità diverse, come nella beta-binomiale di Sezione 11.7, κ non è un numero di osservazioni: indica quanto le probabilità individuali sono simili fra loro.

12.8.4 Ruolo bayesiano

La distribuzione beta è la prior coniugata naturale per il parametro di una distribuzione di Bernoulli o binomiale:

$$Y | \theta \sim \text{Binomiale}(n, \theta), \quad \theta \sim \text{Beta}(\alpha, \beta).$$

Dopo aver osservato y successi su n prove, la distribuzione a posteriori è:

$$\theta | y \sim \text{Beta}(\alpha + y, \beta + n - y).$$

Nei capitoli successivi, useremo questo modello per mettere in relazione la proporzione campionaria, l'incertezza sul parametro e le informazioni fornite dai dati.

La beta interviene anche nella distribuzione beta-binomiale (Sezione 11.7), in due letture diverse. Se la beta descrive l'incertezza su θ , il numero di successi in n prove future segue una beta-binomiale: con la beta a priori si ottiene la distribuzione predittiva a priori, con la beta a posteriori $\text{Beta}(\alpha + y, \beta + n - y)$ quella a posteriori. Se invece la beta descrive le differenze di probabilità tra unità, la beta-binomiale è la distribuzione dei conteggi di successi nella popolazione. In entrambi i casi la beta fornisce la distribuzione del parametro e la binomiale quella dei dati, condizionatamente al parametro.

12.8.5 Forme possibili

La flessibilità della beta dipende da come α e β si collocano rispetto a 1:

Valori dei parametri	Forma della densità
$\alpha < 1$ e $\beta < 1$	a U: la massa si concentra agli estremi, e la densità diverge in 0 e in 1
$\alpha = \beta = 1$	uniforme su $(0, 1)$
$\alpha > 1$ e $\beta > 1$	unimodale, con moda in $(\alpha - 1) / (\alpha + \beta - 2)$
$\alpha = \beta$	simmetrica attorno a $1/2$
$\alpha \neq \beta$ (entrambi > 1)	asimmetrica, con la coda più lunga dalla parte del parametro minore

```
x <- seq(0.001, 0.999, length.out = 500)
```

```
params_beta <- data.frame(
  a_par = c(0.5, 1, 2, 2, 5, 20),
  b_par = c(0.5, 1, 2, 5, 2, 10)
)
```

```
df_beta <- do.call(rbind, lapply(seq_len(nrow(params_beta)), function(i) {
  a_par <- params_beta$a_par[i]
  b_par <- params_beta$b_par[i]
  data.frame(
    x = x,
    densita = dbeta(x, shape1 = a_par, shape2 = b_par),
  )
}))
```

```

    distribuzione = paste0("Beta(", a_par, ", ", b_par, ")")
  )
}))

ggplot(df_beta, aes(x = x, y = densita, color = distribuzione)) +
  geom_line(linewidth = 1) +
  coord_cartesian(ylim = c(0, 6)) +
  labs(
    title = "Flessibilità della distribuzione beta",
    subtitle = "La beta può assumere forme diffuse, uniformi o
      concentrate",
    x = expression(theta),
    y = "Densità",
    color = "Distribuzione"
  )
)

```




Figura 12.5: Forme diverse della distribuzione beta al variare dei parametri di forma.

La Figura 12.5 mostra che la beta non è necessariamente unimodale, ma può assumere diverse forme: a U, uniforme, simmetrica o asimmetrica. Affermare genericamente che la prior è “non informativa” senza specificarne la forma è quindi fuorviante. Le tre forme più comuni a cui viene attribuito questo titolo — Beta(1, 1), Beta(0.5, 0.5) e il limite Beta(0, 0) — hanno forme molto diverse fra loro e, a parità di dati, producono distribuzioni a posteriori distinte: la prima attira la stima verso 1/2, le altre due la lasciano più vicina alla proporzione osservata.

12.9 Distribuzione chi-quadrato

12.9.1 Definizione

La distribuzione chi-quadrato nasce dalla somma di quadrati di variabili normali standard indipendenti.

Definizione 12.6. Se

$$Z_1, \dots, Z_k \stackrel{iid}{\sim} \mathcal{N}(0, 1),$$

allora

$$X = Z_1^2 + \dots + Z_k^2 \sim \chi_k^2.$$

Il parametro k è il numero di gradi di libertà. Le proprietà principali sono:

$$\mathbb{E}(X) = k, \quad \mathbb{V}(X) = 2k.$$

12.9.2 Interpretazione

La chi-quadrato misura una dispersione quadratica: somma le deviazioni standardizzate, le eleva al quadrato e quindi considera la grandezza complessiva dello scostamento, a prescindere dal segno.

Si tratta di un caso particolare della distribuzione gamma (Sezione 12.7):

$$\chi_k^2 = \text{Gamma}\left(\frac{k}{2}, \frac{1}{2}\right)$$

nella parametrizzazione shape-rate.

12.9.3 Ruolo bayesiano

La chi-quadrato è importante perché compare nella teoria della varianza campionaria e, indirettamente, nei modelli normali con varianza sconosciuta. Nelle formulazioni bayesiane moderne si lavora spesso con distribuzioni gamma o inverse-gamma per varianze e precisioni, ma la chi-quadrato rimane un ponte concettuale utile.

```
x <- seq(0, 40, length.out = 500)
df_chisq <- data.frame(
  x = rep(x, 4),
  densita = c(dchisq(x, df = 2), dchisq(x, df = 4),
              dchisq(x, df = 8), dchisq(x, df = 16)),
  df = rep(c("2", "4", "8", "16"), each = length(x))
)

ggplot(df_chisq, aes(x = x, y = densita, color = df)) +
  geom_line(linewidth = 1) +
  labs(
    title = "Distribuzione chi-quadrato",
```

```

subtitle = "All'aumentare dei gradi di libertà la distribuzione diventa
  ↳ meno asimmetrica",
x = "x",
y = "Densità",
color = "Gradi di libertà"
)

```




Figura 12.6: Distribuzioni chi-quadrato con diversi gradi di libertà.

La Figura 12.6 mostra che, con pochi gradi di libertà, la distribuzione è fortemente asimmetrica; aumentando i gradi di libertà, la massa si sposta verso destra e la forma diventa relativamente meno asimmetrica.

12.10 Distribuzione t di Student

12.10.1 Definizione

La distribuzione t di Student emerge quando una variabile normale viene standardizzata utilizzando una stima incerta della sua varianza.

Definizione 12.7. Se $Z \sim \mathcal{N}(0, 1)$, $W \sim \chi^2_\nu$ e Z e W sono indipendenti, allora

$$T = \frac{Z}{\sqrt{W/\nu}} \sim t_\nu.$$

Il parametro ν rappresenta i gradi di libertà.

12.10.2 Interpretazione

La t assomiglia alla normale, ma ha **code più pesanti**, soprattutto quando ν è piccolo. Ciò significa che assegna maggiore plausibilità a valori lontani dal centro.

Quando ν aumenta, la t tende alla distribuzione normale standard. Per $\nu > 1$ la media esiste ed è 0 nella forma standard; per $\nu > 2$ la varianza è finita.

12.10.3 Ruolo bayesiano

La t è utile in due modi:

1. come modello dei dati o distribuzione predittiva quando si vogliono rappresentare code più pesanti della normale;
2. come prior a code pesanti per parametri continui, scegliendo posizione, scala e gradi di libertà in modo coerente con il problema.

Come modello dei dati, una t può ridurre l'influenza relativa delle osservazioni estreme rispetto a una normale. Come prior, invece, le code pesanti non garantiscono da sole robustezza o stabilità computazionale.

```
x <- seq(-5, 5, length.out = 500)
df_t <- data.frame(
  x = rep(x, 4),
  densita = c(dnorm(x), dt(x, df = 1), dt(x, df = 3), dt(x, df = 10)),
  distribuzione = rep(c("Normale", "t(1)", "t(3)", "t(10)"), each =
    ↪ length(x))
)

ggplot(df_t, aes(x = x, y = densita, color = distribuzione)) +
  geom_line(linewidth = 1) +
  labs(
    title = "Confronto tra normale e t di Student",
    subtitle = "Con pochi gradi di libertà, la t ha code più pesanti",
    x = "x",
    y = "Densità",
    color = "Distribuzione"
  )
```




Figura 12.7: Confronto tra la normale standard e distribuzioni t con diversi gradi di libertà.

Nella Figura 12.7 le differenze più importanti emergono nelle code: a parità di centro, valori estremi sono più plausibili sotto una t con pochi gradi di libertà che sotto una normale.

12.11 Distribuzione di Cauchy

12.11.1 Definizione

La distribuzione di Cauchy è un caso particolare della distribuzione t con un solo grado di libertà.

Definizione 12.8. Una variabile casuale X segue una distribuzione di Cauchy con parametro di posizione x_0 e parametro di scala $s > 0$ se

$$X \sim \text{Cauchy}(x_0, s),$$

con densità

$$f(x) = \frac{1}{\pi s \left[1 + \left(\frac{x - x_0}{s} \right)^2 \right]}.$$

La distribuzione di Cauchy ha code molto pesanti e non possiede media e varianza finite. Il parametro x_0 indica una posizione centrale, ma non è una media nel senso usuale.

12.11.2 Ruolo bayesiano

La distribuzione di Cauchy è talvolta utilizzata come prior a code molto pesanti per parametri di posizione o coefficienti di regressione. Il suo carattere più o meno

informativo dipende dalla scala scelta e dalla scala del parametro. La sua versione limitata ai valori positivi, detta *half-Cauchy*, può essere usata come prior per parametri di scala, ad esempio deviazioni standard nei modelli gerarchici; anche in questo caso la scala va motivata e controllata.

⚠ Code pesanti non significa assenza di assunzioni

Una prior Cauchy lascia molto spazio ai valori estremi. Questo può essere utile per la robustezza, ma può anche rendere l'inferenza instabile se i dati sono pochi o il modello è debole. Una prior robusta non sostituisce il ragionamento sostanziale sulla scala plausibile degli effetti.

```
x <- seq(-10, 10, length.out = 800)
df_cauchy <- data.frame(
  x = rep(x, 3),
  densita = c(dnorm(x), dt(x, df = 3), dcauchy(x)),
  distribuzione = rep(c("Normale(0,1)", "t(3)", "Cauchy(0,1)"), each =
    length(x))
)

ggplot(df_cauchy, aes(x = x, y = densita, color = distribuzione)) +
  geom_line(linewidth = 1) +
  labs(
    title = "Normale, t e Cauchy",
    subtitle = "La Cauchy assegna molta più massa alle code",
    x = "x",
    y = "Densità",
    color = "Distribuzione"
  )
```




Figura 12.8: Confronto tra normale, t con tre gradi di libertà e Cauchy standard.

La Figura 12.8 mostra quanto lentamente decrescano le code della Cauchy. Questa proprietà può proteggere da restrizioni troppo forti, ma può anche assegnare plausibilità sostanziale a valori irrealistici se la scala non è scelta con cura.

12.12 Come scegliere una distribuzione continua?

La scelta di una distribuzione non dovrebbe basarsi sulla convenienza matematica, ma sulla struttura del problema. Tre domande aiutano a orientarsi:

12.12.1 1. Qual è il supporto?

- Se la quantità può assumere qualsiasi valore reale, le candidate sono la normale, la t o la Cauchy.
- Se è positiva, si considerano l'esponenziale, la gamma o la log-normale.
- Se è strettamente compresa tra 0 e 1, la beta è una candidata; valori esatti 0 o 1 richiedono un trattamento o un modello differente.
- Se invece è un conteggio, non siamo nel caso continuo: si torna alla binomiale, alla Poisson o, se i conteggi sono più dispersi di quanto questi modelli prevedano, alla beta-binomiale e alla binomiale negativa (Sezione 11.7, Sezione 11.9).

12.12.2 2. Che forma ci aspettiamo?

- Simmetria attorno a un centro: normale o t .
- Asimmetria positiva: gamma o log-normale.
- Probabilità/proporzioni vincolate: beta.
- Code più pesanti della normale: t con gradi di libertà contenuti; la Cauchy rappresenta un caso estremo.

12.12.3 3. Che ruolo ha la distribuzione?

La stessa famiglia può avere ruoli diversi, ad esempio:

- la normale può essere un modello per dati continui o una prior per un effetto;
- la beta è spesso una prior per una probabilità, ma può anche descrivere le differenze di probabilità tra unità, come nella beta-binomiale, oppure modellare dati continui proporzionali strettamente compresi tra 0 e 1;
- la gamma può modellare tempi positivi, essere una prior per un tasso oppure descrivere le differenze di tasso tra unità;
- la t può essere un modello a code pesanti per dati oppure una prior a code pesanti per parametri.

! Modello generativo prima dell'inferenza

Prima di chiedersi come aggiornare una credenza, occorre chiarire quale modello collega il parametro ai dati osservabili. Questo capitolo fornisce il vocabolario delle distribuzioni continue; il Capitolo 13 mostrerà come un campione generato da questi modelli risulti più o meno informativo.

Riflessioni conclusive

Le distribuzioni continue completano il vocabolario avviato con quelle discrete. Consentono di rappresentare dati e parametri su scale continue, ma ogni famiglia incorpora delle assunzioni riguardo al supporto, alla simmetria, all'asimmetria e alla frequenza attesa dei valori estremi.

La scelta non può quindi essere ridotta a un'associazione meccanica tra il tipo di variabile e il nome della distribuzione. Il supporto elimina le famiglie incompatibili, mentre la forma attesa, il processo generativo e il ruolo della distribuzione permettono di distinguere le candidate rimaste. Una distribuzione normale, una gamma e una t possono tutte essere matematicamente ammissibili in un certo problema, ma esprimono ipotesi diverse.

In prospettiva bayesiana, è inoltre essenziale distinguere il modello dei dati dalla distribuzione sui parametri. La distribuzione binomiale può descrivere il numero di successi, mentre la distribuzione beta rappresenta l'incertezza sulla probabilità che li genera oppure la variabilità di quella probabilità tra unità; combinate, producono la beta-binomiale di Sezione 11.7. Allo stesso modo, una distribuzione normale può descrivere osservazioni continue o rappresentare una prior su un effetto: la formula può essere simile, ma il significato dipende dalla posizione occupata nel modello.

Nel Capitolo 13 useremo queste idee per comprendere come la variabilità campionaria, la numerosità e l'errore standard influenzino la quantità di informazioni fornite dai dati.

Esercizi

1. Perché, in una distribuzione continua, il valore della densità $f(x)$ non può essere interpretato come $P(X = x)$?
2. Un tempo di risposta è sempre positivo e presenta una lunga coda destra. Perché una gamma può essere una candidata più plausibile di una normale? Il supporto basta da solo a scegliere definitivamente la gamma?
3. Per $X \sim \mathcal{N}(100, 15^2)$, che cosa restituiscono rispettivamente $\text{dnorm}(100, 100, 15)$ e $\text{pnorm}(115, 100, 15) - \text{pnorm}(85, 100, 15)$?
4. Una prior uniforme su $\theta \in (0, 1)$ assegna la stessa probabilità a intervalli della stessa ampiezza sulla scala di θ . Perché questo non significa che sia neutrale rispetto a qualunque trasformazione di θ ?

5. La distribuzione esponenziale ha la proprietà di assenza di memoria. Che cosa significa questa proprietà e perché può essere poco plausibile per molti fenomeni psicologici?
6. Se $X \sim \text{Gamma}(6, 2)$ nella parametrizzazione shape-rate, qual è il valore atteso? Che cosa accadrebbe al valore atteso se il parametro di tasso diventasse 4 mantenendo invariata la forma?
7. Confronta $\text{Beta}(2, 2)$ e $\text{Beta}(20, 20)$. Hanno la stessa media? Quale delle due esprime maggiore concentrazione attorno a tale media?
8. Perché una distribuzione t con pochi gradi di libertà può ridurre l'influenza relativa dei valori estremi rispetto a una normale? Perché non è corretto concludere che qualunque prior t o Cauchy sia automaticamente appropriata?
9. In una popolazione di studenti, la probabilità di ricordare una parola varia secondo una beta con media $m = 0,6$ e concentrazione $\kappa = 3$. Calcola la varianza delle probabilità individuali. Quale quota della varianza di una singola prova è dovuta alle differenze tra studenti?
10. Una prior $\text{Beta}(1, 1)$ su una probabilità viene talvolta descritta come «non informativa». Che cosa implica per il numero di successi previsti in 10 prove? Perché questa conseguenza è rilevante?

Soluzioni

1. Nel continuo, la probabilità è assegnata ad aree su intervalli. Un singolo punto ha area nulla e quindi probabilità zero. La densità descrive invece quanta massa è concentrata localmente e può anche assumere valori superiori a 1.
2. La gamma ammette soltanto valori positivi e può rappresentare asimmetria a destra, mentre la normale assegna massa anche a valori negativi ed è simmetrica. Il supporto elimina modelli incompatibili, ma non basta: occorre confrontare anche forma, code e processo generativo con i dati.
3. `dnorm(100, 100, 15)` restituisce la densità nel punto 100, non la probabilità di osservare esattamente 100. La differenza tra le due `pnorm()` restituisce la probabilità che X cada tra 85 e 115.
4. L'uniformità dipende dalla scala. Una trasformazione non lineare modifica la lunghezza relativa degli intervalli e induce una distribuzione non uniforme sulla nuova scala. La prior incorpora quindi una scelta di parametrizzazione.
5. Significa che, condizionatamente al fatto che l'evento non sia ancora avvenuto, l'attesa futura ha la stessa distribuzione che aveva all'inizio. È poco plausibile quando il rischio cambia con il tempo, per esempio per apprendimento, fatica, recupero o accumulo di esposizione.
6. Il valore atteso è $\alpha/\beta = 6/2 = 3$. Se il tasso diventasse 4, il valore atteso sarebbe $6/4 = 1,5$: a parità di forma, un tasso maggiore concentra la distribuzione verso valori più piccoli.

7. Entrambe hanno media $1/2$. La $Beta(20,20)$ è molto più concentrata attorno a $0,5$ perché la somma dei parametri è maggiore a media fissata.
8. Le code più pesanti assegnano maggiore plausibilità a osservazioni lontane dal centro, evitando che esse debbano essere spiegate mediante grandi spostamenti dei parametri centrali. Tuttavia, adeguatezza, robustezza e stabilità dipendono anche da scala, gradi di libertà, ruolo della distribuzione e quantità di dati.
9. $V(\theta) = m(1 - m)/(\kappa + 1) = 0,6 \times 0,4/4 = 0,06$. La varianza di una singola prova è $m(1 - m) = 0,24$, quindi la quota dovuta alle differenze tra studenti è $0,06/0,24 = 1/(\kappa + 1) = 0,25$: la stessa quantità che in Sezione 11.7 misurava la correlazione tra due prove dello stesso studente.
10. Il numero di successi segue una beta-binomiale con $\alpha = \beta = 1$, cioè l'uniforme discreta su $\{0, \dots, 10\}$: ogni conteggio ha probabilità $1/11$. I risultati 0, 1 o 10 hanno complessivamente probabilità $3/11 \approx 0,27$, e un risultato estremo è plausibile quanto uno centrale. La prior non è quindi neutrale rispetto ai dati previsti, e questa conseguenza va valutata alla luce di ciò che si sa sul compito.

i Punti chiave

- Per una variabile continua, la probabilità di un singolo punto è zero; le probabilità sono aree su intervalli.
- La densità non è una probabilità puntuale e può essere maggiore di 1.
- Il supporto esclude famiglie incompatibili, ma non determina da solo il modello.
- Le funzioni d , p , q e r di R restituiscono rispettivamente densità, probabilità cumulata, quantile e simulazioni.
- L'uniforme tratta simmetricamente intervalli della stessa lunghezza sulla scala scelta; non è neutrale rispetto a trasformazioni non lineari.
- La normale è utile per quantità approssimativamente simmetriche, ma non è un modello universale.
- L'esponenziale rappresenta attese con tasso costante e assenza di memoria; la gamma offre forme più flessibili per quantità positive.
- La beta rappresenta distribuzioni su valori in $(0, 1)$; media e concentrazione dipendono congiuntamente da α e β .
- La beta può descrivere l'incertezza su un'unica probabilità oppure le differenze di probabilità tra unità; combinata con la binomiale, in entrambi i casi produce la beta-binomiale.
- La frazione $1/(\kappa + 1)$ è la quota della varianza di una singola prova dovuta alle differenze tra unità.
- La gamma può descrivere differenze di tasso tra unità; combinata con la Poisson produce la binomiale negativa.
- La chi-quadrato deriva da somme di quadrati di normali standard ed è

collegata alla gamma.

- La t e la Cauchy hanno code più pesanti della normale; il loro uso richiede comunque una scelta motivata di scala e, per la t , dei gradi di libertà.
- Una stessa famiglia può descrivere dati, parametri o predizioni. Il significato dipende dal ruolo occupato nel modello.

Formule essenziali

$$P(a \leq X \leq b) = \int_a^b f(x) dx.$$

$$X \sim \mathcal{N}(\mu, \sigma^2), \quad \mathbb{E}(X) = \mu, \quad \mathbb{V}(X) = \sigma^2.$$

$$X \sim \text{Gamma}(\alpha, \beta), \quad \mathbb{E}(X) = \frac{\alpha}{\beta}, \quad \mathbb{V}(X) = \frac{\alpha}{\beta^2}.$$

$$\theta \sim \text{Beta}(\alpha, \beta), \quad \mathbb{E}(\theta) = m = \frac{\alpha}{\alpha + \beta}, \quad \mathbb{V}(\theta) = \frac{m(1-m)}{\kappa + 1}, \quad \kappa = \alpha + \beta.$$

Ambiente di sviluppo

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Golden Gate 27.0
#>
#> Matrix products: default
#> BLAS:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods
#> [7] base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.18.0
#> [3] withr_3.0.3         systemfonts_1.3.2
#> [5] patchwork_1.3.2     ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.16.0
#> [9] ggplot2_4.0.3       reliabilitydiag_0.2.1
```

```

#> [11] priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.1            rstan_2.32.7
#> [15] StanHeaders_2.39.1    brms_2.23.1
#> [17] Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0      janitor_2.2.1
#> [21] matrixStats_1.5.0     modelr_0.1.11
#> [23] tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2           rio_1.3.0
#> [27] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8          tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2              fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39         timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5       magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0           tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51            labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8        curl_8.0.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8           purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1          xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4         scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2         rmarkdown_2.32        generics_0.1.4
#> [34] otel_0.2.0            RcppParallel_6.2.1    cachem_1.1.0
#> [37] stringr_1.6.0         parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0              Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2    glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1  lubridate_1.9.5       stringi_1.8.9
#> [49] gtable_0.3.6          QuickJSR_1.11.0       pillar_1.11.1
#> [52] htmltools_0.5.9       Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5     rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.23-1        backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13          snakecase_0.11.1      rstantools_2.7.1
#> [64] coda_0.19-4.1         gridExtra_2.3.1       nlme_3.1-171
#> [67] checkmate_2.3.4       xfun_0.60             pkgconfig_2.0.3

```

Parte IV

PARTE 4: Verso l'inferenza

Dal campione all'evidenza: informazione, precisione e incertezza

i In sintesi

Da sapere. Comprendere come un modello generativo colleghi parametri ignoti e dati osservabili; distinguere variabilità campionaria, errore standard, incertezza a posteriori e bias; riconoscere il ruolo della Legge dei Grandi Numeri, del Teorema del Limite Centrale e dell'analisi di sensibilità.

Da saper fare. Interpretare una media o una proporzione campionaria come riassunto dei dati; spiegare come la numerosità modifica errore standard e precisione; leggere una distribuzione campionaria senza confonderla con una distribuzione a posteriori; riconoscere perché un risultato molto preciso può essere comunque sistematicamente errato.

Introduzione

Uno psicologo clinico sta prendendo in considerazione l'adozione di un nuovo protocollo per la depressione. In uno studio pilota, il 36% dei pazienti trattati ha raggiunto la remissione completa dei sintomi. Il dato è incoraggiante, ma da solo non basta per prendere una decisione. Quanto potrebbe cambiare in una replica? Sarebbe compatibile con un tasso generativo del 30%, del 40% o del 50%? Inoltre, quanto dell'incertezza dipende dal numero di partecipanti piuttosto che dalla qualità del disegno e delle misure?

Queste domande segnano il passaggio dalla semplice descrizione del campione all'evidenza statistica. Un risultato osservato diventa informativo solo quando viene inserito in un modello che specifica quali dati sarebbero più o meno attesi per diversi valori di una quantità sconosciuta.

In questo capitolo non introdurremo ancora formalmente la funzione di verosimiglianza, che sarà il tema del capitolo successivo. Introdurremo però i concetti necessari

per comprenderla: il modello generativo, i riassunti campionari, la distribuzione campionaria, l'errore standard, la precisione, la convergenza e il bias.

La prospettiva rimane bayesiana. Proporzioni, medie, varianze ed effetti sono quantità sulle quali possiamo avere incertezza epistemica. Tuttavia, i dati non diventano automaticamente evidenza: acquistano un significato inferenziale solo attraverso un modello e in base alle assunzioni che collegano il campione alla popolazione o al costrutto di interesse.

13.1 Perché un campione diventa evidenza?

La stessa proporzione del 36% può assumere significati molto diversi. Se deriva da 11 pazienti, può cambiare sensibilmente da una replica all'altra, mentre se deriva da 10.000 pazienti indipendenti e ben campionati, la variabilità campionaria è molto più piccola. In entrambi i casi, però, un errore di selezione o di misurazione può produrre una conclusione precisa, ma distorta.

Per interpretare un campione dobbiamo quindi tenere separate tre domande:

1. **Quale modello collega il parametro ignoto ai dati osservabili?**
2. **Quanto potrebbe variare il risultato in ipotetiche repliche dello stesso disegno?**
3. **Il disegno e la misura permettono davvero di collegare il campione alla popolazione o al costrutto di interesse?**

La distribuzione campionaria e l'errore standard rispondono soprattutto alla seconda domanda. L'inferenza bayesiana combina poi il modello dei dati con la prior per ottenere una distribuzione a posteriori. Nessuno di questi strumenti, da solo, corregge automaticamente bias di selezione, errori di misurazione o modelli inadeguati.

Prerequisiti

Per seguire il capitolo è utile avere letto Capitolo 5, Capitolo 6, Capitolo 8, Capitolo 10, Capitolo 11 e Capitolo 12. Per la notazione matematica, consulta Appendice A.

Per richiami su sommatorie, limiti e convergenza, consulta le appendici matematiche disponibili nel Companion.

Panoramica del capitolo

Il percorso segue il naturale processo di inferenza. Partiremo da un parametro sconosciuto e da un modello che genera dati, per poi vedere come la media e la proporzione riassumono un campione e come cambierebbero in ipotetiche repliche. Su questa base introdurremo la distribuzione campionaria, l'errore standard e la precisione. La Legge dei Grandi Numeri e il Teorema del Limite Centrale chiariranno cosa accade quando il numero di elementi aumenta. Infine, torneremo alla prospettiva bayesiana per discutere il ruolo della prior, l'analisi di sensibilità e il

limite fondamentale della sola precisione: un risultato stabile può comunque essere distorto.

i Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()
apply_visual_theme()
```

13.2 Dati, parametri e modello generativo

13.2.1 Dal fenomeno osservato al parametro ignoto

Supponiamo di voler stimare la prevalenza θ di studenti universitari con sintomi depressivi clinicamente rilevanti. Se selezioniamo un campione di n studenti e registriamo per ciascuno la presenza o l'assenza del sintomo, otterremo osservazioni binarie:

$$X_i = \begin{cases} 1 & \text{se lo studente } i \text{ presenta sintomi clinicamente rilevanti,} \\ 0 & \text{altrimenti.} \end{cases}$$

Il parametro θ rappresenta la proporzione del fenomeno nella popolazione di riferimento. Non è possibile osservarlo direttamente. Possiamo soltanto raccogliere dati che, sotto opportune assunzioni, forniscano informazioni su di esso.

Questa distinzione è il punto di partenza dell'inferenza statistica: da una parte vi è una quantità sconosciuta che vogliamo conoscere; dall'altra, un insieme di osservazioni che dipendono probabilisticamente da tale quantità.

13.2.2 Il modello generativo

Un modello probabilistico semplice assume che, condizionatamente a θ , le osservazioni siano indipendenti e abbiano la stessa probabilità:

$$X_i \mid \theta \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta), \quad i = 1, \dots, n.$$

La notazione descrive la direzione generativa del modello: **se** il valore di θ fosse noto, potremmo stabilire quali dati aspettarci. Se, per esempio, $\theta = 0.30$, ogni studente avrebbe una probabilità dello 0.30 di presentare il sintomo e, una volta condizionati su θ , gli esiti degli studenti non si influenzerebbero direttamente.

Le ipotesi di indipendenza e di probabilità comune sono componenti del modello e non proprietà automatiche dei dati. Tali ipotesi possono risultare inadeguate quando, per esempio, gli studenti sono raggruppati in classi o atenei, oppure quando la probabilità del fenomeno varia tra le diverse sottopopolazioni.

Dal punto di vista bayesiano, prima di osservare il campione possiamo rappresentare la nostra incertezza su θ mediante una distribuzione a priori:

$$\theta \sim p(\theta).$$

Il modello completo comprende quindi due parti:

$$\theta \sim p(\theta), \quad X_i | \theta \stackrel{\text{iid}}{\sim} p(x_i | \theta).$$

La prima rappresenta ciò che sappiamo o assumiamo prima dei dati; la seconda descrive il processo che genera le osservazioni, condizionatamente al parametro.

i Idea chiave

Nel ragionamento bayesiano, i dati aggiornano le credenze solo attraverso un modello. Non basta osservare una proporzione campionaria: dobbiamo specificare quale processo probabilistico renda quella proporzione più o meno attesa per diversi valori del parametro.

13.2.3 Il riassunto campionario

Nel caso Bernoulliano, un riassunto naturale dei dati è la proporzione campionaria:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Se osserviamo 72 studenti con sintomi su 200, otteniamo:

$$\bar{X} = \frac{72}{200} = 0.36.$$

La proporzione osservata fornisce una descrizione compatta del campione, ma non costituisce ancora una conclusione inferenziale. Nel modello Bernoulli *iid*, il numero totale di successi e la proporzione contengono la stessa informazione su θ . Per capire quanto questa informazione sia precisa dobbiamo però immaginare che cosa accadrebbe ripetendo lo stesso studio: **quanto potrebbe cambiare $\bar{X}$ da un campione all'altro?**

13.3 Che cosa varia da un campione all'altro

13.3.1 La media campionaria è centrata sul valore generativo

Siano $X_1, X_2, \dots, X_n$ variabili casuali indipendenti e identicamente distribuite, con valore atteso finito $\mathbb{E}(X_i | \theta) = \theta$. La media campionaria è:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Per la linearità del valore atteso:

$$\mathbb{E}(\bar{X} \mid \theta) = \theta.$$

Questa uguaglianza descrive il centro della distribuzione delle possibili medie campionarie. Se potessimo ripetere molte volte lo stesso studio, sempre con campioni della stessa dimensione e provenienti dallo stesso processo generativo, la media delle proporzioni osservate sarebbe centrata su θ .

In questo senso, la proporzione campionaria non tende sistematicamente a sovrastimare o sottostimare il parametro, a condizione che il modello sia corretto e che il campionamento non introduca bias. L'affermazione riguarda quindi la variabilità attorno al parametro all'interno del modello, non la validità del disegno nel mondo reale.

i Dimostrazione del valore atteso

$$\mathbb{E}(\bar{X} \mid \theta) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i \mid \theta\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i \mid \theta) = \frac{1}{n} \sum_{i=1}^n \theta = \theta.$$

13.3.2 Quanto oscilla la media campionaria

Essere centrata su θ non significa che ogni media campionaria coincida con θ . Campioni diversi producono valori diversi. Se le osservazioni $X_1, \dots, X_n$ sono indipendenti e hanno la stessa varianza condizionata $\text{Var}(X_i \mid \theta) = \sigma^2$, allora:

$$\text{Var}(\bar{X} \mid \theta) = \frac{\sigma^2}{n}.$$

La deviazione standard di questa distribuzione è l'**errore standard**:

$$\text{SE}(\bar{X} \mid \theta) = \sqrt{\text{Var}(\bar{X} \mid \theta)} = \frac{\sigma}{\sqrt{n}}.$$

L'errore standard descrive l'ampiezza delle oscillazioni della media campionaria in ipotetiche repliche dello stesso disegno. Diminuisce come $1/\sqrt{n}$: aumentando il campione, la statistica diventa più stabile, ma il miglioramento è più lento rispetto a una relazione lineare.

La conseguenza pratica è importante. Per dimezzare l'errore standard, infatti, non basta raddoppiare il campione, ma è necessario **quadruplicarlo**. Un campione più numeroso fornisce informazioni più precise.

i Dimostrazione della varianza

Per l'indipendenza delle osservazioni e la proprietà della varianza rispetto alle costanti moltiplicative:

$$\begin{aligned}
 \text{Var}(\bar{X} \mid \theta) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i \mid \theta\right) \\
 &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i \mid \theta) \\
 &= \frac{1}{n^2} \cdot n\sigma^2 \\
 &= \frac{\sigma^2}{n}.
 \end{aligned}$$

13.3.3 Il caso Bernoulliano

Per una variabile Bernoulliana:

$$\text{Var}(X_i \mid \theta) = \theta(1 - \theta).$$

Di conseguenza:

$$\text{Var}(\bar{X} \mid \theta) = \frac{\theta(1 - \theta)}{n}, \quad \text{SE}(\bar{X} \mid \theta) = \sqrt{\frac{\theta(1 - \theta)}{n}}.$$

Poiché θ è ignoto, nella pratica si usa spesso una stima sostitutiva, per esempio $\bar{X}$:

$$\widehat{\text{SE}}(\bar{X}) = \sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}.$$

Nel caso $\bar{X} = 0.36$ e $n = 200$:

```
p_hat <- 0.36
n <- 200
se_hat <- sqrt(p_hat * (1 - p_hat) / n)
se_hat
#> [1] 0.0339
```

La stima *plug-in* dell'errore standard è circa 0.034. Questo numero non è un margine che contiene certamente θ e non è una deviazione standard a posteriori. Descrive, in modo approssimato e sotto il modello Bernoulli *iid*, l'ordine delle fluttuazioni della proporzione campionaria in ipotetiche repliche con $n = 200$.

13.4 La distribuzione campionaria

13.4.1 Dalla singola osservazione all'insieme delle possibili repliche

Prima di raccogliere i dati, la media campionaria $\bar{X}$ è una variabile casuale: il suo valore dipende da quale campione, tra tutti quelli possibili, verrà effettivamente

osservato. Se potessimo ripetere lo stesso studio un numero molto elevato di volte, otterremmo una sequenza $\bar{X}_1, \bar{X}_2, \dots$, con valori leggermente diversi.

La **distribuzione campionaria** è la distribuzione di questi possibili valori. Descrive quindi come una statistica varierebbe in repliche ideali del medesimo disegno di ricerca.

Questa idea è cruciale per comprendere l'informazione fornita da un campione. Se una statistica tende a fluttuare poco sotto un determinato modello, il suo valore osservato può discriminare più nettamente tra valori parametrici alternativi. Se, invece, la distribuzione campionaria è ampia, molti risultati diversi sarebbero comuni e il dato osservato sarà meno selettivo.

La distribuzione campionaria non è però una distribuzione a posteriori, in quanto non assegna direttamente probabilità ai valori del parametro. Mantiene il parametro fisso e descrive la variabilità della statistica in ipotetiche repliche. Nel capitolo successivo questa stessa descrizione verrà riletta, a dati fissati, attraverso la funzione di verosimiglianza.

13.4.2 Un esempio finito: risposte a un item Likert

Consideriamo una piccola popolazione di quattro partecipanti con risposte numeriche a un item di soddisfazione di vita:

```
popolazione <- data.frame(
  id = c("A", "B", "C", "D"),
  risposta = c(2, 4, 4, 5)
)

media_pop <- mean(popolazione$risposta)
var_pop <- mean((popolazione$risposta - media_pop)^2)

cat("Media della popolazione:", media_pop, "\n")
#> Media della popolazione: 3.75
cat("Varianza della popolazione:", round(var_pop, 3), "\n")
#> Varianza della popolazione: 1.19
```

L'esempio tratta i punteggi come valori numerici con distanze interpretabili. È una scelta didattica e non implica che qualunque singolo item ordinale debba essere analizzato automaticamente come una misura intervallare.

Per costruire la distribuzione campionaria consideriamo tutti i campioni ordinati di dimensione $n = 2$ **con reinserimento**. Le quattro unità possono essere selezionate a ogni estrazione, quindi esistono $4^2 = 16$ campioni equiprobabili.

```
indici <- expand.grid(
  prima = seq_len(nrow(popolazione)),
  seconda = seq_len(nrow(popolazione))
)

valore_1 <- popolazione$risposta[indici$prima]
valore_2 <- popolazione$risposta[indici$seconda]
medie_campionarie <- (valore_1 + valore_2) / 2
```

```
df_campioni <- data.frame(
  Campione = paste0(
    "(", popolazione$id[indici$prima], ", ",
    popolazione$id[indici$seconda], ")"
  ),
  Valori = paste0("(", valore_1, ", ", valore_2, ")"),
  Media = medie_campionarie
)

knitr::kable(df_campioni, align = c("c", "c", "c"))
```

Tabella 13.1: Tutti i 16 campioni ordinati di dimensione 2 con reinserimento e le relative medie.

Campione	Valori	Media
(A, A)	(2, 2)	2.0
(B, A)	(4, 2)	3.0
(C, A)	(4, 2)	3.0
(D, A)	(5, 2)	3.5
(A, B)	(2, 4)	3.0
(B, B)	(4, 4)	4.0
(C, B)	(4, 4)	4.0
(D, B)	(5, 4)	4.5
(A, C)	(2, 4)	3.0
(B, C)	(4, 4)	4.0
(C, C)	(4, 4)	4.0
(D, C)	(5, 4)	4.5
(A, D)	(2, 5)	3.5
(B, D)	(4, 5)	4.5
(C, D)	(4, 5)	4.5
(D, D)	(5, 5)	5.0

La Tabella 13.1 distingue i campioni in base alle unità selezionate: i due partecipanti con risposta 4 rimangono unità diverse, anche se producono lo stesso valore osservato.

```
dist_medie <- as.data.frame(table(medie_campionarie))
names(dist_medie) <- c("media", "frequenza")
dist_medie$media <- as.numeric(as.character(dist_medie$media))
dist_medie$probabilita <- dist_medie$frequenza / sum(dist_medie$frequenza)

ggplot(dist_medie, aes(x = media, y = probabilita)) +
  geom_col(width = 0.35) +
  geom_vline(
    xintercept = media_pop,
    linetype = "dashed",
    linewidth = 1.0
  ) +
  scale_x_continuous(breaks = sort(unique(medie_campionarie))) +
```



```
labs(
  title = "Distribuzione campionaria della media (n = 2)",
  subtitle = "La linea tratteggiata indica la media della popolazione",
  x = "Media campionaria",
  y = "Probabilità"
)
```




Figura 13.1: Distribuzione campionaria discreta della media per tutti i campioni ordinati di dimensione 2 con reinserimento.

La Figura 13.1 è una distribuzione discreta: ogni barra rappresenta la probabilità di uno dei possibili valori della media.

```
var_medie <- mean((medie_campionarie - mean(medie_campionarie))^2)

cat("Media delle medie campionarie:", mean(medie_campionarie), "\n")
#> Media delle medie campionarie: 3.75
cat("Media della popolazione:", media_pop, "\n")
#> Media della popolazione: 3.75
cat("\n")
cat("Varianza delle medie campionarie:", round(var_medie, 3), "\n")
#> Varianza delle medie campionarie: 0.594
cat("Varianza teorica (sigma^2 / n):", round(var_pop / 2, 3), "\n")
#> Varianza teorica (sigma^2 / n): 0.594
```

Questo esempio mette in luce due proprietà fondamentali. Le medie campionarie variano da un campione all'altro, ma la loro distribuzione è centrata sulla media della popolazione. Inoltre, la variabilità delle medie è inferiore a quella delle singole osservazioni: con $n = 2$, la varianza delle medie è pari alla metà della varianza della popolazione.

! Dal campione all'evidenza

La distribuzione campionaria non è una parentesi frequentista estranea alla prospettiva bayesiana. È il modo in cui il modello descrive quali dati potremmo aspettarci prima di osservarli. Questa descrizione permetterà, nel capitolo successivo, di valutare quali valori del parametro rendano più plausibili i dati effettivamente osservati.

13.5 Errore standard, precisione e informazione

13.5.1 Che cosa ci dice l'errore standard

L'errore standard è la deviazione standard della distribuzione campionaria di una statistica. Per la media:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Un errore standard piccolo indica che la media campionaria tende a essere stabile da una replica all'altra. Sotto il modello specificato, il dato osservato discrimina più nettamente tra valori parametrici che prevedono risultati molto diversi.

Un errore standard elevato indica invece che campioni diversi avrebbero potuto produrre risultati molto differenti. In questo caso il dato è meno selettivo e un insieme più ampio di valori parametrici rimane compatibile con ciò che abbiamo osservato.

13.5.2 La stessa idea espressa come precisione

In alcuni modelli, soprattutto gaussiani, è utile esprimere la stabilità in termini di **precisione**, definita come l'inverso della varianza:

$$\tau = \frac{1}{\sigma^2}.$$

Per la media campionaria:

$$\text{Precisione}(\bar{X}) = \frac{1}{\text{Var}(\bar{X})} = \frac{n}{\sigma^2}.$$

Nel modello indipendente e omoschedastico considerato, la precisione della media cresce linearmente con n . La proprietà non vale automaticamente quando le osservazioni sono dipendenti, hanno qualità diversa o condividono fonti comuni di errore.

💡 Regola pratica

Se l'errore standard è proporzionale a $1/\sqrt{n}$, allora:

- per dimezzarlo occorre moltiplicare n per 4;
- per ridurlo a un terzo occorre moltiplicare n per 9;
- aumentare molto la precisione richiede spesso campioni molto più grandi di quanto l'intuizione suggerisca.

i Approfondimento: combinare evidenze indipendenti

La precisione fornisce anche un'intuizione utile per la sintesi di più studi. Supponiamo di avere due studi indipendenti sulla stessa quantità:

- Studio A: $\hat{p}_A = 0.42$, $SE_A = 0.07$;
- Studio B: $\hat{p}_B = 0.38$, $SE_B = 0.035$.

Una combinazione approssimata, valida quando le stime sono trattabili come gaussiane, pesa ciascuna stima in base alla sua precisione:

$$\hat{p}_{\text{comb}} = \frac{\tau_A \hat{p}_A + \tau_B \hat{p}_B}{\tau_A + \tau_B}, \quad \tau_j = \frac{1}{SE_j^2}.$$

```
p_hat_A <- 0.42
se_A <- 0.07
p_hat_B <- 0.38
se_B <- 0.035

precisione_A <- 1 / se_A^2
precisione_B <- 1 / se_B^2
precisione_combinata <- precisione_A + precisione_B
p_comb <- (precisione_A * p_hat_A + precisione_B * p_hat_B) /
  ~ precisione_combinata
se_comb <- sqrt(1 / precisione_combinata)

cat("Precisione A:", round(precisione_A, 1), "\n")
#> Precisione A: 204
cat("Precisione B:", round(precisione_B, 1), "\n")
#> Precisione B: 816
cat("Stima combinata:", round(p_comb, 3), "\n")
#> Stima combinata: 0.388
cat("Errore standard combinato:", round(se_comb, 4), "\n")
#> Errore standard combinato: 0.0313
```

Lo Studio B riceve più peso perché il suo errore standard è minore. La combinazione rimane soltanto un'approssimazione: presuppone stime indipendenti, distribuzioni approssimativamente gaussiane sulla scala usata e assenza di eterogeneità rilevante. Non sostituisce un modello meta-analitico quando contesti o effetti possono differire.

La stessa intuizione tornerà nell'aggiornamento bayesiano normale-normale: sotto le assunzioni del modello, la media a posteriori è una media ponderata dalle precisioni della prior e dei dati.

13.6 La Legge dei Grandi Numeri

13.6.1 La stabilizzazione delle medie

La **Legge dei Grandi Numeri** afferma che, aumentando il numero di osservazioni, la media campionaria tende ad avvicinarsi al valore atteso della distribuzione generativa:

$$\bar{X}_n \xrightarrow{P} \mu.$$

Nel caso Bernoulliano, $\mu = \theta$, quindi:

$$\bar{X}_n \xrightarrow{P} \theta.$$

Il simbolo $\xrightarrow{P}$ indica convergenza in probabilità. La legge non afferma che ogni grande campione restituisca esattamente il valore generativo. Afferma che, fissata una distanza positiva da quel valore, la probabilità di superarla tende a zero al crescere di n .

```
set.seed(42)
theta_true <- 0.45
n_max <- 1000

osservazioni <- rbinom(n_max, size = 1, prob = theta_true)
medie_cumulative <- cumsum(osservazioni) / seq_along(osservazioni)

data_plot <- data.frame(
  n = 1:n_max,
  media = medie_cumulative
)

ggplot(data_plot, aes(x = n, y = media)) +
  geom_line(linewidth = 0.8, alpha = 0.8) +
  geom_hline(yintercept = theta_true, linetype = "dashed", linewidth = 1.2)
  +
  labs(
    title = "Convergenza della proporzione campionaria",
    subtitle = "La linea tratteggiata indica il valore generativo theta =
    0.45",
    x = "Numero di osservazioni",
    y = "Proporzione cumulativa"
  )
```




Figura 13.2: Convergenza della proporzione campionaria al valore generativo.

Nella Figura 13.2 la proporzione cumulativa oscilla molto nelle prime osservazioni e tende poi a stabilizzarsi vicino al valore generativo. La singola simulazione illustra il fenomeno; la Legge dei Grandi Numeri è però un risultato probabilistico che riguarda l'insieme delle ipotetiche ripetizioni del processo.

13.6.2 Lettura bayesiana

Dal punto di vista bayesiano, la Legge dei Grandi Numeri aiuta a comprendere perché l'evidenza empirica diventi progressivamente più vincolante. Se i dati sono generati stabilmente da un modello con parametro θ , campioni più grandi tendono a produrre riassunti vicini a quel valore. I valori parametrici incompatibili con tali riassunti ricevono quindi sempre meno supporto dai dati.

Questo è il principio alla base di molti risultati di **concentrazione a posteriori**. In problemi regolari, quando il modello è adeguato, il parametro è identificabile e la prior assegna massa alle regioni compatibili con il processo generativo, l'accumularsi dei dati tende a ridurre l'influenza delle differenze iniziali tra prior.

Tuttavia, non si tratta di una garanzia universale. Modelli mal specificati, parametri non identificabili o prior che escludono le regioni rilevanti possono impedire tale convergenza.

13.7 Il Teorema del Limite Centrale

13.7.1 La forma della distribuzione campionaria

La Legge dei Grandi Numeri descrive dove tende la media; il **Teorema del Limite Centrale** descrive invece la forma della sua distribuzione campionaria. Per osserva-

zioni indipendenti e identicamente distribuite con valore atteso μ e varianza finita σ^2 , quando n è grande:

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Il risultato è notevole perché non richiede che la distribuzione originaria sia normale. È la distribuzione della media campionaria a diventare approssimativamente normale.

```
set.seed(42)
popolazione <- runif(20000, min = 0, max = 1)

ggplot(data.frame(x = popolazione), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30) +
  labs(
    title = "Distribuzione della popolazione",
    subtitle = "Popolazione uniforme: non normale",
    x = "Valore",
    y = "Densità"
  )
```




Figura 13.3: Distribuzione originaria uniforme da cui vengono estratti i campioni.

```
n_campione <- 30
n_ripetizioni <- 1000

medie <- replicate(n_ripetizioni, {
  campione <- sample(popolazione, size = n_campione, replace = TRUE)
  mean(campione)
})

x_bar <- mean(medie)
```

```
std <- sd(medie)

ggplot(data.frame(media = medie), aes(x = media)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30) +
  stat_function(fun = dnorm, args = list(mean = x_bar, sd = std), linewidth
    ~ = 1.2) +
  labs(
    title = "Distribuzione delle medie campionarie",
    subtitle = "La curva sovrapposta è una normale con media e deviazione
      ~ standard empiriche",
    x = "Media campionaria",
    y = "Densità"
  )
)
```




Figura 13.4: Distribuzione delle medie campionarie: nonostante la popolazione uniforme, le medie assumono una forma approssimativamente normale.

La Figura 13.3 mostra una distribuzione originaria uniforme; la Figura 13.4 mostra la distribuzione di molte medie calcolate su campioni con $n = 30$.

13.7.2 Perché il risultato è utile

Il Teorema del Limite Centrale spiega perché, in campioni sufficientemente grandi, la distribuzione campionaria di molte somme o medie possa essere approssimata da una distribuzione gaussiana. Tuttavia, il numero n deve essere sufficientemente grande e questo dipende dalla forma della distribuzione originaria, in particolare da asimmetria, code e dipendenza tra le osservazioni.

Il teorema non afferma che i dati individuali siano normali. Non garantisce neppure, da solo, che la verosimiglianza o la distribuzione a posteriori siano gaussiane. Fornisce una delle ragioni per cui le approssimazioni gaussiane sono spesso utili per le statistiche aggregate in problemi regolari.

13.8 Prior, dati e sensibilità

13.8.1 Dalla variabilità campionaria all'incertezza sul parametro

Finora abbiamo mantenuto fissato il parametro e abbiamo studiato come potrebbero variare i dati. L'inferenza bayesiana compie il passaggio complementare: una volta osservati i dati, descrive l'incertezza sui possibili valori del parametro.

La struttura generale dell'aggiornamento è:

$$p(\theta | D) \propto p(D | \theta)p(\theta).$$

Il termine $p(\theta)$ rappresenta le credenze prima dei dati; il termine $p(D | \theta)$ descrive quanto i dati siano compatibili con ciascun valore del parametro. Nel capitolo successivo questo secondo termine verrà formalizzato come **verosimiglianza**.

Per ora è sufficiente cogliere la dinamica generale. Quando i dati sono pochi o rumorosi, prior diverse possono produrre conclusioni diverse. Quando i dati sono numerosi e informativi, l'influenza della prior tende spesso ad attenuarsi, purché la prior non escluda in anticipo i valori compatibili con i dati e il modello sia adeguato.

i Approfondimento: convergenza con prior diverse

Consideriamo tre ricercatori con credenze iniziali differenti sulla prevalenza θ :

- Ricercatore A: prior Beta(2,8), centrata su valori bassi;
- Ricercatore B: prior Beta(8,2), centrata su valori alti;
- Ricercatore C: prior Beta(1,1), uniforme.

Supponiamo che i dati siano generati con $\theta = 0.45$. Per diversi valori di n , osserviamo come cambiano le posterior Beta-Binomiale.

```
set.seed(42)
theta_true <- 0.45
n_osservazioni <- c(10, 50, 200, 1000)

# Tutti i ricercatori osservano la stessa sequenza cumulativa di dati.
osservazioni <- rbinom(max(n_osservazioni), size = 1, prob =
  ~ theta_true)
successi <- cumsum(osservazioni)[n_osservazioni]

priors <- list(
  "A: centrata in basso" = c(2, 8),
  "B: centrata in alto" = c(8, 2),
  "C: uniforme su theta" = c(1, 1)
)

theta_grid <- seq(0.001, 0.999, length.out = 500)

posterior_plot <- do.call(rbind, lapply(seq_along(n_osservazioni),
  ~ function(i) {
    n <- n_osservazioni[i]
```



```
y <- successi[i]

do.call(rbind, lapply(names(priors), function(nome) {
  prior <- priors[[nome]]
  post_alpha <- prior[1] + y
  post_beta <- prior[2] + n - y

  data.frame(
    theta = theta_grid,
    density = dbeta(theta_grid, post_alpha, post_beta),
    prior = nome,
    n = paste("n =", n)
  )
}))

posterior_plot$n <- factor(posterior_plot$n, levels = paste("n =",
  ~ n_osservazioni))

ggplot(posterior_plot, aes(x = theta, y = density, linetype = prior)) +
  geom_line(linewidth = 1.1) +
  geom_vline(xintercept = theta_true, linetype = "dashed", linewidth =
    ~ 1.0) +
  facet_wrap(~ n, ncol = 2, scales = "free_y") +
  labs(
    title = "Da credenze diverse a conclusioni più simili",
    subtitle = "La linea verticale indica il valore generativo theta =
      ~ 0.45",
    x = "Parametro theta",
    y = "Densità a posteriori",
    linetype = "Prior"
  ) +
  theme(legend.position = "bottom")
```

Da credenze diverse a conclusioni più simili

La linea verticale indica il valore generativo $\theta = 0.45$




Figura 13.5: Distribuzioni posteriori ottenute con prior diverse ma con gli stessi dati cumulativi, al crescere della dimensione campionaria.

Nella Figura 13.5 tutti i ricercatori osservano gli stessi dati cumulativi. Con pochi dati, le posterior riflettono ancora chiaramente le prior; con l'aumentare di n , le differenze si riducono. La figura illustra un caso coniugato e ben specificato, non una legge automatica valida per qualunque modello.

13.8.2 Rendere visibile l'influenza delle assunzioni

L'analisi di sensibilità verifica quanto le conclusioni cambino al variare di assunzioni ragionevoli sulla prior. È particolarmente importante nei contesti psicologici e clinici, nei quali le conoscenze pregresse possono essere informative senza essere definitive.

```
n <- 200
y <- 90

priors_sens <- list(
  "Centrata in basso" = c(2, 8),
  "Uniforme su theta" = c(1, 1),
  "Centrata in alto" = c(8, 2)
)

sens <- do.call(rbind, lapply(names(priors_sens), function(nome) {
  prior <- priors_sens[[nome]]
  post_alpha <- prior[1] + y
  post_beta <- prior[2] + n - y
  data.frame(
    prior = nome,
```

```

    media_post = post_alpha / (post_alpha + post_beta),
    q025 = qbeta(0.025, post_alpha, post_beta),
    q975 = qbeta(0.975, post_alpha, post_beta)
  )
}))

sens
#>           prior media_post q025 q975
#> 1 Centrata in basso    0.438 0.372 0.506
#> 2 Uniforme su theta    0.450 0.383 0.519
#> 3 Centrata in alto     0.467 0.400 0.534

```

Se le conclusioni sostantive sono simili sotto prior diverse, l'inferenza è robusta rispetto a quelle scelte. Se cambiano molto, il risultato non deve essere nascosto: segnala che i dati disponibili non sono ancora abbastanza informativi per superare le differenze tra assunzioni iniziali plausibili.

! Una buona pratica bayesiana

La prior non è un fastidio da eliminare, ma una parte esplicita del modello. Proprio perché è esplicita, possiamo studiarne l'influenza con analisi di sensibilità e comunicare quanto le conclusioni dipendano dalle assunzioni iniziali.

13.9 Incertezza campionaria, bias e falsa precisione

13.9.1 La precisione non coincide con la validità

L'errore standard quantifica la **variabilità campionaria** di una statistica, ovvero indica quanto essa fluttuerebbe in ipotetiche repliche sotto il modello assunto. Non si tratta, di per sé, di una misura bayesiana dell'incertezza sul parametro, che è rappresentata dalla distribuzione a posteriori e che dipende anche dalla prior e dal modello.

Inoltre, l'errore standard non misura gli errori sistematici, o **bias**. Un campione molto ampio può produrre un errore standard estremamente piccolo e, allo stesso tempo, una stima gravemente distorta. Allo stesso modo, una distribuzione a posteriori molto concentrata garantisce solo poca incertezza condizionata alle assunzioni adottate, ma non garantisce che il campione, la misura e il modello siano adeguati.

Immaginiamo un'indagine online sul benessere psicologico con decine di migliaia di risposte. La numerosità può rendere l'errore standard molto piccolo. Tuttavia, se il campione sovrarappresenta persone con maggiore accesso digitale, interesse per il tema o particolari caratteristiche socio-demografiche, lo scarto sistematico rispetto alla popolazione di interesse può essere molto più grande della fluttuazione campionaria descritta dall'errore standard.

⚠ Il pericolo della falsa precisione

La combinazione di un **errore standard piccolo** e di un **bias sostanziale** è particolarmente insidiosa: produce stime precise ma sistematicamente errate, creando l'illusione di una conoscenza affidabile.

La qualità dell'inferenza non dipende quindi soltanto dal numero di osservazioni, ma anche dalla validità del disegno di ricerca: rappresentatività del campione, accuratezza degli strumenti e controllo delle fonti di distorsione sistematica. Questi aspetti devono essere valutati prima ancora di considerare l'errore standard.

13.9.2 Fonti comuni di bias nella ricerca psicologica

Tra le fonti di distorsione più rilevanti troviamo:

- **bias di selezione:** il campione non rappresenta la popolazione di interesse;
- **bias di risposta:** desiderabilità sociale, acquiescenza, stanchezza o motivazione differenziale;
- **errore di misurazione:** lo strumento non misura adeguatamente il costrutto teorico;
- **attrition selettiva:** abbandonano lo studio soprattutto alcuni tipi di partecipanti;
- **specificazione incompleta del modello:** il modello ignora variabili o dipendenze rilevanti.

Questi problemi non scompaiono aumentando n . Al contrario, grandi campioni possono renderli più pericolosi, producendo intervalli molto stretti attorno a un valore sbagliato.

13.9.3 Precisione e accuratezza

La Figura 13.6 usa un bersaglio metaforico per distinguere dispersione e scostamento sistematico. È un'illustrazione concettuale: nell'analisi reale, accuratezza e bias non sono generalmente osservabili senza informazioni esterne o assunzioni aggiuntive.

13.9.4 Come mitigare il problema

L'approccio bayesiano non elimina automaticamente le distorsioni sistematiche e non garantisce che tutte le assunzioni rilevanti vengano riconosciute. Offre però un linguaggio esplicito per rappresentare alcune fonti di incertezza e per studiare come le conclusioni cambino al variare della prior e della struttura del modello.

Questa trasparenza deve essere accompagnata da buone pratiche di progettazione e validazione:

1. **Progettare lo studio con rigore prima di raccogliere i dati.** La qualità dell'inferenza si decide in larga parte nella fase di disegno, non soltanto in quella di

Precisione e accuratezza nell'inferenza statistica

La croce indica il valore corretto del parametro




Figura 13.6: Quattro combinazioni di precisione e accuratezza. Il centro rappresenta il valore corretto del parametro.

analisi.

2. **Utilizzare strumenti di misura validati** e teoricamente coerenti con il costrutto di interesse, riducendo gli errori sistematici di misurazione.
3. **Modellare esplicitamente le fonti note di eterogeneità o distorsione**, quando possibile, invece di ignorarle.
4. **Confrontare modelli alternativi** per valutare quanto le conclusioni dipendano dalla struttura specifica adottata.
5. **Condurre analisi di sensibilità** sulle prior e sulle assunzioni strutturali, verificando se le conclusioni cambino sostanzialmente al variare di ipotesi ragionevoli.
6. **Distinguere sempre precisione statistica e validità sostantiva.** Un intervallo di credibilità stretto non equivale, da solo, a una stima corretta.

In sintesi, l'inferenza bayesiana non rende i dati immuni dai bias. Può rendere alcune assunzioni più esplicite e verificabili, ma la validità scientifica dipende anche da campionamento, misurazione, disegno e confronto con informazioni esterne.

13.10 Verso la verosimiglianza

Abbiamo seguito il percorso che conduce da un parametro ignoto a un campione osservato. Il modello generativo specifica quali dati potremmo aspettarci; la media o la proporzione ne forniscono un riassunto; la distribuzione campionaria descrive

come tale riassunto cambierebbe tra le varie repliche; l'errore standard ne misura la dispersione. La Legge dei Grandi Numeri e il Teorema del Limite Centrale chiariscono poi come questa struttura cambi al crescere del numero di osservazioni.

A questo punto possiamo formulare la domanda centrale del prossimo capitolo:

Una volta osservati i dati, quali valori del parametro li rendono più plausibili?

La risposta è la **funzione di verosimiglianza**. Essa mantiene fissi i dati osservati e valuta, per ogni valore possibile di θ , quanto quei dati sarebbero attesi sotto il modello. Se il modello specifica $p(D | \theta)$, la verosimiglianza è la stessa espressione letta come funzione di θ :

$$L(\theta; D) = p(D | \theta).$$

Nel Capitolo 14 formalizzeremo questo cambio di prospettiva. Passeremo dalla domanda predittiva «Quali dati potrei osservare se θ fosse noto?» alla domanda inferenziale «Quali valori di θ sono più compatibili con i dati osservati?».

Riflessioni conclusive

Un campione diventa informativo quando un modello specifica quali risultati sarebbero più o meno attesi per diversi valori del parametro. La media o la proporzione osservate riassumono i dati; la distribuzione campionaria descrive come questi riassunti varierebbero in ipotetiche repliche; l'errore standard ne misura la dispersione sulla scala originale.

Per una media di osservazioni indipendenti con varianza finita, la varianza diminuisce come $1/n$ e l'errore standard come $1/\sqrt{n}$. La Legge dei Grandi Numeri spiega la progressiva stabilizzazione delle medie, mentre il Teorema del Limite Centrale chiarisce perché molte distribuzioni campionarie di somme e medie assumano una forma approssimativamente normale.

Questi risultati descrivono la variabilità campionaria, non garantiscono la validità dell'inferenza. Un errore standard piccolo non corregge un campione selezionato in modo inadeguato, una misura distorta o un modello mal specificato. Allo stesso modo, una distribuzione a posteriori concentrata può essere precisa rispetto ad assunzioni errate. Pertanto, la precisione campionaria e la validità scientifica devono essere valutate separatamente.

Nel Capitolo 14 fisseremo i dati osservati e useremo il modello per confrontare i diversi valori del parametro. Questo cambio di prospettiva conduce alla funzione di verosimiglianza.

Esercizi

1. In un modello Bernoulli *iid*, che cosa rappresenta θ e quali due assunzioni sono contenute nell'espressione $X_i | \theta \stackrel{iid}{\sim} \text{Bernoulli}(\theta)$?

2. Uno studio osserva una proporzione pari a 0.36 con $n = 200$ e stima un errore standard di circa 0.034. Che cosa descrive questo numero? Che cosa **non** permette di concludere su θ ?
3. Perché quadruplicare la numerosità dimezza l'errore standard, mentre raddoppiarla non lo dimezza?
4. Qual è la differenza tra distribuzione campionaria della media e distribuzione a posteriori di un parametro?
5. Due studi indipendenti stimano la stessa quantità. Il secondo ha un errore standard pari alla metà di quello del primo. Quale studio riceve più peso in una combinazione per precisione? Perché questa regola non è sufficiente in presenza di forte eterogeneità tra studi?
6. Distingui la Legge dei Grandi Numeri dal Teorema del Limite Centrale: che cosa afferma ciascuno sulla media campionaria?
7. Tre ricercatori partono da prior differenti ma osservano gli stessi dati. Perché le loro posterior possono differire molto con pochi dati e diventare più simili con molti dati? Quale controllo permette di rendere esplicita questa dipendenza?
8. Un'indagine molto grande produce una stima con errore standard minimo, ma il campione esclude sistematicamente una parte importante della popolazione. La stima è precisa? È necessariamente accurata? Spiega la distinzione.

Soluzioni

1. θ rappresenta la probabilità comune dell'esito 1 nel modello. L'indicazione *iid* assume che, condizionatamente a θ , le osservazioni siano indipendenti e abbiano tutte la stessa distribuzione Bernoulli.
2. 0.034 è una stima della deviazione standard della proporzione campionaria in ipotetiche repliche, sotto il modello assunto. Non è una probabilità, non è un intervallo certo per θ e non coincide automaticamente con la deviazione standard della posterior.
3. Poiché $SE(\bar{X}) = \sigma / \sqrt{n}$, sostituendo n con $4n$ si ottiene $\sigma / \sqrt{4n} = SE(\bar{X})/2$. Con $2n$ l'errore standard viene moltiplicato per $1/\sqrt{2}$, non per $1/2$.
4. La distribuzione campionaria descrive i possibili valori di una statistica in repliche del campionamento, mantenendo fissato il parametro. La posterior descrive invece l'incertezza sui valori del parametro dopo avere osservato i dati, condizionatamente a modello e prior.
5. Il secondo studio ha varianza quattro volte più piccola e quindi precisione quattro volte maggiore: riceve più peso. Se gli studi stimano effetti diversi o differiscono per popolazione e disegno, una semplice media per precisione ignora l'eterogeneità e può essere fuorviante.
6. La Legge dei Grandi Numeri afferma che la media campionaria converge al valore atteso. Il Teorema del Limite Centrale descrive la forma approssimativamente normale della distribuzione della media standardizzata, sotto specifiche condizioni, quando n cresce.

7. Con pochi dati, la verosimiglianza è relativamente poco concentrata e la prior può incidere molto sulla posterior. Con molti dati informativi, le posterior tendono spesso a concentrarsi in regioni simili, se modello e prior soddisfano condizioni adeguate. L'analisi di sensibilità confronta le conclusioni sotto prior alternative plausibili.
8. La stima può essere molto precisa rispetto alla variabilità campionaria del campione osservato, ma non necessariamente accurata rispetto alla popolazione di interesse. L'esclusione sistematica introduce bias che non viene ridotto semplicemente aumentando n nello stesso processo di selezione.

i Punti chiave

- Un modello generativo collega parametri ignoti e dati osservabili.
- Nel modello Bernoulli *iid*, la proporzione campionaria riassume il numero di successi, ma la sua interpretazione dipende dalle assunzioni del modello.
- La distribuzione campionaria descrive la variabilità di una statistica in ipotetiche repliche; non è una distribuzione a posteriori.
- L'errore standard è la deviazione standard della distribuzione campionaria di una statistica.
- Per una media di osservazioni indipendenti con varianza comune, la varianza diminuisce come $1/n$ e l'errore standard come $1/\sqrt{n}$.
- La precisione è l'inverso della varianza e, nel modello semplice considerato, cresce linearmente con n .
- La Legge dei Grandi Numeri riguarda la convergenza della media al valore atteso.
- Il Teorema del Limite Centrale riguarda la forma della distribuzione campionaria di somme e medie; non rende automaticamente normali i dati o la posterior.
- Prior differenti possono influenzare molto le conclusioni quando i dati sono poco informativi. L'analisi di sensibilità rende visibile questa dipendenza.
- Un errore standard piccolo non protegge da bias di selezione, errori di misurazione o modelli inadeguati.

Formule essenziali

$$\mathbb{E}(\bar{X} \mid \theta) = \theta, \quad \text{Var}(\bar{X} \mid \theta) = \frac{\sigma^2}{n}, \quad \text{SE}(\bar{X} \mid \theta) = \frac{\sigma}{\sqrt{n}}.$$

Nel caso Bernoulli:

$$\text{Var}(\bar{X} \mid \theta) = \frac{\theta(1 - \theta)}{n}.$$

La precisione è:

$$\tau = \frac{1}{\text{Var}}.$$

L'aggiornamento bayesiano mantiene la forma generale:

$$p(\theta | D) \propto p(D | \theta)p(\theta).$$

i Ambiente di sviluppo

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods
#> [7] base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0
#> [3] withr_3.0.3         systemfonts_1.3.2
#> [5] patchwork_1.3.2     ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0
#> [9] ggplot2_4.0.3       reliabilitydiag_0.2.1
#> [11] priorsense_1.2.0    posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7
#> [15] StanHeaders_2.32.10 brms_2.23.1
#> [17] Rcpp_1.1.2          sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1
#> [21] matrixStats_1.5.0   modelr_0.1.11
#> [23] tibble_3.3.1        dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0
#> [27] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1    farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0       tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0    estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5      compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1         yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3      bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0          RColorBrewer_1.1-3
```

```
#> [22] abind_1.4-8      purrr_1.2.2      grid_4.6.1
#> [25] stats4_4.6.1     xtable_1.8-8     inline_0.3.21
#> [28] emmeans_2.0.4    scales_1.4.0     cli_3.6.6
#> [31] mvtnorm_1.4-2    rmarkdown_2.31   generics_0.1.4
#> [34] otel_0.2.0       RcppParallel_6.2.0 cachem_1.1.0
#> [37] stringr_1.6.0    parallel_4.6.1   vctrs_0.7.3
#> [40] V8_8.2.0         Matrix_1.7-6     jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2 glue_1.8.1       codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5  stringi_1.8.7
#> [49] gtable_0.3.6     QuickJSR_1.10.0  pillar_1.11.1
#> [52] htmltools_0.5.9  Brobdingnag_1.2-9 R6_2.6.1
#> [55] textshaping_1.0.5 rprojroot_2.1.1  evaluate_1.0.5
#> [58] lattice_0.22-9   backports_1.5.1  memoise_2.0.1
#> [61] broom_1.0.13     snakecase_0.11.1 rstantools_2.7.0
#> [64] coda_0.19-4.1    gridExtra_2.3.1  nlme_3.1-170
#> [67] checkmate_2.3.4  xfun_0.60        pkgconfig_2.0.3
```

La verosimiglianza

i In sintesi

Da sapere Comprendere che la verosimiglianza legge il modello dei dati nella direzione inversa: i dati osservati restano fissi e si confrontano valori diversi del parametro. Distinguere verosimiglianza, probabilità dei dati e distribuzione a posteriori; riconoscere il significato della posizione, della forma e della concentrazione di una curva di verosimiglianza.

Da saper fare Spiegare intuitivamente che cosa significa che un valore del parametro rende i dati più plausibili di un altro; interpretare un rapporto di verosimiglianza senza trasformarlo in una probabilità del parametro; descrivere perché, nell'aggiornamento bayesiano, la prior viene moltiplicata per la verosimiglianza e poi normalizzata.

Introduzione

In uno studio pilota, 72 pazienti su 200 raggiungono la remissione dopo un trattamento. La proporzione osservata è

$$\frac{72}{200} = 0.36.$$

Questo numero descrive il campione, ma non determina automaticamente l'efficacia reale θ del trattamento. Per interpretarlo dobbiamo compiere un passo ulteriore: considerare diversi valori possibili del parametro θ e chiederci quanto ciascuno di essi renda plausibile ciò che abbiamo osservato.

Se l'efficacia reale fosse 0.20, osservare 72 remissioni sarebbe piuttosto inatteso. Se fosse 0.36, il risultato sarebbe molto più naturale. Se fosse 0.60, una proporzione osservata tanto bassa sarebbe di nuovo difficile da spiegare.

La **verosimiglianza** organizza precisamente questo confronto. Mantiene fissi i dati osservati e, per ogni valore possibile del parametro, misura quanto bene quel valore riesca a renderli plausibili.

La domanda non è ancora

Qual è la probabilità che il parametro valga 0.36?

Questa è una domanda a posteriori e richiede anche una distribuzione a priori. La domanda della verosimiglianza è più elementare:

Se il parametro avesse un certo valore, quanto sarebbero plausibili proprio i dati che abbiamo osservato?

Questa idea costituisce il ponte tra il modello generativo e l'aggiornamento bayesiano. Prima dei dati, la prior assegna un peso ai diversi valori del parametro. Dopo l'osservazione, la verosimiglianza modifica quei pesi: i valori che rendevano i dati relativamente plausibili acquistano importanza rispetto a quelli sotto cui i dati sarebbero stati difficili da osservare.

In forma schematica:

$$\underbrace{p(\theta)}_{\text{peso prima dei dati}} \times \underbrace{L(\theta; y)}_{\text{compatibilità con i dati}} \rightarrow \underbrace{p(\theta | y)}_{\text{peso dopo i dati}} .$$

La normalizzazione finale garantisce che questi pesi formino una distribuzione di probabilità, con integrale (o somma) uguale a 1. Senza la verosimiglianza, i dati non potrebbero modificare la prior; senza la prior, la verosimiglianza non sarebbe ancora una distribuzione di probabilità sul parametro.

! L'intuizione da conservare

La prior dice **quali valori consideravamo plausibili prima**. La verosimiglianza dice **quanto ciascun valore riesce a rendere plausibili i dati osservati**. La posterior combina entrambe le informazioni.

💡 Prerequisiti

Per seguire il capitolo è utile avere letto Capitolo 5, Capitolo 13, Capitolo 10, Capitolo 11 e Capitolo 12. Per la notazione matematica, consulta Appendice A. Per richiami su prodotti, logaritmi, derivate e integrali, consulta le appendici matematiche disponibili nel Companion.

Panoramica del capitolo

Il capitolo segue il percorso naturale che conduce dal modello dei dati all'aggiornamento:

1. parte dalla direzione predittiva del modello e introduce la domanda inferenziale;
2. definisce la funzione di verosimiglianza fissando i dati e facendo variare il parametro;
3. chiarisce che cosa la verosimiglianza è, e soprattutto che cosa non è;

4. mostra come leggere posizione, larghezza e forma di una curva;
5. costruisce la verosimiglianza Bernoulli–binomiale e quella gaussiana;
6. introduce la log-verosimiglianza e l'accumulo dell'evidenza;
7. discute il ruolo della massima verosimiglianza e dei rapporti di verosimiglianza;
8. conclude mostrando dove termina la verosimiglianza e dove comincia l'aggiornamento bayesiano.

i Preparazione del notebook

```
here::here("code", "_common.R") |>
  source()
apply_visual_theme()
```

14.1 Dal modello generativo alla domanda inversa

14.1.1 La direzione predittiva

Un modello probabilistico descrive quali dati potremmo osservare se il parametro fosse noto. Nel caso di esiti binari possiamo scrivere:

$$Y_i | \theta \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta), \quad i = 1, \dots, n.$$

Se $\theta = 0.36$, ogni osservazione ha probabilità 0.36 di essere un successo, sotto le ipotesi di indipendenza condizionata e probabilità comune. La direzione del modello è quindi

$$\theta \rightarrow \text{dati possibili.}$$

In questa lettura, θ è fissato e sono i dati a variare. La quantità

$$p(y | \theta)$$

risponde alla domanda:

Se il parametro valesse θ , con quale probabilità o densità potremmo osservare y ?

14.1.2 La direzione inferenziale

Nella ricerca empirica incontriamo il problema nella direzione opposta. I dati sono già stati osservati, mentre il parametro è ignoto. Se registriamo 72 remissioni su 200 pazienti, fissiamo quel risultato e confrontiamo valori diversi di θ :

$$\text{dati osservati} \rightarrow \text{confronto tra valori del parametro.}$$

La formula matematica rimane $p(y | \theta)$, ma cambia il ruolo degli argomenti:

- come probabilità o densità, facciamo variare y mantenendo fisso θ ;

- come verosimiglianza, manteniamo fisso y e facciamo variare θ .

La verosimiglianza non inverte quindi la probabilità condizionata. Legge la stessa funzione da un punto di vista diverso.

14.1.3 Un primo confronto

Supponiamo di osservare 7 successi su 10 prove. Consideriamo, per il momento, soltanto tre valori possibili di θ :

Valore ipotizzato	Probabilità di osservare esattamente 7 successi
$\theta = 0.30$	0.009
$\theta = 0.50$	0.117
$\theta = 0.70$	0.267

Il risultato osservato è molto più compatibile con $\theta = 0.70$ che con $\theta = 0.30$. Questo non significa che $\theta = 0.70$ abbia probabilità 0.70, né che sia certamente il valore vero. Significa soltanto che, tra i valori considerati e sotto il modello binomiale, 7 successi su 10 sarebbero più facili da osservare se θ fosse vicino a 0.70.

i Idea chiave

La verosimiglianza legge $p(y | \theta)$ mantenendo fissi i dati osservati. Il suo scopo è confrontare quanto bene valori diversi di θ riescano a spiegare lo stesso risultato.

14.2 Definizione della funzione di verosimiglianza

i Definizione formale

Sia Y una variabile casuale, o un vettore di variabili casuali, la cui distribuzione dipende da un parametro ignoto $\theta \in \Theta$. Indichiamo con $f(y | \theta)$ la funzione di massa, nel caso discreto, o la funzione di densità, nel caso continuo.

Dopo avere osservato y_{obs} , la **funzione di verosimiglianza** è la stessa espressione considerata come funzione di θ :

$$L(\theta; y_{\text{obs}}) = f(y_{\text{obs}} | \theta), \quad \theta \in \Theta.$$

I dati y_{obs} sono fissi; il parametro θ varia.

Valori di θ con verosimiglianza maggiore rendono i dati osservati relativamente più plausibili, sotto il modello adottato. L'avverbio **relativamente** è essenziale: la verosimiglianza confronta valori del parametro, ma non assegna loro direttamente probabilità.

14.2.1 Probabilità e verosimiglianza a confronto

Aspetto	Probabilità o densità	Verosimiglianza
Espressione	$f(y \theta)$	$L(\theta; y_{\text{obs}}) = f(y_{\text{obs}} \theta)$
Quantità fissata	θ	y_{obs}
Quantità variabile	y	θ
Domanda	Quali dati sono attesi se conosco θ ?	Quali valori di θ rendono plausibili i dati osservati?
Normalizzazione	Somma o integra a 1 rispetto a y	Non è richiesta rispetto a θ
Esito	Distribuzione dei dati	Funzione di confronto tra valori parametrici

14.2.2 Perché non è una distribuzione sui parametri

La verosimiglianza è una funzione di θ , ma in generale non è normalizzata rispetto a θ :

$$\int_{\Theta} L(\theta; y_{\text{obs}}) d\theta \neq 1.$$

Anche quando l'integrale è finito e la curva potrebbe essere riscalata per avere area 1, questa operazione non costituisce da sola un aggiornamento neutrale. Equivarrebbe a introdurre una specifica scelta di misura o, in molti casi semplici, una prior uniforme nella parametrizzazione utilizzata. Una trasformazione del parametro potrebbe quindi cambiare il risultato.

Nell'inferenza bayesiana, la distribuzione sul parametro nasce invece da un passaggio esplicito:

$$p(\theta | y_{\text{obs}}) = \frac{L(\theta; y_{\text{obs}})p(\theta)}{\int_{\Theta} L(\theta'; y_{\text{obs}})p(\theta') d\theta'}.$$

! Da ricordare

La verosimiglianza è il contributo dei dati all'aggiornamento. La posterior è il risultato della combinazione tra prior e verosimiglianza, seguita dalla normalizzazione.

14.3 Scala arbitraria e verosimiglianza relativa

Per definizione, la verosimiglianza coincide con la massa o la densità dei dati osservati:

$$L(\theta; y) = f(y | \theta).$$

Quando confrontiamo valori di θ all'interno dello stesso modello, possiamo però eliminare i fattori positivi che non dipendono da θ . Se

$$L_1(\theta) = cL_2(\theta), \quad c > 0,$$

allora i rapporti tra valori parametrici restano invariati:

$$\frac{L_1(\theta_a)}{L_1(\theta_b)} = \frac{L_2(\theta_a)}{L_2(\theta_b)}.$$

Per questo si scrive spesso

$$L(\theta; y) \propto g(\theta; y),$$

eliminando le costanti che non cambiano al variare di θ .

Una curva può inoltre essere resa più leggibile dividendo ogni valore per il massimo:

$$R(\theta) = \frac{L(\theta)}{\max_{\theta'} L(\theta')}.$$

La **verosimiglianza relativa** varia tra 0 e 1. Il valore 1 identifica il punto che rende i dati più plausibili tra quelli considerati. Se $R(\theta) = 0.5$, il dataset osservato ha, in quel punto, una verosimiglianza pari alla metà del massimo.

⚠ Non è una probabilità del parametro

$R(\theta) = 0.5$ non significa che θ abbia probabilità 50%, né che vi sia una probabilità del 50% che sia vero. È soltanto un confronto con il valore che massimizza la verosimiglianza.

14.4 Verosimiglianza Bernoulli–binomiale

Il caso binomiale permette di vedere in modo trasparente come la verosimiglianza emerga dal modello dei dati.

14.4.1 Dati individuali Bernoulliani

Supponiamo di osservare n esiti binari:

$$y_i = \begin{cases} 1 & \text{se il paziente raggiunge la remissione,} \\ 0 & \text{altrimenti.} \end{cases}$$

Assumiamo che, condizionatamente a θ , gli esiti siano indipendenti e condividano la stessa probabilità:

$$Y_i \mid \theta \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta).$$

Per una singola osservazione:

$$p(y_i | \theta) = \theta^{y_i} (1 - \theta)^{1-y_i}.$$

Per l'intera sequenza osservata:

$$L(\theta; y_1, \dots, y_n) = \prod_{i=1}^n \theta^{y_i} (1 - \theta)^{1-y_i}.$$

Se $y = \sum_i y_i$ è il numero totale di successi, raccogliendo i termini otteniamo:

$$L(\theta; y_1, \dots, y_n) = \theta^y (1 - \theta)^{n-y}.$$

Sotto questo modello, l'ordine degli esiti non modifica la forma della verosimiglianza per θ : contano il numero di successi e il numero di insuccessi.

14.4.2 Dal vettore degli esiti al conteggio binomiale

Se il dato osservato è direttamente il conteggio $Y = y$ su n prove, allora

$$Y | \theta \sim \text{Binomiale}(n, \theta)$$

e

$$L(\theta; y, n) = \binom{n}{y} \theta^y (1 - \theta)^{n-y}.$$

Il coefficiente $\binom{n}{y}$ conta quante sequenze producono lo stesso numero di successi. Modifica la probabilità del conteggio rispetto alla probabilità di una singola sequenza, ma non modifica il confronto tra valori di θ , perché non dipende da θ :

$$L(\theta; y, n) \propto \theta^y (1 - \theta)^{n-y}.$$

Che cosa raccontano successi e insuccessi?

Il fattore θ^y favorisce valori più alti di θ quando osserviamo molti successi; il fattore $(1 - \theta)^{n-y}$ favorisce valori più bassi quando osserviamo molti insuccessi. La curva nasce dal bilanciamento tra queste due componenti.

Quando non basta il modello binomiale

La forma binomiale presuppone indipendenza condizionata e una probabilità comune. Dipendenza tra pazienti, differenze individuali sistematiche o variazioni tra centri clinici richiedono modelli più ricchi.

14.5 Un esempio psicologico: remissione in uno studio pilota

Torniamo allo studio iniziale. Abbiamo osservato $y = 72$ remissioni su $n = 200$ pazienti, quindi

$$\hat{\theta} = \frac{72}{200} = 0.36.$$

La verosimiglianza binomiale è

$$L(\theta; y = 72, n = 200) \propto \theta^{72}(1 - \theta)^{128}.$$

```
n <- 200
y <- 72
theta_grid <- seq(0.001, 0.999, length.out = 1000)
log_lik <- dbinom(y, size = n, prob = theta_grid, log = TRUE)
rel_lik <- exp(log_lik - max(log_lik))

df_lik <- data.frame(
  theta = theta_grid,
  relative_likelihood = rel_lik
)

ggplot(df_lik, aes(x = theta, y = relative_likelihood)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = y / n, linetype = "dashed") +
  labs(
    x = expression(theta),
    y = "Verosimiglianza relativa"
  )
```




Figura 14.1: Verosimiglianza relativa per 72 remissioni su 200 pazienti. Il massimo si trova in corrispondenza della proporzione osservata.

La curva in Figura 14.1 raggiunge il massimo in $\theta = 0.36$. Valori vicini, come 0.34 o 0.39, rendono comunque i dati abbastanza plausibili; valori molto lontani producono invece una verosimiglianza relativa più bassa.

Una curva di verosimiglianza va letta come un profilo del sostegno relativo fornito dai dati:

- la **posizione del massimo** indica il valore che rende i dati osservati più plausibili tra quelli considerati;
- la **larghezza** indica quanto bene i dati discriminano tra valori vicini: una curva larga discrimina poco, una curva stretta di più;
- la **forma** può essere simmetrica o asimmetrica, a seconda del modello e dei dati;
- l'**altezza assoluta** non è una probabilità del parametro: sono soprattutto i rapporti tra le altezze a essere informativi.

14.5.1 Stessa proporzione, diversa quantità di informazione

Per comprendere il ruolo della numerosità, confrontiamo due studi con la stessa proporzione osservata:

- 9 remissioni su 25 pazienti, $\hat{\theta} = 0.36$;
- 72 remissioni su 200 pazienti, $\hat{\theta} = 0.36$.

```
theta_grid <- seq(0.001, 0.999, length.out = 1000)

lik_small_log <- dbinom(9, size = 25, prob = theta_grid, log = TRUE)
lik_large_log <- dbinom(72, size = 200, prob = theta_grid, log = TRUE)

df_compare <- rbind(
  data.frame(
    theta = theta_grid,
    relative_likelihood = exp(lik_small_log - max(lik_small_log)),
    studio = "9/25"
  ),
  data.frame(
    theta = theta_grid,
    relative_likelihood = exp(lik_large_log - max(lik_large_log)),
    studio = "72/200"
  )
)

ggplot(df_compare, aes(x = theta, y = relative_likelihood, linetype =
  ~ studio)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = 0.36, linetype = "dashed") +
  labs(
    x = expression(theta),
    y = "Verosimiglianza relativa",
    linetype = "Dati osservati"
  )
```




Figura 14.2: Stessa proporzione osservata, ma diversa numerosità. Il campione più grande produce una verosimiglianza più concentrata.

In Figura 14.2 il massimo coincide, perché la proporzione è la stessa. La curva basata su 200 pazienti è però molto più stretta: il campione grande esclude più nettamente valori lontani da 0.36.

La numerosità non cambia necessariamente il punto preferito dai dati, ma cambia quanto decisamente i dati riescono a distinguerlo dalle alternative.

! Collegamento con la precisione

Nel capitolo precedente abbiamo visto che l'errore standard della proporzione diminuisce all'aumentare di n . La maggiore concentrazione della verosimiglianza esprime la stessa idea dal punto di vista del confronto tra valori parametrici.

14.6 Log-verosimiglianza

La rappresentazione diretta della verosimiglianza diventa presto scomoda. Con molte osservazioni, infatti, dobbiamo moltiplicare numerose probabilità o densità spesso minori di 1. Il prodotto può diventare così piccolo da essere rappresentato dal computer come zero.

Per evitare questo problema si usa la **log-verosimiglianza**:

$$\ell(\theta; y) = \log L(\theta; y).$$

Se le osservazioni sono indipendenti condizionatamente a θ ,

$$L(\theta; y_1, \dots, y_n) = \prod_{i=1}^n f(y_i | \theta),$$

allora

$$\ell(\theta; y_1, \dots, y_n) = \sum_{i=1}^n \log f(y_i | \theta).$$

Il logaritmo trasforma quindi i prodotti in somme. L'idea inferenziale non cambia: cambia soltanto la scala di rappresentazione.

Poiché il logaritmo è strettamente crescente,

$$\arg \max_{\theta} L(\theta; y) = \arg \max_{\theta} \ell(\theta; y).$$

La log-verosimiglianza conserva l'ordine dei valori: se un parametro ha verosimiglianza maggiore di un altro, ha anche log-verosimiglianza maggiore.

i Esempio computazionale: evitare l'underflow

```
set.seed(42)
n <- 2000
theta <- 0.35
dati <- rbinom(n, size = 1, prob = theta)

lik_diretta <- prod(dbinom(dati, size = 1, prob = theta))
log_lik <- sum(dbinom(dati, size = 1, prob = theta, log = TRUE))

cat("Verosimiglianza diretta:", lik_diretta, "\n")
#> Verosimiglianza diretta: 0
cat("Log-verosimiglianza:", log_lik, "\n")
#> Log-verosimiglianza: -1294
```

14.6.1 Il caso binomiale

Trascurando la costante che non dipende da θ , la log-verosimiglianza binomiale è

$$\ell(\theta; y, n) = y \log \theta + (n - y) \log(1 - \theta).$$

Questa forma rende visibile l'accumulo dell'evidenza: ogni successo aggiunge un termine $\log \theta$ e ogni insuccesso aggiunge un termine $\log(1 - \theta)$. Il punto di equilibrio determina il massimo; il numero complessivo di osservazioni determina la curvatura e quindi la capacità di discriminare tra valori vicini.

14.7 Verosimiglianza congiunta e accumulo dell'evidenza

L'uso della log-verosimiglianza mette in evidenza un principio generale. Se le osservazioni sono indipendenti una volta fissato θ , i loro contributi si moltiplicano sulla scala originale e si sommano sulla scala logaritmica:

$$L(\theta; y_1, \dots, y_n) = \prod_{i=1}^n f(y_i | \theta),$$

$$\ell(\theta; y_1, \dots, y_n) = \sum_{i=1}^n \log f(y_i | \theta).$$

Ogni nuova osservazione modifica quindi l'intero profilo della verosimiglianza. Non «vota» semplicemente per un valore: aggiunge informazione secondo ciò che il modello prevede per tutti i valori del parametro.

14.7.1 Combinare studi sotto un parametro comune

Supponiamo che quattro studi misurino la stessa probabilità di successo θ :

Studio	Successi	Totale
1	23	30
2	20	28
3	29	40
4	29	36

Se gli studi sono indipendenti condizionatamente a un unico valore comune di θ , la log-verosimiglianza complessiva è

$$\ell(\theta) = \sum_{j=1}^4 [y_j \log \theta + (n_j - y_j) \log(1 - \theta)].$$

```
studi <- data.frame(
  successi = c(23, 20, 29, 29),
  prove = c(30, 28, 40, 36)
)

log_lik_congiunta <- function(theta) {
  sum(studi$successi * log(theta) +
    (studi$prove - studi$successi) * log(1 - theta))
}

theta_seq <- seq(0.5, 0.9, length.out = 400)
log_lik_vals <- vapply(theta_seq, log_lik_congiunta, numeric(1))
rel_lik_vals <- exp(log_lik_vals - max(log_lik_vals))

ggplot(data.frame(theta = theta_seq, rel_lik = rel_lik_vals),
  aes(x = theta, y = rel_lik)) +
  geom_line(linewidth = 1.2) +
  geom_vline(
    xintercept = sum(studi$successi) / sum(studi$prove),
    linetype = "dashed"
  ) +
  labs(
    x = expression(theta),
```

```
y = "Verosimiglianza relativa"
)
```




Figura 14.3: Verosimiglianza relativa congiunta ottenuta combinando quattro studi sotto l'ipotesi di un parametro comune.

La curva in Figura 14.3 riassume l'evidenza dei quattro studi sotto un modello a effetto comune. Non abbiamo calcolato una media non ponderata delle quattro proporzioni: abbiamo valutato la probabilità congiunta dei dati sotto ciascun valore di θ .

⚠ Il parametro comune è un'ipotesi

Se l'efficacia varia tra studi, popolazioni o contesti, moltiplicare le verosimiglianze sotto un unico θ può essere fuorviante. In quel caso serve un modello gerarchico che rappresenti esplicitamente l'eterogeneità.

14.8 Verosimiglianza gaussiana

La stessa logica si applica ai dati continui. Supponiamo di osservare misure descritte dal modello

$$Y_i | \mu \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2),$$

dove μ è ignota e σ è nota. L'ipotesi di normalità è parte del modello e deve essere valutata rispetto al fenomeno e ai dati.

14.8.1 Una singola osservazione

Se osserviamo y , la verosimiglianza per μ è

$$L(\mu; y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(y - \mu)^2}{2\sigma^2}\right].$$

Nel caso continuo questa espressione è una densità valutata nel dato osservato, non la probabilità del singolo punto. Come funzione di μ , è massima in $\mu = y$ e diminuisce allontanandosi dal dato.

```
y_obs <- 114
sigma <- 15
mu_grid <- seq(70, 160, length.out = 500)
log_lik <- dnorm(y_obs, mean = mu_grid, sd = sigma, log = TRUE)
rel_lik <- exp(log_lik - max(log_lik))

ggplot(data.frame(mu = mu_grid, rel_lik = rel_lik),
       aes(x = mu, y = rel_lik)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = y_obs, linetype = "dashed") +
  labs(
    x = expression(mu),
    y = "Verosimiglianza relativa"
  )
)
```




Figura 14.4: Verosimiglianza gaussiana relativa per la media, data una singola osservazione.

La curva in Figura 14.4 è ampia: una sola osservazione non distingue nettamente tra molti valori possibili di μ .

14.8.2 Un campione gaussiano

Con n osservazioni indipendenti,

$$L(\mu; y_1, \dots, y_n) = \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} \exp \left[-\frac{(y_i - \mu)^2}{2\sigma^2} \right].$$

La log-verosimiglianza è

$$\ell(\mu) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2.$$

La verosimiglianza è massima quando la somma degli scarti quadratici è minima, cioè in $\mu = \bar{y}$. Inoltre,

$$L(\mu; y_1, \dots, y_n) \propto \exp \left[-\frac{n}{2\sigma^2} (\mu - \bar{y})^2 \right].$$

Questa espressione ha la stessa forma di un nucleo normale centrato su $\bar{y}$, con scala $\sigma / \sqrt{n}$. La curvatura, o precisione dei dati rispetto a μ , è

$$\tau_{\text{dati}} = \frac{n}{\sigma^2}.$$

```
y <- c(26, 35, 30, 25, 44, 30, 33, 43, 22, 43, 24, 19, 39, 31, 25,
      28, 35, 30, 26, 31, 41, 36, 26, 35, 33, 28, 27, 34, 27, 22)
sigma <- 6.5
mu_grid <- seq(25, 40, length.out = 500)

log_lik <- vapply(mu_grid, function(mu) {
  sum(dnorm(y, mean = mu, sd = sigma, log = TRUE))
}, numeric(1))

rel_lik <- exp(log_lik - max(log_lik))

ggplot(data.frame(mu = mu_grid, rel_lik = rel_lik),
  aes(x = mu, y = rel_lik)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = mean(y), linetype = "dashed") +
  labs(
    x = expression(mu),
    y = "Verosimiglianza relativa"
  )
```




Figura 14.5: Verosimiglianza gaussiana relativa per la media di un campione, assumendo nota la deviazione standard.

La curva in Figura 14.5 è centrata sulla media campionaria ed è più concentrata di quella prodotta da una singola osservazione. Anche qui, più dati o minore variabilità rendono il confronto tra valori del parametro più netto.

! Ponte verso l'aggiornamento normale–normale

Nel modello gaussiano con σ nota, la verosimiglianza per μ ha una forma normale con precisione n/σ^2 . Nel successivo aggiornamento bayesiano, questa precisione si combina con la precisione della prior: dati più numerosi o meno variabili esercitano un peso maggiore.

14.9 Il ruolo della massima verosimiglianza

Una curva di verosimiglianza contiene molte informazioni, ma il suo punto più immediato da individuare è il massimo. Il valore che massimizza la funzione è la **stima di massima verosimiglianza** (*maximum likelihood estimate*, MLE):

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta; y).$$

Nel modello binomiale,

$$\hat{\theta}_{\text{MLE}} = \frac{y}{n},$$

mentre nel modello gaussiano con varianza nota,

$$\hat{\mu}_{\text{MLE}} = \bar{y}.$$

La MLE localizza il valore che rende i dati osservati più plausibili, ma riassume l'intera curva con un solo punto. Due studi possono avere la stessa MLE e curve di larghezza molto diversa, come mostrato in Figura 14.2.

i Approfondimento: MLE, MAP e derivazione binomiale

Nell'inferenza bayesiana interessa l'intera distribuzione a posteriori. La sua moda è la stima MAP (*maximum a posteriori*). Se la prior è uniforme nella parametrizzazione considerata e non intervengono particolarità ai bordi, MLE e MAP possono coincidere; con una prior non uniforme, in generale differiscono. Per il modello binomiale, trascurando costanti che non dipendono da θ ,

$$\ell(\theta) = y \log \theta + (n - y) \log(1 - \theta).$$

Derivando,

$$\frac{d\ell}{d\theta} = \frac{y}{\theta} - \frac{n - y}{1 - \theta}.$$

Ponendo la derivata uguale a zero si ottiene

$$\hat{\theta}_{\text{MLE}} = \frac{y}{n}.$$

i Perché non fermarsi al massimo?

Il massimo dice quale valore rende i dati più plausibili. Non dice quanto siano compatibili i valori vicini, quanto sia concentrata l'evidenza, né come le informazioni pregresse modifichino il risultato.

14.10 Confrontare valori parametrici con rapporti di verosimiglianza

Talvolta non vogliamo esaminare l'intera curva, ma confrontare direttamente due valori specifici del parametro. In questo caso usiamo il **rapporto di verosimiglianza**:

$$\text{LR}_{10} = \frac{L(\theta_1; y)}{L(\theta_0; y)}.$$

Se il rapporto vale 5, il dataset osservato è cinque volte più plausibile sotto θ_1 che sotto θ_0 . Se vale 1, i due valori rendono i dati ugualmente plausibili. Se è minore di 1, i dati favoriscono relativamente θ_0 .

La parola **relativamente** rimane decisiva: il rapporto confronta i dati sotto due valori del parametro, ma non assegna probabilità a quei valori.

i Esempio: 7 successi su 10 prove

Confrontiamo $\theta_0 = 0.50$ e $\theta_1 = 0.70$.

```
n <- 10
y <- 7

L_0 <- dbinom(y, size = n, prob = 0.50)
L_1 <- dbinom(y, size = n, prob = 0.70)
LR <- L_1 / L_0

cat("L(theta = 0.50):", round(L_0, 4), "\n")
#> L(theta = 0.50): 0.117
cat("L(theta = 0.70):", round(L_1, 4), "\n")
#> L(theta = 0.70): 0.267
cat("Rapporto L(0.70) / L(0.50):", round(LR, 2), "\n")
#> Rapporto L(0.70) / L(0.50): 2.28
```

Il rapporto è circa 2.28: i dati osservati sono circa 2.28 volte più plausibili sotto $\theta = 0.70$ che sotto $\theta = 0.50$. Questa affermazione riguarda i dati condizionatamente ai due valori, non la probabilità che uno dei due valori sia vero.

```
theta_seq <- seq(0.001, 0.999, length.out = 500)
lik_vals <- dbinom(y, size = n, prob = theta_seq)
rel_lik <- lik_vals / max(lik_vals)

point_df <- data.frame(
  theta = c(0.50, 0.70),
  rel_lik = c(
    dbinom(y, size = n, prob = 0.50),
    dbinom(y, size = n, prob = 0.70)
  ) / max(lik_vals)
)

ggplot(data.frame(theta = theta_seq, rel_lik = rel_lik),
  aes(x = theta, y = rel_lik)) +
  geom_line(linewidth = 1.2) +
  geom_point(data = point_df, aes(x = theta, y = rel_lik), size = 3) +
  geom_segment(
    data = point_df,
    aes(x = theta, xend = theta, y = 0, yend = rel_lik),
    linetype = "dashed"
  ) +
  labs(
    x = expression(theta),
    y = "Verosimiglianza relativa"
  )
```




Figura 14.6: Due valori parametrici letti sulla stessa curva di verosimiglianza relativa per 7 successi su 10 prove.

Figura 14.6 mostra che il rapporto confronta due altezze della stessa curva.

i Il confine del rapporto di verosimiglianza

Il rapporto di verosimiglianza confronta quanto gli stessi dati siano compatibili con due valori del parametro. Per passare da questo confronto relativo a una distribuzione di probabilità sul parametro occorre introdurre una prior e applicare la regola di aggiornamento bayesiano, come vedremo nel Capitolo 15.

14.11 Errori comuni nell'interpretazione della verosimiglianza

La difficoltà principale non consiste nel calcolare una verosimiglianza, ma nell'interpretarla senza attribuirle un significato che non possiede.

14.11.1 Errore 1: scambiare la probabilità del parametro

La verosimiglianza è $p(y | \theta)$ letta come funzione di θ ; non è $p(\theta | y)$. Per ottenere la posterior occorrono una prior e una normalizzazione.

14.11.2 Errore 2: interpretare l'area come probabilità

L'area sotto una curva di verosimiglianza non ha automaticamente significato probabilistico. Anche una curva riscalata ad area 1 non diventa, per questo solo fatto,

una posterior neutrale.

14.11.3 Errore 3: dimenticare le assunzioni del modello

Una verosimiglianza binomiale assume prove condizionatamente indipendenti e una probabilità comune; una verosimiglianza gaussiana assume la forma normale specificata. Una curva molto concentrata può essere fuorviante se il modello, il campionamento o la misura sono inadeguati.

14.11.4 Errore 4: fermarsi alla MLE

La MLE individua il massimo, ma non rappresenta l'intera incertezza e non incorpora la prior. Una conclusione bayesiana riguarda la posterior, non soltanto il punto che massimizza la verosimiglianza.

14.11.5 Errore 5: confondere confronto relativo e bontà assoluta

Un valore può avere verosimiglianza maggiore di un altro e tuttavia entrambi possono appartenere a un modello che descrive male i dati. La verosimiglianza confronta valori **all'interno del modello specificato**; i controlli predittivi servono a valutare se il modello riesce a generare caratteristiche realistiche dei dati.

Da evitare

Non leggere la curva come una distribuzione di probabilità sul parametro, non interpretare il massimo come certezza e non separare mai la verosimiglianza dalle assunzioni che l'hanno prodotta.

14.12 Dove termina la verosimiglianza

A questo punto il confine concettuale può essere formulato con precisione. La verosimiglianza riassume ciò che i dati dicono **relativamente** ai valori del parametro, ma non è ancora una distribuzione di probabilità su quei valori.

Per ottenere una posterior servono due elementi ulteriori:

1. una **prior**, che assegna i pesi iniziali ai valori del parametro;
2. una **normalizzazione**, che trasforma i pesi aggiornati in una distribuzione di probabilità valida.

Il passaggio può essere anticipato nella forma compatta

$$p(\theta | y) \propto L(\theta; y)p(\theta),$$

ma il suo significato verrà sviluppato nel Capitolo 15. Per ora è sufficiente tratte-

nere l'idea centrale: **la verosimiglianza fornisce l'informazione dei dati; l'aggiornamento bayesiano la combina con l'informazione a priori.**

Riflessioni conclusive

La verosimiglianza è il ponte tra il modello generativo e l'inferenza. Il modello parte da un valore del parametro e descrive i dati che potrebbero essere osservati. Dopo la raccolta, la verosimiglianza mantiene fissi i dati e confronta quanto diversi valori del parametro riescano a renderli plausibili.

Una curva di verosimiglianza comunica più del suo massimo. La posizione indica quali valori sono maggiormente compatibili con i dati; la larghezza mostra quanto nettamente i dati discriminano tra le alternative; la forma rivela eventuali asimmetrie; i rapporti permettono confronti diretti tra valori specifici. Nessuna di queste informazioni rappresenta ancora una probabilità del parametro.

La verosimiglianza, da sola, non conclude quindi l'inferenza bayesiana. Indica come i dati redistribuirebbero il peso tra valori alternativi, ma non specifica i pesi iniziali e non produce ancora una distribuzione normalizzata. Il capitolo successivo introdurrà il passaggio ulteriore: combinare questa informazione con una prior e ottenere la distribuzione a posteriori.

Esercizi

1. In $p(y | \theta)$, che cosa resta fisso e che cosa varia quando la stessa espressione viene letta come verosimiglianza?
2. Perché una verosimiglianza elevata in $\theta = 0.70$ non significa che $P(\theta = 0.70 | y) = 0.70$?
3. Una curva ha il massimo in $\theta = 0.40$. In $\theta = 0.30$ la verosimiglianza relativa è 0.50. Come va interpretato questo valore?
4. Due studi osservano la stessa proporzione di successi, ma uno ha 20 partecipanti e l'altro 500. Quale differenza ti aspetti tra le due curve di verosimiglianza?
5. Perché l'area sotto una curva di verosimiglianza non può essere interpretata automaticamente come probabilità del parametro?
6. In quali condizioni le verosimiglianze di più osservazioni o studi possono essere moltiplicate?
7. Nel modello normale con σ nota, che cosa significa dire che la precisione dei dati per μ è n/σ^2 ?
8. Quali due elementi mancano alla verosimiglianza per ottenere una distribuzione a posteriori sul parametro?

Soluzioni

1. I dati osservati y restano fissi; varia il valore del parametro θ che viene confrontato con gli altri valori possibili.

2. La verosimiglianza misura quanto i dati siano plausibili sotto quel valore. Una probabilità a posteriori richiede anche la prior e la normalizzazione.
3. Il dataset osservato ha, in $\theta = 0.30$, una verosimiglianza pari alla metà di quella raggiunta nel punto di massimo. Non significa che $\theta = 0.30$ abbia probabilità 50%.
4. Entrambe avranno il massimo vicino alla stessa proporzione, ma la curva dello studio con 500 partecipanti sarà normalmente più stretta e discriminerà meglio tra valori vicini.
5. La verosimiglianza non è costruita per sommare o integrare a 1 rispetto al parametro. Per ottenere una distribuzione sul parametro deve essere combinata con una prior e normalizzata.
6. Quando il modello assume indipendenza condizionata dato il parametro e, nel caso di più studi, quando è appropriato rappresentarli con il parametro o la struttura comune specificata.
7. Significa che l'informazione cresce con la numerosità e diminuisce con la variabilità: più osservazioni o una deviazione standard più piccola producono una curva più concentrata per μ .
8. Occorrono una prior, che assegni i pesi iniziali ai valori del parametro, e una normalizzazione, che trasformi i prodotti tra prior e verosimiglianza in una distribuzione di probabilità valida.

i Punti chiave

- La probabilità predittiva e la verosimiglianza usano la stessa espressione $f(y | \theta)$, ma fissano argomenti diversi.
- La verosimiglianza confronta valori parametrici; non assegna loro direttamente probabilità.
- Il massimo indica il valore che rende i dati più plausibili, mentre la larghezza indica quanto i dati discriminano tra alternative.
- Le costanti che non dipendono dal parametro possono essere eliminate nei confronti interni allo stesso modello.
- Per osservazioni condizionatamente indipendenti, le verosimiglianze si moltiplicano e le log-verosimiglianze si sommano.
- Nel modello binomiale:

$$L(\theta; y, n) \propto \theta^y (1 - \theta)^{n-y}.$$

- Nel modello normale con σ nota:

$$L(\mu; y_1, \dots, y_n) \propto \exp \left[-\frac{n}{2\sigma^2} (\mu - \bar{y})^2 \right].$$

- Il rapporto di verosimiglianza confronta il sostegno relativo dei dati a due valori o ipotesi specificati.
- Per ottenere una posterior, la verosimiglianza deve essere combinata

con una prior e normalizzata; questo passaggio è sviluppato nel capitolo successivo.

- Una verosimiglianza precisa può essere fuorviante se il modello o il disegno sono inadeguati.

i Ambiente di sviluppo

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#>
#> LAPACK:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods
#> [7] base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0
#> [3] withr_3.0.3         systemfonts_1.3.2
#> [5] patchwork_1.3.2     ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0
#> [9] ggplot2_4.0.3       reliabilitydiag_0.2.1
#> [11] priorsense_1.2.0    posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7
#> [15] StanHeaders_2.32.10 brms_2.23.1
#> [17] Rcpp_1.1.2          sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1
#> [21] matrixStats_1.5.0   modelr_0.1.11
#> [23] tibble_3.3.1        dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0
#> [27] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1    farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0       tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0    estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5      compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1         yaml_2.3.12
```

```
#> [16] knitr_1.51          labeling_0.4.3      bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0         RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2        grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8       inline_0.3.21
#> [28] emmeans_2.0.4       scales_1.4.0       cli_3.6.6
#> [31] mvtnorm_1.4-2       rmarkdown_2.31     generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_6.2.0 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1     vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-6       jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2  glue_1.8.1         codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5    stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0    pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9  R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1    evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1    memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1   rstantools_2.7.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1    nlme_3.1-170
#> [67] checkmate_2.3.4     xfun_0.60          pkgconfig_2.0.3
```

Dalla verosimiglianza alla posterior: una prima idea dell'aggiornamento bayesiano

i In sintesi

Da sapere La verosimiglianza indica quali valori del parametro sono più compatibili con i dati osservati. L'aggiornamento bayesiano combina questa informazione con la distribuzione a priori e produce una distribuzione a posteriori.

Da saper fare Distinguere prior, verosimiglianza e posterior; spiegare a parole come la verosimiglianza modifica i pesi iniziali; interpretare la posterior come incertezza aggiornata dopo i dati.

Introduzione

Nel Capitolo 14 abbiamo imparato a leggere i dati dal punto di vista della **verosimiglianza**. Mantenendo fissi i dati osservati, abbiamo confrontato valori diversi del parametro e ci siamo chiesti quali li rendessero più compatibili.

Questo è un passaggio essenziale, ma non è ancora un'inferenza bayesiana completa. La verosimiglianza ci dice come i dati discriminano tra valori alternativi del parametro; da sola, però, non esprime quanto tali valori fossero plausibili prima dell'osservazione e non assegna loro probabilità posteriori.

L'aggiornamento bayesiano aggiunge precisamente questo passaggio. Parte da una distribuzione **a priori**, usa la verosimiglianza per ripesarne i valori e ottiene una distribuzione **a posteriori**. In forma narrativa:

Partiamo da ciò che era plausibile prima dei dati, osserviamo quali possibilità spiegano meglio ciò che è accaduto e aggiorniamo di conseguenza la nostra incertezza.

Questo breve capitolo introduce soltanto il significato di tale operazione. L'approssimazione su griglia, le famiglie coniugate, l'analisi di sensibilità e l'interpretazione dettagliata della posterior saranno sviluppate nel Companion.

! L'idea centrale

La prior assegna i pesi iniziali. La verosimiglianza indica come i dati debbano modificarli. La posterior rappresenta i pesi dopo l'aggiornamento.

💡 Prerequisiti

Per seguire il capitolo è utile aver letto:

- Capitolo 5, per la regola di Bayes;
- Capitolo 14, per il significato della verosimiglianza;
- Capitolo 11, per la distribuzione binomiale.

Panoramica del capitolo

Il percorso è intenzionalmente breve. Distingueremo prior, verosimiglianza e posterior; vedremo come queste tre quantità si collegano; infine seguiremo un semplice aggiornamento su tre valori possibili del parametro. L'obiettivo non è imparare una tecnica di calcolo generale, ma comprendere il ruolo della verosimiglianza nell'inferenza bayesiana.

i Preparazione del notebook

```
if (requireNamespace("here", quietly = TRUE) &&
    file.exists(here::here("code", "_common.R"))) {
  source(here::here("code", "_common.R"))
}

if (exists("apply_visual_theme")) {
  apply_visual_theme()
}
```

15.1 Tre oggetti, un unico processo

Consideriamo un parametro θ che rappresenta la probabilità di successo in una prova. Prima e dopo i dati parliamo sempre dello stesso parametro, ma cambia l'informazione disponibile.

La **prior**, indicata con $p(\theta)$, descrive l'incertezza iniziale:

Prima di osservare i nuovi dati, quali valori di θ considero più plausibili?

È una distribuzione di probabilità sul parametro. Può riflettere conoscenze precedenti, risultati di studi passati oppure assunzioni formulate prima dell'osservazione corrente.

La **verosimiglianza**, indicata con $p(y | \theta)$, introduce l'informazione dei dati:

Se θ assumesse un certo valore, quanto sarebbero compatibili con esso i dati y che ho osservato?

Con i dati mantenuti fissi, la verosimiglianza confronta valori alternativi del parametro. Non è però, in quanto tale, una distribuzione di probabilità su θ : descrive il sostegno relativo fornito dai dati.

La **posterior**, indicata con $p(\theta | y)$, esprime infine l'incertezza aggiornata:

Dopo aver osservato i dati, quali valori di θ considero più plausibili?

Oggetto	Domanda	Ruolo nell'aggiornamento
Prior $p(\theta)$	Che cosa era plausibile prima dei dati?	Assegna i pesi iniziali
Verosimiglianza $p(y \theta)$	Quali valori sono più compatibili con i dati?	Modifica i pesi iniziali
Posterior $p(\theta y)$	Che cosa è plausibile dopo i dati?	Esprime l'incertezza aggiornata

La posterior non sostituisce semplicemente la prior con i dati. Nasce dall'incontro tra le due fonti di informazione. Un valore del parametro riceve molto peso a posteriori quando era plausibile in partenza e, nello stesso tempo, rende plausibili i dati osservati. Se una di queste due condizioni manca, il suo peso finale si riduce.

15.2 La regola di aggiornamento

La regola di Bayes per un parametro si scrive:

$$p(\theta | y) = \frac{p(y | \theta)p(\theta)}{p(y)}.$$

Per comprendere il meccanismo è spesso sufficiente concentrarsi sulla forma proporzionale:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

Questa espressione riassume l'intero aggiornamento:

$$\text{posterior} \propto \text{verosimiglianza} \times \text{prior}.$$

Per ogni valore possibile di θ , la verosimiglianza agisce sul peso assegnato dalla prior. Se i dati sono molto compatibili con quel valore, il peso viene relativamente

rafforzato; se sono poco compatibili, viene ridotto. Dopo questo ripesamento, i valori vengono riportati su una scala probabilistica, ottenendo la posterior.

i Che cosa significano prodotto e normalizzazione?

Il prodotto viene eseguito **punto per punto**. Il peso a priori di ciascun valore θ_i viene moltiplicato per la verosimiglianza calcolata nello stesso valore:

$$\text{peso aggiornato non normalizzato} = \text{prior} \times \text{verosimiglianza}.$$

Nel caso discreto, i prodotti vengono poi divisi per la loro somma:

$$p(\theta_i | y) = \frac{p(y | \theta_i)p(\theta_i)}{\sum_j p(y | \theta_j)p(\theta_j)}.$$

Nel caso continuo, il principio è analogo, ma la normalizzazione riguarda l'area complessiva della distribuzione.

La normalizzazione non aggiunge nuove informazioni e non cambia i rapporti tra i pesi. Li trasforma semplicemente in probabilità che sommano, o integrano, a 1.

Un'immagine utile è quella dei gettoni: la prior assegna a ogni possibilità un numero iniziale di gettoni; la verosimiglianza li moltiplica in base a quanto quella possibilità spiega i dati; la normalizzazione converte infine i gettoni aggiornati in percentuali del totale.

15.3 Un esempio con tre valori possibili

Supponiamo di osservare 7 successi in 10 prove. Per rendere visibile il meccanismo, consideriamo soltanto tre valori possibili del parametro:

$$\theta \in \{0.30, 0.50, 0.70\}.$$

Prima di osservare i dati assegniamo i pesi seguenti:

$$p(0.30) = 0.20, \quad p(0.50) = 0.50, \quad p(0.70) = 0.30.$$

La prior favorisce dunque $\theta = 0.50$. I dati, però, contengono 7 successi su 10 e risultano maggiormente compatibili con $\theta = 0.70$. L'aggiornamento deve tenere conto di entrambe le informazioni.

θ	Prior	Verosimiglianza	Prodotto	Posterior
0.30	0.200	0.009	0.0018	0.013
0.50	0.500	0.117	0.0586	0.417
0.70	0.300	0.267	0.0800	0.570

La colonna **Prodotto** mostra i pesi dopo che la verosimiglianza ha modificato la

prior, ma prima della normalizzazione. La colonna **Posterior** esprime gli stessi pesi come probabilità.

```
theta_values <- c(0.30, 0.50, 0.70)
prior <- c(0.20, 0.50, 0.30)
likelihood <- dbinom(7, size = 10, prob = theta_values)
unnormalized <- prior * likelihood
posterior <- unnormalized / sum(unnormalized)

update_data <- rbind(
  data.frame(
    theta = factor(theta_values),
    value = prior,
    phase = "1. Prior"
  ),
  data.frame(
    theta = factor(theta_values),
    value = likelihood,
    phase = "2. Verosimiglianza"
  ),
  data.frame(
    theta = factor(theta_values),
    value = unnormalized,
    phase = "3. Prodotto"
  ),
  data.frame(
    theta = factor(theta_values),
    value = posterior,
    phase = "4. Posterior"
  )
)

update_data$phase <- factor(
  update_data$phase,
  levels = c(
    "1. Prior",
    "2. Verosimiglianza",
    "3. Prodotto",
    "4. Posterior"
  )
)

ggplot(update_data, aes(x = theta, y = value)) +
  geom_col() +
  facet_wrap(~ phase, scales = "free_y") +
  labs(
    x = expression(theta),
    y = "Valore sulla scala propria"
  )
```




Figura 15.1: Aggiornamento bayesiano su tre valori possibili. La verosimiglianza ripesa la prior; la normalizzazione produce la posterior. Le scale verticali sono separate perché le quattro quantità svolgono ruoli differenti.

La Figura 15.1 mostra che la posterior non coincide né con la prior né con la verosimiglianza. Prima dei dati, $\theta = 0.50$ aveva il peso maggiore. Dopo l'osservazione, $\theta = 0.70$ diventa il valore più plausibile perché unisce un peso iniziale non trascurabile alla verosimiglianza più elevata.

Il valore $\theta = 0.30$, al contrario, perde quasi tutto il peso: era già meno favorito dalla prior e rende poco plausibili i 7 successi osservati. La verosimiglianza ha quindi trasformato l'informazione contenuta nei dati in una modifica dei pesi iniziali.

⚠ Una semplificazione didattica

I tre valori non sono gli unici valori possibili di θ . Sono stati scelti per mostrare ogni passaggio in modo trasparente. Nel caso continuo si considera un intero intervallo di valori, ma l'idea rimane la stessa: la verosimiglianza ripesa la prior e il risultato viene normalizzato.

15.4 Che cosa ci dice la posterior?

Dopo l'aggiornamento, la distribuzione può cambiare soprattutto in due modi.

Può cambiare la **posizione**: la posterior si sposta verso i valori maggiormente sostenuti dai dati, nella misura consentita dai pesi iniziali della prior.

Può cambiare anche la **concentrazione**: alcuni valori acquistano molto più peso relativo di altri e l'incertezza può ridursi. Questa maggiore precisione deve però essere interpretata condizionatamente al modello, alla prior e ai dati utilizzati.

Non esiste una regola secondo cui la posterior debba trovarsi esattamente "a metà" tra prior e verosimiglianza. Il risultato dipende dalla posizione e dalla concentrazione

della prior, dalla quantità di dati e dal modello che determina la verosimiglianza.

! La precisione non basta

Una posterior molto concentrata non garantisce che la conclusione sia valida. L'aggiornamento bayesiano non corregge automaticamente un campione distorto, una misura inadeguata o un modello mal specificato. Descrive l'incertezza all'interno delle assunzioni adottate.

15.5 Dove prosegue l'approfondimento

Questo capitolo ha isolato soltanto il principio dell'aggiornamento. Il Companion ne sviluppa gli aspetti operativi e le estensioni:

- **approssimazione su griglia**: rende visibili prodotto e normalizzazione su molti valori del parametro;
- **modello Beta-Binomiale e famiglie coniugate**: mostra quando la posterior può essere ottenuta analiticamente e introduce anche l'aggiornamento sequenziale e il caso Normale-Normale;
- **comprendere e comunicare la posterior**: sviluppa stime, intervalli di credibilità e probabilità posteriori;
- **equilibrio tra prior e verosimiglianza**: approfondisce la forza relativa delle due fonti e l'analisi di sensibilità.

La divisione del lavoro è intenzionale: **qui si comprende che cosa fa la verosimiglianza nell'aggiornamento; nel Companion si impara a calcolare, analizzare e comunicare la posterior.**

Riflessioni conclusive

La verosimiglianza non è ancora una conclusione sul parametro. È il modo in cui i dati indicano quali valori meritano di essere rafforzati e quali devono essere ridimensionati.

L'inferenza bayesiana usa questa informazione per aggiornare una distribuzione iniziale. La prior stabilisce il punto di partenza, la verosimiglianza introduce il contributo dei dati e la posterior descrive la nuova distribuzione dell'incertezza.

Il significato fondamentale dell'aggiornamento può quindi essere espresso in una sola frase:

I dati non cancellano ciò che sapevamo prima, ma ne modificano in modo coerente i pesi.

I dettagli matematici e computazionali saranno sviluppati più avanti. Per ora è sufficiente comprendere il ruolo della verosimiglianza: essa costituisce il ponte attraverso cui i dati trasformano la prior nella posterior.

Esercizi

1. Quale domanda distingue la prior dalla verosimiglianza?
2. Perché la verosimiglianza non è già una posterior?
3. In che senso la verosimiglianza modifica i pesi assegnati dalla prior?
4. Un valore di θ ha prior elevata ma verosimiglianza quasi nulla. Che cosa accade al suo peso a posteriori?
5. Un valore ha verosimiglianza massima ma prior uguale a zero. Può ricevere peso a posteriori all'interno dello stesso modello?
6. Qual è la funzione della normalizzazione? Aggiunge informazione ai dati?
7. Nell'esempio con tre valori, perché $\theta = 0.70$ supera $\theta = 0.50$ dopo l'aggiornamento?
8. Perché una posterior molto concentrata non dimostra, da sola, che il modello sia corretto?

Soluzioni

1. La prior descrive quali valori sono plausibili prima dei dati; la verosimiglianza descrive quanto i dati osservati siano compatibili con ciascun valore.
2. Perché non incorpora i pesi iniziali della prior e, considerata come funzione del parametro, non costituisce una distribuzione di probabilità posteriore.
3. Il peso a priori di ciascun valore viene moltiplicato per la verosimiglianza calcolata nello stesso valore. I dati rafforzano relativamente i valori più compatibili e ridimensionano gli altri.
4. Il prodotto sarà quasi nullo, quindi quel valore riceverà pochissimo peso a posteriori.
5. No. Il prodotto tra prior uguale a zero e qualunque verosimiglianza resta zero. Il modello ha escluso quel valore prima di osservare i dati.
6. Trasforma i prodotti in probabilità che sommano o integrano a 1. Non aggiunge evidenza e non cambia i rapporti relativi tra i prodotti.
7. Perché i dati favoriscono molto di più 0.70 e il suo peso a priori è comunque consistente; il prodotto risulta quindi maggiore.
8. Perché la concentrazione è condizionata alla prior, alla verosimiglianza, ai dati e al modello. Assunzioni o misure inadeguate possono produrre una posterior precisa ma fuorviante.

Punti chiave

- La prior è una distribuzione di probabilità sul parametro prima dei dati.
- La verosimiglianza confronta quanto i dati siano compatibili con valori alternativi del parametro.
- La posterior è una distribuzione di probabilità sul parametro dopo i dati.
- La regola fondamentale è:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

- La verosimiglianza ripesa punto per punto i valori della prior.
- La normalizzazione converte i prodotti in probabilità senza modificarne i rapporti.
- Un valore escluso dalla prior con probabilità zero non può essere recuperato dai dati all'interno dello stesso modello.
- La posterior resta condizionata alla qualità del modello, della prior e dei dati.
- Gli sviluppi matematici, computazionali e interpretativi sono trattati nel Companion.

i Ambiente di sviluppo

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods
#> [7] base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0
#> [3] withr_3.0.3         systemfonts_1.3.2
#> [5] patchwork_1.3.2     ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0
#> [9] ggplot2_4.0.3       reliabilitydiag_0.2.1
#> [11] priorsense_1.2.0    posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7
#> [15] StanHeaders_2.32.10 brms_2.23.1
#> [17] Rcpp_1.1.2          sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1
#> [21] matrixStats_1.5.0   modelr_0.1.11
#> [23] tibble_3.3.1        dplyr_1.2.1
```

```

#> [25] tidyr_1.3.2          rio_1.3.0
#> [27] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8          tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51           labeling_0.4.3        bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8       curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8          purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1         xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4        scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2        rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0           RcppParallel_6.2.0    cachem_1.1.0
#> [37] stringr_1.6.0        parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0             Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2   glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5        stringi_1.8.7
#> [49] gtable_0.3.6         QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9      Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5    rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9       backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13         snakecase_0.11.1      rstantools_2.7.0
#> [64] coda_0.19-4.1        gridExtra_2.3.1       nlme_3.1-170
#> [67] checkmate_2.3.4      xfun_0.60             pkgconfig_2.0.3

```

Conclusioni: dalla probabilità all'inferenza bayesiana

i In sintesi

Da sapere Il percorso ha costruito un unico filo logico: rappresentare l'incertezza con distribuzioni di probabilità, descrivere come i dati possono essere generati, misurare l'informazione fornita dai dati mediante la verosimiglianza e aggiornare le credenze con la regola di Bayes.

Da saper fare Riconoscere il ruolo di variabili, distribuzioni, parametri, prior, verosimiglianza e posterior; spiegare che cosa cambia dopo l'osservazione dei dati; distinguere precisione inferenziale e validità scientifica.

Nel Capitolo 15 abbiamo incontrato la formula che ricompone l'intero percorso:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

La sua forma è compatta, ma il suo significato dipende da tutti i concetti introdotti nei capitoli precedenti. Per comprenderla occorre sapere che cosa rappresenta una probabilità, come una variabile casuale traduce un fenomeno in una quantità osservabile, quale ruolo svolge una distribuzione, perché un campione contiene informazione limitata e in che modo la verosimiglianza mette in relazione i dati con i valori possibili di un parametro.

Questo capitolo non introduce una nuova tecnica. Conclude il modulo ricostruendo il filo che unisce le idee già apprese e chiarendo che cosa il lettore dovrebbe saper riconoscere prima di affrontare i modelli bayesiani sviluppati nel manuale e nel Companion.

Quando i concetti probabilistici vengono studiati separatamente, è facile considerarli come una raccolta di formule: regole della probabilità, distribuzioni, medie, varianze, correlazioni e funzioni di verosimiglianza. Nell'inferenza bayesiana, invece, questi elementi partecipano a un'unica costruzione. La domanda generale che li collega è:

Come possiamo passare da osservazioni variabili a conclusioni esplicite e

controllabili su quantità che non conosciamo direttamente?

Per rispondere dobbiamo definire ciò che osserviamo, specificare un modello probabilistico, rappresentare l'incertezza iniziale, confrontare il modello con i dati e aggiornare i pesi assegnati ai valori possibili del parametro.

! Il filo conduttore

L'inferenza bayesiana non comincia dalla formula di Bayes. Comincia dalla costruzione di un modello che colleghi un fenomeno psicologico, le osservazioni disponibili e le quantità ignote sulle quali vogliamo apprendere.

💡 Prerequisiti

Questo capitolo richiama l'intero percorso. Sono particolarmente importanti:

- Capitolo 13, per distinguere dati osservati, variabilità campionaria e precisione;
- Capitolo 14, per comprendere quale informazione i dati forniscono sui valori del parametro;
- Capitolo 15, per il passaggio da prior e verosimiglianza alla posterior.

i Preparazione del notebook

Questo capitolo non introduce nuovi calcoli. Il blocco seguente mantiene comunque la stessa configurazione degli altri capitoli del sito.

```
if (requireNamespace("here", quietly = TRUE) &&
    file.exists(here::here("code", "_common.R"))) {
  source(here::here("code", "_common.R"))
}

if (exists("apply_visual_theme")) {
  apply_visual_theme()
}
```

16.1 Dal fenomeno all'inferenza: un unico percorso

Un'analisi probabilistica nasce da un problema sostantivo, non da una distribuzione scelta in astratto. In psicologia potremmo voler comprendere la probabilità di una risposta corretta, la frequenza di un comportamento, il tempo necessario per completare un compito oppure la relazione tra due caratteristiche individuali. In ogni caso, il passaggio dal fenomeno all'inferenza segue una sequenza di domande collegate.

Che cosa osserviamo? Una **variabile casuale** rappresenta numericamente un esito incerto. La sua definizione stabilisce quali osservazioni sono possibili e quale informazione viene conservata dalla codifica.

Quali valori può assumere? Il **supporto** permette di distinguere, per esempio, un esito binario, un conteggio, una proporzione o una misura continua. Esclude le famiglie di distribuzioni incompatibili, ma non determina da solo quale modello sia appropriato.

Come potrebbero essere generati i dati? Una distribuzione per i dati specifica quali osservazioni sono plausibili sotto determinati valori dei parametri. Questa è la componente generativa del modello:

$$y \sim p(y | \theta).$$

Il parametro θ controlla una proprietà rilevante del processo, come una probabilità, una media, una variabilità, un tasso o una relazione tra variabili.

Che cosa sappiamo prima dei nuovi dati? La prior $p(\theta)$ rappresenta l'incertezza iniziale sul parametro. Non è una dichiarazione assoluta e indipendente dal contesto: dipende dalle informazioni disponibili, dalla scala del parametro e dalle assunzioni che siamo disposti a formulare.

Che cosa dicono i dati sui valori del parametro? Dopo aver osservato y , la quantità $p(y | \theta)$ viene letta come funzione di θ . In questo ruolo è la **verosimiglianza**: confronta i valori del parametro in base a quanto rendono compatibili i dati osservati. I dati non assegnano da soli probabilità ai parametri, ma modificano il loro confronto relativo.

Come cambiano i pesi assegnati alle possibilità? L'aggiornamento bayesiano combina prior e verosimiglianza:

$$p(\theta | y) = \frac{p(y | \theta)p(\theta)}{p(y)}.$$

La posterior $p(\theta | y)$ descrive l'incertezza aggiornata, condizionatamente al modello, alla prior e ai dati. Apprendere non significa eliminare l'incertezza, ma ridistribuire in modo coerente i pesi assegnati alle possibilità.

Il modello è adeguato allo scopo? La posterior non conclude il lavoro. Occorre ancora chiedersi se il modello riproduca gli aspetti importanti dei dati, se le conclusioni siano sensibili alle scelte iniziali e se il disegno di ricerca permetta l'interpretazione sostantiva proposta. Questi passaggi saranno sviluppati nel Companion.

Questa sequenza mostra perché nessuno dei concetti introdotti nel modulo è isolato. Le variabili definiscono ciò che può essere osservato; le distribuzioni descrivono come tali osservazioni possono variare; i parametri rappresentano aspetti ignoti del processo; prior e verosimiglianza apportano due fonti diverse di informazione; la posterior ne esprime la sintesi aggiornata.

16.2 La mappa essenziale del percorso

Il modulo può essere riletto come una progressione in quattro movimenti.

Il primo riguarda la **coerenza probabilistica**. In Capitolo 1 la probabilità è stata introdotta come rappresentazione dell'incertezza; in Capitolo 2 gli assiomi hanno definito le condizioni minime di coerenza; in Capitolo 3, Capitolo 4 e Capitolo 5

sono state sviluppate le regole che permettono di combinare e aggiornare probabilità. L'idea centrale è che le probabilità non sono numeri isolati: devono rispettare relazioni coerenti tra eventi e informazioni disponibili.

Il secondo movimento riguarda le **quantità incerte e le loro distribuzioni**. In Capitolo 6 le variabili casuali hanno collegato gli esiti a quantità numeriche; in Capitolo 7 sono state distinte massa, densità e funzione di ripartizione; in Capitolo 8 e Capitolo 9 sono state introdotte proprietà come valore atteso, varianza, covarianza e correlazione; infine, in Capitolo 10, Capitolo 11 e Capitolo 12 sono state esaminate alcune famiglie di distribuzioni e i loro possibili ruoli. Una distribuzione, dunque, non è soltanto una forma grafica: è una descrizione delle possibilità e dei pesi loro assegnati.

Il terzo movimento riguarda l'**informazione contenuta nei dati**. In Capitolo 13 è stato chiarito perché una statistica campionaria varia da un campione all'altro; in Capitolo 14 i dati osservati sono stati usati per confrontare i valori possibili del parametro. L'informazione fornita dai dati è relativa e la sua forza dipende dalla quantità e dalla qualità delle osservazioni, oltre che dalla forma del modello.

Il quarto movimento è l'**aggiornamento**. In Capitolo 15 prior e verosimiglianza sono state combinate per ottenere la posterior. Qui le parti precedenti si ricompongono: le possibilità iniziali vengono ripesate alla luce dei dati, ma l'incertezza non scompare e le conclusioni restano condizionate alle assunzioni adottate.

i Una formula, tre ruoli

Nell'espressione

$$p(\theta | y) \propto p(y | \theta)p(\theta),$$

- $p(\theta)$ descrive l'incertezza **prima** dei nuovi dati;
- $p(y | \theta)$ descrive l'informazione fornita **dai dati**;
- $p(\theta | y)$ descrive l'incertezza **dopo** l'aggiornamento.

Confondere questi tre ruoli significa perdere il significato dell'inferenza bayesiana.

16.3 Come leggere criticamente un'analisi bayesiana

Comprendere un'analisi bayesiana non significa soltanto saper leggere una media posteriore o un intervallo di credibilità. Significa ricostruire il ragionamento che collega la domanda scientifica, il modello, i dati e le conclusioni.

Il primo passo è chiedersi **quale sia la domanda scientifica**. Il parametro deve avere un significato collegato al problema psicologico: una stima numerica è utile solo se sappiamo quale proprietà del fenomeno rappresenta.

Occorre poi identificare **il modello dei dati**: quali osservazioni sono possibili, quale distribuzione è stata scelta e quali assunzioni vengono formulate. Tra queste

possono rientrare l'indipendenza condizionata, la forma della distribuzione o la costanza dei parametri.

La lettura deve considerare anche **il ruolo della prior**. È importante capire quali valori favorisce o penalizza, quanto sia concentrata e se la sua scelta sia plausibile sulla scala adottata. La prior non va valutata in astratto, ma in relazione alla domanda, al parametro e alle conoscenze disponibili.

Il confronto tra prior e posterior mostra poi **che cosa il modello ha appreso dai dati**. La posterior può spostarsi, concentrarsi oppure conservare una forte incertezza. Nessuno di questi esiti può essere interpretato senza considerare la forma della verosimiglianza e la quantità di informazione disponibile.

Resta quindi da valutare **quale incertezza permanga**. Una posterior rappresenta un insieme di valori plausibili, non soltanto un'unica stima, e la sua concentrazione deve essere letta condizionatamente alle assunzioni del modello.

Infine, bisogna chiedersi **se le conclusioni siano adeguate ai dati e al disegno di ricerca**. L'inferenza statistica non trasforma automaticamente un'associazione in un effetto causale, non corregge misure poco valide e non rende rappresentativo un campione distorto.

16.4 Precisione, validità e trasparenza

Questa ultima distinzione conduce a uno dei messaggi più importanti del modulo: **precisione inferenziale e validità scientifica non sono la stessa cosa**.

Una posterior molto concentrata indica che, all'interno del modello, alcuni valori hanno ricevuto molto più peso di altri. Non dimostra però che il campione rappresenti la popolazione di interesse, che la misura rappresenti correttamente il costrutto psicologico, che la distribuzione scelta descriva adeguatamente i dati, che un'interpretazione causale sia giustificata o che la prior e le altre assunzioni siano irrilevanti.



Un risultato preciso può essere precisamente sbagliato

Aumentare il numero di osservazioni riduce alcune forme di incertezza, ma non elimina automaticamente bias sistematici, errori di misurazione o inadeguatezze del modello.

L'approccio bayesiano rende esplicite molte scelte che in altri approcci possono rimanere implicite. Questa trasparenza è un vantaggio solo se prior, modello, dati e limiti vengono documentati e sottoposti a controllo critico. Una buona analisi non si limita quindi a produrre una posterior: rende comprensibile il percorso che ha condotto a quella distribuzione e chiarisce quali conclusioni essa può, e non può, sostenere.

16.5 Dal modulo introduttivo ai modelli bayesiani

Questo sito ha fornito il linguaggio probabilistico necessario per seguire l'inferenza bayesiana, senza trasformarsi in un secondo manuale operativo. Il suo punto di arrivo non è l'applicazione meccanica di una formula, ma l'acquisizione di un modo di ragionare.

La probabilità non elimina l'incertezza: permette di rappresentarla e di ragionare in sua presenza. Le variabili casuali definiscono i possibili esiti osservabili; le distribuzioni specificano i pesi assegnati a tali esiti; la verosimiglianza mostra come i dati modificano il confronto tra i valori dei parametri; la regola di Bayes integra questa informazione con ciò che era ritenuto plausibile prima dell'osservazione.

Da qui in avanti, ogni analisi richiederà di formulare con chiarezza alcune domande:

- che cosa sto modellando?
- quali assunzioni sto introducendo?
- quale informazione proviene dai dati?
- quale incertezza rimane?
- quali conclusioni sono realmente sostenute dal disegno di ricerca?

Queste domande accompagneranno tutti i modelli successivi, dai casi più semplici alle analisi gerarchiche e computazionali. Cambieranno le distribuzioni, la complessità dei modelli e gli algoritmi, ma non la logica fondamentale: costruire un modello, confrontarlo con i dati, aggiornare l'incertezza e verificare criticamente quanto appreso.

Nel [Companion](#) il percorso prosegue con:

- costruzione e simulazione di modelli generativi;
- approssimazione della posterior e famiglie coniugate;
- interpretazione e comunicazione delle distribuzioni posteriori;
- controlli predittivi e analisi di sensibilità;
- modelli di regressione, modelli gerarchici e metodi computazionali;
- codice R e Stan riproducibile.

Il manuale mantiene invece il centro sul significato psicologico e inferenziale dei modelli. La divisione del lavoro è intenzionale:

questo sito fornisce il linguaggio della probabilità; il manuale sviluppa il ragionamento; il Companion mostra i modelli in azione.

Esercizi

1. Perché la formula di Bayes, da sola, non basta a definire un'analisi scientificamente utile?
2. Qual è la differenza tra il supporto di una variabile e la distribuzione scelta per modellarla?
3. Che cosa distingue la distribuzione dei dati dalla prior sul parametro?

4. Quale informazione fornisce la verosimiglianza e quale informazione non fornisce?
5. In che senso la posterior rappresenta un aggiornamento dei pesi assegnati ai valori del parametro?
6. Perché una posterior più concentrata non implica necessariamente una conclusione più valida?
7. Quali domande dovresti porre prima di interpretare un intervallo di credibilità?
8. Qual è la differenza tra aggiornare l'incertezza sui parametri e controllare l'adeguatezza del modello?

Soluzioni

1. Perché occorre specificare che cosa rappresentano dati e parametri, come i dati sono generati, quale prior viene adottata e se il modello è adeguato alla domanda scientifica.
2. Il supporto indica quali valori sono possibili; la distribuzione assegna pesi probabilistici a quei valori. Più distribuzioni possono condividere lo stesso supporto.
3. La distribuzione dei dati descrive le osservazioni possibili condizionata ai parametri; la prior descrive l'incertezza sui parametri prima dei nuovi dati.
4. La verosimiglianza confronta quanto i dati osservati siano compatibili con i valori del parametro. Non assegna, da sola, probabilità posteriori ai parametri.
5. La verosimiglianza moltiplica i pesi iniziali della prior e la normalizzazione trasforma i prodotti in una nuova distribuzione di probabilità.
6. Perché la concentrazione è valutata all'interno delle assunzioni adottate. Campionamento distorto, misure inadeguate o un modello mal specificato possono produrre conclusioni precise ma fuorvianti.
7. Quale parametro rappresenta, quale modello è stato usato, quale prior è stata scelta, quali dati sono stati osservati e quali assunzioni condizionano l'intervallo.
8. L'aggiornamento produce una posterior sui parametri assumendo valido il modello specificato. Il controllo di adeguatezza valuta invece se quel modello riesce a rappresentare gli aspetti dei dati rilevanti per la domanda scientifica.

Punti chiave

- La probabilità è un linguaggio coerente per rappresentare l'incertezza.
- Una variabile casuale collega gli esiti possibili a una rappresentazione numerica.
- Una distribuzione assegna pesi ai valori possibili e può svolgere ruoli differenti nel modello.
- Il modello dei dati descrive come le osservazioni dipendono dai parametri.

- La prior rappresenta l'incertezza sui parametri prima dei nuovi dati.
- La verosimiglianza rappresenta l'informazione relativa fornita dai dati osservati.
- La posterior combina prior e verosimiglianza:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

- La posterior resta condizionata al modello, alla prior e ai dati.
- Precisione inferenziale e validità scientifica non sono la stessa cosa.
- Il Companion sviluppa il workflow operativo e i modelli applicati.

i Ambiente di sviluppo

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#>
#> LAPACK:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods
#> [7] base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0
#> [3] withr_3.0.3         systemfonts_1.3.2
#> [5] patchwork_1.3.2     ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0
#> [9] ggplot2_4.0.3       reliabilitydiag_0.2.1
#> [11] priorsense_1.2.0    posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7
#> [15] StanHeaders_2.32.10 brms_2.23.1
#> [17] Rcpp_1.1.2          sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1
#> [21] matrixStats_1.5.0   modelr_0.1.11
#> [23] tibble_3.3.1        dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0
#> [27] here_1.0.2
```

```
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8          tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51           bridgesampling_1.2-1  pkgbuild_1.4.8
#> [19] curl_7.1.0           RColorBrewer_1.1-3    abind_1.4-8
#> [22] purrr_1.2.2          grid_4.6.1            stats4_4.6.1
#> [25] xtable_1.8-8         inline_0.3.21          emmeans_2.0.4
#> [28] scales_1.4.0         cli_3.6.6             mvtnorm_1.4-2
#> [31] rmarkdown_2.31       generics_0.1.4        otel_0.2.0
#> [34] RcppParallel_6.2.0   cachem_1.1.0          stringr_1.6.0
#> [37] parallel_4.6.1       vctrs_0.7.3           V8_8.2.0
#> [40] Matrix_1.7-6         jsonlite_2.0.0        arrayhelpers_1.1-2
#> [43] glue_1.8.1           codetools_0.2-20      distributional_0.8.1
#> [46] lubridate_1.9.5      stringi_1.8.7          gtable_0.3.6
#> [49] QuickJSR_1.10.0      pillar_1.11.1         htmltools_0.5.9
#> [52] Brodningnag_1.2-9    R6_2.6.1              textshaping_1.0.5
#> [55] rprojroot_2.1.1      evaluate_1.0.5        lattice_0.22-9
#> [58] backports_1.5.1      memoise_2.0.1         broom_1.0.13
#> [61] snakecase_0.11.1     rstantools_2.7.0      coda_0.19-4.1
#> [64] gridExtra_2.3.1      nlme_3.1-170          checkmate_2.3.4
#> [67] xfun_0.60            pkgconfig_2.0.3
```


Simbologia di base

Per una scrittura più sintetica possono essere utilizzati alcuni simboli matematici. Questa appendice organizza i simboli più frequenti per categoria tematica, facilitando la consultazione rapida.

A.1 Logica e quantificatori

Simboli utilizzati per esprimere relazioni logiche e condizioni di esistenza.

- L'operatore logico booleano $\wedge$ significa "e" (congiunzione forte) mentre il connettivo di disgiunzione $\vee$ significa "o" (oppure) (congiunzione debole).
- L'implicazione logica " $\Rightarrow$ " significa "implica" (se ...allora). $P \Rightarrow Q$ vuol dire che P è condizione sufficiente per la verità di Q e che Q è condizione necessaria per la verità di P .
- L'equivalenza matematica " $\Leftrightarrow$ " significa "se e solo se" e indica una condizione necessaria e sufficiente, o corrispondenza biunivoca.
- Il quantificatore esistenziale $\exists$ vuol dire "esiste almeno un" e indica l'esistenza di almeno una istanza del concetto/oggetto indicato.
- Il quantificatore esistenziale di unicità $\exists!$ ("esiste soltanto un") indica l'esistenza di esattamente una istanza del concetto/oggetto indicato.
- Il quantificatore esistenziale $\nexists$ nega l'esistenza del concetto/oggetto indicato.
- Il quantificatore universale $\forall$ vuol dire "per ogni."
- Il simbolo $|$ si legge "tale che."

A.2 Teoria degli insiemi

Simboli per descrivere insiemi, appartenenza, relazioni e operazioni.

- A, S : insiemi.
- $x \in A$: x è un elemento dell'insieme A . Il simbolo $\notin$ vuol dire "non appartiene."
- $\subseteq$ si legge "è un sottoinsieme di" (può coincidere con l'insieme stesso). Il simbolo $\subset$ si legge "è un sottoinsieme proprio di."
- $\#$ indica la cardinalità di un insieme (numero di elementi).

- $\cap$ indica l'intersezione di due insiemi. Il simbolo $\cup$ indica l'unione di due insiemi.
- $\emptyset$ indica l'insieme vuoto o evento impossibile.

A.3 Notazione matematica generale

Simboli e convenzioni per operazioni e relazioni matematiche comuni.

- $\log(x)$: il logaritmo naturale di x .
- $\triangleq$ (o $:=$) si legge "uguale per definizione."
- Δ indica la differenza fra due valori della variabile scritta a destra del simbolo.
- $\propto$ si legge "proporzionale a."
- $\approx$ si legge "circa."
- In matematica, argmax identifica l'insieme dei punti per i quali una data funzione raggiunge il suo massimo. In altre parole, $\operatorname{argmax}_x f(x)$ è l'insieme dei valori di x per i quali $f(x)$ raggiunge il valore più alto.

A.4 Algebra lineare

Convenzioni per rappresentare oggetti matematici di diversa dimensione.

- a, c, α, γ : scalari.
- x, y : vettori (in grassetto).
- X, Y : matrici (maiuscole in grassetto).

A.5 Probabilità e statistica

Notazione per variabili casuali, distribuzioni e funzioni probabilistiche.

A.5.1 Notazione generale

- $X \sim p$: la variabile casuale X si distribuisce come p .
- $p(\cdot)$: distribuzione di massa o di densità di probabilità.
- $p(y | x)$: la probabilità o densità di y dato x , ovvero $p(y = Y | x = X)$.
- $f(x)$: una funzione arbitraria di x .
- $f(X; \theta, \gamma)$: f è una funzione di X con parametri θ, γ . Questa notazione indica che X sono i dati che vengono passati ad un modello di parametri θ, γ .

A.5.2 Distribuzioni di probabilità comuni

- $\mathcal{B}(p)$: distribuzione di Bernoulli di parametro p (probabilità di successo).
- $\operatorname{Bin}(n, p)$: distribuzione binomiale di parametri n (numero di prove) e p (probabilità di successo).

- $\text{Poisson}(\lambda)$: distribuzione di Poisson di parametro λ (tasso medio).
- $\mathcal{N}(\mu, \sigma^2)$: distribuzione gaussiana di media μ e varianza σ^2 .
- $\mathcal{U}(a, b)$: distribuzione uniforme con limite inferiore a e limite superiore b .
- $\text{Beta}(\alpha, \beta)$: distribuzione Beta di parametri α e β .
- $\text{Cauchy}(\alpha, \beta)$: distribuzione di Cauchy di parametri α (posizione: media) e β (scala: radice quadrata della varianza).

A.5.3 Altre misure statistiche

- $\mathbb{KL}(p \parallel q)$: la divergenza di Kullback-Leibler da p a q .

