

Probabilità per la psicologia

Modulo di richiamo

Corrado Caudek

12 luglio 2026

Modulo di richiamo per l'inferenza bayesiana in psicologia

Questo sito costituisce il **modulo di richiamo delle nozioni di base della teoria della probabilità** del progetto UTET, concepito come supporto al manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Il modulo fornisce le nozioni teoriche fondamentali, quali variabili casuali, distribuzioni di probabilità, valore atteso, varianza, dipendenza stocastica e teoria del campionamento, necessarie per affrontare con la giusta preparazione i contenuti di inferenza bayesiana e la modellistica presentati nel volume principale.

Percorso di apprendimento e obiettivi

Il percorso si sviluppa attraverso cinque aree concettuali fondamentali, strettamente interconnesse tra loro. Si inizia con il **linguaggio della probabilità**, che introduce gli elementi di base, ovvero, eventi, misure di probabilità, nozioni di indipendenza e probabilità condizionata. Questo fornisce gli strumenti logici per trattare l'incertezza.

Si prosegue con lo **studio delle variabili casuali e delle loro distribuzioni**, distinte in discrete e continue, analizzando le funzioni di massa, densità e ripartizione che ne caratterizzano il comportamento.

La terza area è dedicata ai **momenti e alle misure di dipendenza**: vengono definiti e discussi il valore atteso, la varianza, la covarianza e il coefficiente di correlazione, quali sintesi numeriche essenziali per descrivere distribuzioni e relazioni tra variabili.

Segue una rassegna delle **distribuzioni fondamentali**, ovvero le distribuzioni di Bernoulli, binomiale, di Poisson, normale e le loro principali derivazioni, che costituiscono il vocabolario probabilistico di base, impiegato in gran parte delle applicazioni.

Il modulo si conclude con i **principi del campionamento e della verosimiglianza**, tracciando un ponte ideale verso l'inferenza statistica: dalla legge dei grandi numeri si passa alla funzione di verosimiglianza, che rappresenta uno strumento concettuale propedeutico all'approccio bayesiano.

Dal punto di vista didattico, il modulo mantiene un'impostazione operativa e sintetica: l'esposizione privilegia formule essenziali, esempi minimali e schemi intuitivi, mentre i singoli capitoli rimandano, quando necessario, a approfondimenti presenti nel materiale complementare e nel manuale di riferimento.

Mappa del percorso

La seguente mappa fornisce una visione d'insieme dell'organizzazione del modulo, con indicazioni sul tempo di studio stimato e sui collegamenti al manuale principale.

Parte	Contenuti
PARTE 1 Fondamenti della probabilità	Cap. 1–5 • Interpretazione bayesiana • Assiomi e coerenza • Calcolo combinatorio • Probabilità condizionata • Teorema di Bayes
PARTE 2 Variabili casuali e distribuzioni	Cap. 6–9 • Variabili casuali • Distribuzioni di massa/densità • Valore atteso e varianza • Covarianza e correlazione
PARTE 3 Distribuzioni specifiche	Cap. 10–13 • Dal dato all'ipotesi • Panoramica distribuzioni • Distribuzioni discrete • Distribuzioni continue
PARTE 4 Verso l'inferenza	Cap. 14–15 • La verosimiglianza • Proprietà e aggiornamento bayesiano
APPENDICI Strumenti matematici	App. A–F • Simbologia matematica • Numeri e intervalli • Notazione sommatoria • Teoria degli insiemi • Calcolo combinatorio • Nozioni di calcolo

Legenda

Livello: ☐ Base | ☐☐ Intermedio | ☐☐☐ Avanzato

Tempo: Stima indicativa per lo studio autonomo con esercizi

💡 ☐ Suggerimento per lo studio

- **Prima lettura:** scorri velocemente l'intera parte per avere una visione d'insieme
- **Studio attivo:** rileggi con carta e penna, riproducendo le formule chiave
- **Consolidamento:** risolvi gli esercizi proposti e consulta le appendici per eventuali lacune
- **Integrazione:** collega ogni concetto alla sua applicazione nell'inferenza bayesiana

❗ ☐ Percorso consigliato

Il modulo è progettato per essere seguito **in sequenza**: ogni parte costruisce sui concetti delle precedenti. Se incontri difficoltà in una sezione, consulta prima le appendici rilevanti, poi riprendi dal punto di difficoltà.

Modalità di utilizzo del modulo

Per un apprendimento efficace, si consiglia di procedere in modo sequenziale, poiché i concetti presentano una struttura progressiva e cumulativa. È consigliabile focalizzarsi sull'interpretazione

piuttosto che sul formalismo, riducendo gli approfondimenti formali allo stretto necessario. Infine, è utile mantenere sempre il collegamento con l'inferenza bayesiana, osservando come ciascun concetto trovi applicazione nella costruzione di prior, verosimiglianze e distribuzioni posteriori.

Prerequisiti e strumenti

Per utilizzare il modulo è necessaria una conoscenza di base dei concetti di algebra elementare e di statistica descrittiva. Gli esempi numerici sono corredati, quando necessario, da codice R immediatamente riproducibile.

Collegamenti utili

- **Manuale principale:** [Inferenza bayesiana in psicologia](#)
- **Repository GitHub:** Per segnalare errori o suggerire miglioramenti, utilizza la sezione [Issues](#)
- **Materiali complementari:** Esercizi e soluzioni saranno progressivamente aggiunti al sito

Licenza d'uso

Materiali distribuiti con licenza

[CC BY-NC-ND 4.0](#). È consentita la condivisione con attribuzione, **solo per usi non commerciali e senza modifiche**.

Parte I.

PARTE 1: Fondamenti della probabilità

1. Interpretazione bayesiana della probabilità

Introduzione

In questo capitolo adotteremo una **prospettiva bayesiana** sulla probabilità. Secondo questo approccio, la probabilità non è una proprietà intrinseca degli eventi, né una mera frequenza osservata, bensì un **grado di credenza razionale** che un agente assegna sulla base delle informazioni disponibili.

Questa visione, sviluppata da pensatori quali Thomas Bayes, Pierre-Simon Laplace e Bruno de Finetti, fornisce una cornice concettuale particolarmente adatta alle scienze psicologiche, in cui spesso si è chiamati a ragionare in condizioni di informazione parziale, rumore sistematico e variabilità individuale strutturale.

Dal punto di vista bayesiano, gli assiomi della probabilità non descrivono proprietà oggettive dei fenomeni aleatori, ma costituiscono vincoli di coerenza logica per un sistema di credenze razionali. Essi specificano come le nostre valutazioni dell'incertezza devono relazionarsi tra loro per evitare contraddizioni. La violazione di questi vincoli renderebbe l'assegnazione di probabilità internamente incoerente, esponendo il soggetto a valutazioni paradossali e a scelte decisionali sistematicamente svantaggiose.

Nel corso del modulo ricorreremo spesso a simulazioni al computer. Il loro scopo non è definire astrattamente “che cos'è” la probabilità, ma illustrare come un sistema di credenze coerente si comporta a contatto con i dati empirici, mostrando così perché l'approccio bayesiano sia uno strumento potente per il ragionamento scientifico in psicologia.

Perché la probabilità bayesiana in psicologia?

L'approccio bayesiano offre un quadro epistemologico e statistico particolarmente adatto alla ricerca psicologica, grazie a tre proprietà distintive rispetto al paradigma frequentista.

Integrazione di informazioni complementari.

Molti studi, specie in ambito clinico e sperimentale, si basano su campioni di dimensioni ridotte (n tra 20 e 50), nei quali l'informazione empirica è intrinsecamente limitata. L'inferenza bayesiana compensa tale limite incorporando formalmente le conoscenze pregresse attraverso la distribuzione a priori, sfruttando in modo coerente l'intero spettro informativo disponibile.

Formalizzazione della conoscenza cumulativa.

La ricerca psicologica non procede mai da un vuoto teorico, ma si innesta su teorie consolidate e risultati precedenti. L'approccio bayesiano traduce questa dimensione cumulativa in termini matematici, rendendo esplicito e verificabile l'aggiornamento delle credenze alla luce di nuovi dati, un processo che nei metodi tradizionali rimane spesso implicito.

Interpretabilità diretta dei risultati.

L'inferenza bayesiana esprime le conclusioni nel linguaggio naturale della probabilità, ad esempio: “La probabilità che l'effetto sia compreso tra 0.2 e 0.8 è del 95%”. Questa formulazione supera le note ambiguità degli intervalli di confidenza frequentisti, facilita la comunicazione scientifica e agevola la traduzione dei risultati in decisioni cliniche, indicazioni pratiche e sviluppo teorico. In tal senso,

1. Interpretazione bayesiana della probabilità

l'approccio bayesiano si rivela non solo metodologicamente robusto, ma anche epistemicamente trasparente.

Esempio concreto

Scenario: uno psicologo clinico intende valutare l'efficacia di un nuovo protocollo per l'ansia attraverso uno studio pilota condotto su un campione ristretto ($n = 15$).

Approccio tradizionale: “La numerosità campionaria è insufficiente per garantire una potenza statistica adeguata. Non è possibile trarre conclusioni significative; l'unica soluzione è ampliare drasticamente il campione.”

Approccio bayesiano: “Posso integrare le evidenze della letteratura preesistente definendo un *prior* informativo, per poi aggiornarlo con i dati raccolti sui 15 pazienti. Ne deriverà una distribuzione a posteriori capace di quantificare con rigore sia l'effetto stimato sia l'incertezza residua, offrendo una base razionale per la decisione clinica anche in presenza di dati limitati.”

Prerequisiti

Questo è il capitolo introduttivo del modulo. Non sono richiesti prerequisiti specifici oltre alle conoscenze di algebra elementare e statistica descrittiva indicate nell'introduzione generale. Per consultazioni opzionali:

- [Appendice A](#)
- [Appendice B](#)

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

1.1. Casualità e incertezza: due prospettive a confronto

L'incertezza è una condizione costante dell'esperienza umana: non possiamo ricostruire il passato con assoluta precisione, né prevedere il futuro con certezza, e spesso la complessità del presente ci sfugge. Come osserva Spiegelhalter (2024), questa condizione invita a considerare la casualità non come una proprietà misteriosa degli eventi, ma come un modello operativo che, rinunciando a predizioni deterministiche, consente di individuare regolarità statistiche utili per interpretare la realtà e orientare le decisioni.

Per analizzare sistematicamente l'incertezza, è utile distinguere due dimensioni fondamentali dello stato epistemo. Questa distinzione chiarisce quali aspetti dell'incertezza sono radicati nella struttura del mondo e quali, invece, nei limiti della nostra conoscenza, premessa necessaria per comprendere il ruolo della probabilità nella ricerca psicologica.

1.1.1. Incertezza epistemoica

L'**incertezza epistemoica** (dal greco ἐπιστήμη, “conoscenza”) deriva da informazioni insufficienti o di scarsa qualità. È, almeno in linea di principio, riducibile: nuovi dati, disegni sperimentali più

accurati o misurazioni più affidabili possono diminuirne l'impatto. In psicologia, questa forma di incertezza è onnipresente: campioni di dimensioni limitate, variabili non controllate, informazioni cliniche o anamnestiche incomplete ne sono esempi tipici.

1.1.2. Incertezza ontologica

L'**incertezza ontologica** (dal greco ὄντος, "essere") riguarda invece l'imprevedibilità che sembra inerente ai fenomeni stessi. Non dipende dalle limitazioni del ricercatore e non scompare nemmeno in presenza di misurazioni estremamente precise. Nell'ambito psicologico, rientrano in questa categoria la variabilità comportamentale residua anche in condizioni sperimentali controllate, la natura probabilistica delle decisioni in situazioni ambigue e fenomeni come l'emergere di intuizioni, creatività o cambiamenti improvvisi di strategia cognitiva.

1.1.3. La sintesi bayesiana: l'incertezza come stato epistemico

Nel quadro bayesiano adottato in questo manuale, le due forme di incertezza, epistemica e ontologica, sono trattate in modo unificato. Ciò che viene spesso descritto come incertezza ontologica viene formalizzato mediante lo stesso strumento: l'assegnazione di probabilità.

Questa scelta poggia su una premessa epistemologica: l'accesso dell'osservatore allo stato del sistema è sempre parziale. La probabilità diventa così lo strumento con cui quantifichiamo sistematicamente i limiti della nostra conoscenza, a prescindere che questi derivino da informazioni incomplete o dalla complessità intrinseca del fenomeno.

Come osservò Laplace, un intelletto onnisciente in grado di conoscere tutte le forze della natura e la posizione di ogni particella vedrebbe il futuro determinato con la stessa certezza del passato. In un universo deterministico, l'impossibilità di previsioni perfette non dipenderebbe dalla natura del mondo, ma esclusivamente dall'incompletezza della nostra conoscenza.

Da questa prospettiva, la probabilità non è una proprietà intrinseca del mondo, ma una **conseguenza necessaria dei limiti cognitivi ed epistemici dell'osservatore**. È il nostro stato informativo, non il mondo in sé, a generare l'incertezza.

Questa interpretazione **epistemica della probabilità**, intesa come misura del grado di credenza razionale, costituisce il fondamento concettuale e metodologico dell'intero manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza. Fondamenti, workflow e applicazioni*. Tuttavia, un sistema di credenze, per quanto coerente, rimane astratto finché non viene utilizzato da un decisore. È a questo compito che ora rivolgiamo la nostra attenzione.

1.2. Il decisore coerente di fronte all'incertezza

La trattazione dell'incertezza come stato epistemico, illustrata in precedenza, trova il suo compimento operativo nella figura del decisore razionale. Il paradigma bayesiano non si limita a descrivere l'incertezza, ma fornisce strumenti per agire coerentemente in sua presenza.

1.2.1. Il soggettivismo di de Finetti

Nel suo lavoro fondamentale, Bruno de Finetti ha adottato un approccio esplicitamente soggettivista al processo decisionale in condizioni di incertezza (Finetti, 1970). Le probabilità non sono proprietà intrinseche del mondo, ma valutazioni personali che esprimono quanto un agente ritenga plausibili i diversi stati possibili del sistema.

Di fronte alle stesse circostanze incerte, due decisori possono quindi divergere, talvolta marcatamente, nella stima delle probabilità, nella desiderabilità degli esiti o nella valutazione dell'influenza delle proprie azioni. Questa variabilità non rappresenta un difetto del ragionamento, ma una caratteristica inevitabile di qualsiasi processo decisionale reale.

Il paradigma bayesiano, tuttavia, non si limita a fornire una cornice soggettivista, ma propone anche un ideale matematico di razionalità interna, specificando come dovrebbe comportarsi un decisore che, pur mantenendo le proprie valutazioni soggettive, rispetta un requisito fondamentale: la **coerenza**.

Essere coerenti significa che le proprie credenze e preferenze non devono entrare in contraddizione, in modo da evitare perdite certe quando le valutazioni vengono tradotte in decisioni. Il formalismo matematico che introdurremo non mira a descrivere fedelmente le credenze di ogni decisore in ogni situazione, ma fornisce famiglie di modelli sufficientemente flessibili da rappresentare almeno una versione coerente e operativa di tali credenze.

Nel quadro bayesiano, la coerenza è il massimo che possiamo ragionevolmente richiedere a un decisore. Non gli imponiamo di compiere scelte "giuste" secondo criteri esterni, ma solo di mantenere un sistema di credenze compatibile con le proprie valutazioni. In questa prospettiva, tutto è soggettivo, persino affermazioni apparentemente oggettive come "il vero valore del parametro è x ". Formulazioni di questo tipo vanno interpretate come abbreviazioni di: "Sono convinto che il vero valore del parametro sia x ". Questa rilettura, lungi dall'essere un semplice dettaglio linguistico, permette di accettare le divergenze tra agenti senza rinunciare ai vincoli della coerenza (Heard, 2021).

1.2.2. L'incertezza soggettiva

Le fonti di incertezza che complicano il processo decisionale sono molteplici: eventi futuri non ancora verificati, circostanze passate di cui non si ha notizia, informazioni possedute da altri ma non dal decisore, conoscenze dimenticate. Il paradigma bayesiano tratta tutte queste forme in modo unitario: qualsiasi aspetto rispetto al quale il decisore è incerto deve essere esplicitamente riconosciuto e incorporato nel processo decisionale. Il framework considera esclusivamente lo stato attuale delle conoscenze del decisore, a prescindere da ciò che egli dovrebbe conoscere in linea di principio (Heard, 2021).

La gestione operativa di questa molteplicità avviene attraverso lo strumento formale già introdotto, ovvero la probabilità come **grado di credenza razionale**, che consente di quantificare in modo coerente l'incertezza soggettiva alla luce delle informazioni disponibili.

1.2.3. Coerenza e credenze: il filo conduttore

In sintesi, l'approccio bayesiano unifica due istanze apparentemente distanti: da un lato, il riconoscimento della soggettività e della variabilità interindividuale nelle valutazioni probabilistiche; dall'altro, l'esigenza di un vincolo formale di coerenza che impedisca contraddizioni interne. La probabilità diventa il linguaggio comune in cui si esprime l'incertezza, epistemica, ontologica o soggettiva che sia, e il criterio di coerenza garantisce che tale linguaggio venga impiegato in modo logicamente inattaccabile.

Questa duplice anima, soggettiva nei contenuti e oggettiva nella sintassi formale, costituisce il nucleo metodologico dell'inferenza bayesiana e sarà alla base di tutti gli sviluppi tecnici presentati nel manuale.

i Credere e avere fiducia: due concetti distinti?

Nel linguaggio quotidiano, credere è un atteggiamento categorico: o si crede o non si crede. L'approccio bayesiano introduce invece i gradi di credenza (*credence*): non solo credo che domani pioverà, ad esempio, ma assegno a questa previsione una fiducia del 70%. I gradi di credenza permettono di quantificare l'incertezza in modo granulare e coerente, mentre le credenze categoriche semplificano le decisioni pratiche (Jackson, 2020). Questi due approcci sono complementari: nel manuale adotteremo sistematicamente il primo, perché più adatto all'analisi dei dati psicologici.

1.3. Probabilità come grado di credenza

1.3.1. La visione bayesiana soggettivista

Nel paradigma bayesiano, la probabilità è interpretata come un **grado di fiducia razionale** nel verificarsi di un evento, sulla base delle informazioni disponibili in un determinato momento.

La probabilità è il grado di credenza (plausibilità) assegnato a un'affermazione, in funzione di uno specifico stato informativo.

Questa definizione poggia su quattro caratteristiche interconnesse:

- **Soggettività** — individui diversi, con conoscenze e informazioni differenti, possono legittimamente attribuire probabilità diverse allo stesso evento.
- **Razionalità** — tale soggettività non è arbitraria: le probabilità devono rispettare gli assiomi della probabilità, che garantiscono coerenza interna.
- **Condizionalità** — ogni probabilità è intrinsecamente legata all'insieme informativo disponibile: parlare di probabilità senza specificare “dato ciò che so” è, in senso bayesiano, incompleto.
- **Aggiornabilità** — al sopraggiungere di nuove evidenze, le probabilità vengono riviste in modo sistematico attraverso il meccanismo dell'aggiornamento bayesiano.

Queste proprietà rendono la probabilità uno strumento flessibile ma rigoroso per rappresentare e gestire l'incertezza nei contesti reali di decisione e analisi dei dati.

i Applicazione clinica

Lo stesso punteggio a un test per la depressione ha implicazioni diverse se il soggetto proviene da un reparto psichiatrico (prevalenza elevata) o dalla popolazione generale (prevalenza bassa). La probabilità di depressione non è una proprietà intrinseca del test, ma un grado di credenza che integra conoscenze pregresse (prevalenza, anamnesi) ed evidenza empirica (sensibilità, specificità) attraverso il ragionamento bayesiano.

1.3.2. La coerenza: l'argomento della scommessa olandese

Se la probabilità è un grado di credenza soggettivo, come si giustificano gli assiomi matematici che la governano? La risposta è il celebre *argomento della scommessa olandese* (*Dutch Book*), sviluppato da Ramsey e de Finetti.

Supponiamo che un decisore sia disposto a scommettere denaro in base alle proprie valutazioni probabilistiche. Se queste sono internamente incoerenti, esiste sempre una combinazione di scommesse che, secondo lui, sono accettabili, ma producono una **perdita certa**, qualunque sia l'esito del fenomeno. L'incoerenza non è quindi un problema astratto, ma una forma di vulnerabilità strategica: un sistema di credenze incoerente può essere sfruttato sistematicamente a svantaggio dell'agente.

Esempio: al lancio di una moneta, un decisore assegna probabilità $2/3$ sia a *Testa* sia a *Croce*. È disposto a pagare 2 € per ricevere 3 € se esce Testa, e altrettanto per Croce. Accettando entrambe le scommesse, paga 4 € e incassa comunque solo 3 €, subendo una perdita certa di 1 €. L'incoerenza sta nella somma delle probabilità ($4/3 > 1$), che viola l'assioma fondamentale della probabilità.

Questo esempio mostra che il rispetto degli assiomi probabilistici non è un dettaglio tecnico, ma una condizione necessaria per un ragionamento coerente: chi li viola è esposto a conseguenze pratiche negative, a prescindere da come si svolgeranno i fatti.

1.3.3. Gli assiomi di Kolmogorov

Ramsey e de Finetti hanno dimostrato che per evitare perdite certe è necessario rispettare specifici vincoli di coerenza. Questi vincoli sono formalizzati negli **assiomi della probabilità** (introdotti da Kolmogorov): essi impongono che i gradi di credenza siano non negativi, che l'insieme di tutte le possibilità abbia probabilità 1 e che la probabilità di eventi mutuamente esclusivi sia additiva. La loro formulazione esatta e le loro conseguenze saranno esaminate in dettaglio nel capitolo successivo (Capitolo 2). Per ora, è sufficiente sapere che questi assiomi non sono mere convenzioni matematiche: esprimono le condizioni minime per un sistema di credenze internamente coerente.

1.3.4. 4.4 Implicazioni per la psicologia

L'argomento della scommessa olandese attribuisce alle regole della probabilità un significato pragmatico: non descrivono solo relazioni formali tra eventi, ma stabiliscono i vincoli che un sistema di credenze deve rispettare per guidare scelte razionali in condizioni di incertezza.

La psicologia cognitiva ha ampiamente documentato deviazioni sistematiche da questi criteri di coerenza (Griffiths et al., 2024). L'argomento della scommessa olandese chiarisce la portata pratica di tali deviazioni: non si tratta di distorsioni cognitive astratte, ma di vulnerabilità decisionali che possono tradursi in esiti prevedibilmente sfavorevoli ogni volta che le credenze orientano il comportamento. In questo senso, il rispetto degli assiomi probabilistici non è solo un requisito logico, ma una condizione per un agire razionale nel mondo.

Per approfondire

Una trattazione più formale dell'argomento del *Dutch Book*, insieme al *Principio Principale* di Lewis (che collega credenze soggettive e probabilità oggettive) e alle diverse misure quantitative dell'evidenza, si trova nel capitolo sui fondamenti-epistemologici del sito [companion](#).

1.4. Le origini storiche

Le radici dell'approccio bayesiano affondano nel Settecento, quando Thomas Bayes (1701–1761) formulò il teorema che porta il suo nome, mostrando come le credenze sulle cause possano essere aggiornate a partire dagli effetti osservati. Pierre-Simon Laplace (1749–1827) sviluppò e applicò queste idee a una vasta ampia gamma di problemi scientifici, definendo la probabilità come “buon senso ridotto a calcolo”. Nel Novecento, Bruno de Finetti (1906–1985) ha fornito una rigorosa fondazione soggettivista, sostenendo che la probabilità “non esiste” come proprietà del mondo, ma è uno strumento per quantificare l'incertezza individuale. Harold Jeffreys (1891–1989), con il suo *Theory of Probability* (1939), elaborò invece un approccio “oggettivo” basato su prior non informativi, dimostrando l'efficacia pratica dell'inferenza bayesiana nell'analisi dei dati scientifici. Dopo un periodo di eclissi dovuto al predominio del frequentismo, l'approccio bayesiano ha conosciuto una rinascita a partire dagli anni Novanta, resa possibile dallo sviluppo di metodi computazionali come i metodi Monte Carlo via catena di Markov (MCMC) e dalla loro crescente diffusione in ambito psicologico e nelle scienze cognitive (Gelman et al., 2013; Johnson et al., 2022; Kruschke, 2014; McElreath, 2020).

1.5. Il ruolo delle simulazioni: illustrazione, non definizione

Una differenza fondamentale tra l'approccio bayesiano e quello frequentista riguarda il ruolo delle simulazioni e della legge dei grandi numeri. Le due prospettive divergono sul significato delle frequenze empiriche e sul loro rapporto con il concetto di probabilità.

1.5.1. La prospettiva frequentista

Secondo il frequentismo, la probabilità di un evento è definita come il limite della sua frequenza relativa in una sequenza ideale infinita di prove identiche:

$$P(A) = \lim_{n \rightarrow \infty} \frac{\text{frequenza di occorrenza di } A}{n}.$$

La probabilità è quindi una **proprietà oggettiva** del fenomeno, indipendente dall'osservatore e stimabile tramite esperimenti ripetuti. In questa cornice, la probabilità coincide concettualmente con il comportamento a lungo termine delle frequenze osservate.

Tuttavia, l'approccio frequentista presenta due difficoltà principali quando viene applicato a contesti concreti.

La prima riguarda l'uso della probabilità in riferimento a **eventi o decisioni singolari**. La definizione frequentista interpreta la probabilità come frequenza relativa nel lungo periodo e risulta quindi particolarmente naturale quando si considerano fenomeni ripetibili e osservabili attraverso molte prove simili. Diventa invece meno immediata quando si deve valutare un evento unico, come “domani pioverà a Firenze”, o quando si deve prendere una decisione su un caso specifico, come la scelta della terapia per un paziente.

In queste situazioni, il riferimento a un collettivo di casi simili resta possibile, ma non è sempre univoco. Per attribuire una probabilità all'evento singolo, infatti, è necessario stabilire a quale classe di eventi esso appartenga. Tuttavia, tale scelta può variare a seconda delle informazioni prese in considerazione. Allo stesso modo, una stima come “il 55% dei pazienti trattati con questa terapia migliora” descrive il comportamento medio di un gruppo, ma non determina direttamente quale esito sia più probabile per quel paziente specifico, date le sue caratteristiche particolari.

1. Interpretazione bayesiana della probabilità

La seconda difficoltà riguarda il carattere **ideale e non direttamente osservabile** della probabilità così definita. In senso frequentista, la probabilità corrisponde al limite della frequenza relativa in una sequenza indefinitamente lunga di prove. Tale limite, tuttavia, non può essere osservato empiricamente: nella pratica, infatti, disponiamo solo di un numero finito di osservazioni. La frequenza relativa calcolata su un numero finito di prove può quindi fornire una stima utile della probabilità, ma non coincide necessariamente con la probabilità vera, che resta un'entità teorica.

In sintesi, la prospettiva frequentista è molto efficace quando si analizzano fenomeni ripetibili e grandi campioni di osservazioni. Risulta invece meno naturale quando l'obiettivo è ragionare su eventi unici, prendere decisioni individuali o formulare giudizi probabilistici in situazioni in cui non esiste una sequenza chiaramente definita di repliche.

1.5.2. La prospettiva bayesiana

La prospettiva bayesiana interpreta invece la probabilità come un **grado di credenza razionale** sul verificarsi di un evento, sulla base delle informazioni disponibili. Le probabilità riflettono lo stato informativo dell'agente *prima* dell'osservazione dei dati.

In questo contesto, le simulazioni non definiscono che cosa sia la probabilità, ma verificano che un sistema di credenze coerente produca comportamenti empirici compatibili con le aspettative. La legge dei grandi numeri spiega perché, se le credenze iniziali sono coerenti, le frequenze osservate tenderanno a rifletterle nel lungo periodo. Tale convergenza, tuttavia, non costituisce la definizione ontologica della probabilità, ma una conseguenza delle sue regole di coerenza.

La distinzione è sostanziale: nel frequentismo, la probabilità è definita dalla regolarità empirica emergente dalla ripetizione ideale; nel bayesiano, essa esprime uno stato di conoscenza che guida aspettative razionali sui fenomeni osservabili. Questa differenza di fondo determina anche il diverso ruolo attribuito alle simulazioni.

1.5.3. Simulazione come verifica di coerenza

Nel quadro bayesiano, le simulazioni svolgono un ruolo di *verifica* e di *illustrazione*. Esse mostrano come un sistema di credenze coerente generi regolarità empiriche compatibili con le aspettative teoriche.

Le simulazioni permettono di illustrare concetti quali la convergenza statistica e la variabilità campionaria, di confrontare le previsioni di un modello probabilistico con i dati osservati e di esplorare il comportamento dei modelli in condizioni controllate. È importante sottolineare che le simulazioni non stabiliscono cosa sia la probabilità, ma rendono visibili le conseguenze operative delle assegnazioni probabilistiche.

1.5.4. Esempio: lancio di moneta rivisitato

```
set.seed(42)

# Assegno credenza P(Testa) = 0.5 per simmetria epistémica
p_testa_credenza <- 0.5

# Simulazione: verifico che questa credenza è coerente
n_lanci <- 10000
```

```


risultati <- rbinom(n_lanci, 1, p_testa_credenza)

# Frequenza cumulativa
freq_cumulativa <- cumsum(risultati) / seq_along(risultati)

# Grafico
df <- data.frame(
  lancio = seq_along(risultati),
  freq = freq_cumulativa
)

ggplot(df, aes(x = lancio, y = freq)) +
  geom_line(alpha = 0.7) +
  geom_hline(yintercept = p_testa_credenza,
             linetype = "dashed", color = "red", size = 1) +
  scale_fill_qualitative() +
  labs(
    title = "Frequenza cumulativa converge alla credenza",
    subtitle = "La credenza P(Testa)=0.5 predice la convergenza osservata",
    x = "Numero di lanci",
    y = "Frequenza cumulativa di Teste"
  ) +
  ylim(0.3, 0.7)

```



L'interpretazione bayesiana di questa simulazione evidenzia che l'assegnazione di $P(\text{Testa}) = 0.5$ deriva da un principio di simmetria epistemica, in assenza di informazioni che privilegino un esito rispetto all'altro. La simulazione verifica la coerenza di questa credenza con il comportamento empirico atteso. È importante notare che la probabilità 0.5 non è definita dalla convergenza empirica, ma rappresenta un'assegnazione a priori che la legge dei grandi numeri successivamente conferma.

1.6. Introduzione all'aggiornamento bayesiano

Un principio cardine dell'epistemologia bayesiana è che un agente razionale possiede credenze di diversa intensità, soggette ai vincoli di coerenza imposti dagli assiomi della probabilità. Sia lo stato attuale di una credenza sia la sua evoluzione all'arrivo di nuove informazioni possono essere rappresentati mediante distribuzioni di probabilità.

1.6.1. Il principio di condizionamento

Il **principio di condizionamento** specifica come un agente razionale debba rivedere le proprie credenze quando emergono nuove evidenze. Esso traduce il concetto di probabilità condizionata in una regola operativa: la probabilità iniziale (o *a priori*) di un'ipotesi H viene trasformata nella sua probabilità finale (o *a posteriori*) dopo l'osservazione di un dato E rilevante.

Più che un assioma, si tratta di una **prescrizione di coerenza dinamica**: impone che il nuovo grado di fiducia in H coincida con la probabilità che gli si attribuiva inizialmente, *dato che* si è verificato E . L'informazione nuova viene così incorporata in modo sistematico, evitando aggiustamenti arbitrari e garantendo che la revisione rimanga ancorata allo stato di conoscenza precedente.

1.6.2. Il teorema di Bayes: struttura concettuale

Il **teorema di Bayes** è lo strumento matematico che realizza il principio di condizionamento, scomponendo la credenza aggiornata in tre componenti essenziali:

1. **Probabilità a priori** $P(H)$: il grado di fiducia iniziale nell'ipotesi, prima di osservare i dati.
2. **Verosimiglianza** $P(E | H)$: la plausibilità dell'evidenza E *supponendo vera* l'ipotesi H , ovvero quanto il dato osservato sia compatibile con l'ipotesi.
3. **Probabilità marginale dell'evidenza** $P(E)$: un fattore di normalizzazione che assicura la coerenza, pari alla probabilità complessiva di osservare E sotto tutte le ipotesi considerate.

Il teorema mostra come una credenza iniziale, $P(H)$, venga modulata dalla forza dell'evidenza, $P(E | H)$, per generare una credenza finale, $P(H | E)$. È il nucleo matematico dell'apprendimento dall'esperienza: l'aggiornamento sistematico e coerente delle opinioni alla luce di nuovi dati.

1.6.3. Un esempio anticipatorio: i test diagnostici

Un esempio paradigmatico di aggiornamento bayesiano è l'interpretazione di un test diagnostico. Qui l'ipotesi H è la presenza di una malattia, mentre l'evidenza E è un risultato positivo.

La probabilità a priori riflette la prevalenza della malattia nella popolazione. La verosimiglianza è espressa dalla sensibilità del test (probabilità di un positivo in un malato) e dal tasso di falsi positivi (probabilità di un positivo in un sano). Combinando questi elementi, il teorema restituisce la probabilità a posteriori di malattia dopo un esito positivo.

L'esempio illustra un principio generale: **l'evidenza assume significato solo alla luce delle conoscenze pregresse**. Un test anche molto accurato può condurre a una probabilità a posteriori sorprendentemente bassa se la malattia era inizialmente rara. Questa è la radice della cosiddetta *fallacia del tasso base*: la tendenza, ben documentata in psicologia cognitiva, a sovrastimare $P(\text{malattia} | \text{positivo})$ trascurando la prevalenza. Il teorema di Bayes non è quindi soltanto una regola di calcolo, ma un correttivo normativo a una delle più robuste distorsioni del ragionamento umano.

L'esempio verrà ripreso e sviluppato numericamente nei capitoli successivi, dove mostreremo come la combinazione di *prior* e verosimiglianza possa produrre esiti controintuitivi ma logicamente inattaccabili.

1.6.4. Sintesi concettuale

L'aggiornamento bayesiano può essere rappresentato nella sua essenza come:

$$\underbrace{P(H)}_{\text{prior}} \xrightarrow[\text{osservazione dei dati}]{\text{aggiornamento bayesiano}} \underbrace{P(H | E)}_{\text{posterior}}.$$

Questa sintesi visuale coglie il cuore dell'inferenza bayesiana: un modello formale del ragionamento che integra nuove informazioni con le conoscenze acquisite, senza né ignorare i dati né cedere a sopravvalutazioni. Il teorema di Bayes, in questa prospettiva, si rivela non solo uno strumento matematico, ma una guida razionale per orientarsi e decidere in condizioni di incertezza.

1.7. La probabilità bayesiana nella ricerca psicologica

La teoria bayesiana della probabilità si rivela particolarmente adatta allo studio dei fenomeni psicologici, poiché fornisce strumenti concettuali e metodologici per affrontare in modo esplicito e coerente l'incertezza che caratterizza sia la ricerca empirica sia la pratica clinica.

1.7.1. Quantificare l'incertezza in ambito clinico e cognitivo

In ambito diagnostico, il framework bayesiano consente di integrare sistematicamente fonti informative eterogenee — anamnesi, osservazione comportamentale, test psicometrici — aggiornando le credenze del clinico a ogni nuova evidenza. Un contributo particolarmente rilevante è la possibilità di incorporare esplicitamente la prevalenza dei disturbi, riducendo il rischio di errori dovuti alla negligenza dei tassi di base.

Nello studio dei processi cognitivi, un influente filone di ricerca propone che molti aspetti del funzionamento mentale possano essere descritti come approssimazioni di un ragionamento bayesiano ideale (Griffiths et al., 2024). La percezione, ad esempio, può essere modellata come integrazione tra aspettative pregresse e informazioni sensoriali — spiegando fenomeni come le illusioni percettive — mentre l'apprendimento e molti bias cognitivi trovano una loro interpretazione naturale come aggiornamenti imperfetti o scostamenti dall'ottimalità bayesiana.

Sul piano metodologico, l'inferenza bayesiana offre vantaggi concreti nell'analisi dei dati psicologici: incorporazione formalizzata delle conoscenze pregresse, quantificazione diretta dell'evidenza a favore di ipotesi specifiche, gestione naturale di campioni ridotti e propagazione coerente dell'incertezza attraverso modelli statistici complessi.

In ambito terapeutico, infine, l'approccio consente di aggiornare sequenzialmente le stime di efficacia degli interventi, adattando i protocolli alle risposte del singolo paziente e bilanciando probabilità ed esiti attesi nelle scelte cliniche.

1.7.2. Un quadro epistemologico coerente

Diversamente dal frequentismo — che definisce la probabilità come frequenza relativa in una sequenza ideale infinita di prove ripetute e considera i parametri come quantità fisse ma ignote — l'approccio bayesiano interpreta la probabilità come grado di credenza razionale, tratta i parametri come variabili aleatorie che rappresentano l'incertezza dell'osservatore e consente di formulare affermazioni del tipo: "La probabilità che l'effetto del trattamento sia positivo è pari a 0.85".

Ne deriva un'interpretazione diretta degli intervalli di stima: un intervallo di credibilità al 95% esprime, dati i risultati osservati e il modello adottato, che esiste una probabilità del 95% che il parametro cada al suo interno. Un vantaggio operativo non trascurabile per chi deve prendere decisioni cliniche o di policy.

L'approccio bayesiano non sostituisce l'inferenza frequentista, ma la integra in un quadro epistemologico più ampio, in cui la soggettività delle credenze iniziali viene resa esplicita e vincolata dalla coerenza formale, e l'evidenza empirica modula le opinioni in modo trasparente e verificabile.

Riflessioni conclusive

Abbiamo iniziato questo capitolo con una domanda: perché la probabilità bayesiana in psicologia? La risposta che abbiamo fornito è che la probabilità, intesa come grado di credenza razionale, offre un linguaggio unitario per quantificare l'incertezza, sia quella che deriva dai limiti della nostra conoscenza, sia quella che sembra inerente ai fenomeni stessi. Questa prospettiva, che affonda le proprie radici in Bayes, Laplace e de Finetti, non è un tecnicismo matematico, ma una **lente interpretativa** attraverso cui leggere il ragionamento umano in condizioni di incertezza.

Abbiamo visto che gli assiomi della probabilità non sono mere convenzioni formali, ma **principi di coerenza** che vincolano le nostre credenze: violarli significa esporsi a contraddizioni interne e a decisioni sistematicamente svantaggiose, come dimostrato dall'argomento della scommessa olandese. Abbiamo anche compreso che, nel quadro bayesiano, l'incertezza non è più una proprietà del mondo che emerge solo in lunghe sequenze di prove, ma una misura della nostra conoscenza imperfetta, applicabile anche a eventi singoli e non ripetibili, come la prognosi di un paziente o l'esito di una decisione clinica.

Questo cambiamento di prospettiva ha implicazioni concrete per la ricerca psicologica. L'approccio bayesiano rende esplicite le assunzioni iniziali attraverso la scelta del prior, formalizza l'apprendimento dai dati con il teorema di Bayes e fornisce strumenti per gestire la complessità dei modelli statistici senza rinunciare alla trasparenza. Non elimina l'incertezza — che nella psicologia è una **condizione strutturale**, non un'eccezione — ma fornisce un linguaggio per quantificarla, comunicarla e integrarla nelle decisioni.

Nei prossimi capitoli trasformeremo queste idee in strumenti operativi. Scopriremo come costruire un modello bayesiano, come scegliere i *prior* e come interpretare i risultati. Inoltre, vedremo che concetti come l'equiprobabilità, spesso considerati oggettivi, riflettono in realtà simmetrie nel nostro stato informativo. L'obiettivo non è eliminare l'incertezza — compito impossibile, nella psicologia — ma imparare a ragionare con essa, trasformandola da ostacolo in risorsa.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Interpretazione soggettivista della probabilità

- La probabilità misura il grado di credenza razionale di un agente riguardo a un evento incerto
- È personale ma non arbitraria: deve rispettare regole di coerenza

2. Differenza con l'approccio frequentista

- Frequentista: probabilità come limite di frequenze relative (ripetibilità)

1. Interpretazione bayesiana della probabilità

i Informazioni sull'ambiente di sviluppo


```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2  patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51           labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8       curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8          purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1         xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.3        scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-1        rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0           RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0        parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0             Matrix_1.7-5          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1   glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6         QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9      Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5    rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9       backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13         snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1        gridExtra_2.3.1       nlme_3.1-169
#> [67] checkmate_2.3.4      xfun_0.60             pkgconfig_2.0.3

```

Bibliografia

2. Assiomi e coerenza delle credenze

Introduzione

Nel capitolo precedente abbiamo visto che, nell'interpretazione bayesiana, la probabilità non descrive frequenze oggettive, ma **gradi di credenza razionale**. Questa idea, apparentemente semplice, solleva immediatamente una domanda cruciale: cosa significa, esattamente, che una credenza sia “razionale”?

Non basta avere opinioni: tutti ne abbiamo. Non basta nemmeno avere opinioni informate o ragionevoli. Il punto è più sottile e profondo: le nostre credenze devono essere **internamente coerenti** tra loro. Se, per esempio, credo che piovgerà con probabilità 0.7 e che non piovgerà con probabilità 0.5, sto commettendo un errore logico, a prescindere da quanto siano informate le mie valutazioni meteorologiche. La somma delle mie credenze su eventi mutuamente esclusivi ed esaustivi deve essere 1, non per una convenzione arbitraria, ma perché altrimenti il mio sistema di credenze si contraddice.

Questo capitolo sviluppa il quadro matematico che rende espliciti e controllabili questi vincoli di coerenza. Ma attenzione: non si tratta di aggiungere un livello puramente formale alla discussione. La matematica che introdurremo non è un semplice ornamento tecnico, ma il *linguaggio* attraverso cui possiamo esprimere con precisione il significato di un ragionamento coerente in condizioni di incertezza.

Perché questo è importante per la psicologia

Per gli psicologi, questi assiomi definiscono lo standard normativo contro cui valutare il ragionamento umano in condizioni di incertezza, un tema centrale nella ricerca sui bias cognitivi a partire da Kahneman e Tversky. Inoltre, quando costruiamo modelli statistici, la coerenza probabilistica non è un optional: un modello incoerente è logicamente impossibile, come un triangolo con quattro lati. Comprendere questi vincoli ci rende ricercatori più consapevoli e clinici più competenti.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 1

Conoscenze matematiche richieste:

- Appendice C - per comprendere le proprietà additive
- Appendice D - per operazioni su eventi (unione, intersezione, complemento)

Panoramica del capitolo

Il percorso che seguiremo è questo:

1. Reinterpreteremo lo **spazio campionario** non come l'insieme degli esiti fisicamente possibili, ma come l'insieme delle possibilità che *noi* consideriamo date le nostre informazioni.
2. Vedremo come gli **eventi** diventino *proposizioni* sul mondo a cui assegniamo gradi di credenza.
3. Introdurremo gli **assiomi di Kolmogorov** non come regole arbitrarie, ma come vincoli *necessari* per evitare auto-contraddizioni.
4. Impareremo a **diagnosticare incoerenze** nelle assegnazioni probabilistiche.
5. Costruiremo **tabelle di probabilità congiunta**, lo strumento operativo fondamentale per rappresentare sistemi di credenze complessi.
6. Mostreremo come tutte le probabilità di interesse (marginali, condizionate) **derivino** dalla distribuzione congiunta.



Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()

# Load packages
if (!requireNamespace("pacman")) install.packages("pacman")
pacman::p_load(viridis)
# Riapplica il tema per sicurezza
apply_visual_theme()
```

2.1. Spazio campionario come possibilità epistemiche

Prima di addentrarci nelle definizioni formali, fermiamoci a riflettere su cosa stiamo cercando di catturare.

Quando uno psicologo clinico valuta un paziente, non sta osservando un “esperimento casuale” nel senso fisico del termine. Non c'è un dado che rotola, né una moneta che viene lanciata. Eppure, il clinico si trova in una condizione di *incertezza genuina*: sulla base delle informazioni raccolte (anamnesi, colloquio, test), deve formarsi un'opinione su quale sia la condizione del paziente tra diverse possibilità.

Questa situazione, ovvero avere informazioni incomplete e dover ragionare su possibilità alternative, è esattamente ciò che la teoria della probabilità, nell'interpretazione bayesiana, è progettata per gestire. Il primo passo è definire le possibilità che stiamo prendendo in considerazione.

Definizione 2.1 (Spazio campionario). Lo *spazio campionario* Ω rappresenta l'insieme delle *possibilità epistemiche* compatibili con lo stato informativo corrente. Esso non descrive necessariamente tutto ciò che può accadere fisicamente, ma piuttosto ciò che, dati i limiti della nostra conoscenza, consideriamo logicamente possibile.

2.1.1. Un cambio di prospettiva fondamentale

Questa definizione merita attenzione. Nella visione frequentista tradizionale, lo spazio campionario è qualcosa di “oggettivo”: l’insieme di tutti gli esiti che un esperimento può produrre, indipendentemente da chi lo osserva. Nell’approccio bayesiano, invece, lo spazio campionario diventa *epistemico*: dipende da ciò che *noi* sappiamo e dalle distinzioni che *noi* riteniamo rilevanti.

Questo cambiamento non è un dettaglio tecnico, ma un cambio di prospettiva filosofica con conseguenze pratiche profonde. Ciò significa che:

- **ricercatori diversi possono legittimamente usare spazi campionari diversi** per lo stesso fenomeno, se hanno informazioni diverse o interessi diversi;
- **lo spazio campionario può cambiare** quando si acquisiscono nuove informazioni. Prima di un test diagnostico, consideriamo come possibili sia il risultato “positivo” che quello “negativo”; dopo aver osservato il risultato, lo spazio delle possibilità rilevanti si restringe.
- **la scelta dello spazio campionario è una decisione di modellazione**, non una scoperta empirica; richiede un giudizio su quale livello di dettaglio sia appropriato per il problema in esame.

2.1.2. Caratteristiche dello spazio campionario epistemico

La composizione dello spazio campionario riflette dunque la natura informazionale e soggettiva della probabilità bayesiana. Non esiste “lo” spazio campionario corretto in senso assoluto, ma esiste quello appropriato, date le nostre informazioni e i nostri obiettivi.

i Esempio psicologico: livelli di granularità nella valutazione clinica

Consideriamo la valutazione di un paziente per una possibile depressione. Lo spazio campionario può essere definito a diversi livelli, a seconda delle informazioni disponibili e degli obiettivi clinici:

Livello 1 (binario):

$$\Omega_1 = \{\text{Depresso, Non depresso}\}.$$

Questo è il livello appropriato per una decisione sì/no: il paziente necessita di trattamento per depressione?

Livello 2 (severità):

$$\Omega_2 = \{\text{Nessuna, Lieve, Moderata, Severa}\}.$$

Qui distinguiamo gradi di severità, che sono importanti quando dobbiamo decidere *quale tipo* di trattamento proporre.

Livello 3 (combinazioni diagnostiche):

$$\Omega_3 = \{\text{Depressione, Ansia, Comorbidità, Nessuna}\}.$$

Questo livello considera la possibilità di diagnosi multiple o alternative.

Nessuno di questi spazi campionari è “più corretto” degli altri in senso assoluto. La scelta dipende da:

- le **informazioni disponibili** (uno screening rapido vs. una valutazione approfondita);
- l'**obiettivo dell'analisi** (screening di popolazione vs. diagnosi differenziale);

- le **decisioni da prendere** (inviare a uno specialista o pianificare un trattamento specifico).

La consapevolezza che lo spazio campionario è una *scelta* di modellazione e non un dato di fatto è il primo passo verso un uso maturo della probabilità.

2.2. Eventi come proposizioni sul mondo

Una volta definito lo spazio delle possibilità, il passo successivo è considerare le *affermazioni* su queste possibilità. Qui avviene un'altra importante traduzione concettuale.

Nella teoria degli insiemi, un "evento" è semplicemente un sottoinsieme dello spazio campionario. Tuttavia, nell'interpretazione epistemica, un evento acquista un significato più ricco: diventa una *proposizione*, un'affermazione sul mondo che può essere vera o falsa.

Definizione 2.2 (Evento). Un evento $A \subseteq \Omega$ è una *proposizione* alla quale possiamo assegnare un grado di credenza $P(A)$, condizionato allo stato informativo corrente.

2.2.1. La logica delle proposizioni incerte

Questa interpretazione collega la teoria della probabilità alla logica proposizionale. Le operazioni insiemistiche diventano operazioni logiche:

- L'**unione** $A \cup B$ corrisponde alla disgiunzione logica: " A oppure B è vera" (o entrambe).
- L'**intersezione** $A \cap B$ corrisponde alla congiunzione logica: " A e B sono entrambe vere".
- Il **complemento** A^c corrisponde alla negazione: " A è falsa".

Questa corrispondenza non è casuale. La teoria della probabilità può essere considerata come un'estensione della logica classica al caso dell'incertezza. Mentre la logica classica assegna solo valori "vero" (1) o "falso" (0) alle proposizioni, la probabilità assegna valori intermedi che rappresentano *gradi* di credenza.

L'**insieme vuoto** $\emptyset$ corrisponde a una proposizione logicamente contraddittoria, qualcosa che non può essere vero in nessuna delle possibilità che prendiamo in considerazione. Al contrario, lo **spazio campionario** Ω corrisponde a una tautologia, qualcosa che è necessariamente vero, dato che una delle possibilità deve realizzarsi.

Esempio: Eventi in un test psicometrico

La *Satisfaction with Life Scale* (SWLS) produce punteggi compresi tra 5 e 35. Definiamo:

- $\Omega = \{5, 6, 7, \dots, 35\}$ (punteggi possibili);
- $A = \text{"Punteggio} \geq 25\text{"}$ (alta soddisfazione) $= \{25, 26, \dots, 35\}$;
- $B = \text{"Punteggio} \leq 15\text{"}$ (bassa soddisfazione) $= \{5, 6, \dots, 15\}$;
- $C = \text{"Punteggio tra 16 e 24"}$ (soddisfazione moderata) $= \{16, 17, \dots, 24\}$.

Alcune operazioni sugli eventi e il loro significato:

- $A \cup B$: "La persona ha soddisfazione alta *oppure* bassa" (estremi).
- $A \cap B = \emptyset$: "Alta e bassa soddisfazione insieme"—impossibile per definizione.
- $A^c = B \cup C$: "Non alta soddisfazione" = "soddisfazione bassa o moderata".
- $A \cup B \cup C = \Omega$: le tre categorie esauriscono tutte le possibilità.

Quando assegniamo $P(A) = 0.30$, stiamo dicendo: “Dato ciò che so della popolazione di riferimento e del contesto di valutazione, ritengo plausibile che un individuo selezionato presenti un’alta soddisfazione di vita con una probabilità del 30%”
 Questa è un’affermazione epistemica, non una frequenza oggettiva. Due ricercatori con informazioni diverse potrebbero legittimamente assegnare valori diversi.

2.3. Gli assiomi di Kolmogorov come vincoli di coerenza

Arriviamo ora al cuore concettuale del capitolo. Abbiamo visto che le probabilità sono gradi di credenza su proposizioni. Ma quali valori possiamo assegnare? Siamo liberi di scegliere qualsiasi numero ci piaccia?

La risposta è no, e capire *perché* è fondamentale.

2.3.1. Il problema della coerenza

Immaginiamo un clinico che, valutando un paziente, assegna le seguenti probabilità a tre diagnosi mutualmente esclusive:

- $P(\text{Schizofrenia}) = 0.6$
- $P(\text{Disturbo Bipolare}) = 0.5$
- $P(\text{Nessun disturbo psicotico}) = 0.2$

La somma è 1.3. Cosa significa? Significa che il clinico sta assegnando più certezza di quanta ne abbia a disposizione. È come se il clinico dicesse: “Sono sicuro al 130% che una di queste tre cose sia vera”, il che non ha senso.

Questo non è un errore di valutazione clinica (il clinico potrebbe avere ottime ragioni per ciascuna stima individuale). Si tratta di un errore *logico*: le credenze sono in contraddizione tra loro. Come abbiamo visto nel capitolo precedente, un sistema di credenze incoerente espone a perdite certe (l’argomento della scommessa olandese).

Gli assiomi che introduciamo ora sono precisamente i vincoli che *impediscono* questo tipo di auto-contraddizioni.

Definizione 2.3 (Funzione di probabilità). Una *funzione di probabilità* è una funzione

$$P : \mathcal{F} \rightarrow [0, 1],$$

che assegna a ogni evento A appartenente a una famiglia di eventi $\mathcal{F}$ il numero $P(A)$, interpretabile come il grado di credenza nell’affermazione A , dato lo stato informativo corrente.

Per essere *coerente*, la funzione P deve soddisfare i seguenti **assiomi di coerenza**:

1. Non negatività

$$P(A) \geq 0 \quad \text{per ogni evento } A.$$

2. Normalizzazione

$$P(\Omega) = 1.$$

3. Additività

Se A e B sono eventi mutuamente esclusivi ($A \cap B = \emptyset$), allora

$$P(A \cup B) = P(A) + P(B).$$

Per spazi campionari infiniti, questo principio si estende a successioni numerabili di eventi: se $A_1, A_2, \dots$ sono a due a due disgiunti, allora

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Nella pratica psicologica, tuttavia, lavoreremo quasi sempre con spazi finiti, per cui la versione finita è quella che utilizzeremo più spesso.

2.3.2. Perché questi assiomi e non altri?

Una domanda legittima è: perché proprio questi tre (o quattro) vincoli? La risposta profonda a questa domanda viene dalla teoria della decisione e dall'argomento della scommessa olandese, che abbiamo trattato nel capitolo precedente. Tuttavia, è possibile fornire un'interpretazione intuitiva di ciascun assioma.

La non negatività riflette un fatto semplice: non esiste un grado di credenza “meno che impossibile”. Zero significa “sono certo che non accadrà”; non c'è nulla al di sotto dello zero. Se qualcuno vi dicesse: “Credo che piovenga con probabilità -0.3”, non sapreste nemmeno cosa intende.

La normalizzazione esprime la convinzione che *qualcosa* debba accadere. Per costruzione, lo spazio campionario contiene tutte le possibilità che prendiamo in considerazione. Una di queste deve realizzarsi. Assegnare $P(\Omega) < 1$ significherebbe ammettere la possibilità che nessuna delle alternative si verifichi, ma in tal caso avremmo dimenticato qualche alternativa nel nostro spazio campionario.

L'additività è forse il vincolo più importante, e merita una riflessione più approfondita. Dice che, se A e B non possono verificarsi insieme, allora la mia credenza che “si verifichi A oppure B ” deve essere esattamente la somma delle mie credenze separate in A e in B .

Perché? Qualsiasi altra assegnazione sarebbe incoerente. Se assegnassi $P(A \cup B) < P(A) + P(B)$, direi che credo “meno” nella disgiunzione rispetto alle due opzioni prese separatamente, ma la disgiunzione include entrambe le opzioni! Viceversa, se assegnassi $P(A \cup B) > P(A) + P(B)$, starei “contando due volte” qualcosa.

L'additività numerabile estende questo ragionamento a sequenze infinite di eventi, necessarie per trattare variabili continue, ma il principio è lo stesso.

Un'analogia utile: le aree

Le proprietà della probabilità sono analoghe a quelle delle aree. Se due regioni non si sovrappongono, la loro area totale è la somma delle due aree. Se le regioni si sovrappongono, devo sottrarre l'area di sovrapposizione per evitare di contarla due volte. L'area totale disponibile (normalizzata a 1) non può essere superata. Nessuna regione ha un'area negativa.

Questa analogia non è casuale: matematicamente, la probabilità è una “misura” e le misure generalizzano il concetto di area/volume. Tuttavia, l'interpretazione è diversa: non stiamo misurando estensioni spaziali, ma gradi di credenza.

2.3.3. Conseguenze immediate degli assiomi

Una volta accettati questi vincoli fondamentali, molte altre proprietà ne derivano come conseguenze logiche necessarie. Non si tratta di regole aggiuntive da memorizzare, ma di teoremi che *derivano* dagli assiomi.

Teorema 2.1 (Proprietà derivate della probabilità).

1. Probabilità del complemento

$$P(A^c) = 1 - P(A).$$

2. Probabilità dell'insieme vuoto

$$P(\emptyset) = 0.$$

3. Monotonia

Se $A \subseteq B$, allora

$$P(A) \leq P(B).$$

4. Regola dell'unione (eventi non disgiunti)

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

5. Principio di inclusione-esclusione (caso generale)

$$P(A_1 \cup A_2 \cup A_3) = \sum P(A_i) - \sum P(A_i \cap A_j) + P(A_1 \cap A_2 \cap A_3).$$

La prima proprietà è particolarmente importante e vale la pena di comprenderla bene: se credo che pioverà con probabilità 0.7, *devo* credere che non pioverà con probabilità 0.3. Non ho scelta. È una conseguenza logica degli assiomi.

La quarta proprietà (regola dell'unione generale) merita attenzione, in quanto mostra cosa accade quando gli eventi non sono disgiunti. La sottrazione di $P(A \cap B)$ corregge il “doppio conteggio” che si verificherebbe sommando semplicemente le due probabilità.

2.4. Diagnosi di incoerenze: casi tipici

La teoria è utile solo se ci permette di individuare e correggere gli errori nella pratica. Vediamo alcuni pattern comuni di incoerenza e come riconoscerli.

2.4.1. Incoerenza 1: violazione dell'additività

Questo è l'errore più comune e l'abbiamo già visto nell'esempio iniziale. Quando abbiamo eventi mutuamente esclusivi che insieme esauriscono tutte le possibilità, le loro probabilità devono sommare a 1.

 Esempio di incoerenza clinica

Sovrastima delle probabilità

Un clinico valuta un paziente con sintomi psicotici e assegna i seguenti gradi di credenza a tre diagnosi mutualmente esclusive:

- $P(\text{Schizofrenia}) = 0.6$;
- $P(\text{Disturbo Bipolare}) = 0.5$;
- $P(\text{Nessun disturbo psicotico}) = 0.2$.

La somma $0.6 + 0.5 + 0.2 = 1.3$ eccede il valore massimo consentito di 1.

Diagnosi del problema: il clinico ha probabilmente valutato ciascuna ipotesi separatamente, chiedendosi “quanto è plausibile questa diagnosi?” senza considerare il vincolo secondo cui le tre ipotesi devono spartirsi il 100% della credenza disponibile.

Correzione: il clinico deve riconsiderare le sue valutazioni come un *sistema*. Una possibilità è normalizzare i valori (dividere ogni valore per 1.3), ma è meglio rivalutare criticamente quale diagnosi sia stata sovrastimata. Forse la sicurezza sulla schizofrenia (0.6) e sul disturbo bipolare (0.5) è eccessiva, data l’evidenza disponibile.

2.4.2. Incoerenza 2: violazione dei vincoli di Fréchet per eventi congiunti

Un tipo più sottile di incoerenza emerge quando consideriamo la probabilità che due eventi si verifichino *insieme*. Anche qui esistono vincoli logici che non possono essere violati.

Consideriamo un esempio. Sappiamo che il 60% dei pazienti di un determinato ambulatorio soffre di depressione e il 50% di ansia. Qual è la probabilità che un paziente soffra di *entrambe* le condizioni?

La risposta non è libera. Non possiamo dire “10%” perché la matematica ci impone un valore minimo più alto. Non possiamo neanche dire “55%” perché supererebbe la probabilità dell’evento meno probabile.

Teorema 2.2 (Vincoli di Fréchet). *Per qualsiasi coppia di eventi A e B vale la disuguaglianza:*

$$\max\{0, P(A) + P(B) - 1\} \leq P(A \cap B) \leq \min\{P(A), P(B)\}.$$

Interpretazione intuitiva

Il limite superiore dice qualcosa di ovvio una volta che ci si pensa: la probabilità che accadano sia A che B non può essere maggiore della probabilità che accada solo A (né di quella che accada solo B). Se credo al 50% che pioverà, non posso credere che pioverà e farà freddo con una probabilità del 60%.

Il limite inferiore è meno ovvio ma altrettanto importante: se $P(A) + P(B) > 1$, i due eventi devono sovrapporsi almeno in parte. Se il 60% dei pazienti soffre di depressione e il 50% di ansia, allora almeno il 10% deve soffrire di entrambe le patologie, semplicemente perché altrimenti avremmo più del 100% di pazienti!

i Applicazione alla comorbidità psicologica

Definizione dello scenario

Torniamo all'esempio con $P(\text{Depressione}) = 0.6$ e $P(\text{Ansia}) = 0.5$.

I vincoli di Fréchet determinano l'intervallo ammissibile per la comorbidità:

- limite inferiore: $\max(0, 0.6 + 0.5 - 1) = 0.1$;
- limite superiore: $\min(0.6, 0.5) = 0.5$.

Quindi la probabilità di comorbidità **deve** essere compresa tra il 10% e il 50%.

Implicazioni pratiche: se un collega vi dicesse: “Nella mia esperienza, solo il 5% dei pazienti presenta entrambe le condizioni”, potreste rispondergli che questa stima è logicamente impossibile, date le prevalenze di depressione e ansia riportate. O ha sbagliato le prevalenze, o ha sbagliato la stima della comorbidità. Non c'è una terza possibilità.

Viceversa, qualsiasi valore compreso tra il 10% e il 50% è *logicamente ammissibile*, il che non significa che sia corretto, ma solo che non contraddice le altre assunzioni.

Mapa dei valori ammissibili.


```
# Creare griglia di valori
grid <- expand.grid(
  P_A = seq(0, 1, by = 0.02),
  P_B = seq(0, 1, by = 0.02)
)

# Calcolare vincoli per ogni coppia
grid$limite_inferiore <- pmax(0, grid$P_A + grid$P_B - 1)
grid$limite_superiore <- pmin(grid$P_A, grid$P_B)
grid$ampiezza_lecita <- grid$limite_superiore - grid$limite_inferiore

# Visualizzazione
ggplot(grid, aes(x = P_A, y = P_B, fill = ampiezza_lecita)) +
  geom_tile() +
  scale_fill_viridis_c(
    name = "Ampiezza dell'intervallo\nammissibile",
    option = "plasma",
    limits = c(0, 1)
  ) +
  labs(
    title = "Vincoli di Fréchet:\nintervalli ammissibili per P(A  B)",
    subtitle = "Per ogni coppia (P(A), P(B)), l'area colorata mostra\nquanti valori di l",
    x = "P(A)",
    y = "P(B)",
    caption = "Colori più chiari = maggiore libertà nella scelta di P(A  B)"
  ) +
  coord_fixed()
```

Vincoli di Fréchet: intervalli ammissibili per $P(A \cap B)$

Per ogni coppia $(P(A), P(B))$, l'area colorata mostra quanti valori di $P(A \cap B)$ sono logicamente possibili



Colori più chiari = maggiore libertà nella scelta di $P(A \cap B)$

Figura 2.1.: Regione dei valori ammissibili per $P(A \cap B)$ in funzione di $P(A)$ e $P(B)$.

La mappa rivela pattern interessanti. Negli angoli, corrispondenti agli eventi rari o quasi certi, i vincoli sono stringenti e c'è poca libertà nella scelta della probabilità congiunta. Al centro, dove le probabilità sono intermedie, c'è più libertà.

La regione in alto a destra, in cui $P(A) + P(B) > 1$, impone una sovrapposizione minima obbligatoria. La regione in basso a sinistra permette una sovrapposizione nulla.

2.5. Tabelle di probabilità congiunta

Passiamo ora dallo studio dei vincoli teorici alla costruzione di rappresentazioni operative. Le **tabelle di probabilità congiunta** sono lo strumento fondamentale per questo scopo.

2.5.1. L'idea centrale: la distribuzione congiunta è la "fonte"

Quando abbiamo due o più variabili, possiamo chiederci:

- Qual è la probabilità di ciascun valore della prima variabile? (*marginale*)
- Qual è la probabilità di ciascuna *combinazione* di valori? (*congiunta*)
- Se conosco il valore di una variabile, qual è la probabilità dei valori dell'altra? (*condizionata*)

Queste domande non sono indipendenti. Se conosco la distribuzione congiunta — ovvero le probabilità di tutte le combinazioni — posso **derivare** tutte le altre. La distribuzione congiunta è come il DNA del sistema: contiene tutte le informazioni; marginali e condizionate sono caratteristiche che emergono da quel DNA.

2.5.2. Struttura di una tabella 2×2

Consideriamo il caso più semplice: due eventi dicotomici A e B .

	B	B^c	Marginale
A	$P(A \cap B)$	$P(A \cap B^c)$	$P(A)$
A^c	$P(A^c \cap B)$	$P(A^c \cap B^c)$	$P(A^c)$
Marginale	$P(B)$	$P(B^c)$	1

- Le **quattro celle interne** contengono le probabilità congiunte.
- I **margin**i contengono le probabilità marginali, ottenute sommando righe o colonne:

$$P(A) = P(A \cap B) + P(A \cap B^c), \quad P(B) = P(A \cap B) + P(A^c \cap B).$$

- L'**angolo in basso a destra** deve valere 1: la somma di tutte le celle (e di tutte le marginali) è 1.

2.5.3. Costruzione di una tabella congiunta

Come si costruisce una tabella congiunta a partire dalle informazioni disponibili? La regola fondamentale è il **principio del prodotto**:

$$P(A \cap B) = P(A | B) P(B) = P(B | A) P(A).$$

Se conosciamo una probabilità marginale e una condizionata, possiamo ricavare la congiunta.

i Esempio: test diagnostico per la depressione

Consideriamo un test per la depressione con:

- **prevalenza**: $P(D) = 0.15$;
- **sensibilità**: $P(T^+ | D) = 0.85$;
- **tasso di falsi positivi**: $P(T^+ | D^c) = 0.20$.


Costruiamo la tabella congiunta:

```
prevalenza <- 0.15
sensibilita <- 0.85
tasso_falsi_positivi <- 0.20

p_D_pos <- sensibilita * prevalenza          # 0.1275
p_D_neg <- (1 - sensibilita) * prevalenza    # 0.0225
p_Dc_pos <- tasso_falsi_positivi * (1 - prevalenza) # 0.1700
p_Dc_neg <- (1 - tasso_falsi_positivi) * (1 - prevalenza) # 0.6800

tabella_congiunta <- matrix(
  c(p_D_pos, p_D_neg, p_Dc_pos, p_Dc_neg),
  nrow = 2, byrow = TRUE,
  dimnames = list(
    "Stato reale" = c("Depresso", "Non depresso"),
    "Test" = c("Positivo", "Negativo")
  )
)
round(tabella_congiunta, 4)
#>           Test
#> Stato reale  Positivo Negativo
#>   Depresso    0.128  0.0225
#>   Non depresso 0.170  0.6800
```

Ogni cella rappresenta la probabilità di una combinazione: veri positivi (0.1275), falsi negativi (0.0225), falsi positivi (0.1700), veri negativi (0.6800). La somma è 1.



2.5.4. Calcolo di marginali e condizionate

Una volta costruita la tabella congiunta, tutto il resto si ottiene per derivazione.

2.5.4.1. Probabilità marginali

Si ottengono sommando lungo righe o colonne:

```
#> P(D)      = 0.15 (prevalenza)
#> P(T+)     = 0.297 (test positivo)
```

Notiamo che $P(T^+) \approx 0.30$ è molto più alta della prevalenza (0.15), perché include sia i veri che i falsi positivi.

2.5.4.2. Probabilità condizionate

Si ottengono come rapporto tra probabilità congiunta e marginale:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

Interpretazione epistemica: condizionare significa *restringere* lo spazio delle possibilità a quelle compatibili con l'informazione acquisita, ri-normalizzando le probabilità su questo spazio ristretto.

i Esempio: valore predittivo positivo

La domanda clinica cruciale: “Se il test è positivo, qual è la probabilità che il paziente sia depresso?”

$$P(D | T^+) = \frac{P(D \cap T^+)}{P(T^+)} = \frac{0.1275}{0.1275 + 0.1700} \approx 0.429.$$

```
#> P(D | T+) = 0.429
```

Nonostante l'85% di sensibilità, un test positivo indica depressione solo nel 43% dei casi. La ragione è la bassa prevalenza: la maggior parte dei positivi è falsa. Questo fenomeno, il *paradosso dei test diagnostici*, è stato introdotto nel capitolo precedente e sarà ripreso nel Capitolo 5.

! Messaggio chiave

Una volta specificata la tabella congiunta, marginali e condizionate sono **determinate**. Non c'è libertà di scelta: specificare separatamente $P(A | B)$ e $P(B | A)$ senza una congiunta coerente quasi certamente introduce contraddizioni.

La regola è: **specificare la distribuzione congiunta, derivare tutto il resto.**

2.5.5. Verifica empirica mediante simulazione

Un modo potente per verificare la coerenza di un sistema di credenze è simulare dati secondo quella distribuzione e controllare che le frequenze osservate convergano alle probabilità teoriche.

i Verifica Monte Carlo

Simuliamo 100.000 osservazioni dalla tabella congiunta:


```
set.seed(123)
N <- 100000
probs <- c(p_D_pos, p_D_neg, p_Dc_pos, p_Dc_neg)
outcomes <- sample(1:4, size = N, replace = TRUE, prob = probs)
freq_empiriche <- table(outcomes) / N

df_verifica <- data.frame(
  Configurazione = c("D T+", "D T-", "D^c T+", "D^c T-"),
  Teorica = round(probs, 4),
  Empirica = round(as.numeric(freq_empiriche), 4)
)
print(df_verifica)
```

	Configurazione	Teorica	Empirica
#> 1	D T+	0.1275	0.1266
#> 2	D T-	0.0225	0.0226
#> 3	D^c T+	0.1700	0.1699
#> 4	D^c T-	0.6800	0.6809

Verifica empirica della tabella congiunta

Simulazione con N = 100,000



La convergenza delle frequenze empiriche verso le probabilità teoriche conferma che la distribuzione congiunta è un sistema coerente che specifica un *modello generativo* del mondo.


2.5.6. Estensione a tabelle multidimensionali

Il framework si estende naturalmente a più variabili e più categorie. Il principio è invariato: specificare le probabilità di tutte le combinazioni, derivare tutto il resto.

i Esempio: depressione × ansia (tabella 2×3)

```
tab_2x3 <- matrix(
  c(0.15, 0.20, 0.15, # Depresso: ansia nessuna/lieve/grave
    0.35, 0.10, 0.05), # Non depresso: ansia nessuna/lieve/grave
  nrow = 2, byrow = TRUE,
  dimnames = list(
    Depressione = c("D", "D^c"),
    Ansia = c("Nessuna", "Lieve", "Grave")
  )
)
print(tab_2x3)
#>           Ansia
#> Depressione Nessuna Lieve Grave
#>      D      0.15  0.2  0.15
#>      D^c    0.35  0.1  0.05
cat("\nMarginali depressione:", rowSums(tab_2x3), "\n")
#>
#> Marginali depressione: 0.5 0.5
cat("Marginali ansia:", colSums(tab_2x3), "\n")
#> Marginali ansia: 0.5 0.3 0.2
```

Tabella congiunta 2x3: Depressione × Ansia



Riflessioni conclusive

Siamo partiti da una domanda apparentemente astratta: cosa significa che le credenze siano “coerenti”? e siamo arrivati a strumenti concreti per rappresentare e manipolare sistemi di credenze complessi.

Il percorso ha rivelato che la matematica della probabilità non è un formalismo arbitrario, ma la **struttura logica necessaria** per ragionare in modo coerente in situazioni di incertezza. Gli assiomi di Kolmogorov non sono delle semplici convenzioni, ma dei vincoli che **dobbiamo rispettare** se vogliamo evitare contraddizioni.

2.5.1. Cosa abbiamo guadagnato

Per lo psicologo, questo framework offre diversi vantaggi:

1. **Uno standard normativo:** ora sappiamo cosa significa che un giudizio probabilistico sia “corretto” dal punto di vista logico, anche se può essere sbagliato dal punto di vista empirico.
2. **Strumenti diagnostici:** possiamo identificare incoerenze nei ragionamenti (nostri e altrui) utilizzando criteri precisi, come i vincoli di Fréchet.
3. **Una rappresentazione unificata:** le tabelle di probabilità congiunta condensano in un'unica struttura tutte le informazioni probabilistiche rilevanti su un sistema.
4. **Un ponte verso i dati:** la connessione tra probabilità teoriche e simulazioni mostra come le nostre credenze si traducano in aspettative sui dati osservabili.

2.5.2. Cosa manca ancora

Questo capitolo ha gettato le basi, ma restano ancora delle domande senza risposta:

- Come assegnare le probabilità *iniziali* quando non abbiamo dati? (Tema dell'equiprobabilità).
- Come *aggiorniamo* le nostre credenze quando osserviamo nuove evidenze? (Teorema di Bayes).
- Come trattiamo variabili *continue* che non rientrano in tabelle discrete? (Distribuzioni di probabilità).

Questi temi verranno sviluppati nei capitoli successivi. Tuttavia, la struttura di coerenza che abbiamo costruito rimarrà la cornice di riferimento.

2.5.3. Un invito alla riflessione

Prima di procedere, è opportuno soffermarsi a considerare un punto filosofico più profondo. Abbiamo visto che la coerenza è *necessaria* per evitare contraddizioni. Ma è *sufficiente* per ragionare bene?

La risposta è no. Un sistema di credenze può essere perfettamente coerente ma completamente errato. Posso credere con certezza matematica che domani pioveranno pesci dal cielo, e queste credenze possono essere internamente coerenti, ma saranno smentite dalla realtà.

La coerenza è una condizione *minima*, non una garanzia di verità. Ci protegge dagli errori logici, ma non da quelli empirici. Per avvicinarci alla verità, dobbiamo anche confrontare le nostre credenze con i dati, e questo sarà il tema dell'**inferenza bayesiana**.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. I tre assiomi di Kolmogorov

- Non-negatività: $P(A) \geq 0$ per ogni evento A .
- Normalizzazione: $P(\Omega) = 1$ (certezza per l'intero spazio campionario).
- Additività: $P(A \cup B) = P(A) + P(B)$ se A e B sono disgiunti.

2. Principio di coerenza

- Le credenze probabilistiche devono essere internamente consistenti.
- Un sistema di credenze incoerente porta a perdite certe (Dutch book argument).
- Gli assiomi *garantiscono* la coerenza razionale delle nostre valutazioni.

3. Conseguenze degli assiomi

- Probabilità del complemento: $P(A^c) = 1 - P(A)$.
- Evento impossibile: $P(\emptyset) = 0$.
- Regola dell'unione generale: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

4. Tabelle di probabilità congiunta

- Contengono l'informazione completa sul sistema.
- Marginali = somme di righe/colonne.
- Condizionate = rapporti (congiunta / marginale).
- Tutto deriva dalla distribuzione congiunta.

Formule da ricordare:

$$P(A^c) = 1 - P(A)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

Per il prossimo capitolo:

Nel Capitolo 3 vedremo come applicare questi assiomi a situazioni di equiprobabilità, introducendo il calcolo combinatorio per contare i casi favorevoli e possibili.

Esercizi

! Problemi

2.5.1. Esercizi sulla coerenza

1. Verifica se le seguenti assegnazioni per eventi mutuamente esclusivi sono coerenti:
 - a. $P(A) = 0.3, P(B) = 0.4, P(C) = 0.3$
 - b. $P(A) = 0.5, P(B) = 0.4, P(C) = 0.2$
 - c. $P(A) = 0.25, P(B) = 0.25, P(C) = 0.25, P(D) = 0.25$
2. Un ricercatore assegna $P(A) = 0.7$ e $P(A^c) = 0.4$. Identifica l'incoerenza e spiega perché viola gli assiomi.
3. Per eventi disgiunti A e B con $P(A) = 0.6$ e $P(B) = 0.3$, qualcuno afferma $P(A \cup B) = 0.8$. È coerente? Se no, qual è il valore corretto?

2.5.2. Esercizi sui vincoli di Fréchet

4. Dati $P(A) = 0.4$ e $P(B) = 0.7$:

- a. Calcola i vincoli di Fréchet per $P(A \cap B)$
- b. Quali dei seguenti valori sono coerenti: 0.05, 0.1, 0.3, 0.5?
- c. Visualizza graficamente la regione ammissibile

5. In uno studio su depressione e insonnia:

- $P(\text{Depressione}) = 0.30$
- $P(\text{Insonnia}) = 0.45$

Determina l'intervallo di valori plausibili per $P(\text{Depressione} \cap \text{Insonnia})$.

6. Scrivi una funzione R che, dati $P(A)$ e $P(B)$, verifichi se un proposto $P(A \cap B)$ rispetta i vincoli di Fréchet.

2.5.3. Esercizi su tabelle congiunte

7. Completa la seguente tabella congiunta (alcune celle sono mancanti):

	B	B^c	Marg.
A	0.25	?	0.40
A^c	?	0.45	?
Marg.	?	?	1

8. Costruisci una tabella congiunta 2×2 per:

- Test COVID: $P(+) = 0.08$
- Malattia: $P(\text{COVID}) = 0.05$
- Sensibilità: $P(+ \mid \text{COVID}) = 0.90$

Calcola poi:

- $P(\text{COVID} \mid +)$ (valore predittivo positivo)
- $P(\text{COVID} \mid -)$ (probabilità dopo test negativo)
- Specificità del test

9. Verifica con simulazione Monte Carlo ($N=100,000$) che la tabella dell'esercizio 8 è coerente confrontando frequenze empiriche con probabilità teoriche.

2.5.4. Esercizi applicati (psicologia)

10. **Comorbidità:** In un campione clinico:

- $P(\text{Depressione}) = 0.55$
- $P(\text{PTSD}) = 0.30$
- $P(\text{PTSD} \mid \text{Depressione}) = 0.45$

- Costruisci la tabella congiunta completa
- Calcola $P(\text{Depressione} \mid \text{PTSD})$
- Le due condizioni sono indipendenti?
- Qual è la probabilità di avere almeno una delle due condizioni?

11. **Test psicometrico:** Un test di ansia ha:

- Sensibilità: 0.80
- Specificità: 0.85
- Prevalenza nell'ambulatorio: 0.25

- Costruisci la tabella 2×2 per (Ansia $\times$ Test)
- Un paziente ha test positivo. Quanto è probabile che sia ansioso?
- Se il test è negativo, quanto è probabile l'assenza di ansia?

12. **Tre diagnosi:** Un paziente può avere Depressione (D), Ansia (A), o Nessuna condizione (N). Assegnazioni:

- $P(D) = 0.40$
- $P(A) = 0.35$
- $P(N) = 0.30$

Identifica e correggi l'incoerenza.

2.5.5. Esercizi di pensiero critico

- Spiega perché, nell'approccio bayesiano, specificare una tabella congiunta coerente è "più fondamentale" che specificare separatamente marginali e condizionate.
- Un frequentista obietta: "Le tabelle congiunte funzionano solo per spazi finiti. Come gestite il caso continuo?" Rispondi dall'ottica bayesiana.
- Due clinici costruiscono tabelle congiunte diverse per Depressione $\times$ Test, partendo da prior diversi ma usando la stessa sensibilità/specificità. È un problema? Cosa succederebbe con molti dati?

2.5.6. Esercizi computazionali

16. Scrivi una funzione R che:
 - Input: vettore di probabilità per eventi mutuamente esclusivi
 - Output: TRUE se coerente, FALSE con messaggio di errore se incoerente
 - Bonus: Se incoerente, proponi correzione per normalizzazione
17. Crea una visualizzazione interattiva (Shiny app o plot animato) che mostri come variano i vincoli di Fréchet al variare di $P(A)$ e $P(B)$.
18. Simula 10,000 pazienti secondo la tabella dell'esercizio 10, poi:
 - a. Calcola frequenze empiriche delle 4 configurazioni
 - b. Confronta con probabilità teoriche
 - c. Visualizza convergenza all'aumentare di N

Soluzioni

2.5.7. Soluzioni esercizi sulla coerenza

1.
 - a. $0.3 + 0.4 + 0.3 = 1.0$ ☑ Coerente
 - b. $0.5 + 0.4 + 0.2 = 1.1$ ☒ Incoerente (somma > 1)
 - c. $4 \times 0.25 = 1.0$ ☑ Coerente
2. Per l'assioma del complemento: $P(A) + P(A^c) = 1$. Ma $0.7 + 0.4 = 1.1 \neq 1$. Incoerente. Correzione: deve essere $P(A^c) = 0.3$.
3. Per eventi disgiunti: $P(A \cup B) = P(A) + P(B) = 0.6 + 0.3 = 0.9$. Il valore 0.8 è incoerente (troppo basso).

2.5.8. Soluzioni vincoli di Fréchet

4.
 - a. Lower: $\max(0, 0.4 + 0.7 - 1) = 0.1$; Upper: $\min(0.4, 0.7) = 0.4$
Intervallo: $[0.1, 0.4]$
 - b. Coerenti: 0.1 (al limite), 0.3 (interno), 0.5 (FUORI, troppo alto)
Non coerente: 0.05 (troppo basso)
5. Lower: $\max(0, 0.30 + 0.45 - 1) = 0$; Upper: $\min(0.30, 0.45) = 0.30$
Intervallo plausibile: $[0, 0.30]$

```

6. check_frechet <- function(P_A, P_B, P_AB) {
  lower <- max(0, P_A + P_B - 1)
  upper <- min(P_A, P_B)

  if (P_AB >= lower && P_AB <= upper) {
    cat(" Coerente: P(A B)  [", lower, ",", upper, "]\n")
    return(TRUE)
  } else {
    cat(" Incoerente: P(A B) =", P_AB,
        "ma deve essere in [", lower, ",", upper, "]\n")
    return(FALSE)
  }
}

```

2.5.9. Soluzioni tabelle congiunte

7. Tabella completata:

- $P(A \cap B^c) = 0.40 - 0.25 = 0.15$
- $P(A^c \cap B) = P(B) - 0.25$ (serve calcolare $P(B)$ da altre info)
- $P(A^c) = 1 - 0.40 = 0.60$
- $P(A^c \cap B) = 0.60 - 0.45 = 0.15$
- $P(B) = 0.25 + 0.15 = 0.40$
- $P(B^c) = 0.15 + 0.45 = 0.60$

	B	B^c	Marg.
A	0.25	0.15	0.40
A^c	0.15	0.45	0.60
Marg.	0.40	0.60	1.00

```

8. P_C <- 0.05
   P_pos <- 0.08
   sens <- 0.90

   # Congiunta
   P_C_and_pos <- sens * P_C # = 0.045
   P_C_and_neg <- P_C - P_C_and_pos # = 0.005
   P_notC_and_pos <- P_pos - P_C_and_pos # = 0.035
   P_notC_and_neg <- 1 - (P_C_and_pos + P_C_and_neg + P_notC_and_pos) # = 0.915

   # a)  $P(C \mid +) = 0.045 / 0.08 = 0.5625$ 
   # b)  $P(C \mid -) = 0.005 / 0.92 = 0.0054$ 
   # c) Specificità =  $P(- \mid C^c) = 0.915 / 0.95 = 0.963$ 

```

2.5.10. Soluzioni esercizi applicati

```

10. P_D <- 0.55
    P_P <- 0.30
    P_P_given_D <- 0.45

    # a) Tabella
    P_D_and_P <- P_P_given_D * P_D # = 0.2475
    P_D_and_notP <- P_D - P_D_and_P # = 0.3025
    P_notD_and_P <- P_P - P_D_and_P # = 0.0525
    P_notD_and_notP <- 1 - (P_D_and_P + P_D_and_notP + P_notD_and_P) # = 0.3975

    # b)  $P(D \mid P) = 0.2475 / 0.30 = 0.825$ 

    # c) Test indipendenza:  $P(D) \times P(P) = 0.55 \times 0.30 = 0.165$ 
    #  $P(D \mid P) = 0.2475 / 0.30 = 0.825 \neq 0.165 \rightarrow$  DIPENDENTI

    # d)  $P(D \cup P) = 0.55 + 0.30 - 0.2475 = 0.6025$ 

```

```

11. # Vedi soluzione 8, adattata con prevalenza 0.25
    # a) Tabella costruita con sens=0.80, spec=0.85, prev=0.25
    # b)  $P(A \mid +) = [0.80 \times 0.25] / [0.80 \times 0.25 + 0.15 \times 0.75] = 0.640$ 
    # c)  $P(A^c \mid -) = [0.85 \times 0.75] / [0.20 \times 0.25 + 0.85 \times 0.75] = 0.927$ 

```

12. Somma = 1.05 > 1. Incoerente. Correzione (normalizzazione):

- $P(D) = 0.40/1.05 \approx 0.381$
- $P(A) = 0.35/1.05 \approx 0.333$
- $P(N) = 0.30/1.05 \approx 0.286$

2.5.11. Soluzioni pensiero critico

13. La tabella congiunta è più fondamentale perché rappresenta lo stato di credenza **completo** sul sistema. Da essa derivano automaticamente (e coerentemente) tutte le marginali e

condizionate. Specificare marginali e condizionate separatamente rischia incoerenze (es. $P(A | B)P(B) \neq P(B | A)P(A)$).

14. Nel continuo si usano **densità di probabilità congiunta** $f(x, y)$. Il principio è identico: la densità congiunta determina tutto (marginali tramite integrazione, condizionate tramite rapporti di densità). La struttura di coerenza è preservata.
15. Non è un problema—riflette informazioni diverse. Con molti dati, la verosimiglianza dominerà e i posterior convergeranno, riducendo l'influenza dei prior diversi. È una caratteristica, non un bug: la soggettività è nelle assunzioni iniziali esplicite.

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] viridis_0.6.5      viridisLite_0.4.3  ragg_1.5.2
#> [4] tinytable_0.17.0   withr_3.0.3        systemfonts_1.3.2
#> [7] patchwork_1.3.2    ggdist_3.3.3       tidybayes_3.0.7
#> [10] bayesplot_1.15.0   ggplot2_4.0.3      reliabilitydiag_0.2.1
#> [13] priorsense_1.2.0   posterior_1.7.0     loo_2.10.0
#> [16] rstan_2.32.7       StanHeaders_2.32.10 brms_2.23.0
#> [19] Rcpp_1.1.2         sessioninfo_1.2.4   conflicted_1.2.0
#> [22] janitor_2.2.1      matrixStats_1.5.0   modelr_0.1.11
#> [25] tibble_3.3.1       dplyr_1.2.1         tidyr_1.3.2
#> [28] rio_1.3.0          here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidymodels_1.2.1    farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0       tensorA_0.36.2.1
#> [7] pacman_0.5.1        digest_0.6.39       timechange_0.4.0
#> [10] estimability_2.0.0  lifecycle_1.0.5     magrittr_2.0.5
#> [13] compiler_4.6.1      rlang_1.3.0         tools_4.6.1
#> [16] yaml_2.3.12         knitr_1.51          labeling_0.4.3
#> [19] bridgesampling_1.2-1 pkgbuild_1.4.8      curl_7.1.0
#> [22] RColorBrewer_1.1-3  abind_1.4-8         purrr_1.2.2
#> [25] grid_4.6.1          stats4_4.6.1        xtable_1.8-8
#> [28] inline_0.3.21       emmeans_2.0.3       scales_1.4.0
#> [31] cli_3.6.6           mvtnorm_1.4-1       rmarkdown_2.31
#> [34] generics_0.1.4      otel_0.2.0          RcppParallel_5.1.11-2
#> [37] cachem_1.1.0        stringr_1.6.0       parallel_4.6.1
#> [40] vctrs_0.7.3         V8_8.2.0            Matrix_1.7-5
#> [43] jsonlite_2.0.0       arrayhelpers_1.1-1  glue_1.8.1
#> [46] codetools_0.2-20    distributional_0.8.1 lubridate_1.9.5
#> [49] stringi_1.8.7       gtable_0.3.6        QuickJSR_1.10.0
#> [52] pillar_1.11.1       htmltools_0.5.9     Brodningnag_1.2-9
#> [55] R6_2.6.1            textshaping_1.0.5   rprojroot_2.1.1
#> [58] evaluate_1.0.5      lattice_0.22-9      backports_1.5.1
#> [61] memoise_2.0.1       broom_1.0.13        snakecase_0.11.1
#> [64] rstantools_2.6.0    coda_0.19-4.1       gridExtra_2.3.1
#> [67] nlme_3.1-169        checkmate_2.3.4     xfun_0.60
#> [70] pkgconfig_2.0.3

```

Bibliografia

3. Equiprobabilità e calcolo combinatorio

Introduzione

Qual è la probabilità di ottenere “testa” nel lancio di una moneta? La risposta che viene spontanea, “1/2”, sembra ovvia, quasi banale. Eppure, dietro a questa apparente semplicità si nasconde una questione epistemologica profonda.

La formula che abbiamo imparato,

$$\text{Probabilità} = \frac{\text{casi favorevoli}}{\text{casi possibili}},$$

viene spesso presentata come *la* definizione di probabilità. Ma è davvero così? E soprattutto: quando possiamo utilizzarla in modo legittimo?

La risposta è che questa formula vale solo in un contesto ben preciso: quello in cui tutti gli esiti sono considerati *a priori* ugualmente plausibili. Questo capitolo esplora il significato di questa assunzione, i suoi limiti e gli strumenti per andare oltre, dalla combinatoria alla distribuzione Beta.

Il percorso del capitolo

In questo capitolo faremo tre cose:

1. **Capiremo quando l’equiprobabilità è giustificata** e cosa significa esattamente assumerla. Capiremo che non si tratta di una proprietà del mondo, ma di una scelta inferenziale basata sullo stato delle nostre informazioni.
2. **Impareremo le tecniche combinatorie** (permutazioni, disposizioni e combinazioni) come strumenti per *contare* le configurazioni equiprobabili, riconoscendo che la combinatoria è un’ancella dell’equiprobabilità e non il suo fondamento.
3. **Introdurremo la distribuzione Beta** come generalizzazione continua che ci permette di rappresentare credenze *non* uniformi, aprendo la strada a modelli più realistici per i fenomeni psicologici.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 1
- Capitolo 2

Conoscenze matematiche richieste:

- Appendice D - per operazioni su eventi
- Appendice E - fondamentale per permutazioni, disposizioni e combinazioni

Competenze pratiche:

- familiarità di base con R per eseguire le simulazioni Monte Carlo presentate nel capitolo

Panoramica del capitolo

- Il principio di indifferenza e la simmetria epistemica.
- Formula classica come caso speciale bayesiano.
- Tecniche di calcolo combinatorio: permutazioni, disposizioni, combinazioni.
- Quando l'equiprobabilità NON si applica.
- La distribuzione Beta come generalizzazione continua.
- Applicazioni psicologiche.



Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()

# Load packages
if (!requireNamespace("pacman")) install.packages("pacman")
pacman::p_load(combinat, gtools)
# Riapplica il tema per sicurezza
apply_visual_theme()
```

3.1. Il principio di indifferenza

Partiamo dalla domanda fondamentale: quando è legittimo assumere che tutti gli esiti siano ugualmente probabili?

La risposta, secondo la prospettiva bayesiana, non riguarda le proprietà fisiche degli oggetti, ma *lo stato delle nostre conoscenze*. Il principio che giustifica l'equiprobabilità è chiamato **principio di indifferenza**.

Definizione 3.1 (Principio di indifferenza). Se non abbiamo *ragioni per distinguere* tra n possibilità mutualmente esclusive ed esaustive, è razionalmente coerente assegnare a ciascuna la stessa credenza, pari a $1/n$.

3.1.1. L'equiprobabilità come simmetria dell'ignoranza

Questa definizione merita una lettura attenta. Non dice che gli esiti *sono* equiprobabili. Dice che *è razionale trattarli come tali* quando non abbiamo informazioni che ci permettano di distinguerli.

In questa prospettiva, l'equiprobabilità non è una proprietà del mondo, ma una proprietà della nostra relazione epistemica con esso. Riflette la **simmetria della nostra ignoranza**: se non conosciamo nulla che favorisca un esito rispetto a un altro, non abbiamo basi razionali per assegnare probabilità diverse.

3.1.2. Condizioni di applicabilità

Il principio di indifferenza è potente ma non automatico. La sua applicazione richiede che siano soddisfatte alcune condizioni:

1. **Simmetria fisica rilevante:** il sistema non deve presentare differenze *rilevanti* tra gli esiti.
2. **Ignoranza genuina:** non devono essere disponibili informazioni che permettano di distinguere razionalmente tra gli esiti.
3. **Assenza di struttura rilevante:** il processo non deve presentare pattern o vincoli che rendano alcuni risultati più probabili di altri.

La parola chiave qui è *giudizio*. L'equiprobabilità non si applica in modo meccanico, ma richiede una valutazione esplicita del contesto.

! Due modi di pensare all'equiprobabilità

Prospettiva frequentista: «Il dado è equo, quindi ogni faccia ha probabilità $1/6$.»

Prospettiva bayesiana: «Non dispongo di informazioni che favoriscano una faccia rispetto alle altre, quindi assegno a ciascuna una probabilità di $1/6$.»

La differenza è sostanziale: nel primo caso l'equiprobabilità è una proprietà fisica; nel secondo è una proprietà dello stato informativo dell'osservatore.

i Il paradosso di Bertrand (approfondimento)

L'applicazione ingenua del principio di indifferenza può condurre a contraddizioni. Supponiamo che una fabbrica produca cubi con lato compreso tra 0 e 1 metro. Qual è la probabilità che un cubo selezionato a caso abbia lato > 0.5 ?

- Se assumiamo equiprobabilità rispetto alla *lunghezza*, otteniamo 0.5.
- Se assumiamo equiprobabilità rispetto al *volume*, il calcolo cambia.

Il paradosso non segnala un fallimento della teoria, ma un'**ambiguità nella formulazione del problema**: la probabilità non ha senso finché non specifichiamo *rispetto a quale variabile* assumiamo l'indifferenza.

3.2. La formula classica come caso speciale

Una volta compreso il principio di indifferenza, possiamo finalmente dare una collocazione precisa alla formula classica della probabilità. Non si tratta di una definizione fondamentale, ma di un **teorema derivato** che vale sotto condizioni specifiche.

Teorema 3.1 (Formula classica della probabilità). Sia $\Omega = \{\omega_1, \dots, \omega_n\}$ uno spazio campionario finito in cui, per **simmetria epistemica**, tutti gli esiti sono ritenuti equiprobabili:

$$P(\omega_i) = \frac{1}{n} \quad \text{per ogni } i.$$

Allora, per qualsiasi evento $A \subseteq \Omega$,

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{casi favorevoli}}{\text{casi possibili}}.$$

Messaggio chiave: la formula classica **non definisce** che cosa sia una probabilità. È una **conseguenza** degli assiomi di coerenza e vale solo quando l'ipotesi di equiprobabilità è giustificata.

3.3. Tecniche di calcolo combinatorio

Assumendo che l'equiprobabilità sia stata verificata, il calcolo combinatorio fornisce gli strumenti per contare le configurazioni. La scelta della tecnica appropriata dipende da due domande:

1. L'ordine conta?
2. Selezioniamo tutti gli elementi o solo alcuni?

3.3.1. Principio della somma

Quando le possibilità si suddividono in categorie mutualmente esclusive, il numero totale è la somma delle possibilità di ciascuna categoria.:

$$n_{\text{totale}} = n_1 + n_2 + \dots + n_k.$$

Esempio psicologico

Un paziente può accedere a:

- 8 protocolli cognitivi,
- 6 protocolli comportamentali,
- 10 protocolli integrati.

Se non abbiamo informazioni che favoriscano un tipo di protocollo rispetto agli altri, le opzioni equiprobabili sono:

$$8 + 6 + 10 = 24,$$

con probabilità $1/24$ per ciascun protocollo specifico.

Nota: questa equiprobabilità presuppone che non ci siano indicazioni cliniche che rendano alcuni protocolli più appropriati di altri per questo specifico paziente. Se tali indicazioni esistono, l'equiprobabilità non è più giustificata.

3.3.2. Principio del prodotto

Quando una configurazione è il risultato di scelte sequenziali indipendenti, il numero totale è il prodotto delle possibilità di ciascuna scelta.:

$$n_{\text{totale}} = n_1 \times n_2 \times \dots \times n_k.$$

Esempio psicologico

Nella progettazione di uno studio:

- 3 metodi di valutazione,
- 4 frequenze di misurazione,
- 2 durate di follow-up,

producono:

$$3 \times 4 \times 2 = 24$$

disegni possibili. Se non abbiamo ragioni teoriche per preferire un disegno a un altro, ciascuno ha una probabilità $1/24$ di essere “quello giusto” per il nostro scopo.

Nota: nella pratica, quasi sempre abbiamo delle ragioni per preferire alcuni disegni, come considerazioni sulla fattibilità, sul costo e sulla validità. L’equiprobabilità è raramente la descrizione corretta della nostra incertezza riguardo alla scelta del disegno.

3.3.3. Permutazioni: tutti gli ordinamenti di n elementi

Le **permutazioni** contano i modi di ordinare n oggetti distinti quando l’ordine è rilevante:

$$P_n = n! = n \times (n - 1) \times \cdots \times 1. \quad (3.1)$$

L’intuizione è semplice: il primo elemento può essere scelto in n modi, il secondo in $n - 1$, e così via.

i Esempio psicologico

In un esperimento sulla memoria, 5 parole vengono presentate in ordine casuale. Quanti ordinamenti sono possibili?

$$5! = 120.$$

Se la randomizzazione è davvero casuale (equiprobabilità degli ordinamenti), ogni sequenza specifica ha probabilità $1/120 \approx 0.008$.

```
parole <- c("Tavolo", "Fiore", "Automobile", "Stella", "Libro")
n_perm <- factorial(length(parole))

cat("Parole:", paste(parole, collapse = ", "), "\n")
#> Parole: Tavolo, Fiore, Automobile, Stella, Libro
cat("Ordini possibili:", n_perm, "\n")
#> Ordini possibili: 120
cat("P(ordine specifico):", round(1/n_perm, 5), "\n\n")
#> P(ordine specifico): 0.00833

# Esempi di sequenze
set.seed(123)
cat("Sequenze casuali:\n")
#> Sequenze casuali:
for(i in 1:3) {
  cat(" ", paste(sample(parole), collapse = " → "), "\n")
}
#>   Automobile → Fiore → Libro → Stella → Tavolo
#>   Automobile → Tavolo → Fiore → Libro → Stella
#>   Fiore → Automobile → Tavolo → Stella → Libro
```

Nota psicologica: l'equiprobabilità riguarda la selezione, non gli effetti psicologici dell'ordine.

3.3.4. Disposizioni: k elementi ordinati da n

Le **disposizioni** contano i modi di scegliere e ordinare k oggetti distinti da un insieme di n elementi:

$$D_{n,k} = \frac{n!}{(n-k)!} = n \times (n-1) \times \dots \times (n-k+1). \quad (3.2)$$

i Esempio psicologico

Con 8 partecipanti e 3 ruoli distinti (facilitatore, osservatore, timekeeper), le assegnazioni possibili sono:

$$D_{8,3} = \frac{8!}{5!} = 8 \times 7 \times 6 = 336.$$

In assenza di informazioni sulle competenze, ogni assegnazione ha probabilità $1/336 \approx 0.003$.

Nota: nella pratica, i ruoli si assegnano in base alle competenze, quindi l'equiprobabilità è spesso inappropriata.

3.3.5. Combinazioni: k elementi non ordinati da n

Le **combinazioni** contano i sottoinsiemi di k elementi scelti da n , quando l'ordine non è rilevante:

$$C_{n,k} = \binom{n}{k} = \frac{n!}{k!(n-k)!}. \quad (3.3)$$

i Esempio psicologico

Con 12 volontari per il peer counseling, le coppie possibili sono:

$$\binom{12}{2} = \frac{12!}{2! \cdot 10!} = 66.$$

Se non abbiamo informazioni sulla compatibilità, ogni coppia ha probabilità $1/66 \approx 0.015$.
Nota: nella realtà, alcune coppie funzionano meglio di altre. Un modello realistico dovrebbe assegnare probabilità diverse in base a predittori di compatibilità.

💡 Riepilogo: quale tecnica usare?

Tecnica	Ordine conta?	Formula	Esempio psicologico
Permutazioni	Sì (tutti gli elementi)	$n!$	Ordine di n stimoli
Disposizioni	Sì (solo k elementi)	$\frac{n!}{(n-k)!}$	Assegnazione di ruoli
Combinazioni	No	$\binom{n}{k}$	Formazione di gruppi

! Il punto fondamentale da non dimenticare

Ogni formula combinatoria presuppone che tutte le configurazioni elencate siano **equiprobabili**. La combinatoria ci dice *quante* configurazioni esistono, non *quali* siano più probabili.

3.4. Quando l'equiprobabilità non si applica

Finora abbiamo trattato l'equiprobabilità come se fosse la norma. È il momento di ribaltare la prospettiva: nella ricerca psicologica, l'equiprobabilità è l'*eccezione*, non la regola.

3.4.1. La variabilità è la norma, non l'anomalia

Quasi ogni fenomeno psicologico presenta una variabilità sistematica. Gli item di un test hanno difficoltà diverse. Le persone hanno abilità diverse. I trattamenti funzionano in modo diverso per pazienti diversi. Ignorare questa variabilità assumendo equiprobabilità significa perdere l'essenza del fenomeno.

3.4.2. Esempio: difficoltà degli item nei test

Consideriamo un test con 5 item di difficoltà diversa:

```
item_difficolta <- c(0.9, 0.7, 0.5, 0.3, 0.1)
cat("Probabilità di risposta corretta per item:\n")
#> Probabilità di risposta corretta per item:
```

```
for(i in seq_along(item_difficolta)) {  
  cat(" Item", i, ":", item_difficolta[i], "\n")  
}  
#> Item 1 : 0.9  
#> Item 2 : 0.7  
#> Item 3 : 0.5  
#> Item 4 : 0.3  
#> Item 5 : 0.1  
set.seed(123)  
risposte <- replicate(1000, rbinom(5, 1, item_difficolta))  
cat("\nProporzioni osservate (simulate):", round(rowMeans(risposte), 2))  
#>  
#> Proporzioni osservate (simulate): 0.89 0.71 0.48 0.29 0.1
```

Assumere equiprobabilità ($P = 0.5$ per ogni item) produrrebbe una sottostima sugli item facili e una sovrastima su quelli difficili. L'errore non è solo quantitativo: si ignorerebbe una proprietà fondamentale degli item.

3.4.3. La lezione più ampia

L'equiprobabilità è un'ipotesi da verificare, non da assumere per default. Quando la rifiutiamo, riconosciamo che il mondo è più ricco di quanto l'equiprobabilità possa rappresentare. La distribuzione Beta, che vedremo ora, ci offre uno strumento per esprimere questa ricchezza.

3.5. La distribuzione Beta: dal discreto al continuo

Finora abbiamo ragionato su spazi finiti. Ma in molti contesti psicologici dobbiamo stimare dei **parametri sconosciuti** che possono assumere qualsiasi valore in un intervallo continuo (ad esempio, la probabilità di risposta a un trattamento).

La **distribuzione Beta** è lo strumento che ci permette di rappresentare le nostre credenze su questi parametri.

3.5.1. Intuizione: la Beta come “memoria di esperienze”


La distribuzione Beta(α, β) può essere pensata come la **sintesi di esperienze passate** codificate sotto forma di “conteggi virtuali”:

- $\alpha - 1$ = numero di “successi” osservati (o immaginati);
- $\beta - 1$ = numero di “insuccessi” osservati (o immaginati).
- **Beta(1,1)**: nessuna esperienza pregressa — ogni valore è ugualmente plausibile (analogo continuo dell'equiprobabilità).
- **Beta(5,5)**: come se avessimo osservato 4 successi e 4 insuccessi — credenza centrata, incertezza moderata.
- **Beta(20,10)**: come se avessimo osservato 19 successi e 9 insuccessi — aspettativa elevata, maggiore certezza.

```

theta <- seq(0, 1, length.out = 500)
beta_params <- list(
  "Beta(1,1): Ignoranza totale" = c(1, 1),
  "Beta(5,5): Credenza centrale" = c(5, 5),
  "Beta(20,10): Aspettativa alta" = c(20, 10),
  "Beta(2,8): Aspettativa bassa" = c(2, 8)
)
df_beta <- data.frame()
for(nome in names(beta_params)) {
  params <- beta_params[[nome]]
  df_beta <- rbind(df_beta, data.frame(
    theta = theta,
    Densita = dbeta(theta, params[1], params[2]),
    Distribuzione = nome
  ))
}
ggplot(df_beta, aes(x = theta, y = Densita, color = Distribuzione)) +
  geom_line(linewidth = 1.2) +
  facet_wrap(~ Distribuzione, scales = "free_y", ncol = 2) +
  labs(x = expression(theta), y = "Densità",
       title = "Forme della distribuzione Beta") +
  theme(legend.position = "none")

```



3.5.2. Due parametri, due significati

- **Posizione** (dove pensiamo che sia θ):

$$\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}$$

- **Forza della convinzione** (quanto siamo sicuri):
 $\alpha + \beta$ controlla la concentrazione. Valori alti $\rightarrow$ distribuzione stretta (sicurezza); valori bassi $\rightarrow$ distribuzione diffusa (incertezza).

3.5.3. Beta(1,1): l'equiprobabilità continua

Beta(1,1) è semplicemente la **distribuzione uniforme** su $[0,1]$: ogni valore è ugualmente plausibile. Rappresenta l'analogo *continuo* del principio di indifferenza:

$$\text{Equiprobabilità discreta} \longleftrightarrow \text{Uniformità continua (Beta(1,1))}$$

3.5.4. Aggiornamento bayesiano: il modello Beta-Binomiale

Se partiamo da $\text{Beta}(\alpha, \beta)$ e osserviamo k successi su n prove, la nuova credenza (posteriore) è:


$$\theta \sim \text{Beta}(\alpha, \beta) \xrightarrow{\text{osserviamo } k \text{ su } n} \theta \mid k \sim \text{Beta}(\alpha + k, \beta + n - k).$$

I successi osservati si “aggiungono” ad α , gli insuccessi a β . L'aggiornamento è intuitivo: la conoscenza precedente si combina con i nuovi dati.

i Esempio: test a scelta multipla

Uno studente risponde a 20 domande a scelta multipla (4 opzioni). Adottiamo un prior Beta(1,3), che riflette l'ipotesi di risposte casuali (media = 0.25). Se osserva 7 risposte corrette, la posterior diventa Beta(8,16), con media $8/24 \approx 0.33$.

```
prior <- dbeta(theta, 1, 3)
posterior <- dbeta(theta, 8, 16)
df <- data.frame(
  theta = rep(theta, 2),
  Densita = c(prior, posterior),
  Tipo = rep(c("Prior Beta(1,3)", "Posterior Beta(8,16)"), each = 500)
)
ggplot(df, aes(x = theta, y = Densita, color = Tipo)) +
  geom_line(linewidth = 1.3) +
  geom_vline(xintercept = c(0.25, 0.33), linetype = "dashed", alpha = 0.5) +
  labs(title = "Aggiornamento bayesiano: prima e dopo 20 risposte",
       x = expression(theta ~ "(probabilità di risposta corretta)"),
       y = "Densità")
```



Intervallo di credibilità 95%:

```
alpha_post <- 8; beta_post <- 16
ci <- qbeta(c(0.025, 0.975), alpha_post, beta_post)
cat("Media posteriore:", round(alpha_post/(alpha_post + beta_post), 3), "\n")
#> Media posteriore: 0.333
cat("Intervallo 95%: [", round(ci[1], 2), ",", round(ci[2], 2), "]\n")
#> Intervallo 95%: [ 0.16 , 0.53 ]
```

L'intervallo [0.18, 0.52] esprime l'incertezza residua: siamo ragionevolmente sicuri che la probabilità vera si trovi lì, ma l'intervallo è ancora piuttosto ampio.

3.5.5. Aggiornamento sequenziale: la conoscenza si accumula


Una conseguenza pratica importante è che l'aggiornamento può avvenire **man mano che si osservano nuovi dati**, senza ricalcolare tutto da capo.

```
set.seed(42)
theta_vero <- 0.4
n_domande <- 20
risposte <- rbinom(n_domande, 1, theta_vero)
alpha <- 1; beta <- 3
theta_grid <- seq(0, 1, length.out = 200)
df_evol <- data.frame()
for(i in c(0, 5, 10, 20)) {
  if(i == 0) {
    dens <- dbeta(theta_grid, alpha, beta)
    label <- "Prior (n=0)"
  } else {
    a <- 1 + sum(risposte[1:i])
    b <- 3 + i - sum(risposte[1:i])
    dens <- dbeta(theta_grid, a, b)
    label <- paste0("n = ", i)
  }
}
```

```

}
df_evol <- rbind(df_evol, data.frame(
  theta = theta_grid, Densita = dens, n = label
))
}
ggplot(df_evol, aes(x = theta, y = Densita, color = n)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = theta_vero, linetype = "dashed") +
  annotate("text", x = theta_vero + 0.05, y = max(df_evol$Densita) * 0.9,
    label = expression(theta~"vero"), hjust = 0) +
  labs(title = "Evoluzione delle credenze all'accumularsi dei dati",
    x = expression(theta), y = "Densità", color = "Osservazioni")

```



La distribuzione si sposta gradualmente verso il valore vero ($\theta = 0.4$) e si restringe, riflettendo una crescente certezza.

3.6. Applicazioni psicologiche

Gli strumenti che abbiamo sviluppato trovano applicazione diretta in contesti psicologici concreti.

3.6.1. Item Response Theory (IRT)

La **teoria della risposta agli item** formalizza ciò che ogni insegnante sa intuitivamente: la probabilità di rispondere correttamente a una domanda dipende sia dallo studente che dalla domanda. Il modello base è:

$$P(\text{corretto} \mid \theta, b) = \frac{1}{1 + e^{-(\theta - b)}}$$

dove θ è l'abilità dello studente e b la difficoltà dell'item. Questa formulazione **rifiuta esplicitamente** l'equiprobabilità, riconoscendo che gli item hanno difficoltà diverse e che la probabilità di risposta corretta varia sistematicamente.

3.6.2. Bias di risposta nei questionari

Le risposte ai questionari sono influenzate da fenomeni sistematici come l'**acquiescenza** (tendenza a rispondere "sì"), la **desiderabilità sociale** o gli **effetti di posizione**. Questi bias significano che le opzioni di risposta non sono equiprobabili. Un modello adeguato deve esplicitare queste tendenze, distinguendo la variabilità dovuta al costrutto misurato da quella dovuta allo stile di risposta.

3.6.3. Efficacia degli interventi

Quando si valuta l'efficacia di un trattamento, l'equiprobabilità è particolarmente inappropriata. Non tutti i pazienti rispondono allo stesso modo. L'approccio bayesiano permette di:

1. iniziare con prior informativi basati su studi precedenti;
2. aggiornare progressivamente man mano che i dati si accumulano;
3. rappresentare esplicitamente la variabilità interindividuale;
4. quantificare l'incertezza in modo interpretabile.

Questo approccio produce stime che riconoscono la complessità del fenomeno, invece di nascerla sotto l'ipotesi di uniformità.

Riflessioni conclusive

Siamo partiti da una domanda apparentemente ingenua — “Quando possiamo dire che gli esiti sono ‘ugualmente probabili?’” — e abbiamo scoperto che la risposta ci porta al cuore dell'epistemologia della probabilità.

L'equiprobabilità non è un fatto del mondo. È una **scelta inferenziale** che riflette uno stato particolare di conoscenza: quello in cui non abbiamo ragioni per distinguere tra le varie possibilità. La formula “casi favorevoli su casi possibili” è una conseguenza di questa assunzione, non una legge universale.

Nella ricerca psicologica, l'equiprobabilità è quasi sempre violata. Questa variabilità non è un fastidio da eliminare: è spesso la *sostanza* stessa di ciò che studiamo. La distribuzione Beta ci offre un primo strumento per andare oltre, consentendo di rappresentare credenze con forme e intensità diverse.

Nel prossimo capitolo vedremo come la **probabilità condizionata** e il **teorema di Bayes** formalizzino il processo di apprendimento dall'esperienza — non solo quando partiamo dall'equiprobabilità, ma anche quando disponiamo di informazioni strutturate.

Punti chiave da ricordare

! Importante

1. **Principio di indifferenza:** l'equiprobabilità riflette simmetria epistemica, non una proprietà fisica. Assegniamo $P(\omega_i) = 1/n$ solo quando non abbiamo ragioni per preferire un esito.
2. **Formula classica come caso speciale:** $P(A) = |A|/|\Omega|$ è una *conseguenza* degli assiomi quando vale l'equiprobabilità, non una definizione universale.
3. **Tecniche combinatorie:**

i Informazioni sull'ambiente di sviluppo

3. Equiprobabilità e calcolo combinatorio

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] gtools_3.9.5      combinat_0.0-8      ragg_1.5.2
#> [4] tinytable_0.17.0  withr_3.0.3         systemfonts_1.3.2
#> [7] patchwork_1.3.2   ggdist_3.3.3        tidybayes_3.0.7
#> [10] bayesplot_1.15.0  ggplot2_4.0.3       reliabilitydiag_0.2.1
#> [13] priorsense_1.2.0  posterior_1.7.0     loo_2.10.0
#> [16] rstan_2.32.7      StanHeaders_2.32.10 brms_2.23.0
#> [19] Rcpp_1.1.2        sessioninfo_1.2.4   conflicted_1.2.0
#> [22] janitor_2.2.1     matrixStats_1.5.0   modelr_0.1.11
#> [25] tibble_3.3.1      dplyr_1.2.1         tidyr_1.3.2
#> [28] rio_1.3.0         here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8      tidyselect_1.2.1    farver_2.1.2
#> [4] S7_0.2.2          fastmap_1.2.0       tensorA_0.36.2.1
#> [7] pacman_0.5.1      digest_0.6.39       timechange_0.4.0
#> [10] estimability_2.0.0 lifecycle_1.0.5     magrittr_2.0.5
#> [13] compiler_4.6.1    rlang_1.3.0         tools_4.6.1
#> [16] yaml_2.3.12       knitr_1.51          labeling_0.4.3
#> [19] bridgesampling_1.2-1 pkgbuild_1.4.8      curl_7.1.0
#> [22] RColorBrewer_1.1-3 abind_1.4-8         purrr_1.2.2
#> [25] grid_4.6.1        stats4_4.6.1        xtable_1.8-8
#> [28] inline_0.3.21     emmeans_2.0.3       scales_1.4.0
#> [31] cli_3.6.6         mvtnorm_1.4-1       rmarkdown_2.31
#> [34] generics_0.1.4    otel_0.2.0          RcppParallel_5.1.11-2
#> [37] cachem_1.1.0      stringr_1.6.0       parallel_4.6.1
#> [40] vctrs_0.7.3       V8_8.2.0            Matrix_1.7-5
#> [43] jsonlite_2.0.0    arrayhelpers_1.1-1  glue_1.8.1
#> [46] codetools_0.2-20  distributional_0.8.1 lubridate_1.9.5
#> [49] stringi_1.8.7     gtable_0.3.6        QuickJSR_1.10.0
#> [52] pillar_1.11.1     htmltools_0.5.9     Brodningnag_1.2-9
#> [55] R6_2.6.1          textshaping_1.0.5   rprojroot_2.1.1
#> [58] evaluate_1.0.5    lattice_0.22-9      backports_1.5.1
#> [61] memoise_2.0.1     broom_1.0.13        snakecase_0.11.1
#> [64] rstantools_2.6.0  coda_0.19-4.1       gridExtra_2.3.1
#> [67] nlme_3.1-169      checkmate_2.3.4     xfun_0.60
#> [70] pkgconfig_2.0.3
```

4. Probabilità condizionata come aggiornamento

Introduzione

Immaginate di essere uno psicologo clinico che ha appena ricevuto l'esito positivo di un test diagnostico per un paziente. Prima della somministrazione, avevate formulato una stima della probabilità di depressione. Ora il referto è sul tavolo. Cosa è cambiato?

Tutto e niente. I fatti oggettivi restano immutati: il paziente era depresso, o non lo era, già prima che il test venisse eseguito. Ciò che è radicalmente mutato è il vostro stato di conoscenza. Avete acquisito un'informazione nuova che deve essere incorporata in modo coerente, ristrutturando sistematicamente la valutazione iniziale.

Questo processo dinamico di revisione razionale delle credenze alla luce dell'evidenza empirica costituisce l'essenza stessa del pensiero bayesiano. Lo strumento formale che lo incarna è la **probabilità condizionata**, il ponte matematico che collega le conoscenze precedenti a quelle successive all'osservazione.

In questo capitolo esploreremo la probabilità condizionata da diverse angolazioni:

- come **meccanismo di aggiornamento** epistemico;
- come **fondamento dell'indipendenza**;
- come **strumento per costruire modelli complessi**;
- come **protezione dagli errori** di aggregazione.

Questi concetti preparano direttamente il terreno per il teorema di Bayes che, nel prossimo capitolo, emergerà come la regola per "invertire" le probabilità condizionate.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 1
- Capitolo 2
- Capitolo 3

Conoscenze matematiche richieste:

- Appendice D - per operazioni su eventi (intersezione, unione);
- Appendice C - per la legge della probabilità totale.

Competenze pratiche:

- Familiarità con tabelle congiunte e rappresentazioni 2×2 ;
- Nozioni base di R per eseguire le simulazioni presentate.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()

# Load packages
if (!requireNamespace("pacman")) install.packages("pacman")
pacman::p_load(patchwork, ggforce)
# Riapplica il tema per sicurezza
apply_visual_theme()
```

4.1. Definizione e interpretazione epistemica

Partiamo da una credenza iniziale in un evento A . Poi apprendiamo che si è verificato un altro evento B . Come dovrebbe cambiare la nostra credenza in A ?

La risposta intuitiva è che dovremmo considerare solo le situazioni in cui B è vero e vedere quanto spesso A è vero *in quelle situazioni*. La formula seguente traduce esattamente questa intuizione in linguaggio matematico.

Definizione 4.1 (Probabilità condizionata). Se $P(B) > 0$, la *probabilità condizionata* di A dato B è definita come:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}. \quad (4.1)$$

Interpretazione epistemica: $P(A \mid B)$ quantifica il nostro grado di credenza in A dopo aver appreso che B è vero, tenendo conto del fatto che ora lo spazio delle possibilità si è ristretto a quelle compatibili con B .

4.1.1. Il meccanismo dell'aggiornamento

Apprendere che B è vero innesca un processo in due fasi:

- 1. Riduzione epistemica** — Lo spazio delle possibilità Ω viene ristretto al solo sottoinsieme B . Tutte le configurazioni in cui B è falso vengono eliminate, non perché siano diventate “impossibili” in senso metafisico, ma perché sono diventate *irrilevanti* per il nostro ragionamento.
- 2. Rinormalizzazione** — Le probabilità delle configurazioni rimanenti (quelle in cui B è vero) vengono riscalate in modo che tornino a sommare a 1. Il fattore di scala è esattamente $1/P(B)$.

Questo procedimento garantisce **coerenza**: se avessimo modellato fin dall'inizio un mondo in cui B è l'unica possibilità, avremmo ottenuto esattamente le stesse probabilità relative.

4.1.2. Un'analogia: lo zoom fotografico

Pensate alla distribuzione di probabilità congiunta come a una fotografia. La probabilità condizionata è come fare uno *zoom* su una porzione dell'immagine (la regione B):

- perdiamo di vista tutto ciò che sta fuori dalla regione (riduzione);
- i dettagli della regione riempiono ora tutto lo schermo (rinormalizzazione);
- i rapporti tra gli elementi *all'interno* della regione rimangono invariati.

```
# Visualizzazione grafica dell'aggiornamento
P_A <- 0.6
P_B <- 0.5
P_AB <- 0.35


P_A_given_B <- P_AB / P_B
P_Ac_given_B <- 1 - P_A_given_B

df <- data.frame(
  Parte = c("A B", "A^c B"),
  Valore = c(P_A_given_B, P_Ac_given_B)
)

ggplot(df, aes(x = "", y = Valore, fill = Parte)) +
  geom_col(width = 0.6) +
  coord_flip() +
  geom_text(aes(label = sprintf("%.2f", Valore)),
            position = position_stack(vjust = 0.5),
            color = "white", size = 5) +
  scale_fill_qualitative() +
  labs(
    title = "Probabilità condizionata: 'zoom' nello spazio B",
    subtitle = sprintf("P(A|B) = %.2f/%.2f = %.2f", P_AB, P_B, P_A_given_B),
    x = NULL, y = "Probabilità nel nuovo universo (B)"
  ) +
  theme(axis.text.y = element_blank(),
        panel.grid.major.y = element_blank(),
        legend.position = "bottom")
```

Probabilità condizionata: 'zoom' nello spazio B

$$P(A|B) = 0.35/0.50 = 0.70$$



4.1.3. Ogni probabilità è sempre condizionata

C'è un punto filosofico importante da cogliere: dal punto di vista bayesiano, **ogni probabilità è sempre condizionata**, anche quando non lo scriviamo esplicitamente.

Quando diciamo " $P(A) = 0.3$ ", in realtà intendiamo " $P(A | \mathcal{I}) = 0.3$ ", dove $\mathcal{I}$ rappresenta tutto ciò che sappiamo: dati precedenti, teoria, contesto e assunzioni. Non esistono probabilità assolute e prive di contesto.

Ciò significa che la notazione $P(A)$ è un'abbreviazione comoda, non una descrizione di una proprietà intrinseca del mondo.

4.2. Proprietà della probabilità condizionata

Un risultato importante è che le probabilità condizionate soddisfano tutti gli assiomi della probabilità. In altre parole, $P(\cdot | B)$ è essa stessa una funzione di probabilità legittima.

Teorema 4.1 (Proprietà della condizionata). *Fissato un evento B con $P(B) > 0$, la funzione $P(\cdot | B)$ soddisfa:*

1. **Non-negatività:** $P(A | B) \geq 0$ per ogni evento A .
2. **Normalizzazione:** $P(B | B) = 1$ (certezza di B dato B).
3. **Additività:** se A_1, A_2 sono disgiunti,

$$P(A_1 \cup A_2 | B) = P(A_1 | B) + P(A_2 | B).$$

4. **Complemento:** $P(A^c | B) = 1 - P(A | B)$.

5. **Regola della catena:**

$$P(A \cap B | C) = P(A | B \cap C) \cdot P(B | C).$$

Interpretazione epistemica: queste proprietà ci dicono che il ragionamento in condizioni di informazione parziale segue le stesse regole del ragionamento in condizioni di informazione completa. Non esistono “leggi speciali” per il condizionamento.

i Esempio clinico: test di screening per la depressione

Uno psicologo utilizza un test di screening per il disturbo depressivo maggiore in un contesto di comunità.

Informazioni disponibili:

- **prevalenza:** $P(D) = 0.08$;
- **sensibilità:** $P(T^+ | D) = 0.85$;
- **specificità:** $P(T^- | D^c) = 0.90$.

Costruzione della distribuzione congiunta

```
# Parametri epidemiologici
P_D <- 0.08
sens <- 0.85
spec <- 0.90

# Tassi di classificazione errata
fp_rate <- 1 - spec

# Probabilità congiunte
P_D_and_Tpos <- sens * P_D
P_D_and_Tneg <- (1 - sens) * P_D
P_Dc_and_Tpos <- fp_rate * (1 - P_D)
P_Dc_and_Tneg <- spec * (1 - P_D)

# Probabilità condizionate
P_Tpos <- P_D_and_Tpos + P_Dc_and_Tpos
P_Tneg <- P_D_and_Tneg + P_Dc_and_Tneg
P_D_given_Tpos <- P_D_and_Tpos / P_Tpos
P_D_given_Tneg <- P_D_and_Tneg / P_Tneg
```

Valore predittivo positivo (la domanda clinica cruciale):

$$P(D | T^+) = 0.43$$

Un test positivo indica depressione solo nel 42% dei casi — nonostante l’85% di sensibilità. La ragione è la bassa prevalenza: il 92% della popolazione non è depresso, e anche un tasso di falsi positivi del 10% produce molti falsi positivi in termini assoluti.

Valore predittivo negativo:


$$P(D^c | T^-) = 1 - P(D | T^-) = 0.986$$

Un test negativo è molto più informativo: riduce la probabilità di depressione a circa l’1%.

Visualizzazione dell’aggiornamento

Come cambia la credenza diagnostica con il test

L'aggiornamento dipende criticamente dalla prevalenza di base



La lezione epistemica: lo stesso test può essere molto informativo in un contesto ad alta prevalenza e quasi inutile in uno a bassa prevalenza. L'informazione fornita da un test dipende non solo dalle sue caratteristiche intrinseche, ma anche dal *contesto* in cui viene applicato.

4.3. Indipendenza stocastica

Abbiamo visto che la probabilità condizionata descrive come l'informazione su un evento modifichi le credenze su un altro. Ma cosa succede quando l'informazione *non modifica nulla*? Esiste cioè una situazione in cui apprendere che B si è verificato lascia inalterata la nostra credenza in A ?

La risposta è sì, e definisce il concetto di **indipendenza stocastica**.

Definizione 4.2 (Indipendenza (definizione epistemica)). Due eventi A e B sono detti **indipendenti** (notazione: $A \perp B$) se l'informazione che uno dei due si è verificato non modifica la credenza relativa all'altro:

$$P(A | B) = P(A),$$

e, in modo equivalente,

$$P(B | A) = P(B).$$

4.3.1. L'indipendenza è epistemica, non causale

È importante chiarire subito un potenziale fraintendimento. L'indipendenza stocastica è un concetto **epistemico**, non causale. Affermare che A e B sono indipendenti non significa che non esistano relazioni causali tra loro, ma che, **date le informazioni in nostro possesso**, sapere che uno si è verificato non fornisce alcuna informazione sull'altro.

Un esempio classico è il lancio di due monete equilibrate. Sapere che la prima è uscita testa non modifica la credenza che la seconda uscirà testa. Ma questo non è un fatto “della natura” — è una conseguenza del nostro stato informativo: sappiamo che i lanci sono fisicamente indipendenti e che

non esistono informazioni nascoste che li colleghino. Se sospettassimo che una delle monete sia truccata, l'indipendenza verrebbe meno, perché l'esito della prima lancerebbe un'ombra sull'affidabilità della seconda.

4.3.2. La fattorizzazione come conseguenza

Dalla definizione segue immediatamente una proprietà algebrica fondamentale:

$$P(A \cap B) = P(A) \cdot P(B). \quad (4.2)$$

Questa relazione è spesso presentata nei manuali come *definizione* di indipendenza, ma è più illuminante considerarla come una *conseguenza* della definizione epistemica. La fattorizzazione ci dice che la probabilità congiunta si “scompone” nel prodotto delle marginali: non c'è nulla nella distribuzione congiunta che non sia già catturato dalle marginali separate. L'informazione non scorre tra i due eventi.

Un errore comune: confondere disgiunzione e indipendenza

Due eventi **disgiunti** (mutualmente esclusivi) **non possono essere indipendenti**, a meno che uno dei due abbia probabilità zero.

Perché? Se $A \cap B = \emptyset$ e $P(A) > 0$, $P(B) > 0$, allora:

$$P(A \cap B) = 0, \quad \text{mentre} \quad P(A) \cdot P(B) > 0.$$

La fattorizzazione fallisce clamorosamente.

Interpretazione epistemica: eventi disgiunti sono *massimamente dipendenti*. Se so che si è verificato A , so con certezza che B non si è verificato. Non esiste informazione più forte di questa. L'indipendenza, al contrario, è l'assenza totale di informazione reciproca.

Esempio clinico: consideriamo due diagnosi mutualmente esclusive, come “Disturbo Bipolare” e “Schizofrenia”. Sapere che un paziente ha ricevuto la prima diagnosi fornisce un'informazione decisiva sulla seconda (non può averla, almeno in questo quadro nosologico). I due eventi sono quindi **profondamente dipendenti**, non indipendenti.

4.3.3. Un esempio: il test diagnostico

Torniamo al test diagnostico per la depressione discusso nella sezione precedente. Test e stato sono (fortunatamente!) dipendenti: un test che fosse indipendente dallo stato sarebbe clinicamente inutile.

Verifichiamolo numericamente:

```
# Parametri noti (dalla sezione precedente)
P_D <- 0.08
P_Tpos <- 0.216 # calcolato in precedenza
P_D_and_Tpos <- 0.068

# Se fossero indipendenti
P_D_indep <- P_D * P_Tpos

cat("P(D) × P(T+) =", round(P_D_indep, 4), "\n")
```

4. Probabilità condizionata come aggiornamento

```
#> P(D) × P(T+) = 0.0173
cat("P(D   T+) osservato =", round(P_D_and_Tpos, 4), "\n")
#> P(D   T+) osservato = 0.068
cat("Differenza:", round(P_D_and_Tpos - P_D_indep, 4), "\n")
#> Differenza: 0.0507
```

La differenza è sostanziale: $P(D \cap T^+) = 0.068$, mentre il prodotto delle marginali è $0.08 \times 0.216 \approx 0.017$. Il test e la depressione sono quindi **dipendenti** – proprio come ci aspettiamo da uno strumento diagnostico utile.

4.3.4. Il test di indipendenza nella pratica

Quando disponiamo di una tabella di probabilità congiunta, possiamo verificare l'indipendenza con un semplice confronto: calcoliamo la probabilità congiunta osservata $P(A \cap B)$ e la confrontiamo con il prodotto delle marginali $P(A) \cdot P(B)$. Se coincidono (o sono molto vicine, nel caso di stime empiriche), gli eventi sono indipendenti. In caso contrario, c'è informazione reciproca.

Nella pratica psicologica, tuttavia, è importante ricordare che l'indipendenza è spesso un'**assunzione**, non un dato di fatto. Quando costruiamo modelli statistici, assumiamo indipendenza tra osservazioni, tra item di un test o tra errori di misurazione. Tali assunzioni vanno giustificate teoricamente e verificate empiricamente, perché la loro violazione può portare a stime distorte e a conclusioni errate. L'indipendenza è uno strumento potente, ma va maneggiato con la consapevolezza che, nei fenomeni psicologici, la dipendenza è spesso la regola, non l'eccezione.

4.4. Teorema del prodotto (regola della catena)

Il **teorema del prodotto** ci permette di costruire probabilità congiunte a partire da componenti più semplici.

Teorema 4.2 (Teorema del prodotto). *Per due eventi A e B con $P(B) > 0$:*

$$P(A \cap B) = P(A \mid B) \cdot P(B).$$

Per simmetria:

$$P(A \cap B) = P(B \mid A) \cdot P(A).$$

4.4.1. Interpretazione sequenziale

Il teorema ci dice che la probabilità congiunta può essere pensata come un processo *sequenziale*:

1. valutiamo la probabilità che B sia vero: $P(B)$;
2. valutiamo la probabilità che A sia vero *dato che* B è vero: $P(A \mid B)$;
3. la probabilità che *entrambi* siano veri è il prodotto.

Questa scomposizione riflette un modo naturale di costruire modelli complessi.

4.4.2. La regola della catena: generalizzazione

Il teorema si estende a sequenze di eventi:

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2 | A_1) \cdot P(A_3 | A_1 \cap A_2) \dots P(A_n | A_1 \cap \dots \cap A_{n-1}).$$

Ogni fattore condiziona su tutto ciò che “viene prima”. È il modo in cui funziona l’aggiornamento sequenziale delle credenze.

4.5. Legge della probabilità totale

La **legge della probabilità totale** risponde a una domanda frequente: come calcolare la probabilità di un evento che può verificarsi attraverso *scenari alternativi*?

Teorema 4.3 (Legge della probabilità totale). Sia $\{B_1, B_2, \dots, B_n\}$ una **partizione** di Ω (eventi mutuamente esclusivi e collettivamente esaustivi). Allora:

$$P(A) = \sum_{i=1}^n P(A | B_i)P(B_i).$$

4.5.1. Interpretazione epistemica

La formula racchiude un principio di ragionamento universale: **la probabilità totale si ottiene considerando tutti i modi alternativi in cui l’evento può verificarsi.**

- $P(A | B_i)$: “Se ci troviamo nello scenario B_i , quanto è probabile A ?”;
- $P(B_i)$: “Qual è la probabilità che ci si trovi proprio nello scenario B_i ?”.

È il modo matematicamente corretto di “fare un passo indietro” quando la risposta diretta è “Dipende dal contesto”.

4.5.2. Applicazione: trattare popolazioni eterogenee

In contesti reali, i pazienti provengono spesso da sottopopolazioni con rischi di base molto diversi. Immaginiamo un test per la depressione somministrato a due gruppi:

Fonte del Paziente	Proporzione	Prevalenza
Clinica Specialistica	30%	40%
Popolazione Generale	70%	5%

Test: sensibilità = 0.85, specificità = 0.90.

Calcolo del tasso di positività in ogni sottogruppo:

- Clinica specialistica: $0.85 \times 0.40 + 0.10 \times 0.60 = 0.40$
- Popolazione generale: $0.85 \times 0.05 + 0.10 \times 0.95 = 0.1375$

Tasso complessivo (legge della probabilità totale):

$$P(T^+) = 0.40 \times 0.30 + 0.1375 \times 0.70 \approx 0.216$$

Implicazione clinica: un test positivo in una clinica specialistica (tasso 40%) ha un significato predittivo molto diverso rispetto a un test positivo nella popolazione generale (tasso 13.75%). La prevalenza è parte integrante del risultato.

4.6. Paradosso di Simpson

Il **paradosso di Simpson** è uno degli esempi più istruttivi di come un'aggregazione ingenua possa condurre a conclusioni opposte rispetto a quelle valide a livello disaggregato.

4.6.1. Il fenomeno

Il paradosso si manifesta quando una relazione statistica osservata tra due variabili **si inverte** una volta che i dati vengono analizzati separatamente all'interno di sottogruppi rilevanti.

i Esempio: efficacia di un trattamento per la depressione

Due cliniche valutano un trattamento. La clinica A tratta casi lievi, la B casi gravi.

```
# Clinica A (casi lievi)
n_A_trattati <- 90
n_A_guariti_trattati <- 81
n_A_controllo <- 10
n_A_guariti_controllo <- 9

# Clinica B (casi gravi)
n_B_trattati <- 10
n_B_guariti_trattati <- 2
n_B_controllo <- 90
n_B_guariti_controllo <- 27

# Proporzioni per clinica
prop_A_trattati <- n_A_guariti_trattati / n_A_trattati
prop_A_controllo <- n_A_guariti_controllo / n_A_controllo
prop_B_trattati <- n_B_guariti_trattati / n_B_trattati
prop_B_controllo <- n_B_guariti_controllo / n_B_controllo

# Aggregato
n_tot_trattati <- n_A_trattati + n_B_trattati
n_tot_guariti_trattati <- n_A_guariti_trattati + n_B_guariti_trattati
n_tot_controllo <- n_A_controllo + n_B_controllo
n_tot_guariti_controllo <- n_A_guariti_controllo + n_B_guariti_controllo

prop_tot_trattati <- n_tot_guariti_trattati / n_tot_trattati
prop_tot_controllo <- n_tot_guariti_controllo / n_tot_controllo
```

Risultati per sottogruppo:

- Clinica A: trattati 90%, controllo 90% → nessuna differenza.
- Clinica B: trattati 20%, controllo 30% → trattamento *peggiore*.

In **nessun sottogruppo** il trattamento risulta superiore.


Risultato aggregato:

- Trattati: 83%.
- Controllo: 36%.

Nell'analisi aggregata, il trattamento appare **nettamente migliore!**

Paradosso di Simpson: inversione dell'efficacia

Ogni clinica mostra un effetto nullo o negativo, ma l'aggregato suggerisce l'opposto

**4.6.2. Cosa sta succedendo?**

La chiave è la **distribuzione diseguale dei casi**:

- la clinica B (casi gravi, bassa guarigione) contribuisce di più al gruppo *trattato*;
- la clinica A (casi lievi, alta guarigione) contribuisce di più al gruppo *di controllo*.

La variabile *gravità* agisce da **confondente**: influenza sia la probabilità di ricevere il trattamento sia l'esito. L'aggregazione ignora questa struttura.

4.6.3. La lezione epistemica

L'errore consiste nel rispondere alla **domanda sbagliata**. Non stiamo stimando $P(\text{Guarigione} \mid \text{Trattamento})$, ma una combinazione implicita di probabilità condizionate diverse. La domanda corretta è:

$$P(\text{Guarigione} \mid \text{Trattamento}, \text{Gravità}).$$

Quando è legittimo aggregare? Solo quando:

1. non esistono confondenti rilevanti;
2. i confondenti sono distribuiti uniformemente;
3. l'obiettivo è esplicitamente marginale (e non condizionato).

Riflessioni conclusive

Siamo partiti da una domanda apparentemente semplice — come cambiano le nostre credenze quando apprendiamo qualcosa di nuovo? — e abbiamo scoperto che la risposta richiede un intero apparato concettuale.

4.6.1. Cosa abbiamo imparato

La **probabilità condizionata** è il meccanismo fondamentale attraverso cui l'informazione si trasforma in conoscenza. Ogni volta che aggiorniamo le nostre credenze, stiamo implicitamente applicando le regole che abbiamo studiato.

L'**indipendenza** rappresenta il caso limite in cui l'informazione non fluisce. Riconoscere quando questa condizione è soddisfatta è cruciale per costruire modelli corretti.

Il **teorema del prodotto** ci ha mostrato come costruire credenze complesse a partire da componenti più semplici, scomponendo la probabilità congiunta in una sequenza di aggiornamenti.

La **legge della probabilità totale** ci ha insegnato a ragionare su scenari alternativi combinando le probabilità di ciascuno di essi in una media ponderata.

Il **paradosso di Simpson** ci ha messo in guardia sui pericoli dell'aggregazione incauta, mostrando come conclusioni apparentemente solide possano essere ribaltate quando si svela la struttura nascosta dei dati.

4.6.2. Verso il teorema di Bayes

Tutti questi strumenti preparano il terreno per il passo successivo. Abbiamo visto come calcolare $P(A | B)$, ovvero la probabilità di A sapendo che si verifica B . Spesso, però, la domanda che ci interessa è l'inversa: abbiamo osservato un effetto e vogliamo risalire alla causa.

Nel prossimo capitolo, il **teorema di Bayes** emergerà come la regola per questa “inversione”: passeremo da $P(\text{Dati} | \text{Ipotesi})$ a $P(\text{Ipotesi} | \text{Dati})$, il cuore dell'inferenza scientifica.

Punti chiave da ricordare

! Importante

1. Probabilità condizionata come aggiornamento epistemico

- $P(A | B)$ quantifica la credenza in A dopo aver appreso B .
- Meccanismo: riduzione dello spazio + rinormalizzazione.
- Ogni probabilità è sempre condizionata a uno sfondo informativo: $P(A) = P(A | \mathcal{I})$.

2. Indipendenza come assenza di informazione

- $A \perp B \iff P(A | B) = P(A)$.
- Equivalentemente: $P(A \cap B) = P(A) \cdot P(B)$.
- Eventi disgiunti NON sono indipendenti (hanno informazione reciproca massima).

3. Teorema del prodotto

- $P(A \cap B) = P(A | B) \cdot P(B) = P(B | A) \cdot P(A)$.
- Generalizzazione: regola della catena per sequenze di eventi.

4. Legge della probabilità totale

- $P(A) = \sum_i P(A | B_i)P(B_i)$ per partizione $\{B_i\}$.
- Fondamentale per ragionare su scenari alternativi.

5. Paradosso di Simpson

- Trend aggregati possono invertirsi rispetto a trend stratificati.
- Avvertimento: condiziona sui confondenti!

Formule da ricordare:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A \cap B) = P(A | B) \cdot P(B) = P(B | A) \cdot P(A)$$

$$P(A) = \sum_{i=1}^n P(A | B_i)P(B_i)$$

Per il prossimo capitolo:

Nel Capitolo 5 vedremo come il teorema di Bayes permetta di **invertire** le probabilità condizionate, passando da $P(\text{Dati} | \text{Ipotesi})$ a $P(\text{Ipotesi} | \text{Dati})$.

Esercizi

! Problemi

Esercizi concettuali

1. Spiega perché “ogni probabilità è condizionata” da una prospettiva bayesiana. Cosa significa $P(A)$ implicitamente?
2. La formula $P(A | B) = P(A \cap B)/P(B)$ può sembrare circolare. Spiega perché non lo è, e in quale ordine concettuale pensiamo queste quantità.
3. Quando due eventi sono disgiunti, possono essere indipendenti? Perché o perché no?
4. Il teorema del prodotto dice $P(A \cap B) = P(A | B)P(B)$. Questo è simmetrico? Cioè, posso scrivere $P(A \cap B) = P(B | A)P(A)$? Cosa implica questa simmetria?
5. Il paradosso di Simpson dimostra che l’aggregazione è sempre sbagliata? Quando è legittimo aggregare dati?

Esercizi su probabilità condizionata

6. Data una tabella congiunta:

	B	B^c							
A	0.20	0.30		A^c	0.15	0.35			

 Calcola:
 - a. $P(A | B)$

- b. $P(B \mid A)$
 - c. $P(A \mid B^c)$
 - d. Gli eventi sono indipendenti?
7. $P(A) = 0.6$, $P(B) = 0.5$, $P(A \mid B) = 0.7$. Calcola:
- a. $P(A \cap B)$
 - b. $P(B \mid A)$
 - c. $P(A \cup B)$
8. Test diagnostico: $P(M) = 0.01$, $\text{sens} = 0.95$, $\text{spec} = 0.98$.
- a. Costruisci tabella congiunta
 - b. Calcola VPP e VPN
 - c. Quanto deve essere alta la sensibilità per avere $\text{VPP} > 0.9$?

Esercizi sull'indipendenza

9. Un dado viene lanciato. Siano:
- $A = \text{"Esce numero pari"}$
 - $B = \text{"Esce numero } \leq 3 \text{"}$
- a. A e B sono indipendenti?
 - b. Calcola $P(A \mid B)$ e confronta con $P(A)$
10. Due monete equilibrate vengono lanciate. Siano:
- $A = \text{"Prima moneta è testa"}$
 - $B = \text{"Almeno una testa"}$
- a. Costruisci tabella congiunta
 - b. Calcola $P(A \mid B)$
 - c. A e B sono indipendenti?
11. In una popolazione, $P(\text{Depressione}) = 0.15$ e $P(\text{Insonnia}) = 0.25$. Se fossero indipendenti, quanto sarebbe $P(\text{Depressione} \cap \text{Insonnia})$? È plausibile l'indipendenza?

Esercizi sul teorema del prodotto

12. $P(A) = 0.5$, $P(B \mid A) = 0.6$, $P(C \mid A \cap B) = 0.7$. Calcola $P(A \cap B \cap C)$.
13. Tre test sequenziali per ansia, ciascuno con $\text{sens} = 0.80$ (indipendenti dato stato). $P(\text{Ansia}) = 0.20$. Calcola $P(\text{Ansia} \cap T_1^+ \cap T_2^+ \cap T_3^+)$.
14. Usa la regola del prodotto per dimostrare che se A e B sono indipendenti, allora A e B^c sono indipendenti.

Esercizi sulla probabilità totale

15. Una clinica riceve pazienti da due fonti:
- 60% da medico di base (prevalenza depressione = 10%)
 - 40% da pronto soccorso (prevalenza depressione = 30%)

Qual è la prevalenza complessiva nella clinica?

16. Un questionario ha due versioni (A e B), distribuite casualmente (50% ciascuna). La versione A è più facile:

- $P(\text{punteggio} > 20 \mid \text{Versione A}) = 0.7$
- $P(\text{punteggio} > 20 \mid \text{Versione B}) = 0.4$

Qual è $P(\text{punteggio} > 20)$ complessivamente?

17. Dimostra che $P(A) = P(A \mid B)P(B) + P(A \mid B^c)P(B^c)$ usando la legge della probabilità totale con partizione $\{B, B^c\}$.

Esercizi sul Paradosso di Simpson

18. Considera questi dati su un farmaco antidepressivo:

Pazienti giovani (N=200):

- Farmaco: 70/100 migliorati (70%)
- Placebo: 50/100 migliorati (50%)

Pazienti anziani (N=200):

- Farmaco: 60/100 migliorati (60%)
- Placebo: 40/100 migliorati (40%)

- In ciascun gruppo, il farmaco è migliore?
- Calcola le proporzioni aggregate (tutti i pazienti insieme)
- Costruisci uno scenario dove l'aggregato inverte la tendenza

19. Spiega in termini epistemici perché il paradosso di Simpson non è veramente un "paradosso" ma un avvertimento sull'importanza di condizionare correttamente.

Esercizi applicati

20. **Test per disturbo d'ansia sociale:**

- Prevalenza in popolazione universitaria: 5%
 - Sensibilità: 85%
 - Specificità: 92%
- Costruisci tabella congiunta completa
 - Uno studente risulta positivo. Qual è la probabilità che abbia davvero il disturbo?
 - Quale prevalenza minima serve per avere $VPP > 0.5$?

21. **Comorbidità PTSD e Depressione:**

- In un campione clinico: $P(\text{PTSD}) = 0.30$, $P(\text{Depressione}) = 0.45$
- Osservi che $P(\text{Depressione} \mid \text{PTSD}) = 0.70$

- Calcola $P(\text{PTSD} \cap \text{Depressione})$
- Calcola $P(\text{PTSD} \mid \text{Depressione})$
- Sono indipendenti? Commenta il risultato clinicamente

22. **Due test per ADHD in un bambino:**

- Prior: $P(\text{ADHD}) = 0.08$ (popolazione generale)
- Test comportamentale: positivo (sens=0.80, spec=0.90)
- Test cognitivo: positivo (sens=0.75, spec=0.85)
- Assumendo indipendenza condizionale:

- a. Calcola $P(\text{ADHD} \mid T_1^+)$ dopo primo test
- b. Calcola $P(\text{ADHD} \mid T_1^+, T_2^+)$ dopo entrambi i test
- c. Visualizza l'aggiornamento sequenziale delle credenze

Esercizi computazionali

23. Scrivi una funzione R che:
 - Input: tabella congiunta 2×2
 - Output: tutte le probabilità condizionate possibili e test di indipendenza
24. Simula il paradosso di Simpson:
 - Genera dati per due gruppi con trend positivo in ciascuno
 - Aggrega i dati mostrando inversione del trend
 - Visualizza con ggplot
25. Crea una visualizzazione interattiva (o animazione) che mostra come $P(A \mid B)$ varia al variare della “forza” dell’associazione tra A e B (da indipendenza a dipendenza totale).

Soluzioni selezionate

Soluzioni degli esercizi concettuali

1. Da prospettiva bayesiana, ogni probabilità riflette uno stato di informazione. Scrivere $P(A)$ è abbreviazione per $P(A \mid \mathcal{I})$ dove $\mathcal{I}$ è “tutto ciò che sappiamo”. Non esistono probabilità “incondizionate”—solo probabilità condizionate allo sfondo informativo corrente.
2. Non è circolare perché concettualmente partiamo dalla **tabella congiunta** $P(A \cap B)$ (rappresentazione completa del nostro stato di credenza), poi **deriviamo** le condizionate come rapporti. La formula ci dice *come calcolare* condizionate da congiunte, non *come definire* le congiunte.
3. No (a meno che uno abbia probabilità zero). Eventi disgiunti hanno informazione reciproca **massima**: sapere che uno è vero implica certezza che l’altro è falso. Indipendenza richiede *assenza* di informazione.
4. Sì, è simmetrico: $P(A \cap B) = P(A \mid B)P(B) = P(B \mid A)P(A)$. Questa simmetria è il cuore del teorema di Bayes! Mostra che la congiunta può essere costruita in due modi equivalenti.
5. No, l’aggregazione è legittima quando non c’è confondente rilevante, o quando la confondente è distribuita uniformemente. Il paradosso avverte: *esplicita le tue assunzioni di omogeneità prima di aggregare*.

Soluzioni degli esercizi sulla probabilità condizionata

6.
 - a. $P(A \mid B) = 0.20 / (0.20 + 0.15) = 0.571$
 - b. $P(B \mid A) = 0.20 / (0.20 + 0.30) = 0.400$
 - c. $P(A \mid B^c) = 0.30 / (0.30 + 0.35) = 0.462$
 - d. Test: $P(A) = 0.50$, $P(B) = 0.35$, $P(A)P(B) = 0.175 \neq P(A \cap B) = 0.20$. NON indipendenti.
7.
 - a. $P(A \cap B) = P(A \mid B)P(B) = 0.7 \times 0.5 = 0.35$

- b. $P(B | A) = P(A \cap B) / P(A) = 0.35 / 0.6 \approx 0.583$
 c. $P(A \cup B) = 0.6 + 0.5 - 0.35 = 0.75$
 8. a. Tabella: $P(M \cap T^+) = 0.0095$, $P(M \cap T^-) = 0.0005$, etc.
 b. $VPP = 0.0095 / (0.0095 + 0.0198) \approx 0.324$; $VPN \approx 0.9995$
 c. Per $VPP > 0.9$: serve sens ≈ 0.998 (quasi perfetta con prevalenza così bassa!)

Soluzioni degli esercizi sull'indipendenza

9. a. $P(A) = 1/2$, $P(B) = 1/2$, $P(A \cap B) = P(\{2\}) = 1/6$ $P(A)P(B) = 1/4 \neq 1/6$.
 NON indipendenti.
 b. $P(A | B) = (1/6) / (1/2) = 1/3 \neq 1/2 = P(A)$
 10. Spazio: {TT, TC, CT, CC}, equiprobabili.
 a. Tabella con $A = \{TT, TC\}$, $B = \{TT, TC, CT\}$
 b. $P(A | B) = P(\{TT, TC\}) / P(B) = (1/2) / (3/4) = 2/3$
 c. $P(A) = 1/2 \neq 2/3 = P(A | B)$. NON indipendenti.
 11. Se indipendenti: $P(D \cap I) = 0.15 \times 0.25 = 0.0375$. Ma clinicamente sappiamo che depressione e insonnia sono altamente correlate, quindi l'indipendenza è **implausibile**.

Soluzioni degli esercizi sul teorema del prodotto

12. $P(A \cap B \cap C) = P(C | A \cap B) \cdot P(B | A) \cdot P(A) = 0.7 \times 0.6 \times 0.5 = 0.21$
 13. $P(\text{Ansia} \cap \text{tutti} +) = 0.80^3 \times 0.20 = 0.512 \times 0.20 = 0.1024$
 14. Dimostrazione:

$$\begin{aligned}
 P(A \cap B^c) &= P(A) - P(A \cap B) && [\text{additività}] \\
 &= P(A) - P(A)P(B) && [\text{indipendenza } A, B] \\
 &= P(A)(1 - P(B)) \\
 &= P(A)P(B^c) && [\text{quindi } A \cap B^c]
 \end{aligned}$$

Soluzioni degli esercizi sulla probabilità totale

15. $P(D) = 0.10 \times 0.60 + 0.30 \times 0.40 = 0.06 + 0.12 = 0.18$ (18%)
 16. $P(> 20) = 0.7 \times 0.5 + 0.4 \times 0.5 = 0.35 + 0.20 = 0.55$

Soluzioni degli esercizi sulle applicazioni psicologiche

20. a. $P(A \cap T^+) = 0.85 \times 0.05 = 0.0425$, etc.
 b. $VPP = 0.0425 / (0.0425 + 0.076) = 0.359$ (solo 36%)
 c. Per $VPP > 0.5$, serve prev ≥ 0.10 (10%)
 21. a. $P(P \cap D) = P(D | P) \times P(P) = 0.70 \times 0.30 = 0.21$
 b. $P(P | D) = 0.21 / 0.45 \approx 0.467$
 c. Se indipendenti: $P(P)P(D) = 0.30 \times 0.45 = 0.135 \neq 0.21$. DIPENDENTI (comorbidità alta, clinicamente attesa)

4. Probabilità condizionata come aggiornamento

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ggforce_0.5.0      ragg_1.5.2          tinytable_0.17.0
#> [4] withr_3.0.3        systemfonts_1.3.2   patchwork_1.3.2
#> [7] ggdist_3.3.3       tidybayes_3.0.7     bayesplot_1.15.0
#> [10] ggplot2_4.0.3      reliabilitydiag_0.2.1 priorsense_1.2.0
#> [13] posterior_1.7.0     loo_2.10.0          rstan_2.32.7
#> [16] StanHeaders_2.32.10 brms_2.23.0         Rcpp_1.1.2
#> [19] sessioninfo_1.2.4   conflicted_1.2.0     janitor_2.2.1
#> [22] matrixStats_1.5.0   modelr_0.1.11        tibble_3.3.1
#> [25] dplyr_1.2.1         tidyr_1.3.2          rio_1.3.0
#> [28] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidysselect_1.2.1    farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0        tensorA_0.36.2.1
#> [7] tweenr_2.0.3        pacman_0.5.1         digest_0.6.39
#> [10] timechange_0.4.0    estimability_2.0.0   lifecycle_1.0.5
#> [13] magrittr_2.0.5      compiler_4.6.1       rlang_1.3.0
#> [16] tools_4.6.1         yaml_2.3.12          knitr_1.51
#> [19] labeling_0.4.3      bridgesampling_1.2-1 pkgbuild_1.4.8
#> [22] curl_7.1.0          RColorBrewer_1.1-3   abind_1.4-8
#> [25] purrr_1.2.2         polyclip_1.10-7      grid_4.6.1
#> [28] stats4_4.6.1        xtable_1.8-8         inline_0.3.21
#> [31] MASS_7.3-65         emmeans_2.0.3        scales_1.4.0
#> [34] cli_3.6.6           mvtnorm_1.4-1        rmarkdown_2.31
#> [37] generics_0.1.4      otel_0.2.0           RcppParallel_5.1.11-2
#> [40] cachem_1.1.0        stringr_1.6.0        parallel_4.6.1
#> [43] vctrs_0.7.3         V8_8.2.0             Matrix_1.7-5
#> [46] jsonlite_2.0.0      arrayhelpers_1.1-1    glue_1.8.1
#> [49] codetools_0.2-20    distributional_0.8.1 lubridate_1.9.5
#> [52] stringi_1.8.7       gtable_0.3.6         QuickJSR_1.10.0
#> [55] pillar_1.11.1       htmltools_0.5.9      Brodningnag_1.2-9
#> [58] R6_2.6.1            textshaping_1.0.5    rprojroot_2.1.1
#> [61] evaluate_1.0.5      lattice_0.22-9        backports_1.5.1
#> [64] memoise_2.0.1       broom_1.0.13         snakecase_0.11.1
#> [67] rstantools_2.6.0    coda_0.19-4.1        gridExtra_2.3.1
#> [70] nlme_3.1-169        checkmate_2.3.4      xfun_0.60
#> [73] pkgconfig_2.0.3

```

5. Il teorema di Bayes

Introduzione

Il **teorema di Bayes** rappresenta il punto di arrivo naturale del percorso concettuale sviluppato nei capitoli precedenti. Dopo aver interpretato la probabilità come *grado di credenza razionale* (Capitolo 1), chiarito il ruolo degli assiomi come vincoli di coerenza (Capitolo 2), riconosciuto l'equiprobabilità come caso particolare di simmetria epistemica (Capitolo 3) e identificato la probabilità condizionata come meccanismo generale di aggiornamento delle credenze (Capitolo 4), il teorema di Bayes emerge come la **formalizzazione matematica dell'apprendimento dall'esperienza**.

Prima di introdurre la formula, è tuttavia essenziale comprendere il problema concettuale che essa è chiamata a risolvere.

Il problema fondamentale della conoscenza

Immaginiamo di essere uno psicologo clinico. Un paziente si presenta con sintomi che potrebbero indicare depressione, ma che potrebbero anche essere spiegati da altre condizioni: stress lavorativo, disturbi del sonno o una fase di vita particolarmente difficile. Si decide di somministrare un test di screening e il risultato è positivo.

Che cosa sappiamo ora che non sapevamo prima?

La risposta intuitiva potrebbe essere: *“Ora so che il paziente è probabilmente depresso.”*

Ma questa conclusione è prematura. Il test, infatti, non fornisce direttamente questa informazione. Ci dice invece qualcosa di diverso: **quanto è probabile osservare un risultato positivo se il paziente fosse depresso**. Se la sensibilità del test è, ad esempio, dell'85%, ciò significa che l'85% delle persone depresse ottiene un risultato positivo.

Tuttavia, la domanda che realmente interessa il clinico è un'altra: quanto è probabile che **questa persona specifica**, che ha appena ottenuto un risultato positivo, sia *effettivamente* depressa?

Queste due domande, apparentemente simili, sono in realtà profondamente diverse.

L'asimmetria tra predizione e inferenza

L'esempio mette in luce una **asimmetria fondamentale del ragionamento scientifico**:

- la **predizione** (dalla causa all'effetto): *“Se il paziente è depresso, quanto è probabile che il test risulti positivo?”*;
- l'**inferenza** (dall'effetto alla causa): *“Dato che il test è positivo, quanto è probabile che il paziente sia depresso?”*.

I modelli scientifici sono quasi sempre costruiti nella direzione predittiva. Conosciamo il funzionamento dei test diagnostici: la loro sensibilità (capacità di individuare i casi positivi) e la loro specificità (capacità di escludere i casi negativi). Tuttavia, l'informazione che riceviamo dal mondo empirico procede nella direzione opposta: osserviamo **esiti**, non **stati latenti**.

Il teorema di Bayes è precisamente lo strumento che consente di **collegare queste due direzioni**. Esso permette di trasformare una conoscenza predittiva, ovvero *quanto sarebbe probabile osservare questo risultato se un'ipotesi fosse vera*, in una conoscenza inferenziale, ovvero *quanto è probabile che l'ipotesi sia vera, dato il risultato osservato*.

Perché questo è il cuore della scienza

Questa “inversione” non è un dettaglio tecnico. È l'essenza stessa del metodo scientifico.

Ogni esperimento produce dati. Ma i dati, da soli, non “parlano”. Non ci dicono direttamente quali ipotesi siano vere. Ci dicono soltanto quanto sarebbero attesi sotto diverse ipotesi. Il passaggio dai dati alle ipotesi, cioè l'inferenza, richiede un'operazione logica che il teorema di Bayes formalizza in modo preciso e coerente.

Nella ricerca psicologica questo problema si presenta continuamente:

- un questionario di personalità produce un certo punteggio: che cosa ci dice sul tratto latente sottostante?
- un esperimento mostra una differenza tra gruppi: quanto è plausibile che esista un effetto reale?
- un paziente risponde in un certo modo a un trattamento: in che misura possiamo generalizzare ad altri pazienti simili?

In ciascun caso, osserviamo dati e vogliamo trarre conclusioni su qualcosa che non osserviamo direttamente, ovvero parametri, ipotesi, stati latenti. Il teorema di Bayes fornisce una risposta a questa esigenza fondamentale: ci dice come integrare in modo razionalmente coerente le nuove informazioni con ciò che già sappiamo.

In questo senso, il teorema di Bayes non è soltanto una formula, ma una regola generale del ragionamento in condizioni di incertezza.

Il percorso del capitolo

In questo capitolo:

1. **Deriveremo** il teorema dalla simmetria della probabilità congiunta, mostrando che non è una nuova assunzione ma una conseguenza inevitabile di ciò che abbiamo già stabilito.
2. **Interpreteremo** ciascuna componente, ovvero prior, verosimiglianza, evidenza, posterior, dal punto di vista epistemico.
3. **Esploreremo** la forma in odds, particolarmente utile per applicazioni diagnostiche e per comprendere come le evidenze si accumulano.
4. **Applicheremo** il teorema a scenari clinici e di ricerca, mostrando sia il suo potere sia le insidie del ragionamento probabilistico.
5. **Estenderemo** l'aggiornamento bayesiano al caso di parametri continui, introducendo il modello Beta-Binomiale.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 1
- Capitolo 2
- Capitolo 3
- Capitolo 4 – **fondamentale**

Conoscenze matematiche richieste:

- Appendice D - per operazioni su eventi;
- Appendice C - per legge della probabilità totale.

Lecture complementari consigliate:

- Chivers, T. (2024). *Everything is Predictable: How Bayesian Statistics Explain Our World* (Chivers, 2024), per una prospettiva divulgativa sul ragionamento bayesiano

Panoramica del capitolo

- Derivazione del teorema dalla simmetria della probabilità congiunta.
- Interpretazione epistemica delle componenti: prior, likelihood, posterior.
- Probabilità inversa come problema fondamentale dell'inferenza.
- Forma in odds e rapporti di verosimiglianza per applicazioni cliniche.
- Applicazioni a test diagnostici e valutazione della comorbidità.
- Fallacia del tasso base e sue implicazioni per il ragionamento clinico.
- Aggiornamento bayesiano con distribuzioni Beta.
- Intervalli di credibilità e loro interpretazione epistemica.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

5.1. La simmetria fondamentale della probabilità congiunta

Il **teorema di Bayes** non introduce nuovi principi probabilistici, ma emerge come una conseguenza algebrica inevitabile della definizione di probabilità condizionata. Questa derivazione mostra che l'aggiornamento bayesiano delle credenze non è una scelta arbitraria, bensì una **necessità logica** per chiunque accetti il quadro assiomatico della teoria della probabilità.

5.1.1. L'uguaglianza che genera tutto

Ricordiamo dal capitolo precedente che la probabilità congiunta può essere scritta in due modi equivalenti:

$$P(A \cap B) = P(A | B) \cdot P(B) = P(B | A) \cdot P(A). \quad (5.1)$$

Questa uguaglianza esprime un fatto profondo: la probabilità congiunta è una struttura *simmetrica*. Non “appartiene” né ad A né a B : è una proprietà della loro relazione. Possiamo “scomporla” partendo da A o partendo da B , e otteniamo lo stesso risultato.

Ma se le due espressioni sono uguali, possiamo uguagliarle e risolvere per una delle probabilità condizionate:

$$P(A | B) \cdot P(B) = P(B | A) \cdot P(A)$$

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}.$$

Questo è il teorema di Bayes. Non abbiamo introdotto nulla di nuovo: abbiamo solo riorganizzato le stesse informazioni.

Teorema 5.1 (Teorema di Bayes (forma fondamentale)). *Per eventi A e B con $P(B) > 0$ vale:*

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}. \quad (5.2)$$

5.1.2. Perché questo è importante

La formula sembra semplice e lo è, dal punto di vista algebrico. Tuttavia, la sua importanza risiede in ciò *che permette di fare*: trasformare una probabilità condizionata in un'altra con l'ordine del condizionamento invertito.

Conosciamo $P(B | A)$, ovvero la probabilità di osservare B se A è vero. Ora vogliamo conoscere $P(A | B)$, ovvero quanto è probabile che A sia vero, dato che abbiamo osservato B . Il teorema ci dice esattamente come effettuare questa trasformazione.

Questa inversione non è gratuita: richiede di specificare $P(A)$ e $P(B)$. Vedremo a breve cosa significano questi termini e perché sono essenziali.

5.1.3. Significato epistemico dei componenti

Ciascun termine del teorema di Bayes ha un'interpretazione precisa in termini di credenze e informazioni. Imparare a “leggere” la formula in questo modo è fondamentale per usarla correttamente.

! I quattro attori del teorema di Bayes

La distribuzione a priori: $P(A)$

Rappresenta il grado di credenza nell'ipotesi A *prima* di osservare l'evidenza B . Rappresenta tutto ciò che sapevamo (o credevamo) prima di raccogliere i nuovi dati: studi precedenti, esperienza clinica, prevalenze epidemiologiche, intuizioni teoriche.

Il prior non è un'invenzione arbitraria. È l'esplicitazione di conoscenze che *comunque* influenzano il nostro ragionamento, ma l'approccio bayesiano le rende visibili e criticabili.

La verosimiglianza: $P(B | A)$

Quantifica quanto l'evidenza osservata sia *compatibile* con l'ipotesi. Se A fosse vera, quanto sarebbe plausibile osservare B ?

Questa è la componente che collega le ipotesi ai dati. In diagnostica, corrisponde alla sensibilità, in statistica, alla funzione di verosimiglianza e, in generale, alla capacità predittiva del nostro modello.

L'evidenza marginale: $P(B)$

Rappresenta la probabilità complessiva di osservare B , indipendentemente dalla verità di A . Viene calcolata considerando *tutti* i modi in cui B potrebbe verificarsi.

Questa quantità svolge un ruolo tecnico cruciale: garantisce che la probabilità a posteriori sia correttamente normalizzata, ovvero che la somma delle probabilità di tutte le ipotesi sia pari a 1.

La distribuzione a posteriori: $P(A | B)$

È la risposta alla nostra domanda inferenziale: quanto crediamo in A *dopo* aver osservato B ?

Rappresenta la sintesi razionale tra ciò che sapevamo prima e ciò che i dati ci dicono.

5.1.4. La forma proporzionale: ciò che conta davvero

Spesso è utile scrivere il teorema in forma proporzionale:

$$P(A | B) \propto P(B | A) \cdot P(A).$$

Questa forma evidenzia un fatto importante: il posterior è *proporzionale* al prodotto di verosimiglianza e prior. Il denominatore $P(B)$ serve solo a normalizzare, ovvero a garantire che le probabilità sommino a 1.

In pratica, questo significa che ciò che determina la forma del posterior è il prodotto verosimiglianza $\times$ prior. Il denominatore è lo stesso per tutte le ipotesi che stiamo confrontando e quindi non influenza i loro rapporti relativi.

5.1.5. Visualizzare Bayes attraverso le tabelle congiunte

Il significato del teorema diventa particolarmente chiaro se lo esaminiamo attraverso una tabella di probabilità congiunta:

	B	B^c	Marginali
A	$P(A \cap B)$	$P(A \cap B^c)$	$P(A)$
A^c	$P(A^c \cap B)$	$P(A^c \cap B^c)$	$P(A^c)$
Marginali	$P(B)$	$P(B^c)$	1

In questa rappresentazione:

- il **prior** $P(A)$ è la marginale di riga—quanto crediamo in A prima di sapere qualcosa su B ;
- la **verosimiglianza** $P(B | A) = P(A \cap B)/P(A)$ è la *proporzione* della riga A che cade nella colonna B ;
- il **posterior** $P(A | B) = P(A \cap B)/P(B)$ è la *proporzione* della colonna B che appartiene alla riga A .

Il teorema di Bayes realizza una **rotazione della prospettiva**: dal ragionamento “per righe” (condizionato sull'ipotesi) al ragionamento “per colonne” (condizionato sull'evidenza).

i Esempio: costruzione esplicita di una tabella diagnostica

Consideriamo un test per la depressione con:

$$P(D) = 0.15, \quad P(T^+ | D) = 0.85, \quad P(T^+ | D^c) = 0.10.$$

Passo 1: Costruire la tabella congiunta degli eventi “stato clinico” ed “esito del test”:

```
P_D <- 0.15
sens <- 0.85
fp_rate <- 0.10

# Probabilità congiunte
P_D_and_Tpos <- sens * P_D
P_D_and_Tneg <- (1 - sens) * P_D
P_Dc_and_Tpos <- fp_rate * (1 - P_D)
P_Dc_and_Tneg <- (1 - fp_rate) * (1 - P_D)

tab <- matrix(
  c(P_D_and_Tpos, P_D_and_Tneg,
    P_Dc_and_Tpos, P_Dc_and_Tneg),
  nrow = 2, byrow = TRUE,
  dimnames = list(Stato = c("Depresso", "Non depresso"),
                  Test = c("T+", "T-"))
)
print(round(tab, 4))
#>          Test
#> Stato      T+      T-
#> Depresso   0.128 0.0225
#> Non depresso 0.085 0.7650
```

Passo 2: Calcolare il posterior dalla tabella

Una volta che abbiamo la tabella, il teorema di Bayes emerge naturalmente:

```
P_Tpos <- sum(tab[, 1])          # Marginale P(T+)
P_D_given_Tpos <- tab[1, 1] / P_Tpos # P(D | T+)

cat("P(T+) =", round(P_Tpos, 4), "\n")
#> P(T+) = 0.212
cat("P(D | T+) =", round(P_D_given_Tpos, 4), "\n")
#> P(D | T+) = 0.6
```

Passo 3: Verificare con la formula di Bayes

Possiamo verificare che questo risultato coincide esattamente con l'applicazione diretta della formula di Bayes:

```
posterior_formula <- (sens * P_D) / P_Tpos
cat("Verifica con formula:", round(posterior_formula, 4), "\n")
#> Verifica con formula: 0.6
```

I due metodi danno lo stesso risultato, come deve essere, perché il teorema di Bayes non aggiunge informazioni, ma rende esplicita una relazione già contenuta nella distribuzione congiunta.

5.1.6. Forma estesa con legge della probabilità totale

Nelle applicazioni pratiche, spesso non conosciamo direttamente $P(B)$, ma possiamo calcolarlo considerando tutti i modi in cui B può verificarsi:

$$P(B) = P(B | A) \cdot P(A) + P(B | A^c) \cdot P(A^c)$$

Sostituendo nel teorema di Bayes otteniamo la **forma estesa**:

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B | A) \cdot P(A) + P(B | A^c) \cdot P(A^c)} \quad (5.3)$$

Questa formulazione è particolarmente utile in diagnostica, dove conosciamo la sensibilità $P(T^+ | D)$ e il tasso di falsi positivi $P(T^+ | D^c)$, ma non conosciamo direttamente la probabilità marginale di un test positivo.

5.1.7. Forma estesa con legge della probabilità totale

Nelle applicazioni pratiche, spesso non conosciamo direttamente $P(B)$, ma possiamo calcolarlo considerando tutti i modi in cui B può verificarsi:

$$P(B) = P(B | A) \cdot P(A) + P(B | A^c) \cdot P(A^c)$$

Sostituendo nel teorema di Bayes otteniamo la **forma estesa**:

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B | A) \cdot P(A) + P(B | A^c) \cdot P(A^c)} \quad (5.4)$$

Questa formulazione è particolarmente utile in diagnostica, dove conosciamo sensibilità $P(T^+ | D)$ e tasso di falsi positivi $P(T^+ | D^c)$, ma non direttamente la probabilità marginale di un test positivo.

5.2. Probabilità inversa: il fondamento dell'inferenza

Abbiamo visto la matematica del teorema di Bayes. Ora dobbiamo capire perché questa matematica è così importante, perché risolve un problema fondamentale per la conoscenza scientifica.

5.2.1. Il divario tra modelli e osservazioni

La scienza procede costruendo *modelli*, ovvero rappresentazioni semplificate del mondo che ci permettono di fare previsioni. Un modello ci dice: “Se le cose stanno così, dovremmo osservare questo.”

Ma il mondo ci presenta la situazione opposta: osserviamo *qualcosa*, e vogliamo sapere *come stanno le cose*. Questo è il problema della **probabilità inversa**: risalire dagli effetti alle cause, dalle osservazioni alle ipotesi.

! Le due direzioni del ragionamento scientifico

Direzione predittiva (dal modello ai dati)

“Se l'ipotesi H fosse vera, quali dati D ci aspetteremmo?”

Matematicamente: $P(D | H)$

Questa è la direzione *naturale* dei modelli scientifici. Sappiamo come i meccanismi generano le osservazioni.

Direzione inferenziale (dai dati al modello)

“Dati i dati D che abbiamo osservato, quanto è plausibile l'ipotesi H ?”

Matematicamente: $P(H | D)$

Questa è la direzione *necessaria* per la conoscenza. È ciò che vogliamo sapere.

Il teorema di Bayes è il *ponte* tra queste due direzioni. È la formula che traduce la conoscenza predittiva in conoscenza inferenziale.

5.2.2. L'errore più comune: confondere le direzioni

Una delle fonti più sistematiche di errore nel ragionamento probabilistico, documentata da decenni di ricerca psicologica sul giudizio umano, è la confusione tra $P(D | H)$ e $P(H | D)$.

Queste due quantità sembrano simili, ma sono profondamente diverse. Confonderle porta a errori gravi in ogni campo che richiede il ragionamento in condizioni di incertezza.

! Tre versioni dello stesso errore

In diagnostica clinica

“Il test ha una sensibilità del 95%, quindi un risultato positivo indica che c'è il 95% di probabilità che il paziente sia malato.”

Questo ragionamento confonde $P(T^+ | M)$ con $P(M | T^+)$. Come vedremo, per una malattia rara con una prevalenza dello 0.1%, il valore predittivo positivo può essere inferiore al 5%, nonostante la sensibilità eccellente.

Nel contesto giuridico (la “fallacia del procuratore”)

“La probabilità che un innocente abbia questo profilo genetico è di 1 su 1 milione. Quindi, l'imputato è colpevole con una probabilità di 999.999 su 1 milione.”

Questo equivale a scambiare $P(\text{DNA} | \text{innocente})$ con $P(\text{innocente} | \text{DNA})$. In una città di 10 milioni di abitanti, ci si aspetterebbe di trovare circa 10 profili compatibili, il che renderebbe la “prova” molto meno definitiva.

Nella ricerca scientifica (l'interpretazione errata del valore- p)

“Il valore- p è 0.05, quindi c'è solo il 5% di probabilità che l'ipotesi nulla sia vera.”

Questo confonde $P(\text{dati così estremi} | H_0)$ con $P(H_0 | \text{dati})$. Il valore- p non dice nulla sulla probabilità delle ipotesi, ma indica solo quanto sarebbero inusuali i dati se l'ipotesi nulla fosse vera.

Questi non sono errori di persone poco istruite. Si tratta di errori sistematici commessi da professionisti come medici, avvocati e scienziati che non hanno interiorizzato la distinzione tra le due direzioni del condizionamento.

5.2.3. La soluzione: rendere esplicita l'inversione

Il teorema di Bayes non elimina la difficoltà intrinseca dell'inferenza, ma la rende *esplicita, formale e quindi gestibile*. Ci costringe a specificare con precisione:

1. **ciò che sapevamo prima dell'osservazione dei dati** (*prior*), ossia le nostre conoscenze o assunzioni iniziali;
2. **quanto i dati osservati siano compatibili con ciascuna ipotesi** (*verosimiglianza*), sulla base di un modello esplicito del processo generatore;
3. **come queste informazioni vengono integrate** (attraverso la formula di Bayes) per ottenere credenze aggiornate (*posterior*).

Questa esplicitazione ha un valore epistemologico cruciale. Rendendo separabili i diversi contributi al ragionamento inferenziale, il teorema di Bayes trasforma l'analisi da un processo opaco a uno **trasparente e criticabile**. Se due persone giungono a conclusioni differenti, non è necessario attribuire il disaccordo a un generico "errore": è possibile individuare con precisione il punto di divergenza — nelle assunzioni iniziali, nel modello dei dati o nella loro combinazione.

Rispetto al ragionamento intuitivo, che tende a fondere informazioni pregresse ed evidenza empirica in modo indistinto, questo rappresenta un progresso sostanziale. L'inferenza bayesiana non elimina il giudizio, ma lo **struttura**, rendendolo esplicito, discutibile e, soprattutto, migliorabile.

5.3. Teorema di Bayes in forma di odds

In molte applicazioni, in particolare in ambito diagnostico e decisionale, il teorema di Bayes può essere espresso in una forma particolarmente elegante e intuitiva: la **forma in odds** (quote). Questa formulazione rende l'aggiornamento bayesiano immediatamente interpretabile come un processo di *rafforzamento o indebolimento progressivo* di un'ipotesi alla luce dell'evidenza.

5.3.1. Dalle probabilità agli odds

Le *odds* associate a un'ipotesi H rappresentano il **rapporto tra la probabilità che l'ipotesi sia vera e la probabilità che sia falsa**:

$$\text{Odds}(H) = \frac{P(H)}{1 - P(H)} = \frac{P(H)}{P(H^c)}.$$

Ad esempio, se $P(H) = 0.20$, gli *odds* sono:

$$\frac{0.20}{0.80} = 0.25,$$

che si leggono comunemente come *“una possibilità favorevole contro quattro contrarie”* (1:4). Gli *odds* offrono quindi una rappresentazione alternativa della probabilità, spesso più naturale quando si ragiona in termini comparativi.

5.3.2. L'aggiornamento diventa moltiplicativo

Espresso in termini di *odds*, il teorema di Bayes assume una forma estremamente semplice:

$$\text{Odds}(H \mid E) = \text{Odds}(H) \times \text{LR},$$

dove LR è il **rapporto di verosimiglianza** (*Likelihood Ratio*):

$$\text{LR} = \frac{P(E \mid H)}{P(E \mid H^c)}.$$

L'aggiornamento bayesiano si riduce così a una **moltiplicazione**: gli *odds* a posteriori sono gli *odds* a priori moltiplicati per quanto l'evidenza favorisce (o sfavorisce) l'ipotesi rispetto alla sua negazione.

Questa forma rende evidente che l'inferenza bayesiana non “riparte da zero” a ogni nuova osservazione, ma **aggiorna progressivamente** una credenza iniziale.

5.3.3. Il significato del rapporto di verosimiglianza

Il rapporto di verosimiglianza possiede un'interpretazione diretta e potente: esso misura **quanto l'evidenza osservata sia più compatibile con l'ipotesi H rispetto alla sua negazione H^c** .

- Se $\text{LR} > 1$: l'evidenza è più probabile sotto H che sotto $H^c \rightarrow$ *favorisce H* ;
- Se $\text{LR} < 1$: l'evidenza è più probabile sotto $H^c \rightarrow$ *sfavorisce H* ;
- Se $\text{LR} = 1$: l'evidenza è ugualmente probabile sotto entrambe $\rightarrow$ *non è informativa*.

In altre parole, il rapporto di verosimiglianza quantifica il **peso informativo** di un'osservazione, indipendentemente dalle credenze iniziali.

5.3.4. La forma logaritmica: l'evidenza si somma

Passando alla scala logaritmica, l'aggiornamento bayesiano diventa **additivo**:

$$\log \text{Odds}(H \mid E) = \log \text{Odds}(H) + \log \text{LR}.$$

Questa rappresentazione è particolarmente utile perché rende trasparente l'**accumulo dell'evidenza**: ogni nuova osservazione aggiunge (o sottrae) un contributo ai *log-odds*. L'inferenza può così essere vista come un processo cumulativo, in cui le evidenze si sommano progressivamente nel tempo.

5.3.5. Rapporti di verosimiglianza in diagnostica

In ambito diagnostico, si distinguono due rapporti di verosimiglianza fondamentali.

Rapporto di verosimiglianza positivo (LR^+) Misura quanto un test positivo **aumenti** le *odds* di malattia:

$$LR^+ = \frac{P(T^+ | M)}{P(T^+ | M^c)} = \frac{\text{Sensibilità}}{1 - \text{Specificità}}.$$

Rapporto di verosimiglianza negativo (LR^-) Misura quanto un test negativo **riduca** le *odds* di malattia:

$$LR^- = \frac{P(T^- | M)}{P(T^- | M^c)} = \frac{1 - \text{Sensibilità}}{\text{Specificità}}.$$

Un test diagnostico ideale presenta:

- una LR^+ molto elevata (un risultato positivo è forte evidenza di malattia);
- una LR^- molto piccola (un risultato negativo è forte evidenza di assenza).

5.3.6. Sintesi concettuale

La forma in odds del teorema di Bayes mostra chiaramente che l'inferenza bayesiana consiste nell'aggiornare proporzionalmente le credenze in base all'evidenza. Non ci sono soglie arbitrarie né decisioni dicotomiche: ogni osservazione contribuisce in modo graduale e quantificabile a rafforzare o indebolire un'ipotesi. In questo senso, la formulazione in odds rappresenta una delle espressioni più trasparenti e operative del ragionamento bayesiano.

Interpretazione pratica dei rapporti di verosimiglianza

Linee guida comunemente usate in medicina:

LR^+	LR^-	Impatto diagnostico
> 10	< 0.1	Forte, spesso conclusivo
5-10	0.1-0.2	Moderato
2-5	0.2-0.5	Debole
1-2	0.5-1	Trascurabile

Un test con $LR^+ = 8.5$ significa che un risultato positivo è 8.5 volte più probabile in un paziente malato che in uno sano. Questo è un test ragionevolmente informativo.

Esempio: aggiornamento diagnostico passo per passo

Consideriamo un test con sensibilità 85% e specificità 90%, applicato a una popolazione con prevalenza del 10%.

```
prior_prob <- 0.10
sens <- 0.85
spec <- 0.90

# Rapporti di verosimiglianza
LR_pos <- sens / (1 - spec)
LR_neg <- (1 - sens) / spec

cat("LR+ =", round(LR_pos, 2), "\n")
#> LR+ = 8.5
cat("LR- =", round(LR_neg, 2), "\n")
#> LR- = 0.17
```

Conversione in odds

```
prior_odds <- prior_prob / (1 - prior_prob)
cat("Odds a priori:", round(prior_odds, 3), "(circa 1 a 9)\n")
#> Odds a priori: 0.111 (circa 1 a 9)
```

Scenario 1: test positivo

```
post_odds_pos <- prior_odds * LR_pos
post_prob_pos <- post_odds_pos / (1 + post_odds_pos)

cat("Odds a posteriori:", round(post_odds_pos, 3), "\n")
#> Odds a posteriori: 0.944
cat("Probabilità a posteriori:", round(post_prob_pos * 100, 1), "%\n")
#> Probabilità a posteriori: 48.6 %
```

Le odds aumentano di un fattore 8.5, passando da circa 0.11 a circa 0.94. In termini di probabilità, passiamo dal 10% al 49%.

Scenario 2: test negativo

```
post_odds_neg <- prior_odds * LR_neg
post_prob_neg <- post_odds_neg / (1 + post_odds_neg)

cat("Odds a posteriori:", round(post_odds_neg, 3), "\n")
#> Odds a posteriori: 0.019
cat("Probabilità a posteriori:", round(post_prob_neg * 100, 1), "%\n")
#> Probabilità a posteriori: 1.8 %
```

Le odds diminuiscono di un fattore circa 6 (vengono moltiplicate per 0.17), passando da 0.11 a 0.018. La probabilità scende dal 10% a meno del 2%.

Sintesi: il test è asimmetrico nel suo potere informativo

```
data.frame(  
  Scenario = c("Prima del test", "Dopo test positivo", "Dopo test negativo"),  
  Probabilità = paste0(round(c(prior_prob, post_prob_pos, post_prob_neg) * 100, 1), "%"),  
  Odds = round(c(prior_odds, post_odds_pos, post_odds_neg), 3)  
)  
#>           Scenario Probabilità Odds  
#> 1 Prima del test      10% 0.111  
#> 2 Dopo test positivo  48.6% 0.944  
#> 3 Dopo test negativo   1.8% 0.019
```

Il test è più utile per *escludere* la condizione (un risultato negativo la rende molto improbabile) che per *confermarla* (un risultato positivo lascia ancora un'incertezza sostanziale).

5.4. La fallacia del tasso base

Una delle applicazioni più importanti del teorema di Bayes è la comprensione di un errore cognitivo sistematico: la **fallacia del tasso base**. Questo errore, documentato da decenni di ricerca psicologica, consiste nel sottovalutare l'importanza della prevalenza (il “tasso base”) nell'interpretazione dei test diagnostici.

5.4.1. Il problema

Immaginate questo scenario: un test per una malattia rara ha una sensibilità e una specificità del 99%. Sembra un test quasi perfetto. Un paziente risulta positivo. Qual è la probabilità che sia realmente malato?

La risposta intuitiva di molte persone, inclusi molti medici, è “circa il 99%”. Ma questa risposta è gravemente errata se la malattia è rara.

5.4.2. L'aritmetica della prevalenza

Svolgiamo i calcoli in maniera esplicita. Supponiamo che la malattia abbia una prevalenza dello 0.1% (1 persona su 1000).

```
prevalenza <- 0.001  
sens <- 0.99  
spec <- 0.99  
  
# Applicazione del teorema di Bayes  
P_Tpos <- sens * prevalenza + (1 - spec) * (1 - prevalenza)  
VPP <- (sens * prevalenza) / P_Tpos  
  
cat("Prevalenza:", prevalenza * 100, "%\n")  
#> Prevalenza: 0.1 %  
cat("Sensibilità:", sens * 100, "%\n")  
#> Sensibilità: 99 %  
cat("Specificità:", spec * 100, "%\n")  
#> Specificità: 99 %
```

```
cat("Valore predittivo positivo:", round(VPP * 100, 1), "%\n")
#> Valore predittivo positivo: 9 %
```

Il valore predittivo positivo è solo del 9%! Nonostante la sensibilità e la specificità eccellenti, la maggior parte dei risultati positivi è falsa.

5.4.3. Perché succede questo?

Il meccanismo è semplice ma controintuitivo. Consideriamo 100.000 persone:

- **100 sono malate** (0.1% di 100.000):
 - di queste, 99 risultano positive (sensibilità 99%);
 - 1 risulta negativa (falso negativo).
- **99.900 sono sane** (99.9% di 100.000):
 - di queste, 98.901 risultano negative (specificità 99%);
 - 999 risultano positive (falsi positivi).

Totale positivi: 99 veri positivi + 999 falsi positivi = 1.098.

Proporzione di veri positivi tra tutti i positivi: $99/1.098 \approx 9\%$.

Il problema è che anche un tasso di errore piccolo (1% di falsi positivi), applicato a un gruppo molto grande (99.900 persone sane), produce un numero assoluto di falsi positivi che *supera* il numero di veri positivi.

5.4.4. Visualizzazione dell'effetto della prevalenza

```
VPP <- function(prev, sens, spec) {
  fp <- 1 - spec
  P_Tpos <- sens * prev + fp * (1 - prev)
  (sens * prev) / P_Tpos
}

sens <- 0.85
spec <- 0.90

prevalences <- seq(0.01, 0.50, by = 0.01)
vpps <- VPP(prevalences, sens, spec)

# Punti di riferimento
vpp_bassa <- VPP(0.08, sens, spec) # Medicina generale
vpp_alta <- VPP(0.30, sens, spec)  # Ambulatorio specialistico

df_baseRate <- data.frame(
  Prevalenza = prevalences,
  VPP = vpps
)
```

```
ggplot(df_baseRate, aes(x = Prevalenza, y = VPP)) +
  geom_line(linewidth = 1.2) +
  geom_hline(yintercept = 0.5, linetype = "dashed", alpha = 0.7) +
  geom_vline(xintercept = c(0.08, 0.30), linetype = "dotted", alpha = 0.5) +
  geom_point(aes(x = 0.08, y = vpp_bassa), size = 3) +
  geom_point(aes(x = 0.30, y = vpp_alta), size = 3) +
  annotate("text", x = 0.10, y = vpp_bassa - 0.08,
    label = "Medicina\ngenerale (8%)", hjust = 0, size = 3.5) +
  annotate("text", x = 0.32, y = vpp_alta,
    label = "Ambulatorio\nspecialistico (30%)", hjust = 0, size = 3.5) +
  scale_x_continuous(labels = scales::percent) +
  scale_y_continuous(labels = scales::percent) +
  labs(
    title = "L'effetto del tasso base sul significato di un test positivo",
    subtitle = paste0("Test: sensibilità ", sens*100, "%, specificità ", spec*100, "%"),
    x = "Prevalenza del disturbo",
    y = "Valore Predittivo Positivo"
  )
)
```




Figura 5.1.: L'effetto della prevalenza sul valore predittivo positivo. Lo stesso test (sensibilità 95%, specificità 90%) produce interpretazioni radicalmente diverse a seconda del contesto.

5.4.5. La lezione per la pratica clinica

Questo grafico illustra un principio fondamentale: **lo stesso test può avere significati diversi in contesti diversi.**

- In medicina generale (prevalenza ~8%): un test positivo indica solo il ~43% di probabilità di malattia.
- In un ambulatorio specialistico (prevalenza ~30%): lo stesso test positivo indica una probabilità del ~78%.

La differenza non sta nel test, ma nel contesto. Il teorema di Bayes ci obbliga a considerare esplicitamente questo contesto, mentre l'intuizione tende a ignorarlo.

5.4.6. Implicazioni per lo screening di popolazione

Questa analisi ha importanti conseguenze pratiche:

1. **lo screening di massa è problematico per le condizioni rare:** anche i test eccellenti producono troppi falsi positivi;
2. **il valore principale di molti test è escludere la malattia:** un risultato negativo è spesso più informativo di un risultato positivo;
3. **la pre-selezione migliora l'utilità diagnostica:** testare le persone con sintomi aumenta la prevalenza "effettiva" e quindi il VPP;
4. **comunicare i risultati richiede attenzione:** dire "il test è positivo" senza spiegare cosa significa può generare ansia ingiustificata.

5.5. Applicazioni al ragionamento clinico

Il teorema di Bayes non è solo uno strumento di calcolo, ma un modo di *pensare* al ragionamento clinico. Vediamo alcune applicazioni che illustrano questo concetto.

i Esempio: diagnostica sequenziale nell'ADHD

Il ragionamento clinico raramente si basa su una singola fonte di informazione. Il teorema di Bayes fornisce il quadro naturale per integrare evidenze multiple.

Scenario: valutazione di un bambino per possibile ADHD utilizzando due strumenti complementari.

```
# Parametri iniziali
P_ADHD <- 0.05      # Prevalenza nella popolazione scolastica
sens_T1 <- 0.80     # Questionario genitori
spec_T1 <- 0.85
sens_T2 <- 0.75     # Osservazione in classe
spec_T2 <- 0.88

# Rapporti di verosimiglianza
LR_pos_T1 <- sens_T1 / (1 - spec_T1)
LR_pos_T2 <- sens_T2 / (1 - spec_T2)

cat("LR+ questionario:", round(LR_pos_T1, 1), "\n")
#> LR+ questionario: 5.3
cat("LR+ osservazione:", round(LR_pos_T2, 1), "\n")
#> LR+ osservazione: 6.2
```

Aggiornamento sequenziale

Partiamo dalla prevalenza e aggiorniamo dopo ogni test positivo:

```

# Fase 1: Prior
prior_odds <- P_ADHD / (1 - P_ADHD)

# Fase 2: Dopo questionario positivo
post_odds_T1 <- prior_odds * LR_pos_T1
post_prob_T1 <- post_odds_T1 / (1 + post_odds_T1)

# Fase 3: Dopo anche osservazione positiva
post_odds_both <- post_odds_T1 * LR_pos_T2
post_prob_both <- post_odds_both / (1 + post_odds_both)

# Sintesi
evoluzione <- data.frame(
  Fase = c("Prevalenza iniziale",
           "Dopo questionario (+)",
           "Dopo osservazione (+)"),
  Probabilità = paste0(round(c(P_ADHD, post_prob_T1, post_prob_both) * 100, 1), "%")
)
print(evoluzione)
#>               Fase Probabilità
#> 1  Prevalenza iniziale          5%
#> 2 Dopo questionario (+)       21.9%
#> 3 Dopo osservazione (+)       63.7%

```

Visualizzazione dell'accumulo di evidenze

```

df_seq <- data.frame(
  Fase = factor(c("Prior", "Dopo T1 (+)", "Dopo T1 e T2 (+)"),
               levels = c("Prior", "Dopo T1 (+)", "Dopo T1 e T2 (+)")),
  Probabilità = c(P_ADHD, post_prob_T1, post_prob_both)
)

ggplot(df_seq, aes(x = Fase, y = Probabilità)) +
  geom_col(fill = "#4E79A7", alpha = 0.8, width = 0.6) +
  geom_text(aes(label = sprintf("%.1f%%", Probabilità * 100)),
            vjust = -0.5, size = 4.5) +
  geom_line(aes(group = 1), linewidth = 1, alpha = 0.6) +
  geom_point(size = 3) +
  scale_y_continuous(labels = scales::percent, limits = c(0, 0.75)) +
  labs(
    title = "Aggiornamento bayesiano sequenziale",
    subtitle = paste0("LR+ T1 = ", round(LR_pos_T1, 1),
                     ", LR+ T2 = ", round(LR_pos_T2, 1)),
    y = "P(ADHD)"
  )

```





Figura 5.2.: L'accumulo bayesiano di evidenze: ogni test positivo incrementa la probabilità in modo moltiplicativo sulle odds.

Interpretazione clinica

Il processo illustra diversi principi importanti.

1. **L'evidenza si accumula:** partendo dal 5%, arriviamo al 64% dopo due test positivi concordanti.
2. **L'assunzione di indipendenza condizionale:** abbiamo assunto che i due test forniscano informazioni *indipendenti* dato lo stato del bambino. Questo è plausibile perché misurano contesti diversi (casa vs scuola).
3. **I rapporti di verosimiglianza si moltiplicano:** l'effetto combinato (LR totale ≈ 33) è il prodotto dei singoli LR .
4. **Il prior conta:** se la prevalenza fosse 20% invece che 5%, lo stesso pattern di test produrrebbe una probabilità finale molto più alta.

i Esempio: comorbidità tra depressione e ansia

Il ragionamento bayesiano si applica naturalmente anche alla valutazione della comorbidità.

Scenario: in un contesto clinico, sappiamo che depressione e ansia sono frequentemente co-occorrenti. Come cambia la nostra valutazione della depressione quando osserviamo ansia?

```
# Parametri dalla letteratura
P_D <- 0.40          # Prevalenza depressione in contesto clinico
P_A_given_D <- 0.60 # P(Ansia | Depressione)
P_A <- 0.35          # Prevalenza generale ansia

# Teorema di Bayes per calcolare P(D | A)
P_D_given_A <- (P_A_given_D * P_D) / P_A

# E se l'ansia fosse assente?
P_D_and_A <- P_A_given_D * P_D
P_D_and_not_A <- P_D - P_D_and_A
P_not_A <- 1 - P_A
P_D_given_not_A <- P_D_and_not_A / P_not_A

cat("P(Depressione) = ", P_D * 100, "%\n")
#> P(Depressione) = 40 %
cat("P(Depressione | Ansia presente) =", round(P_D_given_A * 100, 1), "%\n")
#> P(Depressione | Ansia presente) = 68.6 %
cat("P(Depressione | Ansia assente) =", round(P_D_given_not_A * 100, 1), "%\n")
#> P(Depressione | Ansia assente) = 24.6 %
```

Interpretazione

La presenza di ansia quasi raddoppia la probabilità di depressione (dal 40% al 69%), mentre l'assenza di ansia la riduce sostanzialmente (al 25%).

Questo esempio illustra come le informazioni cliniche si influenzino a vicenda. Un clinico esperto sa intuitivamente che ansia e depressione spesso coesistono. Il teorema di Bayes quantifica precisamente questa intuizione e la rende comunicabile.

5.6. Come interpretare il risultato di un test psicologico

Abbiamo discusso il teorema di Bayes attraverso esempi diagnostici. Ma cosa significa tutto questo *concretamente* per uno psicologo che somministra un test a un paziente specifico? Questa domanda merita una risposta esplicita, in quanto tocca il cuore della pratica professionale.

5.6.1. Lo scenario

Immaginate di aver somministrato il Beck Depression Inventory (BDI-II) a un paziente. Il punteggio ottenuto è 22, che supera il cut-off clinico di 20, comunemente utilizzato per indicare una depressione moderata. Cosa potete concludere?

La risposta *non* è: “Il paziente è depresso.” E nemmeno: “C’è il 90% di probabilità che il paziente sia depresso” (o qualsiasi altra percentuale derivata dalle proprietà psicometriche del test).

5.6.2. L’errore da evitare

L’errore più comune, e anche il più grave, è interpretare il risultato del test come se fornisse direttamente la probabilità della condizione. “Il test ha una sensibilità dell’85%, quindi, se risulta positivo, c’è l’85% di probabilità che il paziente sia depresso”.

Come abbiamo visto, questo ragionamento confonde $P(T^+ | D)$ con $P(D | T^+)$. La sensibilità ci dice quanto è probabile che il test dia esito positivo *se* il paziente è depresso. Ma noi vogliamo sapere quanto è probabile che il paziente sia depresso *dato che* il test è positivo. Sono domande diverse, con risposte diverse.

5.6.3. L'interpretazione corretta: un processo bayesiano

Per una corretta interpretazione, è necessario pensare in termini bayesiani, anche se non è necessario effettuare calcoli espliciti. Il processo ha tre componenti.

1. La probabilità pre-test (il prior)

Prima di somministrare il test, avevate già delle informazioni sul paziente? Perché si è rivolto a voi? Quali sintomi ha riferito? Qual è la sua storia? In quale contesto lavorate?

Se il paziente si è presentato spontaneamente lamentando umore depresso, perdita di interesse e disturbi del sonno da tre mesi, la probabilità pre-test di depressione era già alta, forse 60-70%. Se invece il test è stato somministrato come screening di routine a un dipendente aziendale senza particolari segnali di malessere, la probabilità pre-test era molto più bassa, forse del 5-10%.

Questa probabilità non è arbitraria, ma riflette tutto ciò che si sa sul paziente e sulla popolazione di riferimento. È il punto di partenza.

2. L'evidenza fornita dal test (la verosimiglianza)

Il test positivo modifica la vostra credenza iniziale. Di quanto? Dipende dalle proprietà psicometriche del test, ovvero dalla sua capacità di discriminare chi ha la condizione da chi non ce l'ha.

Un test con alta sensibilità e alta specificità fornisce un'evidenza forte: un risultato positivo aumenta molto la probabilità della condizione, mentre un risultato negativo la diminuisce notevolmente. Un test con proprietà più modeste fornisce un'evidenza più debole.

Ma, e questo è il punto cruciale, l'entità dell'aggiornamento dipende anche dalla probabilità pre-test. Lo stesso test positivo ha un significato diverso per il paziente che si è presentato con sintomi evidenti (dove conferma un sospetto già forte) e per il dipendente sottoposto a screening (dove deve "vincere" contro una bassa probabilità di base).

3. La probabilità post-test (il posterior)

Il risultato finale, ovvero la vostra credenza aggiornata sulla condizione del paziente, è la sintesi bayesiana di prior ed evidenza.

Per il paziente sintomatico, se partivate da una probabilità del 65% e il test è positivo, potreste arrivare a una probabilità dell'85-90%. Il test ha confermato e rafforzato un sospetto già forte.

Per il dipendente sottoposto a screening: se partivate da un valore del 8% e il test è risultato positivo, potreste arrivare a un valore compreso tra il 40% e il 50%. Il test ha aumentato in modo significativo la probabilità, ma non l'ha resa elevata. Quel risultato positivo richiede un approfondimento, non una diagnosi.

5.6.4. Implicazioni pratiche

Questa analisi ha conseguenze concrete per la pratica clinica:

Un test positivo non è una diagnosi. È un'informazione che aggiorna le vostre credenze. L'entità dell'aggiornamento dipende dal punto di partenza. Se la probabilità di partenza era bassa, anche dopo un test positivo, potreste non avere la certezza sufficiente per una diagnosi.

Il contesto clinico è parte integrante dell'interpretazione. Lo stesso punteggio BDI di 22 può avere significati diversi per pazienti diversi. Non si tratta di un difetto del test, ma di una conseguenza inevitabile della logica probabilistica.

I test sono più utili in alcune situazioni che in altre. In generale, sono più utili per *escludere* condizioni (un risultato negativo in un contesto ad alta probabilità pre-test è molto informativo) che per *confermarle* (un risultato positivo in un contesto a bassa probabilità pre-test lascia molta incertezza).

La comunicazione al paziente richiede attenzione. Dire “il test è positivo per depressione” può essere fuorviante se non si fornisce il contesto adeguato. È meglio dire: “Il test suggerisce la possibilità di depressione. Insieme alle altre informazioni che abbiamo raccolto, questo mi porta a pensare che [valutazione integrata].”

5.6.5. Un esempio numerico

Rendiamo concreto il ragionamento. Supponiamo che il BDI-II abbia una sensibilità dello 0.85 e una specificità di 0.80 per la depressione maggiore.

```
# Proprietà del test
sens <- 0.85
spec <- 0.80
LR_pos <- sens / (1 - spec) # = 4.25

# Due scenari
prior_sintomatico <- 0.65
prior_screening <- 0.08

# Funzione per calcolare posterior
calcola_posterior <- function(prior, LR) {
  odds_prior <- prior / (1 - prior)
  odds_post <- odds_prior * LR
  odds_post / (1 + odds_post)
}

post_sintomatico <- calcola_posterior(prior_sintomatico, LR_pos)
post_screening <- calcola_posterior(prior_screening, LR_pos)

cat("Paziente sintomatico:\n")
#> Paziente sintomatico:
cat("  Prior:", prior_sintomatico * 100, "%\n")
#>  Prior: 65 %
cat("  Posterior dopo test +:", round(post_sintomatico * 100, 1), "%\n\n")
#>  Posterior dopo test +: 88.8 %
```

```
cat("Screening aziendale:\n")
#> Screening aziendale:
cat("  Prior:", prior_screening * 100, "%\n")
#>  Prior: 8 %
cat("  Posterior dopo test +:", round(post_screening * 100, 1), "%\n")
#>  Posterior dopo test +: 27 %
```

Lo stesso test positivo porta a conclusioni molto diverse: l'88% di probabilità di depressione per il paziente sintomatico e solo il 27% per il dipendente sottoposto a screening. Nel primo caso, una diagnosi provvisoria è ragionevole, mentre nel secondo è necessario un approfondimento prima di poter trarre qualsiasi conclusione.

5.6.6. Il messaggio per la pratica

Il teorema di Bayes non è solo matematica astratta, ma la formalizzazione di ciò che un clinico esperto fa intuitivamente. Quando affermate “Questo test positivo è rilevante, dato il quadro clinico” o “Non mi fido di questo risultato, non è coerente con tutto il resto”, state ragionando in modo bayesiano.

La differenza è che il ragionamento esplicito vi protegge dagli errori sistematici, come la tendenza a sovrastimare il significato di un test positivo, a ignorare il contesto o a considerare il risultato come la risposta definitiva, invece che come un elemento da integrare.

In sintesi: **un test non vi dice se il paziente ha una determinata condizione. Vi dice quanto dovrete aggiornare la vostra credenza sulla condizione, sulla base della vostra valutazione iniziale.** Questa distinzione può sembrare sottile, ma ha conseguenze profonde per la qualità del ragionamento clinico.

5.7. Aggiornamento bayesiano con distribuzioni continue

Finora abbiamo applicato il teorema di Bayes a ipotesi discrete: il paziente è depresso o non lo è, la moneta è bilanciata o non lo è. Tuttavia, in molte situazioni, il parametro di interesse è continuo: non vogliamo sapere se un effetto esiste, ma quanto è grande; non se uno studente conosce la risposta, ma qual è la sua abilità.

In questi casi, l'aggiornamento bayesiano opera su *distribuzioni di probabilità* piuttosto che su singoli valori.

5.7.1. Il modello Beta-Binomiale

Quando il parametro di interesse è una probabilità $\theta \in [0, 1]$ e i dati sono binari (successi e fallimenti), la distribuzione **Beta** offre un framework particolarmente elegante.

! Coniugazione Beta-Binomiale

- **Prior:** $\theta \sim \text{Beta}(\alpha, \beta)$.
- **Dati:** k successi su n prove.
- **Posterior:** $\theta \mid k \sim \text{Beta}(\alpha + k, \beta + n - k)$.

I parametri α e β possono essere interpretati come “pseudo-osservazioni” precedenti: $\alpha - 1$ successi virtuali e $\beta - 1$ fallimenti virtuali. L'aggiornamento consiste semplicemente

nell'aggiungere i nuovi dati a questi conteggi.

Questa proprietà di **coniugazione**, ovvero il fatto che prior e posterior appartengano alla stessa famiglia di distribuzioni, rende l'aggiornamento bayesiano computazionalmente semplice e concettualmente trasparente.

5.7.2. Esempio: valutazione di uno studente

Consideriamo un test a scelta multipla con 4 opzioni per domanda. Il nostro prior riflette l'ipotesi che lo studente stia rispondendo a caso (probabilità $1/4 = 0.25$).

```
# Prior: centrato su risposta casuale
alpha_prior <- 1
beta_prior <- 3 # Media = 1/(1+3) = 0.25

# Dati: 12 risposte corrette su 30
n_obs <- 30
k_success <- 12

# Posterior
alpha_post <- alpha_prior + k_success
beta_post <- beta_prior + (n_obs - k_success)

# Griglia per visualizzazione
theta_seq <- seq(0, 1, length.out = 500)

prior_dens <- dbeta(theta_seq, alpha_prior, beta_prior)
posterior_dens <- dbeta(theta_seq, alpha_post, beta_post)

# Verosimiglianza (normalizzata per visualizzazione)
lik_dens <- dbinom(k_success, n_obs, theta_seq)
lik_dens <- lik_dens / max(lik_dens) * max(posterior_dens)

df_beta <- data.frame(
  theta = rep(theta_seq, 3),
  Densità = c(prior_dens, lik_dens, posterior_dens),
  Componente = rep(c("Prior", "Verosimiglianza", "Posterior"), each = 500)
)

ggplot(df_beta, aes(x = theta, y = Densità, color = Componente, linetype = Componente)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = 0.25, linetype = "dotted", alpha = 0.5) +
  geom_vline(xintercept = k_success/n_obs, linetype = "dotted", alpha = 0.5) +
  annotate("text", x = 0.27, y = max(posterior_dens) * 0.95,
    label = "Prior\n(caso)", hjust = 0, size = 3) +
  annotate("text", x = k_success/n_obs + 0.02, y = max(posterior_dens) * 0.7,
    label = "MLE", hjust = 0, size = 3) +
  scale_linetype_manual(values = c("Prior" = "dashed",
    "Verosimiglianza" = "dotted",
    "Posterior" = "solid")) +
```

```
labs(
  title = "Aggiornamento bayesiano: 12 corrette su 30 domande",
  x = expression(theta ~ "(probabilità di risposta corretta)"),
  y = "Densità"
)
```




Figura 5.3.: L'aggiornamento bayesiano nel modello Beta-Binomiale: la distribuzione a posteriori è un compromesso tra prior e verosimiglianza.

Cosa mostra il grafico:

- il **prior** (tratteggiato) è centrato su 0.25, l'ipotesi di risposta casuale;
- la **verosimiglianza** (punteggiato) indica che i dati ($12/30 = 0.40$) favoriscono valori più alti;
- il **posterior** (continuo) è un *compromesso*: spostato verso i dati rispetto al prior, ma non coincide con la stima di massima verosimiglianza.

```
# Confronto numerico
prior_mean <- alpha_prior / (alpha_prior + beta_prior)
mle <- k_success / n_obs
post_mean <- alpha_post / (alpha_post + beta_post)

data.frame(
  Stima = c("Media a priori", "Massima verosimiglianza", "Media a posteriori"),
  Valore = round(c(prior_mean, mle, post_mean), 3)
)

#>           Stima Valore
#> 1      Media a priori 0.250
#> 2 Massima verosimiglianza 0.400
#> 3      Media a posteriori 0.382
```

La media a posteriori (0.382) si colloca *tra* il prior (0.25) e i dati (0.40). Questo “shrinkage” verso il prior riflette il fatto che non abbiamo ancora abbastanza dati per abbandonare completamente le nostre credenze iniziali.

5.7.3. Intervalli di credibilità: quantificare l'incertezza

A differenza degli intervalli di confidenza frequentisti, che descrivono le proprietà di una *procedura*, gli intervalli di credibilità bayesiani forniscono affermazioni dirette sulla *probabilità* che il parametro cada in un certo intervallo.

```
# Intervallo di credibilità 95%
ci_lower <- qbeta(0.025, alpha_post, beta_post)
ci_upper <- qbeta(0.975, alpha_post, beta_post)

df_post <- data.frame(theta = theta_seq, densità = posterior_dens)

ggplot(df_post, aes(x = theta, y = densità)) +
  geom_line(linewidth = 1.2) +
  geom_area(data = df_post %>% filter(theta >= ci_lower & theta <= ci_upper),
    alpha = 0.3) +
  geom_vline(xintercept = c(ci_lower, ci_upper), linetype = "dashed") +
  geom_vline(xintercept = post_mean, linewidth = 1) +
  annotate("text", x = post_mean + 0.02, y = max(posterior_dens) * 0.8,
    label = paste0("Media: ", round(post_mean, 3)), hjust = 0) +
  annotate("text", x = (ci_lower + ci_upper)/2, y = max(posterior_dens) * 0.4,
    label = paste0("IC 95%\n[", round(ci_lower, 2), ", ", round(ci_upper, 2), "]")) +
  labs(
    title = "Quantificazione dell'incertezza su ",
    x = expression(theta),
    y = "Densità a posteriori"
  )
)
```



Figura 5.4.: Distribuzione a posteriori con intervallo di credibilità al 95%. L'area ombreggiata contiene il vero valore del parametro con probabilità 0.95.

! Interpretazione degli intervalli di credibilità

Intervallo di credibilità bayesiano (95%):

“C’è una probabilità del 95% che il vero valore del parametro sia compreso tra 0.23 e 0.55, date le nostre informazioni.”

Questa interpretazione è *diretta e intuitiva*: è esattamente ciò che le persone si aspettano da un intervallo di confidenza, ma che l’interpretazione frequentista non permette.

Intervallo di confidenza frequentista (95%):

“Se ripetessimo questo esperimento infinite volte e calcolassimo l’intervallo ogni volta, il 95% di questi intervalli conterrebbe il vero parametro.”

Questa interpretazione riguarda le proprietà della *procedura*, non del parametro specifico che ci interessa.

La differenza non è solo filosofica, ma ha anche conseguenze pratiche. L’interpretazione bayesiana consente affermazioni come “è molto improbabile che $\theta > 0.6$ ”, cosa che l’interpretazione frequentista, tecnicamente, non permette.

Riflessioni conclusive

Siamo arrivati al termine del percorso che ha costruito le fondamenta del ragionamento bayesiano. Il teorema di Bayes non è stato presentato come una formula da memorizzare, ma come l’espressione matematica di un principio epistemologico profondo: **l’apprendimento razionale dall’esperienza**.

Cosa abbiamo compreso

La derivazione del teorema dalla simmetria della probabilità congiunta ha mostrato che l’aggiornamento bayesiano non è una scelta metodologica arbitraria. È una *necessità logica* per chiunque accetti i vincoli di coerenza della teoria della probabilità. Non c’è alternativa coerente: se le nostre credenze devono rispettare gli assiomi, devono aggiornarsi secondo Bayes.

L’interpretazione epistemica dei componenti—prior, verosimiglianza, evidenza, posterior—ha rivelato una struttura del ragionamento che è al tempo stesso rigorosa e intuitiva. Il prior esplicita ciò che sapevamo prima; la verosimiglianza misura la compatibilità tra dati e ipotesi; il posterior sintetizza tutto in una credenza aggiornata.

Le applicazioni diagnostiche hanno illustrato sia il potere del teorema sia i pericoli dell’intuizione non guidata. La fallacia del tasso base—l’errore sistematico di ignorare la prevalenza—è una delle scoperte più robuste della psicologia del giudizio. Il teorema di Bayes non solo spiega *perché* commettiamo questo errore, ma ci fornisce lo strumento per evitarlo.

Il messaggio fondamentale

Se dovessimo condensare tutto in un’unica idea, sarebbe questa: **la razionalità è coerenza, e la coerenza richiede Bayes**.

Questo non significa che l'approccio bayesiano sia l'unico valido, o che non abbia limiti. Significa che, una volta accettata l'interpretazione della probabilità come grado di credenza, l'aggiornamento bayesiano segue come conseguenza inevitabile. Le alternative—ignorare il prior, confondere le direzioni del condizionamento, non aggiornare le credenze—non sono semplicemente “scelte diverse”. Sono incoerenze.

Verso il futuro

Questo capitolo conclude la trattazione dei fondamenti. I concetti stabiliti, ovvero, prior, verosimiglianza, posterior, aggiornamento sequenziale e quantificazione dell'incertezza, costituiranno la base per tutto ciò che seguirà: modelli più complessi, metodi computazionali e applicazioni avanzate.

Tuttavia, la logica sottostante rimarrà invariata. Come scrisse Pierre-Simon Laplace oltre due secoli fa, il calcolo delle probabilità non è altro che “il buon senso ridotto a calcolo”. Il teorema di Bayes è il motore che rende possibile questa riduzione.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Il teorema di Bayes come inversione probabilistica

- deriva dalla simmetria della probabilità congiunta;
- permette di passare da $P(E | H)$ a $P(H | E)$;
- non è un'assunzione aggiuntiva, ma una conseguenza degli assiomi.

2. Interpretazione epistemica dei componenti

- **prior** $P(H)$: credenza prima dei dati;
- **verosimiglianza** $P(E | H)$: compatibilità dati-ipotesi;
- **evidenza** $P(E)$: normalizzazione;
- **posterior** $P(H | E)$: credenza aggiornata.

3. Forma in odds

- odds posteriori = LR $\times$ Odds a priori;
- il rapporto di verosimiglianza quantifica la forza dell'evidenza;
- aggiornamenti sequenziali: i LR si moltiplicano.

4. La fallacia del tasso base

- ignorare la prevalenza porta a sovrastimare il VPP;
- lo stesso test ha significati diversi in contesti diversi;
- il teorema di Bayes costringe a considerare il contesto.

5. Aggiornamento con distribuzioni continue

- Beta-Binomiale: $\text{Beta}(\alpha, \beta) \rightarrow \text{Beta}(\alpha + k, \beta + n - k)$;
- intervalli di credibilità: interpretazione probabilistica diretta.

Formule da ricordare:

$$P(H | E) = \frac{P(E | H) \cdot P(H)}{P(E)}$$

$$\text{Odds}(H | E) = \text{LR} \times \text{Odds}(H)$$

$$\text{LR}^+ = \frac{\text{Sensibilità}}{1 - \text{Specificità}}$$

Per il prossimo capitolo:

Nel 1 inizieremo lo studio delle **variabili casuali**, formalizzando il passaggio da eventi discreti a quantità numeriche e preparando il terreno per modelli statistici più sofisticati.

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0     ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0     posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0     estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51           labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8       curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8          purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1         xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.3        scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-1        rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0           RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0        parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0             Matrix_1.7-5          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1    glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1  lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6         QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9      Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5    rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9       backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13         snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1        gridExtra_2.3.1       nlme_3.1-169
#> [67] checkmate_2.3.4      xfun_0.60             pkgconfig_2.0.3

```

Bibliografia

Parte II.

**PARTE 2: Variabili casuali e
distribuzioni**

6. Variabili casuali

Introduzione

Immaginiamo uno scenario ricorrente nella pratica clinica. Una psicologa vuole valutare l'efficacia di un intervento cognitivo-comportamentale per l'ansia sociale. A tal fine, somministra la *Liebowitz Social Anxiety Scale* (LSAS), un questionario i cui punteggi, compresi tra 0 e 144, riflettono la gravità dei sintomi, a 50 pazienti, rilevando le misure prima e dopo un ciclo di 12 sedute.

Tuttavia, la domanda clinica non si riduce a un problema dicotomico del tipo “l'intervento funziona sì o no?”, quesito che gli strumenti probabilistici sin qui introdotti sarebbero già in grado di trattare in termini di test di ipotesi o di probabilità dell'evento. La questione è più complessa e sostanziale: qual è l'entità attesa del miglioramento? Quale distribuzione di probabilità caratterizza gli effetti possibili del trattamento? E, soprattutto, con quale misura di incertezza, in termini di varianza, intervalli di credibilità o densità predittive, dobbiamo accompagnare le nostre stime affinché queste siano interpretabili dal punto di vista clinico?

Per rispondere a queste domande, è necessario compiere un salto concettuale decisivo: non più assegnare probabilità a eventi discreti, ma a quantità numeriche continue e misurabili. È proprio questo il ruolo delle **variabili casuali** che fungono da ponte tra la teoria della probabilità, intesa come sistema formale di credenze coerenti, e i modelli statistici su cui si fonda l'inferenza bayesiana.

Senza questo strumento, domande clinicamente rilevanti resterebbero senza risposta: “Qual è la probabilità che il miglioramento medio superi i 20 punti?” o “In quale intervallo possiamo attendere il punteggio post-trattamento con una probabilità del 95%?” diventano interrogativi risolvibili solo grazie alla formalizzazione offerta dalle variabili casuali.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 1
- Capitolo 2
- Capitolo 3
- Capitolo 4
- Capitolo 5

Conoscenze matematiche richieste:

- Appendice F — **fondamentale** per comprendere le PDF e le variabili continue.
- Appendice C - per marginalizzazione di variabili discrete.

Competenze pratiche:

- Familiarità con R e operazioni vettoriali di base per eseguire le simulazioni.

Panoramica del capitolo

- Definizione formale di variabile casuale come funzione dallo spazio campionario ai numeri reali.
- Distinzione tra variabili casuali discrete e continue.
- Funzione di massa di probabilità (PMF) per variabili discrete.
- Funzione di densità di probabilità (PDF) per variabili continue.
- Funzione di distribuzione cumulativa (CDF) come rappresentazione unificata.
- Variabili casuali multiple e nozione di indipendenza.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

6.1. Dalla probabilità degli eventi ai valori numerici

Nel framework bayesiano sviluppato nei capitoli precedenti, abbiamo assegnato delle probabilità a degli **eventi**, ovvero a dei sottoinsiemi dello spazio campionario che rappresentano delle proposizioni sul mondo. Quando un clinico afferma $P(\text{Depressione maggiore}) = 0.3$, sta quantificando la propria credenza in una proposizione binaria: il paziente soddisfa o non soddisfa i criteri diagnostici.

Questa struttura è potente per molte domande cliniche, come la diagnosi differenziale, la valutazione del rischio e la previsione di esiti categoriali, ma risulta insufficiente quando l'oggetto dell'incertezza non è un evento sì/no, bensì un **valore numerico**. Consideriamo alcune domande tipiche della ricerca psicologica:

- *Quale sarà il punteggio di questo paziente al BDI-II tra sei mesi?*
- *Quanto tempo impiegherà un partecipante a rispondere in questo compito di decisione lessicale?*
- *Quanti sintomi depressivi riporterà il paziente nella prossima settimana?*
- *Quale livello di cortisolo mostrerà lo studente prima dell'esame?*

In tutti i casi, l'incertezza non riguarda il verificarsi di un evento, ma l'ampiezza, la durata o l'intensità di un fenomeno. Per modellare questo tipo di incertezza, dobbiamo passare dagli eventi alle **variabili casuali**.

6.1.1. L'idea fondamentale

Il passaggio concettuale consiste nel riconoscere che molti esperimenti producono naturalmente risultati numerici. Un test psicométrico restituisce un punteggio, una misurazione fisiologica produce un valore continuo e un compito cognitivo genera un tempo di reazione. Anche quando gli esiti originari non sono numerici, è sempre possibile **codificarli** come tali, assegnando 1 al successo e 0 al fallimento in un singolo item o utilizzando codifiche ordinali per le categorie diagnostiche.

La traduzione sistematica degli esiti in numeri è realizzata tramite una **variabile casuale**. La "casualità" non risiede nella funzione in sé, che è perfettamente deterministica, ma nell'incertezza relativa all'esito che si verificherà nello spazio campionario. Una volta che l'esito è stato determinato, il valore numerico associato viene automaticamente calcolato.

6.2. Definizione formale di variabile casuale

Definizione 6.1 (Variabile casuale). Sia Ω uno spazio campionario. Una *variabile casuale* è una funzione

$$X : \Omega \longrightarrow \mathbb{R}$$

che associa a ogni esito $\omega \in \Omega$ un unico numero reale $X(\omega)$.

Questa definizione va interpretata con attenzione. Lo spazio campionario Ω rappresenta, nella nostra prospettiva epistemica, l'insieme di tutte le **possibilità** compatibili con le informazioni a nostra disposizione. La variabile casuale X traduce ciascuna di queste possibilità in un numero, rendendo possibile l'applicazione dell'analisi matematica allo studio dell'incertezza.

Il termine “casuale” è quindi in parte fuorviante: la funzione X non è affatto aleatoria, ma completamente deterministica. L'incertezza deriva esclusivamente dal fatto che non sappiamo quale elemento di Ω si realizzerà.

Per convenzione, le variabili casuali come funzioni sono indicate con lettere maiuscole (X, Y, Z), mentre i valori numerici che possono assumere sono indicati con lettere minuscole (x, y, z). Questa distinzione permette di scrivere espressioni come $P(X = x)$ o $P(X \leq x)$, separando chiaramente l'oggetto aleatorio dai suoi possibili valori.

i Esempio: punteggio in un test a scelta multipla

Il punteggio come variabile casuale

Consideriamo un breve test di memoria di lavoro composto da 5 item. Ogni item può essere risolto correttamente (C) o erroneamente (E). Lo spazio campionario è costituito da tutte le possibili sequenze di risposte:

$$\Omega = \{CCCCC, CCCCE, CCCEC, \dots, EEEEE\}.$$

Poiché ogni item ha due esiti possibili e gli item sono 5, lo spazio campionario contiene $2^5 = 32$ elementi.

Definiamo la variabile casuale X che associa a ogni sequenza di risposte il numero totale di risposte corrette:

$$X(\omega) = \text{numero di C in } \omega.$$

Per l'esito $\omega = CCECE$, ad esempio, il valore della variabile casuale è $X(CCECE) = 3$. La funzione X è perfettamente deterministica: data la sequenza di risposte, il punteggio è univocamente determinato. L'incertezza riguarda solo *quale* sequenza di risposte verrà osservata.

L'evento $\{X = 3\}$ rappresenta l'insieme di tutti gli esiti che producono esattamente 3 risposte corrette:

$$\{X = 3\} = \{CCCEE, CCECE, CCEEC, CECCE, \dots\}.$$

Questo insieme contiene $\binom{5}{3} = 10$ elementi. Se assumiamo che ciascuna risposta sia corretta con probabilità $p = 0.6$ indipendentemente dalle altre, la probabilità di ottenere esattamente 3 risposte corrette è:

$$P(X = 3) = \binom{5}{3} (0.6)^3 (0.4)^2 = 10 \times 0.216 \times 0.16 = 0.3456.$$

6.2.1. Perché questo passaggio è cruciale per l'inferenza bayesiana

L'introduzione delle variabili casuali non è un mero tecnicismo, ma un **prerequisito concettuale** per tutto ciò che seguirà. Nell'inferenza bayesiana, i parametri dei modelli, come la probabilità di successo θ in un modello binomiale, o la media μ di una distribuzione normale, sono trattati essi stessi come variabili casuali. La distribuzione a priori $p(\theta)$ esprime l'incertezza iniziale sul valore del parametro, mentre la distribuzione a posteriori $p(\theta \mid \text{dati})$ esprime l'incertezza aggiornata dopo l'osservazione dei dati.

Senza il concetto di variabile casuale, non sarebbe nemmeno possibile formulare domande come: "Qual è la probabilità che l'efficacia del trattamento superi una certa soglia clinicamente rilevante?" Domande che, al contrario, sono fondamentali per la pratica bayesiana.

6.3. Variabili casuali discrete

La distinzione più fondamentale tra le variabili casuali riguarda la natura dell'insieme dei valori che possono assumere. Una variabile casuale è detta **discreta** quando l'insieme dei suoi valori possibili è finito o numerabile, ovvero quando tali valori possono essere elencati in una sequenza (eventualmente infinita).

Definizione 6.2 (Variabile casuale discreta). Una variabile casuale X è *discreta* se esiste un insieme finito o numerabile

$$\mathcal{X} = \{x_1, x_2, \dots\}$$

tale che

$$P(X \in \mathcal{X}) = 1.$$

In altre parole, X assume con certezza uno dei valori appartenenti all'insieme $\mathcal{X}$.

6.3.1. Esempi in psicologia

Le variabili casuali discrete compaiono in numerosi contesti della ricerca e della pratica psicologica:

- **Punteggi grezzi nei test:** il numero di risposte corrette in un test cognitivo (valori da 0 a n , dove n è il numero di item).
- **Scale Likert:** i punteggi su singoli item o su scale composite con valori discreti (ad esempio, da 1 a 5 o da 1 a 7).
- **Conteggi di comportamenti:** il numero di episodi di abbuffata in una settimana, il numero di risvegli notturni, il numero di interazioni sociali.
- **Categorie diagnostiche codificate:** quando si assegnano codici numerici a categorie (0 = assente, 1 = lieve, 2 = moderato, 3 = grave).

- **Numero di criteri soddisfatti:** in una valutazione diagnostica, quanti criteri del DSM-5 sono soddisfatti per una certa condizione.

La caratteristica distintiva delle variabili discrete è che tra due valori consecutivi **non esistono valori intermedi**: non è possibile osservare, per esempio, 2.7 risposte corrette su 5, né un punteggio Likert di 3.5 su una scala da 1 a 5.

6.4. Funzione di massa di probabilità

Per descrivere completamente una variabile casuale discreta è sufficiente specificare la probabilità associata a ciascun valore possibile. Questa specificazione prende il nome di **funzione di massa di probabilità**.

Definizione 6.3 (Funzione di massa di probabilità (PMF)). La *funzione di massa di probabilità* di una variabile casuale discreta X è la funzione

$$p_X : \mathcal{X} \rightarrow [0, 1]$$

definita da

$$p_X(x) = P(X = x)$$

per ogni $x \in \mathcal{X}$.

La PMF deve soddisfare due condizioni fondamentali, che discendono direttamente dagli assiomi di coerenza della probabilità:

1. Non-negatività

$$p_X(x) \geq 0 \quad \text{per ogni } x \in \mathcal{X}.$$

2. Normalizzazione

$$\sum_{x \in \mathcal{X}} p_X(x) = 1.$$

Una volta nota la funzione di massa di probabilità, è possibile calcolare la probabilità di qualunque evento relativo alla variabile X . Per un sottoinsieme $B \subseteq \mathcal{X}$ vale infatti:

$$P(X \in B) = \sum_{x \in B} p_X(x).$$

6.4.1. Ponte applicativo: la PMF nella pratica clinica

Quando uno psicologo riporta che, su una scala di esito del trattamento, “il 15% dei pazienti mostra remissione completa (4), il 35% miglioramento sostanziale (3), il 30% miglioramento parziale (2), il 15% nessun cambiamento (1) e il 5% peggioramento (0)”, sta implicitamente descrivendo una PMF:

x (esito)	0	1	2	3	4
$p_X(x)$	0.05	0.15	0.30	0.35	0.15

Questa tabella soddisfa entrambe le proprietà richieste: tutti i valori sono non-negativi e la loro somma è 1. Da questa PMF possiamo calcolare, ad esempio, la probabilità di un esito positivo (miglioramento parziale o superiore):

$$P(X \geq 2) = p_X(2) + p_X(3) + p_X(4) = 0.30 + 0.35 + 0.15 = 0.80.$$

i Esempio: PMF del punteggio in un test a 5 item

Derivazione completa della distribuzione

Riprendiamo il test di memoria di lavoro a 5 item. Supponiamo che ogni risposta sia corretta con probabilità $p = 0.7$, indipendentemente dalle altre. La variabile casuale X (numero di risposte corrette) può assumere valori compresi tra 0 e 5.

Per ogni valore x , il numero di sequenze con esattamente x risposte corrette è $\binom{5}{x}$, e ciascuna di queste sequenze ha probabilità $(0.7)^x(0.3)^{5-x}$. Pertanto:

$$p_X(x) = \binom{5}{x} (0.7)^x (0.3)^{5-x}.$$

La distribuzione completa risulta:

x	0	1	2	3	4	5
$p_X(x)$	0.0024	0.0284	0.1323	0.3087	0.3601	0.1681

Si osservi che la distribuzione è asimmetrica, con la moda (valore più probabile) a $x = 4$. La probabilità di ottenere almeno 3 risposte corrette è:

$$P(X \geq 3) = 0.3087 + 0.3601 + 0.1681 = 0.8369.$$

Questa è esattamente la struttura della **distribuzione binomiale**, che studieremo in dettaglio nel capitolo sulle famiglie di distribuzioni.

6.4.2. Connessione con il percorso bayesiano

La PMF che abbiamo appena costruito, ovvero quella relativa al numero di successi in n prove con probabilità p , è una delle **funzione di verosimiglianza** più importanti nei modelli bayesiani. Quando osserviamo k successi su n prove e vogliamo stimare la probabilità di successo θ , la verosimiglianza è proprio:

$$L(\theta|k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}.$$

Comprendere la PMF significa quindi comprendere una delle due componenti essenziali dell'inferenza bayesiana (l'altra è la distribuzione a priori).

i Esempio: PMF della somma di due dadi

Un esempio per consolidare l'intuizione

Consideriamo il lancio di due dadi equilibrati, un esempio classico che, pur essendo distante dalla pratica psicologica, illustra con particolare chiarezza la struttura combinatoria alla base della PMF.

Lo spazio campionario è costituito dalle 36 coppie ordinate:

$$\Omega = \{(1, 1), (1, 2), \dots, (6, 5), (6, 6)\}.$$

Definiamo la variabile casuale X che associa a ogni coppia (i, j) la somma dei valori:

$$X(i, j) = i + j.$$

La somma può assumere valori da 2 a 12. Per ciascun valore, contiamo quante coppie lo producono:

x	2	3	4	5	6	7	8	9	10	11	12
Ca- si	1	2	3	4	5	6	5	4	3	2	1
$p_X(x)$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

La simmetria della distribuzione attorno al valore 7 riflette la struttura combinatoria del problema. Questa forma “triangolare” è un primo esempio di come la struttura del processo generativo (in questo caso, la somma di due quantità uniformi) determini la forma della distribuzione.

Un'analogia psicometrica: se un punteggio composito è la somma di due subscale ciascuna uniformemente distribuita su 1-6, allora la distribuzione del punteggio totale avrà esattamente questa forma triangolare.

6.5. Verifica computazionale della PMF

Le simulazioni al computer costituiscono uno strumento efficace per **verificare empiricamente** le proprietà teoriche di una funzione di massa di probabilità. Generando un gran numero di realizzazioni della variabile casuale, è possibile osservare come le frequenze relative tendano a convergere verso le probabilità teoriche.

```
set.seed(42)

# Simulazione del test a 5 item con p = 0.7
n_sim <- 100000
n_item <- 5
p_corretto <- 0.7


# Generiamo le risposte per tutti i partecipanti simulati
punteggi <- rbinom(n_sim, size = n_item, prob = p_corretto)

# Frequenze empiriche
freq_emp <- table(factor(punteggi, levels = 0:5)) / n_sim
```

```
# Probabilità teoriche (distribuzione binomiale)
valori <- 0:5
prob_teor <- dbinom(valori, size = n_item, prob = p_corretto)

# Confronto
df_confronto <- data.frame(
  x = valori,
  empirica = as.numeric(freq_emp),
  teorica = prob_teor
)

ggplot(df_confronto, aes(x = x)) +
  geom_col(aes(y = empirica), alpha = 0.7, width = 0.6) +
  geom_point(aes(y = teorica), size = 3) +
  geom_line(aes(y = teorica), linewidth = 1) +
  scale_x_continuous(breaks = 0:5) +
  labs(
    x = "Numero di risposte corrette",
    y = "Probabilità",
    title = "PMF del punteggio in un test a 5 item (p = 0.7)"
  )
)
```



La convergenza delle frequenze empiriche verso le probabilità teoriche **non definisce** la distribuzione di probabilità, ma ne verifica la coerenza interna. La simulazione mostra che un sistema di credenze coerente genera il comportamento atteso quando viene sottoposto a ripetute osservazioni.

6.6. Variabili casuali continue

Molte grandezze psicologiche non possono essere rappresentate adeguatamente da variabili discrete. Il tempo di reazione in un compito cognitivo, il livello di cortisolo in una misurazione fisiologica, la latenza di una risposta comportamentale, o anche i punteggi su scale psicometriche quando vengono

trattati come misure continue di un costrutto latente — tutte queste quantità possono assumere, almeno in linea di principio, **qualsiasi valore** all'interno di un intervallo continuo.

Definizione 6.4 (Variabile casuale continua). Una variabile casuale X è *continua* se esiste una funzione non negativa

$$f_X : \mathbb{R} \rightarrow [0, +\infty),$$

detta *funzione di densità di probabilità* (PDF), tale che per ogni intervallo $[a, b]$ valga:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

Questa definizione esprime un cambiamento concettuale importante rispetto al caso discreto: la probabilità non è più assegnata a singoli valori, ma a **intervalli** della retta reale.

6.6.1. Esempi in psicologia

Le variabili casuali continue sono ampiamente utilizzate nella ricerca psicologica:

- **Tempi di reazione:** la latenza di risposta in compiti cognitivi, tipicamente misurata in millisecondi.
- **Misure fisiologiche:** livelli di cortisolo, frequenza cardiaca, conduttanza cutanea.
- **Punteggi standardizzati:** quando i punteggi grezzi vengono trasformati in scale continue (z-score, T-score, percentili).
- **Variabili latenti:** i costrutti psicologici non osservabili direttamente (come l'intelligenza, l'ansia di tratto e l'apertura mentale) sono solitamente modellati come variabili continue.
- **Effetti stimati:** le dimensioni dell'effetto, i coefficienti di regressione, le differenze tra le medie.

6.7. Funzione di densità di probabilità

La funzione di densità di probabilità svolge per le variabili continue un ruolo analogo a quello della PMF per le variabili discrete, ma con una differenza cruciale. Il valore $f_X(x)$ **non rappresenta** la probabilità che la variabile assuma esattamente il valore x .

Infatti, per una variabile casuale continua vale sempre:

$$P(X = x_0) = \int_{x_0}^{x_0} f_X(x) dx = 0.$$

Questo risultato, che può apparire controintuitivo, riflette la struttura del continuo: esistono infiniti valori possibili, e non è possibile assegnare a ciascun punto una probabilità positiva mantenendo la normalizzazione. La probabilità non è concentrata nei punti, ma **distribuita sugli intervalli**.

6.7.1. Come interpretare la densità

La densità $f_X(x)$ può essere interpretata come una misura della **concentrazione della probabilità**. Valori elevati di $f_X(x)$ indicano le regioni della retta reale in cui la variabile è più probabile che assuma un determinato valore, nel senso che gli intervalli di piccole dimensioni attorno a quei punti hanno una probabilità relativamente maggiore.

Un'analogia utile: se la probabilità fosse acqua e la retta reale fosse un contenitore, la densità $f_X(x)$ indicherebbe l'altezza dell'acqua nel punto x . La quantità totale di acqua (ovvero la probabilità totale) è sempre pari a 1, ma può essere distribuita in modo più o meno concentrato in diverse regioni.

Teorema 6.1 (Proprietà delle funzioni di densità di probabilità). *Una funzione $f_X(x)$ è una valida funzione di densità di probabilità se e solo se soddisfa le seguenti condizioni:*

1. **Non-negatività**

$$f_X(x) \geq 0 \quad \text{per ogni } x \in \mathbb{R}.$$

2. **Normalizzazione**

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1.$$

È importante notare che il valore della densità $f_X(x)$ può superare 1: ciò non viola alcun principio, in quanto $f_X(x)$ non rappresenta una probabilità. Solo l'**integrale** della densità su un intervallo restituisce una probabilità. In termini geometrici, la probabilità $P(a \leq X \leq b)$ corrisponde all'**area all'area sottesa dalla curva** di $f_X(x)$ tra a e b .

6.7.2. Ponte applicativo: la PDF nella valutazione clinica

Quando un clinico afferma che “i punteggi del BDI-II nella popolazione generale seguono approssimativamente una distribuzione normale con media 10 e deviazione standard 8”, sta implicitamente specificando una PDF. Da questa distribuzione è possibile calcolare, ad esempio:

- La probabilità che un individuo estratto casualmente abbia un punteggio superiore a 20 (soglia per depressione lieve).
- L'intervallo entro cui cade il 95% centrale della popolazione.
- La probabilità di osservare un punteggio estremo come quello di un particolare paziente.

Questi calcoli sono fondamentali per interpretare i punteggi individuali nel contesto della variabilità normale.

i Esempio: tempo di reazione in un compito cognitivo

Probabilità come area sotto la curva

Consideriamo una variabile casuale continua T che rappresenta il tempo di reazione (in millisecondi) in un compito di decisione lessicale. I tempi di reazione sono solitamente modellati con distribuzioni asimmetriche positive; una scelta comune è la distribuzione **log-normale**. Supponiamo che la variabile T segua una distribuzione log-normale con parametri $\mu = 5.7$ e $\sigma = 0.3$. Ciò significa che il logaritmo naturale del tempo di reazione segue una distribuzione normale: $\ln(T) \sim N(5.7, 0.3^2)$.

La funzione di densità di probabilità è:

$$f_T(t) = \frac{1}{t\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln(t) - \mu)^2}{2\sigma^2}\right) \quad \text{per } t > 0$$

e $f_T(t) = 0$ per $t \leq 0$.

```
# Parametri della distribuzione log-normale
mu <- 5.7 # media del log(T)
sigma <- 0.3 # deviazione standard del log(T)

# Statistiche descrittive della distribuzione
mediana_T <- exp(mu)
media_T <- exp(mu + sigma^2 / 2)
```

```
#> Mediana del tempo di reazione: 299 ms
```

```
#> Media del tempo di reazione: 313 ms
```

La mediana (298 ms) è inferiore alla media (312 ms) perché la distribuzione è asimmetrica a destra, una caratteristica tipica dei tempi di reazione.

La probabilità che il tempo di reazione cada in un certo intervallo si ottiene integrando la densità:

$$P(300 \leq T \leq 400) = \int_{300}^{400} f_T(t) dt$$

```
# Calcolo tramite la CDF
prob_300_400 <- plnorm(400, meanlog = mu, sdlog = sigma) -
  plnorm(300, meanlog = mu, sdlog = sigma)
```


```
#> P(300 <= T <= 400): 0.329
```

Questa probabilità (circa 47%) rappresenta l'area sotto la curva di densità compresa tra 300 e 400 ms.

```
# Visualizzazione
t_vals <- seq(150, 600, length.out = 500)
df_rt <- data.frame(
  t = t_vals,
  densita = dlnorm(t_vals, meanlog = mu, sdlog = sigma)
)

# Area da evidenziare
df_area <- df_rt[df_rt$t >= 300 & df_rt$t <= 400, ]

ggplot(df_rt, aes(x = t, y = densita)) +
  geom_area(data = df_area, aes(x = t, y = densita),
    alpha = 0.4) +
  geom_line(linewidth = 1) +
  geom_vline(xintercept = c(300, 400), linetype = "dashed", alpha = 0.5) +
  labs(
    x = "Tempo di reazione (ms)",
    y = "Densità di probabilità",
    title = "Distribuzione dei tempi di reazione"
  ) +
  annotate("text", x = 350, y = 0.002,
    label = paste0("P = ", round(prob_300_400, 3)))
```



L'area ombreggiata rappresenta la probabilità che il tempo di reazione cada tra 300 e 400 ms. Nelle funzioni di densità di probabilità, il valore della funzione può talvolta superare 1. Ciò non rappresenta un problema o un errore, poiché la densità stessa non è una probabilità, ma una misura di concentrazione.

6.7.3. Connessione con il percorso bayesiano

La distinzione tra PMF e PDF diventa centrale quando specifichiamo le distribuzioni nel modello bayesiano. Per un parametro come una **proporzione** (che può assumere qualsiasi valore compreso tra 0 e 1), useremo una densità continua — tipicamente la distribuzione Beta. Per il **numero di**

successi osservati (assumere solo i valori 0, 1, 2, ..., n), useremo invece una distribuzione discreta, ovvero la distribuzione binomiale.

La distribuzione a priori $p(\theta)$ su un parametro continuo è sempre una PDF; la verosimiglianza $p(\text{dati} \mid \theta)$ per dati discreti è una PMF rispetto ai dati possibili, ma una funzione continua di θ .

6.8. Funzione di distribuzione cumulativa

Esiste una descrizione della distribuzione di probabilità che vale **sia per le variabili discrete che per quelle continue** e che specifica direttamente la probabilità che la variabile assuma valori inferiori o uguali a una determinata soglia. Questa descrizione è fornita dalla **funzione di distribuzione cumulativa**.

Definizione 6.5 (Funzione di distribuzione cumulativa (CDF)). La *funzione di distribuzione cumulativa* di una variabile casuale X è la funzione

$$F_X : \mathbb{R} \rightarrow [0, 1]$$

definita da

$$F_X(x) = P(X \leq x).$$

Dal punto di vista epistemico, $F_X(x)$ rappresenta il grado di credenza che il valore della variabile casuale X non superi la soglia x . Questa interpretazione rende la CDF particolarmente utile per rispondere a domande come: “Qual è la probabilità che il punteggio sia inferiore a questa soglia clinica?”.

6.8.1. Relazione con PMF e PDF

La funzione di distribuzione cumulativa **caratterizza completamente** la distribuzione di probabilità. Da essa è possibile ricavare:

- la *funzione di massa di probabilità* nel caso discreto;
- la *funzione di densità di probabilità* nel caso continuo.

Per le variabili casuali continue vale la relazione fondamentale:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \quad f_X(x) = \frac{d}{dx} F_X(x),$$

ovvero la CDF è l'integrale cumulativo della densità e, viceversa, la densità è la derivata della CDF.

Nel caso discreto, la CDF cresce per *salti*, ciascuno dei quali ha un'ampiezza pari alla probabilità del valore corrispondente:

$$F_X(x) = \sum_{x_i \leq x} p_X(x_i).$$

Teorema 6.2 (Proprietà della funzione di distribuzione cumulativa). *Ogni funzione di distribuzione cumulativa soddisfa le seguenti proprietà:*

1. **Monotonia non decrescente:** per ogni $a < b$,

$$F_X(a) \leq F_X(b).$$

2. **Comportamento asintotico:**

$$\lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow +\infty} F_X(x) = 1.$$

3. **Continuità da destra:** per ogni $x \in \mathbb{R}$,

$$\lim_{h \rightarrow 0^+} F_X(x + h) = F_X(x).$$

6.8.2. Ponte applicativo: uso della CDF per i cut-off clinici

La CDF è lo strumento naturale per calcolare la proporzione di individui che cadono sotto (o sopra) una certa soglia. Se il punteggio X al PHQ-9 nella popolazione clinica segue una certa distribuzione, allora:

- $F_X(9)$ = probabilità che un paziente abbia un punteggio ≤ 9 (depressione minima)
- $1 - F_X(19)$ = probabilità di depressione grave (punteggio > 19)
- $F_X(14) - F_X(9)$ = probabilità di depressione moderata (10-14)


Queste probabilità sono fondamentali per interpretare le proprietà delle scale di screening.

i Esempio: CDF del punteggio nel test a 5 item

```
# CDF per il test a 5 item con p = 0.7
valori <- 0:5
prob <- dbinom(valori, size = 5, prob = 0.7)
cdf <- pbinom(valori, size = 5, prob = 0.7)

# Dati per il grafico a gradini
df_cdf <- data.frame(
  x_start = c(-0.5, valori),
  x_end = c(valori, 5.5),
  y = c(0, cdf)
)

ggplot() +
  geom_segment(
    data = df_cdf,
    aes(x = x_start, xend = x_end, y = y, yend = y),
    linewidth = 1
  ) +
  geom_point(
    data = data.frame(x = valori, y = cdf),
    aes(x = x, y = y),
    size = 3
  ) +
  scale_x_continuous(breaks = 0:5, limits = c(-0.5, 5.5)) +
  scale_y_continuous(breaks = seq(0, 1, 0.2)) +
  labs(
    x = "x (numero di risposte corrette)",
    y = expression(F[X](x) == P(X <= x)),
    title = "CDF del punteggio nel test a 5 item"
  )
```



Nel grafico, ogni **salto** della funzione corrisponde a un possibile valore del punteggio. L'altezza

del salto in x è pari alla probabilità $P(X = x)$. Ad esempio, il salto da $F_X(3)$ a $F_X(4)$ ha ampiezza 0.36, che corrisponde esattamente a $p_X(4)$.

Da questo grafico si può leggere direttamente che:

- $P(X \leq 2) = F_X(2) \approx 0.16$;
- $P(X \leq 3) = F_X(3) \approx 0.47$;
- $P(X \geq 4) = 1 - F_X(3) \approx 0.53$.

6.8.3. Connessione con il percorso bayesiano

La CDF è lo strumento fondamentale per calcolare gli **intervalli di credibilità** nell'inferenza bayesiana. Se il parametro θ ha una distribuzione a posteriori $p(\theta \mid \text{dati})$ e una CDF $F_\theta(t)$, allora:

- il **quantile** q_α tale che $F_\theta(q_\alpha) = \alpha$ indica il valore sotto il quale cade una proporzione α della massa a posteriori;
- l'**intervallo di credibilità al 95%** è tipicamente $[q_{0.025}, q_{0.975}]$;
- la **probabilità a posteriori** che il valore di θ superi una soglia θ_0 è data da $1 - F_\theta(\theta_0)$.

Queste operazioni sono al centro dell'inferenza bayesiana e richiedono una buona padronanza della CDF.

6.9. Variabili casuali multiple

In molti contesti sperimentali e clinici è necessario modellare **più fenomeni aleatori simultaneamente**. In uno studio sulla comorbidità tra ansia e depressione, ad esempio, è necessario rappresentare congiuntamente i punteggi su entrambe le scale. Nello studio della memoria, ad esempio, potremmo voler modellare insieme accuratezza e tempo di risposta. Nell'analisi delle misure ripetute, l'incertezza riguarda i valori osservati in momenti diversi.

Il framework probabilistico si estende naturalmente a questi contesti **multivariati**: invece di descrivere l'incertezza relativa a una singola variabile casuale, si descrive l'incertezza relativa alla **combinazione dei valori** assunti da più variabili.

6.9.1. Distribuzione congiunta

Definizione 6.6 (Distribuzione congiunta). Siano X e Y due variabili casuali discrete. La *funzione di massa di probabilità congiunta* è definita come

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

Essa assegna una probabilità a ciascuna possibile coppia di valori (x, y) assunta congiuntamente dalle due variabili.

La distribuzione congiunta fornisce la **descrizione più completa** dello stato di credenza riguardo alle variabili considerate: tutte le altre quantità probabilistiche possono essere derivate da essa.

6.9.2. Esempio: ansia e depressione

Supponiamo di classificare i pazienti in base a tre livelli di ansia (bassa, media, alta) e tre livelli di depressione (bassa, media, alta). La distribuzione congiunta potrebbe essere la seguente:

	Depr. bassa	Depr. media	Depr. alta
Ansia bassa	0.25	0.10	0.05
Ansia media	0.08	0.15	0.07
Ansia alta	0.02	0.08	0.20

La somma di tutte le celle è 1. La probabilità di osservare un paziente con ansia alta e depressione alte è $p_{X,Y}(\text{alta}, \text{alta}) = 0.20$.

6.9.3. Distribuzioni marginali

Le *distribuzioni marginali* si ottengono eliminando una variabile dalla distribuzione congiunta e sommando i valori della variabile da eliminare.

$$p_X(x) = \sum_y p_{X,Y}(x, y), \quad p_Y(y) = \sum_x p_{X,Y}(x, y).$$

Nell'esempio precedente:

- $p_X(\text{ansia alta}) = 0.02 + 0.08 + 0.20 = 0.30$;
- $p_Y(\text{depr. alta}) = 0.05 + 0.07 + 0.20 = 0.32$.

Dal punto di vista epistemico, la marginalizzazione corrisponde all'ignorare una delle variabili, concentrandosi esclusivamente sull'incertezza relativa all'altra.

6.9.4. Indipendenza stocastica

Le variabili casuali X e Y si dicono **stocasticamente indipendenti** se e solo se la loro distribuzione congiunta si scompone nel prodotto delle distribuzioni marginali:

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y) \quad \text{per ogni } (x, y).$$

Questa condizione esprime l'assenza di qualsiasi relazione informativa: conoscere il valore assunto da una variabile **non modifica** la distribuzione dell'altra.

Nella tabella di esempio, ansia e depressione **non** sono indipendenti. Se lo fossero, dovremmo avere:

$$p_{X,Y}(\text{alta}, \text{alta}) = p_X(\text{alta}) \cdot p_Y(\text{alta}) = 0.30 \times 0.32 = 0.096.$$

Ma il valore osservato è 0.20, molto superiore: le due condizioni tendono a co-occorrere più di quanto ci si aspetterebbe in caso di indipendenza. Questa è la struttura della **comorbidità**.

6.9.5. Ponte applicativo: perché le variabili multiple sono cruciali

Nella pratica clinica, raramente ci interessa una singola variabile presa in isolamento. Le relazioni tra ansia e depressione, tra sintomi e funzionamento, tra processi cognitivi e comportamento manifesto richiedono tutte di modellare distribuzioni congiunte.

Nell'inferenza bayesiana, le variabili multiple sono costantemente presenti. Quando abbiamo più parametri nel modello, come la media e la varianza o gli effetti fissi e casuali, la distribuzione a posteriori è una distribuzione congiunta su tutti i parametri. Comprendere come le distribuzioni congiunte si scompongono in marginali e come l'indipendenza semplifica i calcoli è essenziale per poter utilizzare questi modelli.

6.9.6. Connessione con il percorso bayesiano

La struttura delle variabili casuali multiple è il fondamento per comprendere concetti avanzati che incontreremo:

- **Gerarchie di parametri:** nei modelli multilivello, i parametri di livello inferiore (ad esempio, gli effetti individuali) hanno una distribuzione condizionata ai parametri di livello superiore (ad esempio, i parametri di gruppo).
- **Modelli grafici:** le reti bayesiane rappresentano le relazioni di dipendenza condizionata tra variabili attraverso grafi.
- **Marginalizzazione:** il calcolo della distribuzione a posteriori marginale di un singolo parametro richiede l'integrazione (o marginalizzazione) rispetto agli altri parametri.

Riflessioni conclusive

Il concetto di **variabile casuale** costituisce il ponte fondamentale tra la teoria della probabilità, intesa come sistema di credenze coerenti, e l'analisi quantitativa dei fenomeni psicologici. Grazie a questa formalizzazione, qualsiasi risultato, che si tratti di un punteggio, di un tempo o di un conteggio, può essere tradotto in un oggetto matematico sul quale è possibile applicare gli strumenti del calcolo delle probabilità.

Le due principali classi di variabili casuali, **discrete** e **continue**, richiedono formalizzazioni tecniche differenti (somme vs integrali), ma si basano sullo stesso principio: descrivere la distribuzione della credenza nello spazio dei possibili valori. La *funzione di massa di probabilità* (PMF) per variabili discrete e la *funzione di densità di probabilità* (PDF) per le variabili continue svolgono ruoli analoghi, mentre la *funzione di distribuzione cumulativa* (CDF) fornisce una rappresentazione unificante.

Per lo psicologo che si avvicina all'inferenza bayesiana, questi concetti non sono astrazioni matematiche fini a sé stesse, ma il **vocabolario necessario** per:

- specificare le distribuzioni a priori sui parametri di interesse;
- comprendere la funzione di verosimiglianza che connette parametri e dati;
- interpretare le distribuzioni a posteriori e gli intervalli di credibilità;
- formulare domande probabilistiche sui fenomeni psicologici.

Nei capitoli successivi studieremo le **famiglie parametriche di distribuzioni**, come la distribuzione Beta, la distribuzione Normale, la distribuzione Binomiale, la distribuzione di Poisson e altre, che costituiscono i mattoni elementari della modellazione bayesiana. Ogni distribuzione codifica specifiche assunzioni sul processo generativo dei dati; comprendere le variabili casuali significa essere pronti a scegliere e interpretare queste distribuzioni in modo consapevole.

Punti chiave da ricordare

! Importante**Concetti essenziali:****1. Variabile casuale come funzione**

- $X : \Omega \rightarrow \mathbb{R}$ associa a ogni esito un valore numerico;
- la funzione è deterministica; l'incertezza riguarda quale esito si realizzerà;
- permette di passare da eventi qualitativi a quantità analizzabili.

2. Discrete vs Continue

- **discrete**: valori numerabili (punteggi, conteggi);
- **continue**: valori in intervalli (tempi, misure fisiologiche);
- richiedono strumenti diversi: somme vs integrali.

3. PMF per variabili discrete

- $p_X(x) = P(X = x)$ è una probabilità vera e propria;
- $\sum_x p_X(x) = 1$.

4. PDF per variabili continue

- $f_X(x)$ è una densità, non una probabilità;
- $P(a \leq X \leq b) = \int_a^b f_X(x) dx$;
- $P(X = x) = 0$ per ogni x specifico.

5. CDF come rappresentazione unificata

- $F_X(x) = P(X \leq x)$ funziona per entrambi i tipi;
- fondamentale per quantili e intervalli di credibilità.

6. Variabili multiple

- la distribuzione congiunta descrive l'incertezza su combinazioni di valori;
- marginalizzazione: eliminare una variabile sommando/integrando;
- indipendenza: $p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y)$.

Formule essenziali:

$$\text{PMF: } p_X(x) = P(X = x), \quad \sum_x p_X(x) = 1$$

$$\text{PDF: } P(a \leq X \leq b) = \int_a^b f_X(x) dx, \quad \int_{-\infty}^{+\infty} f_X(x) dx = 1$$

$$\text{CDF: } F_X(x) = P(X \leq x)$$

$$\text{Marginale: } p_X(x) = \sum_y p_{X,Y}(x, y)$$

Per il prossimi capitoli:

Studieremo le famiglie di distribuzioni parametriche (Bernoulli, Binomiale, Normale, Beta...) che costituiscono il vocabolario della modellazione bayesiana. Ogni distribuzione codifica assunzioni specifiche sul processo generativo dei dati.

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2        ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51           labeling_0.4.3        bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8       curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8          purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1         xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.3        scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-1        rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0           RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0        parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-5          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1    glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6         QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9      Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5    rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9       backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13         snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1        gridExtra_2.3.1       nlme_3.1-169
#> [67] checkmate_2.3.4      xfun_0.60             pkgconfig_2.0.3

```

7. Distribuzioni di massa e di densità

Introduzione

Nel capitolo precedente (1) abbiamo introdotto le **variabili casuali** come funzioni che associano valori numerici agli esiti di un esperimento aleatorio. Abbiamo distinto tra variabili casuali **discrete**, che assumono un insieme finito o numerabile di valori, e variabili casuali **continue**, che possono assumere qualsiasi valore all'interno di un intervallo. Per ciascun caso, abbiamo definito formalmente la *funzione di massa di probabilità* (PMF) e la *funzione di densità di probabilità* (PDF) come strumenti fondamentali per descrivere l'incertezza sui valori assunti dalla variabile.

Questo capitolo ha lo scopo di approfondire la **comprensione intuitiva, geometrica e operativa** di tali concetti. Vedremo come la PMF assegni “pesi” discreti a singoli valori, mentre la PDF distribuisca la probabilità in modo continuo lungo la retta reale, rendendo necessario l'uso dell'integrazione per calcolare la probabilità associata a intervalli di valori. In questo contesto affronteremo anche il noto “paradosso” secondo cui, per una variabile casuale continua, la probabilità di osservare un valore esatto è sempre pari a zero, mostrando come questa proprietà non sia affatto paradossale, ma una conseguenza naturale della struttura matematica del continuo.

Un aspetto centrale della trattazione riguarda inoltre la **distinzione interpretativa** tra l'approccio frequentista e quello bayesiano alle distribuzioni di probabilità. Nel paradigma frequentista, la funzione di densità descrive il comportamento dei dati in ipotetiche ripetizioni dell'esperimento. Nell'approccio bayesiano, invece, la PDF rappresenta il **grado di credenza** assegnato ai possibili valori di una quantità incerta, come un parametro o una grandezza latente. Questa differenza concettuale, apparentemente sottile, ha implicazioni profonde per il modo in cui interpretiamo le distribuzioni, calcoliamo le probabilità e traiamo conclusioni inferenziali.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- 1 – **fondamentale**

Questo capitolo approfondisce i concetti di PMF e PDF introdotti nel Capitolo 6, fornendo una comprensione intuitiva, geometrica e operativa.

Conoscenze matematiche richieste:

- Appendice F - per comprendere l'integrale come area sotto una curva
- Familiarità con il concetto di limite per capire il passaggio da istogrammi a densità continue

Lecture complementari consigliate:

- Blitzstein, J. K., & Hwang, J. (2019). *Introduction to Probability* (2nd ed.), capitolo “Random variables and their distributions” (Blitzstein & Hwang, 2019)

Panoramica del capitolo

- Distinzione operativa tra massa di probabilità e densità di probabilità.
- Dagli istogrammi alle funzioni di densità: il limite continuo.
- Il “paradosso” della probabilità zero per valori esatti.
- La funzione di distribuzione cumulativa come rappresentazione unificata.
- Interpretazioni bayesiana e frequentista delle distribuzioni.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

7.1. Dalla massa alla densità di probabilità

La distinzione tra variabili casuali **discrete** e **continue** non è solo tecnica: riflette due modi profondamente diversi in cui la probabilità si distribuisce sui valori possibili. Nel caso discreto, si può assegnare una probabilità positiva a ogni singolo valore; nel caso continuo, invece, la probabilità non si concentra su punti isolati ma si **distribuisce su un continuum**, per cui sono assegnabili solo le probabilità associate a intervalli.

Questa differenza concettuale è cruciale per comprendere correttamente il ruolo delle funzioni di massa e di densità di probabilità.

7.2. La funzione di massa di probabilità

Per una variabile casuale discreta X che assume valori nell'insieme

$$\mathcal{X} = x_1, x_2, \dots,$$

la **funzione di massa di probabilità** (PMF) associa a ciascun valore possibile la probabilità corrispondente:

$$p_X(x) = P(X = x).$$

Il termine *massa* evoca una metafora fisica appropriata: la probabilità può essere immaginata come una collezione di **pesi discreti** collocati sui valori possibili della variabile. Ogni valore x_i è associato a una quantità $p_X(x_i)$ e la somma totale delle masse deve essere pari a 1. In questo contesto, è perfettamente lecito “concentrare” una parte rilevante della probabilità in pochi punti specifici.

Esempio: soddisfazione lavorativa su scala Likert

Distribuzione tipica delle risposte

Consideriamo le risposte a un item sulla soddisfazione lavorativa, misurata su una scala Likert a 5 punti (1 = “molto insoddisfatto”, 5 = “molto soddisfatto”). In molte popolazioni lavorative, le risposte tendono a concentrarsi sui valori centrali e moderatamente positivi, con una distribuzione asimmetrica:

7. Distribuzioni di massa e di densità

Risposta	1 (molto insod.)	2	3	4	5 (molto sodd.)
$p_X(x)$	0.05	0.10	0.25	0.40	0.20

Questa PMF riflette un pattern tipico: pochi lavoratori dichiarano una forte insoddisfazione, la maggior parte si colloca su livelli moderati o buoni, e una minoranza esprime una piena soddisfazione. La coerenza della distribuzione è immediatamente verificabile:

$$\sum_{x=1}^5 p_X(x) = 0.05 + 0.10 + 0.25 + 0.40 + 0.20 = 1.$$


Simulando 10,000 risposte secondo questa distribuzione e confrontando le frequenze empiriche con la PMF teorica, osserviamo una chiara convergenza:

```
set.seed(123)
prob_teoriche <- c(0.05, 0.10, 0.25, 0.40, 0.20)
n_risposte <- 10000

risposte <- sample(1:5, size = n_risposte, replace = TRUE, prob = prob_teoriche)
freq_rel <- table(risposte) / n_risposte

df <- data.frame(
  valore = 1:5,
  empirica = as.numeric(freq_rel),
  teorica = prob_teoriche
)

ggplot(df, aes(x = factor(valore))) +
  geom_col(aes(y = empirica), alpha = 0.7, width = 0.6) +
  geom_point(aes(y = teorica), size = 4) +
  scale_fill_binary() +
  labs(
    x = "Livello di soddisfazione",
    y = "Probabilità / Frequenza relativa",
    title = "PMF della soddisfazione lavorativa (scala Likert 1-5)"
  )
```



Da questa distribuzione possiamo calcolare probabilità di interesse pratico. Ad esempio, la probabilità che un lavoratore riporti almeno un livello di soddisfazione “buono” (4 o 5) è:

$$P(X \geq 4) = p_X(4) + p_X(5) = 0.40 + 0.20 = 0.60.$$

La probabilità di insoddisfazione (1 o 2) è invece:

$$P(X \leq 2) = p_X(1) + p_X(2) = 0.05 + 0.10 = 0.15.$$

Questa convergenza tra frequenze empiriche e probabilità teoriche non **definisce** le probabilità, ma ne verifica la coerenza: un sistema di credenze coerente produce il comportamento empirico atteso quando viene sottoposto a prove ripetute.

7.3. La funzione di densità di probabilità

Nel caso delle variabili casuali continue, questo approccio non è più possibile. Non è possibile assegnare probabilità positive ai singoli valori, in quanto i punti sono infiniti e la somma delle probabilità divergerebbe. La soluzione concettuale consiste nel passare dalla “massa” alla “densità”.

Invece di chiederci quanta probabilità c'è *in* un punto, ci chiediamo quanta probabilità c'è *attorno* a un punto per unità di lunghezza.

Definizione 7.1 (Funzione di densità di probabilità). Una funzione

$$f_X : \mathbb{R} \rightarrow [0, +\infty)$$

è una *funzione di densità di probabilità* (PDF) per una variabile casuale continua X se, per ogni intervallo $[a, b] \subseteq \mathbb{R}$,

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx,$$

e se soddisfa la condizione di normalizzazione

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1.$$

La densità $f_X(x)$ misura la **concentrazione locale della probabilità** in prossimità del punto x . Un valore elevato di $f_X(x)$ indica che, in un intorno molto piccolo di x , si concentra una probabilità relativamente maggiore rispetto alle regioni con densità inferiore.

È importante notare che la densità non rappresenta una probabilità puntuale: per una variabile continua la probabilità che X assuma esattamente un singolo valore è sempre zero, $P(X = x) = 0$. La probabilità è un'area sotto la curva della PDF, non un'altezza.

7.4. Dagli istogrammi alle densità

Un modo particolarmente intuitivo per comprendere la PDF consiste nel considerarla come il **limite ideale di un istogramma**: all'aumentare delle osservazioni e al ridursi della larghezza delle classi, il profilo dell'istogramma delle frequenze relative tende a una curva liscia che approssima la funzione di densità teorica.

Per illustrare questo concetto, consideriamo la distribuzione del quoziente intellettivo (QI) nella popolazione generale. Il QI è convenzionalmente definito con una media $\mu = 100$ e una deviazione standard $\sigma = 15$, e segue approssimativamente una distribuzione normale. Osserviamo come l'istogramma tenda alla PDF teorica all'aumentare della dimensione campionaria:

```
set.seed(42)
mu <- 100
sigma <- 15

n_piccolo <- 50
n_grande <- 20000


x_piccolo <- rnorm(n_piccolo, mean = mu, sd = sigma)
x_grande <- rnorm(n_grande, mean = mu, sd = sigma)

x_seq <- seq(40, 160, length.out = 200)
y_teorica <- dnorm(x_seq, mean = mu, sd = sigma)
df_teorica <- data.frame(x = x_seq, y = y_teorica)

p1 <- ggplot(data.frame(x = x_piccolo), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 15,
                 color = "white", alpha = 0.7) +
  geom_line(data = df_teorica, aes(x = x, y = y),
            linewidth = 1) +
  labs(title = paste("n =", n_piccolo, "individui"),
       x = "QI", y = "Densità")

p2 <- ggplot(data.frame(x = x_grande), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 50,
                 color = "white", alpha = 0.7) +
  geom_line(data = df_teorica, aes(x = x, y = y),
            linewidth = 1) +
  labs(
    title = paste("n =", format(n_grande, big.mark = ","), "individui"),
    x = "QI", y = "Densità")

gridExtra::grid.arrange(p1, p2, ncol = 2)
```



Con soli 50 individui (pannello di sinistra), l'istogramma mostra delle irregolarità dovute alla variabilità campionaria. Con 20.000 individui (pannello di destra), l'istogramma aderisce quasi perfettamente alla curva normale teorica. Questo passaggio dal discreto al continuo mostra visivamente come la PDF emerga come modello ideale della distribuzione dei dati nella popolazione.

La PDF non descrive i dettagli di ogni singola osservazione, ma il **pattern probabilistico sottostante** che emerge quando si aggrega un gran numero di dati. Essa rappresenta quindi un **modello idealizzato** della popolazione che, sacrificando il rumore individuale, permette di ottenere un maggiore potere descrittivo, predittivo e inferenziale.

7.4.1. Punto chiave da ricordare

- La PMF assegna probabilità a **punti**.
- La PDF assegna densità a **regioni**.
- Solo **intervalli** hanno probabilità non nulla nel continuo.
- Le densità sono modelli di credenza, non frequenze puntuali.

7.5. Il paradosso della probabilità nulla

Una delle proprietà più controintuitive delle variabili casuali continue è che la probabilità di osservare *esattamente* un valore specifico è sempre nulla:

$$P(X = x_0) = 0 \quad \text{per ogni } x_0 \in \mathbb{R}.$$

A prima vista, ciò sembra generare un paradosso: se ogni valore puntuale ha probabilità zero, com'è possibile osservare empiricamente un valore qualunque? Quando misuriamo un'altezza di 170 cm, non stiamo forse registrando un evento che la teoria considera impossibile?

7.5.1. Perché la probabilità di un punto è zero

La risposta risiede nel significato geometrico della densità di probabilità. Per una variabile continua, la probabilità si ottiene come l'**area sottostante la curva** su un intervallo. Un singolo punto corrisponde a un intervallo di ampiezza nulla e, quindi, a un'area nulla:

$$P(X = x_0) = \int_{x_0}^{x_0} f_X(x) dx = 0.$$

Questa non è una lacuna della teoria, bensì una proprietà logica del continuo matematico: qualsiasi area calcolata su un intervallo di lunghezza zero è necessariamente pari a zero. Se a ogni singolo punto fosse assegnata una probabilità positiva, l'accumulo su un insieme non numerabile di punti violerebbe la condizione di normalizzazione, secondo cui l'area totale sottostante alla densità deve essere pari a 1.

7.5.2. Perché allora osserviamo un valore?

L'apparente paradosso si dissolve ricordando che una misura empirica non fornisce mai un punto matematico "perfetto", bensì un valore con una **risoluzione finita**. Dire "170 cm" significa, in pratica, "un valore in un piccolo intervallo attorno a 170", determinato dalla precisione dello strumento e dal processo di arrotondamento. La teoria continua descrive proprio questo: le probabilità su intervalli, non su singoli punti.

7.5.3. Implicazioni pratiche

Per le variabili continue non ha senso chiedersi: "Qual è la probabilità che il tempo di reazione sia *esattamente* 250 ms?". La domanda operativa corretta è: "Qual è la probabilità che il tempo di reazione sia compreso tra 245 e 255 ms?". Le probabilità si calcolano sempre su **intervalli**, mai su punti singoli.

Un corollario importante è che, per le variabili continue, includere o escludere gli estremi di un intervallo non modifica la probabilità:

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b).$$

Questo perché i singoli punti a e b hanno probabilità zero.

7.5.4. Conseguenze per la valutazione psicologica

Questa proprietà matematica ha implicazioni dirette sull'interpretazione dei punteggi nei test psicologici. Consideriamo la valutazione del QI: non ha senso chiedersi "qual è la probabilità che il QI di questo bambino sia esattamente 115?" – la risposta sarebbe sempre zero, a prescindere dal bambino.

Le domande clinicamente rilevanti riguardano invece gli intervalli:

- "Qual è la probabilità che il QI rientri nell'intervallo 110-120?" (nella media superiore).
- "Qual è la probabilità che il QI sia inferiore a 70?" (soglia per la disabilità intellettiva).
- "Qual è la probabilità che il QI superi 130?" (soglia per alto potenziale).

Questo principio si applica a tutte le misurazioni continue in psicologia: punteggi di ansia, tempi di reazione, livelli di cortisolo e indici di benessere. La teoria delle variabili continue ci insegna a formulare le domande nel modo corretto, sempre in termini di intervalli e mai di valori puntuali.

7.6. La funzione di distribuzione cumulativa

La funzione di distribuzione cumulativa (CDF) fornisce una rappresentazione unificata delle distribuzioni di probabilità, valida sia per le variabili discrete che per quelle continue.

Definizione 7.2 (Funzione di distribuzione cumulativa). La *funzione di distribuzione cumulativa* di una variabile casuale X è definita come

$$F_X(x) = P(X \leq x).$$

Questa definizione è universale: la CDF “accumula” probabilità da $-\infty$ fino al valore x , e quantifica la credenza che la variabile non superi la soglia x .

7.6.1. Proprietà fondamentali della CDF

Ogni CDF soddisfa tre proprietà strutturali.

Teorema 7.1 (Proprietà della CDF). Per qualsiasi variabile casuale X , la CDF F_X soddisfa:

1. **Monotonia non decrescente:** se $a < b$, allora $F_X(a) \leq F_X(b)$.
2. **Limiti agli estremi:** $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
3. **Continuità a destra:** $\lim_{h \rightarrow 0^+} F_X(x+h) = F_X(x)$ per ogni x .

La monotonia riflette l'ovvio: ampliando l'intervallo $(-\infty, x]$ non si può perdere probabilità. I limiti garantiscono la normalizzazione globale. La continuità a destra è una convenzione tecnica necessaria soprattutto per le variabili discrete, in cui la CDF presenta salti.

7.6.2. CDF per variabili discrete e continue

Per variabili **discrete**, la CDF è una funzione a gradini: è costante tra due valori possibili e cresce a salti. L'altezza del salto nel punto x_i è esattamente $p_X(x_i)$.

Per le variabili **continue**, invece, la CDF è continua e spesso derivabile. In questo caso, la densità si ottiene come derivata:

$$f_X(x) = \frac{d}{dx} F_X(x),$$

e reciprocamente la CDF si ottiene integrando la densità:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

```

# CDF discreta (soddisfazione lavorativa 1-5)
valori_disc <- 1:5
prob_disc <- c(0.05, 0.10, 0.25, 0.40, 0.20)
cdf_disc <- cumsum(prob_disc)

df_disc <- data.frame(
  x_start = c(0, valori_disc),
  x_end = c(valori_disc, 6),
  y = c(0, cdf_disc)
)

p1 <- ggplot() +
  geom_segment(data = df_disc, aes(x = x_start, xend = x_end, y = y, yend = y),
    linewidth = 1) +
  geom_point(data = data.frame(x = valori_disc, y = cdf_disc),
    aes(x = x, y = y), size = 3) +
  geom_point(data = data.frame(x = valori_disc, y = c(0, cdf_disc[-5])),
    aes(x = x, y = y), size = 3, shape = 1) +
  scale_x_continuous(breaks = 0:6, limits = c(0, 6)) +
  scale_y_continuous(breaks = seq(0, 1, 0.2)) +
  scale_fill_qualitative() +
  labs(title = "CDF discreta (soddisfazione lavorativa)",
    x = "Livello di soddisfazione", y = expression(F[X](x)))

# CDF continua (QI, normale con mu=100, sigma=15)
x_cont <- seq(40, 160, length.out = 200)
cdf_cont <- pnorm(x_cont, mean = 100, sd = 15)

p2 <- ggplot(data.frame(x = x_cont, y = cdf_cont), aes(x = x, y = y)) +
  geom_line(linewidth = 1) +
  scale_y_continuous(breaks = seq(0, 1, 0.2)) +
  scale_fill_qualitative() +
  labs(title = "CDF continua (QI)",
    x = "QI", y = expression(F[X](x)))

gridExtra::grid.arrange(p1, p2, ncol = 2)

```




Figura 7.1.: CDF di una variabile discreta (sinistra, a gradini) e di una variabile continua (destra, curva liscia). Per la variabile discreta, i salti corrispondono ai valori con massa positiva; per la variabile continua, la CDF è derivabile ovunque.

7.6.3. Calcolo di probabilità mediante la CDF

Uno dei principali vantaggi principali della CDF è che permette di calcolare la probabilità di qualsiasi intervallo come differenza di due valori:

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

Questa relazione è valida sia per le variabili discrete che per quelle continue ed è uno strumento computazionale fondamentale in statistica.

i Esempio: calcoli con la CDF normale

Probabilità per la distribuzione del QI

Consideriamo il quoziente intellettivo (QI) come variabile normale con media $\mu = 100$ e deviazione standard $\sigma = 15$. Calcoliamo alcune probabilità di interesse clinico.


```

mu <- 100
sigma <- 15

# P(QI > 130) - QI molto elevato (gifted)
p_alto <- 1 - pnorm(130, mean = mu, sd = sigma)
cat("P(QI > 130) =", round(p_alto, 4), "\n")
#> P(QI > 130) = 0.0228

# P(85 < QI < 115) - QI nella norma (±1 SD)
p_norma <- pnorm(115, mean = mu, sd = sigma) - pnorm(85, mean = mu, sd = sigma)
cat("P(85 < QI < 115) =", round(p_norma, 4), "\n")
#> P(85 < QI < 115) = 0.683

# P(QI < 70) - disabilità intellettiva
p_basso <- pnorm(70, mean = mu, sd = sigma)
cat("P(QI < 70) =", round(p_basso, 4), "\n")
#> P(QI < 70) = 0.0228

# Percentile 95
q95 <- qnorm(0.95, mean = mu, sd = sigma)
cat("95° percentile:", round(q95, 1), "\n")
#> 95° percentile: 125

```

Questi calcoli mostrano come la CDF (implementata in R da `pnorm`) consenta di tradurre le domande cliniche in operazioni matematiche dirette:

- solo circa il 2.3% della popolazione ha un QI superiore a 130 (comunemente utilizzato per definire un “alto potenziale cognitivo”);
- circa il 68% della popolazione ha un QI compreso tra 85 e 115 (all’interno di una deviazione standard dalla media);
- circa il 2.3% ha un QI inferiore a 70 (soglia tradizionale per la disabilità intellettiva);
- il 95° percentile corrisponde a un QI di circa 125.

7.7. Interpretazioni bayesiana e frequentista

Le distribuzioni di probabilità assumono significati diversi nei due principali paradigmi dell’inferenza statistica. Questa distinzione non è soltanto filosofica, ma ha un impatto diretto sul modo in cui interpretiamo i risultati, formuliamo i modelli e comunichiamo l’incertezza.

7.7.1. L’interpretazione frequentista

Eccola rivista per migliorare la struttura logica, la precisione terminologica e il flusso del discorso.

Nel paradigma frequentista, la probabilità è definita come **frequenza relativa limite** in una lunga serie ideale di ripetizioni indipendenti dello stesso esperimento, eseguite in condizioni identiche. Per un evento del tipo $a \leq X \leq b$, questa interpretazione implica:

$$P(a \leq X \leq b) = \lim_{n \rightarrow \infty} \frac{\#\{X_i \in [a, b]\}}{n},$$

dove $X_1, X_2, \dots, X_n$ sono realizzazioni indipendenti dello stesso processo stocastico.

In questa prospettiva, la funzione di densità (PDF) non è una misura di credenza soggettiva, ma una **descrizione del meccanismo generativo dei dati**: essa rappresenta la forma limite alla quale converge l'istogramma delle osservazioni man mano che il campione si espande e gli intervalli di classificazione diventano arbitrariamente fini. La variabile casuale X modella l'esito di un esperimento ripetibile, e la sua PDF descrive la variabilità osservabile **tra** le diverse ripetizioni.

Un esempio classico è la distribuzione dell'altezza nella popolazione adulta. Un modello normale con media $\mu = 170$ cm e deviazione standard $\sigma = 10$ cm descrive quale proporzione di individui ci aspetteremmo di osservare in ogni intervallo di altezza, se potessimo campionare ripetutamente e a caso da una popolazione di riferimento molto ampia e stabile.

7.7.2. L'interpretazione bayesiana

Nel paradigma bayesiano, la probabilità quantifica un **grado di credenza razionale**, ovvero una misura della plausibilità assegnata a diverse possibilità alla luce delle informazioni disponibili. Non è necessario immaginare delle ripetizioni ipotetiche: la probabilità è una proprietà dello stato informativo dell'osservatore.

Definizione 7.3 (Interpretazione bayesiana della PDF). Dal punto di vista bayesiano, la funzione di densità $f_X(x)$ rappresenta la **distribuzione della nostra incertezza** sul valore di una quantità X , che è considerata fissa ma ignota. L'integrale $\int_a^b f_X(x) dx$ non misura una frequenza, ma il **grado di credenza** che il valore effettivo di X appartenga all'intervallo $[a, b]$.

Ne deriva un'implicazione cruciale: il paradigma bayesiano permette di descrivere con distribuzioni di probabilità non solo i dati osservabili, ma anche quelle quantità che nel frequentismo sono considerate parametri fissi, come l'effetto medio di un trattamento, la prevalenza di una malattia o la probabilità soggettiva di risposta alla terapia.

In questa logica, una funzione di densità bayesiana rappresenta una mappa di plausibilità: le regioni con densità più alta corrispondono a valori che riteniamo più credibili, mentre quelle con densità bassa riflettono ipotesi meno plausibili. La forma stessa della distribuzione, la sua simmetria o asimmetria, l'estensione delle code e il grado di concentrazione esprimono esplicitamente ciò che sappiamo e, soprattutto, ciò che ignoriamo sulla quantità di interesse.

7.7.3. Confronto tra le due prospettive

Le differenze metodologiche emergono in modo netto in un esempio elementare. Supponiamo di voler stimare l'altezza media di una popolazione, denotata con θ .

- **Nel paradigma frequentista**, θ è un **parametro fisso ma sconosciuto**. La probabilità si applica alle statistiche calcolate dai campioni, come la media campionaria $\bar{X}$. La PDF di $\bar{X}$ descrive come quest'ultima varierebbe se ripetessimo infinite volte il campionamento dalla stessa popolazione. Di conseguenza, un intervallo di confidenza al 95% **non** afferma che il valore di θ abbia una probabilità dello 0.95 di cadere in quell'intervallo (dal momento che θ non è una variabile casuale), ma piuttosto che il *metodo* utilizzato per costruire l'intervallo lo conterrebbe nel 95% delle ripetizioni sperimentali.

- **Nel paradigma bayesiano**, invece, è possibile assegnare direttamente una distribuzione di probabilità a θ , quantificando la nostra incertezza su di esso. La distribuzione *a priori* formalizza le conoscenze iniziali, mentre quella *a posteriori* aggiorna tali conoscenze con le informazioni provenienti dai dati. Pertanto, un intervallo di credibilità al 95% dichiara esattamente ciò che suggerisce: alla luce dei dati osservati e della prior, la probabilità soggettiva che il valore di θ si trovi in quell'intervallo è 0.95.

```
set.seed(123)

# Frequentista: distribuzione dei dati
x_freq <- rnorm(1000, mean = 170, sd = 10)
x_seq <- seq(140, 200, length.out = 200)
y_teorica <- dnorm(x_seq, mean = 170, sd = 10)

p1 <- ggplot() +
  geom_histogram(data = data.frame(x = x_freq), aes(x = x, y = after_stat(density)),
                 bins = 30, alpha = 0.5, color = "white") +
  geom_line(data = data.frame(x = x_seq, y = y_teorica),
            aes(x = x, y = y), linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(title = "Frequentista:\ndistribuzione dei dati",
       subtitle = "PDF come istogramma limite di ripetizioni",
       x = "Altezza (cm)", y = "Densità")

# Bayesiano: distribuzione della credenza su un parametro
theta_seq <- seq(165, 175, length.out = 200)
prior <- dnorm(theta_seq, mean = 170, sd = 2)

p2 <- ggplot() +
  geom_ribbon(data = data.frame(x = theta_seq, y = prior),
            aes(x = x, ymin = 0, ymax = y),
            alpha = 0.3) +
  geom_line(data = data.frame(x = theta_seq, y = prior),
            aes(x = x, y = y), linewidth = 1.2) +
  geom_point(aes(x = 170, y = 0), size = 3, color = "black") +
  annotate("text", x = 170, y = -0.02, label = " (valore vero ignoto)", size = 3) +
  scale_fill_qualitative() +
  labs(title = "Bayesiano:\ndistribuzione della credenza",
       subtitle = "PDF come mappa di plausibilità sul parametro",
       x = expression(theta ~ "(altezza media)"), y = "Densità")

gridExtra::grid.arrange(p1, p2, ncol = 2)
```




Figura 7.2.: Confronto tra interpretazioni frequentista e bayesiana. A sinistra: la PDF descrive la distribuzione dei dati (istogramma) in ripetizioni dell'esperimento. A destra: la PDF rappresenta la credenza sul valore di un parametro, con l'incertezza 'spalmata' sui valori possibili.

La CDF rimane in entrambi i paradigmi lo strumento fondamentale per calcolare le probabilità degli intervalli. A cambiare è il **significato** che attribuiamo a queste probabilità: nel paradigma frequentista essa rappresenta una **frequenza limite** di un evento su ripetizioni ideali dell'esperimento; nel paradigma bayesiano, essa esprime il **grado di credenza** soggettiva che una proposizione sia vera, sulla base delle informazioni disponibili.

Riflessioni conclusive

La distinzione tra **massa** e **densità** di probabilità evidenzia una differenza strutturale fondamentale tra variabili casuali discrete e continue. Per le variabili casuali discrete, la probabilità è concentrata in punti isolati, mentre per quelle continue è distribuita in modo continuo e misurabile solo integrando su intervalli di valori.

Il cosiddetto "paradosso" della probabilità nulla per punti esatti nelle distribuzioni continue si dissolve quando si riconosce che, in questo ambito, la probabilità è intrinsecamente una proprietà degli **intervalli**, non dei **punti**. Ogni singolo valore contribuisce con probabilità nulla, ma l'integrazione su un continuum di valori produce quantità probabilisticamente significative. Per lo psicologo, ciò si traduce in una prassi operativa: formulare domande come "Qual è la probabilità che il punteggio cada in *questo intervallo*?", anziché chiedersi "Qual è la probabilità di ottenere *esattamente* questo punteggio?".

In questo contesto, la **funzione di distribuzione cumulativa** (CDF) si rivela uno strumento unificante. Essa offre una rappresentazione coerente delle distribuzioni sia per variabili discrete che continue, consente il calcolo diretto delle probabilità su intervalli arbitrari e chiarisce sistematicamente il legame tra la funzione di massa, la funzione di densità e le probabilità osservabili.

Infine, la differenza tra l'interpretazione **frequentista** e **bayesiana** delle distribuzioni non è un dibattito puramente filosofico, ma implica scelte metodologiche concrete nella costruzione e nell'in-

interpretazione dei modelli statistici. Poiché l'obiettivo di questo corso è l'inferenza in condizioni di incertezza, ci concentreremo sul paradigma bayesiano, il cui formalismo è appositamente concepito per rappresentare, e aggiornare in modo logicamente coerente, lo stato delle nostre conoscenze alla luce dell'evidenza empirica.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Massa vs densità: due modi profondamente diversi di distribuire probabilità

- **Massa (PMF)**: probabilità concentrata in punti discreti, come “pesi” su una bilancia.
- **Densità (PDF)**: probabilità distribuita su un continuum, come massa in un fluido.
- La distinzione non è solo tecnica ma riflette strutture matematiche diverse (somme vs integrali).

2. La PMF assegna probabilità dirette a valori specifici

- $p_X(x) = P(X = x)$ è la probabilità *del* punto x .
- Diagramma a barre: l'altezza rappresenta direttamente la probabilità.
- Somma delle probabilità: $\sum_x p_X(x) = 1$.

3. La PDF misura concentrazione locale, non probabilità diretta

- $f_X(x)$ indica “quanta probabilità c'è per unità di lunghezza” attorno a x .
- $f_X(x)$ può essere maggiore di 1 (non è una probabilità!).
- Probabilità tramite integrazione: $P(a \leq X \leq b) = \int_a^b f_X(x) dx$.

4. Il “paradosso” $P(X = x) = 0$ per variabili continue

- Non è un paradosso: un singolo punto ha “misura zero” nel continuo.
- Come la “massa di un punto” in un filo: zero, ma il punto esiste.
- Differenza cruciale: probabilità zero $\neq$ impossibilità logica.
- Solo intervalli (anche infinitesimi) hanno probabilità positiva.

5. Dagli istogrammi alle densità: il limite continuo

- All'aumentare di n e al diminuire della larghezza dei bin, gli istogrammi convergono alla PDF.
- La PDF è il limite ideale quando $\text{bin} \rightarrow 0$ e $n \rightarrow \infty$.
- Illustra visivamente come la densità emerga naturalmente dai dati.

6. CDF come rappresentazione unificata

- $F_X(x) = P(X \leq x)$ vale sia per discrete che per continue.
- Discrete: funzione a gradini con salti in corrispondenza dei valori possibili.
- Continue: funzione liscia e crescente.
- Proprietà universali: monotona non decrescente, $F(-\infty) = 0$, $F(+\infty) = 1$.

7. Interpretazioni bayesiana vs frequentista delle distribuzioni

- **Frequentista**: la PDF descrive il comportamento dei dati in ripetizioni ipotetiche.
- **Bayesiano**: la PDF rappresenta il grado di credenza sui possibili valori (anche parametri!).

- Stessa forma matematica, interpretazione epistemica profondamente diversa.
- Per il bayesiano, distribuzioni di parametri sono naturali; per il frequentista no.

Formule da ricordare:

PMF (discrete):

$$p_X(x) = P(X = x), \quad \sum_x p_X(x) = 1$$

PDF (continue):

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx, \quad \int_{-\infty}^{+\infty} f_X(x) dx = 1$$

CDF (universale):

$$F_X(x) = P(X \leq x) = \begin{cases} \sum_{x_i \leq x} p_X(x_i) & \text{(discreta)} \\ \int_{-\infty}^x f_X(t) dt & \text{(continua)} \end{cases}$$

Relazione PDF-CDF per variabili continue:

$$f_X(x) = \frac{d}{dx} F_X(x) \quad (\text{la densità è la derivata della CDF})$$

Calcolo di probabilità da CDF:

$$P(a \leq X \leq b) = F_X(b) - F_X(a)$$

Proprietà chiave:

- **Discrete:** $P(X = x) = p_X(x) > 0$ è possibile.
- **Continue:** $P(X = x) = 0$ sempre (ma $f_X(x)$ può essere > 0).
- **PDF può essere > 1 :** non è una probabilità ma una densità!
- **CDF sempre $\in [0,1]$:** rappresenta una probabilità cumulativa.

Per il prossimo capitolo:

Nel Capitolo 8 le **proprietà delle variabili casuali**: valore atteso (centro di gravità probabilistico), varianza (dispersione), e le loro proprietà algebriche. Questi strumenti di sintesi ci permetteranno di caratterizzare distribuzioni complesse con pochi numeri e di propagare l'incertezza attraverso trasformazioni matematiche, preparando il terreno per l'inferenza bayesiana parametrica.

! Esercizi

Esercizi concettuali

1. Spiega perché il termine “massa” è appropriato per le distribuzioni discrete e “densità” per quelle continue. Quale proprietà fisica richiamano queste metafore?
2. Un collega afferma: “Se $P(X = 170) = 0$, allora è impossibile osservare $X = 170$.” Correggi questo fraintendimento e spiega la distinzione tra “probabilità zero” e “impossibilità”.
3. Nel paradigma bayesiano, ha senso assegnare una distribuzione di probabilità a una costante fisica come la velocità della luce? Perché sì o perché no?

Esercizi sulla PMF

4. Un test psicometrico produce punteggi interi da 1 a 5 secondo la distribuzione:

Punteggio	1	2	3	4	5
$p_X(x)$	0.10	0.20	0.35	0.25	0.10

7. Distribuzioni di massa e di densità

- a. Calcola $P(X \geq 3)$.
 - b. Calcola $P(2 \leq X \leq 4)$.
 - c. Calcola il valore atteso $\mathbb{E}[X]$.
 - d. Costruisci la CDF e rappresentala graficamente.
5. Nella scala LSNS-6 (Lubben Social Network Scale), il numero di amici intimi segue approssimativamente questa distribuzione:

Amici	0	1	2	3	4	5+
$p_X(x)$	0.05	0.15	0.25	0.30	0.15	0.10

- a. Qual è la probabilità di avere almeno 3 amici intimi?
- b. Qual è la probabilità di avere meno di 2 amici intimi?
- c. Calcola valore atteso e varianza.

Esercizi sulla PDF e CDF

6. Il punteggio alla Satisfaction with Life Scale (SWLS) può essere approssimato da una distribuzione normale con $\mu = 20$ e $\sigma = 5$.
 - a. Qual è la probabilità di un punteggio superiore a 25?
 - b. Qual è la probabilità di un punteggio tra 15 e 25?
 - c. Quale punteggio delimita il 10% superiore della distribuzione?
 - d. Verifica i calcoli con le funzioni R `pnorm` e `qnorm`.
7. Il tempo di reazione in un compito cognitivo segue una distribuzione normale con $\mu = 350$ ms e $\sigma = 50$ ms.
 - a. Qual è la probabilità che un tempo di reazione sia inferiore a 300 ms?
 - b. Entro quale intervallo simmetrico attorno alla media cade il 95% dei tempi?
 - c. Un tempo di 450 ms è “anomalo”? Calcola la probabilità di osservare un tempo così estremo o più.

Esercizi sulle interpretazioni

8. **Legge della probabilità totale:** Il 60% degli studenti ha un forte supporto sociale, il 40% ha un supporto limitato. La probabilità di $SWLS > 20$ è 0.75 per chi ha forte supporto e 0.50 per chi ha supporto limitato. Calcola $P(SWLS > 20)$ per uno studente scelto a caso.
9. **Teorema di Bayes:** Usando i dati dell'esercizio 8, calcola la probabilità che uno studente abbia forte supporto sociale *dato* che il suo punteggio SWLS è superiore a 20.
10. Un frequentista e un bayesiano osservano lo stesso dataset e calcolano la stessa PDF normale come modello per i dati. In che senso le loro *interpretazioni* differiscono, pur concordando sulla forma matematica?

Esercizi computazionali

11. Scrivi una funzione R che, data una PMF (vettori di valori e probabilità), generi un grafico con la PMF (diagramma a barre) e la CDF (funzione a gradini) affiancati.
12. Simula 10,000 osservazioni da una distribuzione normale con $\mu = 100$ e $\sigma = 15$. Confronta:
 - a. Media e varianza empiriche con quelle teoriche.
 - b. Proporzione di valori in $[\mu - \sigma, \mu + \sigma]$ con la proporzione teorica ($\approx 68.3\%$).
 - c. Proporzione di valori in $[\mu - 2\sigma, \mu + 2\sigma]$ con la proporzione teorica ($\approx 95.4\%$).

Soluzioni

Soluzioni esercizi concettuali

1. “Massa” evoca l'idea di pesi discreti concentrati in punti specifici, come pesi su una bilancia. “Densità” richiama la distribuzione continua di materia nello spazio: non chiediamo “quanta massa c'è in questo punto” (sarebbe zero), ma “quanta massa c'è per

unità di volume attorno a questo punto”. Analogamente, la PDF misura la “concentrazione” della probabilità per unità di lunghezza.

2. “Probabilità zero” significa che l’evento ha misura nulla nell’insieme delle possibilità, non che sia logicamente escluso. È come chiedere la massa di un singolo punto in un filo: la risposta è zero, ma il punto esiste. L’impossibilità logica (come ottenere 7 con un dado) è diversa dalla probabilità zero (come $X = 170$ esatto in una distribuzione continua).
3. Dal punto di vista bayesiano, sì: la distribuzione rappresenta la nostra *incertezza* sul valore, non una variabilità intrinseca. Prima delle misurazioni di Michelson-Morley, un bayesiano avrebbe assegnato una distribuzione che rifletteva l’ignoranza sul valore esatto. Oggi, con misure estremamente precise, la distribuzione sarebbe concentratissima attorno al valore noto, ma tecnicamente ancora una distribuzione.

Soluzioni esercizi PMF

4.
 - a. $P(X \geq 3) = 0.35 + 0.25 + 0.10 = 0.70$
 - b. $P(2 \leq X \leq 4) = 0.20 + 0.35 + 0.25 = 0.80$
 - c. $\mathbb{E}[X] = 1(0.10) + 2(0.20) + 3(0.35) + 4(0.25) + 5(0.10) = 3.05$
 - d. CDF: $F(1) = 0.10, F(2) = 0.30, F(3) = 0.65, F(4) = 0.90, F(5) = 1.00$
5.
 - a. $P(X \geq 3) = 0.30 + 0.15 + 0.10 = 0.55$
 - b. $P(X < 2) = 0.05 + 0.15 = 0.20$
 - c. $\mathbb{E}[X] = 0(0.05) + 1(0.15) + 2(0.25) + 3(0.30) + 4(0.15) + 5(0.10) = 2.65$
 $\mathbb{E}[X^2] = 0 + 0.15 + 1.00 + 2.70 + 2.40 + 2.50 = 8.75$
 $\text{Var}(X) = 8.75 - 2.65^2 = 1.7275$

Soluzioni esercizi PDF e CDF

6.
 - a. $P(X > 25) = 1 - \Phi\left(\frac{25-20}{5}\right) = 1 - \Phi(1) = 1 - 0.8413 = 0.1587$
 - b. $P(15 < X < 25) = \Phi(1) - \Phi(-1) = 0.8413 - 0.1587 = 0.6826$
 - c. $z_{0.90} = 1.28$, quindi $x = 20 + 1.28 \times 5 = 26.4$
 - d. Verifica R:

```
1 - pnorm(25, mean = 20, sd = 5) # 0.1587
pnorm(25, 20, 5) - pnorm(15, 20, 5) # 0.6827
qnorm(0.90, mean = 20, sd = 5) # 26.41
```

7.
 - a. $P(X < 300) = \Phi\left(\frac{300-350}{50}\right) = \Phi(-1) = 0.1587$
 - b. Intervallo al 95%: $350 \pm 1.96 \times 50 = [252, 448]$ ms
 - c. $P(X > 450) = 1 - \Phi(2) = 0.0228$. Bilaterale: $P(|X - 350| > 100) = 2 \times 0.0228 = 0.0456$. È inusuale (circa 5% di probabilità).

Soluzioni esercizi interpretazioni

8. Per la legge della probabilità totale:

$$P(\text{SWLS} > 20) = 0.75 \times 0.60 + 0.50 \times 0.40 = 0.45 + 0.20 = 0.65$$

9. Per il teorema di Bayes:

$$P(\text{Forte} \mid \text{SWLS} > 20) = \frac{0.75 \times 0.60}{0.65} = \frac{0.45}{0.65} = 0.692$$

10. Entrambi descrivono la stessa PDF, ma il frequentista la interpreta come la distribuzione dei dati in ripetizioni ipotetiche dell'esperimento, mentre il bayesiano la vede come una distribuzione predittiva che incorpora le sue credenze sui parametri. Se la PDF è usata per descrivere l'incertezza su un parametro, il frequentista rifiuterebbe questa interpretazione (i parametri sono fissi, non casuali), mentre il bayesiano la considererebbe naturale.

Soluzioni esercizi computazionali

```
11. plot_pmf_cdf <- function(valori, prob) {
  df <- data.frame(x = valori, pmf = prob, cdf = cumsum(prob))

  p1 <- ggplot(df, aes(x = factor(x), y = pmf)) +
    geom_col(fill = "steelblue") +
    labs(x = "x", y = "P(X = x)", title = "PMF")

  # CDF a gradini
  df_cdf <- data.frame(
    x_start = c(min(valori) - 1, valori),
    x_end = c(valori, max(valori) + 1),
    y = c(0, cumsum(prob))
  )

  p2 <- ggplot() +
    geom_segment(data = df_cdf,
      aes(x = x_start, xend = x_end, y = y, yend = y)) +
    labs(x = "x", y = "F(x)", title = "CDF")

  gridExtra::grid.arrange(p1, p2, ncol = 2)
}
```

```
12. set.seed(42)
x <- rnorm(10000, mean = 100, sd = 15)

# a) Media e varianza
cat("Media empirica:", mean(x), "(teorica: 100)\n")
cat("Varianza empirica:", var(x), "(teorica: 225)\n")

# b) ±1 SD
prop_1sd <- mean(x >= 85 & x <= 115)
cat("Proporzione in [- , +]:", prop_1sd, "(teorica: 0.683)\n")

# c) ±2 SD
prop_2sd <- mean(x >= 70 & x <= 130)
cat("Proporzione in [-2 , +2]:", prop_2sd, "(teorica: 0.954)\n")
```

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0     ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0     posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7         StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2           sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1        matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1         dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0            here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0     estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1          yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3        bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0           RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2          grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8         inline_0.3.21
#> [28] emmeans_2.0.3       scales_1.4.0         cli_3.6.6
#> [31] mvtnorm_1.4-1       rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1       vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-5         jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1  glue_1.8.1           codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5      stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0      pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9    R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1     evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1     memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1     rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1     nlme_3.1-169
#> [67] checkmate_2.3.4     xfun_0.60           pkgconfig_2.0.3

```

Bibliografia

8. Proprietà delle variabili casuali

Introduzione

Immaginiamo uno scenario comune nella pratica clinica. Una psicologa deve decidere se raccomandare a un paziente affetto da depressione moderata un nuovo protocollo di intervento cognitivo-comportamentale. I dati disponibili indicano che, in media, i pazienti trattati mostrano un miglioramento di 8 punti nel BDI-II dopo 12 settimane. Ma quanto è informativo questo numero da solo?

Un miglioramento medio di 8 punti potrebbe derivare da situazioni molto diverse: potrebbe significare che quasi tutti i pazienti migliorano di circa 8 punti, oppure che la metà dei pazienti migliora di 16 punti, mentre l'altra metà non mostra alcun cambiamento. Nel primo caso, il trattamento è prevedibilmente efficace, mentre nel secondo l'esito per il singolo paziente è molto più incerto. Per poter prendere una decisione informata, la clinica ha bisogno di sapere non solo dove si colloca il centro della distribuzione degli esiti, ma anche quanto i singoli esiti si disperdono attorno a questo centro.

Questo capitolo introduce i due indicatori fondamentali che rispondono a queste domande: il **valore atteso**, che individua il “centro di gravità” della distribuzione, e la **varianza**, che ne quantifica la dispersione. Questi concetti non sono semplici convenzioni descrittive, ma possiedono un significato teorico profondo. In una prospettiva bayesiana, il valore atteso rappresenta la nostra **aspettativa razionale** data l'informazione disponibile, mentre la varianza quantifica l'**incertezza residua**, ovvero quanto ancora non sappiamo sul valore che osserveremo.

Per questo motivo, il valore atteso e la varianza occupano una posizione centrale non solo nella statistica descrittiva, ma anche nella **teoria delle decisioni** e nell'**inferenza bayesiana**. Comprenderne il significato e le proprietà è essenziale per interpretare correttamente le distribuzioni di probabilità e per poterle utilizzare come strumenti operativi nel ragionamento scientifico e clinico.

Panoramica del capitolo

- Il valore atteso come media ponderata e centro di massa probabilistico.
- Proprietà algebriche del valore atteso: linearità e additività.
- La varianza come misura della dispersione e dell'incertezza.
- Proprietà della varianza e formula computazionale alternativa.
- Deviazione standard e standardizzazione.
- Il teorema di Chebyshev e i momenti di una distribuzione.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- 1 — **fondamentale**.
- 2 — **fondamentale**.

Questo capitolo introduce gli strumenti di sintesi numerica (valore atteso e varianza) per caratterizzare le distribuzioni di probabilità studiate nei capitoli precedenti.

Conoscenze matematiche richieste:

- Appendice C - per il calcolo del valore atteso discreto.
- Appendice F - per il calcolo del valore atteso continuo.

Competenze pratiche:

- Familiarità con R e operazioni vettoriali per verificare le proprietà attraverso simulazioni.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

8.1. Il valore atteso come centro di gravità

Il **valore atteso** di una variabile casuale rappresenta il suo *baricentro probabilistico*, ovvero il punto attorno al quale la probabilità si bilancia. In una prospettiva bayesiana, il valore atteso formalizza la nostra **aspettativa razionale**, ovvero la migliore previsione puntuale che possiamo fare alla luce dello stato informativo corrente. In una prospettiva frequentista, invece, esso corrisponde al valore medio che ci si aspetta di osservare in una lunga serie di ripetizioni dell'esperimento.

Definizione 8.1 (Valore atteso (speranza matematica)). Il *valore atteso* (o *media* o *speranza matematica*) di una variabile casuale X è definito come segue.

Per variabili **discrete** con funzione di massa di probabilità p_X :

$$\mathbb{E}[X] = \sum_{x \in \mathcal{X}} x \cdot p_X(x).$$

Per variabili **continue** con funzione di densità di probabilità f_X :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx.$$

In entrambi i casi, il valore atteso è una **media ponderata** dei valori possibili della variabile, in cui i pesi sono dati dalle probabilità (nel caso discreto) o dalla densità di probabilità (nel caso continuo).

È importante sottolineare che il valore atteso **non deve necessariamente coincidere con un valore osservabile** della variabile. Questo punto è particolarmente rilevante in psicologia, dove molte scale forniscono solo valori interi.

i Esempio: risposta a un item dicotomico

Il valore atteso non è un esito

Consideriamo un singolo item di un test cognitivo. Definiamo la variabile casuale X tale che:

- $X = 1$ se la risposta è corretta,
- $X = 0$ se la risposta è errata.

Se la probabilità di risposta corretta è $p = 0.7$ (ad esempio, per un item di difficoltà media), il valore atteso è:

$$\mathbb{E}[X] = 0 \cdot 0.3 + 1 \cdot 0.7 = 0.7.$$

Il valore 0.7 non è un esito possibile per questo item — la risposta sarà sempre 0 o 1. Tuttavia, 0.7 rappresenta correttamente il **centro di gravità** della distribuzione: se somministrassimo questo item a molti soggetti con la stessa probabilità di successo, la proporzione di risposte corrette tenderebbe a 0.7.

In termini bayesiani, 0.7 è la nostra **aspettativa razionale**: se dovessimo scommettere sul risultato prima di osservarlo, 0.7 rappresenterebbe la previsione ottimale in termini di minimizzazione dell'errore quadratico medio.

8.2. Il valore atteso come limite di frequenze

Un'interpretazione operativa del valore atteso è fornita dalla **legge dei grandi numeri**. Se ripetiamo un esperimento molte volte e calcoliamo la media aritmetica dei risultati, questa media tende al valore atteso teorico.

Formalmente, se $X_1, X_2, \dots, X_n$ sono realizzazioni indipendenti della stessa variabile casuale X , allora:

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n} \xrightarrow{n \rightarrow \infty} \mathbb{E}[X].$$

Questa convergenza **non definisce** il valore atteso, che resta una media ponderata secondo la definizione formale, ma ne fornisce una giustificazione empirica. Il valore atteso è quindi il valore verso cui tende la media osservata quando il processo viene campionato ripetutamente.

i Esempio: punteggio totale su due subscale

Verifica della convergenza

Consideriamo un questionario composto da due sottoscale, ciascuna con punteggi da 1 a 6 (come in una scala Likert). Il punteggio totale X è la somma dei punteggi sulle due sottoscale e può variare da 2 a 12.

Supponiamo che ciascuna sottoscala abbia la seguente distribuzione (leggermente asimmetrica verso valori alti, tipica di scale di soddisfazione):

Punteggio	1	2	3	4	5	6
Probabilità	0.05	0.10	0.15	0.25	0.30	0.15

Il valore atteso di ciascuna sottoscala è:

$$\mathbb{E}[S] = 1(0.05) + 2(0.10) + 3(0.15) + 4(0.25) + 5(0.30) + 6(0.15) = 4.10.$$

Per la somma delle due sottoscale (assumendo indipendenza):

$$\mathbb{E}[X] = \mathbb{E}[S_1] + \mathbb{E}[S_2] = 4.10 + 4.10 = 8.20.$$

Una simulazione mostra che la media empirica converge a questo valore:

```
set.seed(123)

# Distribuzione di ciascuna subscale
valori_subscala <- 1:6
prob_subscala <- c(0.05, 0.10, 0.15, 0.25, 0.30, 0.15)
E_subscala <- sum(valori_subscala * prob_subscala)

# Simulazione
n_sim <- 100000
subscala1 <- sample(valori_subscala, n_sim, replace = TRUE, prob = prob_subscala)
subscala2 <- sample(valori_subscala, n_sim, replace = TRUE, prob = prob_subscala)
punteggio_totale <- subscala1 + subscala2

E_teorico <- 2 * E_subscala
E_empirico <- mean(punteggio_totale)

cat("Valore atteso teorico:", E_teorico, "\n")
#> Valore atteso teorico: 8.2
cat("Media empirica:", round(E_empirico, 3), "\n")
#> Media empirica: 8.2
```

La convergenza della media empirica al valore teorico illustra concretamente la legge dei grandi numeri.

8.2.1. Ponte applicativo: il punteggio atteso di una scala

Il risultato appena visto ha un'implicazione pratica immediata: **il punteggio atteso di una scala psicometrica** equivale alla somma dei valori attesi dei suoi singoli item. Ad esempio, se una scala è composta da 20 item, ciascuno con un valore atteso di 3.5 (su una scala da 1 a 5), il punteggio totale atteso sarà semplicemente $20 \times 3.5 = 70$.

Questa proprietà, che formalizzeremo in seguito come *linearità del valore atteso*, semplifica notevolmente i calcoli e permette di ragionare sulle proprietà aggregate di scale composite senza dover ricostruire tutta la complessa distribuzione congiunta degli item.

8.3. La linearità del valore atteso

Il valore atteso possiede un'importante proprietà algebrica: la **linearità**. Per qualunque coppia di variabili casuali X e Y e per qualunque costante a , vale:

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y], \quad \mathbb{E}[aX] = a \mathbb{E}[X].$$

Questa proprietà **non richiede alcuna assunzione di indipendenza**: vale sempre, anche quando le variabili sono correlate.

Teorema 8.1 (Linearità). Per qualsiasi variabile casuale X e per qualunque costanti $a, b \in \mathbb{R}$, vale:

$$\mathbb{E}[aX + b] = a \mathbb{E}[X] + b.$$

La linearità afferma che le **traslazioni** e i **riscalamenti** dei valori di una variabile si riflettono direttamente sul valore atteso. Se moltiplichiamo tutti i valori per una costante a , la media viene moltiplicata per a ; se aggiungiamo una costante b a tutti i valori, la media aumenta di b .

Teorema 8.2 (Additività). Per qualsiasi coppia di variabili casuali X e Y vale:

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

Questa proprietà è valida **sempre**, sia che X e Y siano indipendenti o dipendenti.

Per una somma di n variabili casuali $X_1, \dots, X_n$ si ottiene:

$$\mathbb{E}\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n \mathbb{E}[X_i].$$

i Esempio: Punteggio composito di ansia e depressione

Applicazione della linearità in un contesto clinico

Si consideri una valutazione psicometrica che combina due scale:

- punteggio di ansia A (scala 0–21, es. GAD-7);
- punteggio di depressione D (scala 0–27, es. PHQ-9).

Nella popolazione clinica di riferimento si supponga che:

- $\mathbb{E}[A] = 12$ (ansia moderata);
- $\mathbb{E}[D] = 14$ (depressione moderata).

Un possibile indice composito di *distress psicologico* può essere definito come:

$$\text{Distress} = A + D.$$

Per la proprietà di linearità del valore atteso, otteniamo immediatamente:

$$\mathbb{E}[\text{Distress}] = \mathbb{E}[A] + \mathbb{E}[D] = 12 + 14 = 26.$$

Nota importante: il calcolo rimane valido **anche se ansia e depressione sono correlate**, come accade tipicamente in caso di comorbidità clinica. La linearità non richiede l'indipendenza tra le variabili.

Se volessimo costruire un indice ponderato che attribuisce maggiore peso alla depressione:

$$\text{Distress}_w = 0.4 \cdot A + 0.6 \cdot D,$$

il suo valore atteso sarebbe:

$$\mathbb{E}[\text{Distress}_w] = 0.4 \cdot 12 + 0.6 \cdot 14 = 4.8 + 8.4 = 13.2.$$

```
# Verifica con simulazione (ipotesi: correlazione moderata tra A e D)
set.seed(42)
library(MASS)

# Generiamo dati correlati (correlazione r = 0.6, realistico in clinica)
n <- 10000
Sigma <- matrix(c(25, 18, 18, 36), 2, 2) # Var(A)=25, Var(D)=36, Cov=18
dati <- mvrnorm(n, mu = c(12, 14), Sigma = Sigma)
A <- pmax(0, pmin(21, round(dati[,1]))) # adattiamo al range della scala
D <- pmax(0, pmin(27, round(dati[,2])))

distress <- A + D
distress_w <- 0.4 * A + 0.6 * D

cat("Valore atteso teorico di Distress: 26")
#> Valore atteso teorico di Distress: 26
cat(" | Valore atteso empirico:", round(mean(distress), 2), "\n")
#> | Valore atteso empirico: 25.8
cat("Valore atteso teorico di Distress_w: 13.2")
#> Valore atteso teorico di Distress_w: 13.2
cat(" | Valore atteso empirico:", round(mean(distress_w), 2), "\n")
#> | Valore atteso empirico: 13.1
cat("Correlazione osservata tra A e D:", round(cor(A, D), 2), "\n")
#> Correlazione osservata tra A e D: 0.59
```

Come si può notare, nonostante la correlazione tra le due scale, il valore atteso del punteggio composito coincide con il calcolo analitico, confermando la robustezza della linearità.

8.3.1. Prodotto di variabili casuali

Teorema 8.3 (Prodotto di variabili indipendenti). Se X e Y sono variabili casuali **indipendenti**, allora vale:

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

A differenza dell'additività, questa proprietà **richiede** l'indipendenza. In generale, per le variabili dipendenti il valore atteso del prodotto non è uguale al prodotto dei valori attesi. Questa distinzione sarà cruciale quando introdurremo i concetti di covarianza e correlazione.

8.3.2. Valore atteso della media campionaria

Una conseguenza fondamentale della linearità riguarda la **media aritmetica** di più osservazioni. Se $X_1, \dots, X_n$ sono variabili casuali indipendenti e identicamente distribuite (i.i.d.) con valore atteso $\mathbb{E}[X_i] = \mu$, la media campionaria

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

ha valore atteso:

$$\mathbb{E}[\bar{X}] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \cdot n \cdot \mu = \mu.$$

Questo risultato mostra che la media campionaria è uno stimatore non distorto del valore atteso della popolazione: in media, la media campionaria coincide con il parametro che si intende stimare.

8.3.3. Ponte applicativo: perché la media campionaria è uno stimatore coerente

Questo risultato ha implicazioni dirette per la pratica della ricerca in psicologia. Quando calcoliamo la media dei punteggi BDI-II in un campione di pazienti, utilizziamo la **media campionaria** come stimatore del valore atteso (media) della popolazione. La proprietà $\mathbb{E}[\bar{X}] = \mu$, nota come *non distorsione*, ci garantisce che, in media su infiniti campioni possibili, questa procedura di stima “centra il bersaglio”.

Tuttavia, ciò non significa che la stima ottenuta da un singolo campione sia perfettamente accurata: la media campionaria è soggetta a una variabilità intrinseca, in quanto dipende dai soggetti selezionati. Per quantificare **quanto possa oscillare** questa stima da campione a campione, è necessario introdurre il concetto di *varianza* (e di errore standard, che da essa deriva).

8.4. La varianza come misura di dispersione e incertezza

Il valore atteso identifica il centro di una distribuzione, ma da solo non fornisce informazioni su quanto i valori reali tendano a discostarsene. Riprendiamo l'esempio clinico: sapere che il miglioramento medio nel BDI-II è di 8 punti non ci dice se tale cambiamento sia relativamente uniforme tra i pazienti o estremamente variabile.

Dal punto di vista epistemico, la varianza quantifica l'**incertezza residua** su una quantità, anche dopo averne stimato il valore centrale. Un'elevata varianza indica che, pur conoscendo la media, rimaniamo ampiamente incerti sul risultato specifico che osserveremo, mentre una varianza bassa suggerisce invece che la media costituisce una guida affidabile per prevedere le singole realizzazioni.

8.4.1. Perché non usare la media degli scarti?

Per misurare la dispersione di una variabile attorno alla sua media, l'idea naturale è considerare gli **scarti dalla media**, ovvero $X - \mathbb{E}[X]$. Tuttavia, per la stessa definizione di valore atteso, si ha:

$$\mathbb{E}[X - \mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[X] = 0.$$

La media degli scarti è sempre pari a zero, in quanto gli scarti positivi e quelli negativi si compensano a vicenda, rendendo questa quantità inefficace come indice di variabilità.

Per ottenere una misura che sia sempre non negativa e che rifletta l'entità delle deviazioni, si utilizza il **quadrato degli scarti**. Elevando al quadrato, si eliminano i segni negativi e, allo stesso tempo, si attribuisce un peso maggiore agli scostamenti più ampi rispetto alla media.

Definizione 8.2 (Varianza). La *varianza* di una variabile casuale X è definita come il **valore atteso del quadrato degli scarti dalla media**:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

Denotando con $\mu = \mathbb{E}[X]$, la definizione si esprime operativamente come:

- **Caso discreto**

$$\text{Var}(X) = \sum_i (x_i - \mu)^2 p_X(x_i),$$

dove p_X è la funzione di massa di probabilità.

- **Caso continuo**

$$\text{Var}(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f_X(x) dx,$$

dove f_X è la funzione di densità.

La varianza è una quantità **non negativa**: $\text{Var}(X) \geq 0$. Vale $\text{Var}(X) = 0$ se e solo se X assume un unico valore con probabilità 1, ovvero quando non c'è alcuna variabilità.

8.4.2. Interpretazione epistemica

La varianza può essere interpretata come la **perdita attesa** quando si utilizza il valore atteso μ come previsione puntuale e si misura l'errore con una *funzione di perdita quadratica*. Se formuliamo sempre μ come previsione, l'errore quadratico medio associato è:

$$\mathbb{E}[(X - \mu)^2] = \text{Var}(X).$$

In questa ottica, la varianza quantifica **quanto, in media, la nostra previsione si discosta** dal valore effettivo che osserveremo. Rappresenta quindi una misura dell'**incertezza residua** intrinseca alla variabile, anche una volta adottata la migliore stima puntuale possibile.

i Esempio: confronto tra due trattamenti

Stessa media, varianza diversa

Consideriamo due trattamenti per la depressione. Entrambi producono un miglioramento medio di 8 punti al BDI-II, ma con distribuzioni diverse:

Trattamento A (esiti prevedibili): | Miglioramento | 6 | 7 | 8 | 9 | 10 | | :— — — — — : | : : : : : : : : : : : : |
 Probabilità | 0.10 | 0.25 | 0.30 | 0.25 | 0.10 |

Trattamento B (esiti variabili): | Miglioramento | 0 | 4 | 8 | 12 | 16 | | :— — — — — : | : : : : : : : : : : : : |
 Probabilità | 0.10 | 0.25 | 0.30 | 0.25 | 0.10 |

```
# Trattamento A
valori_A <- c(6, 7, 8, 9, 10)
prob_A <- c(0.10, 0.25, 0.30, 0.25, 0.10)
E_A <- sum(valori_A * prob_A)
Var_A <- sum((valori_A - E_A)^2 * prob_A)

# Trattamento B
valori_B <- c(0, 4, 8, 12, 16)
prob_B <- c(0.10, 0.25, 0.30, 0.25, 0.10)
E_B <- sum(valori_B * prob_B)
Var_B <- sum((valori_B - E_B)^2 * prob_B)

cat("Trattamento A: E[X] =", E_A, ", Var(X) =", Var_A, "\n")
#> Trattamento A: E[X] = 8 , Var(X) = 1.3
cat("Trattamento B: E[X] =", E_B, ", Var(X) =", Var_B, "\n")
#> Trattamento B: E[X] = 8 , Var(X) = 20.8
```

Entrambi i trattamenti hanno lo stesso valore atteso (8 punti), ma la varianza del Trattamento B è 16 volte maggiore! Con il Trattamento A, possiamo dire al paziente con ragionevole confidenza che migliorerà di circa 8 punti. Con il Trattamento B, invece, alcuni pazienti non miglioreranno affatto mentre altri miglioreranno moltissimo.

La scelta tra i due trattamenti dipende dalle preferenze del paziente e del clinico riguardo al rischio: un paziente avverso al rischio potrebbe preferire il Trattamento A, mentre uno disposto a “scommettere” su un miglioramento maggiore potrebbe preferire il Trattamento B.

8.5. Formula alternativa della varianza

Spesso, dal punto di vista computazionale, è più conveniente utilizzare una forma equivalente della varianza.

Teorema 8.4 (Formula alternativa).

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

8.5.1. Dimostrazione

Dimostrazione. Sia $\mu = \mathbb{E}[X]$. Partendo dalla definizione:

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[(X - \mu)^2] \\ &= \mathbb{E}[X^2 - 2\mu X + \mu^2] \\ &= \mathbb{E}[X^2] - 2\mu \mathbb{E}[X] + \mu^2 \\ &= \mathbb{E}[X^2] - 2\mu^2 + \mu^2 \\ &= \mathbb{E}[X^2] - \mu^2. \end{aligned}$$

□

Questa formulazione mostra che la varianza dipende esclusivamente da due **momenti** della distribuzione: il valore atteso $\mathbb{E}[X]$ e il valore atteso del quadrato $\mathbb{E}[X^2]$.

i Esempio: varianza del punteggio su due subscale

Calcolo con entrambe le formule

Riprendiamo l'esempio delle due scale con distribuzione:

Punteggio	1	2	3	4	5	6
Probabilità	0.05	0.10	0.15	0.25	0.30	0.15

Varianza di una singola scala:

```
valori <- 1:6
prob <- c(0.05, 0.10, 0.15, 0.25, 0.30, 0.15)

E_S <- sum(valori * prob)
E_S2 <- sum(valori^2 * prob)

# Formula diretta
Var_diretta <- sum((valori - E_S)^2 * prob)

# Formula alternativa
Var_alternativa <- E_S2 - E_S^2

cat("E[S] =", E_S, "\n")
#> E[S] = 4.1
cat("E[S²] =", E_S2, "\n")
#> E[S²] = 18.7
cat("Varianza (formula diretta):", round(Var_diretta, 4), "\n")
#> Varianza (formula diretta): 1.89
cat("Varianza (formula alternativa):", round(Var_alternativa, 4), "\n")
#> Varianza (formula alternativa): 1.89
```

Le due formule producono lo stesso risultato, come atteso.

Varianza della somma di due scale indipendenti:

```
# Per variabili indipendenti: Var(S1 + S2) = Var(S1) + Var(S2)
Var_somma_teorica <- 2 * Var_diretta

# Verifica con simulazione
set.seed(123)
n_sim <- 100000
S1 <- sample(valori, n_sim, replace = TRUE, prob = prob)
S2 <- sample(valori, n_sim, replace = TRUE, prob = prob)
somma <- S1 + S2

cat("\nVarianza della somma (teorica):", round(Var_somma_teorica, 4), "\n")
#>
#> Varianza della somma (teorica): 3.78
cat("Varianza della somma (empirica):", round(var(somma) * (n_sim-1)/n_sim, 4), "\n")
#> Varianza della somma (empirica): 3.76
```


8.6. Proprietà algebriche della varianza

La varianza presenta proprietà algebriche simili a quelle del valore atteso, ma con differenze cruciali che hanno importanti implicazioni per la pratica statistica.

8.6.1. Trasformazioni lineari

Per qualsiasi variabile casuale X e per costanti a e b :

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

Dimostrazione. Sia $\mu = \mathbb{E}[X]$. Allora $\mathbb{E}[aX + b] = a\mu + b$ e quindi:

$$\begin{aligned} \text{Var}(aX + b) &= \mathbb{E}[(aX + b - a\mu - b)^2] \\ &= \mathbb{E}[a^2(X - \mu)^2] \\ &= a^2 \mathbb{E}[(X - \mu)^2] \\ &= a^2 \text{Var}(X). \end{aligned}$$

□

Osservazione: una traslazione (l'addizione di una costante b) **non modifica** la varianza. Ciò ha senso: spostare tutti i valori di una costante non cambia quanto sono dispersi tra loro. La moltiplicazione per una costante a , invece, amplifica o riduce la varianza proporzionalmente a a^2 .

8.6.2. Ponte applicativo: conversione tra scale

Questa proprietà risulta particolarmente utile nella **trasformazione delle scale psicometriche**. Ad esempio, convertendo un punteggio grezzo X in un punteggio standardizzato del tipo $T = 10X + 50$ (come avviene per i *T-score*), la varianza si trasforma come:

$$\text{Var}(T) = 10^2 \cdot \text{Var}(X) = 100 \cdot \text{Var}(X).$$

Si noti che il termine additivo (50) non ha alcun effetto sulla dispersione, ma solo il **coefficiente moltiplicativo** (10) la amplifica secondo il suo quadrato.

8.6.3. Additività della varianza per variabili indipendenti

Se X e Y sono variabili casuali **indipendenti**, allora:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

Questa è una differenza fondamentale rispetto al valore atteso: l'additività della varianza **richiede l'indipendenza**. In presenza di correlazione, la varianza della somma può essere maggiore o minore della somma delle varianze, a seconda del segno della covarianza.

i Esempio: perché l'indipendenza conta

Varianza con e senza indipendenza

Riprendiamo l'esempio di ansia (A) e depressione (D) con $\text{Var}(A) = 25$ e $\text{Var}(D) = 36$.

Se fossero indipendenti:

$$\text{Var}(A + D) = 25 + 36 = 61.$$

Con correlazione positiva ($\rho = 0.6$, tipica per comorbidità):

$$\text{Var}(A + D) = \text{Var}(A) + \text{Var}(D) + 2\text{Cov}(A, D).$$

La covarianza è $\text{Cov}(A, D) = \rho \cdot \sigma_A \cdot \sigma_D = 0.6 \cdot 5 \cdot 6 = 18$, quindi:

$$\text{Var}(A + D) = 25 + 36 + 2(18) = 97.$$

```
# Verifica con i dati simulati precedentemente
cat("Var(A) teorica: 25, empirica:", round(var(A), 1), "\n")
#> Var(A) teorica: 25, empirica: 23.5
cat("Var(D) teorica: 36, empirica:", round(var(D), 1), "\n")
#> Var(D) teorica: 36, empirica: 34.9
cat("Var(A+D) se indipendenti: 61\n")
#> Var(A+D) se indipendenti: 61
cat("Var(A+D) con correlazione teorica: 97\n")
#> Var(A+D) con correlazione teorica: 97
cat("Var(A+D) empirica:", round(var(A + D), 1), "\n")
#> Var(A+D) empirica: 92.3
```

La correlazione positiva **aumenta** la varianza della somma: quando una variabile è alta, l'altra tende a essere alta, amplificando la dispersione complessiva.

8.6.4. Varianza della media campionaria

Un risultato di diretta rilevanza per l'inferenza statistica riguarda la **varianza della media campionaria**. Siano $X_1, X_2, \dots, X_n$ variabili casuali **indipendenti e identicamente distribuite** (i.i.d.) con

$$\mathbb{E}[X_i] = \mu, \quad \text{Var}(X_i) = \sigma^2.$$

La media campionaria è definita come

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Applicando le proprietà della varianza:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right).$$

Poiché le variabili sono indipendenti, la varianza della somma è la somma delle varianze:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) = n\sigma^2.$$

Sostituendo:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

8.6.5. Ponte applicativo: perché campioni più grandi danno stime più precise

Questo risultato costituisce il **fondamento matematico** del principio per cui “più dati portano a stime più precise”. La varianza della media campionaria decresce linearmente con l’inverso della numerosità campionaria:

- con $n = 25$ pazienti, $\text{Var}(\bar{X}) = \sigma^2/25$;
- con $n = 100$ pazienti, $\text{Var}(\bar{X}) = \sigma^2/100$.

Quadruplicando la dimensione del campione, la varianza si riduce a un quarto. In termini di deviazione standard, ovvero l’errore standard della media, si ha:

$$\text{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Per dimezzare l’errore standard è necessario *quadruplicare* il campione. Questo legame inversamente proporzionale tra precisione e numerosità spiega perché gli studi clinici con campioni più ampi tendono a fornire stime dell’efficacia del trattamento più affidabili e meno influenzate dalla variabilità individuale.

```
# Simulazione della varianza della media per diversi n
set.seed(123)
sigma2 <- 100 # Varianza della popolazione
n_values <- c(5, 10, 25, 50, 100, 200)
n_rep <- 1000

risultati <- data.frame(
  n = integer(),
  var_media = numeric()
)

for (n in n_values) {
  medie <- replicate(n_rep, mean(rnorm(n, mean = 50, sd = sqrt(sigma2))))
  risultati <- rbind(risultati, data.frame(
    n = n,
    var_media = var(medie),
    var_teorica = sigma2 / n
  ))
}

ggplot(risultati, aes(x = n)) +
  geom_point(aes(y = var_media), size = 3) +
  geom_line(aes(y = var_teorica), linewidth = 1) +
```

```
scale_x_continuous(breaks = n_values) +
labs(
  x = "Dimensione campionaria (n)",
  y = "Varianza della media campionaria",
  title = expression(Var(bar(X)) == sigma^2 / n)
)
```




Figura 8.1.: La varianza della media campionaria decresce con la dimensione del campione. Questo è il fondamento della precisione statistica.

i Approfondimento inferenziale

Le proprietà della media campionaria che abbiamo derivato hanno conseguenze profonde per l'inferenza statistica. Nel Capitolo 10 esploreremo in dettaglio come questi risultati si concretizzino operativamente nell'aggiornamento delle credenze e nella quantificazione dell'incertezza, introducendo strumenti centrali come la distribuzione campionaria, la funzione di verosimiglianza e l'errore standard.

8.7. Deviazione standard e standardizzazione

La varianza è definita come il valore atteso degli scarti al quadrato dalla media, il che implica che la sua unità di misura è il **quadrato** di quella della variabile originale. Se, ad esempio, misuriamo il miglioramento in punti al BDI-II, la varianza sarà espressa in “punti al quadrato”, un'unità priva di interpretazione clinica diretta.

Per ottenere una misura di dispersione che sia **nella stessa scala dei dati** osservati, si introduce la *deviazione standard*.

Definizione 8.3 (Deviazione standard). La *deviazione standard* di una variabile casuale X è definita come

$$\sigma_X = \text{SD}(X) = \sqrt{\text{Var}(X)}.$$

La deviazione standard misura la dispersione in unità direttamente confrontabili con i valori osservati. In termini intuitivi, essa rappresenta una “distanza tipica” dei valori dalla media.

8.7.1. Standardizzazione

Un ulteriore passo concettualmente importante consiste nel trasformare una variabile casuale in una forma *standardizzata*, eliminando l’effetto della scala e della posizione.

Definizione 8.4 (Variabile standardizzata). Data una variabile casuale X con valore atteso $\mathbb{E}[X] = \mu$ e deviazione standard $\text{SD}(X) = \sigma$, la *variabile standardizzata* è definita come

$$Z = \frac{X - \mu}{\sigma}.$$

La variabile standardizzata Z ha sempre:

$$\mathbb{E}[Z] = 0, \quad \text{Var}(Z) = 1,$$

indipendentemente dalla distribuzione originaria di X . La standardizzazione esprime ogni osservazione in termini di **quante deviazioni standard** essa si discosta dalla media.

i Esempio: confronto tra scale psicometriche diverse

Standardizzazione per confrontare misure eterogenee

Immaginiamo che una psicologa clinica voglia confrontare la gravità dei sintomi di due pazienti valutati con strumenti diversi:

- **Paziente A:** punteggio BDI-II = 28 (scala 0–63, con media $\mu = 14$ e deviazione standard $\sigma = 10$ nella popolazione di riferimento).
- **Paziente B:** punteggio PHQ-9 = 18 (scala 0–27, con media $\mu = 10$ e deviazione standard $\sigma = 6$ nella stessa popolazione).

Senza la standardizzazione, i punteggi grezzi non sono direttamente confrontabili, poiché le due scale differiscono per intervallo, unità di misura e distribuzione dei punteggi nella popolazione.

```
# Standardizzazione
z_A <- (28 - 14) / 10
z_B <- (18 - 10) / 6

cat("Paziente A (BDI-II = 28):\n")
#> Paziente A (BDI-II = 28):
cat("  z =", z_A, "deviazioni standard sopra la media\n\n")
#>   z = 1.4 deviazioni standard sopra la media

cat("Paziente B (PHQ-9 = 18):\n")
#> Paziente B (PHQ-9 = 18):
cat("  z =", round(z_B, 2), "deviazioni standard sopra la media\n\n")
#>   z = 1.33 deviazioni standard sopra la media

cat("Interpretazione: Il Paziente A mostra sintomi più gravi in termini relativi,\n")
#> Interpretazione: Il Paziente A mostra sintomi più gravi in termini relativi,
cat("essendo più lontano dalla media della sua distribuzione di riferimento.\n")
#> essendo più lontano dalla media della sua distribuzione di riferimento.
```

La standardizzazione rivela che il Paziente A, pur avendo un punteggio grezzo che sembra “moderato” sulla scala BDI-II, in realtà si colloca più in alto nella distribuzione rispetto al Paziente B sulla scala PHQ-9.

Conversione in T-score (media 50, SD 10):

```
T_A <- 50 + 10 * z_A
T_B <- 50 + 10 * z_B

cat("T-score Paziente A:", T_A, "\n")
#> T-score Paziente A: 64
cat("T-score Paziente B:", round(T_B, 1), "\n")
#> T-score Paziente B: 63.3
```

I T-score permettono un confronto immediato su una scala comune.

8.7.2. Ponte applicativo: la standardizzazione nella pratica clinica

La trasformazione in punti z (o in punteggi standardizzati analoghi) è uno strumento essenziale in psicomетria e nella valutazione clinica, poiché consente di:

1. **Confrontare punteggi provenienti da scale diverse** – come nell’esempio del BDI-II e del PHQ-9 – neutralizzando le differenze di media e dispersione.
2. **Interpretare la posizione di un individuo** all’interno della distribuzione del gruppo di riferimento, indipendentemente dalla scala originale.
3. **Identificare punteggi clinicamente rilevanti o estremi**: convenzionalmente, valori con $|z| > 2$ sono considerati atipici, mentre con $|z| > 3$ sono molto rari nella popolazione di riferimento.
4. **Costruire indicatori compositi** integrando misure che hanno unità e scale di misura differenti.

i Approfondimento: il teorema di Chebyshev

Una domanda che sorge naturalmente quando si interpretano deviazioni standard è: **quanta probabilità si concentra entro un certo numero di deviazioni standard dalla media?**

Il *teorema di Chebyshev* fornisce una risposta universale, applicabile a **qualsiasi distribuzione** con media e varianza finite, a prescindere dalla sua forma.

Teorema 8.5. Teorema di Chebyshev

Sia X una variabile casuale con media μ e deviazione standard σ . Per ogni $k > 0$ vale:

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Formulato in modo equivalente:

$$P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}.$$

Il teorema offre un **limite inferiore universale** alla probabilità che una qualsiasi osservazione cada entro k deviazioni standard dalla media:

k	$P(X - \mu < k\sigma) \geq$
1	0% (limite banale)
2	75%
3	88.9% (~89%)
4	93.75% (~94%)

Questi limiti sono **molto conservativi**. Per una distribuzione normale, le probabilità effettive sono notevolmente più alte: 68.3%, 95.4% e 99.7% rispettivamente per $k = 1, 2, 3$ — significativamente superiori a quanto garantito da Chebyshev.

Applicazione clinica

Immaginiamo che un test cognitivo abbia una media di 100 e una deviazione standard di 15 nella popolazione di riferimento, ma che nulla sia noto sulla forma della sua distribuzione. Grazie a Chebyshev possiamo comunque affermare che **almeno il 75%** dei punteggi si trova nell'intervallo $[70, 130]$, indipendentemente da come i punteggi siano distribuiti.

Questa proprietà è utile quando:

- la distribuzione è sconosciuta o non gaussiana;
- si desiderano conclusioni robuste con minime assunzioni;
- si lavora con scale nuove o non ancora completamente validate.

i Approfondimento: i momenti di una distribuzione

Momenti di una distribuzione

Il valore atteso e la varianza possono essere visti come i primi due **momenti** di una distribuzione — una famiglia di quantità che descrivono sistematicamente la forma della distribuzione.

Definizione 8.5. Momenti

Il *momento di ordine r* di una variabile casuale X è definito come:

$$\mathbb{E}[X^r] = \begin{cases} \sum_i x_i^r \cdot p_X(x_i) & \text{(caso discreto)} \\ \int_{-\infty}^{+\infty} x^r \cdot f_X(x) dx & \text{(caso continuo)} \end{cases}$$

Il *momento centrale di ordine r* è invece:

$$\mathbb{E}[(X - \mu)^r],$$

dove $\mu = \mathbb{E}[X]$.

- Il **momento di ordine 1** è il valore atteso (centro).
- Il **momento centrale di ordine 2** è la varianza (dispersione).
- Il **momento centrale di ordine 3** (normalizzato) è la **skewness** — misura l'asimmetria.
- Il **momento centrale di ordine 4** (normalizzato) è la **kurtosis** — misura quanto le code sono “pesanti”.

Questi concetti diventano rilevanti nella validazione di scale psicometriche (dove la normalità è spesso assunta) e nella scelta di modelli statistici appropriati.

Riflessioni conclusive

Il **valore atteso** e la **varianza** rappresentano i due strumenti fondamentali per sintetizzare una distribuzione di probabilità. Il primo identifica il centro della distribuzione, ovvero il suo *baricentro probabilistico*, mentre il secondo misura la dispersione dei valori attorno a questo centro, quantificando l'**incertezza residua** associata alla variabile.

Per lo psicologo clinico, questi concetti non sono mere astrazioni teoriche, ma strumenti operativi quotidiani. Quando comunichiamo a un paziente che “il miglioramento atteso è di circa 8 punti”, stiamo facendo riferimento al valore atteso. Se aggiungiamo che “la maggior parte dei pazienti mostra un miglioramento compreso tra 4 e 12 punti”, stiamo implicitamente descrivendo la varianza. Entrambi gli elementi sono essenziali per una comunicazione clinica completa e informativa.

Le proprietà algebriche di queste grandezze spiegano la loro importanza pratica. La **linearità del valore atteso** permette di calcolare in modo semplice le medie di somme e combinazioni lineari di variabili casuali: ecco perché il punteggio atteso di una scala psicometrica è semplicemente la somma dei punteggi attesi dei suoi item. Il comportamento della **varianza**, invece, sottolinea il ruolo cruciale dell'indipendenza: soltanto in assenza di dipendenza la varianza di una somma coincide con la somma delle varianze.

Il risultato secondo cui la varianza della media campionaria decresce come $1/n$ fornisce il **fondamento matematico della precisione statistica**: maggiore è il numero di osservazioni, minore sarà l'incertezza associata alla stima. Questo principio guida la progettazione degli studi clinici, determinando le dimensioni campionarie necessarie, e spiega come l'accumulo di evidenza empirica riduca progressivamente l'incertezza nelle nostre conclusioni.

Nel quadro bayesiano, questi concetti assumono una valenza pienamente **inferenziale**. Nei capitoli successivi, il valore atteso della distribuzione *a posteriori* fungerà da **stima puntuale razionale** del parametro di interesse, mentre la sua varianza misurerà l'incertezza residua dopo aver osservato i dati. In questo senso, valore atteso e varianza costituiscono il punto d'incontro tra probabilità, decisione e apprendimento: sintetizzano ciò che sappiamo, guidano le previsioni ottimali e rendono esplicito quanto ancora ignoriamo.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Valore atteso come centro di gravità probabilistico

- Media ponderata dei valori possibili, con pesi dati dalle probabilità.
- Rappresenta l'aspettativa razionale — la migliore previsione puntuale.
- Non deve necessariamente coincidere con un valore osservabile.
- Legge dei grandi numeri: la media campionaria converge al valore atteso.

2. Linearità del valore atteso (proprietà cruciale)

- $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ **sempre** (anche con dipendenza!).
- $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$ per costanti a, b .
- Applicazione: il punteggio atteso di una scala è la somma dei valori attesi degli item.

3. Varianza come misura di dispersione e incertezza

- $\text{Var}(X) = \mathbb{E}[(X - \mu)^2]$ quantifica quanto i valori si discostano dalla media.
- Interpretazione epistemica: perdita attesa usando il valore atteso come previsione.
- Formula computazionale: $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

4. Proprietà della varianza

- $\text{Var}(aX + b) = a^2\text{Var}(X)$ (traslazioni non cambiano dispersione).
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ **solo se** $X \perp Y$.
- Varianza della media campionaria: $\text{Var}(\bar{X}) = \sigma^2/n$ (fondamento della precisione statistica).

5. Deviazione standard e standardizzazione

- $\sigma = \sqrt{\text{Var}(X)}$ riporta la dispersione nelle unità originali.
- $Z = (X - \mu)/\sigma$ crea variabile con media 0 e varianza 1.
- Permette confronti tra scale diverse (es. BDI-II vs PHQ-9).

Formule da ricordare:

$$\mathbb{E}[X] = \sum_x x \cdot p_X(x) \quad \text{o} \quad \int x \cdot f_X(x) dx$$

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$$

Proprietà critiche:

- Linearità del valore atteso vale **sempre** (anche con dipendenza).
- Additività della varianza richiede **indipendenza**.
- La varianza della media decresce con n (più dati $\rightarrow$ meno incertezza).

Per il prossimo capitolo:

Nel Capitolo 9 studieremo come quantificare la **dipendenza stocastica** tra due variabili attraverso la covarianza e la correlazione, concetti essenziali per comprendere quando e perché l'additività della varianza fallisce e per costruire modelli in grado di catturare le relazioni tra le variabili psicologiche.

i Informazioni sull'ambiente di sviluppo

8. Proprietà delle variabili casuali

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] MASS_7.3-65      ragg_1.5.2        tinytable_0.17.0
#> [4] withr_3.0.3      systemfonts_1.3.2 patchwork_1.3.2
#> [7] ggdist_3.3.3     tidybayes_3.0.7   bayesplot_1.15.0
#> [10] ggplot2_4.0.3    reliabilitydiag_0.2.1 priorsense_1.2.0
#> [13] posterior_1.7.0  loo_2.10.0        rstan_2.32.7
#> [16] StanHeaders_2.32.10 brms_2.23.0       Rcpp_1.1.2
#> [19] sessioninfo_1.2.4 conflicted_1.2.0   janitor_2.2.1
#> [22] matrixStats_1.5.0 modelr_0.1.11      tibble_3.3.1
#> [25] dplyr_1.2.1      tidyr_1.3.2       rio_1.3.0
#> [28] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8      tidyselect_1.2.1   farver_2.1.2
#> [4] S7_0.2.2          fastmap_1.2.0      tensorA_0.36.2.1
#> [7] digest_0.6.39     timechange_0.4.0   estimability_2.0.0
#> [10] lifecycle_1.0.5   magrittr_2.0.5     compiler_4.6.1
#> [13] rlang_1.3.0       tools_4.6.1        yaml_2.3.12
#> [16] knitr_1.51        labeling_0.4.3     bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8    curl_7.1.0         RColorBrewer_1.1-3
#> [22] abind_1.4-8       purrr_1.2.2        grid_4.6.1
#> [25] stats4_4.6.1      xtable_1.8-8       inline_0.3.21
#> [28] emmeans_2.0.3     scales_1.4.0       cli_3.6.6
#> [31] mvtnorm_1.4-1     rmarkdown_2.31     generics_0.1.4
#> [34] otel_0.2.0        RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0     parallel_4.6.1     vctrs_0.7.3
#> [40] V8_8.2.0          Matrix_1.7-5       jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1 glue_1.8.1         codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5    stringi_1.8.7
#> [49] gtable_0.3.6      QuickJSR_1.10.0    pillar_1.11.1
#> [52] htmltools_0.5.9   Brodningnag_1.2-9  R6_2.6.1
#> [55] textshaping_1.0.5 rprojroot_2.1.1    evaluate_1.0.5
#> [58] lattice_0.22-9    backports_1.5.1    memoise_2.0.1
#> [61] broom_1.0.13      snakecase_0.11.1   rstantools_2.6.0
#> [64] coda_0.19-4.1     gridExtra_2.3.1    nlme_3.1-169
#> [67] checkmate_2.3.4   xfun_0.60          pkgconfig_2.0.3
```

9. Covarianza e correlazione

Introduzione

Un ricercatore sta analizzando i dati di uno studio sulla relazione tra ansia e prestazione cognitiva negli studenti universitari. I risultati preliminari mostrano che, in media, livelli più alti di ansia si associano a punteggi più bassi nei test di memoria di lavoro. Ma quanto è robusta questa associazione? È clinicamente o teoricamente rilevante? E come possiamo comunicare questo risultato in modo che sia confrontabile con altri studi, condotti su popolazioni diverse e con strumenti di misura differenti?

Queste domande richiedono strumenti che vadano oltre la descrizione di tendenze generali. La **covarianza** quantifica la tendenza di due variabili a variare insieme in modo sistematico, mentre la **correlazione** standardizza tale misura su una scala universale, permettendo confronti trasversali. Insieme, questi indici costituiscono il vocabolario essenziale per descrivere e comunicare relazioni tra variabili in psicologia.

Dal punto di vista bayesiano, covarianza e correlazione possono essere interpretate come **riassunti quantitativi della struttura delle nostre credenze**, così come codificata nella distribuzione congiunta. Quando affermiamo che due variabili sono correlate negativamente con $\rho = -0.40$, stiamo esprimendo una proprietà specifica di come crediamo che queste variabili si comportino congiuntamente, un'informazione che può derivare da dati osservati, da conoscenze teoriche pregresse, o da una combinazione delle due.

Prima di introdurre formalmente questi concetti, estenderemo brevemente il framework delle distribuzioni congiunte al caso di variabili continue, mostrando come le stesse idee si applichino quando le variabili assumono valori su scale numeriche continue.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- 1 – per il concetto di variabili casuali multiple.
- 2 – per densità congiunte.
- Capitolo 8 – **fondamentale** per valore atteso e varianza.

Questo capitolo estende al caso bivariato i concetti di valore atteso e varianza, introducendo misure di dipendenza lineare tra variabili.

Conoscenze matematiche richieste:

- Appendice C - per calcoli con distribuzioni discrete congiunte.
- Appendice F - per densità congiunte continue.

Competenze pratiche:

- Familiarità con R e visualizzazione di distribuzioni bivariate

Panoramica del capitolo

- Estensione al caso continuo: dalle tabelle alle densità congiunte.
- Covarianza come misura della co-variazione lineare.
- Correlazione come versione standardizzata della covarianza.
- Proprietà matematiche e loro significato pratico.
- Il concetto di incorrelazione e la sua relazione con l'indipendenza.
- Applicazioni nell'inferenza bayesiana e nella ricerca psicologica.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()

library(MASS)
library(viridis)
library(ggExtra)

# Riapplica il tema per sicurezza
apply_visual_theme()
```

9.1. Dalle tabelle discrete alle densità continue

Nel Capitolo 2 abbiamo utilizzato tabelle congiunte 2×2 per rappresentare in modo coerente le nostre credenze su coppie di variabili binarie. Gli stessi principi si estendono senza difficoltà anche a situazioni più complesse: tabelle con un numero maggiore di categorie quando le variabili assumono più livelli discreti e densità congiunte quando le variabili sono continue.

9.1.1. Tabelle con più categorie

Consideriamo un esempio tratto dalla letteratura psicologica: la relazione tra ansia e prestazione cognitiva negli studenti universitari. Numerosi studi suggeriscono una relazione negativa tra questi fattori (Eysenck et al., 2007). Supponiamo di codificare l'ansia in tre livelli (bassa, media, alta) e la prestazione in tre livelli (insufficiente, sufficiente, buona).

Una possibile distribuzione congiunta che rappresenta le nostre credenze, informate dalla letteratura, potrebbe essere la seguente:

	Ansia Bassa	Ansia Media	Ansia Alta	Marginale
Insufficiente	0.05	0.10	0.15	0.30
Sufficiente	0.15	0.20	0.10	0.45
Buona	0.10	0.10	0.05	0.25
Marginale	0.30	0.40	0.30	1.00

Ogni cella rappresenta il nostro grado di credenza in una specifica configurazione. Ad esempio, assegniamo una probabilità pari a 0.20 alla combinazione “prestazione sufficiente e ansia media”, mentre attribuiamo solo 0.05 alla configurazione “buona prestazione e ansia alta”, riflettendo l'idea di una relazione negativa tra ansia e prestazione.

I principi di costruzione e interpretazione sono gli stessi visti per le tabelle 2×2 : le distribuzioni marginali si ottengono sommando lungo le righe o le colonne, le distribuzioni condizionate si ricavano dividendo per la marginale appropriata e la coerenza è garantita dalla non negatività delle celle e dalla somma totale pari a uno.

9.1.2. Il caso continuo: densità congiunte

Quando le variabili assumono valori continui, come i punteggi su scale psicometriche standardizzate, i tempi di reazione o le misure fisiologiche, la distribuzione congiunta non può più essere rappresentata da una tabella finita, ma viene descritta mediante una **densità congiunta** $f(x, y)$.

L'interpretazione rimane invariata: la densità indica quanto riteniamo plausibile una determinata regione dello spazio delle configurazioni possibili.

Definizione 9.1. Una *densità congiunta* $f(x, y)$ assegna a ogni configurazione (x, y) un valore che rappresenta la concentrazione della credenza in quella regione. Per essere coerente, deve soddisfare:

1. **Non negatività:** $f(x, y) \geq 0$ per ogni (x, y) ;
2. **Normalizzazione:**

$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1.$$

Come nel caso discreto, la densità congiunta contiene *tutte* le informazioni sulle relazioni tra le variabili. Le densità marginali si ottengono integrando rispetto a una delle variabili:

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx.$$

Le densità condizionate si ottengono dividendo la densità congiunta per la marginale appropriata:

$$f_{X|Y}(x | y) = \frac{f(x, y)}{f_Y(y)}.$$

9.1.3. Regole di somma e prodotto per le densità congiunte

Le regole di somma e prodotto che abbiamo introdotto per le tabelle discrete si applicano senza modifiche concettuali anche nel caso continuo, sostituendo le somme con gli integrali.

- **Regola di somma (marginalizzazione)** La densità marginale di una variabile si ottiene integrando la densità congiunta rispetto all'altra:

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx, \quad f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy.$$

- **Regola di prodotto** La densità congiunta può essere scomposta come prodotto di una marginale e di una condizionata:

$$f_{X,Y}(x, y) = f_{Y|X}(y | x) f_X(x) = f_{X|Y}(x | y) f_Y(y).$$


Queste relazioni mostrano che conoscere la distribuzione congiunta equivale a conoscere tutte le distribuzioni marginali e condizionate, e viceversa. La distribuzione congiunta rimane quindi l'elemento fondamentale per descrivere le relazioni tra le variabili.

9.1.4. Visualizzazione di una distribuzione congiunta continua

Per rendere più concreto il concetto di densità congiunta, consideriamo nuovamente la relazione tra ansia e prestazione cognitiva, questa volta modellata come una distribuzione continua. Possiamo visualizzare la densità come una mappa termica in cui i colori più caldi indicano le configurazioni a cui attribuiamo una maggiore probabilità.

Distribuzione congiunta: Ansia e Prestazione

Colori più chiari = configurazioni a cui assegniamo



La visualizzazione rivela diversi aspetti della struttura delle nostre credenze. La regione più chiara, situata nella parte centro-sinistra in alto, rappresenta le configurazioni a cui attribuiamo la massima credibilità: bassa ansia associata a buona prestazione. Le regioni più scure, verso l'angolo in alto a destra, indicano configurazioni meno plausibili: alta ansia con buona prestazione. L'orientamento ellittico della distribuzione, inclinato verso il basso da sinistra a destra, riflette la correlazione negativa che abbiamo incorporato nelle nostre credenze sulla base della letteratura.

I grafici ai margini mostrano le densità marginali, ottenute proiettando la distribuzione congiunta su ciascun asse. Queste rappresentano le nostre credenze su ciascuna variabile singolarmente, quando non sono condizionate dall'altra.

! Dalla distribuzione congiunta ai riassunti numerici

La distribuzione congiunta contiene tutta l'informazione sulle relazioni tra le variabili. Tuttavia, comunicare e interpretare un'intera distribuzione può risultare complesso.

La covarianza e la correlazione sono riassunti numerici che:

- catturano l'aspetto *lineare* della relazione;
- condensano l'informazione in un singolo numero;
- comportano una perdita di informazione: dipendenze non lineari possono esistere anche in presenza di correlazione nulla.

Questi indici sono strumenti utili ma parziali: la distribuzione congiunta resta la fonte primaria dell'informazione.

9.2. Covarianza: misura della co-variazione lineare

9.2.1. La domanda fondamentale: le variabili si muovono insieme?

Prima di introdurre la formula matematica, consideriamo l'intuizione sottostante. Quando diciamo che due variabili "co-variano", intendiamo che tendono a muoversi insieme in modo sistematico:

- Quando l'**ansia** è sopra la sua media, la **prestazione** tende a essere sotto la sua media?
- Quando il **supporto sociale** è elevato, il **benessere** tende a essere elevato?
- Quando lo **stress** aumenta, i **sintomi depressivi** aumentano?

La covarianza formalizza questa intuizione, quantificando la tendenza delle variabili a deviare dalle rispettive medie nella stessa direzione (covarianza positiva) o in direzioni opposte (covarianza negativa).

9.2.2. Definizione formale

Definizione 9.2. La *covarianza* tra due variabili casuali X e Y è definita come:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Nel caso di variabili discrete con distribuzione congiunta $p(x, y)$, questa definizione assume la forma:

$$\text{Cov}(X, Y) = \sum_x \sum_y (x - \mu_X)(y - \mu_Y) p(x, y),$$

dove $\mu_X = \mathbb{E}[X]$ e $\mu_Y = \mathbb{E}[Y]$ sono i valori attesi delle due variabili.

L'interpretazione della covarianza emerge direttamente dalla struttura del prodotto $(X - \mu_X)(Y - \mu_Y)$:

- quando **entrambe** le variabili sono sopra le rispettive medie, il prodotto è **positivo** $(+)(+) = (+)$;
- quando **entrambe** sono sotto le rispettive medie, il prodotto è ancora **positivo** $(-)(-) = (+)$;
- quando una è sopra e l'altra sotto, il prodotto è **negativo** $(+)(-) = (-)$.

La covarianza è la media di questi prodotti, ponderata secondo la distribuzione congiunta:

- una **covarianza positiva** indica che le variabili tendono a muoversi nella stessa direzione;
- una **covarianza negativa** indica che tendono a muoversi in direzioni opposte;
- una **covarianza nulla** segnala l'assenza di una tendenza *lineare* sistematica.

9.2.3. Formula computazionale

La covarianza può essere calcolata in modo equivalente mediante la formula:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Questa espressione ha un'interpretazione illuminante: confronta il valore atteso del prodotto XY sotto la distribuzione congiunta effettiva con il valore che si otterrebbe se le variabili fossero **indipendenti** (nel qual caso $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$). La differenza misura quanto la distribuzione congiunta si discosti dall'indipendenza in termini di co-variazione lineare.

Dimostrazione della formula computazionale

Partiamo dalla definizione:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Espandiamo il prodotto:

$$= \mathbb{E}[XY - X\mathbb{E}[Y] - \mathbb{E}[X]Y + \mathbb{E}[X]\mathbb{E}[Y]].$$

Per la linearità del valore atteso e poiché $\mathbb{E}[X]$ e $\mathbb{E}[Y]$ sono costanti:

$$\begin{aligned} &= \mathbb{E}[XY] - \mathbb{E}[X\mathbb{E}[Y]] - \mathbb{E}[\mathbb{E}[X]Y] + \mathbb{E}[\mathbb{E}[X]\mathbb{E}[Y]] \\ &= \mathbb{E}[XY] - \mathbb{E}[Y]\mathbb{E}[X] - \mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[X]\mathbb{E}[Y]. \end{aligned}$$

Semplificando:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

9.2.4. Relazione con la varianza

La covarianza generalizza il concetto di varianza. In particolare, la varianza di una variabile è la covarianza della variabile con se stessa:

$$\mathbb{V}(X) = \text{Cov}(X, X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

Mentre la varianza misura quanto una singola variabile si discosta dal proprio valore atteso, la covarianza misura quanto le deviazioni di due variabili tendano a muoversi insieme.

9.2.5. Ponte applicativo: cosa ci dice la covarianza nella pratica clinica

Quando calcoliamo la covarianza tra ansia e prestazione e otteniamo un valore negativo, formalizziamo l'osservazione clinica secondo cui "i pazienti più ansiosi tendono a ottenere prestazioni peggiori". Tuttavia, la covarianza grezza presenta un limite importante: il suo valore numerico dipende dalle unità di misura utilizzate. Se misurassimo l'ansia su una scala da 0 a 100 invece che da 0 a 10, la covarianza cambierebbe di un fattore 10, anche se la *relazione* tra le variabili rimane invariata.

Questo ci porta alla necessità di utilizzare la correlazione.

i Esempio: calcolo dalla tabella congiunta

Applichiamo ora questi concetti alla tabella congiunta ansia-prestazione introdotta in precedenza. Utilizziamo la seguente codifica numerica: prestazione $X \in \{0, 1, 2\}$ (insufficiente, sufficiente, buona) e ansia $Y \in \{0, 1, 2\}$ (bassa, media, alta).

```
# Tabella congiunta
tab_joint <- matrix(
  c(0.05, 0.10, 0.15,
    0.15, 0.20, 0.10,
    0.10, 0.10, 0.05),
  nrow = 3, byrow = TRUE,
  dimnames = list(
    Prestazione = c("Insufficiente (0)", "Sufficiente (1)", "Buona (2)"),
    Ansia = c("Bassa (0)", "Media (1)", "Alta (2)")
  )
)

cat("Distribuzione congiunta:\n")
#> Distribuzione congiunta:
print(tab_joint)
#>
#>           Ansia
#> Prestazione  Bassa (0) Media (1) Alta (2)
#>  Insufficiente (0)    0.05    0.1    0.15
#>   Sufficiente (1)    0.15    0.2    0.10
#>    Buona (2)        0.10    0.1    0.05
```

Il primo passo consiste nel calcolare i valori attesi dalle distribuzioni marginali:

```

# Valori delle variabili
val_prest <- 0:2
val_ansia <- 0:2

# Distribuzioni marginali
marg_prest <- rowSums(tab_joint)
marg_ansia <- colSums(tab_joint)

# Valori attesi
E_X <- sum(val_prest * marg_prest)
E_Y <- sum(val_ansia * marg_ansia)

cat("\nDistribuzioni marginali:\n")
#>
#> Distribuzioni marginali:
cat("P(Prestazione):", marg_prest, "\n")
#> P(Prestazione): 0.3 0.45 0.25
cat("P(Ansia):", marg_ansia, "\n")
#> P(Ansia): 0.3 0.4 0.3
cat("\nValori attesi:\n")
#>
#> Valori attesi:
cat("E[Prestazione] =", round(E_X, 3), "\n")
#> E[Prestazione] = 0.95
cat("E[Ansia] =", round(E_Y, 3), "\n")
#> E[Ansia] = 1

```

Ora calcoliamo $\mathbb{E}[XY]$ sommando il prodotto xy pesato dalla probabilità congiunta $p(x, y)$:

```

# Calcolo di E[XY]
E_XY <- 0
for (i in 1:3) {
  for (j in 1:3) {
    E_XY <- E_XY + val_prest[i] * val_ansia[j] * tab_joint[i, j]
  }
}

cat("E[XY] =", round(E_XY, 3), "\n")
#> E[XY] = 0.8

```

Infine, applichiamo la formula computazionale:

```
# Covarianza
Cov_XY <- E_XY - E_X * E_Y

cat("\nCovarianza:\n")
#>
#> Covarianza:
cat("Cov(X,Y) = E[XY] - E[X]·E[Y]\n")
#> Cov(X,Y) = E[XY] - E[X]·E[Y]
cat("      =", round(E_XY, 3), "-", round(E_X, 3), "×", round(E_Y, 3), "\n")
#>      = 0.8 - 0.95 × 1
cat("      =", round(Cov_XY, 3), "\n")
#>      = -0.15
```

Questa covarianza negativa riflette la struttura delle nostre credenze: abbiamo assegnato una probabilità maggiore alle configurazioni in cui un'alta ansia si accompagna a una bassa prestazione, generando una co-variazione negativa sistematica.

9.3. Correlazione: covarianza standardizzata

9.3.1. Il problema delle unità di misura

La covarianza presenta un limite pratico rilevante: il suo valore numerico dipende dalle unità di misura delle variabili. Se misurassimo l'ansia su una scala da 0 a 100 anziché da 0 a 2, la covarianza cambierebbe di un fattore costante, anche se la struttura della relazione rimanesse invariata.

Questo rende impossibile rispondere a domande come: “La relazione tra ansia e prestazione nel mio studio è più forte o più debole di quella trovata in altri studi?”. La **correlazione** risolve questo problema standardizzando la covarianza.

Definizione 9.3. Il *coefficiente di correlazione* (o correlazione di Pearson) tra due variabili casuali X e Y è definito come:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\mathbb{V}(X) \mathbb{V}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y},$$

dove σ_X e σ_Y sono le deviazioni standard di X e Y .

La correlazione può essere interpretata come la covarianza tra le versioni **standardizzate** delle variabili. Dividendo il valore della covarianza per il prodotto delle deviazioni standard, si ottiene un indice adimensionale che misura la forza della relazione lineare su una scala universale.

9.3.2. Proprietà fondamentali

Il coefficiente di correlazione possiede proprietà che ne facilitano l'interpretazione:

1. **Limitatezza:** vale sempre $-1 \leq \rho(X, Y) \leq 1$.

2. **Invarianza rispetto a trasformazioni lineari:** se $a > 0$ e $b > 0$, allora

$$\rho(aX + c, bY + d) = \rho(X, Y).$$

Cambiare scala o origine delle misure non altera la correlazione.

3. **Valori estremi:**

- $\rho = +1$: relazione lineare perfetta positiva ($Y = a + bX$ con $b > 0$);
- $\rho = -1$: relazione lineare perfetta negativa ($Y = a + bX$ con $b < 0$);
- $\rho = 0$: assenza di relazione *lineare* (ma possibili dipendenze non lineari!).

9.3.3. Ponte applicativo: perché usiamo la correlazione negli articoli scientifici

La correlazione si è affermata come il *linguaggio comune* per comunicare l'intensità delle associazioni in psicologia e nelle scienze del comportamento per motivi ben precisi.

1. **Comparabilità:** un coefficiente $\rho = -0.40$ tra ansia e prestazione ha lo stesso significato numerico indipendentemente dalle scale specifiche utilizzate (es., GAD-7 vs. BAI, o diversi test di memoria di lavoro). Questo permette confronti diretti e meta-analitici tra studi condotti con strumenti e campioni differenti.
2. **Interpretabilità intuitiva:** il quadrato del coefficiente di correlazione, ρ^2 , rappresenta la **proporzione di varianza condivisa** tra le due variabili. Ad esempio, con $\rho = -0.40$, il 16% della variabilità osservata nella prestazione è “spiegata” (in senso statistico) dalla variabilità nei punteggi di ansia, e viceversa.
3. **Sintesi per la meta-analisi:** essendo una misura standardizzata e priva di unità di misura, la correlazione può essere facilmente aggregata e mediata tra una moltitudine di studi, permettendo di ottenere una stima più precisa e robusta dell'associazione “vera” a livello di popolazione, al netto delle singole peculiarità metodologiche.

i Esempio: correlazione ansia-prestazione

```
# Calcolo delle varianze
Var_X <- sum(val_prest^2 * marg_prest) - E_X^2
Var_Y <- sum(val_ansia^2 * marg_ansia) - E_Y^2

# Correlazione
rho_XY <- Cov_XY / sqrt(Var_X * Var_Y)

cat("Varianze:\n")
#> Varianze:
cat("Var(X) =", round(Var_X, 4), "\n")
#> Var(X) = 0.547
cat("Var(Y) =", round(Var_Y, 4), "\n")
#> Var(Y) = 0.6
cat("\nDeviazioni standard:\n")
#>
#> Deviazioni standard:
cat("_X =", round(sqrt(Var_X), 4), "\n")
#> _X = 0.74
cat("_Y =", round(sqrt(Var_Y), 4), "\n")
#> _Y = 0.775
cat("\nCorrelazione:\n")
#>
#> Correlazione:
cat("(X,Y) =", round(rho_XY, 3), "\n")
#> (X,Y) = -0.262
```

Il valore $\rho(X, Y) \approx -0.26$ indica una relazione lineare negativa di entità moderata. Questa interpretazione può essere articolata su tre livelli:

- la **direzione negativa** conferma che livelli elevati di ansia tendono a essere associati a prestazioni più basse;
- l'**intensità moderata** (circa 0.26 in valore assoluto) segnala che la relazione non è deterministica, ma che permane una considerevole variabilità non spiegata;
- la **varianza condivisa** è $\rho^2 = 0.068$, ovvero circa il 7% della variabilità di una variabile è associato alla variabilità dell'altra.

9.3.4. Linee guida interpretative e contesto psicologico

Le convenzioni suggerite da Cohen (1988) forniscono un punto di riferimento generale per interpretare l'entità di una correlazione:

- $|\rho| < 0.3$: correlazione **modesta** ("small");
- $0.3 \leq |\rho| < 0.5$: correlazione **moderata** ("medium");
- $|\rho| \geq 0.5$: correlazione **sostanziale** ("large").

Tuttavia, queste soglie devono essere sempre valutate alla luce del **contesto specifico** della ricerca psicologica. L'impatto pratico di una correlazione dipende fortemente dal dominio di studio. Di seguito alcuni riferimenti tipici:

Contesto psicometrico/sperimentale	Correlazione tipica	Interpretazione
Affidabilità test-retest	0.70 – 0.90	Valore necessario per scale considerate affidabili
Validità convergente	0.40 – 0.70	Scale che misurano costrutti simili dovrebbero correlare in questo intervallo
Validità discriminante	< 0.30	Scale che misurano costrutti distinti dovrebbero correlare debolmente
Predittori comportamentali	0.20 – 0.40	Intervallo tipico in psicologia sociale e della personalità
Effetti pre-post interventi clinici	0.50 – 0.80	Riflette un cambiamento clinicamente significativo

Una correlazione di $|\rho| = 0.26$ tra ansia e prestazione cognitiva, benché classificabile come “modesta” secondo Cohen, può avere una rilevanza pratica non trascurabile. Se la relazione ha una componente causale, anche una riduzione modesta dell'ansia potrebbe portare a un miglioramento tangibile delle prestazioni in una frazione rilevante della popolazione studentesca.

9.4. Proprietà matematiche della covarianza

Le proprietà matematiche della covarianza non sono soltanto risultati formali, ma hanno conseguenze pratiche rilevanti per l'analisi dei dati psicologici.

Teorema 9.1 (Proprietà della covarianza). *Siano X, Y e Z variabili casuali e a, b, c costanti reali. Allora valgono le seguenti proprietà:*

1. **Simmetria**

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

2. **Covarianza con una costante**

$$\text{Cov}(c, X) = 0.$$

3. **Linearità rispetto a moltiplicazione per costanti**

$$\text{Cov}(aX, bY) = ab \cdot \text{Cov}(X, Y).$$

4. **Additività rispetto alla somma**

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z).$$

5. **Varianza della somma**

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + 2 \text{Cov}(X, Y).$$

La proprietà della **varianza di una somma** merita particolare attenzione, poiché chiarisce come l'incertezza si propaga quando più componenti contribuiscono a un'unica quantità:

- se la covarianza è **positiva**, le fluttuazioni delle variabili tendono ad andare **nella stessa direzione**, amplificando la variabilità complessiva;
- se la covarianza è **negativa**, le fluttuazioni tendono a **compensarsi reciprocamente**, riducendo la variabilità totale;
- se la covarianza è **nulla** (ovvero le variabili sono incorrelate), la varianza della somma è semplicemente la **somma delle varianze** individuali.

9.4.1. Ponte applicativo: affidabilità delle scale composite

Questa proprietà spiega il motivo per cui le scale psicometriche composte da più item tendono a essere più affidabili (cioè meno influenzate dal rumore casuale) dei singoli item presi isolatamente. Quando gli item misurano lo stesso costrutto latente, tendono a essere **positivamente correlati** tra loro. Nella formula della varianza del punteggio totale, le covarianze positive tra item si sommano, **amplificando la componente di varianza comune**, ovvero il “segnale” attribuibile al costrutto sottostante, mentre l'errore di misura casuale tende a non correlare e a non accumularsi nella stessa misura. Il risultato è un punteggio totale più stabile e meno soggetto a fluttuazioni casuali rispetto a qualsiasi item individuale.

i Esempio: variabilità di un punteggio composto di benessere

Il benessere psicologico viene spesso concettualizzato come un costrutto multidimensionale. Consideriamo due componenti correlate:

- **benessere emotivo** ($\sigma_e = 0.4$);
- **benessere sociale** ($\sigma_s = 0.3$);
- correlazione tra le componenti: $\rho = 0.6$.

Il punteggio complessivo è una combinazione ponderata:

$$\text{Benessere} = 0.6 \cdot E + 0.4 \cdot S$$

```

# Definizione dei parametri
sigma_emotivo <- 0.4
sigma_sociale <- 0.3
rho <- 0.6

w_emotivo <- 0.6
w_sociale <- 0.4

# Covarianza tra le componenti
Cov_ES <- rho * sigma_emotivo * sigma_sociale

# Calcolo della varianza del punteggio composito
Var_benessere <- w_emotivo^2 * sigma_emotivo^2 +
  w_sociale^2 * sigma_sociale^2 +
  2 * w_emotivo * w_sociale * Cov_ES

sigma_benessere <- sqrt(Var_benessere)

cat("Componenti della varianza:\n")
#> Componenti della varianza:
cat("- Contributo emotivo: ", round(w_emotivo^2 * sigma_emotivo^2, 4), "\n")
#> - Contributo emotivo: 0.0576
cat("- Contributo sociale: ", round(w_sociale^2 * sigma_sociale^2, 4), "\n")
#> - Contributo sociale: 0.0144
cat("- Contributo covarianza: ", round(2 * w_emotivo * w_sociale * Cov_ES, 4), "\n")
#> - Contributo covarianza: 0.0346
cat("\nVarianza totale:", round(Var_benessere, 4), "\n")
#>
#> Varianza totale: 0.107
cat("Deviazione standard:", round(sigma_benessere, 3), "\n")
#> Deviazione standard: 0.326

```

Il termine di covarianza contribuisce significativamente alla varianza totale. Questo riflette il fatto che le due componenti tendono a variare insieme: quando il benessere emotivo è alto, anche quello sociale tende a essere alto, amplificando la variabilità complessiva del costrutto.

9.5. Incorrelazione e indipendenza

9.5.1. Definizione di incorrelazione

Due variabili casuali X e Y si dicono *incorrelate* quando la loro covarianza è nulla:

$$\text{Cov}(X, Y) = 0 \quad \Leftrightarrow \quad \rho(X, Y) = 0.$$

L'incorrelazione indica l'assenza di una *tendenza lineare sistematica* alla co-variazione. Sapere che X è sopra la sua media non ci dice nulla sulla direzione in cui Y tenderà a discostarsi dalla propria media.

9.5.2. La distinzione cruciale: incorrelazione non implica indipendenza

Una delle trappole concettuali più importanti in statistica riguarda la relazione tra incorrelazione e indipendenza.

! Relazione asimmetrica

- **L'indipendenza implica l'incorrelazione** Se X e Y sono indipendenti, allora necessariamente $\text{Cov}(X, Y) = 0$.
- **L'incorrelazione NON implica l'indipendenza** Possono esistere variabili con $\text{Cov}(X, Y) = 0$ che sono fortemente dipendenti in modo non lineare.

Questa asimmetria nasce dal fatto che la correlazione cattura esclusivamente la *componente lineare* della relazione. Le relazioni non lineari possono essere molto intense, ma produrre comunque una covarianza nulla.

9.5.3. Un esempio psicologico: la legge di Yerkes-Dodson

Un esempio classico di relazione non lineare in psicologia è la **legge di Yerkes-Dodson**, che descrive il legame tra arousal (attivazione fisiologica) e prestazione. Tale relazione ha una forma a **U rovesciata**: la prestazione migliora all'aumentare dell'arousal fino a un punto ottimale, dopodiché declina se l'arousal diventa eccessivo.

```
set.seed(42)
n <- 500

# Simuliamo arousal distribuito uniformemente
arousal <- runif(n, 0, 10)

# La prestazione segue una parabola invertita con rumore
# Massimo a arousal = 5
prestazione <- -0.4 * (arousal - 5)^2 + 10 + rnorm(n, 0, 1)

# Calcoliamo la correlazione
r_lineare <- cor(arousal, prestazione)

# Grafico
df_yd <- data.frame(arousal = arousal, prestazione = prestazione)

ggplot(df_yd, aes(x = arousal, y = prestazione)) +
  geom_point(alpha = 0.4, size = 1.5) +
  geom_smooth(method = "lm", se = FALSE, color = "red",
             linetype = "dashed", linewidth = 1) +
  geom_smooth(method = "loess", se = FALSE, color = "blue", linewidth = 1.2) +
  annotate("text", x = 8, y = 12,
         label = paste0("r = ", round(r_lineare, 3)),
         size = 4, color = "red") +
  labs(
    title = "Legge di Yerkes-Dodson: arousal e prestazione",
    subtitle = "Linea blu: relazione vera (curvilinea) | Linea rossa: regressione lineare"
```

```
x = "Livello di arousal",
y = "Prestazione"
)
```




Figura 9.1.: La legge di Yerkes-Dodson: relazione curvilinea tra arousal e prestazione. Nonostante la forte dipendenza, la correlazione lineare è quasi nulla.

```
cat("Correlazione lineare (Pearson): r =", round(r_lineare, 3), "\n")
#> Correlazione lineare (Pearson): r = 0.007
cat("Correlazione non lineare (Spearman):  =", round(cor(arousal, prestazione, method = "sp"), 3), "\n")
#> Correlazione non lineare (Spearman):  = 0.028
```

Interpretazione clinica: un terapeuta che valutasse soltanto la correlazione lineare tra ansia (una forma di arousal) e prestazione potrebbe concludere erroneamente che “non vi sia alcuna relazione”. In realtà, la relazione è forte ma curvilinea: sia livelli troppo bassi che troppo alti di ansia compromettono la prestazione. Questa intuizione ha implicazioni dirette per l'intervento: l'obiettivo non è eliminare l'ansia, ma modularla per raggiungere un livello ottimale.

i Esempio matematico: dipendenza perfetta con correlazione nulla

Per illustrare il punto in modo ancora più estremo, consideriamo una relazione quadratica perfetta:

$$Y = X^2, \quad \text{con } X \sim \text{Uniforme}(-2, 2)$$

```

set.seed(42)
n <- 1000
X <- runif(n, -2, 2)
Y <- X^2 + rnorm(n, 0, 0.3)

cat("Coefficiente di correlazione lineare di Pearson:\n")
#> Coefficiente di correlazione lineare di Pearson:
cat(" r(X, Y) =", round(cor(X, Y), 3), "\n\n")
#> r(X, Y) = -0.013


cat("Nonostante r ≈ 0, Y è COMPLETAMENTE determinato da X!\n")
#> Nonostante r ≈ 0, Y è COMPLETAMENTE determinato da X!
cat("La correlazione cattura solo la componente lineare della relazione.\n")
#> La correlazione cattura solo la componente lineare della relazione.

ggplot(data.frame(X = X, Y = Y), aes(x = X, y = Y)) +
  geom_point(alpha = 0.4, size = 1.5) +
  geom_smooth(method = "lm", se = FALSE, color = "red", linetype = "dashed") +
  stat_function(fun = function(x) x^2, color = "blue", linewidth = 1) +
  labs(
    title = "Relazione quadratica Y = X² + ε",
    subtitle = "La correlazione lineare è zero, ma la dipendenza è perfetta",
    x = "X",
    y = "Y"
  )

```

Relazione quadratica $Y = X^2 + \varepsilon$

La correlazione lineare è zero, ma la dipendenza è perfetta



La correlazione è nulla perché la relazione è simmetrica rispetto a zero: per $X > 0$ la relazione è positiva, per $X < 0$ è negativa, e le due tendenze si compensano esattamente nel calcolo della covarianza lineare.

9.5.4. Implicazioni pratiche per la ricerca

La lezione operativa è cruciale: **un coefficiente di correlazione pari a zero non autorizza di per sé a concludere che non esista alcuna associazione tra due variabili**. Prima di affermare l'assenza di relazione, è necessario:

1. **visualizzare sempre i dati** con uno scatterplot, esaminando possibili pattern curvilinei o a cluster;
2. **considerare relazioni non lineari** teoricamente plausibili nel dominio di ricerca (come l'esempio di Yerkes-Dodson);
3. **utilizzare misure complementari** quando appropriato, come la correlazione di Spearman per rilevare relazioni monotone, o modelli di regressione flessibili.

La correlazione è uno strumento potente, ma la sua interpretazione è **limitata alla componente lineare** della dipendenza. Confondere “assenza di correlazione lineare” con “assenza di relazione” è un errore metodologico comune che può portare a conclusioni errate.

9.6. Covarianza nell'inferenza bayesiana

Nell'inferenza bayesiana, la covarianza non svolge soltanto un ruolo descrittivo, ma diventa parte integrante della rappresentazione delle nostre credenze sui parametri del modello.

9.6.1. Covarianza a priori

Prima di osservare i dati, possiamo specificare una distribuzione a priori sui parametri che includa una struttura di covarianza. Questa scelta riflette le nostre assunzioni teoriche sulle relazioni tra i parametri.

```
# Prior multivariata normale per due parametri
mu_prior <- c(0, 0)
Sigma_prior <- matrix(c(1, 0.7, 0.7, 1), nrow = 2)

# Simuliamo dalla prior
set.seed(123)
samples_prior <- mvrnorm(1000, mu_prior, Sigma_prior)


cat("Matrice di covarianza a priori:\n")
#> Matrice di covarianza a priori:
print(Sigma_prior)
#>      [,1] [,2]
#> [1,]  1.0  0.7
#> [2,]  0.7  1.0
cat("\nCorrelazione a priori tra parametri:", 0.7, "\n")
#>
#> Correlazione a priori tra parametri: 0.7

# Visualizzazione
ggplot(as.data.frame(samples_prior), aes(x = V1, y = V2)) +
  geom_point(alpha = 0.4) +
  labs(
```

```

title = "Prior multivariata con correlazione 0.7",
subtitle = "Credenze iniziali sulla relazione tra parametri",
x = expression(theta[1]),
y = expression(theta[2])
)

```



Specificare una correlazione positiva nella prior equivale ad affermare che riteniamo plausibile una variazione congiunta dei due parametri: valori elevati di uno tendono ad accompagnarsi a valori elevati dell'altro.

9.6.2. Covarianza a posteriori

Dopo l'osservazione dei dati, la distribuzione a posteriori presenta una propria struttura di covarianza che rappresenta lo stato aggiornato delle nostre credenze. La covarianza a posteriori riflette l'interazione tra l'informazione a priori e l'evidenza empirica.

9.6.3. Ponte applicativo: interpretare l'incertezza congiunta sui parametri

In un modello di regressione, la **covarianza a posteriori tra i parametri**, per esempio tra l'intercetta (β_0) e la pendenza (β_1), rivela come le incertezze sui singoli parametri sono correlate tra loro. Una covarianza negativa (comune quando il predittore non è centrato sullo zero) indica che una sovrastima dell'intercetta tende ad associarsi a una sottostima della pendenza, e viceversa. Questa informazione è essenziale per:

- **costruire intervalli di credibilità congiunti**, che descrivono regioni plausibili per le coppie di valori dei parametri, piuttosto che limitarsi a considerare i parametri singolarmente;
- **propagare correttamente l'incertezza** nelle previsioni, poiché gli errori nei parametri non sono indipendenti;
- **valutare l'identificabilità del modello**, in quanto una covarianza molto elevata in valore assoluto può segnalare collinearità o problemi di stima.

Riflessioni conclusive

La covarianza e la correlazione sono strumenti fondamentali per quantificare la relazione lineare tra due variabili casuali. Come abbiamo visto, questi indici emergono naturalmente dalla distribuzione congiunta e ne forniscono una sintesi numerica utile, ma inevitabilmente parziale.

Per lo psicologo clinico e il ricercatore, questi concetti hanno un'utilità pratica immediata:

- **nella validazione degli strumenti:** le correlazioni misurano la validità convergente e discriminante tra scale;
- **nello studio delle differenze individuali:** quantificano l'intensità delle associazioni tra tratti di personalità, stati emotivi e comportamenti;
- **nella pratica clinica:** informano sulle aspettative di comorbidità, aiutando a prevedere la probabilità congiunta di sintomi;
- **nella modellazione statistica:** la matrice di covarianza è il cuore della regressione multipla, dell'analisi fattoriale e dei modelli a equazioni strutturali.

Un avvertimento cruciale emerso nel capitolo è che la covarianza e la correlazione catturano **soltanto la componente lineare** della relazione. L'esempio della legge di Yerkes-Dodson mostra come associazioni psicologicamente significative possano rimanere nascoste a questi indici. Per un'analisi solida, l'esplorazione numerica sempre essere affiancata da un'attenta **visualizzazione dei dati**.

Nel prosieguo del manuale incontreremo spesso distribuzioni multivariate, in particolare la **distribuzione normale multivariata**, in cui l'intera struttura di dipendenza lineare è codificata nella matrice di covarianza. La padronanza dei concetti qui sviluppati è un prerequisito indispensabile per poter utilizzare tali modelli in modo critico e informato.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Dalle tabelle discrete alle densità congiunte

- Estensione naturale al caso continuo: $f(x, y)$ è la densità congiunta.
- Regole di somma e prodotto si applicano sostituendo somme con integrali.
- La distribuzione congiunta contiene tutta l'informazione sulle relazioni.

2. Covarianza come misura della co-variazione lineare

- $\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$ quantifica la tendenza a variare insieme;
- positiva: valori alti insieme, bassi insieme;
- negativa: valori alti con bassi;
- nulla: assenza di relazione lineare sistematica.

3. Formula computazionale della covarianza

- $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.
- Confronta il prodotto osservato con quello atteso sotto indipendenza.

4. Correlazione come standardizzazione

- $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$.

- Sempre $-1 \leq \rho \leq 1$ (adimensionale).
- Permette confronti tra studi e scale diverse.

5. Incorrelazione $\neq$ indipendenza

- Indipendenza $\Rightarrow$ incorrelazione (sempre).
- Incorrelazione $\nRightarrow$ indipendenza (relazioni non lineari!).
- Esempio: legge di Yerkes-Dodson (arousal-prestazione).

6. Varianza della somma

- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$.
- Spiega perché scale composite sono più affidabili.

Formule da ricordare:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

Linee guida interpretative (Cohen): - $|\rho| < 0.3$: modesta; - $0.3 \leq |\rho| < 0.5$: moderata; - $|\rho| \geq 0.5$: sostanziale.

Per il prossimo capitolo:

nel Capitolo 10 passeremo all'**inferenza statistica**, presentando la *distribuzione campionaria*, l'*errore standard* e il *teorema del limite centrale*. Questi concetti rappresentano il ponte concettuale tra la probabilità, che descrive fenomeni aleatori, e la statistica inferenziale di stampo bayesiano, che aggiorna le nostre credenze alla luce dei dati osservati.

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ggExtra_0.11.0      viridis_0.6.5      viridisLite_0.4.3
#> [4] MASS_7.3-65         ragg_1.5.2          tinytable_0.17.0
#> [7] withr_3.0.3         systemfonts_1.3.2  patchwork_1.3.2
#> [10] ggdist_3.3.3        tidybayes_3.0.7    bayesplot_1.15.0
#> [13] ggplot2_4.0.3       reliabilitydiag_0.2.1 priorsense_1.2.0
#> [16] posterior_1.7.0     loo_2.10.0         rstan_2.32.7
#> [19] StanHeaders_2.32.10 brms_2.23.0        Rcpp_1.1.2
#> [22] sessioninfo_1.2.4   conflicted_1.2.0   janitor_2.2.1
#> [25] matrixStats_1.5.0   modelr_0.1.11      tibble_3.3.1
#> [28] dplyr_1.2.1         tidyr_1.3.2        rio_1.3.0
#> [31] here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] gridExtra_2.3.1      inline_0.3.21      rlang_1.3.0
#> [4] magrittr_2.0.5       snakecase_0.11.1   otel_0.2.0
#> [7] compiler_4.6.1       mgcv_1.9-4         vctrs_0.7.3
#> [10] stringr_1.6.0        pkgconfig_2.0.3    arrayhelpers_1.1-1
#> [13] fastmap_1.2.0        backports_1.5.1    labeling_0.4.3
#> [16] promises_1.5.0       rmarkdown_2.31     purrr_1.2.2
#> [19] xfun_0.60            cachem_1.1.0       jsonlite_2.0.0
#> [22] later_1.4.8          broom_1.0.13       parallel_4.6.1
#> [25] R6_2.6.1            stringi_1.8.7      RColorBrewer_1.1-3
#> [28] lubridate_1.9.5      estimability_2.0.0 knitr_1.51
#> [31] splines_4.6.1        httpuv_1.6.17      Matrix_1.7-5
#> [34] timechange_0.4.0     tidyselect_1.2.1   abind_1.4-8
#> [37] yaml_2.3.12          codetools_0.2-20   miniUI_0.1.2
#> [40] curl_7.1.0           pkgbuild_1.4.8     lattice_0.22-9
#> [43] shiny_1.14.0         bridgesampling_1.2-1 S7_0.2.2
#> [46] coda_0.19-4.1        evaluate_1.0.5     isoband_0.3.0
#> [49] RcppParallel_5.1.11-2 pillar_1.11.1      tensorA_0.36.2.1
#> [52] checkmate_2.3.4      stats4_4.6.1       distributional_0.8.1
#> [55] generics_0.1.4       rprojroot_2.1.1    rstantools_2.6.0
#> [58] scales_1.4.0         xtable_1.8-8       glue_1.8.1
#> [61] emmeans_2.0.3        tools_4.6.1        mvtnorm_1.4-1
#> [64] grid_4.6.1           QuickJSR_1.10.0    nlme_3.1-169
#> [67] cli_3.6.6            textshaping_1.0.5  svUnit_1.0.8
#> [70] Brodingtonag_1.2-9   V8_8.2.0           gtable_0.3.6

```

Bibliografia

Parte III.

PARTE 3: Distribuzioni specifiche

10. Dal dato all'ipotesi: l'evidenza e l'aggiornamento delle credenze

Introduzione

Un psicologo clinico sta valutando se adottare un nuovo protocollo di intervento per la depressione nella propria struttura. I dati di uno studio pilota mostrano che il 36% dei pazienti trattati ha raggiunto la remissione completa dei sintomi. Ma cosa significa realmente questa stima? Può affidarsi a questo numero per prendere una decisione che riguarderà decine di pazienti futuri?

Il 36% osservato è una **stima puntuale**, ma non ci dice quanto potremmo essere lontani dal valore “vero”, cioè la proporzione di remissione che osserveremmo se potessimo trattare l'intera popolazione di pazienti con caratteristiche simili. Forse l'efficacia reale è del 45% e lo studio l'ha sottostimata casualmente. Oppure potrebbe essere solo del 25%, e lo studio l'ha invece sovrastimata. La differenza tra questi scenari ha implicazioni cliniche sostanziali.

La domanda cruciale diventa quindi: **come possiamo quantificare l'incertezza sulle quantità di interesse a partire da dati limitati?** In che modo possiamo esprimere, in termini probabilistici, il grado di fiducia che l'efficacia del trattamento rientri in un certo intervallo?

L'approccio che seguiremo in questo capitolo considera i *parametri* di un modello statistico, come proporzioni, medie e varianze, non come valori fissi, ma come quantità ignote su cui possediamo un'incertezza di tipo **epistemico**. Questa incertezza viene rappresentata tramite distribuzioni di probabilità. Prima di osservare i dati, formalizziamo le nostre conoscenze preliminari attraverso una distribuzione *a priori*. Dopo aver raccolto i dati, aggiorniamo tali credenze ottenendo una distribuzione *a posteriori*. Questo meccanismo di aggiornamento coerente delle credenze alla luce dell'evidenza empirica costituisce il nucleo dell'inferenza bayesiana.

Un esempio concreto: la stima della prevalenza dei sintomi depressivi

Immaginiamo di voler stimare la prevalenza di sintomi depressivi clinicamente rilevanti nella popolazione studentesca universitaria. Poiché non è possibile osservare l'intera popolazione, ci affidiamo a un campione e utilizziamo l'inferenza statistica per generalizzare i risultati.

Supponiamo di reclutare un campione casuale di 200 studenti universitari, rilevando che 72 di loro presentano sintomi depressivi clinicamente significativi (punteggio PHQ-9 ≥ 10). Il nostro obiettivo è stimare il parametro θ , che rappresenta la **vera prevalenza** di tali sintomi nella popolazione di riferimento, e quantificare l'incertezza associata a questa stima.

Nell'approccio bayesiano, il processo inferenziale inizia **prima** della raccolta dei dati. Le nostre conoscenze preliminari su θ (ad esempio, da studi precedenti o considerazioni teoriche) vengono formalizzate in una distribuzione *a priori*. Dopo aver osservato i dati – 72 casi su 200 – queste credenze vengono aggiornate attraverso il teorema di Bayes, producendo una distribuzione *a posteriori* per il parametro θ .

A partire dalla distribuzione a posteriori possiamo ricavare diverse sintesi statistiche. Una delle più informative è l'**intervallo di credibilità**, che riassume l'incertezza sulla stima del parametro. Ad esempio, un intervallo di credibilità al 95% per θ potrebbe essere [0.29; 0.43]. L'interpretazione è diretta: alla luce delle informazioni disponibili (prior e dati), riteniamo che vi sia una probabilità del 95% che il valore vero della prevalenza nella popolazione si trovi tra 0.29 e 0.43.

Questa interpretazione probabilistica dell'incertezza è non solo formalmente corretta, ma anche intuitiva per ricercatori e clinici, poiché riflette il modo naturale in cui esprimiamo la fiducia nelle nostre stime dopo aver osservato i dati.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 5 — **fondamentale**.
- 1.
- 2.
- Capitolo 8 — per valore atteso, varianza, SE.

Questo capitolo segna il passaggio dalla teoria della probabilità all'**inferenza statistica bayesiana**, mostrando come quantificare l'incertezza sui parametri sconosciuti a partire dai dati campionari.

Lecture complementari consigliate:

- Schervish, M. J. (2014). *Theory of Statistics*, capitolo “Sampling Distributions of Estimators” (Schervish & DeGroot, 2014).

Competenze pratiche:

- Familiarità con R per simulazioni e calcolo di distribuzioni campionarie.

Panoramica del capitolo

- Comprendere le proprietà statistiche della media campionaria (valore atteso, varianza, SE) e il loro significato inferenziale.
- Comprendere la distribuzione campionaria; come la sua forma determina la verosimiglianza che i dati impongono sui parametri.
- Legge dei Grandi Numeri: perché la media campionaria converge al valore vero e quali implicazioni ha per l'affidabilità delle stime.
- Teorema del Limite Centrale: quando e perché la distribuzione delle medie può essere approssimata con una distribuzione gaussiana e quali sono i limiti pratici di tale approssimazione.
- Come costruire prior, verosimiglianza e posterior; calcolo degli intervalli di credibilità e interpretazione probabilistica.
- Ruolo dell'errore standard come misura di informatività; definizione di precisione e regole di somma delle precisioni per sintetizzare studi indipendenti.
- Analisi di sensibilità per valutare l'effetto dei prior sulla posterior.
- Distinzione tra incertezza campionaria e distorsioni sistematiche e strategie metodologiche per mitigarle.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

10.1. Dati, parametri e incertezza

10.1.1. Dati osservati e parametro di interesse

Riprendiamo l'esempio introdotto in precedenza, relativo alla stima della prevalenza θ di studenti con sintomi depressivi clinicamente rilevanti. Dopo aver selezionato un campione rappresentativo di n studenti, registriamo per ciascun partecipante la presenza (1) o l'assenza (0) del sintomo.

Le osservazioni campionarie possono essere formalizzate come variabili casuali binarie $X_1, X_2, \dots, X_n$, dove:

$$X_i = \begin{cases} 1 & \text{se lo studente } i \text{ presenta sintomi (PHQ-9} \geq 10), \\ 0 & \text{altrimenti.} \end{cases}$$

Questa rappresentazione esplicita il collegamento tra i dati osservati e un modello probabilistico sottostante. In particolare, permette di descrivere formalmente l'incertezza associata alle osservazioni e di legarla direttamente al parametro di interesse θ , che rappresenta la vera proporzione del fenomeno nella popolazione di riferimento.

10.1.2. Dalla statistica descrittiva all'inferenza probabilistica

Una prima sintesi dei dati osservati è fornita dalla proporzione campionaria:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{\text{numero di studenti con sintomo}}{n}.$$

Nel nostro esempio, $\bar{X} = 72/200 = 0.36$. Questa quantità riassume l'informazione contenuta nel campione, ma ha un ruolo puramente descrittivo. Il nostro obiettivo non è semplicemente quello di descrivere i dati osservati, ma di utilizzare tali informazioni per trarre conclusioni sul parametro θ , che non è direttamente osservabile.

La questione centrale diventa quindi la seguente: **in che modo il valore osservato di $\bar{X}$ dovrebbe modificare la nostra incertezza riguardo a θ ?** Per rispondere a questa domanda, è necessario andare oltre la statistica descrittiva e adottare un approccio inferenziale basato su un modello probabilistico.

10.1.3. Il modello probabilistico di riferimento

Per collegare i dati osservati al parametro di interesse, costruiamo un modello probabilistico che metta in relazione:

1. le osservazioni empiriche $X_1, \dots, X_n$;
2. il parametro θ , considerato come una quantità sconosciuta e soggetta a incertezza epistemica;
3. le informazioni disponibili prima dell'osservazione dei dati.

Assumiamo che, condizionatamente al parametro θ , ciascuna osservazione segua una distribuzione di Bernoulli:

$$X_i \mid \theta \sim \text{Bernoulli}(\theta).$$

Questa assunzione formalizza l'idea che, se il valore di θ fosse noto, la probabilità che uno studente qualsiasi presenti il sintomo sarebbe pari a θ . Il modello specifica quindi come i dati sarebbero generati per ciascun valore possibile del parametro.

i Notazione condizionale e sua interpretazione

La notazione $X_i \mid \theta$ indica che stiamo descrivendo la distribuzione della variabile casuale X_i a condizione che il parametro θ sia fissato a un valore specifico. Questa formulazione non implica che il valore di θ sia noto, ma serve a strutturare il ragionamento inferenziale: se θ assumesse un certo valore, allora le osservazioni seguirebbero una determinata distribuzione.

10.2. Proprietà fondamentali della media campionaria

Nel Capitolo 8 abbiamo già derivato le proprietà algebriche di base della media campionaria come applicazioni dirette della linearità del valore atteso e dell'additività della varianza per variabili indipendenti. Abbiamo visto che $\mathbb{E}[\bar{X}] = \mu$ e che $\text{Var}(\bar{X}) = \sigma^2/n$.

In questa sezione, **approfondiamo il significato inferenziale** di questi risultati, esaminandoli in relazione all'incertezza sul parametro θ e collegandoli esplicitamente alla struttura del processo di campionamento.

10.2.1. Valore atteso della media campionaria

Supponiamo di avere osservazioni $X_1, X_2, \dots, X_n$ **indipendenti e identicamente distribuite** (i.i.d.), ciascuna con valore atteso

$$\mathbb{E}[X_i \mid \theta] = \theta.$$

Teorema 10.1. *Il valore atteso della media campionaria è:*

$$\mathbb{E}[\bar{X} \mid \theta] = \theta.$$

Dimostrazione. Per definizione, la media campionaria è:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Applicando l'operatore di valore atteso:

$$\mathbb{E}[\bar{X} \mid \theta] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i \mid \theta\right].$$

Per la linearità del valore atteso:

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i \mid \theta].$$

Poiché tutte le variabili sono identicamente distribuite con valore atteso pari a θ :

$$= \frac{1}{n} \cdot n\theta = \theta.$$

□

Interpretazione: questo risultato mostra che la media campionaria è *centrata* sul valore del parametro θ . In assenza di errori sistematici, $\bar{X}$ non tende né a sovrastimare né a sottostimare la prevalenza reale nella popolazione. Questa proprietà giustifica l'uso della media campionaria come base per l'inferenza.

10.2.2. Varianza della media campionaria

La seconda proprietà fondamentale riguarda la *variabilità* della media campionaria.

Teorema 10.2. *Se le osservazioni sono indipendenti e ciascuna ha varianza*

$$\text{Var}(X_i \mid \theta) = \sigma^2,$$

allora:

$$\text{Var}(\bar{X} \mid \theta) = \frac{\sigma^2}{n}.$$

Dimostrazione. Per definizione:

$$\text{Var}(\bar{X} \mid \theta) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i \mid \theta\right).$$

Usando la proprietà $\text{Var}(aY) = a^2\text{Var}(Y)$:

$$= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i \mid \theta\right).$$

Poiché le osservazioni sono indipendenti, la varianza della somma è la somma delle varianze:

$$= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i \mid \theta) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

□

Interpretazione: la variabilità della media campionaria diminuisce all'aumentare della dimensione del campione. In particolare:

- la varianza di $\bar{X}$ decresce proporzionalmente a $1/n$;
- per ridurre della metà la deviazione standard della media è necessario quadruplicare il numero di osservazioni.

10.2.3. Il caso delle variabili Bernoulliane

Nel contesto considerato, ciascuna osservazione X_i è una variabile aleatoria binaria. La varianza di una variabile Bernoulliana è:

$$\text{Var}(X_i | \theta) = \theta(1 - \theta).$$

La varianza della media campionaria (proporzione osservata) è quindi:

$$\text{Var}(\bar{X} | \theta) = \frac{\theta(1 - \theta)}{n}.$$

L'**errore standard (SE)** è la radice quadrata della varianza:

$$\text{SE}(\bar{X}) = \sqrt{\frac{\theta(1 - \theta)}{n}}.$$

L'errore standard quantifica la variabilità attesa della proporzione osservata da un campione all'altro. In termini bayesiani, fornisce un'indicazione diretta del **contenuto informativo dei dati**: un errore standard ridotto segnala che le osservazioni sono altamente informative e conducono a una distribuzione a posteriori concentrata.

10.2.4. Ponte applicativo: cosa significano queste proprietà per il ricercatore

Queste proprietà matematiche hanno conseguenze pratiche immediate:

1. **La proporzione campionaria è una buona stima:** poiché $E[\bar{X}] = \theta$, osservare $72/200 = 0.36$ ci dice che la nostra migliore stima puntuale della prevalenza è 36%.
2. **L'incertezza è quantificabile:** con $\theta \approx 0.36$ e $n = 200$, l'errore standard è circa $\sqrt{0.36 \times 0.64/200} \approx 0.034$, ovvero circa 3.4 punti percentuali.
3. **Campioni più grandi forniscono stime più precise:** se avessimo $n = 800$ studenti invece di 200, l'errore standard si dimezzerebbe.
4. **La regola del 4×:** per dimezzare l'incertezza è necessario quadruplicare il campione. Questa regola pratica è utile per la pianificazione degli studi.

10.3. Comprendere la variabilità dei dati

10.3.1. Il concetto di distribuzione campionaria

Immaginiamo di poter osservare molti campioni diversi, tutti della stessa dimensione n , estratti dalla stessa popolazione. Per ciascun campione potremmo calcolare la media campionaria $\bar{X}$, ottenendo ogni volta un valore potenzialmente diverso a causa della variabilità casuale del campionamento.

La **distribuzione campionaria** della media descrive come questi valori di $\bar{X}$ si distribuiscono al variare del campione. Essa non si riferisce a un singolo insieme di dati osservati, ma un esperimento ipotetico ripetuto molte volte nelle stesse condizioni.

Questo concetto teorico è fondamentale per comprendere il ruolo dei dati nell'inferenza statistica. La distribuzione campionaria costituisce la base della **funzione di verosimiglianza**, che quantifica quanto ciascun possibile valore del parametro θ sia compatibile con i dati osservati.

10.3.2. Esempio concreto: risposte a un item Likert

Per rendere il concetto più tangibile, consideriamo un esempio con dati psicologicamente riconoscibili. Supponiamo di avere una piccola popolazione di 4 partecipanti che hanno risposto a un item sulla soddisfazione di vita su una scala da 1 a 5:

```
# Risposte dei 4 partecipanti all'item "Sono soddisfatto della mia vita"
risposte <- c(2, 4, 4, 5)
risposte
#> [1] 2 4 4 5
```

Calcoliamo la media e la varianza della popolazione:

```
media_pop <- mean(risposte)
var_pop <- var(risposte) * ((length(risposte) - 1) / length(risposte))
cat("Media della popolazione:", media_pop, "\n")
#> Media della popolazione: 3.75
cat("Varianza della popolazione:", round(var_pop, 3), "\n")
#> Varianza della popolazione: 1.19
```

Supponiamo ora di estrarre tutti i possibili campioni di dimensione $n = 2$ **con reinserimento** (come faremmo campionando da una popolazione molto grande). Ciò genera $4^2 = 16$ campioni possibili.


```
# Generiamo tutte le coppie possibili
campioni <- expand.grid(risposte, risposte)
colnames(campioni) <- c("Partecipante_1", "Partecipante_2")

# Calcoliamo la media di ciascun campione
medie_campionarie <- rowMeans(campioni)

# Mostriamo alcuni campioni con le loro medie
df_campioni <- data.frame(
  Campione = paste(campioni[,1], campioni[,2], sep = ", "),
  Media = medie_campionarie
)
head(df_campioni, 8)
#>   Campione Media
#> 1      2, 2  2.0
#> 2      4, 2  3.0
#> 3      4, 2  3.0
#> 4      5, 2  3.5
#> 5      2, 4  3.0
#> 6      4, 4  4.0
#> 7      4, 4  4.0
#> 8      5, 4  4.5
```

Visualizziamo la distribuzione delle medie campionarie:

```
ggplot(data.frame(media = medie_campionarie), aes(x = media)) +
  geom_histogram(aes(y = after_stat(density)),
                 binwidth = 0.5, boundary = 0) +
  geom_vline(xintercept = media_pop, linetype = "dashed",
             linewidth = 1.2, color = "red") +
  labs(
    title = "Distribuzione campionaria della media (n = 2)",
    subtitle = "La linea rossa indica la media della popolazione",
    x = "Media campionaria",
    y = "Densità"
  )
```



Verifichiamo le proprietà teoriche:

```
cat("Media delle medie campionarie:", mean(medie_campionarie), "\n")
#> Media delle medie campionarie: 3.75
cat("Media della popolazione:", media_pop, "\n")
#> Media della popolazione: 3.75
cat("\n")
cat("Varianza delle medie campionarie:",
    round(var(medie_campionarie) * 15/16, 3), "\n")
#> Varianza delle medie campionarie: 0.594
cat("Varianza teorica ( ^2/n):", round(var_pop / 2, 3), "\n")
#> Varianza teorica ( ^2/n): 0.594
```

I risultati confermano le proprietà teoriche: la media delle medie campionarie coincide con la media della popolazione, e la varianza delle medie campionarie è circa la metà della varianza della popolazione (perché $n = 2$).

i Interpretazione per l'inferenza

Questa simulazione illustra perché l'osservazione di un valore specifico di $\bar{X}$ fornisce informazioni sul parametro sottostante. I valori della media campionaria tendono a concentrarsi intorno al valore effettivo del parametro. Se nel nostro campione osserviamo $\bar{X} = 4.0$, è ragionevole credere che la media della popolazione sia vicina a 4.

In termini bayesiani, la distribuzione a posteriori di θ sarà centrata in prossimità del valore osservato, con una dispersione che riflette l'incertezza residua.

10.4. Legge dei Grandi Numeri

La *Legge dei Grandi Numeri* (LGN) è uno dei risultati fondamentali della teoria della probabilità e fornisce una giustificazione matematica cruciale per l'inferenza statistica.

10.4.1. Enunciato intuitivo

In forma intuitiva, la LGN afferma che, all'aumentare del numero di osservazioni n , la media campionaria $\bar{X}_n$ tende ad avvicinarsi al valore atteso della variabile casuale:

$$\bar{X}_n \xrightarrow{n \rightarrow \infty} \theta.$$

Questa convergenza può essere formalizzata in due modi:

1. **Legge dei Grandi Numeri Debole:** per ogni $\varepsilon > 0$:

$$\Pr(|\bar{X}_n - \theta| > \varepsilon \mid \theta) \rightarrow 0 \quad \text{quando } n \rightarrow \infty.$$

2. **Legge dei Grandi Numeri Forte:** la media campionaria converge *quasi certamente*:

$$\Pr\left(\lim_{n \rightarrow \infty} \bar{X}_n = \theta \mid \theta\right) = 1.$$

Entrambe le formulazioni esprimono l'idea che, con un numero sufficientemente elevato di osservazioni, la media campionaria fornisce una rappresentazione sempre più accurata del parametro.

10.4.2. Implicazioni per l'inferenza bayesiana

Nel contesto bayesiano, la LGN ha una conseguenza fondamentale: al crescere della dimensione campionaria, l'informazione contenuta nei dati prevale progressivamente su quella contenuta nella distribuzione *a priori*. La distribuzione *a posteriori* tende a concentrarsi sempre più attorno al valore vero del parametro.

Più precisamente: **con un numero sufficiente di osservazioni, i ricercatori che partono da credenze iniziali diverse giungeranno a conclusioni sostanzialmente coincidenti.**

10.4.3. Simulazione della convergenza

Per osservare empiricamente la LGN, consideriamo uno scenario in cui il valore vero della prevalenza è $\theta = 0.45$. Simuliamo una sequenza di osservazioni e calcoliamo la media cumulativa:


```
set.seed(42)
theta_true <- 0.45
n_max <- 1000

# Generazione delle osservazioni (presenza/assenza sintomo)
osservazioni <- rbinom(n_max, size = 1, prob = theta_true)

# Calcolo delle medie cumulative
medie_cumulative <- cumsum(osservazioni) / seq_along(osservazioni)

# Preparazione dei dati per la visualizzazione
data_plot <- data.frame(
  n = 1:n_max,
  media = medie_cumulative
)

ggplot(data_plot, aes(x = n, y = media)) +
  geom_line(linewidth = 0.8, alpha = 0.8) +
  geom_hline(yintercept = theta_true,
             linetype = "dashed",
             linewidth = 1.2, color = "red") +
  geom_ribbon(aes(ymin = media - 1.96 * sqrt(media * (1 - media) / n),
                ymax = media + 1.96 * sqrt(media * (1 - media) / n)),
            alpha = 0.2) +
  labs(
    title = "Convergenza della proporzione campionaria",
    subtitle = "La linea tratteggiata indica il valore vero = 0.45",
    x = "Numero di partecipanti (n)",
    y = "Proporzione con sintomi depressivi"
  ) +
  ylim(0.2, 0.7) +
  annotate("text", x = 800, y = theta_true + 0.03,
         label = paste(" = ", theta_true),
         size = 4.5)
```



Osservazioni: nelle fasi iniziali, la proporzione osservata mostra ampie fluttuazioni. Man mano che n aumenta, le oscillazioni diminuiscono e la stima si stabilizza intorno al valore vero.

10.4.4. Ponte applicativo: implicazioni per la ricerca psicologica

La LGN ha conseguenze pratiche dirette:

Studi pilota: con campioni piccoli ($n = 20-30$), le stime sono inevitabilmente instabili. È normale che uno studio pilota osservi una prevalenza del 50% e che una replica osservi il 30%. Questo non indica necessariamente un errore, ma semplicemente la variabilità campionaria attesa con campioni ridotti.

Meta-analisi: combinare i risultati di molti studi indipendenti equivale, in un certo senso, ad aumentare la dimensione del campione complessivo. La LGN spiega perché le meta-analisi producono stime più stabili rispetto ai singoli studi.

Disegni longitudinali che prevedono l'osservazione ripetuta degli stessi individui nel tempo, permettono di accumulare informazioni progressivamente più dettagliate sui parametri di interesse. La LGN garantisce che questa informazione converga verso i valori reali.

! Il carattere autocorrettivo dell'inferenza bayesiana

Quando ricercatori diversi partono da distribuzioni a priori differenti, ma nessuna esclude il valore vero del parametro, l'osservazione degli stessi dati conduce a distribuzioni a posteriori sempre più simili. L'evidenza empirica "corregge" progressivamente le credenze iniziali.

Questo carattere autocorrettivo conferisce all'approccio bayesiano una notevole solidità: le conclusioni non dipendono in modo arbitrario dalle ipotesi iniziali, ma sono guidate dall'evidenza osservata.

10.5. Teorema del Limite Centrale

Il *Teorema del Limite Centrale* (TLC) è uno dei risultati più profondi della teoria della probabilità e riveste un ruolo centrale nell'inferenza statistica.

10.5.1. Enunciato formale

Teorema 10.3. Siano $X_1, X_2, \dots, X_n$ variabili aleatorie indipendenti e identicamente distribuite, con valore atteso μ e varianza finita σ^2 . Allora, al crescere di n , la distribuzione della media campionaria converge verso una distribuzione normale:

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

dove la notazione $\sim$ indica che la distribuzione è approssimativamente normale per valori di n sufficientemente grandi.

10.5.2. Portata concettuale

La proprietà più sorprendente del TLC è che la distribuzione della media campionaria tende alla normalità **indipendentemente dalla forma della distribuzione delle variabili originarie**, purché queste abbiano varianza finita.


Ciò significa che le variabili provenienti da distribuzioni uniformi, esponenziali, binarie o fortemente asimmetriche, una volta mediate su un numero sufficientemente elevato di osservazioni, producono una distribuzione approssimativamente normale. Questa regolarità emergente spiega il ruolo onnipresente della distribuzione normale in statistica.

10.5.3. Visualizzazione del TLC

Consideriamo una popolazione con distribuzione uniforme (chiaramente non normale):

```
set.seed(42)
popolazione <- runif(5000, min = 0, max = 1)

ggplot(data.frame(x = popolazione), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30) +
  labs(
    title = "Distribuzione della popolazione (uniforme)",
    subtitle = "Questa distribuzione NON è normale",
    x = "Valore",
    y = "Densità"
  )
```



Estraiamo 300 campioni di dimensione $n = 30$ e calcoliamo le medie:

```
n_campione <- 30
n_ripetizioni <- 300

medie <- replicate(n_ripetizioni, {
  campione <- sample(popolazione, size = n_campione, replace = TRUE)
  mean(campione)
})


x_bar <- mean(medie)
std <- sd(medie)

cat("Media delle medie campionarie:", round(x_bar, 4), "\n")
#> Media delle medie campionarie: 0.501
cat("Deviazione standard delle medie:", round(std, 4), "\n")
#> Deviazione standard delle medie: 0.0524
cat("Valore teorico ( /√n):", round(sd(popolazione) / sqrt(n_campione), 4), "\n")
#> Valore teorico ( /√n): 0.0531
```

```
ggplot(data.frame(media = medie), aes(x = media)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30) +
  stat_function(fun = dnorm, args = list(mean = x_bar, sd = std),
    linewidth = 1.2, color = "red") +
  labs(
    title = "Distribuzione delle medie campionarie (n = 30)",
    subtitle = "La curva rossa è la normale teorica - l'approssimazione è eccellente",
    x = "Media campionaria",
    y = "Densità"
  )
```

Distribuzione delle medie campionarie (n = 30)

La curva rossa è la normale teorica — l'approssimazione è eccellente



Nonostante la popolazione sia uniforme, le medie campionarie seguono una distribuzione approssimativamente normale.

10.5.4. Ponte applicativo: quando funziona la regola “ $n \geq 30$ ”?

La regola pratica secondo cui “con $n \geq 30$ l'approssimazione normale è adeguata” è utile ma non universale. Dipende dalla **forma della distribuzione originaria**:

Situazione	n necessario	Esempio in psicologia
Distribuzione simmetrica	$n \geq 15-20$	Punteggi QI, scale ben bilanciate
Distribuzione moderatamente asimmetrica	$n \geq 30-50$	Tempi di reazione, molte scale Likert
Distribuzione fortemente asimmetrica	$n \geq 100+$	Conteggi di eventi rari (es. tentativi di suicidio)
Distribuzione bimodale	Dipende	Popolazioni eterogenee, effetti misti

Esempio critico: se stiamo stimando la proporzione di eventi rari (es. $\theta = 0.02$), anche con $n = 100$ abbiamo solo circa 2 casi attesi. L'approssimazione normale sarà inadeguata, e conviene usare metodi esatti o simulazioni.

i Quando NON fidarsi dell'approssimazione normale

L'approssimazione normale può fallire quando:

- Il parametro è vicino ai limiti (es. proporzioni vicine a 0 o 1)
- La distribuzione originaria ha code molto pesanti
- Ci sono outlier estremi nel campione
- La dimensione campionaria è piccola E la distribuzione è asimmetrica

In questi casi, è preferibile usare metodi bayesiani esatti (con prior coniugate) o metodi

computazionali (MCMC, bootstrap).

10.5.5. Implicazioni per l'inferenza bayesiana

Il TLC ha conseguenze rilevanti anche nel contesto bayesiano. In presenza di campioni di grandi dimensioni, la distribuzione a posteriori tende a assumere una forma approssimativamente gaussiana. Questa "normalità asintotica" contribuisce alla robustezza dell'approccio bayesiano: l'influenza delle scelte specifiche del prior si attenua con l'aumentare dell'evidenza empirica.

10.5.6. Esempio: intervallo di credibilità con approssimazione normale

Consideriamo lo studio sui sintomi depressivi: $n = 200$ studenti, di cui $y = 72$ con sintomi. Con un prior uniforme, la distribuzione a posteriori può essere approssimata nel modo seguente:

$$\theta | y \sim \mathcal{N}\left(\frac{72}{200}, \frac{0.36 \times 0.64}{200}\right)$$

```
n <- 200
y <- 72
p_hat <- y / n

# Approssimazione normale
media_post <- p_hat
sd_post <- sqrt(p_hat * (1 - p_hat) / n)

cat("Media a posteriori:", media_post, "\n")
#> Media a posteriori: 0.36
cat("Deviazione standard a posteriori:", round(sd_post, 4), "\n")
#> Deviazione standard a posteriori: 0.0339


# Intervallo di credibilità al 95%
lower <- qnorm(0.025, mean = media_post, sd = sd_post)
upper <- qnorm(0.975, mean = media_post, sd = sd_post)

cat("\nIntervallo di credibilità 95%: [",
    round(lower, 3), ",", round(upper, 3), "]\n")
#>
#> Intervallo di credibilità 95%: [ 0.293 , 0.427 ]

theta_grid <- seq(0.25, 0.50, length.out = 500)
densita <- dnorm(theta_grid, mean = media_post, sd = sd_post)

ggplot(data.frame(theta = theta_grid, densita = densita),
    aes(x = theta, y = densita)) +
  geom_line(linewidth = 1.2) +
  geom_area(data = subset(data.frame(theta = theta_grid, densita = densita),
    theta >= lower & theta <= upper),
    aes(x = theta, y = densita), alpha = 0.3) +
  geom_vline(xintercept = c(lower, upper), linetype = "dashed") +
```

```
labs(
  title = "Distribuzione a posteriori (approssimazione normale)",
  subtitle = "Intervallo di credibilità al 95% evidenziato",
  x = " (prevalenza nella popolazione)",
  y = "Densità a posteriori"
)
```



10.5.7. Ponte applicativo: come comunicare l'intervallo di credibilità

L'intervallo $[0.29, 0.43]$ ha un'interpretazione diretta che possiamo comunicare al committente dello studio:

“Sulla base dei dati raccolti, stimiamo che la prevalenza di sintomi depressivi clinicamente rilevanti nella popolazione studentesca sia compresa tra il 29% e il 43%, con una probabilità del 95%. La nostra stima puntuale migliore è del 36%.”

Questa comunicazione è:

- **probabilistica**: esprime direttamente l'incertezza sul parametro;
- **informativa**: fornisce un range plausibile, non solo una stima puntuale;
- **interpretabile**: il committente capisce cosa significa “95% di probabilità”.

10.6. Precisione, informazione ed errore standard

10.6.1. L'errore standard come misura di informatività

L'*errore standard* di una statistica è definito come la deviazione standard della sua distribuzione campionaria:

$$SE(\bar{X}) = \sqrt{\frac{\sigma^2}{n}}.$$

Un errore standard ridotto indica che i dati forniscono un'evidenza precisa del valore di θ . In termini bayesiani, ciò si traduce in una distribuzione a posteriori stretta e ben localizzata.

10.6.2. Precisione come inverso della varianza

Nell'inferenza bayesiana è spesso utile esprimere l'incertezza attraverso la nozione di *precisione*:

$$\text{Precisione} = \frac{1}{\text{Varianza}} = \frac{1}{\text{SE}^2}.$$

Per la media campionaria:

$$\text{Precisione}(\bar{X}) = \frac{n}{\sigma^2}.$$

La precisione cresce linearmente con la dimensione campionaria n , rendendo questa parametrizzazione particolarmente intuitiva: ogni osservazione aggiuntiva aumenta la precisione di una quantità costante.

10.6.3. Combinazione di informazioni: prior e dati

Uno degli aspetti più eleganti dell'approccio bayesiano è la sua capacità di integrare formalmente diverse fonti di informazione. Nel modello normale–normale, la precisione a posteriori è la somma delle precisioni:

$$\tau_{\text{post}} = \tau_{\text{prior}} + \frac{n}{\sigma^2}.$$

Questa relazione mostra che ogni nuova osservazione contribuisce ad aumentare la precisione complessiva. Il peso relativo attribuito alla conoscenza pregressa e ai nuovi dati è determinato dalle rispettive precisioni.

10.6.4. Ponte applicativo: sintesi di studi multipli (meta-analisi bayesiana)

Consideriamo uno scenario tipico: due studi indipendenti hanno indagato la stessa domanda, ovvero l'efficacia di un intervento CBT per la depressione.

- **Studio A** (studio pilota): $n_A = 50$, proporzione di remissione $\hat{p}_A = 0.42$, $\text{SE}_A = 0.07$;
- **Studio B** (RCT multicentrico): $n_B = 200$, proporzione di remissione $\hat{p}_B = 0.38$, $\text{SE}_B = 0.035$.

Come possiamo combinare queste evidenze?

```
# Parametri degli studi
n_A <- 50; p_hat_A <- 0.42; se_A <- 0.07
n_B <- 200; p_hat_B <- 0.38; se_B <- 0.035

# Calcolo delle precisioni
precisione_A <- 1 / se_A^2
precisione_B <- 1 / se_B^2

cat("Precisione Studio A:", round(precisione_A, 1), "\n")
#> Precisione Studio A: 204
```

```

cat("Precisione Studio B:", round(precisione_B, 1), "\n")
#> Precisione Studio B: 816
cat("Lo Studio B è", round(precisione_B / precisione_A, 1),
    "volte più informativo\n")
#> Lo Studio B è 4 volte più informativo

# Sintesi bayesiana
precisione_combinata <- precisione_A + precisione_B
media_combinata <- (precisione_A * p_hat_A + precisione_B * p_hat_B) / precisione_combinata
se_combinata <- sqrt(1 / precisione_combinata)

cat("\nStima combinata:", round(media_combinata, 3), "\n")
#>
#> Stima combinata: 0.388
cat("Errore standard combinato:", round(se_combinata, 4), "\n")
#> Errore standard combinato: 0.0313
cat("\nIntervallo di credibilità 95%:\n")
#>
#> Intervallo di credibilità 95%:
cat("[", round(media_combinata - 1.96 * se_combinata, 3), ",",
    round(media_combinata + 1.96 * se_combinata, 3), "]\n")
#> [ 0.327 , 0.449 ]

```

Interpretazione: la stima combinata (38,8%) è più vicina allo studio B, perché quest'ultimo è circa quattro volte più informativo. L'intervallo di credibilità combinato è più stretto rispetto a quello di entrambi gli studi singoli, riflettendo l'accumulo di evidenze.

Questo è esattamente ciò che fa una **meta-analisi bayesiana**: combina le evidenze di studi diversi, assegnando a ciascuno un peso in base alla sua precisione e producendo una sintesi ottimale dell'informazione disponibile.

10.7. Convergenza bayesiana: da credenze diverse a conclusioni condivise

10.7.1. Il teorema di convergenza bayesiana

Un risultato teorico centrale riguarda il comportamento asintotico della distribuzione a posteriori.

Teorema 10.4 (Consistenza bayesiana). *Sotto opportune condizioni di regolarità, se la prior assegna una densità positiva al valore vero del parametro θ_0 , allora, al crescere del numero di osservazioni:*

1. la distribuzione a posteriori converge verso il valore vero:

$$p(\theta \mid \mathbf{X}_n) \xrightarrow{n \rightarrow \infty} \delta(\theta - \theta_0);$$

2. la media a posteriori converge:

$$\mathbb{E}[\theta \mid \mathbf{X}_n] \xrightarrow{n \rightarrow \infty} \theta_0;$$

3. la varianza a posteriori tende a zero:

$$\text{Var}(\theta \mid \mathbf{X}_n) \xrightarrow{n \rightarrow \infty} 0.$$

10.7.2. Illustrazione: convergenza con prior differenti

Consideriamo tre ricercatori con credenze iniziali molto diverse sulla prevalenza dei sintomi depressivi:

- **Ricercatore A:** prior Beta(2, 8) — crede che la prevalenza sia bassa (circa 20%).
- **Ricercatore B:** prior Beta(8, 2) — crede che la prevalenza sia alta (circa 80%).
- **Ricercatore C:** prior Beta(1, 1) — non ha opinioni forti (prior uniforme).

Il valore vero è $\theta_0 = 0.45$. Osserviamo come le loro credenze convergono:

```
theta_true <- 0.45
n_osservazioni <- c(10, 50, 200, 1000)

# Prior dei tre ricercatori
prior_A <- c(2, 8) # pessimista
prior_B <- c(8, 2) # ottimista
prior_C <- c(1, 1) # agnostico

# Funzione per calcolare la posterior (Beta-Binomiale)
calcola_posterior <- function(prior, n, theta) {
  y <- rbinom(1, n, theta) # successi osservati
  c(prior[1] + y, prior[2] + n - y)
}

set.seed(42)
posteriors <- list()

for (n in n_osservazioni) {
  theta_grid <- seq(0.1, 0.9, length.out = 200)

  post_A <- calcola_posterior(prior_A, n, theta_true)
  post_B <- calcola_posterior(prior_B, n, theta_true)
  post_C <- calcola_posterior(prior_C, n, theta_true)

  posteriors[[as.character(n)]] <- data.frame(
    theta = rep(theta_grid, 3),
    density = c(
      dbeta(theta_grid, post_A[1], post_A[2]),
      dbeta(theta_grid, post_B[1], post_B[2]),
      dbeta(theta_grid, post_C[1], post_C[2])
    ),
    ricercatore = rep(c("A (prior pessimista)",
                       "B (prior ottimista)",
                       "C (prior agnostico)"),
                     each = length(theta_grid)),
    n = n
  )
}

all_posteriors <- do.call(rbind, posteriors)
all_posteriors$n <- factor(all_posteriors$n,
```




```

      levels = n_osservazioni,
      labels = paste("n =", n_osservazioni))

ggplot(all_posteriors,
      aes(x = theta, y = density,
          color = ricercatore, linetype = ricercatore)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = theta_true,
             linetype = "dashed",
             linewidth = 1.2) +
  facet_wrap(~ n, ncol = 2, scales = "free_y") +
  labs(
    title = "Convergenza bayesiana: da credenze diverse a conclusioni condivise",
    subtitle = "La linea verticale indica il valore vero  $\theta = 0.45$ ",
    x = "Parametro  $\theta$ ",
    y = "Densità a posteriori",
    color = "Ricercatore",
    linetype = "Ricercatore"
  ) +
  theme(legend.position = "bottom")

```

**Osservazioni:**

1. Con $n = 10$: le posterior riflettono fortemente le prior diverse.
2. Con $n = 50$: si osserva un chiaro avvicinamento.
3. Con $n = 200$: le posterior sono ampiamente sovrapposte.
4. Con $n = 1000$: le differenze sono praticamente impercettibili.

10.7.3. Ponte applicativo: analisi di sensibilità nella pratica

L'**analisi di sensibilità** consiste nel verificare se le conclusioni cambiano sostanzialmente con prior diversi. In pratica:

1. **specificare 2-3 prior alternative** che rappresentano credenze ragionevolmente diverse;
2. **calcolare le posterior** per ciascuna prior;
3. **confrontare gli intervalli di credibilità**.

Se gli intervalli si sovrappongono ampiamente, le conclusioni sono **robuste** rispetto alla scelta del prior. Se invece differiscono in modo sostanziale, il prior è **influyente** e richiede una giustificazione.

```
# Analisi di sensibilità per lo studio n=200
n <- 200
y <- 90 # supponiamo 90 casi su 200

# Tre prior alternative
priors <- list(
  "Informativo pessimista" = c(2, 8),
  "Non informativo" = c(1, 1),
  "Informativo ottimista" = c(8, 2)
)

cat("Analisi di sensibilità (n=200, y=90)\n")
#> Analisi di sensibilità (n=200, y=90)
cat("=====\n\n")
#> =====

for (nome in names(priors)) {
  prior <- priors[[nome]]
  post_alpha <- prior[1] + y
  post_beta <- prior[2] + n - y

  media <- post_alpha / (post_alpha + post_beta)
  ic_lower <- qbeta(0.025, post_alpha, post_beta)
  ic_upper <- qbeta(0.975, post_alpha, post_beta)

  cat(nome, ":\n")
  cat(" Media posteriori:", round(media, 3), "\n")
  cat(" IC 95%: [", round(ic_lower, 3), ",", round(ic_upper, 3), "]\n\n")
}

#> Informativo pessimista :
#> Media posteriori: 0.438
#> IC 95%: [ 0.372 , 0.506 ]
#>
#> Non informativo :
#> Media posteriori: 0.45
#> IC 95%: [ 0.383 , 0.519 ]
#>
#> Informativo ottimista :
#> Media posteriori: 0.467
#> IC 95%: [ 0.4 , 0.534 ]
```

In questo esempio, gli intervalli si sovrappongono ampiamente, il che indica che le conclusioni sono robuste rispetto alla scelta del prior. Con $n = 200$ osservazioni, i dati prevalgono sulle credenze iniziali.

10.8. Incertezza, distorsione sistematica e limiti dell'inferenza

10.8.1. L'errore standard quantifica solo l'incertezza campionaria

È essenziale chiarire che l'errore standard e la dispersione della distribuzione a posteriori misurano esclusivamente l'incertezza dovuta alla **variabilità campionaria**. Tale misura non fornisce alcuna informazione sulla presenza di **errori sistematici** nel disegno della ricerca.

Di conseguenza, una stima può essere estremamente precisa dal punto di vista statistico e, al tempo stesso, sostanzialmente errata dal punto di vista scientifico.

10.8.2. Fonti di distorsione che persistono

Alcune fonti di distorsione non vengono attenuate dall'aumento della dimensione campionaria:

Distorsione da selezione: se stimiamo la prevalenza della depressione attraverso un campione di volontari che rispondono a un annuncio online, potremmo sovrarappresentare individui con sintomi (che cercano informazioni) o sottorappresentarli (se evitano l'argomento). Anche con $n = 10,000$, la stima risulterà distorta.


Distorsione da risposta: nello studio di costrutti auto-riferiti come la frequenza di pensieri suicidari, la desiderabilità sociale può indurre risposte attenuate. Otterremo quindi una stima precisa di una quantità sistematicamente sottostimata.

Errori di misurazione: se il PHQ-9 non coglie adeguatamente la depressione in una specifica popolazione (ad esempio, gli anziani o le persone di culture diverse), l'aumento del campione produce stime più precise di una quantità mal definita.

10.8.3. Rappresentazione visiva: precisione versus accuratezza

Precisione e accuratezza nell'inferenza statistica

La croce rossa indica il valore vero del parametro



Il caso più pericoloso è quello in alto a destra: alta precisione con bassa accuratezza. I metodi statistici producono intervalli di credibilità stretti attorno a un valore errato, creando una falsa sensazione di certezza.

⚠ Il pericolo della falsa precisione

Un intervallo di credibilità stretto può indurre l'illusione di una conoscenza accurata. Tuttavia, tale intervallo quantifica esclusivamente l'incertezza campionaria.

In presenza di bias sistematici, il valore vero potrebbe collocarsi ben al di fuori dell'intervallo calcolato. **La precisione statistica non deve mai essere confusa con la validità scientifica.**

Un esempio concreto: uno studio online con $n = 5,000$ partecipanti auto-selezionati potrebbe produrre un intervallo di credibilità $[0.32, 0.34]$ per la prevalenza della depressione. Tuttavia, se il campione è distorto (per esempio, se sovrarappresenta le persone interessate alla salute mentale), il valore vero nella popolazione potrebbe essere 0.20, completamente fuori dall'intervallo "preciso".

10.8.4. Strategie di mitigazione

1. **Progettazione metodologica solida:** campionamento probabilistico, protocolli standardizzati, strumenti validati.
2. **Analisi di sensibilità:** valutare la robustezza delle conclusioni rispetto a diverse assunzioni.
3. **Modellazione esplicita del bias:** quando possibile, includere nel modello le potenziali fonti di distorsione.
4. **Trasparenza epistemica:** riconoscere esplicitamente i limiti metodologici come parte integrante dell'inferenza.

10.9. Verso la verosimiglianza: come i dati informano le credenze

In questo capitolo abbiamo esaminato le proprietà matematiche fondamentali che governano il comportamento della media campionaria:

- è centrata sul parametro: $\mathbb{E}[\bar{X}] = \theta$;
- la sua variabilità diminuisce con n : $\text{Var}(\bar{X}) = \sigma^2/n$;
- converge al valore vero: Legge dei Grandi Numeri;
- la sua distribuzione tende alla normale: Teorema del Limite Centrale.

Resta ora da chiarire come queste proprietà si traducano operativamente nell'aggiornamento delle credenze bayesiane. La risposta risiede nella **funzione di verosimiglianza**, che formalizza il modo in cui i dati informano le credenze: per ogni possibile valore del parametro θ , essa quantifica quanto tale valore renda plausibili le osservazioni raccolte.

È attraverso la verosimiglianza che le informazioni contenute nei dati vengono combinate con la distribuzione a priori, generando la distribuzione a posteriori. Le proprietà analizzate in questo capitolo, ovvero centratura, precisione crescente e convergenza, trovano nella funzione di verosimiglianza la loro espressione formale.

Riflessioni conclusive

In questo capitolo abbiamo esaminato come quantificare sistematicamente l'incertezza quando si traggono conclusioni da evidenze limitate. Per lo psicologo e il ricercatore clinico, questi concetti non sono mere astrazioni matematiche, ma **strumenti operativi** che guidano scelte concrete:

- **Pianificare studi:** sapere che l'errore standard decresce come $1/\sqrt{n}$ permette di calcolare dimensioni campionarie adeguate alla precisione desiderata.
- **Interpretare risultati:** gli intervalli di credibilità comunicano l'incertezza in modo probabilisticamente rigoroso e clinicamente significativo.
- **Combinare evidenze:** la regola di aggregazione delle precisioni (somma delle informazioni) costituisce la base formale della meta-analisi bayesiana.
- **Valutare la robustezza:** l'analisi di sensibilità verifica se le conclusioni dipendono criticamente dalle assunzioni a priori o dal modello scelto.

L'inferenza bayesiana si conferma come un **framework coerente** per rappresentare e aggiornare l'incertezza epistemica. Le credenze iniziali (prior) vengono integrate in modo logico con i nuovi dati, producendo una distribuzione a posteriori che rappresenta lo stato più informato delle nostre conoscenze. Con evidenza sufficiente, credenze iniziali anche molto diverse tendono a convergere verso stime condivise, garantendo oggettività nel lungo termine.

Tuttavia, è essenziale riconoscere i limiti di questa logica: le procedure inferenziali quantificano l'**incertezza campionaria**, ma non correggono errori sistematici (*bias*). Un campione ampio ma distorto può portare a stime molto precise, ma altrettanto erranee. La validità del disegno di ricerca e la qualità della misurazione rimangono presupposti irrinunciabili, che nessuna sofisticazione statistica può sostituire.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Distribuzione campionaria della media

- $\mathbb{E}[\bar{X}] = \mu$ (stimatore non distorto)
- $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ (decresce con la dimensione campionaria)
- $\text{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$ misura la precisione della stima

2. Legge dei Grandi Numeri (LGN)

- La media campionaria converge al valore vero al crescere di n
- Giustifica l'uso della media come stimatore consistente
- Spiega perché meta-analisi e studi grandi sono più affidabili

3. Teorema del Limite Centrale (TLC)

- Per n grande, la media campionaria è approssimativamente normale
- Vale **indipendentemente dalla distribuzione di X**
- Regola pratica: $n \geq 30$ spesso sufficiente, ma dipende dalla simmetria

4. Prior, verosimiglianza e posterior

- **Prior:** $p(\theta)$ codifica credenze iniziali
- **Verosimiglianza:** $p(D | \theta)$ descrive compatibilità dati-parametro
- **Posterior:** $p(\theta | D) \propto p(D | \theta) \cdot p(\theta)$

5. Intervalli di credibilità bayesiani

- IC al 95%: "C'è probabilità 95% che θ sia in questo intervallo"
- Interpretazione diretta sul parametro (diverso da IC frequentista)

6. Precisione e meta-analisi

- Precisione: $\tau = 1/\text{SE}^2$ (cresce linearmente con n)
- Studi indipendenti: le precisioni si sommano
- Fondamento della sintesi bayesiana delle evidenze

7. Analisi di sensibilità

- Verifica se le conclusioni dipendono dal prior
- Se prior diversi $\rightarrow$ posterior simili: conclusioni robuste
- Se posterior cambiano molto: prior influente

8. Incertezza campionaria vs distorsioni sistematiche

- L'errore standard quantifica SOLO la variabilità campionaria
- Bias di selezione, risposta, misurazione NON si risolvono con n grande
- Alta precisione + bassa accuratezza = pericolo di false certezze

Formule da ricordare:

$$\mathbb{E}[\bar{X}] = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \text{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

$$p(\theta \mid D) \propto p(D \mid \theta) \cdot p(\theta)$$

$$\tau_{\text{combinata}} = \tau_1 + \tau_2 + \cdots + \tau_k$$

Per il prossimo capitolo:

Nel Capitolo 11 inizieremo lo studio sistematico delle **famiglie parametriche di distribuzioni** (Beta, Binomiale, Normale, Poisson, Gamma), che costituiscono il vocabolario standard per specificare prior, verosimiglianze e posterior nell'inferenza bayesiana.

! Esercizi

Esercizi sulla distribuzione campionaria e sull'inferenza sono disponibili sulla seguente [pagina web](#).

i Informazioni sull'ambiente di sviluppo


```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0     ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0     posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0     estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51           labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8       curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8          purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1         xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.3        scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-1        rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0           RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0        parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-5          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1   glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6         QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9      Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5    rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9       backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13         snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1        gridExtra_2.3.1       nlme_3.1-169
#> [67] checkmate_2.3.4      xfun_0.60             pkgconfig_2.0.3

```

Bibliografia

11. Introduzione alle distribuzioni di probabilità

Introduzione

Un ricercatore sta progettando uno studio sui tempi di reazione in un compito di decisione lessicale. Sa che dovrà modellare questi dati statisticamente, ma si trova di fronte a una scelta: quale distribuzione utilizzare? I tempi di reazione sono sempre positivi, spesso asimmetrici verso destra, e occasionalmente presentano valori estremi. Una distribuzione normale, simmetrica e definita su tutti i numeri reali, sembra inadeguata. Forse una gamma o una log-normale sarebbero più appropriate?

In un altro laboratorio, una clinica sta analizzando i dati di uno studio clinico su un nuovo intervento per la depressione. Deve modellare la proporzione di pazienti che raggiungono la remissione. Questa proporzione è necessariamente compresa tra 0 e 1: quale distribuzione può rappresentare adeguatamente l'incertezza di un parametro con questi vincoli?

Queste domande operative motivano il presente capitolo. Nei capitoli precedenti abbiamo costruito un framework per ragionare in modo coerente in condizioni di incertezza. Ora, però, sorge una questione pratica: **come possiamo rappresentare concretamente le nostre credenze?** Le famiglie parametriche di distribuzioni, come la normale, la binomiale, la beta, la gamma e altre, forniscono un vocabolario matematico per esprimere l'incertezza in forme standardizzate, ciascuna adatta a specifici tipi di variabili e configurazioni di credenze.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- 1
- 2
- Capitolo 8
- Capitolo 10 — **fondamentale** per comprendere il duplice ruolo delle distribuzioni (prior e verosimiglianza)

Questo capitolo introduce il **vocabolario delle famiglie parametriche**, che saranno poi studiate in dettaglio nei capitoli successivi.

Conoscenze matematiche richieste:

- Appendice F - per proprietà delle distribuzioni continue

11.1. L'incertezza come condizione epistemica

11.1.1. Perché abbiamo bisogno delle distribuzioni

Nel ragionamento scientifico ci troviamo costantemente in una condizione di conoscenza incompleta. Non conosciamo con certezza il valore esatto di un parametro di interesse, che si tratti della prevalenza di un disturbo, dell'efficacia di un intervento o della correlazione tra due costrutti psicologici. Questa incertezza non rappresenta un difetto del metodo scientifico, ma una sua caratteristica costitutiva: la scienza avanza attraverso la riduzione progressiva dell'incertezza, non attraverso la sua eliminazione definitiva.

L'approccio bayesiano riconosce esplicitamente questa condizione e la pone al centro del ragionamento inferenziale. L'incertezza non viene nascosta dietro stime puntuali o decisioni dicotomiche (ad esempio significativo/non significativo), ma viene rappresentata, quantificata e comunicata mediante distribuzioni di probabilità.

In questa prospettiva, una distribuzione di probabilità non descrive primariamente “come sono distribuiti i dati nel mondo”, bensì “quali valori riteniamo più o meno plausibili, dato il nostro attuale stato di conoscenza”. Questa distinzione è sottile ma cruciale: la distribuzione è uno strumento epistemico, utilizzato per rappresentare credenze razionali, non una proprietà ontologica intrinseca del fenomeno studiato.

11.1.2. Dalla credenza puntuale alla credenza distribuita

Immaginiamo di voler esprimere le nostre credenze sulla proporzione di studenti universitari che presentano sintomi di ansia clinicamente rilevanti, indicata con θ . Un approccio ingenuo potrebbe consistere nell'indicare un singolo valore: “Credo che sia il 25%”. Tuttavia, una risposta di questo tipo è epistemicamente inadeguata, poiché non rende conto dell'incertezza che accompagna inevitabilmente tale credenza.

Una rappresentazione più adeguata riconosce che non attribuiamo la stessa plausibilità a tutti i possibili valori di θ . Potremmo ritenere molto plausibili i valori compresi tra 0.20 e 0.30, moderatamente plausibili quelli tra 0.15 e 0.35, e considerare altamente implausibili valori inferiori a 0.05 o superiori a 0.50. Una distribuzione di probabilità su θ consente di rappresentare in modo esplicito e coerente questa struttura graduata di credenze.

La distribuzione Beta, che incontreremo nei prossimi capitoli, è particolarmente adatta a rappresentare credenze sulle proporzioni. Ad esempio, una distribuzione Beta(5, 15) esprime la convinzione che il valore di θ sia probabilmente intorno a 0.25, con un'incertezza maggiore verso i valori più elevati rispetto a quelli più bassi. I parametri della distribuzione, in questo caso 5 e 15, codificano in modo compatto l'intera struttura delle nostre credenze, trasformando un insieme complesso di giudizi qualitativi in un oggetto matematico maneggevole.

11.2. Il duplice ruolo delle distribuzioni nell'inferenza bayesiana

Nell'approccio bayesiano, le distribuzioni di probabilità svolgono due ruoli distinti ma complementari, che corrispondono ai due termini fondamentali del teorema di Bayes. La chiara comprensione di questa dualità è essenziale per cogliere il motivo per cui le famiglie parametriche occupano una posizione centrale nell'inferenza bayesiana.

11.2.1. Distribuzioni come rappresentazione dell'incertezza sui parametri

Il primo ruolo, più caratteristico e distintivo dell'approccio bayesiano, consiste nel rappresentare formalmente l'incertezza circa i parametri del modello. Prima di osservare i dati, le conoscenze preliminari o le credenze sul parametro vengono codificate in una **distribuzione a priori** (*prior*). Questa può incorporare informazioni provenienti dalla letteratura scientifica, vincoli teorici, esperienza pregressa o, in assenza di informazioni sostanziali, esprimere una marcata incertezza iniziale.

Dopo l'osservazione dei dati, le credenze iniziali vengono aggiornate attraverso il teorema di Bayes, dando vita alla **distribuzione a posteriori**. Questa sintetizza tutto ciò che si è appreso, combinando il prior con l'evidenza empirica contenuta nei dati. La sua forma, ovvero la sua posizione, la sua dispersione, e l'eventuale presenza di asimmetria o multimodalità, comunica in modo completo ciò che abbiamo appreso e quanta incertezza residua permane.

In questo senso, la distribuzione risponde alla domanda: «*Quanto dovrei credere in ciascun possibile valore del parametro?*».

11.2.2. Distribuzioni come modelli generativi dei dati

Il secondo ruolo riguarda la descrizione del processo probabilistico che ha generato i dati, condizionatamente ai parametri. Questo ruolo è formalizzato dalla **funzione di verosimiglianza**.

La verosimiglianza risponde a una domanda diversa: «*Se il parametro avesse un valore specifico, quanto sarebbero plausibili (o probabili) i dati che abbiamo effettivamente osservato?*».

Quando assumiamo, ad esempio, che i tempi di reazione seguano una distribuzione gamma o che le risposte a un item dicotomico seguano una distribuzione di Bernoulli, stiamo formulando ipotesi sul meccanismo generativo dei dati. Tali ipotesi determinano la forma della funzione di verosimiglianza e influenzano direttamente il modo in cui l'evidenza empirica aggiorna le nostre credenze.

La scelta del modello generativo riflette le nostre ipotesi sostantive sulla natura del fenomeno studiato: i tempi di reazione sono sempre positivi e spesso asimmetrici (suggerendo distribuzioni come la gamma o la log-normale); i conteggi di eventi rari presentano una struttura particolare (suggerendo la distribuzione di Poisson); le proporzioni sono vincolate tra 0 e 1 (suggerendo la distribuzione beta per la *prior* e la binomiale per la verosimiglianza).

11.2.3. L'interazione tra i due ruoli

Il teorema di Bayes rappresenta il ponte matematico che connette questi due ruoli fondamentali:

$$\underbrace{p(\theta \mid \text{dati})}_{\text{posteriore}} \propto \underbrace{p(\text{dati} \mid \theta)}_{\text{verosimiglianza}} \times \underbrace{p(\theta)}_{\text{prior}}.$$

La distribuzione a posteriori nasce dall'integrazione dinamica tra la conoscenza pregressa sui parametri, formalizzata nel prior, e l'evidenza empirica dei dati, catturata dalla verosimiglianza. Poiché entrambe le componenti dell'inferenza sono espresse attraverso distribuzioni di probabilità, le famiglie parametriche costituiscono strumenti indispensabili per formulare modelli coerenti, interpretabili e aggiornabili nell'inferenza bayesiana.

11.2.4. Esempio concreto: la distribuzione Beta nel duplice ruolo

Consideriamo uno studio sull'efficacia di un intervento CBT per l'ansia sociale. Il parametro di interesse è θ , ovvero la probabilità di remissione.

Come prior, prima di raccogliere dati, il ricercatore utilizza una $\text{Beta}(3, 7)$ per esprimere la credenza che la remissione sia possibile ma non molto probabile (media a priori = 0.30). Questa scelta riflette la letteratura esistente su interventi simili.

Come verosimiglianza: i dati osservati (12 remissioni su 30 pazienti) sono modellati con una distribuzione Binomiale, che descrive il processo generativo: ogni paziente ha una probabilità θ di remissione, indipendentemente dagli altri.

Come posterior: applicando il teorema di Bayes, si ottiene una distribuzione $\text{Beta}(3 + 12, 7 + 18) = \text{Beta}(15, 25)$, che sintetizza ciò che sappiamo dopo aver osservato i dati. La media a posteriori (0.375) rappresenta un compromesso tra la credenza iniziale (0.30) e la proporzione osservata (0.40).

In questo esempio, la distribuzione Beta appare sia come prior che come posterior (appartengono alla stessa famiglia, proprietà detta *coniugazione*), mentre la Binomiale funge da verosimiglianza. Questa è la struttura tipica dell'inferenza bayesiana per le proporzioni.

11.3. Le famiglie parametriche come vocabolario

11.3.1. Cosa significa “famiglia parametrica”

Una *famiglia parametrica* di distribuzioni è un insieme di distribuzioni che condividono la stessa forma funzionale, ma differiscono per i valori di uno o più parametri. La famiglia normale, per esempio, comprende infinite distribuzioni tutte caratterizzate da una forma a campana simmetrica, che si distinguono per la loro posizione (parametro μ) e per la loro dispersione (parametro σ).

Specificare una famiglia parametrica equivale quindi a fare un'assunzione sulla *forma* della distribuzione, mentre specificare i valori dei parametri significa selezionare un caso particolare all'interno di quella famiglia. Nell'inferenza bayesiana, di solito si fissa la famiglia sulla base di considerazioni teoriche o sostanziali (ad esempio: “ritengo plausibile una distribuzione normale”) e si lascia che siano i dati a informare i valori dei parametri attraverso il processo di aggiornamento bayesiano.

11.3.2. Il vocabolario delle forme

Ogni famiglia parametrica possiede caratteristiche distintive che la rendono adatta a rappresentare specifici tipi di variabili. Vediamole con esempi dalla ricerca psicologica.

Distribuzioni discrete — assegnano probabilità a valori distinti e contabili:

- **Bernoulli**: modella eventi binari singoli. *Esempio*: la risposta di un paziente a un trattamento (remissione sì/no), la correttezza di una risposta a un item di test, la presenza/assenza di un sintomo.
- **Binomiale**: descrive il numero di successi in una sequenza di prove. *Esempio*: quanti item corretti su 20 in un test di memoria, quanti pazienti su 50 rispondono a un farmaco, quanti giorni su 14 un paziente riporta umore depresso.
- **Poisson**: appropriata per conteggi di eventi rari in intervalli definiti. *Esempio*: numero di attacchi di panico in un mese, numero di errori in un compito di attenzione sostenuta, frequenza di comportamenti autolesionistici in una settimana.

Distribuzioni continue — assegnano densità di probabilità a scale numeriche continue:

- **Normale (Gaussiana)**: emerge quando un fenomeno è influenzato da molti fattori indipendenti di piccolo effetto. *Esempio*: punteggi QI (costruiti per essere normali), punteggi a scale di personalità ben validate, misure antropometriche.
- **Gamma e Log-normale**: adatte a quantità positive e asimmetriche. *Esempio*: tempi di reazione (sempre positivi, con coda destra), latenze di risposta, durata degli episodi depressivi, tempo alla ricaduta.
- **Beta**: definita sull'intervallo $[0,1]$, ideale per proporzioni e probabilità. *Esempio*: probabilità che un paziente risponda a un trattamento, proporzione di varianza spiegata, tasso di accuratezza in un compito.

11.3.3. Ponte applicativo: come scegliere la distribuzione appropriata

Nella pratica, la scelta della distribuzione non è un atto astratto ma una **decisione informata**, che può essere affrontata in modo sistematico seguendo una logica a cascata. Le domande chiave sono poche, ma poste nell'ordine giusto.

1. Qual è il supporto della variabile?

Il primo criterio è sempre il dominio dei valori possibili: una distribuzione che assegna probabilità a valori impossibili è automaticamente esclusa.

- Solo 0 e 1 → **Bernoulli**
- Numero di successi tra 0 e n → **Binomiale**
- Conteggi interi non negativi senza limite superiore → **Poisson**
- Numeri reali positivi (> 0) → **Gamma, Log-normale**
- Proporzioni comprese tra 0 e 1 → **Beta**
- Numeri reali su tutta la retta → **Normale, t di Student**

☒ Questa fase serve soprattutto a **escludere** modelli inadatti.

2. Qual è la forma attesa della distribuzione?

Una volta ristretto il campo, si considera la forma plausibile dei dati, sulla base di teoria, esperienza o letteratura.

- Simmetrica, campaniforme → **Normale**
- Asimmetrica a destra (coda lunga verso valori alti) → **Gamma, Log-normale**
- Asimmetrica a sinistra → **Beta** con ($\alpha > \beta$)
- Presenza di outlier o code pesanti → **t di Student**

☒ Qui entra in gioco l'**intelligenza sostantiva** del problema, non solo la matematica.

3. Ci sono informazioni pregresse da incorporare?

Se il modello è bayesiano, la distribuzione scelta deve dialogare bene con il *prior*.

- Se esistono conoscenze precedenti (studi, esperti, dati storici), il *prior* deve poterle rappresentare in modo naturale.
- Le coppie **coniugate** (prior e posterior della stessa famiglia) non sono obbligatorie, ma:
 - semplificano i calcoli,
 - rendono l'interpretazione più trasparente,
 - facilitano il debugging del modello.

☒ La scelta della distribuzione non riguarda solo i dati, ma l'intero **ecosistema del modello**.

Esempio applicativo

“Devo modellare i tempi di reazione in un esperimento di priming.”

1. **Supporto** I tempi di reazione sono numeri reali positivi → la **Normale è esclusa**.
2. **Forma attesa** I tempi di reazione mostrano tipicamente una forte asimmetria a destra → candidati naturali: **Gamma** o **Log-normale**.
3. **Considerazioni di modellazione**
 - La **Gamma** ha parametri interpretabili (forma e scala).
 - È compatibile con strutture gerarchiche e coniugazioni utili.
 - È spesso più stabile numericamente in modelli complessi.

☒ **Scelta finale: Distribuzione Gamma.**

In sintesi

Scegliere una distribuzione significa rispondere a tre domande fondamentali:

1. *Quali valori sono possibili?*
2. *Che forma mi aspetto realisticamente?*
3. *Che tipo di inferenza voglio costruire (frequentista o bayesiana)?*

Se queste tre risposte sono coerenti tra loro, la distribuzione “giusta” emerge quasi naturalmente.

11.3.4. Parsimonia e flessibilità

Le famiglie parametriche realizzano un equilibrio tra *parsimonia* e *flessibilità*. Con un numero ridotto di parametri, tipicamente uno, due o tre, possono rappresentare una vasta gamma di forme distribuzionali. La distribuzione normale richiede soltanto due parametri, μ e σ , per essere completamente specificata, mentre la distribuzione beta utilizza due parametri, α e β , per rappresentare credenze su proporzioni che possono essere simmetriche o asimmetriche, concentrate o disperse.

Questa parsimonia ha un valore epistemico rilevante: costringe a rendere esplicite le assunzioni fondamentali senza introdurre complessità non giustificate dall'evidenza disponibile. Allo stesso tempo, la varietà delle famiglie parametriche fornisce una flessibilità sufficiente per adattarsi alle caratteristiche dei diversi fenomeni psicologici, rendendo possibile una modellizzazione al tempo stesso semplice e informativa.

11.4. Applicazione: la variabilità nei fenomeni psicologici

11.4.1. Perché la variabilità richiede un trattamento distribuzionale

Le considerazioni epistemiche sviluppate finora trovano un'applicazione particolarmente rilevante nella ricerca psicologica, dove la variabilità tra individui, nel tempo e tra contesti rappresenta la norma piuttosto che l'eccezione.

Un recente articolo di Segal et al. (2025) sui disturbi mentali illustra efficacemente questo punto. L'autore osserva che molti limiti nella comprensione dell'eziologia dei disturbi psichiatrici derivano da una sottovalutazione sistematica della variabilità. Storicamente, gran parte della ricerca ha confrontato gruppi di pazienti con gruppi di controllo, identificando le differenze nelle medie come tratti distintivi. Questo approccio, pur avendo prodotto risultati importanti, trascura un aspetto cruciale: i disturbi psichiatrici sono caratterizzati da un'elevata eterogeneità che i semplici confronti tra medie non sono in grado di cogliere.

I numeri rendono evidente la portata del problema. Nel disturbo da stress post-traumatico, ad esempio, esistono oltre 636000 possibili combinazioni di sintomi che soddisfano i criteri diagnostici. Per quanto riguarda la depressione maggiore, le configurazioni sintomatologiche compatibili con la diagnosi superano le 16000, e meno del 50% dei pazienti depressi presenta la stessa configurazione di sintomi.

11.4.2. Oltre le medie di gruppo

Quando confrontiamo le medie di due gruppi e osserviamo una differenza "statisticamente significativa", stiamo formulando un'affermazione a livello di popolazione. Tale affermazione può risultare epistemicamente inadeguata se la variabilità all'interno dei gruppi è molto maggiore della differenza tra le medie, se le distribuzioni si sovrappongono in modo sostanziale o se esistono sottogruppi eterogenei mascherati dalla media complessiva.

In questi contesti, la media rischia di diventare un riassunto fuorviante. Rappresentare l'intera distribuzione, includendone la forma, la dispersione e le eventuali caratteristiche come l'asimmetria o la multimodalità, fornisce un quadro molto più fedele del nostro stato di conoscenza.

L'approccio bayesiano, che fa un uso sistematico delle distribuzioni di probabilità, è naturalmente attrezzato per affrontare questa complessità. Non ci si limita a stimare un singolo valore "più probabile", ma si ottiene una distribuzione a posteriori che quantifica esplicitamente l'incertezza. I modelli gerarchici consentono di stimare simultaneamente parametri di popolazione e parametri

individuali, catturando la variabilità tra soggetti. I modelli di miscela, infine, permettono di identificare sottogruppi eterogenei all'interno di campioni apparentemente omogenei.

11.4.3. La variabilità come informazione

In questa prospettiva, la variabilità non è un “rumore” da eliminare mediante tecniche statistiche, ma un'informazione da modellare e comprendere. Le distribuzioni di probabilità diventano strumenti per rappresentare in modo esplicito tale variabilità: una distribuzione con alta varianza comunica qualcosa di sostanzialmente diverso rispetto a una distribuzione con bassa varianza e, in contesti differenti, entrambe possono essere epistemicamente appropriate.

Come sottolinea Segal et al. (2025), solo integrando sistematicamente la variabilità nell'analisi empirica è possibile sviluppare modelli predittivi robusti e interventi sensibili alla diversità individuale. Le famiglie parametriche di distribuzioni forniscono il linguaggio formale necessario per realizzare tale integrazione in modo coerente e rigoroso.

11.5. Verso i capitoli successivi

Nei prossimi capitoli esploreremo sistematicamente le principali famiglie di distribuzioni utilizzate nella ricerca psicologica, mostrando come esse possano essere impiegate per rappresentare l'incertezza in modo coerente e informativo.

Il Capitolo 12 sarà dedicato alle **distribuzioni discrete**: la distribuzione di Bernoulli per eventi binari singoli, la distribuzione binomiale per il conteggio dei successi in un numero finito di prove e la distribuzione di Poisson per la modellizzazione di eventi rari. Queste distribuzioni sono fondamentali per descrivere risposte categoriali, frequenze e conteggi.

Il Capitolo 13 affronterà invece le **distribuzioni continue**: la distribuzione normale per fenomeni influenzati da molti fattori indipendenti, la gamma e la log-normale per quantità positive e asimmetriche, la beta per proporzioni e probabilità e la *t* di Student per le situazioni in cui vi è incertezza sulla varianza.

Per ciascuna famiglia esamineremo la forma della distribuzione e il significato dei parametri, le proprietà matematiche rilevanti, i contesti in cui è appropriato utilizzarla e il suo ruolo nell'inferenza bayesiana, come distribuzione a priori, funzione di verosimiglianza o distribuzione a posteriori.

11.5.1. Una nota epistemologica

È importante ricordare che nessuna distribuzione è “vera” in senso assoluto. Come osservava George Box: *“tutti i modelli sono sbagliati, ma alcuni sono utili”*. La scelta di una famiglia parametrica rappresenta sempre un compromesso pragmatico: l'obiettivo non è catturare la realtà in ogni suo dettaglio, ma rappresentarne gli aspetti salienti con un adeguato livello di accuratezza e parsimonia.

Nel framework bayesiano, questa consapevolezza è incorporata nel metodo stesso. Modelli alternativi possono essere confrontati mediante il fattore di Bayes, combinati attraverso il *model averaging* e valutati tramite *posterior predictive checks*. In questo modo, anche l'incertezza associata alla scelta del modello diventa esplicita, quantificabile e gestibile all'interno del processo inferenziale.

Riflessioni conclusive

Nel framework bayesiano, le distribuzioni di probabilità sono strumenti fondamentali per rappresentare e comunicare l'incertezza. Ogni distribuzione fornisce una risposta formale alla domanda: «*Quanto dovrei credere in ciascun possibile valore?*», dato il mio attuale stato di conoscenza.

Le famiglie parametriche costituiscono un vocabolario ricco e flessibile per esprimere diversi tipi di credenze. La scelta della famiglia riflette le nostre assunzioni sulla natura del fenomeno studiato, ad esempio sui valori possibili, sulla simmetria o sull'asimmetria della distribuzione, mentre i valori dei parametri codificano il nostro stato di conoscenza specifico. Nell'inferenza bayesiana, questo vocabolario viene utilizzato sia per rappresentare le credenze a priori sui parametri, sia per formulare ipotesi sul processo generativo dei dati attraverso la verosimiglianza.

L'applicazione alla ricerca psicologica mette in luce l'importanza di questo approccio. La variabilità che caratterizza i fenomeni psicologici, sia tra individui, sia nel tempo, sia tra contesti, richiede strumenti che vadano oltre i semplici confronti tra medie. Le distribuzioni di probabilità permettono di rappresentare l'intera struttura della variabilità, trasformandola da "rumore" da ignorare a informazione da modellare e interpretare.

Nei capitoli successivi, esploreremo progressivamente questo vocabolario, concentrandoci sulle famiglie di distribuzioni che si sono rivelate più utili nella ricerca psicologica. L'obiettivo non è memorizzare formule, ma sviluppare un'intuizione solida sul tipo di distribuzione più appropriato in diverse circostanze e su come utilizzarla per ragionare in modo rigoroso e trasparente in situazioni di incertezza.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Le distribuzioni come linguaggio per l'incertezza

- Non descrivono "come sono i dati" ma "quali valori riteniamo plausibili"
- Strumento epistemico per rappresentare credenze razionali
- Passaggio da "credenza puntuale" a "credenza distribuita"

2. Duplice ruolo nell'inferenza bayesiana

- **Come prior:** rappresentano incertezza sui parametri $p(\theta)$
- **Come verosimiglianza:** descrivono il processo generativo $p(D | \theta)$
- La stessa famiglia può svolgere entrambi i ruoli in contesti diversi

3. Famiglie parametriche fondamentali

- **Bernoulli e Binomiale:** eventi binari e conteggi di successi
- **Beta:** proporzioni e probabilità (coniugata con Binomiale)
- **Normale (Gaussiana):** misure continue con variabilità simmetrica
- **Poisson:** conteggi di eventi rari in intervalli fissi
- **Gamma:** tempi di attesa e variabili continue positive

4. Supporto delle distribuzioni

- **Discreto finito:** Bernoulli, Binomiale (numero fisso di valori)

- **Discreto infinito:** Poisson (interi non negativi)
- **Continuo limitato:** Beta ($[0,1]$), Uniforme ($[a,b]$)
- **Continuo illimitato:** Normale ($\mathbb{R}$), Gamma ($\mathbb{R}^+$)

5. Parametri e interpretabilità

- **Parametri di posizione:** dove si concentra la distribuzione (media, moda)
- **Parametri di scala:** quanto è dispersa (varianza, deviazione standard)
- **Parametri di forma:** asimmetria, code pesanti, multimodalità
- Scelta parametri = scelta assunzioni esplicite

6. Coniugazione (anteprima)

- Prior e verosimiglianza “coniugati” $\rightarrow$ posterior della stessa famiglia del prior
- Semplifica enormemente i calcoli (forma chiusa per la posterior)
- Esempi: Beta-Binomiale, Normale-Normale, Gamma-Poisson

7. Principio di massima entropia

- Scegliere la distribuzione che massimizza l'entropia dati i vincoli noti
- Normale: massima entropia dato media e varianza note
- Esponenziale: massima entropia data solo la media (per $\mathbb{R}^+$)
- Uniforme: massima entropia senza vincoli (massima ignoranza)

8. Scelta della distribuzione nella pratica

- Vincoli sul supporto: interi vs reali, limitati vs illimitati
- Simmetria vs asimmetria
- Code pesanti vs leggere
- Informazioni pregresse codificabili
- Coniugazione per semplificare calcoli

Criteri di selezione:

Tipo di variabile	Supporto	Famiglia tipica	Esempio psicologico
Binaria (0/1)	$\{0,1\}$	Bernoulli	Risposta corretta/errata a un item
Conteggio successi	$\{0,1,\dots,n\}$	Binomiale	Item corretti su 20 in un test
Conteggio eventi rari	$\{0,1,2,\dots\}$	Poisson	Attacchi di panico in un mese
Proporzione/probabilità	$[0,1]$	Beta	Tasso di remissione, accuratezza
Misura continua simmetrica	$\mathbb{R}$	Normale	Punteggi QI, scale standardizzate
Tempo di attesa/reazione	$\mathbb{R}^+$	Gamma, Log-normale	Tempi di reazione, latenze
Varianza/precisione	$\mathbb{R}^+$	Gamma, Inversa-Gamma	Variabilità tra soggetti

Relazioni tra famiglie:

- Bernoulli è Binomiale con $n = 1$
- Esponenziale è Gamma con shape $\alpha = 1$
- Poisson emerge come limite di Binomiale per $n \rightarrow \infty, p \rightarrow 0$
- Normale emerge dal TLC (somma di variabili qualsiasi)

Per i prossimi capitoli:

Nel Capitolo 12 e Capitolo 13 studieremo in dettaglio le proprietà matematiche, i momenti, i grafici e le applicazioni psicologiche di ciascuna famiglia parametrica, fornendo gli strumenti operativi per specificare prior informativi e costruire modelli bayesiani interpretabili.

Bibliografia

12. Distribuzioni di variabili casuali discrete

Introduzione

Come discusso nel Capitolo 11, le distribuzioni di probabilità sono strumenti epistemici che permettono di rappresentare formalmente l'incertezza. In questo capitolo ci concentreremo sulle *distribuzioni discrete*, utilizzate per modellare fenomeni con esiti numerabili, come conteggi, scelte categoriali ed eventi binari.

Nel framework bayesiano, le distribuzioni discrete svolgono tre ruoli strettamente interconnessi. In qualità di **verosimiglianza**, descrivono il modo in cui i dati osservati vengono generati in funzione di un determinato valore del parametro. Come **distribuzioni a priori e a posteriori**, rappresentano le nostre credenze sui parametri prima e dopo l'osservazione dei dati. Infine, come **distribuzioni predittive**, esprimono le nostre aspettative riguardo alle osservazioni future, integrando l'incertezza sui parametri con la struttura del modello.

In questa prospettiva, i parametri delle distribuzioni, come p nella distribuzione binomiale o λ nella distribuzione di Poisson, non sono valori da “scoprire”, ma quantità su cui siamo più o meno incerti. L'inferenza bayesiana permette di descrivere questa incertezza e di aggiornarla in modo coerente sulla base dei dati osservati.

Una nota importante: quando presentiamo le distribuzioni discrete come Bernoulli, Binomiale e Poisson, lavoriamo inizialmente con la **verosimiglianza condizionale** $P(\text{dati}|\theta)$, dove θ (es. p o λ) è condizionato su un valore specifico. Questo non significa che θ sia “noto” o “fisso” in senso ontologico, ma solo che stiamo calcolando la probabilità dei dati *per un dato valore* del parametro. In seguito vedremo come integrare l'incertezza su θ attraverso le **distribuzioni predittive**, dove θ viene marginalizzato anziché condizionato.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- 1
- 2
- Capitolo 8
- Capitolo 11 — **fondamentale**

Questo capitolo studia in dettaglio le **distribuzioni discrete** (Bernoulli, Binomiale, Poisson) essenziali per modellare conteggi, eventi binari e fenomeni psicologici discreti.

Conoscenze matematiche richieste:

- Appendice E - per coefficienti binomiali

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
library(reshape2)
library(VGAM)
library(extraDistr)
```

12.1. Funzioni R per le distribuzioni

Per ogni distribuzione, R fornisce quattro funzioni con prefissi standardizzati:

```
# Esempio con binomiale: n=10 prove, p=0.6 probabilità di successo

# d = densità (massa di probabilità)
dbinom(7, size = 10, prob = 0.6) # P(X = 7)
#> [1] 0.215

# p = probabilità cumulativa
pbinom(7, size = 10, prob = 0.6) # P(X ≤ 7)
#> [1] 0.833

# q = quantile
qbinom(0.95, size = 10, prob = 0.6) # 95° percentile
#> [1] 8

# r = generazione casuale
rbinom(5, size = 10, prob = 0.6) # 5 simulazioni
#> [1] 8 6 7 7 5
```

Nell'inferenza bayesiana, la funzione *d* viene utilizzata per calcolare la verosimiglianza, mentre la funzione *r* permette di simulare dalla distribuzione predittiva.

12.2. Distribuzione uniforme discreta

12.2.1. Definizione

Definizione 12.1. Una variabile casuale X ha distribuzione *uniforme discreta* su $1, \dots, N$ se a ciascun valore possibile viene assegnata la stessa probabilità:

$$X \sim \text{Uniforme-Discreta}(N), \quad P(X = x) = \frac{1}{N} \quad \text{per } x \in 1, \dots, N.$$

Proprietà:

$$\mathbb{E}(X) = \frac{N+1}{2}, \quad \mathbb{V}(X) = \frac{N^2-1}{12}.$$

12.2.1.1. Interpretazione epistemica

La distribuzione uniforme discreta implementa il **principio di indifferenza**: quando non vi sono informazioni che discriminino tra le alternative, tutte le possibilità sono trattate come equiprobabili. La distribuzione uniforme riflette uno stato informativo simmetrico rispetto agli esiti, non una caratteristica oggettiva del sistema osservato.

12.2.2. Ruolo nell'inferenza bayesiana

Nel paradigma bayesiano, la distribuzione uniforme discreta svolge un ruolo fondamentale come **distribuzione a priori non informativa** su spazi parametrici finiti. Quando ci troviamo di fronte a un insieme di K ipotesi o modelli alternativi, e non disponiamo di alcuna informazione preliminare che favorisca specifiche alternative, la scelta più neutrale consiste nell'attribuire a ciascuna ipotesi la medesima probabilità iniziale:

$$P(M_k) = \frac{1}{K}, \quad k = 1, \dots, K.$$

Questa assegnazione formalizza esplicitamente l'**indifferenza epistemica** tra le opzioni disponibili, assicurando che l'evidenza empirica derivante dai dati sia l'unico fattore a guidare l'aggiornamento delle credenze attraverso il teorema di Bayes.

Esempio classico: dado equilibrato

Il lancio di un dado a sei facce rappresenta l'esempio paradigmatico di distribuzione uniforme discreta. Nell'ipotesi di perfetta simmetria del dado, ogni esito $\{1, 2, 3, 4, 5, 6\}$ ha probabilità pari a $1/6$.

```
# Simulazione di lanci di dado
set.seed(42)
N <- 6
n_lanci <- 10000
lanci <- sample(1:N, size = n_lanci, replace = TRUE)
```




```
# Confronto tra valori teorici ed empirici
media_teorica <- (N + 1) / 2
varianza_teorica <- (N^2 - 1) / 12

cat("Confronto statistico:\n")
#> Confronto statistico:
cat("  • Media:\n")
#>    • Media:
cat("      Teorica:", media_teorica, "\n")
#>      Teorica: 3.5
cat("      Empirica:", round(mean(lanci), 4), "\n\n")
#>      Empirica: 3.46
cat("  • Varianza:\n")
#>    • Varianza:
cat("      Teorica:", round(varianza_teorica, 4), "\n")
#>      Teorica: 2.92
cat("      Empirica:", round(var(lanci), 4))
#>      Empirica: 2.87

# Visualizzazione della distribuzione empirica
ggplot(data.frame(Esito = lanci), aes(x = factor(Esito))) +
  geom_bar(aes(y = ..prop.., group = 1), alpha = 0.8) +
  geom_hline(yintercept = 1/N, linetype = "dashed", linewidth = 1) +
  scale_y_continuous(labels = scales::percent_format()) +
  scale_fill_qualitative() +
  labs(
    title = "Distribuzione empirica di 10.000 lanci di dado",
    subtitle = paste("Linea tratteggiata: probabilità teorica uniforme (",
                     round(100/N, 1), "%)", sep = ""),
    x = "Esito del lancio",
    y = "Frequenza relativa"
  )
)
```

Distribuzione empirica di 10.000 lanci di dado

Linea tratteggiata: probabilità teorica uniforme (16.7%)



Applicazioni nella psicologia e nella ricerca sperimentale

Contesti di utilizzo tipici:

- **Assegnazione casuale:** la distribuzione uniforme viene utilizzata per modellare la randomizzazione dei partecipanti in K condizioni sperimentali, assumendo che ciascuna condizione abbia la stessa probabilità di essere assegnata. Questa procedura contribuisce a ridurre bias sistematici e a garantire la validità interna dello studio.
- **Prior non informativo:** in assenza di informazioni preliminari che favoriscano una specifica ipotesi teorica, una distribuzione uniforme su un insieme finito di ipotesi rappresenta una scelta iniziale neutrale e metodologicamente trasparente.
- **Campionamento di item:** quando stimoli, item o prove vengono selezionati casualmente da un insieme finito e ciascun elemento ha la stessa probabilità di essere scelto, la variabile casuale associata alla selezione può essere descritta mediante una distribuzione uniforme discreta.
- **Modelli di scelta:** in alcuni compiti decisionali, la distribuzione uniforme è impiegata come modello di riferimento per rappresentare scelte puramente casuali, in assenza di preferenze sistematiche.

Esempio sperimentale: in un esperimento di psicologia sociale con quattro condizioni sperimentali, l'assegnazione dei partecipanti può essere modellata assumendo una distribuzione uniforme discreta sui valori 1, 2, 3, 4. In questo modo, ciascuna condizione ha la stessa probabilità di essere selezionata, indipendentemente dalle caratteristiche individuali dei partecipanti.

Nota metodologica fondamentale: l'assunzione di equiprobabilità non implica che il fenomeno studiato sia intrinsecamente "casuale" o privo di struttura. Piuttosto, essa rappresenta una **scelta modellistica esplicita**, che riflette uno stato di incertezza iniziale o l'assenza di informazioni rilevanti sulle probabilità relative degli esiti possibili.

12.3. Distribuzione di Bernoulli

12.3.1. Definizione

Definizione 12.2. Una variabile casuale X segue una distribuzione di *Bernoulli* se può assumere **solo due valori possibili**, convenzionalmente codificati come 1 ("successo") e 0 ("insuccesso"). La probabilità di successo è indicata con p , mentre la probabilità di insuccesso è $1 - p$:

$$X \sim \text{Bernoulli}(p), \quad P(X = x) = p^x(1 - p)^{1-x}, \quad x \in 0, 1.$$

Proprietà:

$$\mathbb{E}(X) = p, \quad \mathbb{V}(X) = p(1 - p).$$

La distribuzione di Bernoulli rappresenta il **modello probabilistico più semplice** per descrivere fenomeni aleatori dicotomici, nei quali ogni osservazione corrisponde a un singolo esito binario.

12.3.1.1. Interpretazione epistemica

Il parametro p rappresenta la **probabilità associata all'esito etichettato come "successo"**. Dal punto di vista epistemico, p può essere interpretato come il grado di credenza o l'informazione disponibile circa il verificarsi di tale esito, prima dell'osservazione dei dati.

In ambito psicologico e sperimentale, la distribuzione di Bernoulli è frequentemente utilizzata per modellare eventi come risposte corrette/errate, presenza/assenza di un comportamento, decisioni sì/no o superamento/fallimento di una prova. In tutti questi casi, l'incertezza riguarda un singolo evento e non una sequenza di prove.

12.3.2. Ruolo nell'inferenza bayesiana

La distribuzione di Bernoulli costituisce il **modello di base per l'analisi di dati binari** ed è un elemento fondamentale nell'inferenza bayesiana. In particolare, essa descrive il meccanismo generativo di ciascuna osservazione individuale, mentre l'aggregazione di più prove indipendenti conduce naturalmente alla distribuzione binomiale, trattata nel paragrafo successivo.

Nell'approccio bayesiano, il parametro p è considerato una variabile casuale e viene tipicamente modellato mediante una distribuzione Beta, che funge da prior coniugato. Questa scelta consente di aggiornare le credenze su p in modo analitico, combinando informazione a priori e dati osservati in maniera coerente e trasparente.

Applicazioni nella psicologia e nelle scienze comportamentali

Contesti tipici di utilizzo:

- **Item di test cognitivi:** risposta corretta o errata a una singola domanda.
- **Diagnosi psicopatologiche:** presenza o assenza di uno specifico sintomo (ad es. attacchi di panico nella settimana precedente).
- **Screening clinici:** esito positivo o negativo a strumenti di valutazione diagnostica (ad es. test per il PTSD).
- **Scelte comportamentali:** decisioni dicotomiche, come accettare o rifiutare una proposta.
- **Osservazioni comportamentali:** occorrenza o non occorrenza di un comportamento target (ad es. fare una pausa durante l'esecuzione di un compito).

Esempio concreto.

Un partecipante completa un test di memoria episodica composto da 10 item. Ciascuna risposta viene modellata come

$$X_i \sim \text{Bernoulli}(p),$$

dove p rappresenta la probabilità di ricordare correttamente un singolo item. In questo contesto, la competenza mnestica del partecipante è sintetizzata dal valore del parametro p .

Scelta del prior bayesiano:

- **Prior non informativo:** $\text{Beta}(1, 1)$, che corrisponde a una distribuzione uniforme sull'intervallo $[0, 1]$.
- **Prior informativo:** $\text{Beta}(\alpha, \beta)$, con i parametri α e β scelti sulla base di dati normativi o di risultati provenienti da studi precedenti sulla difficoltà del compito.

i Esempio: sensibilità di un test diagnostico

Consideriamo un test diagnostico con sensibilità pari a 0.85, ossia con probabilità $p = 0.85$ di fornire un risultato positivo quando la condizione è presente. Ogni singolo esito del test può essere modellato come una variabile di Bernoulli.

```
# Test diagnostico con sensibilità 0.85
p_sens <- 0.85
set.seed(123)
risultati <- rbinom(1000, size = 1, prob = p_sens)
```

```
cat("Proporzione campionaria di test positivi:",
    round(mean(risultati), 3), "\n")
#> Proporzione campionaria di test positivi: 0.853
```

```
cat("Valore teorico:", p_sens)
#> Valore teorico: 0.85
```

La simulazione mostra che, su un numero elevato di osservazioni, la proporzione campionaria di esiti positivi si avvicina al valore del parametro p . Tuttavia, per campioni più piccoli, tale proporzione può variare sensibilmente, riflettendo l'incertezza intrinseca associata alle singole osservazioni binarie.

12.4. Distribuzione binomiale

12.4.1. Dalla Bernoulli alla binomiale

La distribuzione binomiale nasce come **estensione naturale della distribuzione di Bernoulli** al caso di **più osservazioni indipendenti**. Comprenderne la costruzione passo per passo aiuta a chiarire il significato della sua formula e delle sue componenti.

Supponiamo di osservare n prove indipendenti, ciascuna caratterizzata da due soli esiti possibili:

- **successo** 1, con probabilità p ;
- **insuccesso** 0, con probabilità $1 - p$.

L'obiettivo è descrivere la probabilità di osservare un determinato **numero totale di successi** al termine delle n prove.

12.4.2. Passo 1 — Probabilità di una sequenza specifica

Consideriamo una **sequenza ordinata** di n esiti che contenga esattamente k successi e $n - k$ insuccessi. Poiché le prove sono indipendenti, la probabilità di osservare quella specifica sequenza è data dal prodotto delle probabilità dei singoli esiti:

$$p^k (1 - p)^{n-k}.$$

Questa probabilità è identica per **qualsiasi** sequenza che presenti k successi, indipendentemente dall'ordine in cui essi compaiono.

12.4.3. Passo 2 — Conteggio delle sequenze possibili

Nella maggior parte delle applicazioni non interessa l'ordine degli esiti, ma solo **quanti** successi si verificano complessivamente. È quindi necessario contare quante sequenze distinte di lunghezza n contengono esattamente k successi.

Questo numero è fornito dal **coefficiente binomiale**:

$$\binom{n}{k},$$

che rappresenta il numero di modi in cui è possibile scegliere k posizioni di successo tra le n prove disponibili.

12.4.4. Passo 3 — Probabilità di k successi

Le sequenze che contengono k successi sono:

- tutte equiprobabili;
- mutuamente esclusive.

La probabilità di osservare **esattamente** k **successi** è quindi ottenuta sommando le probabilità di tutte queste sequenze:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

Questa espressione costituisce la **funzione di massa di probabilità della distribuzione binomiale**.

i Idea chiave

La distribuzione binomiale nasce dalla combinazione di due componenti fondamentali:

- **Componente probabilistica** $p^k(1 - p)^{n-k}$: probabilità associata a una specifica configurazione di successi e insuccessi.
- **Componente combinatoria** $\binom{n}{k}$: numero di configurazioni distinte che producono lo stesso numero totale di successi.

La probabilità binomiale è il prodotto di questi due fattori.

12.4.5. Definizione

Definizione 12.3. Una variabile casuale X che rappresenta il numero di successi osservati in n prove indipendenti di Bernoulli, ciascuna con probabilità di successo p , segue una distribuzione binomiale:

$$X \sim \text{Binomiale}(n, p), \quad P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

Momenti principali:

$$\mathbb{E}(X) = np, \quad \mathbb{V}(X) = np(1 - p).$$

12.4.5.1. Interpretazione epistemica

La distribuzione binomiale rappresenta le nostre **credenze sul numero di successi** quando:

- il numero di prove n è noto;
- il parametro p esprime l'incertezza sulla probabilità di successo di ciascuna singola prova.

Il coefficiente binomiale riflette il fatto che **molti pattern distinti di esiti** possono condurre allo stesso conteggio complessivo di successi.

12.4.6. Ruolo nell'inferenza bayesiana

La distribuzione binomiale costituisce la **verosimiglianza fondamentale** per dati binari aggregati. Osservati y successi su n prove, la verosimiglianza per il parametro p è:

$$L(p \mid y, n) \propto p^y (1 - p)^{n-y}.$$

Assumendo una prior beta:

$$p \sim \text{Beta}(\alpha, \beta),$$

la distribuzione a posteriori risulta ancora una beta:

$$p \mid y \sim \text{Beta}(\alpha + y, \beta + n - y).$$

Questa relazione di coniugazione rende l'aggiornamento delle credenze particolarmente semplice: i dati osservati si traducono in un incremento diretto degli **pseudo-conteggi** associati alla *prior*.

i Esempio: aggiornamento bayesiano

```
# Dati osservati: 23 successi su 30 prove
n <- 30
y <- 23

# Prior: Beta(2, 2) - moderatamente informativa, centrata su 0.5
alpha_prior <- 2
beta_prior <- 2

# Posterior: Beta(25, 9)
alpha_post <- alpha_prior + y
beta_post <- beta_prior + (n - y)


# Visualizzazione
p_seq <- seq(0, 1, length.out = 1000)

df <- data.frame(
  p = rep(p_seq, 2),
  densita = c(dbeta(p_seq, alpha_prior, beta_prior),
              dbeta(p_seq, alpha_post, beta_post)),
  tipo = rep(c("Prior Beta(2,2)", "Posterior Beta(25,9)"), each = length(p_seq))
)

ggplot(df, aes(x = p, y = densita, color = tipo)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(
    title = "Aggiornamento Bayesiano: Beta-Binomiale",
    subtitle = "23 successi su 30 prove",
    x = "p", y = "Densità"
  )
)
```

Aggiornamento Bayesiano: Beta-Binomiale

23 successi su 30 prove



```
cat("Media prior:", round(alpha_prior/(alpha_prior + beta_prior), 3), "\n")
#> Media prior: 0.5
```

```
cat("Media posterior:", round(alpha_post/(alpha_post + beta_post), 3), "\n")
#> Media posterior: 0.735
```

La distribuzione a posteriori si concentra attorno a $p \approx 0.74$, mostrando una notevole riduzione dell'incertezza rispetto alla *prior*. Ciò riflette l'aggiornamento coerente delle credenze alla luce dei 23 successi osservati.

Applicazioni in psicologia

Contesti tipici di utilizzo:

- **Test cognitivi:** punteggio totale su n item (ad es. 18 risposte corrette su 20).
- **Scale diagnostiche:** numero di sintomi positivi in una checklist (ad es. 5 su 9 criteri del DSM-5).
- **Compiti ripetuti:** risposte corrette in prove multiple (ad es. 7 richiami corretti su 10 prove).
- **Monitoraggio longitudinale:** conteggio di comportamenti target in periodi definiti (ad es. 22 giorni di aderenza terapeutica su 30).

Esempio: un partecipante risponde a 25 item Vero/Falso, ciascuno con probabilità di risposta corretta $p = 0.7$. Il punteggio totale segue una distribuzione binomiale $\text{Binom}(25, 0.7)$.

Approccio bayesiano: per il parametro p , la distribuzione Beta è il prior coniugato. Alcune configurazioni tipiche sono:

- $\text{Beta}(1, 1)$: prior non informativo (uniforme su $[0, 1]$);
- $\text{Beta}(5, 5)$: prior debolmente informativo, centrato intorno a $p \approx 0.5$;
- $\text{Beta}(20, 10)$: prior informativo, con aspettativa $\mathbb{E}[p] \approx 0.67$.

Relazione strutturale: la distribuzione binomiale può essere interpretata come la **somma di n variabili di Bernoulli indipendenti e identicamente distribuite**.

12.5. Distribuzione di Poisson

12.5.1. Quando ha senso usare la distribuzione di Poisson

La distribuzione di Poisson viene utilizzata per modellare il **numero di eventi che si verificano in un intervallo di tempo o di spazio**, quando sono soddisfatte le seguenti condizioni:

- gli eventi sono **rari** rispetto all'ampiezza dell'intervallo considerato;
- gli eventi si verificano **indipendentemente** l'uno dall'altro;
- la probabilità che due o più eventi avvengano simultaneamente è trascurabile.

Esempi tipici in psicologia includono il numero di attacchi di panico in un mese, il numero di errori in un compito di attenzione sostenuta (es. CPT), il numero di comportamenti autolesionistici in una settimana, o il numero di risvegli notturni in pazienti con disturbi del sonno.

12.5.2. Definizione

Definizione 12.4. Una variabile casuale Y segue una distribuzione di Poisson con parametro $\lambda > 0$ se la probabilità di osservare y eventi è:

$$Y \sim \text{Poisson}(\lambda), \quad P(Y = y) = \frac{\lambda^y e^{-\lambda}}{y!}, \quad y = 0, 1, 2, \dots$$

Proprietà caratteristica:

$$\mathbb{E}(Y) = \mathbb{V}(Y) = \lambda.$$

12.5.2.1. Interpretazione epistemica

Il parametro λ rappresenta il **tasso medio atteso di occorrenza degli eventi** nell'intervallo considerato. Ad esempio, affermare che $\lambda = 0.7$ significa ritenere che, in media, ci si aspetti meno di un evento per intervallo, pur ammettendo che possano verificarsi anche eventi multipli.

La proprietà $\mathbb{E}(Y) = \mathbb{V}(Y)$ prende il nome di **equidispersione** e costituisce un'assunzione forte del modello. Nei dati psicologici e comportamentali è tuttavia frequente osservare **sovradisersione**, ossia una varianza maggiore della media. In tali situazioni, la distribuzione di Poisson può risultare inadeguata e vengono spesso preferiti modelli più flessibili, come la distribuzione binomiale negativa.

i Idea chiave della distribuzione di Poisson

La distribuzione di Poisson non modella *se* un evento si verifica, ma **quante volte** si verifica in un dato intervallo, assumendo eventi rari e indipendenti nel tempo o nello spazio.

12.5.3. Ruolo nell'inferenza bayesiana

Nel framework bayesiano, la distribuzione di Poisson svolge il ruolo di **verosimiglianza** per dati di conteggio. Il parametro λ è trattato come una quantità incerta, su cui esprimere una distribuzione a priori.

La **distribuzione coniugata** per λ è la distribuzione Gamma, che consente un aggiornamento analiticamente semplice delle credenze.

Coniugazione Gamma–Poisson. Se

$$\lambda \sim \text{Gamma}(\alpha, \beta),$$

e osserviamo conteggi indipendenti $y_1, \dots, y_n$, allora la distribuzione a posteriori è:

$$\lambda \mid \mathbf{y} \sim \text{Gamma} \left(\alpha + \sum_{i=1}^n y_i, \beta + n \right).$$

L'aggiornamento è intuitivo:

- il numero totale di eventi osservati aggiorna il parametro di forma;
- il numero di intervalli osservati aggiorna il parametro di scala (o tasso).

Applicazioni in psicologia

Quando è tipicamente utile:

- **Eventi rari nel tempo** (conteggi su un intervallo):
 - attacchi di panico in un mese;
 - errori di omissione in un compito di vigilanza;
 - accessi al pronto soccorso per crisi psicotiche in una settimana.
- **Conteggi con esposizione variabile** (tassi: eventi per unità di “tempo di esposizione”):
 - parole richiamate per minuto di studio;
 - click su uno stimolo target per secondo di esposizione.

Esempio clinico Un paziente con disturbo d’ansia presenta una frequenza media di $\lambda = 2.5$ attacchi di panico al mese. Il numero di attacchi osservati in un periodo di **30 giorni** può essere modellato come:

$$Y \sim \text{Poisson}(2.5).$$

Inferenza bayesiana Per il parametro λ , la famiglia $\text{Gamma}(\alpha, \beta)$ è il prior coniugato. In questa parametrizzazione:

- α rappresenta uno “pseudo-conteggio” di eventi;
- β rappresenta una “pseudo-durata” dell’osservazione.

Ad esempio, una prior $\text{Gamma}(5, 2)$ equivale a una credenza simile a “**5 eventi osservati in 2 mesi**”.

Distinzione chiave

- **Binomiale**: numero *fisso* di prove $\rightarrow$ conteggio dei successi;
- **Poisson**: eventi rari e indipendenti $\rightarrow$ conteggio delle occorrenze in un intervallo continuo (tempo o spazio).

i Esempio: eventi rari e dati storici

Un esempio classico di applicazione della distribuzione di Poisson è il dataset di von Bortkiewicz sui decessi causati da calci di cavallo nell’esercito prussiano, spesso citato come prototipo di processo con eventi rari e indipendenti.

```
# Dati storici
decessi <- 0:4
freq_oss <- c(109, 65, 22, 3, 1)
n_tot <- sum(freq_oss)

# Stima del tasso medio
lambda_mle <- sum(decessi * freq_oss) / n_tot

data.frame(
  Decessi = decessi,
  Frequenza_osservata = round(freq_oss / n_tot, 4),
  Prob_Poisson = round(dpois(decessi, lambda = lambda_mle), 4)
)
#>   Decessi Frequenza_osservata Prob_Poisson
#> 1      0             0.545         0.5434
#> 2      1             0.325         0.3314
#> 3      2             0.110         0.1011
#> 4      3             0.015         0.0206
#> 5      4             0.005         0.0031
```

L'elevata corrispondenza tra le frequenze osservate e le probabilità teoriche suggerisce che il processo generativo sia compatibile con le assunzioni della distribuzione di Poisson.

12.5.4. Aggiornamento bayesiano del tasso

```
# Prior debolmente informativa
alpha_prior <- 0.5
beta_prior <- 1

# Totale eventi osservati
y_tot <- sum(decessi * freq_oss)

# Posterior
alpha_post <- alpha_prior + y_tot
beta_post <- beta_prior + n_tot

# Stima a posteriori
lambda_post <- alpha_post / beta_post
IC_95 <- qgamma(c(0.025, 0.975), alpha_post, beta_post)
```

```
cat("Media a posteriori di :", round(lambda_post, 3), "\n")
#> Media a posteriori di : 0.609
```

```
cat("Intervallo di credibilità 95%: [",
    round(IC_95[1], 3), ", ",
    round(IC_95[2], 3), "]\n", sep = "")
#> Intervallo di credibilità 95%: [0.506, 0.722]
```

La distribuzione a posteriori fornisce una stima coerente del tasso di occorrenza e quantifica in modo esplicito l'incertezza residua sul parametro λ .

i Nota avanzata: distribuzione beta-binomiale (materiale opzionale per approfondimento futuro)

Avvertenza per il lettore

Questa sezione introduce un concetto che verrà sviluppato in modo sistematico nei capitoli successivi. La sua comprensione completa richiede familiarità con:

- la distribuzione Beta (trattata nel prossimo capitolo),
- l'integrazione per marginalizzazione,
- le distribuzioni predittive e i modelli gerarchici.

È del tutto legittimo saltare questa sezione e tornarci dopo aver studiato le distribuzioni continue. È inclusa come anticipazione concettuale per il lettore curioso, ma non è necessaria per proseguire.

Da verosimiglianza condizionale a distribuzione predittiva

Quando modelliamo $Y \sim \text{Binomiale}(n, p)$, lavoriamo tipicamente con la **verosimiglianza condizionale**:

$$P(Y = k | p) = \binom{n}{k} p^k (1-p)^{n-k}$$

Questa formula ci dice: “Qual è la probabilità di osservare k successi, *dato un valore specifico* del parametro p ?” Qui p è **condizionato**: stiamo calcolando la verosimiglianza per un particolare valore di p , non perché p sia “noto” o “oggettivamente fisso”, ma perché questa è la struttura della verosimiglianza.

Tuttavia, nell'approccio bayesiano, p è una **quantità incerta** su cui abbiamo una distribuzione di credenza. Quando vogliamo fare previsioni sui dati futuri **senza fissare un valore specifico di p** , dobbiamo integrare la nostra incertezza su p attraverso la sua distribuzione a priori.

Dalla condizionalità alla marginalizzazione

Se rappresentiamo la nostra incertezza su p con una distribuzione Beta:

$$p \sim \text{Beta}(\alpha, \beta)$$

e vogliamo calcolare la probabilità di osservare k successi **integrando** su tutti i possibili valori di p , dobbiamo calcolare la **distribuzione predittiva a priori**:

$$P(Y = k) = \int_0^1 P(Y = k | p) \cdot P(p) dp = \int_0^1 \binom{n}{k} p^k (1-p)^{n-k} \cdot \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} dp$$

Questo integrale, sebbene tecnicamente complesso, produce una forma chiusa nota come **distribuzione beta-binomiale**:

$$Y \sim \text{BetaBinomiale}(n, \alpha, \beta)$$

con funzione di massa:

$$P(Y = k) = \binom{n}{k} \frac{B(k + \alpha, n - k + \beta)}{B(\alpha, \beta)},$$

dove $B(\cdot, \cdot)$ è la funzione beta.

Interpretazione epistemica

La transizione da binomiale a beta-binomiale riflette un cambiamento di prospettiva:

- **Verosimiglianza condizionale** $P(Y | p)$: “Quant’è probabile osservare k successi *condizionando su un valore specifico* p ?”
 - Risposta: distribuzione **Binomiale**
 - p è trattato come parametro condizionato
- **Distribuzione predittiva** $P(Y)$: “Quant’è probabile osservare k successi *prima di sapere quale sia* il valore di p ?”
 - Risposta: distribuzione **Beta-Binomiale**
 - p è marginalizzato (integrato via) per riflettere l’incertezza

Entrambe sono perfettamente coerenti con l’approccio bayesiano: nella prima *condizioniamo* su p per strutturare la verosimiglianza, nella seconda *marginalizziamo* su p per fare previsioni che tengano conto dell’incertezza sul parametro.

Simulazione in R

In R, la distribuzione beta-binomiale è disponibile tramite il pacchetto `extraDistr`:

```
# Simulazione: confronto tra binomiale (p fisso) e beta-binomiale (p incerto)
set.seed(42)
n <- 20 # numero di prove

# Scenario 1: Binomiale con p fissato a 0.3
# (come se sapessimo con certezza che p = 0.3)
p_fisso <- 0.3
y_bin <- rbinom(n = 10000, size = n, prob = p_fisso)

# Scenario 2: Beta-binomiale con p ~ Beta(3, 7)
# (rappresenta incertezza su p, con E[p] = 0.3 ma varianza positiva)
alpha <- 3
beta <- 7
y_bb <- rbbinom(n = 10000, size = n, alpha = alpha, beta = beta)
```


Confrontiamo le distribuzioni:

```
# Preparazione dati per visualizzazione
df_comparison <- data.frame(
  k = 0:n,
  Binomiale = dbinom(0:n, size = n, prob = p_fisso),
  BetaBinomiale = dbbinom(0:n, size = n, alpha = alpha, beta = beta)
) |>
  pivot_longer(cols = c(Binomiale, BetaBinomiale),
               names_to = "Modello",
               values_to = "Probabilità")

# Visualizzazione
ggplot(df_comparison, aes(x = k, y = Probabilità, fill = Modello)) +
  geom_col(position = "dodge", alpha = 0.8) +
  scale_fill_qualitative() +
  labs(
    title = "Confronto: Binomiale vs Beta-Binomiale",
    subtitle = bquote("Binomiale: " ~ p == 0.3 ~ "(fisso)" ~ "|" ~
                      "Beta-Binomiale: " ~ p %~% Beta(3,7) ~ "(incerto)"),
    x = "Numero di successi (k)",
    y = "Probabilità P(Y = k)"
  ) +
  theme(legend.position = "top")
```

Confronto: Binomiale vs Beta-Binomiale

Binomiale: $p = 0.3$ (fisso) | Beta-Binomiale: $p \sim B(3, 7)$ (incerto)



Osservazione chiave: la beta-binomiale presenta **code più pesanti** e una distribuzione più dispersa rispetto alla binomiale. Questo riflette l'ulteriore fonte di incertezza: non solo la variabilità campionaria (binomiale), ma anche l'incertezza sul valore del parametro p stesso.

La sovradisersione come firma dell'incertezza parametrica

Confrontiamo le varianze empiriche:

```
cat("Beta-Binomiale - Varianza:", round(var(y_bb), 3), "\n")
#> Beta-Binomiale - Varianza: 11.8
cat("Binomiale (p condizionato) - Varianza:", round(var(y_bin), 3), "\n")
#> Binomiale (p condizionato) - Varianza: 4.29
```

Interpretazione: la beta-binomiale **anticipa una maggiore dispersione**, poiché integra due fonti di incertezza:

1. **Variabilità campionaria:** la fluttuazione casuale nel numero di successi (presente in entrambi i modelli).
2. **Incertezza parametrica:** il fatto che non sappiamo esattamente quale sia il valore di p (presente solo nella beta-binomiale).

Questa “varianza extra” rispetto alla binomiale standard è detta **sovradisersione** ed è una caratteristica distintiva delle distribuzioni predittive.

Dove riapparirà nel manuale

La distribuzione beta-binomiale, e più in generale il concetto di distribuzione predittiva, ricomparirà in tre contesti fondamentali:

1. **Distribuzioni predittive bayesiane**, quando si vogliono prevedere nuove osservazioni integrando l'incertezza a posteriori sui parametri dopo aver osservato dati.
2. **Sovradispersione nei dati empirici**, quando la variabilità osservata eccede quella prevista dalla binomiale standard, segnalando che è necessario modellare l'eterogeneità tra unità di osservazione.
3. **Modelli gerarchici**, quando ogni unità (persona, gruppo, item) possiede il proprio parametro p_i , estratto da una distribuzione comune $\text{Beta}(\alpha, \beta)$.

Messaggio da portare con sé

La distribuzione beta-binomiale non introduce un nuovo tipo di fenomeno, ma un nuovo **livello di rappresentazione dell'incertezza**: quello relativo al parametro stesso. Passa dalla domanda “Cosa succede dato p ?” alla domanda “Cosa succede quando non so esattamente quale sia p ?”

Non è necessario padroneggiare ora i dettagli matematici: essi verranno ripresi e chiariti in modo sistematico nel capitolo dedicato alle distribuzioni continue (Capitolo 13) e nei capitoli dedicati alle distribuzioni predittive e ai modelli gerarchici del sito [utet-companion](#).

Per il momento, è sufficiente:

- riconoscere che la beta-binomiale **esiste**;
- comprenderne il **ruolo concettuale**: marginalizzare l'incertezza sul parametro;
- ricordare che produce **sovradisersione** rispetto alla binomiale condizionale.

Questi concetti diventeranno centrali quando affronteremo l'inferenza bayesiana completa.

Riflessioni conclusive

Le distribuzioni discrete esaminate in questo capitolo costituiscono strumenti epistemici fondamentali per rappresentare e aggiornare le credenze relative a fenomeni caratterizzati da esiti numerabili. Ciascuna distribuzione incorpora assunzioni specifiche sul processo di generazione dei dati: la distribuzione uniforme discreta formalizza uno stato di indifferenza epistemica rispetto a un insieme finito di alternative; la distribuzione di Bernoulli modella eventi binari elementari; la distribuzione

binomiale descrive il numero di successi in una serie di prove indipendenti con probabilità costante; la distribuzione di Poisson rappresenta il verificarsi di eventi rari governati da un tasso medio costante; la distribuzione beta-binomiale, infine, estende il modello binomiale descrivendo la distribuzione dei conteggi quando vi è incertezza sul parametro sottostante.

In questa prospettiva bayesiana, i parametri di tali modelli non sono semplici quantità fisse da “stimare”, ma grandezze incerte su cui formuliamo distribuzioni di credenza. L’eleganza formale del framework bayesiano emerge in modo particolarmente chiaro attraverso le relazioni di coniugazione: la distribuzione beta fornisce una rappresentazione naturale delle credenze sul parametro p della distribuzione di Bernoulli e di quella binomiale, mentre la distribuzione gamma svolge un ruolo analogo per il parametro λ della distribuzione di Poisson. Queste relazioni consentono aggiornamenti coerenti e, in molti casi, analiticamente trattabili delle credenze alla luce dei dati osservati.

Nel capitolo successivo ci occuperemo delle **distribuzioni continue**, come la distribuzione beta, la distribuzione gamma, la distribuzione normale e altre ancora. Queste distribuzioni svolgeranno un duplice ruolo: da un lato, fungeranno da modelli per le variabili continue osservabili; dall’altro, costituiranno distribuzioni a priori naturali per i parametri dei modelli discreti introdotti in questo capitolo. In questo modo, completeremo progressivamente il vocabolario probabilistico essenziale per sviluppare e comprendere l’inferenza bayesiana in contesti sempre più generali.

Guida rapida: quale distribuzione usare?

Distribuzione	Dominio	Quando usarla	Prior tipici	Esempio psicologico
Uniforme discreta	$\{1, \dots, N\}$	Scelta casuale tra N alternative equiprobabili	—	Randomizzazione tra 4 condizioni sperimentali
Bernoulli	$\{0, 1\}$	Singolo esito binario (successo/fallimento)	Beta(1,1) o Beta(α, β)	Risposta corretta a un item del test
Binomiale	$\{0, \dots, n\}$	Numero di successi su n prove indipendenti	Beta(α, β)	18 risposte corrette su 25 domande
Poisson	$\{0, 1, 2, \dots\}$	Conteggio di eventi rari in tempo/spazio fisso	Gamma(α, β)	3 attacchi di panico in un mese
Beta-Binomiale	$\{0, \dots, n\}$	Binomiale con p incerto (sovradisersione)	Beta(α, β) su p	Successi quando ogni soggetto ha un p diverso

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Distribuzione di Bernoulli

- Modella singolo evento binario: successo (1) o fallimento (0)

- $P(X = 1) = \theta, P(X = 0) = 1 - \theta$
- $\mathbb{E}[X] = \theta, \text{Var}(X) = \theta(1 - \theta)$
- Base per tutti i modelli binari in psicologia

2. Distribuzione Binomiale

- Conteggio di successi in n prove Bernoulli indipendenti
- $P(X = k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$
- $\mathbb{E}[X] = n\theta, \text{Var}(X) = n\theta(1 - \theta)$
- Usata per: risposte corrette in test, prevalenze, adesione a trattamenti

3. Distribuzione di Poisson

- Conteggio di eventi rari in intervallo fisso
- $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots$
- $\mathbb{E}[X] = \lambda, \text{Var}(X) = \lambda$ (equidispersione!)
- Usata per: numero sintomi, comportamenti rari, crisi panic

4. Proprietà chiave delle distribuzioni discrete

- Dominio: valori numerabili (interi)
- Somma di PMF = 1
- Facilmente visualizzabili con diagrammi a barre
- Simulabili facilmente in R

5. Applicazioni in psicologia

- **Bernoulli**: diagnosi binaria (disturbo presente/assente)
- **Binomiale**: accuratezza in test cognitivi, risposte “sì/no” in questionari
- **Poisson**: eventi psicopatologici infrequenti, conteggio sintomi DSM

Formule da ricordare:

Bernoulli(θ):

$$P(X = x) = \theta^x (1 - \theta)^{1-x}, \quad x \in \{0, 1\}$$

Binomiale(n, θ):

$$P(X = k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}, \quad k = 0, 1, \dots, n$$

$$\mathbb{E}[X] = n\theta, \quad \text{Var}(X) = n\theta(1 - \theta)$$

Poisson(λ):

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

$$\mathbb{E}[X] = \lambda, \quad \text{Var}(X) = \lambda$$

Proprietà critiche:

- Binomiale è somma di n Bernoulli i.i.d.
- Poisson è limite di Binomiale per $n \rightarrow \infty, p \rightarrow 0, np = \lambda$
- Poisson ha equidispersione (media = varianza)
- Varianza Binomiale massima quando $\theta = 0.5$

Per il prossimo capitolo:

Nel Capitolo 13 studieremo le **distribuzioni continue** (Beta, Normale, Gamma, Esponenziale), fondamentali per modellare proporzioni, misure psicometriche, tempi di reazione e parametri continui nei modelli bayesiani.

Esercizi

 Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] splines stats4 stats graphics grDevices utils datasets
#> [8] methods base
#>
#> other attached packages:
#> [1] extraDistr_1.10.0.4 VGAM_1.1-14 reshape2_1.4.5
#> [4] ragg_1.5.2 tinytable_0.17.0 withr_3.0.3
#> [7] systemfonts_1.3.2 patchwork_1.3.2 ggdist_3.3.3
#> [10] tidybayes_3.0.7 bayesplot_1.15.0 ggplot2_4.0.3
#> [13] reliabilitydiag_0.2.1 priorsense_1.2.0 posterior_1.7.0
#> [16] loo_2.10.0 rstan_2.32.7 StanHeaders_2.32.10
#> [19] brms_2.23.0 Rcpp_1.1.2 sessioninfo_1.2.4
#> [22] conflicted_1.2.0 janitor_2.2.1 matrixStats_1.5.0
#> [25] modelr_0.1.11 tibble_3.3.1 dplyr_1.2.1
#> [28] tidyr_1.3.2 rio_1.3.0 here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8 tidyselect_1.2.1 farver_2.1.2
#> [4] S7_0.2.2 fastmap_1.2.0 tensorA_0.36.2.1
#> [7] digest_0.6.39 timechange_0.4.0 estimability_2.0.0
#> [10] lifecycle_1.0.5 magrittr_2.0.5 compiler_4.6.1
#> [13] rlang_1.3.0 tools_4.6.1 knitr_1.51
#> [16] labeling_0.4.3 bridgesampling_1.2-1 pkgbuild_1.4.8
#> [19] curl_7.1.0 plyr_1.8.9 RColorBrewer_1.1-3
#> [22] abind_1.4-8 purrr_1.2.2 grid_4.6.1
#> [25] xtable_1.8-8 inline_0.3.21 emmeans_2.0.3
#> [28] scales_1.4.0 cli_3.6.6 mvtnorm_1.4-1
#> [31] rmarkdown_2.31 generics_0.1.4 otel_0.2.0
#> [34] RcppParallel_5.1.11-2 cachem_1.1.0 stringr_1.6.0
#> [37] parallel_4.6.1 vctrs_0.7.3 V8_8.2.0
#> [40] Matrix_1.7-5 jsonlite_2.0.0 arrayhelpers_1.1-1
#> [43] glue_1.8.1 codetools_0.2-20 distributional_0.8.1
#> [46] lubridate_1.9.5 stringi_1.8.7 gtable_0.3.6
#> [49] QuickJSR_1.10.0 pillar_1.11.1 htmltools_0.5.9
#> [52] Brodningnag_1.2-9 R6_2.6.1 textshaping_1.0.5
#> [55] rprojroot_2.1.1 evaluate_1.0.5 lattice_0.22-9
#> [58] backports_1.5.1 memoise_2.0.1 broom_1.0.13
#> [61] snakecase_0.11.1 rstantools_2.6.0 coda_0.19-4.1
#> [64] gridExtra_2.3.1 nlme_3.1-169 checkmate_2.3.4
#> [67] xfun_0.60 pkgconfig_2.0.3

```

13. Distribuzioni di variabili casuali continue

Introduzione

Nel Capitolo 12 abbiamo esplorato le distribuzioni discrete come strumenti per rappresentare le credenze su fenomeni con esiti numerabili. In questo capitolo, estendiamo il framework alle **distribuzioni continue** che permettono di esprimere credenze su quantità che variano su scale numeriche continue, come i tempi, le distanze, le proporzioni, i tassi e i punteggi psicometrici. In questo contesto, la probabilità non viene assegnata a valori singoli, ma a intervalli tramite funzioni di densità.

Le distribuzioni continue rivestono, nel quadro bayesiano, un ruolo complementare a quello delle distribuzioni discrete. Esse vengono principalmente impiegate **come modelli di verosimiglianza per dati continui**, dove ogni famiglia di distribuzione riflette un diverso processo generativo: la normale descrive misure affette da errori simmetrici, l'esponenziale modella tempi di attesa, mentre la gamma è adatta a variabili positive di natura asimmetrica.

Le stesse distribuzioni, così come altre ancora, servono inoltre a formalizzare e aggiornare le credenze iniziali e finali, assumendo la funzione di **prior e posterior per parametri continui**. Ad esempio, la beta è usata per probabilità $p \in (0, 1)$, la gamma per tassi $\lambda > 0$, la normale per medie $\mu \in \mathbb{R}$, mentre la Cauchy e la t di Student sono spesso scelte come prior robusti, in grado di gestire code pesanti.

Una proprietà elegante dell'inferenza bayesiana è la **dualità discreto-continuo** espressa dalle famiglie coniugate: la distribuzione binomiale si abbina naturalmente alla beta, così come la Poisson alla gamma. Questa simmetria, già introdotta nel capitolo precedente, viene qui approfondita attraverso lo studio delle distribuzioni continue che agiscono come *prior* naturali per i parametri di modelli discreti.

Struttura del capitolo

L'esposizione procederà con una progressione graduale, dalle distribuzioni concettualmente più semplici a quelle con ruoli più specifici nell'inferenza bayesiana. Si inizierà con la **distribuzione uniforme**, che formalizza un'ignoranza locale e simmetrica all'interno di un intervallo finito. Si passerà quindi alla **distribuzione esponenziale**, fondamentale per modellare i tempi di attesa e i fenomeni privi di memoria, e alla **distribuzione normale**, pilastro del Teorema del Limite Centrale e modello di riferimento per le misurazioni affette da errori casuali simmetrici. Successivamente, si esamineranno la **distribuzione chi-quadrato** e la **distribuzione t di Student**, che derivano direttamente dalla normale e sono essenziali per l'inferenza su varianze e per la modellazione robusta con piccoli campioni. Si concluderà con le distribuzioni di massima rilevanza bayesiana: la **beta** come prior naturale per proporzioni e probabilità, la **gamma** per tassi e varianze, e la **Cauchy** come prior robusto a code pesanti, in grado di gestire valori anomali senza influenzare eccessivamente le stime.

Per ciascuna di queste distribuzioni, presenteremo la definizione matematica, l'interpretazione epistemica dei parametri, il ruolo nell'inferenza bayesiana e le applicazioni pratiche in R.

 Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- 1
- 2 – **fondamentale** per PDF
- Capitolo 8
- Capitolo 11

Questo capitolo studia in dettaglio le **distribuzioni continue** (Beta, Normale, Gamma, Esponenziale) essenziali per modellare parametri continui e costruire prior informativi. Conoscenze matematiche richieste:

- Appendice F – **fondamentale** per calcolare probabilità tramite integrazione

 Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

13.1. Distribuzione uniforme continua

13.1.1. Definizione e interpretazione epistemica

La distribuzione uniforme continua modella una situazione di **ignoranza simmetrica locale** all'interno di un intervallo chiuso $[a, b]$. In assenza di evidenze o ragioni logiche che favoriscano un particolare valore dell'intervallo rispetto a un altro, essa esprime la massima incertezza: ogni valore in $[a, b]$ ha la stessa densità di probabilità.

Definizione 13.1. Una variabile casuale X si distribuisce uniformemente sull'intervallo $[a, b]$ se la sua funzione di densità di probabilità è costante:

$$X \sim \text{Uniforme}(a, b), \quad f(x) = \frac{1}{b-a} \quad \text{per } x \in [a, b],$$

e $f(x) = 0$ al di fuori dell'intervallo.

Proprietà caratteristiche: $\mathbb{E}(X) = \frac{a+b}{2}$, $\mathbb{V}(X) = \frac{(b-a)^2}{12}$.

Interpretazione epistemica

Questa distribuzione implementa formalmente il *principio di indifferenza* (o principio di ragione insufficiente). Quando la conoscenza a priori non fornisce elementi per discriminare tra i possibili valori di un parametro all'interno di un certo dominio, si assegna credenza uguale a tutti i sottointervalli di uguale ampiezza. In questo senso, rappresenta l'analogo continuo della distribuzione uniforme discreta.

13.1.2. Ruolo nell'inferenza bayesiana

Nel quadro bayesiano, la distribuzione uniforme è tipicamente adottata come **prior “vincolato non informativo”** per parametri il cui supporto è un intervallo finito e noto. Un caso paradigmatico è l'uso della $\text{Uniforme}(0, 1)$, matematicamente equivalente alla $\text{Beta}(1, 1)$, come prior iniziale per una proporzione o una probabilità, per la quale non si possiede alcuna informazione specifica.

Limitazioni e criticità come prior

Nonostante la sua apparente neutralità, la scelta di un prior uniforme può veicolare informazioni involontarie e presenta svantaggi concettuali:

- Impone una **probabilità zero assoluta** a qualsiasi valore al di fuori dell'intervallo $[a, b]$, un'assunzione spesso troppo forte.
- La sua non-informatività **non è invariante rispetto a trasformazioni** del parametro. Un prior uniforme su un parametro θ non implica un prior uniforme su una sua trasformazione non lineare (ad esempio, $\log(\theta)$ o θ^2), introducendo quindi un'arbitrarietà nella parametrizzazione scelta.
- Per intervalli semi-infiniti $[0, \infty]$ o infiniti $(-\infty, \infty)$, la distribuzione uniforme diventa *impropria* (il suo integrale non converge a 1), sebbene in alcuni casi possa comunque condurre a posteriori propri.

Per queste ragioni, in contesti che richiedono una reale non-informatività su scale illimitate o per parametri di scala, si ricorre spesso a prior impropri non informativi (come quello di Jeffreys) o a distribuzioni a code pesanti (ad esempio, Cauchy o t di Student) che, pur essendo proprie, non escludono in modo così netto valori estremi.

13.1.3. Calcolo delle probabilità

Per una variabile $X \sim \text{Uniforme}(a, b)$, la probabilità che appartenga a un sottointervallo $[c, d] \subseteq [a, b]$ è semplicemente il rapporto tra la lunghezza del sottointervallo di interesse e la lunghezza totale dell'intervallo di definizione:

$$P(c \leq X \leq d) = (d - c) / (b - a).$$

Questa proprietà rende il calcolo estremamente intuitivo.

```
# Esempio: probabilità che uno spinner circolare (range 0-360°) si fermi in un arco tra 150 e 250°
lunghezza_totale <- 360
lunghezza_intervallo <- 250 - 150
prob <- lunghezza_intervallo / lunghezza_totale
cat("P(150 ≤ X ≤ 250) =", round(prob, 4), "\n")
#> P(150 ≤ X ≤ 250) = 0.278
```

```
# Calcolo equivalente utilizzando le funzioni di distribuzione in R
prob_r <- punif(250, min = 0, max = 360) - punif(150, min = 0, max = 360)
cat("Verifica con punif():", prob_r, "\n")
#> Verifica con punif(): 0.278
```


13.1.4. Visualizzazione

Il seguente codice R genera un grafico che illustra la densità costante della distribuzione e evidenzia l'area corrispondente alla probabilità calcolata nell'esempio.

```
# Creazione della griglia di valori e calcolo della densità
x <- seq(-50, 410, length.out = 500)
density_uniform <- dunif(x, min = 0, max = 360)
df <- data.frame(x = x, y = density_uniform)

# Definizione dell'area da evidenziare
df_area <- subset(df, x >= 150 & x <= 250)

# Grafico
ggplot(df, aes(x = x, y = y)) +
  geom_line(linewidth = 1.2) +
  geom_area(data = df_area, aes(x = x, y = y), alpha = 0.4) +
  scale_fill_qualitative() +
  labs(
    title = "Distribuzione Uniforme Continua su [0, 360]",
    subtitle = "Area evidenziata: P(150 ≤ X ≤ 250) ≈ 0.278",
    x = "Valore (x)",
    y = "Densità f(x)"
  ) +
  scale_x_continuous(breaks = seq(0, 360, by = 90))
```



Legenda visiva: La linea continua rappresenta la funzione di densità costante $f(x) = 1/360$. L'area ombreggiata sotto la curva, delimitata tra $x=150$ e $x=250$, corrisponde alla probabilità dell'evento, visualizzando in modo diretto il principio "probabilità = area".

13.2. Distribuzione esponenziale

13.2.1. Definizione e interpretazione epistemica

La distribuzione esponenziale modella il tempo di attesa fino al verificarsi di un evento, assumendo che il **tasso di occorrenza sia costante nel tempo**. Questa assunzione è cruciale e implica che la probabilità di osservare un evento non dipenda da quanto tempo si è già atteso.

Definizione 13.2. Una variabile casuale X segue una distribuzione esponenziale con parametro di tasso $\lambda > 0$ se la sua funzione di densità di probabilità è:

$$X \sim \text{Exp}(\lambda), \quad f(x) = \lambda e^{-\lambda x} \quad \text{per } x \geq 0.$$

Proprietà caratteristiche: $\mathbb{E}(X) = \frac{1}{\lambda}$, $\mathbb{V}(X) = \frac{1}{\lambda^2}$.

Interpretazione epistemica Il parametro λ rappresenta il **tasso atteso di occorrenza** (eventi per unità di tempo). Un valore elevato di λ indica eventi frequenti e attese brevi, mentre un valore piccolo corrisponde a eventi rari e attese lunghe. Il suo inverso, $\frac{1}{\lambda}$, ha un'interpretazione concreta: è il tempo medio di attesa. Questa distribuzione è dunque l'espressione probabilistica di un unico, semplice presupposto: il processo di attesa in esame è “sempre come nuovo”.

13.2.2. Proprietà di assenza di memoria

La caratteristica distintiva della distribuzione esponenziale è la *proprietà di assenza di memoria*: la probabilità che un evento si verifichi in un intervallo futuro è indipendente dal tempo già trascorso. Formalmente, per ogni $s, t > 0$:

$$P(X > s + t \mid X > s) = P(X > t).$$

Questa uguaglianza significa che, sapendo che l'evento non si è verificato fino al tempo s , la distribuzione del tempo di attesa aggiuntivo t è identica alla distribuzione del tempo di attesa dall'inizio. Se si aspetta un autobus la cui frequenza segue un processo esponenziale, la probabilità di dover aspettare altri 5 minuti è sempre la stessa, indipendentemente dal fatto che si sia già atteso 1 minuto o 10 minuti. L'esponenziale è l'unica distribuzione continua con questa proprietà, che rende appropriato il suo utilizzo per modellare durate di eventi senza “usura” o “invecchiamento”.

13.2.3. Ruolo nell'inferenza bayesiana

Nell'inferenza bayesiana, la distribuzione esponenziale riveste un duplice ruolo, fondamentale per modellare processi psicologici o comportamentali caratterizzati da **attese, tempi di risposta o intervalli tra eventi**.

1. **Come funzione di verosimiglianza:** è il modello naturale per dati continui e positivi che rappresentano durate, in contesti dove si assume un **tasso costante di occorrenza** (proprietà di assenza di memoria). Per esempio:
 - modellare il tempo che intercorre tra uno stimolo (es., un suono) e la risposta motoria di un partecipante in un compito di tempi di reazione semplice, dove il processo cognitivo sottostante non cambia nel tempo.

- modellare la durata di un episodio di concentrazione focalizzata prima di un'interruzione (es., distrazione da notifica), assumendo che la probabilità di interrompersi sia costante in ogni istante.

2. **Nel contesto dell'aggiornamento bayesiano:** formalmente, la distribuzione esponenziale è un caso particolare della distribuzione Gamma, con $\exp(\lambda) = \text{Gamma}(1, 1/\lambda)$ (nella comune parametrizzazione a tasso). Di conseguenza, la **distribuzione Gamma funge da prior coniugato** per il parametro di tasso λ di un modello di verosimiglianza esponenziale.

Questo permette un aggiornamento bayesiano analitico e intuitivo. Supponiamo di voler inferire il **tasso latente** λ di un processo psicologico (es., il tasso con cui emergono pensieri intrusivi). Si specifica una credenza a priori come $\lambda \sim \text{Gamma}(\alpha_0, \beta_0)$, dove:

- α_0 (parametro di forma) può essere interpretato come un **numero pseudo-osservato di eventi attesi**.
- β_0 (parametro di velocità/inverso scala) può essere interpretato come la **durata pseudo-osservata totale** di riferimento.

Dopo aver osservato n intervalli di tempo indipendenti $x_1, \dots, x_N$ tra gli eventi (con $x_i \sim \exp(\lambda)$), la distribuzione a posteriori per λ è ancora una Gamma, i cui parametri si aggiornano semplicemente aggiungendo le osservazioni alle pseudo-osservazioni del prior:

$$\lambda \mid \mathbf{x} \sim \text{Gamma}(\alpha_n, \beta_n),$$

$$\alpha_n = \alpha_0 + n, \quad \beta_n = \beta_0 + \sum_{i=1}^n x_i.$$

Interpretazione epistemica: il parametro di forma α accumula il *conteggio* degli eventi (reali e pseudo-osservati), mentre il parametro di velocità β accumula il *tempo totale* osservato (reale e pseudo-osservato). La media a posteriori $E[\lambda \mid x] = \alpha_n/\beta$ è dunque una media pesata tra il tasso medio a priori (α_0/β_0) e il tasso osservato nei dati ($n/\sum x_i$).

13.2.4. Esempio: tempi di attesa

```
# Tempo medio di attesa: 4 giorni (lambda = 0.25)
lambda <- 0.25


# Probabilità di attesa 1.5 giorni
cat("P(X 1.5) =", round(pexp(1.5, rate = lambda), 3), "\n")
#> P(X 1.5) = 0.313

# Probabilità di attesa tra 1 e 6 giorni
cat("P(1 X 6) =", round(pexp(6, rate = lambda) - pexp(1, rate = lambda), 3), "\n")
#> P(1 X 6) = 0.556

x <- seq(0, 20, by = 0.1)
pdf <- dexp(x, rate = lambda)

ggplot(data.frame(x = x, y = pdf), aes(x = x, y = y)) +
  geom_line(linewidth = 1.2) +
  geom_area(
```

```
data = subset(data.frame(x, y = pdf), x >= 1 & x <= 6),
alpha = 0.5
) +
scale_fill_qualitative() +
labs(
  title = "Distribuzione esponenziale (λ = 0.25)",
  subtitle = "Area evidenziata: P(1 ≤ X ≤ 6)",
  x = "Tempo di attesa (giorni)", y = "Densità"
)
```



13.3. Distribuzione normale

13.3.1. Definizione e interpretazione epistemica

La distribuzione normale (o gaussiana) emerge naturalmente come risultato della somma di molti effetti casuali indipendenti, un principio formalizzato dal Teorema del Limite Centrale. Questa proprietà la rende centrale nella modellazione di fenomeni psicologici influenzati da molteplici fattori. È importante sottolineare che la distribuzione normale non va interpretata come una descrizione letterale della realtà, bensì come un modello ideale che emerge quando molte fonti di variabilità indipendenti contribuiscono in modo additivo. In questo senso, la normale rappresenta spesso una **approssimazione epistemicamente giustificata**, più che una legge naturale dei fenomeni.

Definizione 13.3. Una variabile casuale Y segue una distribuzione normale con media μ e deviazione standard σ se:

$$Y \sim \mathcal{N}(\mu, \sigma^2), \quad f(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right).$$

Proprietà caratteristiche: $\mathbb{E}(Y) = \mu, \mathbb{V}(Y) = \sigma^2$.

Interpretazione epistemica dei parametri:

- il parametro μ rappresenta il valore atteso, costituendo il “centro di massa” attorno al quale si concentrano le nostre credenze;
- il parametro σ quantifica il grado di incertezza associato a tali credenze, indicando quanto riteniamo plausibile che i valori veri possano discostarsi dal valore centrale μ .

13.3.2. Ruolo nell’inferenza bayesiana

La distribuzione normale occupa una posizione centrale nell’inferenza bayesiana e si rivela utile in molti contesti applicativi. In qualità di verosimiglianza, viene comunemente impiegata per modellare una vasta gamma di fenomeni continui, quali gli errori di misurazione, i punteggi psicometrici e le variabili di natura biologica. Quando viene utilizzata come distribuzione a priori per i parametri di posizione, nella forma $\mu \sim \mathcal{N}(\mu_0, \sigma_0^2)$, essa permette di esprimere formalmente le credenze iniziali riguardo alla posizione del parametro di interesse. Un’ulteriore proprietà che ne accresce l’utilità pratica è la coniugazione: se la varianza σ^2 è nota, la distribuzione normale si configura come *prior* coniugata per il parametro μ , garantendo che la distribuzione a posteriori appartenga alla stessa famiglia distributiva.

Un ulteriore motivo della centralità della distribuzione normale nell’inferenza bayesiana è che essa emerge frequentemente come **approssimazione della distribuzione a posteriori**, anche quando il modello di partenza non è normale. In virtù del Teorema del Limite Centrale e delle approssimazioni di tipo laplaciano, posteriori complesse tendono ad assumere una forma approssimativamente normale in prossimità del loro massimo, soprattutto in presenza di campioni numerosi.

Applicazioni in psicologia

Processi modellabili con la Normale

La distribuzione normale trova applicazione in psicologia principalmente come modello approssimato per **misure sintetiche** o quando si analizza la **variabilità intorno a una tendenza centrale**.

- **Punteggi standardizzati:** distribuzione dei punteggi in test cognitivi (es., QI, dove $\mu = 100, \sigma = 15$), inventari di personalità o scale di attitudine standardizzate (per es., SAT, GRE).
- **Errori di misura:** variazione casuale nelle risposte di un individuo a uno strumento di misura ripetuto nelle stesse condizioni (per es., punteggi di ansia di stato).
- **Medie di campioni:** per il Teorema del Limite Centrale, la media di un campione sufficientemente grande di osservazioni (anche non normali) tende a distribuirsi normalmente. Questo è fondamentale per l’inferenza statistica.
- **Prior su effetti continui:** rappresenta l’incertezza a priori su un parametro che può assumere qualsiasi valore reale (per es., la differenza media tra gruppi in un trattamento).

Esempio concreto: in un campione rappresentativo, i punteggi totali dell’inventario di depressione BDI-II possono mostrare una distribuzione approssimativamente normale, con $\mu \approx 12$ e $\sigma \approx 10$.

Uso come prior nell’inferenza bayesiana

La normale è il **prior coniugato** naturale per la media μ di un modello di verosimiglianza normale quando la varianza σ^2 è nota.

- $\mathcal{N}(0, 10^2)$: un **prior debolmente informativo** per un effetto standardizzato (es., dimensione dell’effetto d di Cohen), suggerendo che valori tra -20 e +20 sono plausibili a priori.

- $\mathcal{N}(\mu_0, \sigma_0^2)$: un **prior informativo** che concentra la credenza attorno a un valore teorico μ_0 con un grado di certezza $\propto 1/\sigma_0^2$. Ad esempio, $\mathcal{N}(5, 2^2)$ per una differenza attesa piccola e positiva.

Attenzione critica alle assunzioni L'applicazione acritica della normale è un errore comune. Molti fenomeni psicologici intrinseci hanno distribuzioni **non normali**:

- **Tempi di reazione** e durate: sono tipicamente **asimmetrici positivamente** e meglio modellati da distribuzioni log-normali o Gamma.
- **Conteggi** (per es., numero di errori, risposte corrette): seguono distribuzioni discrete come Poisson o Binomiale Negativa.
- **Punteggi di scale a risposta limitata** (per es., Likert a 5 punti): sono variabili ordinali e limitate, per cui modelli come la regressione ordinata o Beta sono più appropriati.

Raccomandazione pratica: Prima di modellare una variabile psicologica con una normale, verificare sempre la sua distribuzione empirica e considerare trasformazioni (es., logaritmica) o famiglie di distribuzioni alternative più aderenti alla natura del dato.

⚠ Quando la normale NON è appropriata

In psicologia, numerose variabili osservate violano l'assunzione di normalità:

- **Tempi di reazione:** sono sempre positivi e presentano una tipica asimmetria positiva → modelli come Gamma o Log-normale sono spesso più appropriati.
- **Scale Likert con pochi item:** sono variabili discrete e possono mostrare effetti di *floor* o *ceiling*.
- **Conteggi di sintomi:** sono discreto e spesso caratterizzati da un eccesso di zeri → si adattano meglio a modelli come Poisson o a varianti Zero-inflated.
- **Proporzioni o punteggi standardizzati:** vincolati nell'intervallo $[0, 1]$ → la distribuzione Beta offre una modellazione più naturale.

La distribuzione normale rimane una scelta appropriata per **punteggi compositi** derivati da scale psicometriche ben validate (ad esempio, QI, fattori del NEO-PI-R) e come approssimazione robusta quando il Teorema del Limite Centrale garantisce che la media campionaria si distribuisca approssimativamente in modo normale.

13.3.3. La regola 68-95-99.7

La distribuzione normale possiede una proprietà universale che rimane invariata indipendentemente dai valori specifici dei parametri μ e σ . In particolare, si può affermare che approssimativamente il 68.3% della massa probabilistica è concentrato entro un intervallo di più o meno una deviazione standard dalla media, percentuale che sale al 95.4% quando si considera un intervallo di due deviazioni standard e raggiunge il 99.7% per uno scarto di tre deviazioni standard.

Questa caratteristica fondamentale conferisce alla deviazione standard il ruolo di unità di misura naturale per quantificare la “distanza dalla media” in termini probabilistici, trasformandola da semplice misura di dispersione a strumento per l'interpretazione probabilistica della distribuzione.

Questa concentrazione rapida della massa probabilistica attorno alla media riflette la presenza di **code leggere**, una caratteristica che rende la distribuzione normale sensibile a osservazioni estreme.

Nei contesti in cui tali osservazioni sono plausibili o frequenti, può risultare opportuno ricorrere a distribuzioni alternative con code più pesanti, come la t di Student o la Cauchy.

13.3.4. Il Teorema del Limite Centrale in azione: una simulazione psicologica

Il Teorema del Limite Centrale (TLC) spiega l'onnipresenza della distribuzione normale in statistica: la somma (o media) di molte variabili casuali indipendenti e identicamente distribuite tende a una distribuzione normale, **indipendentemente dalla forma della distribuzione originaria**. Questo fenomeno non è solo teorico ma emerge costantemente in processi complessi.

Visualizziamo questo principio attraverso una metafora psicologica: **il processo decisionale come somma di piccole influenze**. Immaginiamo che un giudizio finale (es., la valutazione di un prodotto) sia il risultato della somma di numerose micro-considerazioni ($n = 16$), ciascuna delle quali può spingere leggermente l'opinione in una direzione positiva o negativa. Ogni micro-considerazione è modellata come una variabile uniforme tra -1 e $+1$, rappresentando un piccolo "passo" casuale nell'atteggiamento.

```
set.seed(123) # Per riproducibilità
n_soggetti <- 1000 # Numero di giudizi simulati
n_influenze <- 16 # Numero di micro-considerazioni per giudizio

# Simula le micro-influenze per ogni soggetto
micro_influenze <- matrix(
  runif(n_soggetti * n_influenze, min = -1, max = 1),
  ncol = n_influenze
)

# Il giudizio finale è la somma di tutte le micro-influenze
giudizio_finale <- rowSums(micro_influenze)

# Visualizzazione
df_giudizi <- data.frame(Giudizio = giudizio_finale)

ggplot(df_giudizi, aes(x = Giudizio)) +
  geom_histogram(
    aes(y = after_stat(density)),
    bins = 30,
    alpha = 0.6
  ) +
  # Sovrapponi la curva normale teorica
  stat_function(
    fun = dnorm,
    args = list(
      mean = mean(giudizio_finale),
      sd = sd(giudizio_finale)
    ),
    linewidth = 1.2
  ) +
  scale_fill_qualitative() +
  labs(
    title = "Il Teorema del Limite Centrale nella Cognizione",
```


```

subtitle = sprintf(
  "Distribuzione del giudizio finale (somma di %d influenze uniformi)",
  n_influenze
),
x = "Valore del giudizio finale",
y = "Densità"
)

```

Il Teorema del Limite Centrale nella Cognizione

Distribuzione del giudizio finale (somma di 16 influenze uniformi)



Interpretazione del risultato: Nonostante ogni singola “micro-influenza” segua una distribuzione **uniforme** (tutti i suoi valori sono ugualmente probabili), la distribuzione del **giudizio finale** (la loro somma) assume una forma a campana caratteristica della **distribuzione normale**. Questa simulazione mostra empiricamente come processi complessi — come la formazione di un’opinione — possano produrre distribuzioni normali anche quando i loro componenti elementari non lo sono, fornendo una giustificazione fondamentale per l’uso ubiquitario della normale nella modellazione psicologica e statistica.

13.3.5. Visualizzazione degli intervalli di credibilità (o probabilità)

Un’altra proprietà cruciale della distribuzione normale è che una proporzione precisa della sua massa di probabilità è contenuta entro intervalli definiti in termini di deviazioni standard ($\pm\sigma$) dalla media (μ). L’intervallo $\mu \pm 1.96\sigma$ contiene esattamente il **95%** della probabilità, rendendolo l’intervallo di credibilità (o confidenza) standard per questa distribuzione.

Il seguente grafico illustra questa proprietà per una distribuzione $\mathcal{N}(\mu = 100, \sigma = 15)$, tipica dei punteggi di QI.

```

mu <- 100 # Media
sigma <- 15 # Deviazione standard

# Crea una sequenza di valori x attorno alla media
x <- seq(mu - 4*sigma, mu + 4*sigma, length.out = 1000)
# Calcola la densità di probabilità normale

```


```
pdf <- dnorm(x, mean = mu, sd = sigma)

df <- data.frame(x = x, densita = pdf)

# Definisci i limiti dell'intervallo al 95%
lim_inf <- mu - 1.96 * sigma
lim_sup <- mu + 1.96 * sigma

# Crea il dataframe per l'area evidenziata (intervallo al 95%)
df_area <- subset(df, x >= lim_inf & x <= lim_sup)

ggplot(df, aes(x = x, y = densita)) +
  # Traccia la linea della curva normale
  geom_line(linewidth = 1) +
  # Evidenzia l'area dell'intervallo al 95%
  geom_area(data = df_area, aes(x = x, y = densita), alpha = 0.7) +
  # Aggiunge linee verticali per i limiti dell'intervallo
  geom_vline(xintercept = c(lim_inf, lim_sup), linetype = "dashed") +
  # Aggiunge etichette testuali
  annotate("text", x = mu, y = 0.005, label = "95%", size = 5, fontface = "bold") +
  annotate("text", x = lim_inf, y = 0.002, label = round(lim_inf,1), hjust = 1.1) +
  annotate("text", x = lim_sup, y = 0.002, label = round(lim_sup,1), hjust = -0.1) +
  scale_fill_qualitative() +
  labs(
    title = "Distribuzione Normale e\nIntervallo di Credibilità al 95%",
    subtitle = sprintf("N( = %.0f, = %.0f)", mu, sigma),
    x = "Valore (es., punteggio QI)",
    y = "Densità di probabilità f(x)"
  )
)
```



Interpretazione del grafico: la curva nera rappresenta la densità della normale. L'area verde evidenziata mostra la porzione centrale della distribuzione che contiene il 95% della probabilità totale.

I trattini verticali verdi indicano i limiti esatti di questo intervallo ($\mu \pm 1.96\sigma = 100 \pm 29.4$), che qui vanno da circa 70.6 a 129.4. Questa visualizzazione rende immediatamente evidente come la distribuzione normale concentri la maggior parte della sua probabilità in una regione simmetrica attorno alla media, una proprietà fondamentale per la costruzione di intervalli di credibilità in inferenza bayesiana e di confidenza in statistica frequentista.

13.4. Distribuzione chi-quadrato

13.4.1. Definizione e interpretazione epistemica

La distribuzione chi-quadrato emerge naturalmente dalla somma dei quadrati di variabili normali standard indipendenti. Essa quantifica quindi la **magnitudine complessiva delle deviazioni** rispetto a un valore centrale, indipendentemente dal segno.

Definizione 13.4. Se $Z_1, \dots, Z_k$ sono variabili casuali i.i.d. con distribuzione $\mathcal{N}(0, 1)$, allora:

$$X = Z_1^2 + Z_2^2 + \dots + Z_k^2 \sim \chi_k^2,$$

dove k rappresenta il numero di *gradi di libertà*.

Proprietà: $\mathbb{E}(X) = k, \mathbb{V}(X) = 2k$.

Interpretazione epistemica La distribuzione chi-quadrato misura la **dispersione quadratica** di un insieme di variabili normali. Elevando al quadrato le deviazioni si elimina l'informazione sul segno e si attribuisce maggiore peso agli scostamenti più ampi. I gradi di libertà k indicano quante fonti indipendenti di variabilità contribuiscono alla dispersione complessiva.

13.4.2. Ruolo nell'inferenza bayesiana

La distribuzione chi-quadrato è un caso particolare della distribuzione gamma ed è formalmente equivalente a:

$$\chi_k^2 = \text{Gamma}\left(\frac{k}{2}, \frac{1}{2}\right).$$

Nel contesto dell'inferenza bayesiana, essa riveste un ruolo fondamentale nella modellazione dell'incertezza associata alla **variabilità dei dati**. In particolare, la somma dei quadrati delle deviazioni standardizzate di osservazioni normali segue una distribuzione chi-quadrato, fornendo una base teorica per la distribuzione della varianza campionaria.

La trasformazione inversa di questa distribuzione, nota come **chi-quadrato inversa**, costituisce la prior coniugata per il parametro di varianza σ^2 nel modello normale con media nota. In molte formulazioni bayesiane si preferisce modellare la **precisione** $\tau = 1/\sigma^2$, grandezza positiva per la quale la famiglia gamma (e quindi la chi-quadrato) risulta particolarmente naturale.


La distribuzione chi-quadrato compare inoltre implicitamente in modelli gerarchici e multilevel, dove consente di rappresentare formalmente l'incertezza sulla scala della variabilità.

13.4.3. Visualizzazione

```
x <- seq(0, 40, by = 0.1)
nus <- c(2, 4, 8, 16)

data <- do.call(rbind, lapply(nus, function(nu) {
  data.frame(x = x, f_x = dchisq(x, df = nu), nu = as.factor(nu))
}))

ggplot(data, aes(x = x, y = f_x, color = nu)) +
  geom_line(linewidth = 1) +
  scale_fill_qualitative() +
  labs(
    title = "Distribuzione chi-quadrato",
    subtitle = "La distribuzione diventa più simmetrica all'aumentare dei gradi di libertà",
    x = "x", y = "f(x)", color = " "
  )
)
```



(Nota: al crescere dei gradi di libertà, la distribuzione chi-quadrato tende ad assumere una forma sempre più simmetrica, avvicinandosi a una distribuzione normale.)

13.5. Distribuzione t di Student

13.5.1. Definizione e interpretazione epistemica

La distribuzione t di Student emerge quando una variabile aleatoria normale viene standardizzata utilizzando una stima **incerta** della sua varianza, tipicamente derivata da un campione finito. In questo senso, la distribuzione t può essere interpretata come una distribuzione normale la cui scala non è nota con certezza.

Definizione 13.5. Date due variabili aleatorie indipendenti $Z \sim \mathcal{N}(0, 1)$ e $W \sim \chi^2_\nu$, la variabile risultante dalla trasformazione:

$$T = \frac{Z}{\sqrt{W/\nu}} \sim t_\nu$$

segue una distribuzione t di Student con ν gradi di libertà.

Proprietà: $\mathbb{E}(T) = 0$ per $\nu > 1$; $\mathbb{V}(T) = \frac{\nu}{\nu-2}$ per $\nu > 2$.

Interpretazione epistemica La distribuzione t di Student presenta **code più pesanti rispetto alla normale**, riflettendo l'incertezza aggiuntiva associata alla stima della varianza. I gradi di libertà ν possono essere interpretati come una misura indiretta della quantità di informazione disponibile sulla scala del fenomeno: per valori piccoli di ν l'incertezza è elevata, mentre all'aumentare di ν la distribuzione t converge progressivamente alla distribuzione normale.

13.5.2. Ruolo nell'inferenza bayesiana

La distribuzione t di Student riveste un ruolo di particolare rilievo nell'inferenza bayesiana per almeno tre motivi fondamentali. In primo luogo, essa funge da **prior robusta per parametri di posizione**. L'uso di una distribuzione $t_\nu(\mu_0, \sigma_0)$ come prior per una media assegna una maggiore plausibilità ai valori estremi rispetto a una distribuzione normale, rendendo il modello meno sensibile a osservazioni anomale o inattese.

In secondo luogo, la distribuzione t emerge naturalmente come **distribuzione predittiva** quando si tiene conto dell'incertezza congiunta sia sulla media sia sulla varianza in un modello normale. In tali condizioni, la distribuzione predittiva marginale per nuove osservazioni assume una forma t di Student, a differenza del caso in cui la varianza sia nota, dove la predittiva rimane normale.

Infine, la distribuzione t si presta efficacemente come **prior debolmente informativa**. Specificando un numero ridotto di gradi di libertà, come $\nu = 3$, o nel caso limite $\nu = 1$, che corrisponde alla distribuzione di Cauchy, è possibile costruire prior che esercitano una regolarizzazione moderata senza dominare l'evidenza fornita dai dati, anche in presenza di campioni di piccole dimensioni.

13.5.3. Confronto con la normale

```
x <- seq(-4, 4, length.out = 1000)
gradi_liberta <- c(1, 3, 10)


dati_plot <- data.frame(
  x = rep(x, length(gradi_liberta) + 1),
  densita = c(
    dnorm(x),
    dt(x, df = gradi_liberta[1]),
    dt(x, df = gradi_liberta[2]),
    dt(x, df = gradi_liberta[3])
  ),
  distribuzione = rep(
    c("Normale", paste0("t ( df = ", gradi_liberta, ")")),
    each = length(x)
  )
)
```

```

)
)

ggplot(dati_plot, aes(x = x, y = densita, color = distribuzione)) +
  geom_line(linewidth = 1) +
  scale_fill_qualitative() +
  labs(
    title = "Confronto t di Student e Normale",
    subtitle = "Code più pesanti per v piccoli; convergenza alla normale per v → ∞",
    x = "Valore", y = "Densità", color = "Distribuzione"
  )

```



Il grafico mostra chiaramente come, per valori piccoli di ν , la distribuzione t presenti code più pesanti rispetto alla normale, mentre al crescere dei gradi di libertà le due distribuzioni diventano praticamente indistinguibili.

13.6. Distribuzione di Cauchy

13.6.1. Definizione e interpretazione epistemica

La distribuzione di Cauchy costituisce un caso particolare della distribuzione t di Student, corrispondente a un singolo grado di libertà (t_1). La sua caratteristica distintiva è la presenza di **code estremamente pesanti**, che decadono molto più lentamente rispetto a quelle della distribuzione normale.

Definizione 13.6. Una variabile casuale X segue una distribuzione di Cauchy con parametro di posizione α e parametro di scala $\beta > 0$ se la sua funzione di densità è data da:

$$X \sim \text{Cauchy}(\alpha, \beta), \quad f(x) = \frac{1}{\pi\beta \left[1 + \left(\frac{x-\alpha}{\beta}\right)^2\right]}.$$

Proprietà distintive A differenza di molte distribuzioni parametriche comuni, la distribuzione di Cauchy **non possiede momenti primi e secondi definiti**. Sebbene il parametro α rappresenti una posizione centrale (mediana e moda), gli integrali che definiscono la media e la varianza non convergono, a causa del decadimento estremamente lento delle code.

Interpretazione epistemica La distribuzione di Cauchy esprime un grado elevato di incertezza, assegnando una plausibilità non trascurabile anche a valori molto distanti dal parametro di posizione. Essa risulta particolarmente appropriata nei contesti inferenziali in cui non si intende escludere a priori la possibilità di osservare valori estremi, adottando un atteggiamento epistemico di massima prudenza nei confronti delle potenziali osservazioni anomale.

13.6.2. Ruolo nell'inferenza bayesiana

La distribuzione di Cauchy trova ampia applicazione come **prior debolmente informativa e robusta** nell'inferenza bayesiana. Viene frequentemente utilizzata come prior per parametri di posizione: ad esempio, una $\text{Cauchy}(0, 2.5)$ è una scelta comune per i coefficienti di regressione standardizzati, poiché consente valori estremi pur mantenendo una concentrazione significativa di massa probabilistica attorno allo zero.


Per i parametri di scala, la **half-Cauchy**, ottenuta troncando la distribuzione ai valori positivi, è spesso raccomandata come prior per le deviazioni standard nei modelli gerarchici. In questi contesti, la Cauchy svolge un ruolo cruciale: non impone una scala caratteristica rigida, lasciando che siano i dati a informare l'ampiezza della variabilità, pur esercitando una regolarizzazione debole.

13.6.3. Confronto con altre distribuzioni

```
x <- seq(-5, 5, length.out = 500)

df <- data.frame(
  x = rep(x, 3),
  density = c(dnorm(x), dt(x, df = 3), dcauchy(x)),
  distribuzione = rep(c("Normale(0,1)", "t ( = 3)", "Cauchy(0,1)"), each = length(x))
)

ggplot(df, aes(x = x, y = density, color = distribuzione)) +
  geom_line(linewidth = 1) +
  scale_fill_qualitative() +
  labs(
    title = "Confronto delle code",
    subtitle = "La Cauchy ha le code più pesanti, seguita dalla t",
    x = "x", y = "Densità"
  )
```



Il confronto evidenzia come la distribuzione di Cauchy presenti le code più pesanti, seguita dalla distribuzione t di Student, mentre la normale concentra la massa probabilistica in modo più marcato attorno al valore centrale.

13.6.4. Chiusura concettuale

Nel complesso, la distribuzione di Cauchy rappresenta il punto estremo di un continuum che va dalla distribuzione normale alla t di Student: al crescere dell'incertezza sulla scala del fenomeno, il modello probabilistico adotta code sempre più pesanti, riflettendo un atteggiamento epistemico progressivamente più prudente. In questo senso, la Cauchy non costituisce un'anomalia, ma una scelta coerente quando si desidera minimizzare le assunzioni a priori sulla variabilità dei dati.

13.7. Distribuzione Beta

13.7.1. Definizione e interpretazione epistemica

La distribuzione Beta è la scelta naturale per rappresentare credenze su proporzioni o probabilità, ovvero quantità vincolate all'intervallo $(0, 1)$. È importante sottolineare che la distribuzione Beta non descrive la variabilità dei dati osservati, bensì **lo stato di conoscenza (o di incertezza)** riguardo al valore del parametro p , che rimane non osservabile.

Definizione 13.7. Una variabile casuale θ segue una distribuzione Beta con parametri $\alpha > 0$ e $\beta > 0$ se:

$$\theta \sim \text{Beta}(\alpha, \beta), \quad f(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)},$$

dove $B(\alpha, \beta)$ è la funzione beta di Eulero.

Proprietà:

- $\mathbb{E}(\theta) = \frac{\alpha}{\alpha+\beta}$;

- $V(\theta) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$;
- Moda (per $\alpha, \beta > 1$): $\frac{\alpha-1}{\alpha+\beta-2}$.

Interpretazione epistemica dei parametri: i parametri α e β della distribuzione Beta ammettono un'interpretazione epistemica particolarmente intuitiva in termini di "pseudo-osservazioni". In questa prospettiva, $\alpha - 1$ rappresenta il numero ipotetico di successi precedentemente osservati, mentre $\beta - 1$ corrisponde al numero analogo di insuccessi. Questa caratteristica consente di incorporare in modo trasparente l'informazione a priori nel modello. Il caso particolare $\alpha = \beta = 1$ assume un significato speciale, in quanto produce una distribuzione uniforme che rappresenta formalmente uno stato di massima ignoranza riguardo al parametro di interesse.

In questa interpretazione, la quantità $\alpha + \beta$ può essere vista come la **dimensione di un campione virtuale** che quantifica la forza informativa della prior. Valori piccoli di $\alpha + \beta$ corrispondono a credenze deboli e facilmente aggiornabili dai dati, mentre valori grandi indicano credenze più rigide che richiedono un'evidenza empirica consistente per essere modificate.

13.7.2. Ruolo nell'inferenza bayesiana

La Beta è la **prior coniugata** per il parametro p della distribuzione binomiale:

Prior: $p \sim \text{Beta}(\alpha, \beta)$, Dati: k successi su n prove.

Posterior: $p \mid k \sim \text{Beta}(\alpha + k, \beta + n - k)$.

Questa proprietà rende l'aggiornamento bayesiano analiticamente trattabile: i parametri della distribuzione a posteriori si ottengono semplicemente sommando i conteggi osservati agli pseudo-conteggi della distribuzione a priori.

La media della distribuzione a posteriori può essere interpretata come una media ponderata tra la proporzione implicita nella prior e la proporzione osservata nei dati, con pesi determinati rispettivamente dalla forza della prior e dalla dimensione del campione osservato. In questo senso, l'aggiornamento bayesiano realizza un compromesso quantitativo tra credenze iniziali ed evidenza empirica.

La coniugazione tra distribuzione Beta e modello binomiale non rappresenta soltanto una semplificazione computazionale, ma riflette una profonda **coerenza epistemica**: le informazioni a priori e quelle fornite dai dati sono espresse nella stessa unità concettuale, ovvero conteggi di successi e insuccessi, rendendo l'aggiornamento trasparente e interpretabile.

☒ Quando la usi in psicologia?

Situazioni tipiche:

- **Prior per proporzioni/probabilità** $p \in (0,1)$:
 - Tasso di risposta corretta
 - Probabilità di aderenza terapeutica
 - Prevalenza di un disturbo
- **Prior per correlazioni** (dopo trasformazione Fisher z)
- **Modellazione diretta** di variabili vincolate a $[0,1]$

Esempio pratico: Vuoi stimare la probabilità p che un trattamento funzioni. Prima dei dati, usi $\text{Beta}(5,5)$ come prior (credenza verso $p \approx 0.5$ con moderata incertezza).

Interpretazione intuitiva dei parametri:

- α = “pseudo-successi” già osservati
- β = “pseudo-insuccessi” già osservati
- Es: Beta(20,10) $\rightarrow$ come se avessi già visto 20 successi e 10 fallimenti

Casi speciali:

- Beta(1,1) = Uniforme(0,1): totale ignoranza
- Beta(0.5,0.5) = Jeffreys prior: prior non informativo che è invariante per trasformazioni

Coniugazione con Binomiale: Se prior è Beta(α, β) e osservi k successi su n , posterior è Beta($\alpha+k, \beta+n-k$) $\rightarrow$ aggiornamento additivo!

13.7.3. Flessibilità della forma

La distribuzione beta può assumere forme molto diverse a seconda dei parametri:


```
x <- seq(0, 1, length.out = 200)
params <- list(
  c(0.5, 0.5), c(1, 1), c(2, 2), c(2, 5), c(5, 2)
)

df <- do.call(rbind, lapply(params, function(p) {
  data.frame(
    x = x,
    density = dbeta(x, p[1], p[2]),
    label = paste0(" = ", p[1], ", ", " = ", p[2])
  )
}))

ggplot(df, aes(x = x, y = density, color = label)) +
  geom_line(linewidth = 1) +
  scale_fill_qualitative() +
  labs(
    title = "Flessibilità della distribuzione Beta",
    subtitle = "Diverse combinazioni di parametri producono forme radicalmente diverse",
    x = " ", y = "f()"
  )
  theme(legend.title = element_blank())
#> <theme> List of 1
#> $ legend.title: <ggplot2::element_blank>
#> @ complete: logi FALSE
#> @ validate: logi TRUE
```


Flessibilità della distribuzione Beta

Diverse combinazioni di parametri producono forme radicalmente diverse



13.7.4. Esempio: aggiornamento bayesiano

```
# Prior: Beta(2, 2) - credenza iniziale moderatamente incerta
alpha_prior <- 2
beta_prior <- 2

# Dati osservati: 7 successi su 10 prove
successi <- 7
prove <- 10

# Posterior: Beta(2+7, 2+3) = Beta(9, 5)
alpha_post <- alpha_prior + successi
beta_post <- beta_prior + (prove - successi)


# Visualizzazione
x <- seq(0, 1, length.out = 200)
df <- data.frame(
  x = rep(x, 2),
  density = c(dbeta(x, alpha_prior, beta_prior), dbeta(x, alpha_post, beta_post)),
  tipo = rep(c("Prior Beta(2,2)", "Posterior Beta(9,5)"), each = length(x))
)

ggplot(df, aes(x = x, y = density, color = tipo)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(
    title = "Aggiornamento Bayesiano: Beta-Binomiale",
    subtitle = "7 successi su 10 prove aggiornano la prior",
    x = "p", y = "Densità"
  )
)
```

```
cat("Media prior:", round(alpha_prior/(alpha_prior + beta_prior), 3), "\n")
#> Media prior: 0.5
cat("Media posterior:", round(alpha_post/(alpha_post + beta_post), 3), "\n")
#> Media posterior: 0.643
```

Aggiornamento Bayesiano: Beta-Binomiale

7 successi su 10 prove aggiornano la prior



13.7.5. Distribuzione gamma

13.7.5.1. Definizione e interpretazione epistemica

La distribuzione gamma rappresenta una famiglia di distribuzioni per variabili casuali strettamente positive, che svolge un ruolo fondamentale come distribuzione a priori coniugata per il parametro di tasso nella distribuzione di Poisson. Dal punto di vista epistemico, la distribuzione gamma rappresenta l'analogo continuo della distribuzione beta: mentre la beta modella credenze su proporzioni, la gamma modella credenze su **tassi di occorrenza** o quantità positive associate a conteggi di eventi.

Definizione 13.8. Una variabile casuale X segue una distribuzione gamma con parametro di forma $\alpha > 0$ e parametro di tasso $\beta > 0$ quando la sua funzione di densità è data da:

$$X \sim \text{Gamma}(\alpha, \beta), \quad f(x) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)} \quad \text{per } x > 0$$

Proprietà fondamentali: $\mathbb{E}(X) = \frac{\alpha}{\beta}$, $\mathbb{V}(X) = \frac{\alpha}{\beta^2}$.

Interpretazione epistemica dei parametri: Il parametro di forma α determina la configurazione morfologica della distribuzione: quando $\alpha < 1$ la densità risulta monotona decrescente, per $\alpha = 1$ si ottiene la distribuzione esponenziale, mentre per $\alpha > 1$ la distribuzione presenta una forma unimodale. Il parametro di tasso β governa invece la scala della distribuzione, per cui valori più elevati tendono a concentrare la massa probabilistica in prossimità dello zero.

In un'interpretazione bayesiana, i parametri α e β possono essere letti come **pseudo-conteggi**: α rappresenta un numero equivalente di eventi precedentemente osservati, mentre β corrisponde a una quantità equivalente di esposizione (tempo, area, numero di unità osservate). Questa lettura rende l'aggiornamento bayesiano particolarmente trasparente.

13.7.5.2. Ruolo nell'inferenza bayesiana

La distribuzione gamma riveste un ruolo di primo piano nell'inferenza bayesiana grazie alle sue molteplici applicazioni. In primo luogo, funge da distribuzione a priori coniugata per il parametro λ nel modello di Poisson:

$$\text{Prior: } \lambda \sim \text{Gamma}(\alpha, \beta), \quad \text{Dati: } y_1, \dots, y_n \sim \text{Poisson}(\lambda)$$

$$\text{Posterior: } \lambda \mid \mathbf{y} \sim \text{Gamma}\left(\alpha + \sum y_i, \beta + n\right)$$

L'aggiornamento bayesiano assume quindi una forma estremamente intuitiva: gli eventi osservati si sommano agli eventi "attesi" a priori, mentre l'esposizione empirica si aggiunge a quella implicita nella prior. La media della distribuzione a posteriori, $\mathbb{E}(\lambda \mid \mathbf{y}) = \frac{\alpha + \sum y_i}{\beta + n}$, rappresenta così un compromesso ponderato tra credenze iniziali ed evidenza empirica.

In secondo luogo, la distribuzione gamma è comunemente utilizzata come distribuzione a priori per il parametro di precisione (definito come l'inverso della varianza) nei modelli normali. Infine, essa fornisce un modello flessibile per la rappresentazione dei tempi di attesa, generalizzando la distribuzione esponenziale al caso in cui si considera l'attesa per il verificarsi di α eventi successivi.

In questo senso, la distribuzione gamma generalizza la distribuzione esponenziale: mentre quest'ultima descrive il tempo di attesa fino al primo evento, la gamma consente di modellare il tempo necessario al verificarsi di un numero arbitrario di eventi, mantenendo la stessa struttura probabilistica di base.

☒ Quando la usi in psicologia?

Situazioni tipiche:

- **Prior per tassi positivi** $\lambda > 0$:
 - Tasso di eventi Poisson (es. sintomi/settimana)
 - Parametri di scala/velocità
- **Prior per precisioni** $\tau = 1/\sigma^2$ nei modelli normali
- **Tempi di attesa** per k eventi successivi

Esempio pratico: Vuoi stimare λ = numero medio di errori cognitivi per ora di compito. Prior: $\text{Gamma}(5, 2) \rightarrow$ credenza che $\lambda \approx 2.5$.

Interpretazione intuitiva:

- α = "pseudo-eventi" osservati
- β = "pseudo-tempo" di esposizione
- Es: $\text{Gamma}(10, 4) \rightarrow$ come se avessi visto 10 eventi in 4 unità di tempo

Prior comuni:

- $\text{Gamma}(0.01, 0.01)$: prior molto vaga
- $\text{Gamma}(\alpha, \beta)$ con α/β uguale alla tua guess della media

Coniugazione con Poisson: Se prior è $\text{Gamma}(\alpha, \beta)$ e osservi totale k eventi su n unità, posterior è $\text{Gamma}(\alpha+k, \beta+n) \rightarrow$ aggiornamento additivo!

Link con altre distribuzioni:

- $\text{Gamma}(1, \lambda) = \text{Esponenziale}(\lambda)$
- $\text{Gamma}(k/2, 1/2) = \text{Chi-quadrato}(k)$

13.7.6. Esempio: inferenza su un tasso Poisson

```

# Prior: Gamma(2, 1) - credenza che sia intorno a 2
alpha_prior <- 2
beta_prior <- 1

# Dati: 5 osservazioni con totale 18 eventi
n_obs <- 5
totale_eventi <- 18

# Posterior: Gamma(2 + 18, 1 + 5) = Gamma(20, 6)
alpha_post <- alpha_prior + totale_eventi
beta_post <- beta_prior + n_obs

# Visualizzazione
x <- seq(0, 8, length.out = 200)
df <- data.frame(
  x = rep(x, 2),
  density = c(dgamma(x, alpha_prior, beta_prior), dgamma(x, alpha_post, beta_post)),
  tipo = rep(c("Prior Gamma(2,1)", "Posterior Gamma(20,6)"), each = length(x))
)


ggplot(df, aes(x = x, y = density, color = tipo)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(
    title = "Aggiornamento Bayesiano: Gamma-Poisson",
    subtitle = "18 eventi in 5 osservazioni aggiornano la prior",
    x = " ", y = "Densità"
  )

cat("Media prior:", round(alpha_prior/beta_prior, 3), "\n")
#> Media prior: 2
cat("Media posterior:", round(alpha_post/beta_post, 3), "\n")
#> Media posterior: 3.33
cat("IC 95%: [", round(qgamma(0.025, alpha_post, beta_post), 2), ", ",
    round(qgamma(0.975, alpha_post, beta_post), 2), "]\n", sep = "")
#> IC 95%: [2.04, 4.95]

```

Aggiornamento Bayesiano: Gamma-Poisson

18 eventi in 5 osservazioni aggiornano la prior




13.7.7. Visualizzazione della flessibilità

```
x <- seq(0, 10, length.out = 200)
params <- list(c(1, 0.5), c(2, 0.5), c(3, 1), c(5, 1), c(9, 2))

df <- do.call(rbind, lapply(params, function(p) {
  data.frame(
    x = x,
    density = dgamma(x, shape = p[1], rate = p[2]),
    label = paste0(" = ", p[1], ",   = ", p[2])
  )
}))

ggplot(df, aes(x = x, y = density, color = label)) +
  geom_line(linewidth = 1) +
  scale_fill_qualitative() +
  labs(
    title = "Flessibilità della distribuzione Gamma",
    x = "x", y = "f(x)"
  ) +
  theme(legend.title = element_blank())
```



Riflessioni conclusive

Le distribuzioni continue esplorate in questo capitolo costituiscono il vocabolario fondamentale per esprimere credenze su quantità numeriche nell'inferenza bayesiana. Ogni famiglia presenta caratteristiche distintive che la rendono adatta a ruoli specifici all'interno del processo inferenziale.

Riepilogo dei ruoli nell'inferenza bayesiana

Distribuzione	Dominio	Ruolo principale	Prior coniugata per
Uniforme	$[a, b]$	Prior "non informativa"	—
Esponenziale	$(0, \infty)$	Verosimiglianza per tempi di attesa	—
Normale	$\mathbb{R}$	Prior/verosimiglianza per parametri di posizione	μ nella normale
Chi-quadrato	$(0, \infty)$	Modellazione della variabilità	—
t di Student	$\mathbb{R}$	Prior robusta, distribuzione predittiva	—
Beta	$(0, 1)$	Prior per proporzioni	p nella binomiale
Cauchy	$\mathbb{R}$	Prior robusta debolmente informativa	—
Gamma	$(0, \infty)$	Prior per tassi e precisioni	λ nella Poisson

Principi guida per la scelta

La scelta della distribuzione appropriata dipende da tre considerazioni fondamentali.

Il **dominio del parametro** costituisce il primo vincolo: la distribuzione beta è naturale per le proporzioni, la distribuzione gamma per i tassi positivi, la distribuzione normale o la distribuzione t per parametri non vincolati.

L'**informazione a priori** determina i valori dei parametri della distribuzione: prior vaghe producono distribuzioni disperse, mentre prior informative concentrano la massa probabilistica attorno a valori ritenuti plausibili.

Infine, la **robustezza desiderata** guida la scelta tra distribuzioni con comportamento delle code differente: la Cauchy e la t con pochi gradi di libertà offrono una maggiore protezione contro l'influenza di osservazioni estreme rispetto alla distribuzione normale.

La prospettiva unificante

Tutte le distribuzioni discusse condividono lo stesso ruolo epistemico: sono strumenti per rappresentare formalmente i nostri gradi di credenza. Queste distribuzioni non descrivono “come sono realmente le cose”, ma codificano “quanto riteniamo plausibile ciascun valore” alla luce delle informazioni disponibili. Questa interpretazione soggettivista costituisce il filo conduttore che unisce le diverse famiglie in un framework coerente per il ragionamento sotto incertezza.

Le proprietà matematiche, come la coniugazione, l'esistenza dei momenti o il comportamento delle code, non sono fini a sé stesse, ma hanno conseguenze epistemiche concrete: determinano come le credenze vengono aggiornate, quanta incertezza residua permane e quali previsioni possono essere formulate riguardo alle osservazioni future. Nei capitoli successivi, questi strumenti verranno combinati e messi in opera all'interno di modelli bayesiani sempre più articolati.

Come scelgo la distribuzione giusta?

Domande chiave per i dati:

1. “**Sono misure simmetriche senza vincoli?**” → Normale (o t se outlier)
2. “**Sono solo valori positivi?**” → Gamma, Log-normale, Esponenziale
3. “**Sono tempi di attesa con tasso costante?**” → Esponenziale
4. “**Sono proporzioni tra 0 e 1?**” → Beta (come dato, non come prior)

Domande chiave per i parametri:

1. “**È una probabilità $p \in (0,1)$?**” → Beta come prior
2. “**È un tasso $\lambda > 0$?**” → Gamma come prior
3. “**È una media μ senza vincoli?**” → Normale come prior
4. “**Voglio essere robusto a outlier?**” → t di Student o Cauchy

Coniugazioni da ricordare:

- Beta $\leftrightarrow$ Binomiale/Bernoulli
- Gamma $\leftrightarrow$ Poisson
- Normale $\leftrightarrow$ Normale (su μ)

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Distribuzione Beta

- Supporto: $[0, 1]$ (perfetta per proporzioni e probabilità)
- Parametri: $\alpha, \beta > 0$ (shape parameters)
- $\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}$, Moda = $\frac{\alpha - 1}{\alpha + \beta - 2}$ (se $\alpha, \beta > 1$)
- **Coniugata con Binomiale:** essenziale per inferenza bayesiana su proporzioni
- Interpretazione: $\alpha - 1$ = “successi pregressi”, $\beta - 1$ = “fallimenti pregressi”

2. Distribuzione Normale (Gaussiana)

- Supporto: $\mathbb{R}$ (intera retta reale)
- Parametri: $\mu \in \mathbb{R}$ (media), $\sigma^2 > 0$ (varianza)
- $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$
- Simmetrica, unimodale, code esponenziali
- Emerge dal TLC: distribuzione naturale per somme di variabili
- Circa 68% entro $\mu \pm \sigma$, 95% entro $\mu \pm 1.96\sigma$

3. Distribuzione Gamma

- Supporto: $\mathbb{R}^+$ (numeri positivi)
- Parametri: shape $\alpha > 0$, rate $\beta > 0$ (o scale $\theta = 1/\beta$)
- $\mathbb{E}[X] = \alpha/\beta$, $\text{Var}(X) = \alpha/\beta^2$
- Flessibile per modellare tempi di attesa, variabilità
- **Coniugata con Poisson e Normale** (per precisione)

4. Distribuzione Esponenziale

- Caso speciale di Gamma con $\alpha = 1$
- Modella tempo fino al primo evento in processo Poisson
- $\mathbb{E}[X] = 1/\lambda$, $\text{Var}(X) = 1/\lambda^2$
- Proprietà di assenza di memoria: $P(X > s + t \mid X > s) = P(X > t)$
- Usata per tempi di reazione, durate, intervalli tra eventi

5. Distribuzione Uniforme

- Supporto: $[a, b]$
- Massima entropia data solo l'informazione sui limiti
- $\mathbb{E}[X] = (a + b)/2$, $\text{Var}(X) = (b - a)^2/12$
- Prior non informativo per parametri limitati

6. Relazioni tra distribuzioni

- Esponenziale è Gamma con $\alpha = 1$
- Beta(1,1) è Uniforme(0,1)
- Normale emerge dal TLC
- Gamma modella somme di Esponenziali

7. Applicazioni psicologiche

- **Beta:** prior su proporzioni (prevalenza disturbi, accuratezza)
- **Normale:** punteggi psicometrici, QI, misure standardizzate

- **Gamma:** tempi di reazione, durate di episodi
- **Esponenziale:** tempi tra sintomi, latenze

Formule da ricordare:**Beta**(α, β):

$$f(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}, \quad \theta \in [0, 1]$$

$$\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}, \quad \text{Var}(\theta) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

Normale(μ, σ^2):

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}$$

$$\mathbb{E}[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

Gamma(α, β):

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0$$

$$\mathbb{E}[X] = \frac{\alpha}{\beta}, \quad \text{Var}(X) = \frac{\alpha}{\beta^2}$$

Esponenziale(λ):

$$f(x) = \lambda e^{-\lambda x}, \quad x > 0$$

$$\mathbb{E}[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

Proprietà critiche:

- Beta è coniugata con Binomiale (aggiornamento: $\text{Beta}(\alpha, \beta) \rightarrow \text{Beta}(\alpha + k, \beta + n - k)$)
- Normale è coniugata con sé stessa (per la media)
- Gamma è coniugata con Poisson e Normale (per precisione)
- Circa 95% della massa normale sta entro $\mu \pm 1.96\sigma$

Per il prossimo capitolo:

Nel Capitolo 14 studieremo formalmente la **funzione di verosimiglianza**, che quantifica quanto i dati osservati sono compatibili con ciascun valore del parametro. Vedremo come la verosimiglianza costituisca il ponte tra il modello probabilistico (le distribuzioni appena studiate) e l'inferenza bayesiana, permettendo di aggiornare le credenze sui parametri alla luce dell'evidenza empirica.

 Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2  patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7    bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           knitr_1.51
#> [16] labeling_0.4.3      bridgesampling_1.2-1  pkgbuild_1.4.8
#> [19] curl_7.1.0          RColorBrewer_1.1-3    abind_1.4-8
#> [22] purrr_1.2.2         grid_4.6.1            stats4_4.6.1
#> [25] xtable_1.8-8        inline_0.3.21         emmeans_2.0.3
#> [28] scales_1.4.0        cli_3.6.6             mvtnorm_1.4-1
#> [31] rmarkdown_2.31      generics_0.1.4        otel_0.2.0
#> [34] RcppParallel_5.1.11-2 cachem_1.1.0          stringr_1.6.0
#> [37] parallel_4.6.1      vctrs_0.7.3           V8_8.2.0
#> [40] Matrix_1.7-5        jsonlite_2.0.0         arrayhelpers_1.1-1
#> [43] glue_1.8.1          codetools_0.2-20      distributional_0.8.1
#> [46] lubridate_1.9.5     stringi_1.8.7         gtable_0.3.6
#> [49] QuickJSR_1.10.0     pillar_1.11.1         htmltools_0.5.9
#> [52] Brodningnag_1.2-9   R6_2.6.1              textshaping_1.0.5
#> [55] rprojroot_2.1.1     evaluate_1.0.5        lattice_0.22-9
#> [58] backports_1.5.1     memoise_2.0.1         broom_1.0.13
#> [61] snakecase_0.11.1    rstantools_2.6.0      coda_0.19-4.1
#> [64] gridExtra_2.3.1     nlme_3.1-169          checkmate_2.3.4
#> [67] xfun_0.60           pkgconfig_2.0.3

```

Parte IV.

PARTE 4: Verso l'inferenza

14. La verosimiglianza

Nei capitoli precedenti abbiamo utilizzato le distribuzioni di probabilità come strumenti per descrivere il comportamento delle variabili casuali. Sotto l'ipotesi di un modello probabilistico con parametri noti, siamo stati in grado di calcolare la probabilità associata a determinati valori osservati o a specifiche configurazioni dei dati.

Nella pratica della ricerca empirica, tuttavia, il problema che ci si trova ad affrontare è spesso di natura inversa. Ad esempio, uno psicologo clinico osserva che 18 pazienti su 25 hanno risposto positivamente a un nuovo trattamento. L'interrogativo rilevante non è "qual è la probabilità di osservare 18 successi?", domanda che presupporrebbe un tasso di risposta noto, ma piuttosto "quanto è efficace questo trattamento?", ovvero: quali valori del parametro che esprime il tasso di risposta sono maggiormente compatibili con i dati osservati? In questa prospettiva, i dati costituiscono il punto di partenza e l'obiettivo è determinare quali valori parametrici siano più plausibili alla luce dell'evidenza empirica disponibile. Questo cambio di prospettiva, dal calcolo della probabilità dei dati condizionatamente al modello alla valutazione della plausibilità dei parametri condizionatamente ai dati osservati, rappresenta il nucleo concettuale dell'inferenza statistica.

È proprio per rispondere a questo problema inverso che viene introdotta la **funzione di verosimiglianza**. Essa non assegna una distribuzione di probabilità ai parametri, ma quantifica, per ciascun valore parametrico, il grado di plausibilità dei dati osservati, a condizione che la struttura del modello probabilistico sia correttamente specificata. In altri termini, la verosimiglianza definisce una mappa della plausibilità parametrica che consente di confrontare diversi valori dei parametri in base alla loro capacità di spiegare l'evidenza empirica.

In questo capitolo, la funzione di verosimiglianza viene presentata come concetto fondamentale dell'inferenza bayesiana. Nel capitolo successivo, ne esamineremo le principali proprietà matematiche e mostreremo come, una volta combinata con le distribuzioni a priori, conduca naturalmente e formalmente alla determinazione della distribuzione a posteriori.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 5
- Capitolo 10 — per il contesto inferenziale
- Capitolo 11
- Capitolo 12 — **fondamentale**
- Capitolo 13 — **fondamentale**

Questo capitolo formalizza la **funzione di verosimiglianza**, uno dei tre pilastri dell'inferenza bayesiana (insieme a prior e posterior).

Conoscenze matematiche richieste:

- Appendice C - per verosimiglianze con dati multipli

Panoramica del capitolo

- Definizione e interpretazione della funzione di verosimiglianza.
- Distinzione tra verosimiglianza e funzione di probabilità.
- Log-verosimiglianza: vantaggi computazionali e analitici.
- Verosimiglianza per dati binomiali e gaussiani.
- Stima di massima verosimiglianza (MLE).
- Verosimiglianza congiunta per osservazioni multiple.
- Rapporto di verosimiglianze per il confronto tra ipotesi.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
# Riapplica il tema per sicurezza
apply_visual_theme()
```

14.1. Il principio della verosimiglianza

Il principio di verosimiglianza costituisce uno dei fondamenti dell'inferenza statistica. Esso fornisce un criterio sistematico per valutare quanto ciascun possibile valore dei parametri di un modello sia compatibile con i dati osservati. Invece di assegnare probabilità ai parametri, come avviene nell'inferenza bayesiana completa, il principio di verosimiglianza stabilisce come confrontare tra loro diversi valori parametrici sulla base della loro capacità di spiegare l'evidenza empirica.

14.1.1. Definizione formale

Definizione 14.1 (Funzione di verosimiglianza). Sia Y una variabile casuale (o un vettore di variabili casuali) la cui distribuzione dipende da un parametro incognito $\theta \in \Theta$. Tale distribuzione è descritta da una funzione di densità di probabilità (nel caso continuo) o da una funzione di massa di probabilità (nel caso discreto), che indichiamo con $f(y | \theta)$.

Una volta osservato un particolare insieme di dati y , la *funzione di verosimiglianza* è definita come:

$$L(\theta; y) = f(y | \theta).$$

In questa definizione è fondamentale distinguere chiaramente il ruolo delle due quantità coinvolte:

- y è **fissato**: rappresenta i dati effettivamente osservati;
- θ è **variabile**: rappresenta i possibili valori del parametro incognito $\theta \in \Theta$.

Di conseguenza, la funzione di verosimiglianza associa a ciascun valore possibile di θ un grado di compatibilità con i dati osservati.

Interpretazione. La verosimiglianza **non** rappresenta la probabilità che un'ipotesi sul parametro θ sia vera. Essa misura invece quanto i dati osservati risultino plausibili *assumendo* che il parametro abbia un determinato valore. Valori di θ per i quali i dati risultano più plausibili ricevono un supporto maggiore dalla funzione di verosimiglianza.

Questa distinzione è cruciale: la verosimiglianza confronta ipotesi parametriche, ma non assegna loro probabilità.

14.1.2. Verosimiglianza e funzione di probabilità: due prospettive

Dal punto di vista formale, la funzione di probabilità e la funzione di verosimiglianza hanno la stessa espressione matematica, $f(y | \theta)$. Tuttavia, esse svolgono ruoli concettualmente distinti, a seconda di quale quantità venga considerata variabile e quale venga considerata fissata.

- **La funzione di probabilità** descrive il comportamento dei dati *prima* che essi siano osservati. Risponde alla domanda: “Se il parametro avesse valore θ , quali dati potremmo osservare e con quale probabilità?” In questo contesto, θ è **fisso** (un’ipotesi sul modello) e y è **variabile** (l’esito incerto).
- **La funzione di verosimiglianza**, invece, entra in gioco *dopo* l’osservazione dei dati. Risponde alla domanda: “Avendo osservato il dato y , quali valori del parametro θ sono più compatibili con questa evidenza?” In questo caso, y è **fisso** (l’evidenza empirica) e θ è **variabile** (l’oggetto dell’inferenza).

In altri termini, passare dalla probabilità alla verosimiglianza significa cambiare prospettiva: dall’analisi dei dati *possibili* all’analisi dei parametri *incogniti*.

Caratteristica	Funzione di probabilità	Funzione di verosimiglianza
Quantità variabile	y (aleatoria)	θ (incognita)
Quantità fissata	θ (assunto noto)	y (osservato)
Domanda centrale	Quali dati aspettarsi?	Quali valori dei parametri sono più plausibili?
Scopo principale	Predizione	Inferenza

Questa dualità mette in evidenza un punto essenziale: la stessa espressione matematica può assumere significati concettualmente diversi, a seconda dell’obiettivo dell’analisi.

! Il ruolo della verosimiglianza nell’inferenza bayesiana

Nell’approccio bayesiano, la funzione di verosimiglianza svolge un ruolo centrale di collegamento tra i dati e i parametri. Essa si combina con la distribuzione a priori per determinare la distribuzione a posteriori:

$$p(\theta | y) \propto L(\theta; y), p(\theta).$$

I dati non aggiornano direttamente le credenze sui parametri, ma lo fanno **attraverso** la verosimiglianza, che quantifica quanto ciascun valore di θ sia compatibile con l’evidenza osservata. Nel capitolo successivo analizzeremo in dettaglio le proprietà matematiche di questa funzione e il suo ruolo nel meccanismo di aggiornamento bayesiano.

14.2. La log-verosimiglianza

14.2.1. Definizione e motivazione

In ambito statistico e computazionale è spesso conveniente lavorare non direttamente con la funzione di verosimiglianza, ma con il suo logaritmo naturale, detto *log-verosimiglianza*. Essa è definita come:

$$\ell(\theta; y) = \log L(\theta; y) = \log f(y | \theta).$$

La log-verosimiglianza non introduce nuove informazioni rispetto alla verosimiglianza originale, ma ne riformula l’espressione in una forma più adatta sia all’analisi matematica sia al calcolo numerico.

Questa trasformazione è ampiamente utilizzata in pratica, specialmente quando si lavora con campioni di grandi dimensioni o con modelli complessi.

14.2.2. Vantaggi computazionali e analitici

14.2.2.1. Vantaggi computazionali: la stabilità numerica

Quando i dati osservati sono numerosi, la verosimiglianza è spesso espressa come il prodotto di molte probabilità (o densità) individuali. Poiché tali quantità sono generalmente minori di 1, il loro prodotto può diventare estremamente piccolo, fino a risultare numericamente indistinguibile da zero nei calcoli effettuati al computer. Questo fenomeno è noto come *underflow numerico*.

La log-verosimiglianza risolve questo problema trasformando il prodotto in una somma. Nel caso di osservazioni indipendenti $y_1, \dots, y_n$, si ha infatti:

$$\ell(\theta; y_1, \dots, y_n) = \log L(\theta; y) = \sum_{i=1}^n \log f(y_i | \theta).$$

Poiché le somme di numeri reali sono molto più stabili dei prodotti di valori molto piccoli, questa trasformazione garantisce una maggiore affidabilità numerica nei calcoli.

Esempio pratico: underflow vs. stabilità

```
# Il prodotto diretto di molte probabilità piccole può collassare a zero (underflow)
n <- 1000
theta <- 0.3
set.seed(42)
dati <- sample(0:1, n, replace = TRUE)

# Verosimiglianza diretta: prodotto rischioso
prod(dbinom(dati, 1, theta)) # Potrebbe risultare 0
#> [1] 0

# Log-verosimiglianza: calcolo stabile
sum(dbinom(dati, 1, theta, log = TRUE)) # Restituisce un valore finito
#> [1] -781
```

Questo esempio mostra come la log-verosimiglianza permetta di lavorare con campioni di grandi dimensioni senza perdere informazione a causa dei limiti della rappresentazione numerica.

14.2.2.2. Vantaggi analitici: una forma più maneggevole

Oltre ai vantaggi computazionali, la log-verosimiglianza presenta anche importanti benefici dal punto di vista analitico.

1. **Semplificazione delle derivate.** Poiché il logaritmo trasforma un prodotto in una somma, il calcolo delle derivate della log-verosimiglianza risulta in genere più semplice rispetto a quello delle derivate della verosimiglianza originale. Questo aspetto è particolarmente utile quando si studia il comportamento della funzione al variare dei parametri.

2. **Equivalenza dei massimi.** Il logaritmo naturale è una funzione **monotona crescente**. Di conseguenza, massimizzare la log-verosimiglianza $\ell(\theta; y)$ è matematicamente equivalente a massimizzare la verosimiglianza $L(\theta; y)$. I valori del parametro θ che rendono massima una funzione rendono massima anche l'altra.

In sintesi, l'uso della log-verosimiglianza offre un duplice vantaggio: da un lato evita problemi numerici legati all'underflow, dall'altro rende più agevole l'analisi matematica della funzione di verosimiglianza. Per questi motivi, la log-verosimiglianza rappresenta lo strumento standard sia nell'inferenza statistica classica sia in quella bayesiana.

14.3. Verosimiglianza per dati binomiali

14.3.1. Un esempio introduttivo: il lancio di una moneta

Consideriamo il problema di stimare la probabilità θ che una moneta produca l'esito *Testa*. Assumiamo che ogni lancio sia indipendente dagli altri e che la probabilità θ rimanga costante da un lancio all'altro.

Se in n lanci osserviamo y esiti *Testa*, il numero totale di successi segue una distribuzione binomiale. In questo contesto, la probabilità di osservare esattamente quei dati, *dato* un valore del parametro θ , è:

$$P(\text{dati} \mid \theta) = \theta^y (1 - \theta)^{n-y}.$$

Se ora fissiamo i dati osservati e consideriamo questa stessa espressione come funzione del parametro θ , otteniamo la **funzione di verosimiglianza**:

$$L(\theta; \text{dati}) \propto \theta^y (1 - \theta)^{n-y}.$$

Il simbolo $\propto$ indica che stiamo trascurando eventuali costanti moltiplicative che non dipendono da θ e che quindi non influenzano il confronto tra valori diversi del parametro.

L'idea fondamentale è la seguente: **la verosimiglianza non chiede quanto siano probabili i dati in generale, ma quali valori di θ rendano più plausibili i dati che abbiamo effettivamente osservato.**

14.3.2. Esempio: due scenari a confronto

Per comprendere meglio il significato della verosimiglianza, confrontiamo due situazioni semplici.

14.3.2.1. Scenario 1: 1 Testa su 2 lanci

Supponiamo di osservare un esito *Testa* in due lanci della moneta ($n = 2, y = 1$).

Valutiamo la plausibilità di due possibili valori del parametro:

- Se $\theta = 0.5$:

$$L(0.5) = 0.5^1 \cdot 0.5^1 = 0.25.$$

- Se $\theta = 0.4$:

$$L(0.4) = 0.4^1 \cdot 0.6^1 = 0.24.$$

In questo caso, il valore $\theta = 0.5$ rende i dati leggermente più plausibili rispetto a $\theta = 0.4$. La differenza è modesta, ma il confronto è già informativo.

14.3.2.2. Scenario 2: 1 Testa su 3 lanci

Consideriamo ora un campione leggermente più grande: un esito *Testa* osservato in tre lanci ($n = 3$, $y = 1$).

- Se $\theta = 0.5$:

$$L(0.5) = 0.5^1 \cdot 0.5^2 = 0.125.$$

- Se $\theta = 0.4$:

$$L(0.4) = 0.4^1 \cdot 0.6^2 = 0.144.$$

In questo caso, i dati supportano maggiormente il valore $\theta = 0.4$ rispetto a $\theta = 0.5$. Osservare una sola *Testa* su tre lanci è infatti più compatibile con una moneta leggermente sbilanciata verso *Croce*.

Questo esempio mostra chiaramente che **la verosimiglianza dipende dai dati osservati**: a parità di numero di successi, un campione più grande può cambiare il grado di supporto assegnato ai diversi valori del parametro.

14.3.3. La verosimiglianza come funzione di θ

Possiamo visualizzare la funzione di verosimiglianza calcolandola per tutti i valori possibili di $\theta \in [0, 1]$.

```
theta_seq <- seq(0, 1, length.out = 200)

# Scenario 1: 2 lanci, 1 testa
lik1 <- theta_seq^1 * (1 - theta_seq)^1

# Scenario 2: 3 lanci, 1 testa
lik2 <- theta_seq^1 * (1 - theta_seq)^2

df <- data.frame(
  theta = rep(theta_seq, 2),
  likelihood = c(lik1, lik2),
  scenario = rep(c("2 lanci (1 testa)", "3 lanci (1 testa)"), each = length(theta_seq))
)

ggplot(df, aes(x = theta, y = likelihood, color = scenario)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(
    x = expression(theta),
    y = "Verosimiglianza",
    color = "Scenario"
  )
```




Figura 14.1.: Confronto delle funzioni di verosimiglianza per due scenari. Con più dati (3 lanci), la curva è più concentrata, indicando una maggiore informazione sul parametro.

Osservazioni chiave. Il massimo della verosimiglianza coincide con la proporzione campionaria osservata, cioè $\hat{\theta} = y/n$. Inoltre, all’aumentare della dimensione del campione, la funzione di verosimiglianza tende a concentrarsi sempre di più attorno al suo massimo, diventando più stretta. Questo riflette il fatto che dati più numerosi forniscono un’informazione più precisa sul valore del parametro.

Infine, quando nel campione sono presenti sia esiti *Testa* sia esiti *Croce*, i valori estremi del parametro (con θ molto vicino a 0 o a 1) risultano fortemente incompatibili con i dati e ricevono un supporto empirico praticamente nullo.

14.3.4. Verosimiglianza binomiale completa

Consideriamo ora un esperimento più realistico, con $n = 30$ lanci e $y = 23$ esiti *Testa*. Il numero totale di successi è modellato mediante una distribuzione binomiale. In questo caso, la funzione di verosimiglianza completa è:

$$L(\theta; y, n) = \binom{n}{y} \theta^y (1 - \theta)^{n-y} = \binom{30}{23} \theta^{23} (1 - \theta)^7.$$

In questo esempio manteniamo la costante combinatoria $\binom{30}{23}$, poiché stiamo lavorando con l’espressione completa della verosimiglianza. Sebbene tale costante non influenzi il valore del parametro che massimizza la funzione, essa è rilevante quando si confrontano verosimiglianze su scala assoluta.

```
n <- 30
y <- 23
theta <- seq(0, 1, length.out = 1000)
likelihood <- dbinom(y, size = n, prob = theta)

ggplot(data.frame(theta, likelihood), aes(x = theta, y = likelihood)) +
```

```
geom_line(linewidth = 1.2) +
geom_vline(xintercept = y/n, linetype = "dashed") +
scale_fill_qualitative() +
labs(
  x = expression(theta),
  y = "Verosimiglianza"
)
```




Figura 14.2.: Verosimiglianza binomiale per 23 successi su 30 prove. Il massimo si trova in corrispondenza della proporzione campionaria.

L'analisi grafica mostra un picco ben definito in corrispondenza di $\theta \approx 0.77$, che coincide con la proporzione campionaria $\hat{\theta} = 23/30$. Questo valore rappresenta la **stima di massima verosimiglianza** del parametro.

La forma relativamente concentrata della curva indica che il campione fornisce un'informazione piuttosto precisa su θ . Al contrario, i valori estremi del parametro risultano fortemente incompatibili con i dati osservati e sono quindi supportati in misura trascurabile dalla verosimiglianza.

14.4. La massima verosimiglianza come criterio frequentista

La funzione di verosimiglianza è uno strumento centrale dell'inferenza statistica. Nel paradigma **frequentista**, essa viene spesso utilizzata per ottenere una stima puntuale del parametro, detta *stima di massima verosimiglianza* (MLE).

È importante sottolineare fin da subito che **questo non è lo scopo della verosimiglianza nell'approccio bayesiano**.

L'inferenza bayesiana non mira a individuare un singolo valore "migliore" del parametro, ma a descrivere l'intera distribuzione dei valori plausibili di θ alla luce dei dati osservati.

Tuttavia, comprendere il criterio di massima verosimiglianza è utile per due motivi:

1. aiuta a chiarire il significato operativo della funzione di verosimiglianza;

2. fornisce un punto di confronto con l'approccio bayesiano, che verrà sviluppato nei capitoli successivi.

14.4.1. Il principio (in un'ottica frequentista)

Nel paradigma frequentista, la *stima di massima verosimiglianza* è definita come il valore del parametro che massimizza la funzione di verosimiglianza:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta; y).$$

Questo criterio seleziona il valore di θ che rende i dati osservati **più compatibili**, in termini di verosimiglianza, rispetto a ogni altra ipotesi parametrica.

i Approfondimento (opzionale): derivazione della MLE nel caso binomiale

Per derivare lo stimatore di massima verosimiglianza nel caso di una prova bernoulliana ripetuta, è opportuno lavorare con la **log-verosimiglianza**. Dati n lanci indipendenti con y successi (*Testa*), si ha:

$$\ell(\theta) = \log L(\theta; y) = y \log \theta + (n - y) \log(1 - \theta).$$

Per trovare il massimo, calcoliamo la derivata prima rispetto a θ e la poniamo uguale a zero:

$$\frac{d\ell}{d\theta} = \frac{y}{\theta} - \frac{n - y}{1 - \theta} = 0.$$

Risolvendo l'equazione per θ si ottiene:

$$\frac{y}{\theta} = \frac{n - y}{1 - \theta} \Rightarrow y(1 - \theta) = (n - y)\theta \Rightarrow y - y\theta = n\theta - y\theta \Rightarrow y = n\theta.$$

Pertanto, lo stimatore di massima verosimiglianza è:

$$\hat{\theta}_{\text{MLE}} = \frac{y}{n}.$$

Questo risultato mostra che, nel modello binomiale, la stima di massima verosimiglianza coincide con la proporzione campionaria.

14.4.2. La verosimiglianza su una griglia di valori

Un modo particolarmente intuitivo per studiare la funzione di verosimiglianza consiste nel valutarla su una griglia di possibili valori del parametro θ .

Questo approccio **non è specifico della stima di massima verosimiglianza**: al contrario, esso sarà centrale nell'inferenza bayesiana, dove la distribuzione a posteriori verrà ottenuta combinando, punto per punto, la verosimiglianza con una distribuzione a priori.

```
# Metodo 1: Ricerca su griglia
n <- 30          # Numero di lanci
y <- 23          # Numero di successi (Testa)
theta_grid <- seq(0.001, 0.999, length.out = 10000) # Griglia di valori
likelihood <- dbinom(y, size = n, prob = theta_grid) # Verosimiglianza per ogni punto
```

Osservando i valori della verosimiglianza sulla griglia, è possibile individuare il punto in cui essa raggiunge il massimo.

```
mle_grid <- theta_grid[which.max(likelihood)]
mle_grid
#> [1] 0.767
```

Questo valore coincide con la stima di massima verosimiglianza, ma qui l'aspetto rilevante è un altro: **la verosimiglianza è una funzione definita su tutto lo spazio dei parametri**. Nel capitolo successivo, questa stessa griglia verrà utilizzata per costruire direttamente la distribuzione a posteriori, combinando la verosimiglianza con una distribuzione a priori.

14.4.3. Verosimiglianza e inferenza bayesiana

Nell'approccio bayesiano, la funzione di verosimiglianza non viene utilizzata per selezionare un singolo valore del parametro. Il suo ruolo è invece quello di *modellare come i dati aggiornano le credenze* su tutti i valori possibili di θ .

Solo in un caso particolare — quando la distribuzione a priori è uniforme — il valore che massimizza la verosimiglianza coincide con la moda della distribuzione a posteriori. In questo caso, la stima di massima verosimiglianza coincide con la stima **Maximum A Posteriori** (MAP).

Al di fuori di questo caso specifico, l'inferenza bayesiana produce una distribuzione a posteriori la cui forma dipende congiuntamente dalla verosimiglianza e dalla distribuzione a priori, e non può essere riassunta in modo adeguato da una singola stima puntuale.

14.5. Verosimiglianza congiunta

Il concetto di verosimiglianza si estende in modo naturale al caso di osservazioni multiple, dando origine alla **verosimiglianza congiunta**. Questo strumento consente di combinare in modo coerente l'informazione proveniente da un intero campione di dati, fornendo una valutazione globale della plausibilità di un parametro alla luce di *tutta* l'evidenza disponibile.

14.5.1. Dalle osservazioni singole al campione

Sia $y_1, y_2, \dots, y_n$ un campione di osservazioni **indipendenti** provenienti da una distribuzione che dipende da un parametro incognito θ . In questo caso, la verosimiglianza complessiva è data dal **prodotto** delle verosimiglianze associate alle singole osservazioni:

$$L(\theta; y_1, \dots, y_n) = \prod_{i=1}^n f(y_i | \theta).$$

Questa forma riflette direttamente l'assunzione di indipendenza: ogni osservazione contribuisce in modo moltiplicativo alla plausibilità complessiva del parametro.

Passando alla rappresentazione logaritmica, il prodotto si trasforma in una **somma**:

$$\ell(\theta; y_1, \dots, y_n) = \sum_{i=1}^n \log f(y_i | \theta).$$

Questa proprietà non è solo computazionalmente conveniente, ma evidenzia anche un aspetto concettuale importante: **ogni osservazione aggiunge un contributo informativo** alla valutazione complessiva di θ .

14.5.2. Esempio: osservazioni Bernoulliane

Nel caso di n lanci indipendenti di una moneta, in cui ogni esito y_i vale 1 per *Testa* e 0 per *Croce*, la verosimiglianza congiunta assume la forma:

$$L(\theta; y_1, \dots, y_n) = \prod_{i=1}^n \theta^{y_i} (1 - \theta)^{1-y_i} = \theta^{\sum_{i=1}^n y_i} (1 - \theta)^{n - \sum_{i=1}^n y_i}.$$

Un aspetto cruciale di questa espressione è che essa dipende dai dati **solo attraverso il numero totale di successi**

$$S_n = \sum_{i=1}^n y_i.$$

Questa quantità costituisce una **statistica sufficiente** per il parametro θ : una volta noto S_n , l'intera sequenza delle osservazioni individuali non fornisce ulteriore informazione rilevante ai fini dell'inferenza su θ .

Da un punto di vista pratico, ciò significa che non è necessario conoscere l'ordine o la disposizione specifica degli esiti *Testa* e *Croce*: è sufficiente conoscere il numero totale di successi osservati. Questo fatto anticipa un principio centrale dell'inferenza bayesiana: **l'aggiornamento delle credenze dipende dai dati solo attraverso le informazioni statisticamente rilevanti**.

14.5.3. Combinazione di studi indipendenti

La verosimiglianza congiunta fornisce anche un meccanismo naturale per integrare evidenze provenienti da studi diversi. Supponiamo di disporre di quattro studi indipendenti che indagano lo stesso parametro sottostante θ , come la probabilità di successo in una prova Bernoulliana. Assumendo che tutti gli studi condividano lo stesso valore di θ , la log-verosimiglianza complessiva è data dalla somma delle log-verosimiglianze associate a ciascuno studio:

$$\ell(\theta) = \sum_{i=1}^4 [y_i \log(\theta) + (n_i - y_i) \log(1 - \theta)].$$

Consideriamo i seguenti dati:

- studio 1: 23 successi su 30 prove;
- studio 2: 20 successi su 28 prove;
- studio 3: 29 successi su 40 prove;
- studio 4: 29 successi su 36 prove.

Sviluppando esplicitamente la somma otteniamo:

$$\begin{aligned} \ell(\theta) = & 23 \log(\theta) + 7 \log(1 - \theta) + \\ & 20 \log(\theta) + 8 \log(1 - \theta) + \\ & 29 \log(\theta) + 11 \log(1 - \theta) + \\ & 29 \log(\theta) + 7 \log(1 - \theta). \end{aligned}$$


Questa espressione mostra in modo trasparente come ciascuno studio contribuisca additivamente all'evidenza complessiva sul parametro θ .

```
# Dati dei quattro studi
studi <- data.frame(
  successi = c(23, 20, 29, 29),
  prove    = c(30, 28, 40, 36)
)

# Log-verosimiglianza congiunta
log_lik_congiunta <- function(theta) {
  sum(studi$successi * log(theta) +
      (studi$prove - studi$successi) * log(1 - theta))
}

theta_seq <- seq(0.5, 0.9, length.out = 200)
log_lik_vals <- sapply(theta_seq, log_lik_congiunta)

ggplot(data.frame(theta = theta_seq, log_lik = log_lik_vals),
  aes(x = theta, y = log_lik)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(
    x = expression(theta),
    y = "Log-verosimiglianza congiunta",
    title = "Profilo di verosimiglianza\nper i quattro studi combinati"
  )
)
```



Il profilo risultante mostra come l'informazione proveniente dai diversi studi si combini in modo coerente, producendo una funzione di verosimiglianza più concentrata rispetto a quella che si otterrebbe analizzando ciascuno studio separatamente.

i Nota (frequentista): stima puntuale combinata

Nel paradigma frequentista, il massimo di questa funzione di verosimiglianza congiunta fornisce una stima puntuale del parametro θ basata su tutti gli studi considerati insieme. Nel caso binomiale, tale valore coincide con la proporzione complessiva di successi:

$$\hat{\theta} = \frac{\sum_i y_i}{\sum_i n_i}.$$

Questa osservazione, tuttavia, non esaurisce il ruolo della verosimiglianza. Nell'approccio bayesiano, l'intera funzione di verosimiglianza, e non solo il suo massimo, verrà combinata con una distribuzione a priori per ottenere la distribuzione a posteriori.

14.6. Verosimiglianza gaussiana

La distribuzione gaussiana (o Normale) occupa un ruolo centrale in statistica. Essa fornisce un modello efficace per molte variabili continue di interesse psicologico e scientifico, come il quoziente intellettivo (QI), i tempi di reazione e numerose misure psicofisiologiche.

In questa sezione utilizzeremo la distribuzione gaussiana per illustrare come la verosimiglianza si comporta nel caso di dati continui e per preparare il terreno all'aggiornamento bayesiano nel modello **normale–normale**, che verrà discusso nel manuale.

14.6.1. Caso di una singola osservazione

Supponiamo che una variabile casuale segua una distribuzione Normale con media incognita μ e deviazione standard nota σ . Dopo aver osservato un singolo valore y , la funzione di verosimiglianza per μ è data da:

$$L(\mu; y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right).$$

È fondamentale ricordare il cambio di prospettiva:

- il valore osservato y è **fissato**;
- la quantità che varia è il parametro μ .

Vista come funzione di μ , la verosimiglianza ha la forma di una **curva a campana** centrata esattamente sul valore osservato y . Questo riflette un principio intuitivo: i valori di μ più vicini all'osservazione rendono i dati più plausibili.

```
y_obs <- 114
sigma <- 15
mu_grid <- seq(70, 160, length.out = 500)
likelihood <- dnorm(y_obs, mean = mu_grid, sd = sigma)

ggplot(data.frame(mu = mu_grid, lik = likelihood),
       aes(x = mu, y = lik)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = y_obs, linetype = "dashed") +
```

```
scale_fill_qualitative() +
labs(
  x = expression(mu),
  y = "Verosimiglianza"
)
```




Figura 14.3.: Verosimiglianza gaussiana per una singola osservazione. Il massimo coincide con il valore osservato.

Questo primo caso mostra già un punto chiave: **una singola osservazione fornisce informazione su μ , ma in modo ancora molto impreciso.**

14.6.2. Caso di un campione gaussiano

Consideriamo ora un campione di n osservazioni indipendenti e identicamente distribuite (i.i.d.)

$$y_1, \dots, y_n \sim \mathcal{N}(\mu, \sigma^2),$$

dove la varianza σ^2 è nota.

In questo caso, la verosimiglianza congiunta è il prodotto delle densità individuali:

$$L(\mu; y_1, \dots, y_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_i - \mu)^2}{2\sigma^2}\right].$$

Per analizzare questa funzione in modo più semplice, consideriamo la **log-verosimiglianza**:

$$\begin{aligned} \ell(\mu) &= -\frac{n}{2} \log(2\pi\sigma^2) \\ &\quad - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2. \end{aligned}$$

Questa espressione mette in evidenza un fatto cruciale: tutta l'informazione sui dati rilevante per μ è contenuta nella **somma dei quadrati degli scarti** rispetto a μ .

Nel paradigma frequentista, massimizzare la log-verosimiglianza equivale a minimizzare tale somma, e conduce a un risultato ben noto:

$$\hat{\mu}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}.$$

Anche in questo caso, sottolineiamo che il valore della MLE non è l'obiettivo principale in un'ottica bayesiana: ciò che conta è la **forma completa** della funzione di verosimiglianza.

```
set.seed(42)
y <- c(26, 35, 30, 25, 44, 30, 33, 43, 22, 43, 24, 19, 39, 31, 25,
      28, 35, 30, 26, 31, 41, 36, 26, 35, 33, 28, 27, 34, 27, 22)
sigma <- 6.5

log_lik <- function(mu) {
  sum(dnorm(y, mean = mu, sd = sigma, log = TRUE))
}

mu_grid <- seq(25, 40, length.out = 200)
ll_vals <- sapply(mu_grid, log_lik)

ggplot(data.frame(mu = mu_grid, ll = ll_vals),
       aes(x = mu, y = ll)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = mean(y), linetype = "dashed") +
  scale_fill_qualitative() +
  labs(
    x = expression(mu),
    y = "Log-verosimiglianza"
  )
```




Figura 14.4.: Log-verosimiglianza per un campione di 30 osservazioni. Il massimo corrisponde alla media campionaria.

i La forma della verosimiglianza gaussiana

Nel caso gaussiano, la log-verosimiglianza è una **funzione quadratica** di μ , cioè una parabola con concavità verso il basso. Il suo vertice si trova in corrispondenza della media campionaria $\bar{y}$.

Poiché la verosimiglianza è l'esponentiale della log-verosimiglianza, essa assume la forma di una **curva a campana** centrata su $\bar{y}$. La *larghezza* di questa campana dipende da due fattori:

- la variabilità delle osservazioni (σ^2);
- il numero di dati raccolti (n).

In particolare, la verosimiglianza per μ è una distribuzione gaussiana con varianza σ^2/n . Questo risultato è cruciale: nel modello normale–normale, la quantità σ^2/n determina direttamente quanto i dati rendono la distribuzione a posteriori più o meno concentrata.

14.7. Confrontare ipotesi tramite la verosimiglianza

La funzione di verosimiglianza consente non solo di valutare singoli valori di un parametro, ma anche di confrontare direttamente ipotesi alternative. In particolare, è possibile confrontare **quanto meglio una ipotesi spiega i dati rispetto a un'altra**, utilizzando il rapporto delle loro verosimiglianze.

Questo tipo di confronto verrà sviluppato in modo sistematico nell'inferenza bayesiana attraverso il *fattore di Bayes*. Per chi fosse interessato a un'anticipazione di questa idea, il box seguente presenta il concetto di *rapporto di verosimiglianze*.

i Approfondimento: il rapporto di verosimiglianze**Confronto tra due ipotesi puntuali**

Dato un modello e due ipotesi alternative sui parametri, θ_0 e θ_1 , il **rapporto di verosimiglianze** è definito come:

$$\Lambda = \frac{L(\theta_1; \text{dati})}{L(\theta_0; \text{dati})}.$$

Si tratta, quindi, di un confronto diretto tra le verosimiglianze: il numeratore indica quanto i dati sono plausibili assumendo θ_1 , mentre il denominatore indica quanto lo sono assumendo θ_0 . Il rapporto di verosimiglianze **non** è la probabilità che H_1 sia vera: misura solo quante volte i dati sono più compatibili con H_1 rispetto a H_0 .

Interpretazione

- $\Lambda > 1$: i dati risultano più plausibili assumendo θ_1 rispetto a θ_0 ; quindi l'evidenza relativa favorisce θ_1 ;
- $\Lambda < 1$: i dati risultano più plausibili assumendo θ_0 ; quindi l'evidenza relativa favorisce θ_0 ;
- $\Lambda \approx 1$: le due ipotesi hanno un potere esplicativo simile; quindi i dati non permettono di discriminare in modo netto tra loro.

La distanza dall'unità indica quanto un'ipotesi renda i dati più (o meno) plausibili rispetto all'altra. In questo modo, il rapporto di verosimiglianze fornisce una misura continua e graduata della forza dell'evidenza empirica, evitando valutazioni dicotomiche e mettendo in primo piano il contributo informativo dei dati.

Esempio: moneta equilibrata vs. sbilanciata

Supponiamo di osservare $x = 7$ successi su $n = 10$ lanci. Confrontiamo due modelli:

- H_0 : moneta equilibrata ($\theta_0 = 0.5$);
- H_1 : moneta sbilanciata ($\theta_1 = 0.7$).

```
n <- 10
y <- 7

L_H0 <- dbinom(y, n, prob = 0.5)
L_H1 <- dbinom(y, n, prob = 0.7)
LR <- L_H1 / L_H0

cat("L(H0):", round(L_H0, 4), "\n")
#> L(H0): 0.117
cat("L(H1):", round(L_H1, 4), "\n")
#> L(H1): 0.267
cat("Rapporto di verosimiglianze:", round(LR, 2), "\n")
#> Rapporto di verosimiglianze: 2.28
```

Il rapporto di circa 2.3 indica che i dati sono circa 2.3 volte più probabili sotto H_1 rispetto a H_0 . È un'evidenza moderata a favore della moneta sbilanciata.

```

theta_seq <- seq(0, 1, length.out = 500)
lik_vals <- dbinom(y, n, prob = theta_seq)

ggplot(data.frame(theta = theta_seq, lik = lik_vals), aes(x = theta, y = lik)) +
  geom_line(linewidth = 1.2) +
  geom_point(aes(x = 0.5, y = L_H0), size = 3) +
  geom_point(aes(x = 0.7, y = L_H1), size = 3) +
  geom_segment(aes(x = 0.5, xend = 0.5, y = 0, yend = L_H0),
    linetype = "dashed") +
  geom_segment(aes(x = 0.7, xend = 0.7, y = 0, yend = L_H1),
    linetype = "dashed") +
  annotate("text", x = 0.5, y = L_H0 + 0.02, label = "H0") +
  annotate("text", x = 0.7, y = L_H1 + 0.02, label = "H1") +
  scale_fill_qualitative() +
  labs(
    x = expression(theta),
    y = "Verosimiglianza"
  )

```




Figura 14.5.: Funzione di verosimiglianza con i due valori parametrici confrontati. Il rapporto delle altezze nei due punti è il rapporto di verosimiglianze.

Connessione con l'inferenza bayesiana

Nel caso di **ipotesi puntuali** e priori uniformi sui modelli, il rapporto di verosimiglianze coincide con il fattore di Bayes, che rappresenta uno strumento centrale del confronto tra modelli in ambito bayesiano.

Nel manuale, il fattore di Bayes verrà introdotto come estensione naturale di questo principio, integrando la verosimiglianza con le credenze a priori.

i Approfondimento (frequentista): il criterio di informazione di Akaike (AIC)

Questo box è incluso per completezza: l'AIC è un criterio molto usato in ambito frequentista, ma non è lo strumento standard in un corso bayesiano.

Il *Criterio di Informazione di Akaike (AIC)* fornisce una soluzione semplice per il problema della selezione dei modelli.

Il problema dell'overfitting

Quando si confrontano modelli, quelli più complessi (con un maggior numero di parametri) tendono ad adattarsi meglio ai dati. Tuttavia, questo vantaggio può riflettere solo una maggiore flessibilità e non una reale capacità esplicativa. Questo fenomeno è noto come “sovradattamento” (*overfitting*) e richiede quindi criteri che penalizzino opportunamente la complessità.

Definizione dell'AIC

Il **Criterio di Informazione di Akaike (AIC)** fornisce una misura per confrontare modelli statistici, conciliando la bontà di adattamento ai dati con la loro complessità:

$$AIC = 2k - 2 \log(\hat{L}),$$

dove k è il numero di parametri stimati del modello e $\hat{L}$ rappresenta il valore massimo della funzione di verosimiglianza per quel modello.

La formula unisce due principi fondamentali dell'inferenza statistica. Il termine $-2 \log(\hat{L})$ misura la mancanza di adattamento (lack of fit): valori minori indicano una maggiore compatibilità del modello con i dati. Il termine $2k$ opera invece come una penalità per la complessità, penalizzando i modelli con un numero elevato di parametri e promuovendo la parsimonia. In sostanza, l'AIC rappresenta un compromesso tra capacità esplicativa e semplicità, premiando i modelli che descrivono bene i dati utilizzando un numero minore di parametri.

Interpretazione: nel confronto tra modelli, viene preferito il modello con il valore AIC **più basso**. La penalità $2k$ garantisce che un adattamento ai dati leggermente migliore, ma ottenuto aggiungendo molti parametri, non venga considerato un reale miglioramento del modello, promuovendo il principio di parsimonia.

Esempio: effetto del contenuto emotivo sulla memoria

Supponiamo di voler valutare l'effetto del contenuto emotivo delle immagini sulla memoria visiva. In un esperimento controllato, 30 partecipanti per condizione hanno mostrato i seguenti risultati:

```
# Dati sperimentali
successi_neutro <- 14
successi_emozione <- 22
n <- 30
```

Il modello nullo ipotizza che il contenuto emotivo non influenzi la memoria, postulando una probabilità comune per entrambe le condizioni:

```
# Modello nullo: stessa probabilità per entrambi
p_null <- (successi_neutro + successi_emozione) / (2 * n)
ll_null <- dbinom(successi_neutro, n, p_null, log = TRUE) +
  dbinom(successi_emozione, n, p_null, log = TRUE)
AIC_null <- 2 * 1 - 2 * ll_null # 1 parametro
```

Il modello alternativo consente probabilità differenziate, riconoscendo il possibile effetto dell'emozione:

```
# Modello alternativo: probabilità diverse
p1 <- successi_neutro / n
p2 <- successi_emozione / n
ll_alt <- dbinom(successi_neutro, n, p1, log = TRUE) +
          dbinom(successi_emozione, n, p2, log = TRUE)
AIC_alt <- 2 * 2 - 2 * ll_alt # 2 parametri
```

La valutazione mediante AIC bilancia adattamento e complessità:

```
cat("Modello nullo - AIC:", round(AIC_null, 2), "\n")
#> Modello nullo - AIC: 14
cat("Modello alternativo - AIC:", round(AIC_alt, 2), "\n")
#> Modello alternativo - AIC: 11.5
cat("Differenza (ΔAIC):", round(AIC_alt - AIC_null, 2), "\n")
#> Differenza (ΔAIC): -2.51
```

Una differenza AIC negativa indica che il modello alternativo è preferibile nonostante abbia un parametro in più. L'evidenza suggerisce che il modello che assegna probabilità distinte ai due gruppi descrive meglio i dati osservati.

Nota finale importante. L'AIC è uno strumento di selezione dei modelli tipico dell'inferenza frequentista. Nell'approccio bayesiano, il confronto tra modelli si basa invece sulla probabilità marginale dei dati e sul fattore di Bayes, che tengono conto dell'intera distribuzione a posteriori dei parametri.

Questo confronto verrà discusso nel manuale.

Riflessioni conclusive

La funzione di verosimiglianza è il concetto centrale che collega i dati ai parametri nell'inferenza statistica. Per ogni possibile valore del parametro, essa quantifica quanto i dati osservati siano compatibili con quel valore, fornendo una mappa di plausibilità costruita esclusivamente a partire dall'evidenza empirica.

In questo capitolo abbiamo esplorato le caratteristiche fondamentali della verosimiglianza. Abbiamo visto che essa **inverte la prospettiva** propria della funzione di probabilità: invece di chiederci quali dati potremmo osservare assumendo un certo valore del parametro, ci chiediamo quali valori del parametro siano più o meno compatibili con i dati effettivamente osservati. Abbiamo inoltre evidenziato i vantaggi computazionali e analitici della log-verosimiglianza, che trasforma prodotti potenzialmente instabili in somme numericamente e concettualmente più maneggevoli.

Abbiamo incontrato la *stima di massima verosimiglianza* (MLE) come uno dei possibili utilizzi della funzione di verosimiglianza nel paradigma frequentista. Nei modelli semplici, come quello binomiale e quello normale, la MLE coincide con statistiche campionarie intuitive, quali la proporzione e la media del campione. Tuttavia, è importante sottolineare che la MLE non esaurisce il ruolo della verosimiglianza: ciò che conta, in particolare nell'ottica bayesiana, è la **forma completa** della funzione di verosimiglianza e il modo in cui essa distribuisce il supporto empirico sui diversi valori del parametro.

Abbiamo inoltre visto come la verosimiglianza congiunta consenta di combinare in modo coerente informazioni provenienti da osservazioni multiple o da studi indipendenti, e come il rapporto di verosimiglianza permetta di esprimere l'evidenza relativa a favore di ipotesi alternative. In tutti questi casi, la verosimiglianza emerge come uno strumento cumulativo, che integra l'informazione contenuta nei dati senza introdurre, di per sé, alcuna assunzione sulle credenze a priori.

Nel prossimo capitolo approfondiremo le proprietà matematiche della funzione di verosimiglianza e mostreremo come essa si combini con la distribuzione a priori per generare la distribuzione a posteriori. In particolare, analizzeremo perché la verosimiglianza tende a concentrarsi attorno al valore “vero” del parametro al crescere della quantità di dati, come la sua precisione aumenti con l'ampiezza del campione e come questa informazione si integri con quella contenuta nella distribuzione a priori. Infine, discuteremo il ruolo della legge dei grandi numeri e del teorema del limite centrale nel chiarire il meccanismo dell'aggiornamento bayesiano.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Verosimiglianza come funzione del parametro

- $L(\theta | D) = p(D | \theta)$ è la PMF/PDF dei dati vista come funzione di θ
- **Cambio di prospettiva:** dati fissi, parametro variabile
- Non è una distribuzione su θ (non integra a 1!)
- Quantifica “quanto i dati supportano ciascun valore di θ ”

2. Principio di verosimiglianza

- Tutta l'informazione inferenziale nei dati è contenuta nella verosimiglianza
- Se $L(\theta | D_1) \propto L(\theta | D_2)$, i due dataset forniscono la stessa evidenza su θ
- Fondamentale nell'approccio bayesiano

3. Log-verosimiglianza

- $\ell(\theta) = \log L(\theta | D)$ trasforma prodotti in somme
- Stessa forma della verosimiglianza (monotona crescente)
- Facilita i calcoli, specialmente con dati multipli
- Numericamente più stabile (evita underflow)

4. Verosimiglianza per dati i.i.d.

- Se $D = \{x_1, \dots, x_n\}$ i.i.d., allora $L(\theta) = \prod_{i=1}^n p(x_i | \theta)$
- Log-verosimiglianza: $\ell(\theta) = \sum_{i=1}^n \log p(x_i | \theta)$
- Semplifica enormemente i calcoli

5. Massima verosimiglianza (MLE)

- $\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta | D)$
- Stima che “massimizza la compatibilità con i dati osservati”
- Importante ma **non bayesiano** (ignora il prior!)
- Spesso coincide con media posteriori per prior uniformi

6. Verosimiglianza relativa

- $R(\theta) = \frac{L(\theta)}{L(\hat{\theta}_{MLE})}$ normalizza rispetto al massimo
- Sempre $0 \leq R(\theta) \leq 1$
- Facilita interpretazione: “quanto meno supportato è θ rispetto alla MLE?”

7. Ruolo nel teorema di Bayes

- $p(\theta | D) \propto L(\theta | D) \cdot p(\theta)$
- Verosimiglianza “ribilancia” il prior alla luce dei dati
- Verosimiglianza piatta $\rightarrow$ posterior = prior (dati non informativi)
- Verosimiglianza concentrata $\rightarrow$ posterior dominata dai dati

8. Proprietà della verosimiglianza

- **Non è una probabilità** (può essere > 1 per variabili continue)
- **Non si normalizza** (non integra a 1)
- **Scala arbitraria**: solo i rapporti tra valori contano
- **Forma dipende dal modello** scelto

Formule da ricordare:

Definizione:

$$L(\theta | D) = p(D | \theta) = \begin{cases} \prod_{i=1}^n p(x_i | \theta) & \text{(i.i.d. discreto)} \\ \prod_{i=1}^n f(x_i | \theta) & \text{(i.i.d. continuo)} \end{cases}$$

Log-verosimiglianza:

$$\ell(\theta) = \log L(\theta | D) = \sum_{i=1}^n \log p(x_i | \theta)$$

Teorema di Bayes con verosimiglianza:

$$p(\theta | D) = \frac{L(\theta | D) \cdot p(\theta)}{\int L(\theta' | D) \cdot p(\theta') d\theta'}$$

Forma proporzionale:

$$p(\theta | D) \propto L(\theta | D) \cdot p(\theta)$$

Esempi di verosimiglianze:

- **Bernoulli**: $L(\theta) = \theta^k (1 - \theta)^{n-k}$ per k successi su n
- **Normale** (varianza nota): $L(\mu) \propto \exp\left(-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\right)$
- **Poisson**: $L(\lambda) = \frac{\lambda^{\sum x_i} e^{-n\lambda}}{\prod x_i!}$

Proprietà critiche:

- La verosimiglianza non dipende dal prior (solo dai dati e dal modello)
- MLE ignora il prior $\rightarrow$ non è stima bayesiana
- Con prior uniforme, moda posteriore = MLE
- Log-verosimiglianza facilita derivazioni e calcoli numerici

Per il prossimo capitolo:

Nel Capitolo 15 approfondiremo le **proprietà della verosimiglianza**, studiando score function, informazione di Fisher, normalità asintotica, e il ruolo della verosimiglianza nell'aggiornamento bayesiano. Vedremo anche come le verosimiglianze si combinano con prior coniugati per produrre posterior di forma chiusa.

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2  patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidymodels_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.3       scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-1       rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-5          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1  glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1       nlme_3.1-169
#> [67] checkmate_2.3.4     xfun_0.60             pkgconfig_2.0.3

```

Bibliografia

15. Proprietà della verosimiglianza e aggiornamento bayesiano

Introduzione

Nel capitolo precedente abbiamo introdotto la funzione di verosimiglianza come lo strumento che quantifica la compatibilità relativa tra i dati osservati e i possibili valori dei parametri di un modello. Attraverso esempi concreti, abbiamo osservato alcune sue caratteristiche ricorrenti: la verosimiglianza tende a concentrarsi attorno a un valore ben definito, diventa progressivamente più stretta con l'aumentare della dimensione del campione e, per campioni sufficientemente ampi, assume una forma approssimativamente gaussiana.

Queste osservazioni sollevano naturalmente alcune domande di fondo: *perché la verosimiglianza si comporta in questo modo?* E, soprattutto, *in che modo queste proprietà influenzano la costruzione e l'evoluzione della distribuzione a posteriori nell'inferenza bayesiana?*

Il presente capitolo affronta queste domande fornendo una lettura teorica unificante dei fenomeni osservati. Mostriamo che il comportamento della verosimiglianza non è accidentale, ma riflette regolarità matematiche profonde che governano il comportamento delle statistiche campionarie e il flusso di informazione dai dati ai parametri. In particolare, vedremo perché la verosimiglianza tende a concentrarsi attorno al valore corretto del parametro e perché la sua informatività cresce al crescere del numero di osservazioni disponibili.

In questa prospettiva, l'aggiornamento bayesiano potrà essere reinterpretato come un processo di integrazione dell'informazione, in cui la verosimiglianza e la distribuzione a priori contribuiscono in modo complementare alla forma finale della distribuzione a posteriori. Questa lettura mette in evidenza come l'evidenza empirica e la conoscenza pregressa non siano in competizione, ma cooperino nella costruzione dell'inferenza.

Infine, discuteremo il ruolo di due risultati fondamentali della teoria della probabilità, ovvero la **Legge dei Grandi Numeri** e il **Teorema del Limite Centrale**, che aiutano a comprendere il comportamento asintotico dell'inferenza bayesiana. Senza entrare in dimostrazioni formali, useremo questi teoremi per spiegare perché, al crescere dei dati, la distribuzione a posteriori tende a concentrarsi attorno al valore vero del parametro e perché, in molti contesti, essa può essere ben approssimata da una distribuzione gaussiana, indipendentemente dalla forma iniziale del prior.

Prerequisiti

Per seguire questo capitolo è necessario aver letto:

- Capitolo 5
- Capitolo 10
- Capitolo 12
- Capitolo 13
- Capitolo 14 — **fondamentale**

Questo capitolo completa lo studio della verosimiglianza, introducendo score function, infor-

mazione di Fisher, coniugazione e fornendo gli strumenti operativi per l'inferenza bayesiana parametrica.

Conoscenze matematiche richieste:

- Appendice F - per derivate e integrali della verosimiglianza

Panoramica del capitolo

- Collegamento tra proprietà della media campionaria e forma della verosimiglianza.
- Precisione come misura di informatività e regola di combinazione delle precisioni.
- Aggiornamento bayesiano nel caso gaussiano: formula esplicita per la distribuzione a posteriori.
- Legge dei Grandi Numeri e convergenza della distribuzione a posteriori.
- Teorema del Limite Centrale e approssimazione normale della distribuzione a posteriori.
- Combinazione di evidenze da studi multipli.
- Limiti dell'inferenza: distinzione tra incertezza campionaria e distorsioni sistematiche.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
library(patchwork)

# Riapplica il tema per sicurezza
apply_visual_theme()
```

15.1. Dalla media campionaria alla verosimiglianza

15.1.1. Il problema inferenziale

Consideriamo un problema concreto: stimare la prevalenza θ di sintomi depressivi clinicamente rilevanti nella popolazione studentesca universitaria. Poiché non è possibile osservare l'intera popolazione, raccogliamo un campione di n studenti e registriamo, per ciascuno, la presenza (1) o assenza (0) del sintomo.

Dal punto di vista probabilistico, le osservazioni $X_1, X_2, \dots, X_n$ possono essere modellate come variabili casuali indipendenti e identicamente distribuite (i.i.d.) con distribuzione di Bernoulli:

$$X_i \mid \theta \sim \text{Bernoulli}(\theta).$$

L'informazione contenuta nel campione viene tipicamente riassunta dalla **proporzione campionaria**

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

che rappresenta la frazione di studenti nel campione che presentano il sintomo.

Prima di osservare i dati, le nostre conoscenze su θ possono essere rappresentate da una distribuzione a priori. Dopo l'osservazione, l'aggiornamento bayesiano avviene tramite la **verosimiglianza**. Per

capire *perché* la verosimiglianza ha la forma che osserviamo nei grafici, dobbiamo quindi capire *come* si comporta la media campionaria $\bar{X}$.

15.1.2. Perché la verosimiglianza è centrata nel punto giusto

Un primo fatto fondamentale è che, in media, la proporzione campionaria coincide con il parametro che vogliamo stimare.

Teorema 15.1. Per osservazioni i.i.d. con $\mathbb{E}[X_i | \theta] = \theta$:

$$\mathbb{E}[\bar{X} | \theta] = \theta.$$

Interpretazione. Se potessimo ripetere l'esperimento molte volte, la media delle proporzioni osservate coinciderebbe con il valore vero di θ . In altre parole, $\bar{X}$ non tende sistematicamente a sovrastimare o sottostimare il parametro.

Conseguenza per la verosimiglianza. Poiché la funzione di verosimiglianza riflette quanto i dati sono compatibili con ciascun valore di θ , questa proprietà spiega perché il **picco della verosimiglianza** si trovi in corrispondenza della proporzione osservata $\bar{X}$. La verosimiglianza è quindi *centrata correttamente*.

i Dimostrazione

$$\mathbb{E}[\bar{X} | \theta] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i | \theta] = \theta.$$

15.1.3. Perché la verosimiglianza diventa più stretta con più dati

Un secondo fatto cruciale riguarda **quanto** la proporzione campionaria può fluttuare attorno al suo valore medio.

Teorema 15.2. Per osservazioni i.i.d. con varianza $\text{Var}(X_i | \theta) = \sigma^2$:

$$\text{Var}(\bar{X} | \theta) = \frac{\sigma^2}{n}.$$

Interpretazione. All'aumentare del numero di osservazioni, la variabilità della media campionaria diminuisce. Ogni nuovo dato contribuisce a "stabilizzare" la stima.

Conseguenza per la verosimiglianza. Poiché la verosimiglianza riflette l'incertezza sulla posizione del parametro, questa proprietà spiega perché la funzione di verosimiglianza diventa sempre più **concentrata** al crescere di n . In termini intuitivi, più dati osserviamo, meno valori di θ restano compatibili con l'evidenza.

i Dimostrazione

$$\text{Var}(\bar{X} | \theta) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i | \theta) = \frac{\sigma^2}{n}.$$

15.1.4. Il caso Bernoulliano: quanta incertezza rimane?

Nel caso delle variabili di Bernoulli, la variabilità di ciascuna osservazione dipende dal valore stesso di θ :

$$\text{Var}(X_i | \theta) = \theta(1 - \theta).$$

Di conseguenza, la variabilità della proporzione campionaria è:

$$\text{Var}(\bar{X} | \theta) = \frac{\theta(1 - \theta)}{n}.$$

La quantità

$$\text{SE}(\bar{X}) = \sqrt{\frac{\theta(1 - \theta)}{n}}$$

è detta **errore standard** e rappresenta l'ordine di grandezza delle fluttuazioni attese di $\bar{X}$ attorno al valore vero di θ .

Questa espressione ha una forma particolarmente informativa:

- l'incertezza è massima quando $\theta = 0.5$;
- diminuisce rapidamente al crescere di n ;
- tende a zero quando θ è vicino a 0 o a 1.

15.1.5. Visualizzazione: come la verosimiglianza cambia con n

```
# Proporzione osservata fissa
p_obs <- 0.6

# Diverse dimensioni campionarie
n_values <- c(10, 50, 200)

# Griglia di valori per theta
theta_grid <- seq(0.01, 0.99, length.out = 500)

# Calcolo delle verosimiglianze
likelihood_data <- do.call(rbind, lapply(n_values, function(n) {
  y <- round(p_obs * n) # numero di successi
  lik <- dbinom(y, size = n, prob = theta_grid)
  # Normalizziamo per confronto visivo
  lik_norm <- lik / max(lik)
  data.frame(
    theta = theta_grid,
    likelihood = lik_norm,
    n = factor(paste0("n = ", n), levels = paste0("n = ", n_values))
  )
}))
```

```
ggplot(likelihood_data, aes(x = theta, y = likelihood, color = n)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = p_obs, linetype = "dashed") +
  scale_fill_qualitative()
labs(
  x = expression(theta),
  y = "Verosimiglianza (normalizzata)",
  color = "Dimensione\ncampionaria"
)
#> <ggplot2::labels> List of 3
#> $ x      : expression(theta)
#> $ y      : chr "Verosimiglianza (normalizzata)"
#> $ colour: chr "Dimensione\ncampionaria"
```




Figura 15.1.: La verosimiglianza diventa più concentrata all'aumentare della dimensione campionaria. Tutti i campioni hanno la stessa proporzione osservata (0.6), ma la precisione aumenta con n .

Lettura del grafico. A parità di proporzione osservata ($\bar{X} = 0.6$), campioni più grandi producono funzioni di verosimiglianza sempre più strette. Questo illustra visivamente il principio chiave di questa sezione:

la forma della verosimiglianza riflette direttamente la variabilità della media campionaria.

15.2. Precisione e informatività

15.2.1. Perché parlare di precisione?

Nell'inferenza bayesiana è spesso più utile ragionare in termini di **precisione** piuttosto che di varianza. La precisione è definita come l'inverso della varianza:

$$\tau = \frac{1}{\sigma^2}.$$

Questa scelta non è puramente convenzionale. La precisione fornisce infatti una misura diretta di **quanta informazione** è contenuta in una distribuzione:

- una varianza grande indica molta incertezza e quindi **bassa precisione**;
- una varianza piccola indica poca incertezza e quindi **alta precisione**.

In altre parole, la precisione quantifica quanto “strettamente” una distribuzione è concentrata attorno ai valori più plausibili del parametro.

15.2.2. La precisione della media campionaria

Nel capitolo precedente abbiamo visto che la varianza della media campionaria decresce con il numero di osservazioni:

$$\text{Var}(\bar{X} \mid \theta) = \frac{\sigma^2}{n}.$$

Passando alla precisione otteniamo:

$$\text{Precisione}(\bar{X} \mid \theta) = \frac{1}{\text{Var}(\bar{X} \mid \theta)} = \frac{n}{\sigma^2}.$$

Osservazione chiave. La precisione cresce in modo **lineare** con la dimensione campionaria n . Questo significa che:

- ogni nuova osservazione aggiunge la *stessa quantità di informazione*;
- l’informazione totale fornita dai dati è la **somma** delle informazioni contenute nelle singole osservazioni.

Questa proprietà è fondamentale, perché anticipa uno dei meccanismi centrali dell’aggiornamento bayesiano:

le informazioni si combinano in modo additivo quando sono espresse in termini di precisione.

15.2.3. Errore standard e informatività dei dati

L’**errore standard**

$$\text{SE} = \frac{\sigma}{\sqrt{n}}$$

fornisce una misura immediata dell’incertezza associata alla media campionaria come stima del parametro.

Dal punto di vista bayesiano:

- un errore standard **piccolo** indica che i dati sono molto informativi: la verosimiglianza è stretta e concentrata;

15. Proprietà della verosimiglianza e aggiornamento bayesiano

- un errore standard **grande** indica che i dati sono poco informativi: la verosimiglianza è ampia e diffusa.

La precisione e l'errore standard descrivono quindi lo stesso fenomeno da due prospettive complementari:

- l'errore standard misura l'**incertezza residua**;
- la precisione misura l'**informazione accumulata**.

15.2.4. Visualizzazione: come informazione e incertezza cambiano con n

```
n_seq <- 1:200
sigma <- 1 # varianza unitaria per semplicità

precision_data <- data.frame(
  n = n_seq,
  se = sigma / sqrt(n_seq),
  precision = n_seq / sigma^2
)

p1 <- ggplot(precision_data, aes(x = n, y = se)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(
    x = "Dimensione campionaria (n)",
    y = "Errore standard",
    title = "Errore standard\ndecresce come 1/√n"
  )

p2 <- ggplot(precision_data, aes(x = n, y = precision)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  labs(
    x = "Dimensione campionaria (n)",
    y = "Precisione",
    title = "Precisione cresce\nlinearmente con n"
  )

p1 + p2
```




Figura 15.2.: Relazione tra dimensione campionaria, errore standard e precisione. Mentre l'errore standard decresce come $1/\sqrt{n}$, la precisione cresce linearmente con n .

Lettura dei grafici. Il primo grafico mostra che l'errore standard decresce lentamente, come $1/\sqrt{n}$: raddoppiare il campione non dimezza l'incertezza. Il secondo grafico mostra invece che la precisione cresce linearmente con n : ogni osservazione aggiunge la stessa quantità di informazione.

Questa differenza di comportamento spiega perché, nell'inferenza bayesiana, la precisione sia spesso il linguaggio più naturale per descrivere il contributo dei dati.

15.3. L'aggiornamento bayesiano come combinazione di precisioni

15.3.1. L'idea chiave

Nel caso gaussiano, l'aggiornamento bayesiano può essere compreso in modo sorprendentemente semplice: **la stima a posteriori è una media ponderata tra ciò che credevamo prima e ciò che ci dicono i dati**, dove i pesi sono dati dalle rispettive **precisioni**.

Questa sezione rende esplicita questa idea nel contesto più semplice possibile, ma anche uno dei più istruttivi.

15.3.2. Il caso gaussiano: prior e dati

Supponiamo di avere una credenza iniziale sul parametro θ , rappresentata da una distribuzione a priori gaussiana:

$$\theta \sim \mathcal{N}(\mu_0, \sigma_0^2).$$

Questa distribuzione riassume ciò che sappiamo (o crediamo di sapere) *prima* di osservare nuovi dati:

15. Proprietà della verosimiglianza e aggiornamento bayesiano

- μ_0 è il valore più plausibile secondo le nostre conoscenze pregresse;
- σ_0^2 quantifica l'incertezza associata a tale credenza.

Ora raccogliamo un campione di n osservazioni indipendenti:

$$X_1, \dots, X_n \sim \mathcal{N}(\theta, \sigma^2),$$

dove la varianza σ^2 è nota. Come visto nelle sezioni precedenti, tutta l'informazione rilevante contenuta nel campione è riassunta dalla **media campionaria** $\bar{X}$.

15.3.3. La verosimiglianza come distribuzione informativa

Considerata come funzione del parametro θ , la verosimiglianza associata ai dati è proporzionale a una distribuzione normale:

$$L(\theta; \bar{x}) \propto \exp\left(-\frac{n(\bar{x} - \theta)^2}{2\sigma^2}\right).$$

Questa funzione:

- è centrata sulla media osservata $\bar{x}$;
- ha varianza σ^2/n ;
- diventa più stretta al crescere del numero di osservazioni.

In termini di **precisione**, l'informazione fornita dai dati è pari a:

$$\tau_{\text{dati}} = \frac{n}{\sigma^2}.$$

15.3.4. La distribuzione a posteriori

Il teorema di Bayes stabilisce che la distribuzione a posteriori è proporzionale al prodotto tra prior e verosimiglianza:

$$p(\theta | \bar{x}) \propto p(\theta) L(\theta; \bar{x}).$$

Nel caso gaussiano, questo prodotto genera ancora una distribuzione normale:

$$\theta | \bar{x} \sim \mathcal{N}(\mu_{\text{post}}, \sigma_{\text{post}}^2).$$

Teorema 15.3 (Aggiornamento bayesiano gaussiano (forma esplicita)). *La **media a posteriori** è una media ponderata tra prior e dati:*

$$\mu_{\text{post}} = \frac{\tau_0 \mu_0 + \tau_{\text{dati}} \bar{x}}{\tau_0 + \tau_{\text{dati}}},$$

dove:

- $\tau_0 = 1/\sigma_0^2$ è la *precisione del prior*;
- $\tau_{\text{dati}} = n/\sigma^2$ è la *precisione dei dati*.

La **precisione a posteriori** è la somma delle precisioni:

$$\tau_{post} = \tau_0 + \tau_{dati}.$$

15.3.5. Come leggere queste formule

Queste espressioni matematiche traducono in modo preciso la logica dell'aggiornamento bayesiano:

1. **Media ponderata** La stima a posteriori si colloca tra μ_0 e $\bar{x}$, più vicina alla fonte di informazione più precisa.
2. **Somma delle informazioni** Le precisioni si sommano: l'incertezza diminuisce ogni volta che incorporiamo nuova informazione.
3. **Dominanza dei dati** Quando il campione è grande, τ_{dati} domina e la posterior è centrata vicino a $\bar{x}$.
4. **Dominanza del prior** Quando i dati sono pochi o molto rumorosi, il prior ha un peso maggiore.

In breve:

Bayes aggiorna credenze facendo una media, ma una media “intelligente”, pesata dall'informazione disponibile.

15.3.6. Esempio numerico

L'esempio seguente mostra visivamente come prior e dati contribuiscano alla distribuzione a posteriori in proporzione alle loro precisioni.

```
# Parametri del prior
mu_0 <- 100
sigma_0 <- 15
tau_0 <- 1 / sigma_0^2

# Parametri dei dati
n <- 25
x_bar <- 115
sigma <- 20 # deviazione standard nota
tau_data <- n / sigma^2

# Calcolo della posterior
tau_post <- tau_0 + tau_data
sigma_post <- sqrt(1 / tau_post)
mu_post <- (tau_0 * mu_0 + tau_data * x_bar) / tau_post

# Griglia di valori
theta_grid <- seq(60, 150, length.out = 500)

# Calcolo delle distribuzioni
prior_density <- dnorm(theta_grid, mu_0, sigma_0)
likelihood <- dnorm(theta_grid, x_bar, sigma / sqrt(n))
posterior_density <- dnorm(theta_grid, mu_post, sigma_post)
```

```
# Normalizzazione per visualizzazione
likelihood_norm <- likelihood * max(prior_density) / max(likelihood)

plot_data <- data.frame(
  theta = rep(theta_grid, 3),
  density = c(prior_density, likelihood_norm, posterior_density),
  type = factor(rep(c("Prior", "Verosimiglianza", "Posterior"), each = length(theta_grid)),
    levels = c("Prior", "Verosimiglianza", "Posterior"))
)

ggplot(plot_data, aes(x = theta, y = density, color = type, linetype = type)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  scale_linetype_manual(values = c("solid", "dashed", "solid")) +
  labs(
    x = expression(theta),
    y = "Densità",
    color = "",
    linetype = ""
  )
)
```




Figura 15.3.: Aggiornamento bayesiano: il prior (blu), la verosimiglianza (arancione) e la distribuzione a posteriori (verde). La posterior è un compromesso tra prior e dati, pesato dalle rispettive precisioni.

```
# Stampa dei risultati
cat("Prior: N(", mu_0, ", ", sigma_0, "^2)\n", sep = "")
#> Prior: N(100, 15^2)
cat("Dati: n =", n, ", media campionaria =", x_bar, "\n")
#> Dati: n = 25 , media campionaria = 115
cat("Precisione prior:", round(tau_0, 6), "\n")
#> Precisione prior: 0.00444
```



```

cat("Precisione dati:", round(tau_data, 6), "\n")
#> Precisione dati: 0.0625
cat("Precisione posterior:", round(tau_post, 6), "\n")
#> Precisione posterior: 0.0669
cat("\nMedia posterior:", round(mu_post, 2), "\n")
#>
#> Media posterior: 114
cat("Deviazione standard posterior:", round(sigma_post, 2), "\n")
#> Deviazione standard posterior: 3.86

```

i Il peso relativo di prior e dati

In questo esempio, la precisione dei dati ($\tau_{\text{dati}} = 0.062$) è circa 14.1 volte maggiore della precisione del prior ($\tau_0 = 0.004$). Di conseguenza, la media a posteriori (114) è molto più vicina alla media campionaria (115) che alla media a priori (100).

15.4. La Legge dei Grandi Numeri e la convergenza bayesiana

Tra i risultati fondamentali della teoria della probabilità, la **Legge dei Grandi Numeri (LGN)** descrive come l'informazione fornita dai dati si stabilizzi progressivamente all'aumentare del numero di osservazioni. Nella sua interpretazione più intuitiva, essa afferma che, ripetendo molte volte lo stesso esperimento nelle medesime condizioni, la frequenza relativa di un evento tende ad avvicinarsi alla sua probabilità teorica.

In termini più formali, se $X_1, \dots, X_n$ sono variabili casuali indipendenti e identicamente distribuite con valore atteso μ , la media campionaria

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

tende, al crescere di n , a concentrarsi attorno al valore costante μ .

Questo non significa che la media campionaria smetta di fluttuare, ma che **deviazioni ampie dal valore vero diventano sempre meno probabili**: le oscillazioni persistono, ma si fanno progressivamente più piccole e trascurabili rispetto a μ .

15.4.1. Conseguenze per la verosimiglianza

La Legge dei Grandi Numeri ha un impatto diretto sul comportamento della funzione di verosimiglianza. Nei modelli in cui il massimo della verosimiglianza coincide con una statistica campionaria — come la media nel caso gaussiano — tale massimo converge al valore vero del parametro.

Di conseguenza, all'aumentare della quantità di dati, la funzione di verosimiglianza:

- si concentra sempre più attorno al valore corretto del parametro;
- assegna un supporto sempre minore ai valori alternativi;
- restringe progressivamente l'insieme dei parametri plausibili.

L'incertezza non viene eliminata, ma **localizzata**: le ipotesi sbagliate non scompaiono, diventano semplicemente sempre meno credibili alla luce dell'evidenza accumulata.

15.4.2. Conseguenze per l'inferenza bayesiana: la consistenza

Questo comportamento della verosimiglianza si riflette direttamente nell'aggiornamento bayesiano delle credenze e conduce al principio di **consistenza bayesiana**.

Teorema 15.4 (Consistenza bayesiana). *Se la distribuzione a priori assegna probabilità positiva a ogni intorno del valore vero θ_0 , allora, al crescere della dimensione campionaria ($n \rightarrow \infty$), la distribuzione a posteriori si concentra sempre più attorno a θ_0 .*

In termini intuitivi, questo risultato afferma che l'inferenza bayesiana è un procedimento **auto-correttivo**. Le credenze iniziali possono essere imprecise, deboli o persino fortemente divergenti tra loro; tuttavia, purché non escludano a priori il valore vero del parametro, l'accumulo dell'evidenza empirica le costringe progressivamente a convergere verso la stessa conclusione.

Con l'aumentare dei dati:

- l'influenza del prior si attenua;
- l'informazione fornita dai dati diventa dominante;
- la distribuzione a posteriori diventa una rappresentazione sempre più concentrata e accurata del parametro che governa il fenomeno osservato.

15.4.3. Simulazione: convergenza con prior diversi

```
set.seed(42)
theta_true <- 0.45
n_values <- c(10, 50, 200, 1000)

# Prior diversi
priors <- list(
  A = c(2, 8), # Prior pessimista (media = 0.2)
  B = c(8, 2), # Prior ottimista (media = 0.8)
  C = c(1, 1)  # Prior uniforme (media = 0.5)
)

# Funzione per calcolare la posterior Beta
compute_posterior <- function(prior_params, n, theta_true) {
  y <- rbinom(1, n, theta_true)
  c(prior_params[1] + y, prior_params[2] + n - y)
}

# Generazione dei dati per il plot
set.seed(42)
theta_grid <- seq(0.01, 0.99, length.out = 300)

all_data <- do.call(rbind, lapply(n_values, function(n) {
  do.call(rbind, lapply(names(priors), function(name) {
    post <- compute_posterior(priors[[name]], n, theta_true)
    data.frame(
      theta = theta_grid,
      density = dbeta(theta_grid, post[1], post[2]),
```

```

    researcher = name,
    n = n
  )
}))
}))

all_data$n_label <- factor(paste("n =", all_data$n),
                          levels = paste("n =", n_values))
all_data$researcher <- factor(all_data$researcher,
                             labels = c("Prior pessimista (  $\beta = 0.2$ )",
                                         "Prior ottimista (  $\beta = 0.8$ )",
                                         "Prior uniforme"))

ggplot(all_data, aes(x = theta, y = density, color = researcher)) +
  geom_line(linewidth = 1) +
  geom_vline(xintercept = theta_true, linetype = "dashed",
            linewidth = 0.8) +
  facet_wrap(~ n_label, scales = "free_y", ncol = 2) +
  scale_fill_qualitative() +
  labs(
    x = expression(theta),
    y = "Densità a posteriori",
    color = "Ricercatore"
  ) +
  theme(legend.position = "bottom")

```




Figura 15.4.: Convergenza bayesiana: tre ricercatori con prior molto diversi convergono alla stessa conclusione all'aumentare dei dati. La linea verticale indica il valore vero $\theta_0 = 0.45$.

Lettura del grafico. Quando il campione è molto piccolo ($n = 10$), le distribuzioni a posteriori

riflettono ancora fortemente le diverse credenze iniziali dei ricercatori. Con $n = 50$, inizia a emergere un avvicinamento sistematico. A partire da $n = 200$, le posteriori risultano sostanzialmente sovrapposte, e con $n = 1000$ sono praticamente indistinguibili, tutte fortemente concentrate attorno al valore vero θ_0 .

Questa simulazione fornisce un'illustrazione concreta del principio di consistenza bayesiana: **a sufficienza di dati, ricercatori con prior molto diversi arrivano alle stesse conclusioni.**

15.5. Il Teorema del Limite Centrale e l'approssimazione normale

15.5.1. Perché la normalità emerge

Nel capitolo precedente abbiamo visto che, all'aumentare del numero di osservazioni, la verosimiglianza tende a concentrarsi attorno a un valore ben definito del parametro. Un ulteriore passo consiste nel capire **perché questa concentrazione assume spesso una forma gaussiana**, anche quando i dati non provengono da una popolazione normale.

La risposta a questa domanda è fornita dal **Teorema del Limite Centrale (TLC)**, uno dei risultati più importanti della teoria della probabilità.

15.5.2. L'idea del Teorema del Limite Centrale

In forma intuitiva, il TLC afferma che, quando si calcola la media di molte osservazioni indipendenti, il risultato tende a comportarsi come una variabile normale. Questo accade **indipendentemente dalla forma della distribuzione originale**, purché la varianza sia finita.

In altri termini:

- i singoli dati possono essere asimmetrici, discreti o irregolari;
- ma le **medie campionarie** tendono a seguire una distribuzione gaussiana.

Teorema 15.5 (Teorema del Limite Centrale (forma intuitiva)). *Per osservazioni i.i.d. con media μ e varianza $\sigma^2 < \infty$, la distribuzione della media campionaria $\bar{X}_n$ può essere approssimata, per n sufficientemente grande, da una distribuzione normale:*

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Questa proprietà spiega perché le distribuzioni gaussiane compaiano così frequentemente in statistica: **non perché la natura sia normale, ma perché facciamo medie.**

15.5.3. Conseguenze per la verosimiglianza

Poiché in molti modelli la verosimiglianza dipende dalla media campionaria (o da statistiche che si comportano in modo analogo), il TLC implica che, per campioni sufficientemente grandi, la verosimiglianza assuma una forma **approssimativamente normale** rispetto al parametro:

$$L(\theta | \bar{x}) \approx \mathcal{N}\left(\bar{x}, \frac{\sigma^2}{n}\right),$$

interpretata come funzione di θ .

È importante sottolineare che questa normalità **non deriva** dalla distribuzione delle singole osservazioni, ma dal loro comportamento aggregato. Anche partendo da popolazioni fortemente non gaussiane, la verosimiglianza tende ad assumere una struttura a campana man mano che il numero di dati cresce.

15.5.4. Conseguenze per l'inferenza bayesiana

Se la verosimiglianza è approssimativamente normale e il prior non è patologico, anche la distribuzione a posteriori eredita questa forma. Questo fatto è formalizzato da un risultato noto come **teorema di Bernstein–von Mises**.

Teorema 15.6 (Teorema di Bernstein–von Mises (interpretazione)). *Sotto condizioni di regolarità e per campioni sufficientemente grandi, la distribuzione a posteriori può essere approssimata da una distribuzione normale centrata sul valore stimato del parametro, con una dispersione che riflette la quantità di informazione contenuta nei dati.*

Interpretazione intuitiva. Quando i dati sono numerosi:

- il ruolo del prior diventa marginale;
- la posterior è dominata dalla verosimiglianza;
- la forma della posterior è ben approssimata da una gaussiana, anche se il prior e il modello iniziale non lo erano.

Questo risultato spiega perché, in molti contesti applicativi, l'inferenza bayesiana produca risultati simili a quelli frequentisti per grandi campioni, pur mantenendo un'interpretazione probabilistica distinta.

15.5.5. Visualizzazione: il TLC in una popolazione non normale

```
set.seed(42)

# Popolazione: distribuzione uniforme (non gaussiana)
population <- runif(1e6, min = 0, max = 1)

# Funzione per simulare distribuzioni campionarie
simulate_sampling_dist <- function(pop, sample_size, n_samples = 1e5) {
  replicate(n_samples, mean(sample(pop, sample_size, replace = TRUE)))
}

# Diverse dimensioni campionarie
sample_sizes <- c(1, 5, 30)

sampling_data <- do.call(rbind, lapply(sample_sizes, function(n) {
  means <- simulate_sampling_dist(population, n)
  data.frame(
    mean = means,
    n = factor(paste("n =", n), levels = paste("n =", sample_sizes))
  )
})
```

```

}))

ggplot(sampling_data, aes(x = mean)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40,
    alpha = 0.7) +
  stat_function(fun = dnorm,
    args = list(mean = 0.5, sd = sqrt(1/12) / sqrt(30)),
    data = subset(sampling_data, n == "n = 30"),
    linewidth = 1.2) +
  facet_wrap(~ n, scales = "free_y") +
  scale_fill_qualitative() +
  labs(
    x = "Media campionaria",
    y = "Densità"
  )

```




Figura 15.5.: Il Teorema del Limite Centrale in azione: anche partendo da una distribuzione uniforme, la distribuzione delle medie campionarie converge rapidamente a una forma gaussiana.

Lettura del grafico. Con $n = 1$, la distribuzione delle medie coincide con la distribuzione originale. Già con $n = 5$, inizia a emergere una forma a campana. Con $n = 30$, la distribuzione delle medie è praticamente indistinguibile da una normale.

Questo esempio mostra in modo visivo il messaggio centrale del TLC:

la normalità non è una proprietà dei dati, ma delle medie dei dati.

15.6. Combinazione di evidenze da studi multipli

15.6.1. L'idea di base

Uno dei punti di forza dell'approccio bayesiano è la possibilità di **integrare in modo coerente evidenze provenienti da fonti diverse**. Questo principio è alla base della **meta-analisi bayesiana**, che combina i risultati di studi indipendenti per ottenere stime più precise e robuste. Quando più studi indipendenti indagano lo stesso parametro θ , ciascuno di essi può essere visto come una fonte di informazione parziale, caratterizzata da una stima centrale e da un certo grado di incertezza.

Il principio fondamentale è semplice:

le informazioni si combinano sommando le loro precisioni.

15.6.2. Il principio della somma delle precisioni

Supponiamo che ciascuno studio i fornisca:

- una stima $\bar{x}_i$ del parametro θ ;
- una misura della sua incertezza, espressa tramite la **precisione** τ_i (l'inverso della varianza).

La stima combinata risulta essere una **media ponderata**:

$$\bar{x}_{\text{comb}} = \frac{\sum_i \tau_i \bar{x}_i}{\sum_i \tau_i},$$

dove i pesi riflettono l'affidabilità relativa degli studi.

Allo stesso tempo, la precisione complessiva è semplicemente:

$$\tau_{\text{comb}} = \sum_i \tau_i.$$

Queste formule riflettono esattamente la logica dell'aggiornamento bayesiano: ogni nuova fonte di informazione contribuisce in proporzione alla propria precisione, riducendo l'incertezza complessiva.

15.6.3. Esempio: sintesi di due studi

Consideriamo due studi indipendenti che stimano la prevalenza di un sintomo:

```
# Parametri degli studi
studi <- data.frame(
  studio = c("A", "B"),
  n = c(50, 200),
  proporzione = c(0.42, 0.38),
  se = c(0.07, 0.035)
)

studi$precisione <- 1 / studi$se^2

precisione_totale <- sum(studi$precisione)
```

```
media_combinata <- sum(studi$precisione * studi$proporzione) / precisione_totale
se_combinato <- sqrt(1 / precisione_totale)
```

```
#> Stima combinata: 0.388
#> Errore standard combinato: 0.0313
#> Precisioni:
#> - Studio A: 204
#> - Studio B: 816
#> - Totale: 1020
```

Risultato chiave. La stima combinata ha un errore standard (0.031) inferiore a quello di entrambi gli studi presi singolarmente. Questo accade perché la **precisione totale** (1020.4) è la somma delle precisioni individuali: l'incertezza si riduce man mano che integriamo più evidenza affidabile.¹

15.6.4. Visualizzazione: perché uno studio pesa più dell'altro

```
theta_grid <- seq(0.2, 0.6, length.out = 500)

meta_data <- data.frame(
  theta = rep(theta_grid, 3),
  density = c(
    dnorm(theta_grid, studi$proporzione[1], studi$se[1]),
    dnorm(theta_grid, studi$proporzione[2], studi$se[2]),
    dnorm(theta_grid, media_combinata, se_combinato)
  ),
  studio = factor(rep(c("Studio A (n=50)", "Studio B (n=200)", "Combinato"),
    each = length(theta_grid)),
    levels = c("Studio A (n=50)", "Studio B (n=200)", "Combinato"))
)

ggplot(meta_data, aes(x = theta, y = density, color = studio, linetype = studio)) +
  geom_line(linewidth = 1.2) +
  scale_fill_qualitative() +
  scale_linetype_manual(values = c("dashed", "dashed", "solid")) +
  labs(
    x = expression(theta),
    y = "Densità",
    color = "",
    linetype = ""
  )
```

¹Questo principio, che formalizza il modo *ottimale* di combinare informazioni incerte, ha ispirato e motivato una vasta quantità di ricerche empiriche nel campo delle Scienze della Visione. In particolare, ci si è chiesti se il sistema visivo umano si comporti come un “osservatore ideale”, ovvero se integri le informazioni in modo statisticamente ottimale e coerente con l'integrazione bayesiana. Questa domanda ha motivato molti studi condotti per comprendere come un individuo integri segnali visivi che possono essere parzialmente discordanti, come ad esempio quelli provenienti dalla stereopsi e dalla parallasse di movimento (Domini & Caudek, 2011).




Figura 15.6.: Combinazione di evidenze. Lo studio B ($n=200$), avendo una precisione notevolmente maggiore, contribuisce di più alla stima combinata (linea verde). L'intervallo di credibilità risultante è più stretto di quello di ciascuno studio preso singolarmente.

Lettura del grafico. Lo studio B, avendo una dimensione campionaria maggiore, presenta una distribuzione più stretta e quindi una precisione più elevata. Di conseguenza, la stima combinata (linea verde) risulta più vicina allo studio B che allo studio A. L'intervallo risultante è inoltre più stretto di entrambi, riflettendo la maggiore informazione complessiva.

i Il peso dell'evidenza

La stima combinata (0.388) è più vicina al valore riportato dallo studio B (0.38) perché questo studio fornisce un'informazione più precisa. In un'ottica bayesiana, **le evidenze non si contano, si pesano**: fonti più affidabili contribuiscono di più alla conclusione finale. Questo principio — che formalizza il modo ottimale di integrare informazioni incerte — ha ispirato numerose ricerche nelle scienze cognitive e percettive, dove ci si è chiesti se il sistema umano integri i segnali sensoriali in modo coerente con l'inferenza bayesiana (Domini & Caudek, 2011).

15.7. Limiti dell'inferenza: precisione vs. accuratezza

15.7.1. Cosa misura davvero l'errore standard

Le quantità studiate in questo capitolo, come la concentrazione della verosimiglianza, il restringimento della distribuzione a posteriori e la riduzione dell'errore standard, descrivono **una sola dimensione dell'inferenza statistica**: la **precisione**, cioè quanto una stima è influenzata dalla variabilità campionaria.

Un errore standard piccolo indica che, se ripetessimo lo studio molte volte nelle stesse condizioni, otterremmo risultati molto simili. Tuttavia, questa stabilità **non garantisce** che la stima sia vicina al valore vero del parametro.

In altre parole:

una stima può essere molto precisa, ma comunque sbagliata.

L'inferenza bayesiana, come qualunque procedura statistica, **non può correggere distorsioni sistematiche** introdotte prima dell'analisi, durante la progettazione dello studio, la raccolta dei dati o la misurazione dei costrutti.

15.7.2. Fonti comuni di distorsione sistematica

Nella ricerca applicata, in particolare in ambito psicologico e sociale, sono frequenti meccanismi che producono errori sistematici (*bias*). Anche un'analisi statisticamente impeccabile può portare a conclusioni fuorvianti se questi problemi non vengono affrontati a monte.

Distorsione da selezione Si verifica quando il campione osservato non è rappresentativo della popolazione di interesse. Reclutamento opportunistico, autoselezione o bassi tassi di risposta possono produrre stime che descrivono bene *il campione*, ma non *la popolazione*.

Distorsione da desiderabilità sociale In presenza di temi sensibili, i partecipanti possono fornire risposte socialmente accettabili piuttosto che veritiere. In questi casi, le osservazioni non riflettono il costrutto psicologico di interesse, compromettendo la validità delle inferenze.

Errori di misurazione Strumenti poco affidabili o non validati possono introdurre rumore o distorsioni sistematiche. Anche grandi campioni non compensano misure che catturano il fenomeno sbagliato o in modo instabile.

15.7.3. Il paradosso della falsa precisione




Figura 15.7.: Precisione e accuratezza nell'inferenza. La situazione più pericolosa è l'alta precisione con bassa accuratezza (in alto a destra): stime molto sicure ma sistematicamente sbagliate.

⚠ Il pericolo della falsa precisione

La situazione più insidiosa si verifica quando un'elevata precisione si accompagna a una bassa accuratezza. In questo caso, l'analisi produce intervalli di credibilità molto stretti — che suggeriscono grande certezza — attorno a valori che sono invece sistematicamente distorti. Un campione numericamente grande ma affetto da bias può essere **più pericoloso** di un campione piccolo ma corretto: consolida conclusioni errate con un'apparenza di rigore e affidabilità scientifica.

15.7.4. Come mitigare questi limiti

La consapevolezza dei limiti dell'inferenza statistica suggerisce alcune buone pratiche fondamentali.

Progettazione metodologica rigorosa La prevenzione dei bias avviene principalmente *prima* dell'analisi dei dati: campionamento appropriato, randomizzazione, protocolli standardizzati e strumenti validati sono insostituibili.

Analisi di sensibilità L'approccio bayesiano permette di esplorare esplicitamente l'impatto di ipotesi alternative e di valutare quanto le conclusioni dipendano da assunzioni potenzialmente discutibili.

Trasparenza epistemica È essenziale comunicare chiaramente che gli intervalli di credibilità quantificano solo l'incertezza campionaria. La valutazione critica della qualità dei dati e del disegno di ricerca resta una responsabilità centrale del ricercatore.

Riflessioni conclusive

Questo capitolo ha messo in luce il legame profondo tra il comportamento delle statistiche campionarie e il meccanismo dell'aggiornamento bayesiano. Le proprietà matematiche della media campionaria non sono semplici risultati tecnici, ma costituiscono il fondamento che spiega *perché* la verosimiglianza e la distribuzione a posteriori assumono le forme osservate.

In particolare, il fatto che la media campionaria sia centrata sul valore del parametro di interesse e che la sua variabilità diminuisca con l'aumentare del numero di osservazioni determina la forma della funzione di verosimiglianza: essa è centrata sul valore osservato e diventa progressivamente più concentrata man mano che l'evidenza empirica cresce. Queste stesse proprietà governano il modo in cui la distribuzione a posteriori risponde ai dati.

Nel caso gaussiano, l'aggiornamento bayesiano assume una forma particolarmente trasparente: la **precisione a posteriori** è la somma delle precisioni del prior e dei dati, mentre la **media a posteriori** è una media ponderata delle due fonti di informazione. Grazie al Teorema del Limite Centrale, questo schema si estende in modo approssimato a una vasta classe di modelli, giustificando l'uso dell'approssimazione normale per campioni sufficientemente ampi.

La Legge dei Grandi Numeri garantisce la **consistenza dell'inferenza bayesiana**: quando l'evidenza empirica diventa abbondante, la distribuzione a posteriori si concentra attorno al valore vero del parametro, indipendentemente dalla distribuzione a priori adottata, purché essa non lo escluda a priori. Questo risultato conferisce una solida robustezza epistemica al metodo bayesiano: nel lungo periodo, i dati prevalgono sulle convinzioni iniziali.

Il Teorema del Limite Centrale spiega inoltre perché la forma normale emerga così frequentemente nella distribuzione a posteriori per grandi campioni, fornendo il fondamento teorico di molte approssimazioni pratiche utilizzate nell'inferenza statistica.

È tuttavia essenziale riconoscere i **limiti** intrinseci di questi risultati. Tutte le proprietà discusse riguardano esclusivamente l'incertezza dovuta al campionamento casuale. Esse non possono correggere né compensare distorsioni sistematiche legate al disegno di ricerca, alla selezione del campione o agli strumenti di misura. La precisione statistica, quindi, non deve mai essere confusa con la validità scientifica delle conclusioni.

Nei capitoli successivi del manuale principale, questi principi teorici verranno utilizzati in modo operativo nella costruzione, stima e interpretazione di modelli bayesiani applicati alla ricerca psicologica. Il ruolo di questo companion è fornire le basi concettuali necessarie per comprendere *perché* tali modelli funzionano e *in quali condizioni* le loro inferenze possono essere considerate affidabili.

Punti chiave da ricordare

! Importante

Concetti essenziali di questo capitolo:

1. Score function (funzione punteggio)

- $S(\theta) = \frac{\partial}{\partial \theta} \ell(\theta) = \frac{\partial}{\partial \theta} \log L(\theta)$
- Pendenza della log-verosimiglianza
- $S(\hat{\theta}_{MLE}) = 0$ (condizione del primo ordine per massimo)
- Intuitivamente: “direzione di maggiore crescita della verosimiglianza”

2. Informazione di Fisher

- $I(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \ell(\theta) \right] = \mathbb{E}[S(\theta)^2]$
- Quantifica “quanta informazione sul parametro fornisce un’osservazione”
- Curvatura della log-verosimiglianza al punto vero
- $I_n(\theta) = n \cdot I(\theta)$ per n osservazioni i.i.d. (informazione si accumula!)

3. Normalità asintotica della MLE

- Per n grande: $\hat{\theta}_{MLE} \approx \mathcal{N} \left(\theta_{\text{vero}}, \frac{1}{I_n(\theta)} \right)$
- La verosimiglianza diventa approssimativamente normale attorno alla MLE
- Permette approssimazioni gaussiane della posterior (approssimazione di Laplace)

4. Prior coniugati

- Prior e verosimiglianza “coniugati” $\rightarrow$ posterior della stessa famiglia del prior
- **Beta-Binomiale:** $\text{Beta}(\alpha, \beta) + \text{Bin}(n, \theta) \rightarrow \text{Beta}(\alpha + k, \beta + n - k)$
- **Normale-Normale:** prior Normale + dati Normali $\rightarrow$ posterior Normale
- **Gamma-Poisson:** prior Gamma + dati Poisson $\rightarrow$ posterior Gamma
- Enormemente semplifica i calcoli (forma chiusa!)

5. Interpretazione parametri coniugati

- **Beta**(α, β): $\alpha - 1$ successi pregressi, $\beta - 1$ fallimenti pregressi
- **Gamma**(α, β): α eventi osservati in tempo β
- Parametri prior = “dimensione campionaria equivalente” delle credenze iniziali

6. Aggiornamento sequenziale

- Posterior(oggi) diventa prior(domani)
- Con coniugazione: aggiornare parametri sequenzialmente = aggiornare con tutti i dati insieme

- Proprietà di **coerenza temporale**: l'ordine dei dati non conta

7. Regola della precisione

- Precisione posteriore = Precisione prior + Precisione likelihood
- $\tau_{\text{post}} = \tau_{\text{prior}} + \tau_{\text{data}}$
- Per prior deboli: $\tau_{\text{post}} \approx \tau_{\text{data}}$ (posterior dominata dai dati)

8. Quando la coniugazione non è disponibile

- Approssimazioni: normale asintotica, approssimazione di Laplace
- Metodi computazionali: MCMC, variational inference
- Prior non coniugati permettono maggiore flessibilità ma richiedono calcolo numerico

Formule da ricordare:

Score function:

$$S(\theta) = \frac{\partial}{\partial \theta} \log L(\theta), \quad S(\hat{\theta}_{\text{MLE}}) = 0$$

Informazione di Fisher:

$$I(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log L(\theta) \right] = \mathbb{E}[S(\theta)^2]$$

Informazione per n osservazioni i.i.d.:

$$I_n(\theta) = n \cdot I(\theta)$$

Normalità asintotica MLE:

$$\hat{\theta}_{\text{MLE}} \xrightarrow{d} \mathcal{N} \left(\theta, \frac{1}{I_n(\theta)} \right)$$

Aggiornamento Beta-Binomiale:

$$\text{Beta}(\alpha, \beta) \xrightarrow{k/n} \text{Beta}(\alpha + k, \beta + n - k)$$

Aggiornamento Normale-Normale (media):

$$\mathcal{N}(\mu_0, \sigma_0^2) \xrightarrow{\bar{x}, n} \mathcal{N} \left(\frac{\tau_0 \mu_0 + n \tau \bar{x}}{\tau_0 + n \tau}, \frac{1}{\tau_0 + n \tau} \right)$$

dove $\tau = 1/\sigma^2$ è la precisione.

Aggiornamento Gamma-Poisson:

$$\text{Gamma}(\alpha, \beta) \xrightarrow{\sum x_i, n} \text{Gamma}(\alpha + \sum x_i, \beta + n)$$

Coppie coniugate principali:

Verosimiglianza	Prior coniugato	Posterior	Parametro
Binomiale	Beta	Beta	Proporzione θ
Normale (var nota)	Normale	Normale	Media μ
Normale (media nota)	Gamma	Gamma	Precisione τ
Poisson	Gamma	Gamma	Rate λ
Sponenziale	Gamma	Gamma	Rate λ

Proprietà critiche:

- Informazione di Fisher cresce linearmente con n
- Coniugazione preserva la famiglia parametrica
- Prior deboli $\rightarrow$ posterior dominata dai dati
- Prior informativi $\rightarrow$ sintesi ponderata
- Aggiornamento sequenziale = aggiornamento batch (con coniugazione)

Conclusione del modulo:

Questo capitolo conclude il **modulo di richiamo della teoria della probabilità**. Abbiamo costruito un percorso completo: dall'interpretazione bayesiana della probabilità agli assiomi di coerenza, dalle variabili casuali alle distribuzioni parametriche, dalla verosimiglianza all'aggiornamento bayesiano. Questi fondamenti costituiscono la base concettuale e operativa per l'**inferenza bayesiana** presentata nel manuale principale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*.

Per il manuale principale:

Il manuale UTET approfondisce: modelli gerarchici, confronto di modelli, inferenza decisionale, metodi computazionali (MCMC, HMC, Stan), regressione bayesiana, modelli di mistura, analisi di mediazione e moderazione, e applicazioni psicologiche avanzate.

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidymodels_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.3       scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-1       rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-5          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1  glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5        stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1       nlme_3.1-169
#> [67] checkmate_2.3.4     xfun_0.60             pkgconfig_2.0.3

```


Bibliografia

16. Conclusioni: dal linguaggio della probabilità all'inferenza bayesiana

Il percorso compiuto

Questo modulo ha costruito, passo dopo passo, il vocabolario concettuale e gli strumenti formali necessari per ragionare in modo rigoroso in condizioni di incertezza.

Siamo partiti da una domanda fondamentale: *come possiamo rappresentare e aggiornare le nostre credenze alla luce dell'evidenza?* La risposta bayesiana a questa domanda richiede un linguaggio preciso, ovvero il linguaggio della probabilità, e strumenti matematici per manipolarlo in modo coerente.

Il percorso si è articolato nelle seguenti tappe:

- **L'interpretazione bayesiana della probabilità** ha stabilito che le probabilità rappresentano gradi di credenza razionale, non frequenze ipotetiche. Gli assiomi di Kolmogorov garantiscono la coerenza interna di queste credenze, evitando contraddizioni logiche.
- **Le variabili casuali e le distribuzioni** hanno fornito il linguaggio per descrivere quantità incerte. Abbiamo imparato a distinguere tra variabili discrete e continue, a caratterizzarle mediante funzioni di massa e densità, e a sintetizzarle attraverso momenti come il valore atteso e la varianza.
- **La covarianza e la correlazione** hanno esteso questo linguaggio alle situazioni multivariate, permettendoci di descrivere come le incertezze su diverse quantità siano legate tra loro.
- **Le famiglie parametriche di distribuzioni**, ovvero la distribuzione di Bernoulli, la distribuzione binomiale, la distribuzione di Poisson, la distribuzione normale, la distribuzione beta e la distribuzione gamma, hanno costituito un vocabolario standardizzato per esprimere credenze in forme matematicamente trattabili e clinicamente interpretabili.
- **La verosimiglianza** ha completato il quadro, formalizzando il modo in cui i dati osservati aggiornano le nostre credenze sui parametri. Abbiamo visto come essa si combini con la distribuzione *a priori* per generare la distribuzione *a posteriori*, e come le proprietà fondamentali della media campionaria, come la sua centratura, la precisione crescente con la numerosità e la convergenza, si riflettano direttamente nel comportamento dell'inferenza bayesiana.

I tre elementi fondamentali dell'inferenza bayesiana

Al termine di questo percorso, disponete degli strumenti concettuali per comprendere e impiegare i tre elementi costitutivi dell'inferenza bayesiana:

$$\underbrace{p(\theta \mid \text{dati})}_{\text{a posteriori}} \propto \underbrace{p(\text{dati} \mid \theta)}_{\text{verosimiglianza}} \times \underbrace{p(\theta)}_{\text{a priori}}$$

La **distribuzione a priori** formalizza le credenze iniziali sul parametro, prima di osservare i dati. Sapete ora come scegliere famiglie parametriche appropriate (ad esempio, Beta per proporzioni, Gamma per tassi, Normale per quantità non vincolate) e come i loro parametri traducono in forma matematica il vostro stato di conoscenza iniziale.

La **verosimiglianza** quantifica quanto ciascun valore possibile del parametro renda plausibili i dati osservati. Comprendete perché questa funzione si concentra attorno a valori particolari, perché diventi più “stretta” (informativa) all’aumentare dei dati, e come la Legge dei Grandi Numeri e il Teorema del Limite Centrale ne descrivano il comportamento asintotico.

La **distribuzione a posteriori** sintetizza tutto ciò che sappiamo dopo aver osservato i dati. Sapete interpretarla come distribuzione aggiornata delle credenze, calcolare da essa intervalli di credibilità e comprendere perché ricercatori con conoscenze iniziali differenti convergano verso conclusioni simili quando l’evidenza empirica diventa sufficientemente ricca.

Verso il manuale principale

Il manuale *Inferenza bayesiana in psicologia: Ragionare con l’incertezza* costruisce su queste fondamenta per affrontare problemi di complessità crescente e di diretta rilevanza per la ricerca psicologica.

Modelli bayesiani applicati: I concetti di prior, verosimiglianza e posterior saranno applicati concretamente a modelli di regressione, ANOVA bayesiana, modelli per dati categoriali e analisi di mediazione e moderazione.

Modelli gerarchici: La struttura dell’aggiornamento bayesiano si estende naturalmente a modelli multilivello, in cui i parametri a livello individuale sono a loro volta descritti da distribuzioni a livello di popolazione. Questo approccio è particolarmente adatto ai dati psicologici, che presentano tipicamente variabilità strutturata tra soggetti, item e contesti di misurazione.

Metodi computazionali: Quando le soluzioni analitiche non sono disponibili, metodi come Markov Chain Monte Carlo (MCMC) e Hamiltonian Monte Carlo (HMC) consentono di esplorare distribuzioni a posteriori di forma arbitraria. Il linguaggio Stan offrirà lo strumento pratico per implementare questi metodi in modo efficiente e validato.

Confronto di modelli: Strumenti come il fattore di Bayes e i criteri di informazione permetteranno di confrontare modelli alternativi, quantificando l’evidenza relativa a favore di diverse ipotesi teoriche, a completamento di un’inferenza basata sulla stima dei parametri.

Un messaggio finale

La statistica bayesiana non è semplicemente una collezione di tecniche alternative a quelle frequentiste. Essa rappresenta un **modo di pensare all’incertezza** che rispecchia il ragionamento scientifico stesso: partiamo da ciò che già sappiamo, raccogliamo nuova evidenza, e aggiorniamo in modo logicamente coerente le nostre credenze.

I concetti sviluppati in questo modulo, ovvero la probabilità come grado di credenza, le distribuzioni come rappresentazione dell’incertezza, la verosimiglianza come ponte tra dati e parametri, non sono prerequisiti da archiviare. Essi costituiscono il **fondamento concettuale** su cui poggia ogni analisi bayesiana, dalla più elementare alla più sofisticata.

Quando, nel manuale principale, incontrerete una distribuzione a posteriori complessa o un modello gerarchico articolato, la logica sottostante rimarrà invariata: $\text{prior} \times \text{verosimiglianza} \rightarrow \text{posterior}$.

16. Conclusioni: dal linguaggio della probabilità all'inferenza bayesiana

La complessità risiederà nella specificazione del modello e nella sua struttura, non nel principio fondamentale che lo governa.

Con questi strumenti concettuali, siete ora pronti per affrontare l'inferenza bayesiana applicata ai problemi concreti della ricerca psicologica.

A. Simbologia di base

Per una scrittura più sintetica possono essere utilizzati alcuni simboli matematici. Questa appendice organizza i simboli più frequenti per categoria tematica, facilitando la consultazione rapida.

A.1. Logica e quantificatori

Simboli utilizzati per esprimere relazioni logiche e condizioni di esistenza.

- L'operatore logico booleano $\wedge$ significa “e” (congiunzione forte) mentre il connettivo di disgiunzione $\vee$ significa “o” (oppure) (congiunzione debole).
- L'implicazione logica “ $\Rightarrow$ ” significa “implica” (se ...allora). $P \Rightarrow Q$ vuol dire che P è condizione sufficiente per la verità di Q e che Q è condizione necessaria per la verità di P .
- L'equivalenza matematica “ $\Leftrightarrow$ ” significa “se e solo se” e indica una condizione necessaria e sufficiente, o corrispondenza biunivoca.
- Il quantificatore esistenziale $\exists$ vuol dire “esiste almeno un” e indica l'esistenza di almeno una istanza del concetto/oggetto indicato.
- Il quantificatore esistenziale di unicità $\exists!$ (“esiste soltanto un”) indica l'esistenza di esattamente una istanza del concetto/oggetto indicato.
- Il quantificatore esistenziale $\nexists$ nega l'esistenza del concetto/oggetto indicato.
- Il quantificatore universale $\forall$ vuol dire “per ogni.”
- Il simbolo $|$ si legge “tale che.”

A.2. Teoria degli insiemi

Simboli per descrivere insiemi, appartenenza, relazioni e operazioni.

- $\mathcal{A}, \mathcal{S}$: insiemi.
- $x \in A$: x è un elemento dell'insieme A . Il simbolo $\notin$ vuol dire “non appartiene.”
- $\subseteq$ si legge “è un sottoinsieme di” (può coincidere con l'insieme stesso). Il simbolo $\subset$ si legge “è un sottoinsieme proprio di.”
- $\#$ indica la cardinalità di un insieme (numero di elementi).
- $\cap$ indica l'intersezione di due insiemi. Il simbolo $\cup$ indica l'unione di due insiemi.
- $\emptyset$ indica l'insieme vuoto o evento impossibile.

A.3. Notazione matematica generale

Simboli e convenzioni per operazioni e relazioni matematiche comuni.

- $\log(x)$: il logaritmo naturale di x .
- $\triangleq$ (o $:=$) si legge “uguale per definizione.”
- Δ indica la differenza fra due valori della variabile scritta a destra del simbolo.

A. Simbologia di base

- $\propto$ si legge “proporzionale a.”
- $\approx$ si legge “circa.”
- In matematica, argmax identifica l'insieme dei punti per i quali una data funzione raggiunge il suo massimo. In altre parole, $\operatorname{argmax}_x f(x)$ è l'insieme dei valori di x per i quali $f(x)$ raggiunge il valore più alto.

A.4. Algebra lineare

Convenzioni per rappresentare oggetti matematici di diversa dimensione.

- a, c, α, γ : scalari.
- x, y : vettori (in grassetto).
- X, Y : matrici (maiuscole in grassetto).

A.5. Probabilità e statistica

Notazione per variabili casuali, distribuzioni e funzioni probabilistiche.

A.5.1. Notazione generale

- $X \sim p$: la variabile casuale X si distribuisce come p .
- $p(\cdot)$: distribuzione di massa o di densità di probabilità.
- $p(y | x)$: la probabilità o densità di y dato x , ovvero $p(y = Y | x = X)$.
- $f(x)$: una funzione arbitraria di x .
- $f(X; \theta, \gamma)$: f è una funzione di X con parametri θ, γ . Questa notazione indica che X sono i dati che vengono passati ad un modello di parametri θ, γ .

A.5.2. Distribuzioni di probabilità comuni

- $\mathcal{B}(p)$: distribuzione di Bernoulli di parametro p (probabilità di successo).
- $\operatorname{Bin}(n, p)$: distribuzione binomiale di parametri n (numero di prove) e p (probabilità di successo).
- $\operatorname{Poisson}(\lambda)$: distribuzione di Poisson di parametro λ (tasso medio).
- $\mathcal{N}(\mu, \sigma^2)$: distribuzione gaussiana di media μ e varianza σ^2 .
- $\mathcal{U}(a, b)$: distribuzione uniforme con limite inferiore a e limite superiore b .
- $\operatorname{Beta}(\alpha, \beta)$: distribuzione Beta di parametri α e β .
- $\operatorname{Cauchy}(\alpha, \beta)$: distribuzione di Cauchy di parametri α (posizione: media) e β (scala: radice quadrata della varianza).

A.5.3. Altre misure statistiche

- $\mathbb{KL}(p || q)$: la divergenza di Kullback-Leibler da p a q .

B. Numeri e intervalli

i Perché questa appendice è importante

La teoria della probabilità richiede diversi tipi di numeri: interi per contare eventi, razionali per esprimere proporzioni, reali per rappresentare misure continue. Comprendere queste distinzioni è fondamentale per interpretare correttamente variabili casuali discrete e continue.

B.1. Numeri binari

I numeri binari rappresentano il sistema numerico più elementare utilizzato in informatica, poiché sono composti unicamente da due simboli: 0 e 1. Questa caratteristica li rende particolarmente adatti alla rappresentazione di situazioni dicotomiche (vero/falso, presente/assente) e consente ai computer di operare rapidamente ed efficacemente sui dati.

Un esempio semplice d'impiego dei valori logici binari si ottiene quando raccogliamo risposte a una domanda chiusa. Immaginiamo, ad esempio, di porre la domanda “Ritieni che l'apprendimento della statistica sia utile per la tua formazione?” a 10 studenti di psicologia. Se le risposte vengono memorizzate in R come valori logici (TRUE per “Sì” e FALSE per “No”), potremmo avere:

```
opinion <- c(TRUE, FALSE, TRUE, TRUE, TRUE, FALSE, TRUE, TRUE, TRUE, FALSE)
opinion
```

```
[1] TRUE FALSE TRUE TRUE TRUE FALSE TRUE TRUE TRUE FALSE
```

In questo caso, TRUE e FALSE corrispondono a 1 e 0 rispettivamente quando utilizzati in operazioni numeriche. Lo stesso avviene in Python, dove True è interpretato come 1 e False come 0. Questa rappresentazione binaria permette di ottenere facilmente statistiche sintetiche. Per esempio, per calcolare la proporzione di risposte positive rispetto al totale, è sufficiente sommare i valori (contando così il numero di TRUE) e dividere per la lunghezza del vettore:

```
sum(opinion) / length(opinion)
```

```
[1] 0.7
```

Questo fornisce immediatamente la percentuale di studenti che hanno risposto “Sì” alla domanda.

B.2. Numeri interi

I numeri interi sono caratterizzati dall'assenza di componenti decimali. Essi includono sia i numeri naturali (1, 2, 3, ...), tradizionalmente utilizzati per il conteggio, sia i loro opposti negativi. L'insieme dei numeri naturali è indicato con $\mathbb{N}$, mentre l'insieme dei numeri interi (che include i numeri naturali, i loro negativi e lo zero) si denota con $\mathbb{Z}$:

$$\mathbb{Z} = \{0, \pm 1, \pm 2, \pm 3, \dots\}$$

Applicazione in psicologia: I numeri interi sono utilizzati per contare eventi discreti, come il numero di risposte corrette in un test, il numero di partecipanti in uno studio, o il numero di volte che un comportamento si manifesta.

B.3. Numeri razionali

I numeri razionali sono quei numeri che possono essere espressi come il rapporto tra due numeri interi, con il denominatore diverso da zero. Essi formano l'insieme:

$$\mathbb{Q} = \left\{ \frac{m}{n} \mid m, n \in \mathbb{Z}, n \neq 0 \right\}.$$

Poiché ogni numero naturale è anche un intero, e ogni intero può essere rappresentato come razionale (ad esempio $5 = \frac{5}{1}$), si ha una catena d'inclusioni tra i diversi insiemi di numeri:

$$\mathbb{N} \subseteq \mathbb{Z} \subseteq \mathbb{Q}.$$

Se si desidera considerare solo i numeri razionali non negativi, si utilizza la notazione:

$$\mathbb{Q}^+ = \{q \in \mathbb{Q} \mid q \geq 0\}.$$

Applicazione in psicologia: Le proporzioni e le percentuali (es. $0.75 = 75\%$ di risposte corrette) sono numeri razionali. Anche i punteggi standardizzati come i rapporti sono razionali.

B.4. Numeri irrazionali

Non tutti i numeri possono essere espressi come rapporto di due interi. I numeri che non hanno questa proprietà sono detti irrazionali. Essi non possono essere scritti in forma frazionaria e la loro espansione decimale è infinita e non periodica. Esempi tipici di numeri irrazionali sono:

- $\sqrt{2}$
- $\sqrt{3}$
- $\pi = 3.141592\dots$
- $e = 2.718281\dots$ (base del logaritmo naturale)

Nota: Sebbene i numeri irrazionali possano sembrare astratti, essi compaiono naturalmente nei calcoli statistici. Ad esempio, la costante e appare nella distribuzione normale, mentre π compare nella formula della densità gaussiana.

B.5. Numeri reali

I numeri razionali non coprono tutti i possibili punti sulla retta reale. Per rappresentare ogni possibile misura, grandezza o punto su una linea continua, si considerano i numeri reali, denotati con $\mathbb{R}$. L'insieme dei numeri reali comprende sia i razionali sia gli irrazionali:

$$\mathbb{N} \subseteq \mathbb{Z} \subseteq \mathbb{Q} \subseteq \mathbb{R}.$$

In statistica, la precisione con cui si esprime una misura è spesso legata al numero di cifre decimali utilizzate, sfruttando così appieno la “continuità” offerta dai numeri reali.

Applicazione in psicologia: Variabili continue come il tempo di reazione (in millisecondi), l'intensità di un'emozione misurata su scala continua, o il punteggio in un test psicometrico sono rappresentate come numeri reali.

B.6. Intervalli numerici

Definizione: Un **intervallo numerico** è un sottoinsieme connesso della retta reale. Intuitivamente, rappresenta tutti i numeri reali compresi tra due estremi, che possono o meno essere inclusi nell'intervallo stesso.

Classificazione degli intervalli: Gli intervalli vengono classificati in base all'inclusione o meno degli estremi:

- **Intervallo chiuso:** Include entrambi gli estremi. Si indica con $[a, b]$ e rappresenta l'insieme dei numeri reali x tali che $a \leq x \leq b$.
- **Intervallo aperto:** Non include alcun estremo. Si indica con (a, b) e rappresenta l'insieme dei numeri reali x tali che $a < x < b$.
- **Intervalli semiaperti:**

- **Chiuso a sinistra e aperto a destra:** Include l'estremo sinistro ma non quello destro. Si indica con $[a, b)$ e rappresenta l'insieme dei numeri reali x tali che $a \leq x < b$.
- **Aperto a sinistra e chiuso a destra:** Include l'estremo destro ma non quello sinistro. Si indica con $(a, b]$ e rappresenta l'insieme dei numeri reali x tali che $a < x \leq b$.

Tabella riassuntiva:

Intervallo	Notazione	Condizione	Esempio
Chiuso	$[a, b]$	$a \leq x \leq b$	$[0, 1]$ include 0 e 1
Aperto	(a, b)	$a < x < b$	$(0, 1)$ esclude 0 e 1
Chiuso a sinistra, aperto a destra	$[a, b)$	$a \leq x < b$	$[0, 1)$ include 0, esclude 1
Aperto a sinistra, chiuso a destra	$(a, b]$	$a < x \leq b$	$(0, 1]$ esclude 0, include 1

Osservazioni: * La scelta della notazione con parentesi quadre o tonde indica rispettivamente l'inclusione o l'esclusione degli estremi. * Gli intervalli infiniti sono indicati con i simboli $-\infty$ e $+\infty$. Ad esempio, $[0, +\infty)$ rappresenta tutti i numeri reali non negativi.

❗ Perché gli intervalli sono fondamentali per la probabilità

Gli intervalli sono essenziali per definire e calcolare probabilità con variabili casuali continue:

1. **Supporto delle distribuzioni:** Il supporto di una variabile casuale continua è spesso un intervallo. Ad esempio:

- La distribuzione uniforme è definita su $[a, b]$
- La distribuzione normale ha supporto $(-\infty, +\infty)$
- La distribuzione Beta ha supporto $[0, 1]$

2. **Calcolo di probabilità:** Per una variabile casuale continua X , la probabilità che X cada in un intervallo $[a, b]$ è:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

dove $f(x)$ è la funzione di densità di probabilità.

3. **Intervalli di credibilità:** Nell'inferenza bayesiana, gli intervalli di credibilità al 95% indicano un intervallo $[L, U]$ tale che:

$$P(L \leq \theta \leq U \mid \text{dati}) = 0.95$$

4. **Distinzione cruciale:** Notare che per variabili continue, $P(X = a) = 0$ per qualsiasi valore specifico a . Solo gli intervalli hanno probabilità non nulla, da cui l'importanza di questa notazione.

C. Sommatorie

Le somme sono uno strumento fondamentale in molti contesti matematici e statistici, e per gestirle in modo efficace è essenziale disporre di una notazione chiara e precisa. Consideriamo, ad esempio, la somma dei primi n numeri interi, che può essere espressa come $1 + 2 + \dots + (n-1) + n$, dove i puntini di sospensione (...) indicano che la sequenza deve essere completata seguendo il pattern definito dai termini precedenti e successivi. Tuttavia, una notazione come $1 + 7 + \dots + 73.6$ risulterebbe ambigua senza ulteriori specifiche. In generale, ci troveremo di fronte a somme della forma

$$x_1 + x_2 + \dots + x_n,$$

dove x_n rappresenta un numero definito altrove. Sebbene questa notazione con i puntini di sospensione sia utile in alcuni contesti, può risultare poco chiara in altri. Per questo motivo, si preferisce utilizzare la notazione di sommatoria:

$$\sum_{i=1}^n x_i,$$

che si legge “sommatoria per i che va da 1 a n di x_i ”. Il simbolo $\sum$ (la lettera sigma maiuscola dell’alfabeto greco) rappresenta l’operazione di somma, x_i è il generico addendo, mentre 1 e n sono gli *estremi della sommatoria*, che definiscono l’intervallo di variazione dell’indice i . Solitamente, l’estremo inferiore è 1, ma potrebbe essere qualsiasi altro numero $m < n$. Pertanto, possiamo scrivere:

$$\sum_{i=1}^n x_i = x_1 + x_2 + \dots + x_n.$$

Ad esempio, se i valori di x sono $\{3, 11, 4, 7\}$, avremo:

$$\sum_{i=1}^4 x_i = 3 + 11 + 4 + 7 = 25,$$

dove $x_1 = 3$, $x_2 = 11$, e così via. La quantità x_i è detta *argomento* della sommatoria, mentre la variabile i , che assume valori interi successivi, è chiamata *indice* della sommatoria.

La notazione di sommatoria può anche essere espressa nella forma:

$$\sum_{P(i)} x_i,$$

dove $P(i)$ è una proposizione logica riguardante i che può essere vera o falsa. Quando è evidente che si vogliono sommare tutte le n osservazioni, la notazione può essere semplificata in $\sum_i x_i$ o addirittura $\sum x_i$. L’indice i può essere sostituito da altre lettere, come $k, j, l, \dots$, a seconda del contesto.

C.1. Manipolazione di somme

Per semplificare i calcoli che coinvolgono le sommatorie, è utile conoscere alcune proprietà fondamentali.

C.1.1. Proprietà 1 (Somma di una costante)

La sommatoria di n valori tutti uguali a una costante a è pari a n volte la costante stessa:

$$\sum_{i=1}^n a = \underbrace{a + a + \cdots + a}_{n \text{ volte}} = na.$$

C.1.2. Proprietà 2 (Proprietà distributiva)

Se l'argomento della sommatoria contiene una costante, è possibile fattorizzarla. Ad esempio:

$$\sum_{i=1}^n ax_i = ax_1 + ax_2 + \cdots + ax_n = a(x_1 + x_2 + \cdots + x_n) = a \sum_{i=1}^n x_i.$$

C.1.3. Proprietà 3 (Proprietà associativa)

Se l'argomento della sommatoria è una somma, possiamo separare i termini:

$$\sum_{i=1}^n (a + x_i) = (a + x_1) + (a + x_2) + \cdots + (a + x_n) = na + \sum_{i=1}^n x_i.$$

In generale, possiamo scrivere:

$$\sum_{i=1}^n (x_i + y_i) = \sum_{i=1}^n x_i + \sum_{i=1}^n y_i.$$

C.1.4. Proprietà 4 (Operazioni algebriche)

Se è necessario eseguire un'operazione algebrica (come l'elevamento a potenza o il logaritmo) sull'argomento della sommatoria, questa operazione deve essere eseguita prima della somma. Ad esempio:

$$\sum_{i=1}^n x_i^2 = x_1^2 + x_2^2 + \cdots + x_n^2 \neq \left(\sum_{i=1}^n x_i \right)^2.$$

C.1.5. Proprietà 5 (Prodotto di termini)

Nel caso di un prodotto tra termini, il prodotto deve essere eseguito prima della somma:

$$\sum_{i=1}^n x_i y_i = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n.$$

Infatti, $a_1 b_1 + a_2 b_2 \neq (a_1 + a_2)(b_1 + b_2)$.

C.2. Doppia sommatoria

In alcuni contesti, si incontrano espressioni con una doppia sommatoria e un doppio indice:

$$\sum_{i=1}^n \sum_{j=1}^m x_{ij}.$$

Questa notazione implica che, per ogni valore dell'indice esterno i (da 1 a n), si deve sviluppare la sommatoria interna per j (da 1 a m). Ad esempio:

$$\sum_{i=1}^3 \sum_{j=4}^6 x_{ij} = (x_{1,4} + x_{1,5} + x_{1,6}) + (x_{2,4} + x_{2,5} + x_{2,6}) + (x_{3,4} + x_{3,5} + x_{3,6}).$$

Un caso particolare interessante è la doppia sommatoria del prodotto di due variabili:

$$\sum_{i=1}^n \sum_{j=1}^n x_i y_j.$$

In questo caso, poiché x_i non dipende dall'indice j , possiamo estrarre x_i dalla sommatoria interna:

$$\sum_{i=1}^n \left(x_i \sum_{j=1}^n y_j \right).$$

Allo stesso modo, la sommatoria interna $\sum_{j=1}^n y_j$ non dipende da i , quindi può essere estratta dalla sommatoria esterna:

$$\sum_{i=1}^n \sum_{j=1}^n x_i y_j = \left(\sum_{i=1}^n x_i \right) \left(\sum_{j=1}^n y_j \right).$$

C.2.1. Esempio pratico

Consideriamo i vettori $x = \{2, 3, 1\}$ e $y = \{1, 4, 9\}$. Calcoliamo la doppia sommatoria:

$$\begin{aligned}\sum_{i=1}^3 \sum_{j=1}^3 x_i y_j &= x_1 y_1 + x_1 y_2 + x_1 y_3 + x_2 y_1 + x_2 y_2 + x_2 y_3 + x_3 y_1 + x_3 y_2 + x_3 y_3 \\ &= 2 \times (1 + 4 + 9) + 3 \times (1 + 4 + 9) + 1 \times (1 + 4 + 9) \\ &= 2 \times 14 + 3 \times 14 + 1 \times 14 = 84.\end{aligned}$$

D'altra parte, il prodotto delle due sommatorie è:

$$\left(\sum_{i=1}^3 x_i \right) \left(\sum_{j=1}^3 y_j \right) = (2 + 3 + 1) \times (1 + 4 + 9) = 6 \times 14 = 84.$$

I due risultati coincidono, confermando la validità della proprietà.

Per ulteriori approfondimenti, si consiglia la consultazione del testo *Concrete Mathematics: A Foundation for Computer Science* (Graham et al., 1994).

Esercizi pratici sono disponibili sulla seguente [pagina web](#).

Bibliografia

D. Insiemi

Un insieme (o collezione, classe, gruppo, ...) è stato definito da Georg Cantor nel modo seguente:

un insieme è una collezione di oggetti, determinati e distinti, della nostra percezione o del nostro pensiero, concepiti come un tutto unico; tali oggetti si dicono elementi dell'insieme.

Mentre non è rilevante la natura degli oggetti che costituiscono l'insieme, ciò che importa è distinguere se un dato oggetto appartenga o meno ad un insieme. Deve essere vera una delle due possibilità: il dato oggetto è un elemento dell'insieme considerato oppure non è elemento dell'insieme considerato. Due insiemi A e B si dicono uguali se sono formati dagli stessi elementi, anche se disposti in ordine diverso: $A = B$. Due insiemi A e B si dicono diversi se non contengono gli stessi elementi: $A \neq B$. Ad esempio, i seguenti insiemi sono uguali:

$$\{1, 2, 3\} = \{3, 1, 2\} = \{1, 3, 2\} = \{1, 1, 1, 2, 3, 3, 3\}.$$

Gli insiemi sono denotati da una lettera maiuscola, mentre le lettere minuscole, di solito, designano gli elementi di un insieme. Per esempio, un generico insieme A si indica con

$$A = \{a_1, a_2, \dots, a_n\}, \quad \text{con } n > 0.$$

La scrittura $a \in A$ dice che a è un elemento di A . Per dire che b non è un elemento di A si scrive $b \notin A$.

Per quegli insiemi i cui elementi soddisfano una certa proprietà che li caratterizza, tale proprietà può essere usata per descrivere più sinteticamente l'insieme:

$$A = \{x \mid \text{proprietà posseduta da } x\},$$

che si legge come “ A è l'insieme degli elementi x per cui è vera la proprietà indicata.” Per esempio, per indicare l'insieme A delle coppie di numeri reali (x, y) che appartengono alla parabola $y = x^2 + 1$ si può scrivere:

$$A = \{(x, y) \mid y = x^2 + 1\}.$$

Dati due insiemi A e B , diremo che A è un *sottoinsieme* di B se e solo se tutti gli elementi di A sono anche elementi di B :

$$A \subseteq B \iff (\forall x \in A \Rightarrow x \in B).$$

Se esiste almeno un elemento di B che non appartiene ad A allora diremo che A è un *sottoinsieme proprio* di B :

$$A \subset B \iff (A \subseteq B, \exists x \in B \mid x \notin A).$$

Un altro insieme, detto *insieme delle parti*, o insieme potenza, che si associa all'insieme A è l'insieme di tutti i sottoinsiemi di A , inclusi l'insieme vuoto e A stesso. Per esempio, per l'insieme $A = \{a, b, c\}$, l'insieme delle parti è:

$$\mathcal{P}(A) = \{\emptyset, \{a\}, \{b\}, \{c\}, \{a, b\}, \{a, c\}, \{b, c\}, \{a, b, c\}\}.$$

D.1. Diagrammi di Eulero-Venn

I diagrammi di Venn sono uno strumento grafico molto utile per rappresentare gli insiemi e per verificare le proprietà delle operazioni tra di essi. Questi diagrammi prendono il nome dal matematico inglese del 19° secolo John Venn, anche se rappresentazioni simili erano già state utilizzate in precedenza da Leibniz e Eulero.

I diagrammi di Venn rappresentano gli insiemi come regioni del piano delimitate da una curva chiusa. Nel caso di insiemi finiti, è possibile evidenziare alcuni elementi di un insieme tramite punti, e in alcuni casi possono essere evidenziati tutti gli elementi degli insiemi considerati.

In sostanza, questi diagrammi sono un modo visuale per rappresentare le proprietà degli insiemi e delle operazioni tra di essi. Sono uno strumento molto utile per visualizzare la relazione tra gli insiemi e per capire meglio come si combinano gli elementi all'interno di essi.

D.2. Operazioni tra insiemi

Si definisce *intersezione* di A e B l'insieme $A \cap B$ di tutti gli elementi x che appartengono ad A e contemporaneamente a B :

$$A \cap B = \{x \mid x \in A \wedge x \in B\}.$$

Si definisce *unione* di A e B l'insieme $A \cup B$ di tutti gli elementi x che appartengono ad A o a B , cioè

$$A \cup B = \{x \mid x \in A \vee x \in B\}.$$

Differenza. Si indica con $A \setminus B$ l'insieme degli elementi di A che non appartengono a B :

$$A \setminus B = \{x \mid x \in A \wedge x \notin B\}.$$

Insieme complementare. Nel caso che sia $B \subseteq A$, l'insieme differenza $A \setminus B$ è detto insieme complementare di B in A e si indica con B^C .

Dato un insieme S , una *partizione* di S è una collezione di sottoinsiemi di S , $S_1, \dots, S_k$, tali che

$$S = S_1 \cup S_2 \cup \dots \cup S_k$$

e

$$S_i \cap S_j = \emptyset, \quad \text{con } i \neq j.$$

La relazione tra unione, intersezione e insieme complementare è data dalle leggi di DeMorgan:

$$(A \cup B)^c = A^c \cap B^c,$$

$$(A \cap B)^c = A^c \cup B^c.$$

In tutte le seguenti figure, S è la regione delimitata dal rettangolo, L è la regione all'interno del cerchio di sinistra e R è la regione all'interno del cerchio di destra. La regione evidenziata mostra l'insieme indicato sotto ciascuna figura.




Figura D.1.: Diagrammi di Venn

I diagrammi di Eulero-Venn che illustrano le leggi di DeMorgan sono forniti nella figura seguente.




Figura D.2.: Leggi di DeMorgan

D.3. Implementazione in R

Vediamo ora come implementare in R i concetti fondamentali della teoria degli insiemi. Gli esempi sono volutamente concisi per servire come riferimento rapido.

D.3.1. Appartenenza e relazioni base

```
# Definire insiemi
my_set <- c(1, 3, 5)
Super <- c(2, 4, 6, 8)
Sub <- c(4, 6)

# Verificare appartenenza
1 %in% my_set      # TRUE
```

```
[1] TRUE
```

```
2 %in% my_set      # FALSE
```

```
[1] FALSE
```

```
# Verificare se Sub è sottoinsieme di Super
all(Sub %in% Super) # TRUE
```

```
[1] TRUE
```

D.3.2. Operazioni tra insiemi

```
S1 <- c(1, 2, 3, 4, 5)
S2 <- c(4, 5, 6, 7, 8)

# Intersezione
intersect(S1, S2)      # {4, 5}
```

```
[1] 4 5
```

```
# Unione
union(S1, S2)          # {1, 2, 3, 4, 5, 6, 7, 8}
```

```
[1] 1 2 3 4 5 6 7 8
```

```
# Differenza
setdiff(S1, S2)        # {1, 2, 3}
```

```
[1] 1 2 3
```

```
setdiff(S2, S1)        # {6, 7, 8}
```

```
[1] 6 7 8
```

```
# Complementare (rispetto a un universo)
universo <- 1:10
S <- c(2, 4, 6, 8, 10)
setdiff(universo, S)      # {1, 3, 5, 7, 9}
```

```
[1] 1 3 5 7 9
```

D.4. Coppie ordinate e prodotto cartesiano

Una coppia ordinata (x, y) è l'insieme i cui elementi sono $x \in A$ e $y \in B$ e nella quale x è la prima componente (o prima coordinata) e y la seconda. L'insieme di tutte le coppie ordinate costruite a partire dagli insiemi A e B viene detto **prodotto cartesiano**:

$$A \times B = \{(x, y) \mid x \in A \wedge y \in B\}.$$

Ad esempio, sia $A = \{1, 2, 3\}$ e $B = \{a, b\}$. Allora,

$$\{1, 2\} \times \{a, b, c\} = \{(1, a), (1, b), (1, c), (2, a), (2, b), (2, c)\}.$$

Più in generale, un prodotto cartesiano di n insiemi può essere rappresentato da un array di n dimensioni, dove ogni elemento è una ennupla o tupla ordinata (ovvero, una collezione o un elenco ordinato di n oggetti). Una n -pla ordinata si distingue da un insieme di n elementi in quanto fra gli elementi di un insieme non è dato alcun ordine. Inoltre gli elementi di una ennupla possono anche essere ripetuti. Essendo la n -pla un elenco ordinato, in generale di ogni suo elemento è possibile dire se sia il primo, il secondo, il terzo, eccetera, fino all' n -esimo. Il prodotto cartesiano prende il nome da René Descartes la cui formulazione della geometria analitica ha dato origine al concetto.

```
A <- c("a", "b", "c")
S <- 1:3

# Prodotto cartesiano
cartesian_product <- expand.grid(A, S)
print(cartesian_product)
```

	Var1	Var2
1	a	1
2	b	1
3	c	1
4	a	2
5	b	2
6	c	2
7	a	3
8	b	3
9	c	3

```
# Cardinalità del prodotto
nrow(cartesian_product) # 9 = 3 × 3
```

[1] 9

Si definisce *cardinalità* (o potenza) di un insieme finito il numero degli elementi dell'insieme. Viene indicata con $|A|$, $\#(A)$ o $c(A)$.

Esempio: potenza del prodotto cartesiano

```
A <- c("Head", "Tail")  
  
# A2: prodotto cartesiano di A con se stesso  
p2 <- expand.grid(A, A)  
nrow(p2) # 4 = 22
```

[1] 4

```
# A3  
p3 <- expand.grid(A, A, A)  
nrow(p3) # 8 = 23
```

[1] 8

i Collegamento al calcolo delle probabilità

Gli insiemi e il loro prodotto cartesiano sono fondamentali per definire lo spazio campionario negli esperimenti casuali. Ad esempio, il lancio di due monete ha spazio campionario $\Omega = \{\text{Testa, Croce}\} \times \{\text{Testa, Croce}\}$, con cardinalità $|\Omega| = 4$.

E. Calcolo combinatorio

```
here::here("code", "_common.R") |>
  source()

if (!requireNamespace("pacman")) install.packages("pacman")
pacman::p_load(gtools, combinat)
```

Il **calcolo combinatorio** studia il numero di modi in cui è possibile combinare, ordinare o disporre elementi appartenenti a uno o più insiemi, seguendo regole ben definite. Molti problemi di probabilità richiedono strumenti combinatori per determinare la probabilità di eventi complessi. In questo capitolo, esploreremo i concetti fondamentali del calcolo combinatorio, illustrandoli attraverso il modello del **campionamento dall'urna**. Tratteremo i principi della somma e del prodotto, fondamentali per affrontare problemi più avanzati, come permutazioni, disposizioni e combinazioni.

E.1. Principio della somma

Il **principio della somma** si applica quando un insieme di elementi può essere suddiviso in **sottoinsiemi disgiunti** (ossia senza sovrapposizioni). In questo caso, il numero totale di elementi è dato dalla somma delle cardinalità dei sottoinsiemi:

$$n_{\text{tot}} = n_1 + n_2 + \dots + n_k.$$

Esempio

Un distributore contiene tre scomparti di caramelle, ciascuno con un diverso tipo di dolci:

- **Scomparto A:** 10 caramelle alla menta,
- **Scomparto B:** 8 caramelle alla frutta,
- **Scomparto C:** 12 caramelle al cioccolato.

Quante caramelle ci sono in totale nel distributore?

Secondo il **principio della somma**, il numero totale di caramelle è:

$$n_{\text{tot}} = n_A + n_B + n_C = 10 + 8 + 12 = 30.$$

Calcolo in R:

```
A <- 10
B <- 8
C <- 12

totale_caramelle <- A + B + C
totale_caramelle
#> [1] 30
```

Risultato: Nel distributore ci sono **30 caramelle** in totale.

E.2. Principio del prodotto

Il **principio del prodotto** si applica quando un'operazione può essere suddivisa in più **fasi indipendenti**, ciascuna con un numero specifico di possibilità. In tal caso, il numero totale di combinazioni è dato dal **prodotto** delle possibilità offerte da ciascuna fase:

$$n_{\text{tot}} = n_1 \cdot n_2 \cdot \dots \cdot n_k.$$

Esempio

Supponiamo di avere quattro urne contenenti palline di diverso colore:

- **Urna A:** 5 palline,
- **Urna B:** 6 palline,
- **Urna C:** 3 palline,
- **Urna D:** 2 palline.

Vogliamo formare insiemi di due palline, ciascuna estratta da urne differenti.

Secondo il **principio del prodotto**, per ogni coppia di urne, il numero di combinazioni è dato dal prodotto del numero di palline contenute nelle due urne. Utilizziamo poi il **principio della somma** per ottenere il totale complessivo:

$$n_{\text{tot}} = AB + AC + AD + BC + BD + CD.$$

Calcolo in R:

```
AB <- 5 * 6
AC <- 5 * 3
AD <- 5 * 2
BC <- 6 * 3
BD <- 6 * 2
CD <- 3 * 2

totale_insiemi <- AB + AC + AD + BC + BD + CD
totale_insiemi
#> [1] 91
```

Risultato: È possibile formare **91 insiemi** di due palline, ciascuna estratta da urne differenti.

E.3. Il modello dell'urna e i metodi di campionamento

Molti problemi di calcolo combinatorio possono essere interpretati come **estrazioni di palline da un'urna**. Esistono quattro modi fondamentali di effettuare un campionamento, a seconda che:

1. le estrazioni siano con o senza ripetizione,
2. l'ordine degli elementi conti o meno.

Queste quattro combinazioni danno origine a quattro principali metodi di campionamento:

1. **Con ripetizione e con ordine:** Dopo ogni estrazione, la pallina viene rimessa nell'urna. (Es. formazione di codici numerici con ripetizioni)
2. **Senza ripetizione e con ordine:** Ogni estrazione rimuove definitivamente la pallina dall'urna. (Es. assegnare premi in una gara)
3. **Con ripetizione e senza ordine:** Si considerano i gruppi di elementi senza preoccuparsi dell'ordine. (Es. selezionare un certo numero di ingredienti da una dispensa)
4. **Senza ripetizione e senza ordine:** Si scelgono elementi distinti senza considerare l'ordine. (Es. formare squadre da un gruppo di persone)

Esempio E.1.

```
urna <- c("a", "b", "c")

# Con ripetizione e ordine
campionamento1 <- expand.grid(urna, urna) |>
  rename(Elemento1 = Var1, Elemento2 = Var2)

# Senza ripetizione e con ordine
campionamento2 <- permutations(n = length(urna), r = 2, v = urna) |>
  as.data.frame() |>
  rename(Elemento1 = V1, Elemento2 = V2)

# Con ripetizione e senza ordine
campionamento3 <- combinations(
  n = length(urna), r = 2, v = urna, repeats.allowed = TRUE
) |>
  as.data.frame() |>
  rename(Elemento1 = V1, Elemento2 = V2)

# Senza ripetizione e senza ordine
campionamento4 <- combinations(n = length(urna), r = 2, v = urna) |>
  as.data.frame() |>
  rename(Elemento1 = V1, Elemento2 = V2)

# Risultati
list(
  `Con ripetizione e ordine` = campionario1,
  `Senza ripetizione e con ordine` = campionario2,
  `Con ripetizione e senza ordine` = campionario3,
```

```

`Senza ripetizione e senza ordine` = campionamento4
)
#> $`Con ripetizione e ordine`
#>   Elemento1 Elemento2
#> 1         a         a
#> 2         b         a
#> 3         c         a
#> 4         a         b
#> 5         b         b
#> 6         c         b
#> 7         a         c
#> 8         b         c
#> 9         c         c
#>
#> $`Senza ripetizione e con ordine`
#>   Elemento1 Elemento2
#> 1         a         b
#> 2         a         c
#> 3         b         a
#> 4         b         c
#> 5         c         a
#> 6         c         b
#>
#> $`Con ripetizione e senza ordine`
#>   Elemento1 Elemento2
#> 1         a         a
#> 2         a         b
#> 3         a         c
#> 4         b         b
#> 5         b         c
#> 6         c         c
#>
#> $`Senza ripetizione e senza ordine`
#>   Elemento1 Elemento2
#> 1         a         b
#> 2         a         c
#> 3         b         c

```

E.4. Permutazioni: Disporre tutti gli elementi con ordine

Le **permutazioni** rappresentano tutti i modi in cui è possibile ordinare n elementi distinti. Il numero di permutazioni è dato da:

$$P_n = n!$$

dove $n!$ (n fattoriale) è il prodotto di tutti i numeri da 1 a n :

$$n! = n \cdot (n - 1) \cdot (n - 2) \cdot \dots \cdot 1.$$

E.4.1. Intuizione della formula

Immaginiamo di avere n **elementi distinti** e di doverli disporre in una sequenza. Il primo elemento può essere scelto in n **modi**. Una volta scelto il primo, rimangono $n - 1$ **possibilità** per il secondo, poi $n - 2$ per il terzo e così via, fino all'ultimo elemento, che avrà **1 sola possibilità**. Applicando il **principio del prodotto**, otteniamo:

$$P_n = n \times (n - 1) \times (n - 2) \times \cdots \times 1 = n!$$

E.4.2. Metodo di campionamento corrispondente

- **Campionamento senza ripetizione e con ordine:** si estrae una pallina, la si esclude dall'urna e si continua fino a esaurire gli elementi.
- **Esempio pratico:** Ordinare i partecipanti di una gara su un podio (primo, secondo e terzo classificato).

E.4.3. Esempio in R: Permutazioni di tre elementi

Se abbiamo tre lettere {a, b, c}, le possibili permutazioni sono:

$$P_3 = 3! = 3 \times 2 \times 1 = 6.$$

```
A <- c("a", "b", "c")
perm <- permutations(n = length(A), r = length(A), v = A)
print(perm)
#>      [,1] [,2] [,3]
#> [1,] "a"  "b"  "c"
#> [2,] "a"  "c"  "b"
#> [3,] "b"  "a"  "c"
#> [4,] "b"  "c"  "a"
#> [5,] "c"  "a"  "b"
#> [6,] "c"  "b"  "a"
nrow(perm) # Verifica del numero di permutazioni
#> [1] 6
```

Risultato:

$$\{a, b, c\}, \{a, c, b\}, \{b, a, c\}, \{b, c, a\}, \{c, a, b\}, \{c, b, a\}.$$

E.5. Disposizioni: Selezionare alcuni elementi con ordine

Le **disposizioni** si usano quando si scelgono k elementi da un insieme di n , rispettando l'ordine. Il numero totale di disposizioni è:

$$D_{n,k} = \frac{n!}{(n - k)!}.$$

E.5.1. Intuizione della formula

Supponiamo di avere n **elementi** e di voler scegliere solo k **elementi**, mantenendo l'ordine.

- il primo elemento può essere scelto in n **modi**;
- il secondo elemento può essere scelto tra gli $n - 1$ **elementi rimanenti**;
- il terzo tra gli $n - 2$ rimanenti.

Si prosegue fino a quando si hanno scelto k **elementi**, fermandosi prima di esaurire tutti gli elementi.

$$D_{n,k} = n \times (n - 1) \times (n - 2) \times \cdots \times (n - k + 1).$$

Questa espressione corrisponde alla divisione del fattoriale di n per il fattoriale degli elementi che non vengono selezionati:

$$D_{n,k} = \frac{n!}{(n - k)!}.$$

E.5.2. Metodo di campionamento corrispondente

- **Campionamento senza ripetizione e con ordine:** si estrae una pallina, la si esclude dall'urna e si continua fino a raggiungere il numero desiderato di elementi, fermandosi prima di esaurire tutti gli elementi.
- **Esempio pratico:** Estrarre casualmente 2 studenti da una classe di 10 e assegnare loro i ruoli di rappresentante e vice-rappresentante (l'ordine conta).

E.5.3. Esempio in R: Disposizioni di 2 elementi da {a, b, c}

Se scegliamo 2 lettere su 3, il numero di disposizioni è:

$$D_{3,2} = \frac{3!}{(3 - 2)!} = \frac{3 \times 2 \times 1}{1} = 6.$$

```
disp <- permutations(n = length(A), r = 2, v = A)
print(disp)
#>      [,1] [,2]
#> [1,] "a"  "b"
#> [2,] "a"  "c"
#> [3,] "b"  "a"
#> [4,] "b"  "c"
#> [5,] "c"  "a"
#> [6,] "c"  "b"
nrow(disp) # Verifica del numero di disposizioni
#> [1] 6
```

Risultato:

$$\{a, b\}, \{a, c\}, \{b, a\}, \{b, c\}, \{c, a\}, \{c, b\}.$$

Le disposizioni **considerano l'ordine**, quindi $\{a, b\}$ è diverso da $\{b, a\}$.

E.6. Combinazioni: Selezionare alcuni elementi senza ordine

Le **combinazioni** rappresentano il numero di modi per scegliere k elementi da n **senza considerare l'ordine**. Il numero di combinazioni è dato da:

$$C_{n,k} = \binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

E.6.1. Intuizione della formula

Supponiamo di avere n **elementi** e di voler selezionare k **elementi senza considerare l'ordine**. Come nel caso delle disposizioni, il primo elemento può essere scelto in n **modi**, il secondo in $n - 1$, e così via fino a selezionare k **elementi**.

$$D_{n,k} = n \times (n - 1) \times \dots \times (n - k + 1).$$

Tuttavia, in questo caso, l'ordine **non** conta, quindi ogni selezione viene **duplicata** per il numero di modi in cui i k elementi possono essere ordinati, ossia $k!$ **permutazioni interne**. Per correggere questa duplicazione, dobbiamo dividere per $k!$:

$$C_{n,k} = \frac{D_{n,k}}{k!} = \frac{n!}{k!(n-k)!}.$$

E.6.2. Metodo di campionamento corrispondente

- **Campionamento senza ripetizione e senza ordine:** si estrae una pallina e la si esclude dall'urna, ma non importa l'ordine in cui le palline vengono estratte.
- **Esempio pratico:** Formare una squadra di 2 studenti da un gruppo di 10 senza assegnare ruoli specifici (quindi $\{a, b\}$ è uguale a $\{b, a\}$).

E.6.3. Esempio in R: Combinazioni di 2 elementi da {a, b, c}

Se scegliamo 2 lettere su 3 senza considerare l'ordine, otteniamo:

$$C_{3,2} = \binom{3}{2} = \frac{3!}{2!(3-2)!} = \frac{3 \times 2 \times 1}{2 \times 1 \times 1} = 3.$$

```

comb <- combinations(n = length(A), r = 2, v = A)
print(comb)
#>      [,1] [,2]
#> [1,] "a"  "b"
#> [2,] "a"  "c"
#> [3,] "b"  "c"
nrow(comb) # Verifica del numero di combinazioni
#> [1] 3

```

Risultato:

$$\{a, b\}, \{a, c\}, \{b, c\}.$$

Le combinazioni **non considerano l'ordine**, quindi $\{a, b\}$ è uguale a $\{b, a\}$.

E.7. Sintesi: Quando usare ciascun metodo?

Metodo	Ripetizione?	Ordine?	Formula	Metodo di campionamento
Permutazioni	☒ No	☒ Sì	$n!$	Senza ripetizione e con ordine
Disposizioni	☒ No	☒ Sì	$\frac{n!}{(n-k)!}$	Senza ripetizione e con ordine
Combinazioni	☒ No	☒ No	$\binom{n}{k} = \frac{n!}{k!(n-k)!}$	Senza ripetizione e senza ordine

In conclusione, abbiamo visto come il **modello dell'urna** aiuti a comprendere i problemi combinatori. Le differenze tra **permutazioni**, **disposizioni** e **combinazioni** dipendono da due fattori fondamentali: **ripetizione** e **ordine**.

Questa classificazione è essenziale per risolvere problemi di probabilità e statistica in modo rigoroso. Gli esempi e il codice R forniscono strumenti concreti per applicare questi concetti nella pratica.

! Importante

Questi concetti sono fondamentali per comprendere la distribuzione binomiale (Capitolo 12).

F. Per liberarvi dai terrori preliminari

In questo capitolo, traduciamo e adattiamo il capitolo *Per liberarvi dai terrori preliminari* tratto da *Calculus made easy*.

! Superare i terrori preliminari

Il terrore preliminare, che spesso impedisce agli studenti di avvicinarsi all'analisi matematica, può essere superato comprendendo il significato intuitivo dei due simboli principali utilizzati in questo campo.

Questi simboli, che possono sembrare intimidatori, sono in realtà molto semplici:

1. d : Questo simbolo significa semplicemente “un po' di”. Ad esempio, dx indica un piccolo incremento di x , mentre du rappresenta un piccolo incremento di u . I matematici preferiscono dire “un elemento di” invece di “un po' di”, ma il concetto è lo stesso. Questi piccoli incrementi possono essere considerati infinitamente piccoli.
2. $\int$: Questo simbolo è una S allungata e rappresenta “la somma di”. Quindi, $\int dx$ significa la somma di tutti i piccoli incrementi di x , mentre $\int dt$ indica la somma di tutti i piccoli incrementi di t . I matematici chiamano questo simbolo “integrale”. Se consideri x come composto da tanti piccoli pezzi dx , sommandoli tutti otterrai l'intero valore di x . La parola “integrale” significa semplicemente “il tutto”. Ad esempio, se pensi a un'ora come composta da 3600 secondi, la somma di tutti questi secondi ti darà un'ora. Quando vedi un'espressione che inizia con $\int$, significa che devi sommare tutti i piccoli pezzi indicati dai simboli che seguono.

Ecco, il terrore è svanito!

F.1. Integrali

F.1.1. Intuizione e verifica con simulazioni in R

Per calcolare e visualizzare l'integrale di una funzione di densità, possiamo utilizzare il linguaggio di programmazione R. Consideriamo come esempio la funzione di densità gaussiana, definita dalla seguente formula:

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

In R, possiamo definire questa funzione come segue:

```
gaussian <- function(x, mu, sigma) {  
  1 / (sigma * sqrt(2 * pi)) * exp(-((x - mu)^2) / (2 * sigma^2))  
}
```


Definiamo i parametri e generiamo i valori per il calcolo della funzione di densità su un intervallo:

```
mu <- 0      # Media
sigma <- 1    # Deviazione standard
a <- -10     # Limite inferiore
b <- 10      # Limite superiore
n <- 10000   # Numero di punti

x_range <- seq(a, b, length.out = n) # Valori x
fx <- gaussian(x_range, mu, sigma)   # Ordinata della funzione
```

Visualizziamo la funzione utilizzando il pacchetto ggplot2:

```
ggplot(data.frame(x = x_range, fx = fx), aes(x, fx)) +
  geom_line() +
  scale_fill_qualitative() +
  labs(
    title = "Funzione di densità gaussiana",
    x = "x",
    y = "f(x)"
  )
```



F.1.2. Approssimare l'integrale: il metodo dei rettangoli

L'idea fondamentale è che l'integrale rappresenta l'area sotto la curva. Possiamo approssimarla sommando i prodotti $\Delta x \cdot f(x)$, dove Δx è la larghezza di piccoli rettangoli:

```
integral_approximation <- function(f, a, b, n) {
  delta <- (b - a) / n
  sum(delta * f)
}
```

```
# Calcolo dell'integrale approssimato sull'intero dominio
approx <- integral_approximation(fx, a, b, n)
approx
#> [1] 1
```

Confrontiamo il risultato con il calcolo fornito dalla funzione `integrate` di R:

```
integrate(
  function(x) gaussian(x, mu, sigma),
  lower = a,
  upper = b
)
#> 1 with absolute error < 0.000074
```

F.1.3. Esempio applicato: intervallo di confidenza al 95%

Calcoliamo l'area sotto la curva nell'intervallo $[-1.96, 1.96]$, che corrisponde al 95% dell'area nella distribuzione normale standard. Questo è un calcolo fondamentale in statistica per gli intervalli di confidenza.

```
a <- -1.96
b <- 1.96
x_range <- seq(a, b, length.out = n)
fx <- gaussian(x_range, mu, sigma)

# Approssimazione
approx <- integral_approximation(fx, a, b, n)
cat("Approssimazione numerica:", approx, "\n")
#> Approssimazione numerica: 0.95

# Valore esatto
exact <- integrate(
  function(x) gaussian(x, mu, sigma),
  lower = a,
  upper = b
)
cat("Integrale esatto:", exact$value, "\n")
#> Integrale esatto: 0.95
```

Come previsto, otteniamo circa 0.95 (95%), confermando che l'integrale calcola correttamente l'area sotto la curva.

Collegamento alla probabilità

In statistica bayesiana, gli integrali sono fondamentali per calcolare:

- La costante di normalizzazione di una distribuzione di probabilità
- Distribuzioni marginali (integrando su parametri di disturbo)
- Valori attesi e varianze di distribuzioni continue

F.2. Potenze

Le potenze sono un'operazione matematica che rappresenta un prodotto ripetuto. Si indicano generalmente come:

$$a^n,$$

dove:

- a è la **base**,
- n è l'**esponente**.

La potenza rappresenta il prodotto della base a ripetuto n volte.

F.2.1. Definizione di potenza

$$a^n = \underbrace{a \cdot a \cdot \dots \cdot a}_{n \text{ fattori}} \quad \text{con } n \in \mathbb{N}.$$

Ad esempio:

- $2^3 = 2 \cdot 2 \cdot 2 = 8$,
 - $3^4 = 3 \cdot 3 \cdot 3 \cdot 3 = 81$.
-

F.2.2. Proprietà delle potenze

1. Moltiplicazione di potenze con la stessa base:

$$a^m \cdot a^n = a^{m+n}$$

Esempio: $2^3 \cdot 2^2 = 2^{3+2} = 2^5 = 32$.

2. Divisione di potenze con la stessa base:

$$\frac{a^m}{a^n} = a^{m-n}, \quad \text{con } m \geq n.$$

Esempio: $\frac{5^4}{5^2} = 5^{4-2} = 5^2 = 25$.

3. Potenze di potenze:

$$(a^m)^n = a^{m \cdot n}.$$

Esempio: $(3^2)^3 = 3^{2 \cdot 3} = 3^6 = 729$.

4. Prodotto di potenze con basi diverse ma lo stesso esponente:

$$a^n \cdot b^n = (a \cdot b)^n.$$

Esempio: $2^3 \cdot 3^3 = (2 \cdot 3)^3 = 6^3 = 216.$

5. Divisione di potenze con basi diverse ma lo stesso esponente:

$$\frac{a^n}{b^n} = \left(\frac{a}{b}\right)^n.$$

Esempio: $\frac{4^2}{2^2} = \left(\frac{4}{2}\right)^2 = 2^2 = 4.$

6. Esponente zero:

$$a^0 = 1, \quad \text{con } a \neq 0.$$

Esempio: $5^0 = 1.$

7. Esponente negativo:

$$a^{-n} = \frac{1}{a^n}.$$

Esempio: $2^{-3} = \frac{1}{2^3} = \frac{1}{8}.$

8. Radice come potenza frazionaria:

$$a^{\frac{1}{n}} = \sqrt[n]{a}, \quad a^{\frac{m}{n}} = \sqrt[n]{a^m}.$$

Esempio: $8^{\frac{1}{3}} = \sqrt[3]{8} = 2.$

F.2.3. Esempi pratici**1. Calcolo semplice:**

$$4^3 = 4 \cdot 4 \cdot 4 = 64.$$

2. Utilizzo delle proprietà:

$$3^5 \cdot 3^2 = 3^{5+2} = 3^7 = 2187.$$

3. Divisione:

$$\frac{6^4}{6^2} = 6^{4-2} = 6^2 = 36.$$

4. **Esponente negativo:**

$$10^{-2} = \frac{1}{10^2} = \frac{1}{100} = 0.01.$$

5. **Radice come potenza:**

$$16^{\frac{1}{2}} = \sqrt{16} = 4.$$

F.2.4. Nota sui numeri razionali e reali

- Le potenze con esponenti interi sono definite per ogni base.
- Le potenze con esponenti frazionari o reali richiedono che la base sia positiva per evitare ambiguità.

F.3. Logaritmi

Il logaritmo è una funzione matematica che risponde alla domanda: “quante volte devo moltiplicare un certo numero (chiamato “base”) per ottenere un altro numero?” Matematicamente, questo è espresso come:

$$\log_b(a) = x \iff b^x = a$$

Ad esempio, $\log_2(8) = 3$ perché $2^3 = 8$.

Nel contesto dei logaritmi, i valori molto piccoli (compresi tra 0 e 1) diventano più grandi (in termini assoluti) e negativi quando applichiamo una funzione logaritmica. Questo è utile per stabilizzare i calcoli, specialmente quando lavoriamo con prodotti di numeri molto piccoli che potrebbero portare a problemi di underflow.

Per esempio:

- $\log(1) = 0$
- $\log(0.1) = -1$
- $\log(0.01) = -2$
- $\log(0.001) = -3$

Come si può vedere, i valori assoluti dei logaritmi crescono man mano che il numero originale si avvicina a zero.

F.3.1. Proprietà fondamentali dei logaritmi

Una delle proprietà più utili dei logaritmi è che consentono di trasformare un prodotto in una somma:

$$\log_b(a \times c) = \log_b(a) + \log_b(c)$$

Questa proprietà è estremamente utile in calcoli complessi, come nella statistica bayesiana, dove il prodotto di molte probabilità potrebbe diventare un numero molto piccolo e causare problemi numerici.

Un'altra proprietà utile dei logaritmi è che un rapporto tra due numeri diventa la differenza dei loro logaritmi:

$$\log_b\left(\frac{a}{c}\right) = \log_b(a) - \log_b(c)$$

Anche questa proprietà è molto utilizzata in matematica, specialmente in situazioni in cui è necessario normalizzare i dati.

Applicazione alla verosimiglianza bayesiana

Nell'inferenza bayesiana, si lavora spesso con la **log-verosimiglianza** invece della verosimiglianza:

$$\log \mathcal{L}(\theta) = \sum_{i=1}^n \log p(y_i | \theta)$$

Questo trasforma il prodotto di probabilità in una somma, rendendo i calcoli numericamente stabili e computazionalmente efficienti.

In sintesi, i logaritmi sono strumenti potenti per semplificare e stabilizzare i calcoli matematici. Essi consentono di lavorare più agevolmente con numeri molto grandi o molto piccoli e di trasformare operazioni complesse come prodotti e divisioni in somme e differenze, rendendo i calcoli più gestibili e meno inclini a errori numerici.

Blitzstein, J. K., & Hwang, J. (2019). *Introduction to probability*. CRC Press.

Chivers, T. (2024). *Everything is Predictable: How Bayesian Statistics Explain Our World*. Simon; Schuster.

Cohen, J. (1988). *Statistical power analysis for the behavior science*. Lawrence Erlbaum Association.

Domini, F., & Caudek, C. (2011). Combining Image Signals before Three-Dimensional Reconstruction: The Intrinsic Constraint Model of Cue Integration. In J. Trommershäuser, K. Körding, & M. S. Landy (A c. Di), *Sensory Cue Integration* (pp. 120–143). Oxford University Press. <https://doi.org/10.1093/acprof:oso/9780195387247.003.0008>

Eysenck, M. W., Derakshan, N., Santos, R., & Calvo, M. G. (2007). Anxiety and cognitive performance: attentional control theory. *Emotion*, 7(2), 336–353.

Finetti, B. de. (1970). *Teoria delle probabilità* (pp. VIII, 350–769). G. Einaudi.

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3^a ed.). Chapman and Hall/CRC.

Graham, R. L., Knuth, D. E., & Patashnik, O. (1994). *Concrete Mathematics: A Foundation for Computer Science* (2nd ed.). Addison-Wesley.

Griffiths, T. L., Chater, N., & Tenenbaum, J. B. (2024). *Bayesian models of cognition: reverse engineering the mind*. MIT Press.

- Heard, N. (2021). *An introduction to Bayesian inference, methods and computation*. Springer.
- Jackson, E. G. (2020). The relationship between belief and credence. *Philosophy Compass*, 15(6), e12668.
- Johnson, A. A., Ott, M., & Dogucu, M. (2022). *Bayes Rules! An Introduction to Bayesian Modeling with R*. CRC Press.
- Kruschke, J. (2014). *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan*. Academic Press.
- McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan* (2nd Edition). CRC Press.
- Schervish, M. J., & DeGroot, M. H. (2014). *Probability and statistics* (Vol. 563). Pearson Education London, UK:
- Segal, A., Tiego, J., Parkes, L., Holmes, A. J., Marquand, A. F., & Fornito, A. (2025). Embracing variability in the search for biological mechanisms of psychiatric illness. *Trends in Cognitive Sciences*, 29(1), 85–99.
- Spiegelhalter, D. (2024). Why probability probably doesn't exist (but it is useful to act like it does). *Nature*, 636(8043), 560–563.